Analyse donnees du PIM

Pierre Massé

April 25, 2020

1 Analyse des données du PIM

1.1 Extraction des données

1.1.1 Préambule technique

[1]:
```
# setting up sys.path for relative imports
from pathlib import Path
import sys
project_root = str(Path(sys.path[0]).parents[1].absolute())
if project_root not in sys.path:
    sys.path.append(project_root)
```

[2]:
```
# imports and customization of diplay
import io
import pandas as pd
pd.options.display.min_rows = 6
pd.options.display.width=108
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.ticker as ticker

from src.pimapi import Requester
```

1.1.2 Récupération des données

Le requêtage des données dans le PIM s'appuie sur la classe `Requester` du module pimapi.

[5]:
```
requester = Requester('prd')
# Let's fetch the full content of PIM system
requester.fetch_all_from_PIM()
requester.result
```

```
Done
```

[5]:
```
[<Response [200]>,
 <Response [200]>,
 <Response [200]>,
 <Response [200]>,
 <Response [200]>,
 <Response [200]>,
 <Response [200]>,
 <Response [200]>,
 <Response [200]>,
 <Response [200]>,
 <Response [200]>,
 <Response [200]>,
 <Response [200]>,
 <Response [200]>]
```

A ce stade, les données sont chargées en mémoire sous la forme de fichiers JSON. La conversion des données récupérées par l'API se fait via la méthode `result_to_dataframe` de la classe `Requester`.

[6]:
```
df = requester.result_to_dataframe()
df.head(4)
```

[6]:

uid	entity-type	repository	path	type	state	parentRef	isCheckedOut	isVersion	isProxy	changeToken	…	properties.pprodqmdd:manufacturingDiagram.length	properties.pprodqmdd:manufacturingDiagram.data	properties.pprodq:visualPhoto.name	properties.pprodq:visualPhoto.mime-type	properties.pprodq:visualPhoto.encoding
afee12c7-177e-4a68-9539-8cbb68442503	document	default	/default-domain/pomSupplierWorkspace/SICO/DEST…	pomProduct	product.waiting.supplier.validation	a58845c0-cab3-492f-b48d-531f146c3777	True	False	False	17-0	…	NaN	NaN	NaN	NaN	
7d390121-17e8-43bf-a357-9d06b79d2d47	document	default	/default-domain/pomSupplierWorkspace/UNILEVER_…	pomProduct	product.waiting.supplier.validation	a37abc27-f485-4ae9-921b-f761f16c8c1c	False	False	False	15-0	…	NaN	NaN	NaN	NaN	
f234cd84-c8f6-433f-85ec-6e0b6980adc6	document	default	/default-domain/pomSupplierWorkspace/AZTECA_FO…	pomProduct	product.waiting.supplier.validation	3ff7819a-a392-493f-beb8-0b323ac331c7	True	False	False	33-0	…	NaN	NaN	NaN	NaN	
e82a8173-b379-41ac-b319-aa058a04fcfb	document	default	/default-domain/pomSupplierWorkspace/UVCDR_-_C…	pomProduct	product.waiting.sending.supplier	e4b5167c-ece2-4f7a-83c1-fb884034a1bf	False	False	False	19-0	…	NaN	NaN	NaN	NaN	

```
uid
afee12c7-177e-4a68-9539-8cbb68442503                                    NaN
7d390121-17e8-43bf-a357-9d06b79d2d47                                    NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6                                    NaN
e82a8173-b379-41ac-b319-aa058a04fcfb                                    NaN

                                    properties.pprodq:visualPhoto.digestAlgorithm  \
uid
afee12c7-177e-4a68-9539-8cbb68442503                                             NaN
7d390121-17e8-43bf-a357-9d06b79d2d47                                             NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6                                             NaN
e82a8173-b379-41ac-b319-aa058a04fcfb                                             NaN

                                    properties.pprodq:visualPhoto.digest  \
uid
afee12c7-177e-4a68-9539-8cbb68442503                                  NaN
7d390121-17e8-43bf-a357-9d06b79d2d47                                  NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6                                  NaN
e82a8173-b379-41ac-b319-aa058a04fcfb                                  NaN

                                    properties.pprodq:visualPhoto.length  \
uid
afee12c7-177e-4a68-9539-8cbb68442503                                  NaN
7d390121-17e8-43bf-a357-9d06b79d2d47                                  NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6                                  NaN
e82a8173-b379-41ac-b319-aa058a04fcfb                                  NaN

                                     properties.pprodq:visualPhoto.data properties.notif:notifications
uid
afee12c7-177e-4a68-9539-8cbb68442503                                 NaN                              NaN
7d390121-17e8-43bf-a357-9d06b79d2d47                                 NaN                              NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6                                 NaN                              NaN
e82a8173-b379-41ac-b319-aa058a04fcfb                                 NaN                              NaN

[4 rows x 487 columns]
```

1.2 Définitions pour les mises en formes

1.2.1 Descriptifs longs

On définit un dictionnaire permettant de “traduire” les codes de champs en libellés long.

[7]:
```
lab = {
    'code': 'Code produit',
    'supplier': 'Code fournisseur',
    'type': 'Type de produit',
    'GTIN': 'GTIN',
    'base_unit': 'Unité de base',
    'net_weight': 'Poids net',
    'gross_weight': 'Poids brut',
    'dry_weight': 'Poids net égoutté',
    'volume': 'Volume',
    'total_life': 'Durée de vie totale',
    'remaining_life': 'Durée minimale restante',
    'type_cons': 'Type de conservation',
    'before_open': 'Conservation avant ouv.',
    'after_open': 'Convervation après ouv.',
    'cons_temp': 'Température',
}
```

1.2.2 Champs interessants

On liste également les champs intéressants pour un affichage plus court du dataframe.

[8]:
```
def_fields = {'properties.vig:code': 'code',
              'properties.psec:supplierCode': 'supplier',
```

```
            'properties.pprodtop:typeOfProduct': 'type',
            'properties.pprodi:gtin': 'gtin',
            'properties.pprodi:supplierDesignation': 'designation'}
```

1.3 Description des attributs des produit

1.3.1 Volumétrie des attributs

On constate que chaque produit porte un très grand nombre d'attributs :

[9]:
```
print('Count of columns in df:', len(df.columns))
print('\nInfo of df:')
df.info()
```

```
Count of columns in df: 487

Info of df:
<class 'pandas.core.frame.DataFrame'>
Index: 13193 entries, afee12c7-177e-4a68-9539-8cbb68442503 to 6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a
Columns: 487 entries, entity-type to properties.notif:notifications
dtypes: bool(12), float64(60), int64(2), object(413)
memory usage: 48.1+ MB
```

De plus, de par la nature hiérarchique du format JSON, certains attributs dits "multivalués" sont parfois stockés sous forme de liste dans le dataframe "à plat". Par exemple, on peut voir que le pays de transformation, ou les facettes, peuvent être multivalués.

[10]:
```
df.loc[['609af223-2f14-4f83-a553-cef276f2eca7',
        'c94013e4-0dca-441a-85c1-0b29ecb54d0a',
        '82d1af25-2bdd-4315-9670-67784b70dfa7'],
       ['properties.pprodg:transfoCountries',
        'facets']]
```

[10]:
```
                                                properties.pprodg:transfoCountries  \
uid
609af223-2f14-4f83-a553-cef276f2eca7                                    [PL, FR, ES]
c94013e4-0dca-441a-85c1-0b29ecb54d0a  [DE, NO, BE, RU, CH, BG, LT, GR, FR, UA, HU, E…
82d1af25-2bdd-4315-9670-67784b70dfa7                                          [FR]

                                                                              facets
uid
609af223-2f14-4f83-a553-cef276f2eca7  [Versionable, Folderish, Commentable, beginnin…
c94013e4-0dca-441a-85c1-0b29ecb54d0a  [endMigration, Versionable, Folderish, Comment…
82d1af25-2bdd-4315-9670-67784b70dfa7  [endMigration, Versionable, Folderish, Comment…
```

De plus, certains attributs sont dits "complexes", car chacune des valeurs de la liste est elle-même un dictionnaire d'attribut. La combinaison des deux, des attributs "complexes multivalués" existe également. On a alors une liste de dictionnaires. On peut comme ceci imbriquer des niveaux jusqu'à n'importe quelle profondeur.

C'est par exemple le cas des labels qui sont multivalués (un produit peut porter plusieurs labels), qui sont des complexes portant : - le type de label (bio, Label Rouge, …) - la date de fin de validité du label (si applicable) - le fichier de certification du label (si applicable), qui est lui-même un complexe…

[11]:
```
multilabel_ds = df.loc[df['properties.pprodl:labels'].apply(len) > 1, 'properties.pprodl:labels']
for uid, label_list in multilabel_ds.head(3).iteritems():
    print('product uid:', uid)
    for cpt, label in enumerate(label_list):
        print('\n\tlabel', cpt + 1, ':')
        for key, val in label.items():
            print('\t\t', key, ':', val)
    print('---------------------------------------')
```

```
product uid: 362e6230-ba3a-4396-8a47-728b0a1d56db

        label 1 :
                 labelCertificateEndDate : 2024-12-30T23:00:00.000Z
```

```
                typeOfLabel : 80
                labelCertificateFile : {'name': 'KCC Coleshill Tissue Paper Ecolabel Renewal Certificate
Mar 2020.pdf', 'mime-type': 'application/pdf', 'encoding': None, 'digestAlgorithm': 'MD5', 'digest':
'6615e3027ff2e014fdc3fa37e67851bb', 'length': '425662', 'data': 'https://produits.groupe-pomona.fr/nuxeo/nxf
ile/default/362e6230-ba3a-4396-8a47-728b0a1d56db/pprodl:labels/0/labelCertificateFile/KCC%20Coleshill%20Tiss
ue%20Paper%20Ecolabel%20Renewal%20Certificate%20Mar%202020.pdf?changeToken=36-0'}

        label 2 :
                labelCertificateEndDate : 2022-09-16T22:00:00.000Z
                typeOfLabel : NA
                labelCertificateFile : {'name': 'FCC_DoC_Coleshill Mill_PW_blue_Ref13351_Eng V01.pdf',
'mime-type': 'application/pdf', 'encoding': None, 'digestAlgorithm': 'MD5', 'digest':
'78cfcc67b8bf0f693e060088f7d97c48', 'length': '84473', 'data': 'https://produits.groupe-pomona.fr/nuxeo/nxfi
le/default/362e6230-ba3a-4396-8a47-728b0a1d56db/pprodl:labels/1/labelCertificateFile/FCC_DoC_Coleshill%20Mil
l_PW_blue_Ref13351_Eng%20V01.pdf?changeToken=36-0'}
--------------------------------------
product uid: 3c2a8d1a-634d-40bb-9852-81eb8a340114

        label 1 :
                labelCertificateEndDate : None
                typeOfLabel : 30
                labelCertificateFile : None

        label 2 :
                labelCertificateEndDate : None
                typeOfLabel : 40
                labelCertificateFile : None
--------------------------------------
product uid: d3681e26-b024-4603-ae0b-0d5630329fa0

        label 1 :
                labelCertificateEndDate : 2020-03-30T22:00:00.000Z
                typeOfLabel : 100
                labelCertificateFile : {'name': 'SAS - Certificat AB V2.pdf', 'mime-type':
'application/pdf', 'encoding': None, 'digestAlgorithm': 'MD5', 'digest': '1d424d2d2c9539abca07b8ad9576a339',
'length': '128780', 'data': 'https://produits.groupe-pomona.fr/nuxeo/nxfile/default/d3681e26-b024-4603-ae0b-
0d5630329fa0/pprodl:labels/0/labelCertificateFile/SAS%20-%20Certificat%20AB%20V2.pdf?changeToken=92-0'}

        label 2 :
                labelCertificateEndDate : 2020-03-30T22:00:00.000Z
                typeOfLabel : 80
                labelCertificateFile : {'name': 'SAS - Certificat AB V2.pdf', 'mime-type':
'application/pdf', 'encoding': None, 'digestAlgorithm': 'MD5', 'digest': '1d424d2d2c9539abca07b8ad9576a339',
'length': '128780', 'data': 'https://produits.groupe-pomona.fr/nuxeo/nxfile/default/d3681e26-b024-4603-ae0b-
0d5630329fa0/pprodl:labels/1/labelCertificateFile/SAS%20-%20Certificat%20AB%20V2.pdf?changeToken=92-0'}
--------------------------------------
```

1.3.2 Description des principaux attributs

On commence par déclarer des utilitaires permettant de mettre en forme les représentations.

[12]:
```python
# Defining main data to explore
mappings = {
    'identification': {
      'properties.vig:code': 'code',
      'properties.psec:supplierCode': 'supplier',
      'properties.pprodtop:typeOfProduct': 'type',
      'properties.pprodi:gtin': 'GTIN',
    },
    'dimensions': {
        'properties.pprodtop:baseUnit': 'base_unit',
        'properties.pprodg:netWeight': 'net_weight',
        'properties.pprodg:grossWeight': 'gross_weight',
        'properties.pprodg:dryWeight': 'dry_weight',
        'properties.pprodg:volume': 'volume',
    },
    'conservation': {
```

```
        'properties.pprodg:totalLife': 'total_life',
        'properties.pprodg:guaranteedLife': 'remaining_life',
        'properties.pprodq:typeOfConservation': 'type_cons',
        'properties.pprodq:conservationBeforeOpening': 'before_open',
        'properties.pprodq:conservationAfterOpening': 'after_open',
        'properties.pprodq:conservationTemperature': 'cons_temp',
    }
  }

# Helper function to transform pandas `to_latex` method output to a tabularx env instead.
def to_tabularx(stringio):
    text = stringio.getvalue()
    text = text.replace(r'\begin{tabular}', r'\begin{tabularx}{\linewidth}')
    text = text.replace(r'\end{tabular}',r'\end{tabularx}')
    return(text)

# Function that saves dataframe as Latex tabularx files as input
def save_to_disk(df, path, lab=lab, tex_label=None):
    text = io.StringIO()
    c_format = 'l' + 'X' * len(df.columns)
    (df.rename(lab, axis=1)
       .to_latex(text,
                 bold_rows=True,
                 column_format=c_format,
                 na_rep='-',
                 label=tex_label,
                 ))
    with open(path, mode='w') as file:
        file.write(to_tabularx(text))
```

On boucle sur les différents mappings, et on les sauvegardes dans des tableaux latex pour intégration au rapport.

[13]:
```
for map_type, mapping in mappings.items():
    cur_df = df.loc[:, list(mapping.keys())].rename(mapping, axis=1).fillna(np.nan)
    desc = cur_df.describe(include='all')
    samp = cur_df.sample(n=5, random_state=42)
    print(map_type)
    print(samp.rename(lab, axis=1))
    print('-------------------------------------------------')
    print(desc.rename(lab, axis=1)
              .round(3)
         )
    print('-------------------------------------------------')

    # Writing dataframes to .tex files
    text = io.StringIO()
    c_format = 'l' + 'X' * len(cur_df.columns)
    (samp.rename(lab, axis=1)
         .to_latex(text,
                   bold_rows=True,
                   column_format=c_format,
                   na_rep='-'
                   ))
    with open(Path('..') / 'tbls' / ('Exemple '+ map_type +'.tex'), mode='w') as file:
        file.write(to_tabularx(text))

    text = io.StringIO()
    (desc.rename(lab, axis=1)
         .round(3)
         .to_latex(text,
                   bold_rows=True,
                   column_format=c_format,
                   na_rep='-'
                   ))
    with open(Path('..') / 'tbls' / ('Desc '+ map_type +'.tex'), mode='w') as file:
        file.write(to_tabularx(text))
```

identification

uid	Code produit	Code fournisseur	Type de produit	GTIN
1351c135-0d48-41ae-a568-2f33af6fdae9	PIMP-0000011253	PIMF-0000000416	grocery	3760063337099
ffabf67f-314e-47a8-932e-37da7a3ab1ae	PIMP-0000011972	PIMF-0000000486	hygiene	NaN
7bb3d9a9-d50c-4042-9d28-21b31f5cbbb1	PIMP-0000009973	PIMF-0000000328	alcoholicDrink	NaN
38b95b6e-5603-46bd-ad44-912a926ee0e4	PIMP-0000012507	PIMF-0000000391	chemistry	7615400045495
8738c768-9d5d-4233-b54c-99358fa66411	PIMP-0000000321	PIMF-0000000074	hygiene	3504082216054

	Code produit	Code fournisseur	Type de produit	GTIN
count	13193	13193	13193	12025
unique	13193	605	5	11339
top	PIMP-0000000721	PIMF-0000000179	grocery	
freq	1	370	8756	352

---

dimensions

uid	Unité de base	Poids net	Poids brut	Poids net égoutté	Volume
1351c135-0d48-41ae-a568-2f33af6fdae9	SAC	0.500	0.520	NaN	NaN
ffabf67f-314e-47a8-932e-37da7a3ab1ae	PU	NaN	NaN	NaN	NaN
7bb3d9a9-d50c-4042-9d28-21b31f5cbbb1	BIB	1.500	1.600	NaN	1.5
38b95b6e-5603-46bd-ad44-912a926ee0e4	BT.	1.053	1.150	NaN	NaN
8738c768-9d5d-4233-b54c-99358fa66411	COL	3.000	3.028	NaN	NaN

	Unité de base	Poids net	Poids brut	Poids net égoutté	Volume
count	13193	12827.000	12827.000	1026.000	1915.000
unique	30	NaN	NaN	NaN	NaN
top	BTE	NaN	NaN	NaN	NaN
freq	3051	NaN	NaN	NaN	NaN
mean	NaN	3.112	2.986	1.475	7.750
std	NaN	59.600	42.171	1.133	78.897
min	NaN	0.000	0.000	0.000	0.000
25%	NaN	0.482	0.535	0.480	0.500
50%	NaN	1.000	1.100	1.500	0.946
75%	NaN	3.000	3.298	2.380	2.500
max	NaN	4900.000	4730.500	10.000	3100.000

---

conservation

uid	Durée de vie totale	Durée minimale restante	Type de conservation	\
1351c135-0d48-41ae-a568-2f33af6fdae9	NaN	720.0	AM	
ffabf67f-314e-47a8-932e-37da7a3ab1ae	NaN	NaN	NaN	
7bb3d9a9-d50c-4042-9d28-21b31f5cbbb1	NaN	NaN	AM	
38b95b6e-5603-46bd-ad44-912a926ee0e4	NaN	NaN	AM	
8738c768-9d5d-4233-b54c-99358fa66411	NaN	NaN	AM	

uid	Conservation avant ouv.	Convervation après ouv.	Température
1351c135-0d48-41ae-a568-2f33af6fdae9	ambientTemperature	coolAndDryPlace	NaN
ffabf67f-314e-47a8-932e-37da7a3ab1ae	NaN	NaN	NaN
7bb3d9a9-d50c-4042-9d28-21b31f5cbbb1	ambientTemperature	notConcerned	NaN
38b95b6e-5603-46bd-ad44-912a926ee0e4	NaN	NaN	NaN
8738c768-9d5d-4233-b54c-99358fa66411	NaN	NaN	NaN

	Durée de vie totale	Durée minimale restante	Type de conservation	Conservation avant ouv.	\
count	8946.000	9466.000	12806	9977	
unique	NaN	NaN	2	7	
top	NaN	NaN	AM	ambientTemperature	
freq	NaN	NaN	12772	8270	
mean	651.406	351.618	NaN	NaN	
std	487.412	380.255	NaN	NaN	
min	0.000	0.000	NaN	NaN	
25%	360.000	180.000	NaN	NaN	
50%	540.000	300.000	NaN	NaN	
75%	900.000	480.000	NaN	NaN	
max	9999.000	9999.000	NaN	NaN	

	Convervation après ouv.	Température

```
count                     9947          21
unique                      18           9
top           coolAndDryPlace          15
freq                      4512           6
mean                       NaN         NaN
std                        NaN         NaN
min                        NaN         NaN
25%                        NaN         NaN
50%                        NaN         NaN
75%                        NaN         NaN
max                        NaN         NaN
--------------------------------------------------
```

1.3.3 Analyses spécifiques : GTIN

On peut mettre en évidence les produits qui portent les mêmes GTIN en double. En y jetant un oeil rapide, quelques explications peuvent être trouvées : - il peut s'agir d'un changement de code fournisseur (les 2 premières lignes ne portent pas le même code fournisseur) - il peut s'agir d'un changement de recette côté industriel, qui a décidé de conserver le même GTIN (second couple) - il peut s'agir d'une erreur, et de produits en doublon dans le système (troisième couple) - …

[14]:
```
GTIN_mask = (df['properties.pprodi:gtin'] != '') & ~(pd.isna(df['properties.pprodi:gtin']))
dups_mask = df.loc[GTIN_mask, 'properties.pprodi:gtin'].duplicated(keep=False)
examples = (df.loc[GTIN_mask & dups_mask, def_fields.keys()]
              .rename(def_fields, axis=1)
              .sort_values('gtin')
              .head(8))
save_to_disk(examples,
             Path('..') / 'tbls' / 'Duplicated_GTIN.tex',
             lab={},
             tex_label='tab:dup_gtin',
            )
print(examples)
```

```
                                          code         supplier     type            gtin  \
uid
048712e3-f145-4f40-b8ad-7c0b912983bd  PIMP-0000009515  PIMF-0000000420  grocery   0020176760607
4de8ce87-8df5-440c-959d-3d77d59bb4f3  PIMP-0000013159  PIMF-0000000182  grocery   0020176760607
7e455046-def3-4526-a28b-bc5c0e6e64fc  PIMP-0000011456  PIMF-0000000290  grocery  03344540125906
a92c6ac5-d5be-4f92-98b3-9f6c588f7613  PIMP-0000013198  PIMF-0000000290  grocery  03344540125906
66590f04-5eae-4829-b0da-c899a18dd9cb  PIMP-0000010839  PIMF-0000000250  grocery   3011360083845
27e20042-dc53-46b4-874c-f970db554aec  PIMP-0000001494  PIMF-0000000250  grocery   3011360083845
02803e27-487a-43e3-9324-9ad1660b63b2  PIMP-0000002338  PIMF-0000000348  grocery   3038353024906
52d3f309-e402-4931-974c-b6b6fa721aff  PIMP-0000002337  PIMF-0000000348  grocery   3038353024906

                                                                    designation
uid
048712e3-f145-4f40-b8ad-7c0b912983bd                          42 QUICHE FEUILL SG 11CM
4de8ce87-8df5-440c-959d-3d77d59bb4f3                                QUICHE FEUILLETEE
7e455046-def3-4526-a28b-bc5c0e6e64fc     622028 SAUCE FUEGO SQUEEZE DE 580 G "O'TACOS"
a92c6ac5-d5be-4f92-98b3-9f6c588f7613  622029 SAUCE FUEGO (NR) SQUEEZE DE 580 G "O'TA…
66590f04-5eae-4829-b0da-c899a18dd9cb                 Jus de poulet en boîte 750g KNORR
27e20042-dc53-46b4-874c-f970db554aec                Jus de poulet en boîte 750 g KNORR
02803e27-487a-43e3-9324-9ad1660b63b2                Torti aux œufs en sac 5 kg PANZANI
52d3f309-e402-4931-974c-b6b6fa721aff        Tagliatelle aux œufs en colis 5 kg PANZANI
```

Si l'on produit la répartition du nombre de produit portant un GTIN donné dans le système, on obtient :

[15]:
```
df2 = (df.pivot_table(values='properties.vig:code',
                      index='properties.pprodi:gtin',
                      aggfunc='count')
       .rename({'properties.vig:code': 'code_count'}, axis=1)
      )

df2 = (df2.reset_index()
          .loc[df2.index != '']
          .pivot_table(index='code_count',
                       aggfunc='count',
```

```
                      values='code_count')
          .rename({'properties.pprodi:gtin': 'Nb de GTIN'},
                  axis=1)
)

df2.index.rename('Pdt portant le GTIN', inplace=True)

print(df2)

save_to_disk(df2,
             Path('..') / 'tbls' / 'gtin_counts.tex')

fig, ax = plt.subplots(figsize=(5,3))
df2.plot(kind='bar', legend=None, title='Nombre de produit par GTIN', ax=ax)
fig.savefig(Path('..') / 'img' / 'repartition_gtin.png', bbox_inches='tight')
```

```
                    Nb de GTIN
Pdt portant le GTIN
1                        11068
2                          227
3                           22
4                           20
5                            1
```

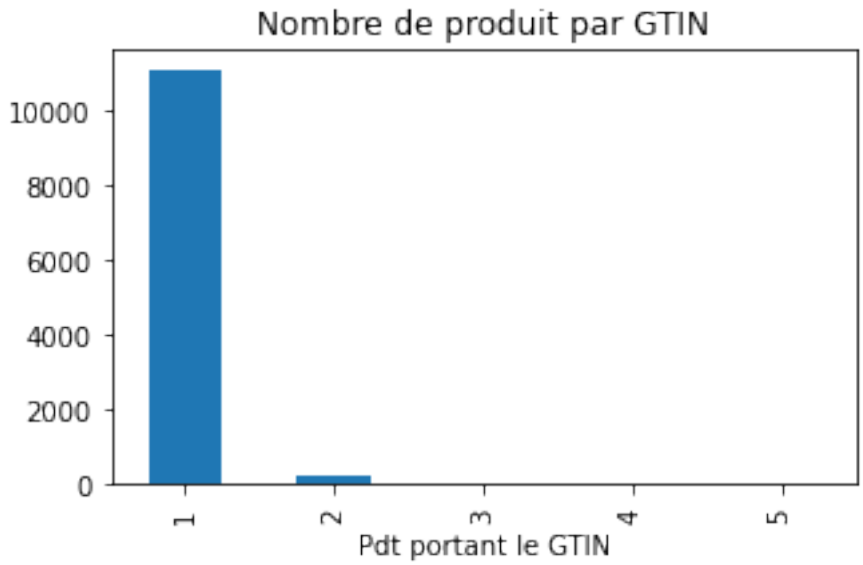

1.3.4 Analyse spécifique : distribution par fournisseur

On peut représenter la distribution produit, par fournisseur.

[16]:
```
# construction the counts
counts = (df.loc[:, list(def_fields.keys())]
            .rename(def_fields, axis=1)
            .pivot_table(values='code',
                         index='supplier',
                         aggfunc='count')
            .reset_index()
            .pivot_table(values=['supplier', 'code'],
                         index='code',
                         aggfunc={'supplier': 'count',
                         'code': 'sum'})
)
```

```
# aligning index to have it countinuous
new_idx = pd.RangeIndex(start=1, stop=max(counts.index) + 1)

counts = (counts.reindex(new_idx)
                .fillna(0)
)

counts = pd.concat([counts,
                    counts.cumsum().rename({'code': 'cum_code', 'supplier': 'cum_supplier'},
                                           axis=1),
                   ],
                   axis=1)

for feature in ['supplier', 'code']:
    counts['cump_' + feature] = 100 * counts['cum_' + feature] / counts.loc[:, 'cum_' + feature].iloc[-1]

counts
```

[16]:

	code	supplier	cum_code	cum_supplier	cump_supplier	cump_code
1	79.0	79.0	79.0	79.0	13.057851	0.598802
2	138.0	69.0	217.0	148.0	24.462810	1.644812
3	177.0	59.0	394.0	207.0	34.214876	2.986432
..	…	…	…	…	…	…
368	0.0	0.0	12454.0	603.0	99.669421	94.398545
369	369.0	1.0	12823.0	604.0	99.834711	97.195482
370	370.0	1.0	13193.0	605.0	100.000000	100.000000

[370 rows x 6 columns]

[17]:
```
fig, axs = plt.subplots(nrows=2,
                        ncols=2,
                        figsize=(14, 6),
                        gridspec_kw= {'width_ratios': [2, 1]})

axs2 = [[ax.twinx() for ax in axrow] for axrow in axs]

for i, feature in enumerate(['supplier', 'code']):
    axs[i][0].bar(data=counts.loc[:, feature].reset_index(), x='index', height=feature)
    axs2[i][0].plot('index', 'cump_' + feature, data=counts.loc[:, 'cump_' + feature].reset_index(),
                    color='red', linestyle='--')
    axs2[i][0].grid(True, axis='y', color='red', alpha=0.5, linestyle='--')

    axs[i][1].bar(data=counts.loc[:, feature].reset_index(), x='index', height=feature)
    axs2[i][1].plot('index', 'cump_' + feature, data=counts.loc[:, 'cump_' + feature].reset_index(),
                    color='red', linestyle='--')
    axs2[i][1].grid(True, axis='y', color='red', alpha=0.5, linestyle='--')

    axs[i][1].set_xlim(0, 30)

for i in range(len(axs)):
    for j in range(len(axs[i])):
        axs2[i][j].set_ylim(0, 100)
        # remove all bottom ticks except for bottom line
        # set_yticks does not work as it removes the grid
        if i < len(axs) - 1:
            axs[i][j].set_xticklabels([])
            for tic in axs[i][j].xaxis.get_major_ticks():
                tic.tick1line.set_visible(False)
                tic.tick2line.set_visible(False)
        # remove all right ticks except for right column
        # set_yticks does not work as it removes the grid
        if j < len(axs[i]) - 1:
            axs2[i][j].set_yticklabels([])
            for tic in axs2[i][j].yaxis.get_major_ticks():
                tic.tick1line.set_visible(False)
                tic.tick2line.set_visible(False)
```

```
        # remove all left ticks except for first column
        if j > 0:
            axs[i][j].set_yticks([])
        if j == len(axs[i]) - 1:
            axs2[i][j].tick_params(axis='y', colors='red')
            axs2[i][j].yaxis.set_major_formatter(ticker.PercentFormatter())
            axs2[i][j].set_ylabel('Proportion en cumul', color='red')
            axs[i][j].grid(True, axis='x', color='k', alpha=0.5, linestyle='--')
        if j == 0:
            axs[i][j].tick_params(axis='y', colors='blue')
            if i == 0:
                axs[i][j].set_ylabel('Nombre de fournisseurs', color='blue')
            if i == 1:
                axs[i][j].set_ylabel('Nombre de produits représentés', color='blue')
axs[1][0].set_xlabel('Nombre de produit par fournisseur',
                     fontsize=12,
                     labelpad=8,
                    )
axs[1][1].set_xlabel('Focus sur les fournisseurs à 30 produits ou moins',
                     fontsize=12,
                     labelpad=8,
                    )

fig.suptitle('Distribution des fournisseurs fonction du nombre de produit par fournisseur',
             fontsize=16,
            )

fig.savefig(Path('..') / 'img' / 'distribution_fournisseurs_par_prd_count.png', bbox_inches='tight')
```

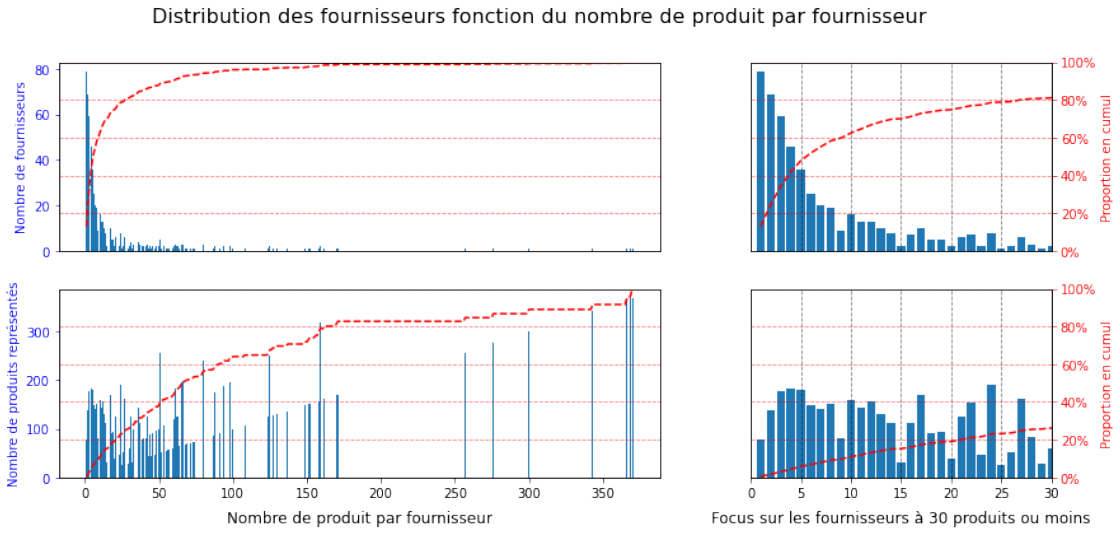

On peut également représenter le nombre de produits “récupérés” si on prend les fournisseurs par nombre de produits décroissant.

[18]:
```
# construction the counts
counts = (df.loc[:, list(def_fields.keys())]
            .rename(def_fields, axis=1)
            .pivot_table(values='code',
                         index='supplier',
                         aggfunc='count')
            .sort_values('code', ascending=False)
)
counts['code_cumsum'] = counts['code'].cumsum()
counts
```

[18]:
```
                 code  code_cumsum
supplier
PIMF-0000000179   370          370
PIMF-0000000250   369          739
PIMF-0000000283   366         1105
…                 …            …
PIMF-0000000408     1        13191
PIMF-0000000407     1        13192
PIMF-0000000666     1        13193

[605 rows x 2 columns]
```

[19]:
```
fig, axs = plt.subplots(nrows=1,
                        ncols=2,
                        figsize=(14, 3),
                        gridspec_kw= {'width_ratios': [2, 1]})

for j in range(len(axs)):
    axs[j].plot('index',
                'code_cumsum',
                data=counts.reset_index().reset_index(),
                color='red',
                linestyle='--',
               )
    axs[j].set_xlabel('Nombre de fournisseurs', fontsize=12)
    axs[j].set_ylim(0)
    axs[j].set_xlim(0)
    axs[j].grid(True)
    axs[j].yaxis.set_ticks(np.arange(0, 14000, 1000))

axs[0].set_ylabel('Nombre de produits cumulés')
axs[1].set_xlim(0, 30)
axs[1].set_xlabel('Nombre de fournisseurs (limite 30)', fontsize=12)
axs[1].set_yticklabels([])
for tic in axs[1].yaxis.get_major_ticks():
    tic.tick1line.set_visible(False)
    tic.tick2line.set_visible(False)

fig.suptitle('"Rappel" des produits en fonction des fournisseurs', fontsize=16)

fig.savefig(Path('..') / 'img' / 'rappel_produit_par_fournisseur.png', bbox_inches='tight')
```