

Extraction des ingrédients depuis les fiches techniques de produits alimentaires

Pierre MASSÉ

Juin 2020

Résumé

La gestion de l'information produit est devenue un enjeu de société majeur ces dernières années. Les scandales sanitaires récents ont déclenché une prise de conscience collective des consommateurs, en parallèle de la mise en place de réglementations de plus en plus contraignantes pour l'ensemble des acteurs de la filière [3][4].

La construction et le déploiement d'outils mettant en oeuvre les principes du Machine Learning appliqués au traitement du langage permettrait d'aider les opérationnels de la gestion de l'information à interpréter plus vite et mieux les documents mis à disposition par les fournisseurs du groupe. Le présent rapport détaille la mise en place d'un outil permettant d'extraire les listes d'ingrédients des fiches techniques transmises par les fabricants des produits.

Dans une première partie, on explicitera les objectifs et le cas d'usage retenu. Nous analyserons ensuite les données disponibles, et la manière de les exploiter. La troisième partie sera consacrée à la construction du modèle à proprement parler, et la dernière partie portera un regard critique sur les résultats obtenus et ouvrira la réflexion sur les travaux à venir.

TABLE DES MATIÈRES

I Les objectifs de ce projet	5
1 Les cas d'usage	5
1.1 Objectifs : Qualité et productivité	5
1.2 La préalimentation d'information	5
1.3 Le contrôle des informations transmises	6
1.3.1 Le contrôle à la saisie fournisseur	6
1.3.2 L'aide aux vérifications Pomona	6
1.3.3 Les contrôles en masse asynchrones	6
2 Présentation rapide des données relatives au cas d'usage	8
2.1 Les listes d'ingrédients	8
2.2 Pièces jointes	9
2.2.1 Fiches techniques fournisseur	9
2.2.2 Étiquettes produit	11
2.3 Récapitulatif de la complétude des données	12
2.3.1 Complétude des listes d'ingrédients	12
2.3.2 Complétude des pièces jointes	12
2.4 Les données « manuellement étiquetées »	13
2.4.1 Pour répondre à quel besoin ?	13
2.4.2 Mode de constitution de l'échantillon	13
2.4.3 Méthodologie de l'étiquetage manuel	13
2.4.4 Règles de gestion pour l'étiquetage manuel	14
2.4.5 Confrontation avec le contenu du PIM	14
3 Le choix du cas d'usage	14
3.1 Étiquettes contre fiches techniques	14
3.1.1 La représentation dominante des fiches techniques	14
3.1.2 L'extraction de données textuelles	14
3.2 Impossibilité de produire des templates pour l'exploitation de ces documents	16
3.3 Quelles données ?	17
3.3.1 Les principales données et leur mode de présentation dans les fiches techniques	17
3.3.2 L'identification d'une liste d'ingrédient par son contenu	17
3.4 Quels produits ?	18
3.5 Conclusion quant au choix du cas d'usage	18
II Analyse des données textuelles	19
4 Caractéristiques générales du jeu de données	19
4.1 Volumétrie	19
4.2 Distributions des longueurs des textes	19
5 Analyse textuelle	21
5.1 Mots de chacun des corpus	21
5.2 Répartitions des mots dans et hors des listes d'ingrédients	21
5.3 Représentations graphiques des textes et mots	23
5.3.1 Vectorisation des mots	23
5.3.2 Vectorisation des textes	25

III Construction du modèle	29
6 Prototypage	29
6.1 Premier prototype : modèle simple « ouvert »	29
6.1.1 Principes généraux	29
6.1.2 Entraînement	30
6.1.3 Prédiction	31
6.1.4 Illustration des résultats obtenus	32
6.2 Second prototype : industrialisation	34
6.2.1 Chargement des données manuellement étiquetées	35
6.2.2 Découpage des textes en blocs	36
6.2.3 Entrainement et prédiction	37
6.2.4 Illustration des prédictions obtenues	37
7 Mesure de la performance	40
7.1 Accuracy	40
7.1.1 Approche naïve	40
7.1.2 Avec du « text-postprocessing »	42
7.2 Fonctions de « similarité » spécifiques	44
7.2.1 Similarité basée sur la distance de Levenshtein	44
7.2.2 Similarité basée sur la distance de Damerau-Levenshtein	45
7.2.3 Similarité de Jaro	45
7.2.4 Similarité de Jaro-Wrinkler	45
7.2.5 Évaluation de ces similarités sur la ground truth	45
7.2.6 Décision sur la métrique à utiliser et illustration	46
7.2.7 Performance en fonction de la longueur de la liste d'ingrédients	46
8 Ajustement des paramètres	48
8.1 Description des paramètres ajustables	48
8.1.1 Text-preprocessing	48
8.1.2 Découpage du texte des documents en blocs	48
8.1.3 Vectorisation des textes	49
8.1.4 Calcul de similarité	49
8.2 Ajustements et résultats	52
8.2.1 Ajustement du text-preprocessing	52
8.2.2 Tuning du découpage du texte des documents	53
8.2.3 Comparatif des fonctions de similarité	53
8.2.4 Comparaison des méthodes de vectorisation	56
8.2.5 Utilisation d'embeddings	60
8.3 Conclusion, et évaluation finale de la performance	62
IV Travaux subséquents	64
9 Extension des fonctionnalités offertes	64
9.1 Amélioration de la performance du modèle	64
9.1.1 Découpage du contenu des documents en blocs de textes	64
9.1.2 Amélioration de l'identification par similarité	65
9.1.3 Filtrage des similarités trop basses	65
9.2 Extension du périmètre couvert avec la méthode « textuelle »	66
9.2.1 Prise en compte de nouveaux types de pièces jointes	66
9.2.2 Utilisation d'outil d'OCR pour les pdf non structurés	66
9.2.3 Évaluation de la performances sur d'autres familles de produits	66
9.2.4 Récupération des dénominations réglementaires	67
9.3 Changement de méthode	67

9.3.1	Mise en place d'outil de spatialisation des textes	67
9.3.2	Aides pour le contrôle de cohérence	67
10	Déploiement opérationnel de l'outil	68
10.1	Mise en place d'une organisation projet	68
10.1.1	Sponsor et Client	68
10.1.2	Choix techniques et technologiques	68
10.1.3	Développement microservice ?	69
10.2	Maintien en condition opérationnelle	70
10.2.1	Mise à niveau	70
10.2.2	Intégration et déploiement continu	70
10.2.3	Monitoring de la performance du modèle	70
V	Annexes	72
A	Figures, tableaux et bibliographie	72
B	Contexte métier : le groupe, information produit et généralités sur les données	76
B.1	Description du groupe	76
B.1.1	Le métier du Groupe Pomona	76
B.1.2	La décentralisation	77
B.2	La gestion de l'information produit	81
B.2.1	L'information produit	81
B.2.2	Le processus	87
B.2.3	Les outils informatiques associés	92
C	Le périmètre produit	97
C.1	Les produits non-alimentaires	97
C.2	Accessibilité de la donnée en fonction des branches	98
C.3	Analyses quantitatives	98
C.3.1	Comparatifs entre les branches	98
C.3.2	Les grands types de produits	99
D	Les données utilisables, issues du PIM	100
D.1	Données structurées	103
D.1.1	Description des données structurées	103
D.1.2	Analyse de ces données structurées	104
D.2	Données non structurées	110
D.2.1	Les libellés	110
D.3	Analyse qualitative des données	110
D.3.1	Évaluation de la qualité des données	110
D.3.2	Types de pdf possédés	111
E	Exemples de pièces jointes et ground truth	111
E.1	Fiches techniques	111
E.1.1	Fiche technique sel Cerebos	112
E.1.2	Fiche technique olives Valtonia	113
E.1.3	Fiche technique Panna Cotta Nestlé	114
E.1.4	Fiche technique confiture Andros	116
E.1.5	Fiche technique ciboulette La case aux épices	118
E.1.6	Fiche technique poivron El Arenal	120
E.1.7	Fiche technique mélange trappeur Terre Exotique	123
E.2	Étiquettes produit	124
E.2.1	Étiquette curry Grain d'ailleurs	124

E.2.2	Étiquette madeleines Saint Michel	125
E.2.3	Étiquette lentilles Soufflet	126
E.2.4	Étiquette pannacotta Nestlé	127
E.2.5	Étiquette sauce soja Kikkoman	128
E.2.6	Étiquette mélange trappeur Terre Exotique	129
E.3	Étiquetage manuel des données	130
E.3.1	Règles de gestion pour l'étiquetage	130
F	Résultats du modèle retenu	134
G	Les notebooks de ce projet	139
G.1	Génération de l'échantillon de données manuellement étiquetées	140
G.2	Modèle « ouvert »	168
G.3	Modèle basé sur les données manuellement étiquetées	176
G.4	Mesure de la performance	189
G.5	Ajustement des paramètres du modèle	203
G.6	Analyse quantitative	245
G.7	Analyse des données du PIM	255
H	Le code des différents modules	277
H.1	Gestion du fichier de configuration - Module conf	277
H.2	Extraction des données du PIM - Module pimapi	277
H.3	Conversion des pièces jointes en textes - Module pimpdf	277
H.4	Transformateurs et estimateurs spécifiques - Module pimest	277

Première partie

LES OBJECTIFS DE CE PROJET

L'objet de ce mémoire est de présenter si et comment le machine learning pourrait appuyer le Groupe Pomona dans la gestion des informations produit qu'il commercialise. Le groupe et sa gestion de l'information produit sont présentés en annexe B.1.1 page 76.

Chapitre 1

LES CAS D'USAGE

1.1 Objectifs : Qualité et productivité

La gestion de l'information produit est un processus lourd, avec des étapes de contrôle redondantes visant à assurer la qualité de la donnée (cf. annexe B.2.2 page 90), en particulier la cohérence des informations transmises avec le contenu des pièces jointes mises à disposition. Un traitement automatique des documents mis à disposition permettrait de décharger les personnes qui interviennent dans le processus (fournisseurs, acheteurs, gestionnaires de référentiels, ingénieurs qualité) et de garantir une meilleure pertinence de l'information produit.

1.2 La préalimentation d'information

Une des manières de gagner en productivité et en qualité serait :

- de modifier l'interface homme machine de l'écran de saisie des données par le fournisseur, pour que le chargement des pièces jointes se fasse en premier
- d'interpréter le contenu des pièces jointes dès qu'elles sont chargées, pour alimenter les autres champs de saisie
- laisser ensuite au fournisseur la possibilité de compléter et corriger ces informations avant de les soumettre à Pomona

Il est illusoire d'automatiser totalement la saisie et d'imaginer se passer d'une saisie complémentaire par le fournisseur. La mise en place de la GDSN (cf. section B.2.3 page 95), qui permet pourtant de faire transiter par EDI les données produit de manière standardisée et efficace, n'a pas permis de s'affranchir de cette tâche. Sous réserve d'avoir un outil suffisamment fiable, on pourrait faire gagner du temps aux fournisseurs et améliorer la qualité de l'information produit. Néanmoins, plusieurs freins existent à la mise en place

- cela n'a d'intérêt que si le système est capable de produire de l'information structurée avec une fiabilité élevée (par exemple, 80% de données correctes serait un minimum)
- cela entre en concurrence directe avec le système GDSN - avec la question de la manière de gérer les conflits entre les informations issues de ce réseau et celles extraites des pièces jointes
- cela apporte l'essentiel de la valeur aux fournisseurs, et pas au groupe

1.3 Le contrôle des informations transmises

Plus le taux de détection des erreurs est élevé, et plus les erreurs sont détectées tôt, mieux c'est :

- la qualité des données s'en trouve évidemment améliorée
- le processus est plus court en temps, en évitant les aller-retours
- on décharge l'ensemble des acteurs, en limitant le nombre d'interventions de chacun, ainsi que la charge administrative de synchronisation de leurs actions

Les différentes étapes possibles pour lesquelles effectuer un contrôle sont présentées à la FIGURE 1 page 7.

1.3.1 Le contrôle à la saisie fournisseur

Si on déclenche un contrôle au moment où le fournisseur soumet les données et qu'on l'alerte en cas d'incohérence, on peut dès le début du processus éviter une erreur. L'avantage d'avoir une identification des problèmes aussi tôt est qu'on économise immédiatement au moins une étape de contrôle des données.

1.3.2 L'aide aux vérifications Pomona

Lors des contrôles inclus au sein du processus, on pourrait mettre en évidence les incohérences détectées entre pièces jointes et données à contrôler. Cela permettrait de fiabiliser les étapes de contrôle, et éviter qu'une erreur soit détectée tardivement (par les gestionnaires de référentiel ou les ingénieurs qualité). C'est d'autant plus intéressant que la première étape de contrôle est faite par les acheteurs. Dans la mesure où c'est une tâche administrative qui n'est pas dans leur cœur de métier, elle est souvent effectuée rapidement et est peu efficace.

1.3.3 Les contrôles en masse asynchrones

Enfin, il pourrait être pertinent de faire tourner de manière asynchrone des contrôles de qualité de données sur l'ensemble de la base. Il pourrait sembler inutile d'effectuer cette tâche alors qu'on a une validation des




FIGURE 1 – Étapes du processus article pouvant être améliorées

données par l'application (contrôles « informatiques ») et par des contrôleurs humains. Néanmoins, il arrive fréquemment que des changements de règles de gestion informatiques ou métier soit mis en place, sans que les données soient ensuite remises à jour. Par exemple, les mentions des traces d'allergènes dans les ingrédients était par le passé retirées des listes d'ingrédients, alors qu'elles sont aujourd'hui incluses. Mais aucun chantier de remise à niveau de l'historique n'a été entrepris au moment du changement de règle, d'où des données qui ne sont pas alignées avec les règles de gestion.

Chapitre 2

PRÉSENTATION RAPIDE DES DONNÉES RELATIVES AU CAS D'USAGE

2.1 Les listes d'ingrédients

Une information produit dont l'exactitude est critique sont les listes d'ingrédients. La construction des listes d'ingrédients doit suivre les règles suivantes, même si l'application n'est pas toujours parfaitement respectée :

- elle doit détailler l'ensemble des ingrédients, y compris les additifs et les arômes
- elle doit être triée par ordre d'importance pondérale décroissante (i.e. les ingrédients les plus représentatifs en poids doivent être cités en premier)
- la quantité de certains ingrédients (en pourcentage de la masse) par exemple ceux mis en valeur sur l'étiquetage ou dans la dénomination de vente (ex. gâteau aux fraises, pizza au jambon)

Même s'il ne s'agit pas d'une exigence réglementaire, le Groupe Pomona demande à ses fournisseurs de ne pas distinguer les ingrédients par phase comme cela se fait parfois. Cela signifie, par exemple, séparer une partie de la composition du produit (la pâte de la garniture pour une tarte, la sauce et les raviolis, ...). De telles pratiques peuvent parfois induire le consommateur en erreur, comme par exemple dans la liste d'ingrédients suivante (s'applique à des chips de légumes) :

Légumes 64% (betterave, panais, carottes, patates douces), huile de tournesol, sel marin.

Sans l'artifice d'avoir regroupé les légumes en une seule phase, le premier ingrédient de la liste aurait pu être l'huile de tournesol, qui est un ingrédient moins attractif pour un consommateur de chips de légumes.

Quelques exemples de listes d'ingrédients sont présentées à la TABLE 1 page 9.

Les contraintes ci-dessus s'appliquant aux listes d'ingrédients font qu'en général, il s'agit d'une énumération d'ingrédients, sans doublon.

Désignation produit fournisseur	Liste d'ingrédients
HARICOTS BLANCS À LA TOMATE	Haricots blancs (UE et non UE), eau, sel, tomate concentré, antioxydant : acide citrique.
POIVRE VERT DÉSHYDRATÉ	100% poivre vert
Crème de marron de l'Ardèche en boîte 500 g CLEMENT FAUGIER	Châtaignes 50%, sucre, marrons glacés, sirop de glucose, eau, extrait naturel de vanille
Velouté de poireaux pommes de terre hyposodé en sachet 800 g NEFF MADA	Pomme de terre 32 %, amidon modifié de pomme de terre, féculle de pomme de terre, maltodextrine de blé, poireau 8 %, arômes naturels, sucre, oignon, antiagglomérant : E551 "nano", plantes aromatiques, curcuma
Poivre Kampot rouge en pot 50 g TERRE EXOTIQUE	Poivre de Kampot rouge 100%

TABLE 1 – Exemples de listes d'ingrédients

2.2 Pièces jointes

Dans le PIM, les pièces jointes - intéressantes au titre de l'information produit - gérées au niveau du produit sont les suivantes :

- les fiches techniques fournisseur
- les étiquettes produits

D'autres types de pièces jointes sont gérées, mais elle ne seront pas décrites dans le détail (car non pertinente pour le cas d'usage présenté) :

les certificats des labels : ce sont des documents pdf produits par les organismes de certification attestant qu'un produit peut porter un label. Ils sont mis à disposition par les fournisseurs

les images produit : ce sont des visuels des produits (photographies ou images construites) qui visent à être utilisées dans des catalogues ou sur les sites de vente en ligne

les fiches logistiques : ce sont des fichiers qui viennent compléter les informations de la fiche technique lorsque cette dernière ne porte pas les informations relatives à la hiérarchie logistique.

les fiches techniques et argumentaires Pomona : ce sont des documents pdf produits par le PIM, stockées sur les articles, qui reprennent des informations produit et article (cf. section B.2.2 page 87). Elles sont transmises aux clients ou utilisés par les commerciaux Pomona. Elles permettent d'avoir une présentation uniforme de l'ensemble de l'assortiment (les fiches techniques fournisseur ont des formats très variables)

2.2.1 Fiches techniques fournisseur

Généralités sur les fiches techniques

Une fiche technique fournisseur est un document, d'une à une dizaine de pages, qui reprend l'essentiel des informations techniques à propos du produit. Elles portent globalement l'ensemble des informations

produit telles que présentées à la section B.2.1 page 83. C'est le document le plus complet vis-à-vis des informations produit, il porte en général des informations complémentaires à toutes les informations présentes sur l'emballage du produit (les étiquettes). En général, une fiche technique ne porte d'information que pour un unique produit, mais dans le cas d'assortiments, les informations peuvent être relatives à plusieurs d'entre eux. Cf. la fiche technique pour l'assortiment de confitures, présentée en annexe E.1.4 page 116. Les fiches techniques fournisseur sont des pièces jointes qui sont collectées par la branche ÉpiSaveurs depuis la mise en place du logiciel de gestion historique GIP (cf. section B.2.3 page 92), et il s'agit d'une données obligatoire dans le PIM également.

Le format des fiches techniques

Dans le PIM, ces pièces jointes sont collectées et stockées sous forme de pdf (les autres formats de fichier ne sont pas autorisés). Sauf de rares exceptions, il s'agit de fichiers issus de logiciels de traitement de texte, au format A4 portrait. Ce sont des documents techniques, et sont donc en général très structurés, avec des paragraphes, sous-paragraphes, tableaux, ... Comme cela se constate aisément sur les exemples présentés en annexe, même si les informations portées sont sensiblement toujours les mêmes, les formats de ces documents sont extrêmement variables. Il n'y a aucun standard réglementaire ou normatif relatif à la construction de ces fiches, chaque industriel constitue donc son propre format. On a donc un foisonnement de formats différents.

Focus sur le mode de présentation de quelques informations

Les informations produits sont en général présentées de la manière suivantes dans les fiches techniques :

Liste d'ingrédients : elle est quasiment toujours présentée sous forme de texte (identique à la liste d'ingrédients telle qu'affichée sur l'emballage du produit), mais elle peut également être présentée sous forme de tableau. Cf. la fiche technique présentée en annexe E.1.6 page 120 (celle-ci ne porte pas de liste d'ingrédients sous forme de texte)

Allergènes : il peuvent être :

- soit mis en évidence dans la liste d'ingrédients via la police (gras, souligné, majuscules)
- soit listés hors de la liste d'ingrédient, sous forme de texte. Cf. la fiche technique présentée en annexe E.1.3 page 114
- soit listés sous forme d'un tableau reprenant l'ensemble des allergènes réglementaires, et le niveau de présence associé (présence, contamination croisée ou absence). Cf. la fiche technique présentée en annexe E.1.5 page 118

Données nutritionnelles : les données nutritionnelles sont en général présentées sous forme de tableau dans les fiches techniques. De plus, les informations nutritionnelles sont souvent données pour 100 grammes (ou 100 millilitres), ce qui est réglementaire, mais également parfois pour une portion. La taille de la portion est définie arbitrairement par le fournisseur. Cf. la fiche technique de la préparation pour panna cotta E.1.3 page 114.

Données logistiques : les informations relatives à la hiérarchie logistiques se présentent souvent sous forme de tableaux. L'interprétation de ces tableaux est généralement complexe et nécessite un peu de réflexion.

2.2.2 Étiquettes produit

Généralités sur les étiquettes

L'étiquette produit est la partie de l'emballage du produit qui porte les informations produit. Selon la technologie de l'emballage - très liée au fait que le produit est plutôt brut ou plutôt transformé - il peut s'agir :

- d'une photo de l'étiquette collante apposée sur l'extérieur de l'emballage du produit (cf. exemple des étiquettes de lentilles E.2.3 page 126 ou de sauce soja E.2.5 page 128)
- d'un applat de l'emballage, ou son bon-à-tirer, qui est le document qui est ensuite envoyé aux chaînes de production pour impression (cf. exemple du bon à tirer pour la préparation pour panna cotta E.2.4 page 127)
- ou de tout autre visuel montrant une partie indissociable de l'emballage physique du produit (ex : un photo de la face de l'emballage qui porte les informations produit, cf. l'étiquette des madeleines E.2.2 page 125)

Pour résumer, l'étiquette est une pièce jointe qui représente l'information produit qui « voyage avec le produit ». La cohérence entre les données de l'étiquette et l'information produit transmises aux clients est un enjeu majeur, dans la mesure où ce sont en général les informations portées par le produit physique qui sont correctes. La collecte systématique des étiquettes produit est une nouveauté arrivée avec la mise en place du PIM pour ÉpiSaveurs (mai 2019). En théorie, les étiquettes mises à disposition par les fournisseurs devraient systématiquement porter les informations réglementaires. Or, du fait de la relative nouveauté de cette collecte, les pièces jointes transmises ne sont pas toujours conformes (cf. l'étiquette des lentilles E.2.3 page 126, qui ne portent aucune information nutritionnelle ou de composition).

Le format des étiquettes

Comme les fiches techniques, ces pièces jointes sont collectées et stockées sous forme de pdf (les autres formats de fichier ne sont pas autorisés). Du fait que les natures mêmes de ces pièces jointes sont diverses (cf. paragraphe précédent), il n'existe pas de format prédominant.

Focus sur le mode de présentation de quelques informations

Les étiquettes portent moins d'information que les fiches techniques. Par exemple, elles ne portent pas d'information sur la hiérarchie logistique, les données administratives (tel que le taux de TVA ou la nomenclature douanière), les codes d'identification (hormis le GTIN qui est présent sur le code à barre), ... Les durées

de vie ne sont pas mentionnées : sur l'emballage d'un produit seule la date limite apparaît, et elle dépend du lot de production. En règle générale, hormis quelques allégations volontairement affichées par l'industriel, l'étiquette ne porte que les informations réglementaires. Les informations positionnées sur l'étiquette se présentent de la manière suivante :

Liste d'ingrédients : elle est toujours présentée sous forme d'un texte énumérant les ingrédients (cf. la section 2.1 page 8 qui détaille le contenu d'une liste d'ingrédients)

Allergènes : ils sont uniquement mis en évidence dans la liste d'ingrédients, par l'utilisation d'une police spécifique (gras, souligné, majuscule, ...). Cela peut se constater par exemple sur l'étiquette de madeleines E.2.2 page 125 ou celle de la sauce soja E.2.5 page 128

Données nutritionnelles : les données nutritionnelles se présentent souvent sous forme d'un tableau, toujours avec les valeurs pour 100 grammes ou 100 millilitres, et parfois pour une portion. Il peut arriver, plutôt pour les produits peu transformés, que ces données soient simplement écrites sous forme de texte tel que

Énergie : 1101 kJ/260 kcal, Glucides : 57 g, Sucres : 52 g, Protéines : 4,3 g, Sel : 7,1 g

2.3 Récapitulatif de la complétude des données

Dans cette section, les indicateurs présentés se basent sur les notions « En qualité » et « Hors qualité », qui sont explicitées en annexe D.1.2 page 104.

2.3.1 Complétude des listes d'ingrédients

2.3.2 Complétude des pièces jointes

Si on analyse le niveau de renseignement des données pour les étiquettes et les fiches techniques, on obtient la TABLE 2 page 12.

	En qualité						Hors qualité						Total					
	Fiche technique		Etiquette			Fiche technique		Etiquette			Fiche technique		Etiquette			Fiche technique		Etiquette
	cpt	sur	%	cpt	sur	%	cpt	sur	%	cpt	sur	%	cpt	sur	%	cpt	sur	%
Epicerie	3007	3007	100%	2996	3007	99%	4791	5755	83%	1921	5755	33%	7798	8762	88%	4917	8762	56%
Boissons	355	355	100%	352	355	99%	458	551	83%	184	551	33%	813	906	89%	536	906	59%
Alcools	253	253	100%	253	253	100%	296	354	83%	74	354	20%	549	607	90%	327	607	53%
Hygiène	768	768	100%	688	768	89%	1509	1733	87%	420	1733	24%	2277	2501	91%	1108	2501	44%
Chimie	130	130	100%	130	130	100%	310	329	94%	127	329	38%	440	459	95%	257	459	55%
Total	4513	4513	100%	4419	4513	97%	7364	8722	84%	2726	8722	31%	11877	13235	89%	7145	13235	53%

TABLE 2 – Analyse volumétrique des pièces jointes

On en tire comme conclusions que :

- le taux de collecte de ces documents est quasiment parfait pour les produits dits « En qualité » (cf. les définitions données à la section D.1.2 page 104)
- la volumétrie d'étiquettes sur les produits « Hors qualité » est bien plus faible, de l'ordre de 30%

2.4 Les données « manuellement étiquetées »

2.4.1 Pour répondre à quel besoin ?

La qualité des données actuellement présentes dans le système fait que la cohérence entre les listes d'ingrédients du PIM et celles présentes dans les fiches techniques n'est pas assurée. Comme dans tout modèle de machine learning se basant sur des données, il est indispensable ici d'avoir des données dont on est sûrs de la qualité. Il a donc été décidé d'étiqueter manuellement un échantillon représentatif de fiches techniques, en leur faisant correspondre leurs listes d'ingrédients.

2.4.2 Mode de constitution de l'échantillon

Le code pour la constitution de l'échantillon est présenté dans le notebook en annexe G.1 page 140.

Les règles de gestion adoptées pour la constitution de cet échantillon sont les suivantes :

- On constitue un échantillon de 500 fiches techniques étiquetées
- On se limite aux produits d'Épicerie et de Boisson non alcoolisée, car ce sont les produits pour lesquels la réglementation impose d'afficher une liste d'ingrédients aux consommateurs
- On stratifie cet échantillon par type de produit (Épicerie vs. Boisson non alcoolisée)
- On se limite évidemment à des produits qui possèdent une fiche technique

Il aurait pu être intéressant de se limiter aux produits « en qualité » (cf. les définitions données à la section D.1.2 page 105 sur les statuts des produits), mais l'étiquetage manuel avait été fait avant l'analyse de ces statuts. La constitution de cet échantillon s'est traduite par la génération d'un fichier csv de 500 lignes, avec 3 colonnes :

- l'uid du produit de l'échantillon
- la désignation produit fournisseur
- une colonne vide, visant à accueillir les listes d'ingrédients lors de l'étiquetage manuel

2.4.3 Méthodologie de l'étiquetage manuel

Cette activité s'est faite simplement, dans un environnement Windows :

- les pièces jointes ont été téléchargées localement, dans des dossiers portant l'uid du produit associé
- le csv contenant les uid et les désignation produit fournisseur a été ouvert dans le tableur Microsoft Excel
- en prenant chaque uid séquentiellement, il était relativement rapide de rechercher localement la fiche technique correspondante dans l'explorateur de fichier et de l'ouvrir
- le plus souvent, il était possible de copier/coller la liste d'ingrédient dans le tableur Excel
- le fichier a ensuite été à nouveau sauvegardé au format csv, afin de pouvoir être chargé dans pandas

Une passe de nettoyage des caractères spéciaux issus des copier/coller a ensuite été faite dans excel.

2.4.4 Règles de gestion pour l'étiquetage manuel

Malgré le fait que l'exercice semble à priori peu complexe, en pratique un nombre assez élevé de cas particuliers ont nécessité de prendre des décisions, parfois arbitraires. En général, il s'agit de décisions à prendre lorsque des mentions qui ne sont pas des ingrédients au sens strict sont incluses dans le texte des ingrédients. Le principe de base qui a été retenu est d'essayer de coller au plus à ce qui est attendu dans le PIM. Par exemple, dans le PIM on demande de retirer les préfixes du type « Ingrédients : » car ces mentions sont reprises telles sur les sites internet, ce qui peut se traduire par l'affichage de « Ingrédients : Ingrédients : ... ». L'ensemble des règles sont documentées à l'annexe E.3.1 page 130.

2.4.5 Confrontation avec le contenu du PIM

Il est possible de comparer les liste d'ingrédients du PIM, et ceux des données étiquetées manuellement. Si on prend uniquement en compte les égalités strictes, on a un niveau de cohérence exactement à 10% (50 produits sur les 500 du périmètre). Des exemples de liste d'ingrédients en écart sont présentées à la TABLE 3 page 15. Il apparaît clairement que l'essentiel des écarts sur cet échantillon sont dus à des ajustements de forme (mise en majuscule des allergènes, retrait de parenthèses, retours à la ligne, ...).

Chapitre 3

LE CHOIX DU CAS D'USAGE

3.1 Étiquettes contre fiches techniques

3.1.1 La représentation dominante des fiches techniques

Les pièces jointes utilisées lors des contrôles métier pour la vérification des données produit sont les fiches techniques fournisseur et les étiquettes. Or, les étiquettes sont moins représentées que les fiches techniques dans le PIM (cf. TABLE 2 page 12).

3.1.2 L'extraction de données textuelles

Comme cela a été décrit à la section 2.2.2 page 11 Les étiquettes sont des pièces jointes au format pdf, mais qui peuvent être générées de multiples façons :

- issues d'un logiciel graphique pour la constitution du applat du packaging
- construites à partir d'une ou plusieurs photos insérées dans outil de traitement de texte
- ...

Ingrédients du PIM	Ingrédients de la ground truth
Céréales (farine de FROMENT (27,5%), céréales complètes (15,1%) (farine complète de FROMENT (15%), farine complète de SEIGLE, farine complète d'ORGE) sucre graisses végétales (palme, palmiste, colza) poudre de cacao maigre (5,1%) amidon de BLE LAIT écrémé en poudre (équivalent lait 16%) amidon de pomme de terre poudres à lever (carbonates de sodium et d'ammonium, diphosphates) LACTOSE et protéines de LAIT sel arôme émulsifiant : lécithine de tournesol agent de traitement de la farine : E223 (SULFITES).	Céréales [farine de froment (27.5%), céréales complètes (15.1%) (farine complète de froment (15 %), farine complète de seigle , farine complète d'orge)] sucre graisses végétales (palme, palmiste, colza) poudre de cacao maigre (5.1%) amidon de blé lait écrémé en poudre (équivalent lait 16%) amidon de pomme de terre poudres à lever (carbonates de sodium et d'ammonium, diphosphates) lactose et protéines de lait sel arôme émulsifiant : lécithine de tournesol agent de traitement de la farine : E223 (sulfites) Peut contenir des traces de fruits à coque, de soja, d'oeuf et de sésame
cheddar fondu(44%) (eau, LACTOSERUM, cheddar(5%) (LAIT, ferment, acidifiant (sulfates de sodium (E514)), enzymes), LAIT écrémé, maltodextrine, antioxydant (phosphate de sodium (E339)), CREME, épaisseurs (octényle succinate d'amidon sodique (E1450), gomme xanthane (E415)), acidifiant (sulfates de sodium (E514))), eau, huile de palme, épaisseurs (amidon modifié de tapioca, amidon modifié de maïs), maltodextrine, acidifiants (sulfates de sodium (E514), citrate de sodium (E331), acide phosphorique (E338), acide lactique (E270)), arôme, antioxydant (phosphate de sodium (E339)), colorants (béta carotène (E160a), annatto (E160b), extrait de paprika (E160c)), émulsifiant (stéaroyl-2-lactylate de sodium (E481), mono et diglycérides d'acides gras alimentaires (E471))	cheddar fondu (44%) (eau, lactosérum, cheddar (5%) (lait, ferment, acidifiant (sulfates de sodium (E514)), enzymes), lait écrémé, maltodextrine, antioxydant (phosphate de sodium (E339)), crème, épaisseurs (octényle succinate d'amidon sodique (E1450), gomme xanthane (E415)), acidifiant (sulfates de sodium (E514)), eau, huile de palme, épaisseurs (amidon modifié de tapioca, amidon modifié de maïs), maltodextrine, acidifiants (sulfates de sodium (E514), citrate de sodium (E331), acide phosphorique (E338), acide lactique (E270)), arôme, antioxydant (phosphate de sodium (E339)), colorants (béta carotène (E160a), annatto (E160b), extrait de paprika (E160c)), émulsifiants (stéaroyl-2-lactylate de sodium (E481), mono et diglycérides d'acides gras alimentaires (E471))
Pommes* (80%), framboises* (20%)	pommes* (80%), framboises* (20%) *Ingrédient issu de l'agriculture biologique
Eau, graines de MOUTARDE, vinaigre d'alcool, sel, vin blanc (contient SULFITES), sucre, épices, acidifiant (acide citrique), conservateur (DISULFITE de potassium)	Eau, graines de moutarde, vinaigre d'alcool, sel, vin blanc (contient sulfites), sucre, épices, acidifiant (acide citrique), conservateur (disulfite de potassium)
Pâte à tartiner aux NOISETTES et au cacao 81,5 % (sucre, huile de palme, NOISETTES 13%, LAIT écrémé en poudre 8,7%, cacao maigre 7,4%, émulsifiants : lécithines [SOJA] , vanilline), farine de FROMENT 16%, levure de bière, extrait de malt d'ORGE, sel, LAIT écrémé en poudre, émulsifiants : lécithines [SOJA] , protéines de FROMENT, protéines de LAIT, eau.	pâte à tartiner aux noisettes et au cacao 81,5 % (sucre, huile de palme, noisettes 13%, lait écrémé en poudre 8,7%, cacao maigre 7,4%, émulsifiants : lécithines [soja]; vanilline), farine de froment 16%, levure de bière, extrait de malt d'orge, sel, lait écrémé en poudre, émulsifiants : lécithines [soja]; protéines de froment, protéines de lait, eau. Le chocolat utilisé est un chocolat pur beurre de cacao.
Sirop de glucose, sucre, amidons transformés, acidifiants : acide citrique, acide malique, correcteurs d'acidité : citrate tricalcique, malate acide de sodium, agent d'enrobage : cire de carnauba, arôme, concentrés de fruits et de plantes : carthame, citron, colorants : carmins, bleu patenté V, lutéine, sirop de sucre inverti.	sirop de glucose ; sucre ; amidons transformés ; acidifiants : acide citrique, acide malique ; correcteurs d'acidité : citrate tricalcique, malate acide de sodium ; agent d'enrobage : cire de carnauba ; arôme ; concentrés de fruits et de plantes : carthame, citron ; colorants : carmins, bleu patenté V, lutéine ; sirop de sucre inverti.
Huile de colza, jaunes d'OEUFS, purée de tomates, eau, vinaigre, câpres (2.8 %) (câpres, eau, sel), cornichons (2.8 %) (cornichons, vinaigre, sel), sucre, sel, amidon modifié, acidifiant : glucono-delta-lactone, conservateur : sorbate de potassium, antioxydant : E385, épice, arôme naturel aneth.	Huile de colza (70.45 %), jaunes d'oeufs (6.2 %), purée de tomates, eau, vinaigre, câpres (2.8 %) (câpres, eau, sel), cornichons (2.8 %) (cornichons, vinaigre, sel), sucre, sel, amidon modifié, acidifiant : glucono-delta-lactone, conservateur : sorbate de potassium, antioxydant : E385 (74 mg/kg), épice, arôme naturel aneth.
Lentilles, eau, sel, arôme naturel (CELERI)	Lentilles, eau, sel, arôme naturel (céleri)
Ingrédients : Sucre, pâte de cacao, NOISETTES (23%) , beurre de cacao, BEURRE concentré, émulsifiant (lécithine de SOJA), arôme, LAIT écrémé en poudre. Cacao : 46% minimum dans le chocolat noir. PEUT CONTENIR AUTRES FRUITS À COQUE.\t\t\t	Sucre, pâte de cacao, NOISETTES (23%) , beurre de cacao, BEURRE concentré, émulsifiant (lécithine de SOJA), arôme, LAIT écrémé en poudre. Cacao : 46% minimum dans le chocolat noir. PEUT CONTENIR AUTRES FRUITS À COQUE.
Huile de colza, eau, vinaigre d'alcool, jaunes d'OEUFS, sucre, estragon (2,5%), échalote (2,4%), sel, cerfeuil, jus de citron à base de concentré, piment de Cayenne, arômes, amidon modifié, colorant : bêta-carotène, conservateur : sorbate de potassium.	Huile de colza, eau, vinaigre d'alcool, jaunes d'oeufs, sucre, estragon (2,5%), échalote (2,4%), sel, cerfeuil, jus de citron à base de concentré, piment de Cayenne, arômes, amidon modifié, colorant : bêta-carotène, conservateur : sorbate de potassium.Ce produit peut contenir des traces de moutarde.

TABLE 3 – Exemples d'écart entre les données étiquetées et celles du PIM

Les textes présents dans ces pdf se présentent donc parfois sous forme de textes extractibles par des bibliothèques de pdf mining, soit sous forme d'images qui nécessitent alors des fonctionnalités d'OCR (Optical Character Recognition [20]). Le taux de pièces jointes avec des textes extractibles est présenté à la TABLE 4 page 16 ; pour mémoire seul un tiers des étiquettes ont un contenu exploitable par les outils de pdfmining. De plus, l'orientation des textes peut parfois faire l'objet d'une rotation (cf. l'étiquette des lentilles en annexe E.2.3 page 126), voire n'être pas toujours la même selon les faces de l'emballage (cf. l'étiquette de la panna cotta, en annexe E.2.4 page 127). Ces contraintes, bien que surmontables, imposent des travaux qui n'auraient pas d'intérêt dans le cadre de ce mémoire.

Documents vides			
	Nombre de documents vides	Nombre total de documents	Taux de vides
Etiquettes	214	315	67%
Fiches techniques	22	500	4%

TABLE 4 – Pièces jointes dont les textes ne sont pas extractibles

On va donc dans un premier temps travailler avec les fiches techniques plutôt qu'avec les étiquettes

3.2 Impossibilité de produire des templates pour l'exploitation de ces documents

Chaque fournisseur décide du format des fiches techniques qu'il souhaite produire. On a donc beaucoup de formats différents, à peu de choses près on a un format par fournisseur. On pourrait imaginer développer un outil qui sur la base d'un template permet d'extraire de manière fiable le contenu de documents qui ont toujours le même format (cela se fait par exemple pour les commandes clients reçues par mail). L'établissement d'un « traducteur » de documents de ce type représente une charge d'une dizaine de jours de travail par format de fichier. Le Pareto des produits par fournisseur présenté à la FIGURE 2 page 17 montre qu'il ne serait pas économiquement pertinent de construire ce genre d'outil (10 templates ne permettraient de couvrir que 3000 produits, et le gain marginal ne cesserait de diminuer ensuite). On n'approche pas du seuil de rentabilité requis. En comparaison, les outils de parsing des commandes mail permettent de traiter plus de 20 000 postes de commandes par jour, avec moins de 5 templates.

Une approche traditionnelle d'extraction de données depuis des documents pdf ne pourra pas être appliquée pour ce cas d'usage

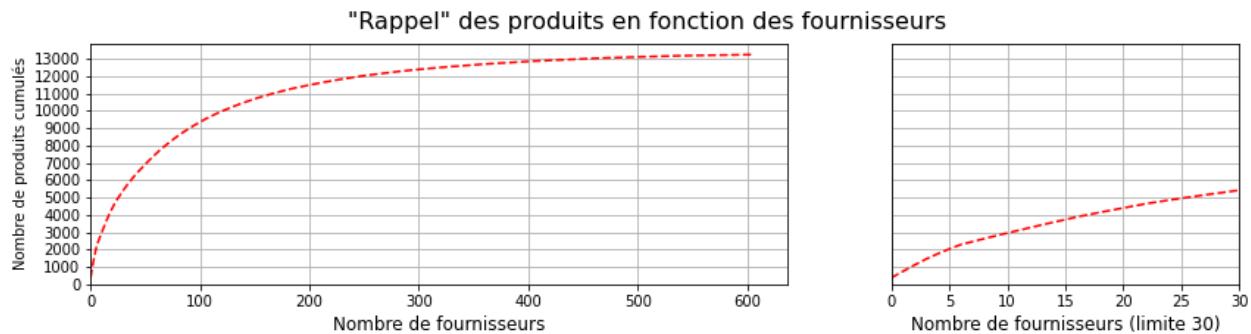


FIGURE 2 – Le Pareto des produits en fonction des fournisseur

3.3 Quelles données ?

3.3.1 Les principales données et leur mode de présentation dans les fiches techniques

Les données que l'on souhaite récupérer sont globalement de 4 types :

- données de composition : listes d'ingrédients
- données de composition : allergènes
- données nutritionnelles
- données logistiques

Comme vu dans la section 2.2.1 page 9, parmi les données présentes dans les fiches techniques, seule la liste d'ingrédients se présente quasiment toujours sous la forme d'un texte brut (par opposition à un affichage au sein d'un tableau). La représentation des données nutritionnelles se fait régulièrement sous forme de tableau, les données logistiques également (cf. les exemples de fiches techniques présentées en annexe, à partir de E.1.1 page 112).

3.3.2 L'identification d'une liste d'ingrédient par son contenu

Il est possible de dire si un texte est une liste d'ingrédients, juste en lisant ce texte. Il s'agit souvent d'une énumération d'ingrédients individuels (cf. la section 2.1 page 8). Même sortie de son contexte, il est en général faisable pour un humain d'identifier comme telle une liste d'ingrédients. Par exemple :

Huile de colza (70.45 %), jaunes d'oeufs (6.2 %), purée de tomates, eau, vinaigre, câpres (2.8 %) (câpres, eau, sel), cornichons (2.8 %) (cornichons, vinaigre, sel), sucre, sel, amidon modifié, acidifiant : lucono-delta-lactone, conservateur : sorbate de potassium, antioxydant : E385 (74mg/kg), épice, arôme naturel aneth

est de toute évidence une liste d'ingrédients.

À l'inverse, les autres grands types d'information nécessitent du contexte dans le document. Par exemple, « 14g » peut être une quantité de glucides, de lipides, le poids d'une pièce unitaire, ...

L'identification de listes d'ingrédients pourrait se faire sans avoir à construire de fonctionnalités s'appuyant sur le contexte au sein du document

3.4 Quels produits ?

Pour des raisons d'accessibilité de la donnée, on travaillera sur les produits de la branche ÉpiSaveurs. Il est de toute façon prévu de déployer le PIM sur l'ensemble des autres branches du groupe, on pourra adresser leurs produits à ce moment-là. La notion d'ingrédients n'a pas de sens pour les produits d'hygiène (cf. section C.1 page 97 sur les produits non-alimentaires), mais existe pour les produits de chimie. Comme les ingrédients des produits alimentaires sont en général différents des produits de chimie, on se limitera d'abord aux premiers. Enfin, la réglementation étant moins stricte pour les boissons alcoolisées sur le sujet spécifique de l'étiquetage de la composition, on ne les prendra pas non plus en compte dans ce mémoire.

3.5 Conclusion quant au choix du cas d'usage

Au vu des différentes contraintes listées dans cette partie, on s'attachera à extraire les listes d'ingrédients des produits alimentaires de la branche EpiSaveurs (épicerie et boissons non alcoolisées) depuis les fiches techniques fournisseur, en se basant sur le contenu textuel de ces documents.

Deuxième partie

ANALYSE DES DONNÉES TEXTUELLES

Chapitre 4 CARACTÉRISTIQUES GÉNÉRALES DU JEU DE DONNÉES

Dans toute cette analyse, on se basera sur les données manuellement étiquetées (ou ground truth), échantillon de 500 fiches techniques avec les listes d'ingrédients associées. Le code ayant servi à effectuer ces analyses est présenté dans le notebook en annexe ?? page ??.

4.1 Volumétrie

TODO peut-être : Produits par type, avec les comptes, du PIM et de la GT, avec l'axe en qualité et hors qualité.

TODO peut-être : Textes renseignés vs. pas renseignés.

4.2 Distributions des longueurs des textes

TODO peut-être : Longueur des listes d'ingrédients dans le PIM, fonction du type de produit.

L'analyse des longueurs des textes montre que les listes d'ingrédients sont en moyenne longues de 400 caractères, et le contenu des documents de 4000 caractères (cf. TABLE 5 page 20). La distribution des longueurs de listes d'ingrédients et des longueurs de textes est présentée à la FIGURE 3 page 20, et leur représentation de l'une en fonction de l'autre à la FIGURE 4 page 20. Il apparaît qu'il n'y a pas de corrélation entre la longueur de la liste d'ingrédients et la longueur du contenu du document ($r^2 = 0.139$).

	text count	mean	std	min	25%	50%	75%	max
Texte des documents	500.0	3937.630	3280.860732	0.0	2173.75	3247.5	5034.25	37322.0
Listes d'ingrédients	500.0	199.686	457.044723	0.0	43.00	122.0	250.75	7963.0

TABLE 5 – Longueur des textes dans le dataset

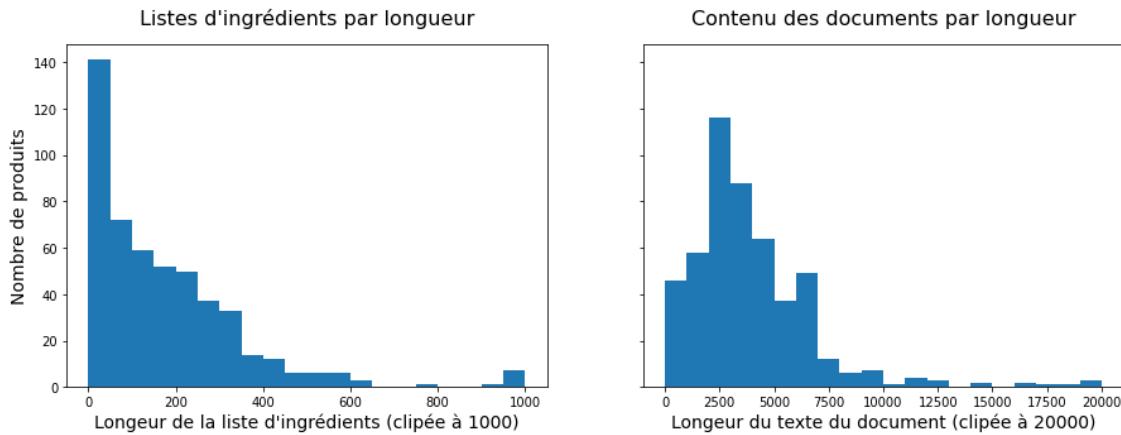


FIGURE 3 – Distribution des longueurs de textes

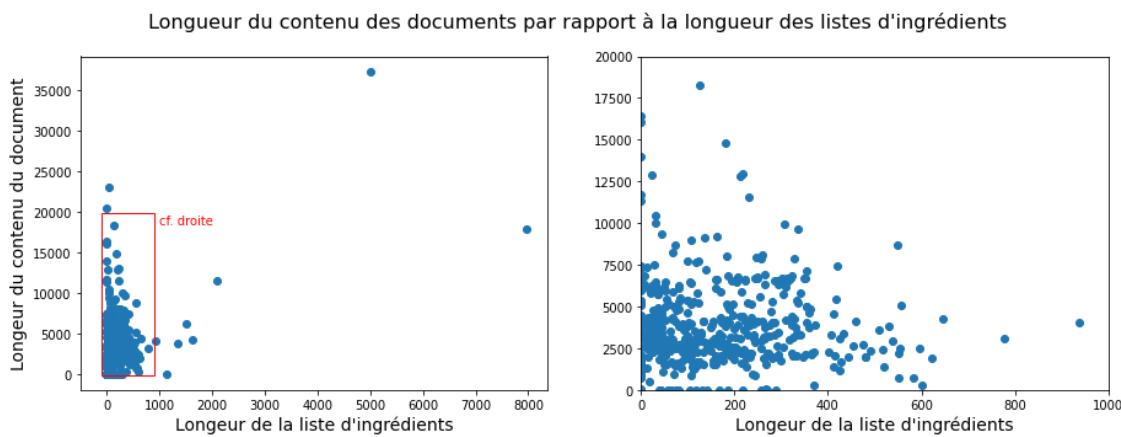


FIGURE 4 – Corrélation entre longueurs des textes

Chapitre 5

ANALYSE TEXTUELLE

5.1 Mots de chacun des corpus

Pour l'analyse des mots de chacun des corpus (listes d'ingrédients et contenu des documents), on fait d'abord un preprocessing de ces textes bruts :

- mise en minuscule de ces textes
- retrait des accents
- retrait des stopwords suivants : 'pas', 'le', 'en', 'pour', 'ou', 'ce', 'de', 'dans', 'du', 'and', 'un', 'sur', 'et', 'of', 'est', 'par', 'la', 'les', 'dont', 'au', 'des', 'que'
- split des textes à chaque whitespace (espace, tabulation, retour à la ligne, ...)

La liste de ces stopwords a été manuellement établie à partir des mots les plus fréquents de chacun des vocabulaires. Elle est commune aux deux corpus. Un descriptif des vocabulaires est présenté à la TABLE 6 page 22. Un rapide parcours de ces exemples montre que l'utilisation des mots dans ces deux corpus (ingrédients et contenu des documents) est différente. On s'attend à pouvoir différencier automatiquement ces types de textes. Le vocabulaire des ingrédients est, comme on pouvait s'y attendre, entièrement inclus dans le vocabulaire du contenu des fiches techniques.

5.2 Répartitions des mots dans et hors des listes d'ingrédients

On calcule la « document frequency » des mots du corpus des ingrédients dans les listes d'ingrédients. Elle s'étend simplement au corpus du contenu des documents en la mettant à 0 pour les mots qui n'appartiennent pas au vocabulaire des ingrédients. Cela permet de calculer un score absolu s_i pour chaque mot i via la formule suivante :

$$s_i = \log_2(1 + c_i)$$

où c_i est le nombre de listes d'ingrédients dans lequel le mot i apparaît (proportionnel à la document frequency).

Le score absolu vaut donc 0 si le mot n'est pas présent dans le vocabulaire des ingrédients, 1 s'il est présent une fois, et progresse de manière logarithmique en fonction du taux de présence du mots dans le corpus des ingrédients (c'est une « smooth document frequency »). On peut, de manière similaire, calculer un score pour l'ensemble des mots, relatif à la présence dans le contenu des documents. Attention, dans la mesure où la composition est normalement portée par la fiche technique, en théorie les mots de la liste d'ingrédients sont

	Ingrédients	Contenu des documents
Longueur du vocabulaire	1324	15465
Top 20 mots	sucré : 363 occurrences	produit : 2198 occurrences
	acide : 255 occurrences	non : 2164 occurrences
	sel : 240 occurrences	produits : 1508 occurrences
	sirop : 180 occurrences	10 : 1404 occurrences
	eau : 178 occurrences	kg : 1290 occurrences
	poudre : 176 occurrences	base : 1119 occurrences
	arôme : 175 occurrences	sel : 1041 occurrences
	lait : 171 occurrences	poids : 1021 occurrences
	ble : 171 occurrences	100 : 971 occurrences
	huile : 146 occurrences	palette : 933 occurrences
	critique : 132 occurrences	ingredients : 917 occurrences
	farine : 128 occurrences	date : 904 occurrences
	amidon : 125 occurrences	sucré : 841 occurrences
	glucose : 124 occurrences	12 : 803 occurrences
	cacao : 122 occurrences	code : 801 occurrences
	extrait : 117 occurrences	lait : 733 occurrences
	acidifiant : 114 occurrences	absence : 697 occurrences
	arômes : 98 occurrences	fiche : 688 occurrences
	soja : 96 occurrences	the : 658 occurrences
	concentré : 92 occurrences	france : 657 occurrences

TABLE 6 – Caractéristiques des vocabulaires

contenus dans le texte du document. Pour prendre en compte ce point, avant de calculer le score par rapport au contenu des documents, on soustrait les comptes des mots de la liste d'ingrédients des comptes de mots du contenu du document. Ne sont considérés comme apparaissant dans le contenu du document que les mots dont la différence est strictement positive. Une illustration de ces scores est donnée à la FIGURE 5 page 22.




FIGURE 5 – Exemples de scores absolus de mots

La TABLE 6 page 22 montre que certains mots sont répandus à la fois au sein des listes d'ingrédients, mais également dans le corps des documents (ex : « sel », « sucre », « lait », ...). L'identification des listes d'ingrédients devrait être plus efficace si on prend en compte la fréquence relative des mots dans chacun des corpus :

- la présence du mot « sucre », bien qu'il soit très souvent présent dans les listes d'ingrédients, n'est pas forcément un bon indicateur que le bloc de texte considéré est une liste d'ingrédients
- le mot « poids » devrait pénaliser fortement un bloc de texte car il n'est pas présent dans les listes

d'ingrédients, mais fréquemment à l'extérieur

On peut calculer un score relatif s'_i pour chaque mot i via la formule suivante :

$$s'_i = \log_2\left(\frac{1 + c_i^{ingred}}{1 + c_i^{docs}}\right) = \log_2(1 + c_i^{ingred}) - \log_2(1 + c_i^{docs}) = s_i^{ingred} - s_i^{docs}$$

où c_i^{corpus} est le nombre de documents du corpus *corpus* dans lequel le mot i apparaît, et s_i^{corpus} est le score absolu du mot i dans le corpus *corpus* tel que défini précédemment. Cette manière de calculer le score :

- fait qu'un mot autant présent (au sens de la document frequency) dans les deux corpus a un score de 0
- un mot 2 fois plus présent dans le corpus des ingrédients que dans le corpus des documents aura un score de 1
- un mot plus présent dans le corpus des documents que dans le corpus des ingrédients aura un score négatif
- un mot plus présent dans le corpus des ingrédients que dans le corpus des documents aura un score positif
- peut fonctionner parce que la taille des corpus est équilibrée (il faudrait passer en document frequency en cas de déséquilibre)

Une illustration de ces scores est présentée à la FIGURE 6 page 23.

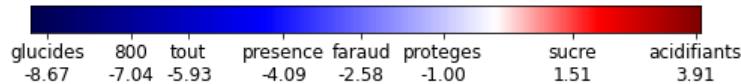
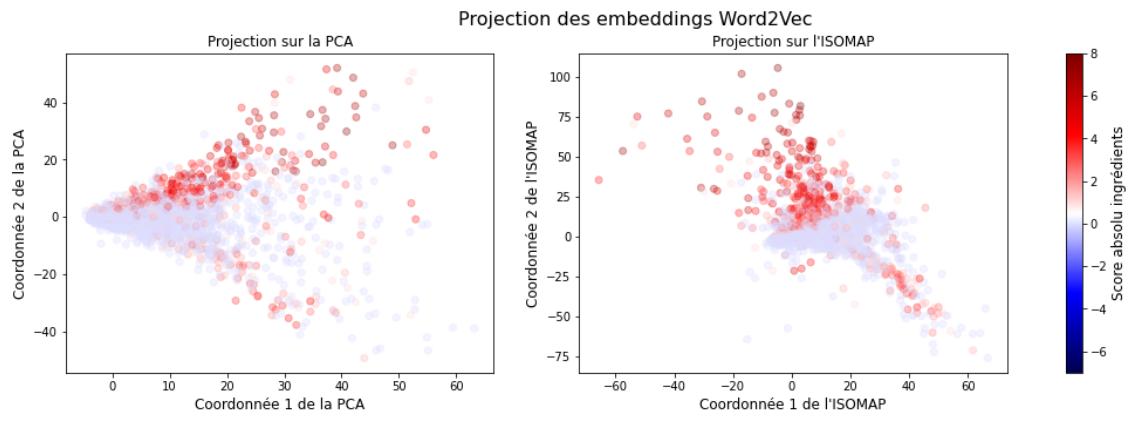


FIGURE 6 – Exemples de scores relatifs de mots

5.3 Représentations graphiques des textes et mots

5.3.1 Vectorisation des mots

On calcule les embeddings des mots via l'algorithme Word2Vec, sur le corpus du contenu des documents. Si l'on applique deux méthodes de réduction de la dimensionnalité sur ces embeddings (PCA et ISOMAP), on peut en faire une représentation graphique. Le résultat de cette projection est présenté à la FIGURE 7 page 24. On voit clairement que les embeddings des mots issus du vocabulaire des ingrédients sont localisés dans les mêmes régions. Le calcul des embeddings via l'algorithme Word2Vec semble donc avoir un intérêt pour l'identification des listes d'ingrédients.



Remarque : ci-dessus, la colormap a très légèrement été décalée pour que les mots ayant un score de 0 soient visibles (gris/bleu clair) - scores absolus




FIGURE 7 – Projection des embeddings Word2Vec

5.3.2 Vectorisation des textes

La vectorisation des textes va se faire sur la base de la matrice des comptes ou des fréquences de mots. On commence par effectuer une PCA (après standardisation) sur les comptes de mots de chacun des textes : listes d'ingrédients ou contenu des documents. Les résultats sont présentés à la FIGURE 8 page 25. Les corpus

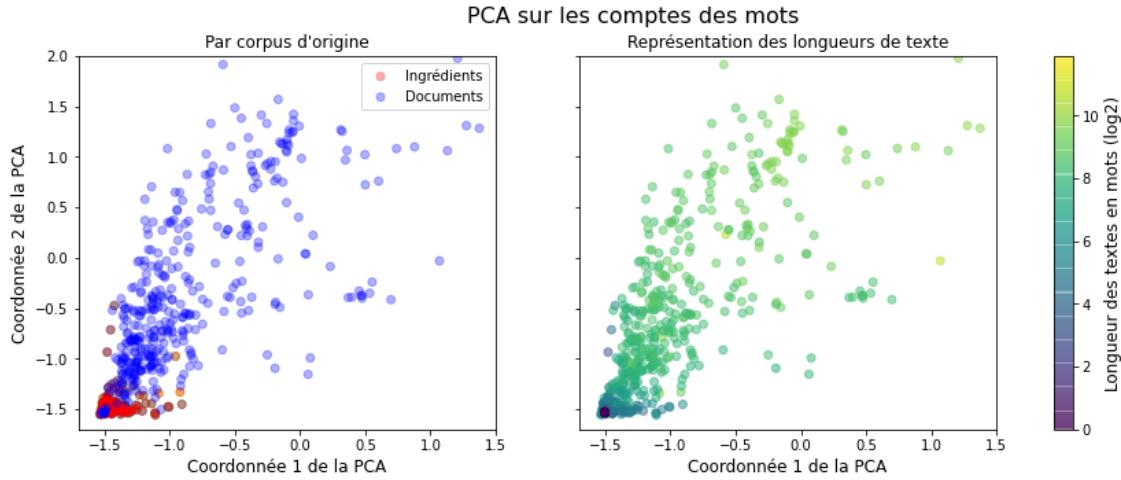


FIGURE 8 – Projection des comptes : PCA

sont bien séparés. Une explication pour cette séparation assez franche est la suivante : les vecteurs du corpus des contenus de documents ont en général une norme plus élevée que celle des ingrédients. La dispersion est donc plus grande pour les contenus des documents que pour les ingrédients.

On peut appliquer une transformation similaire, mais cette fois en utilisant une Truncated SVD (cf. FIGURE 9 page 25). Là encore, les deux corpus sont différemment localisés. La même explication que pour

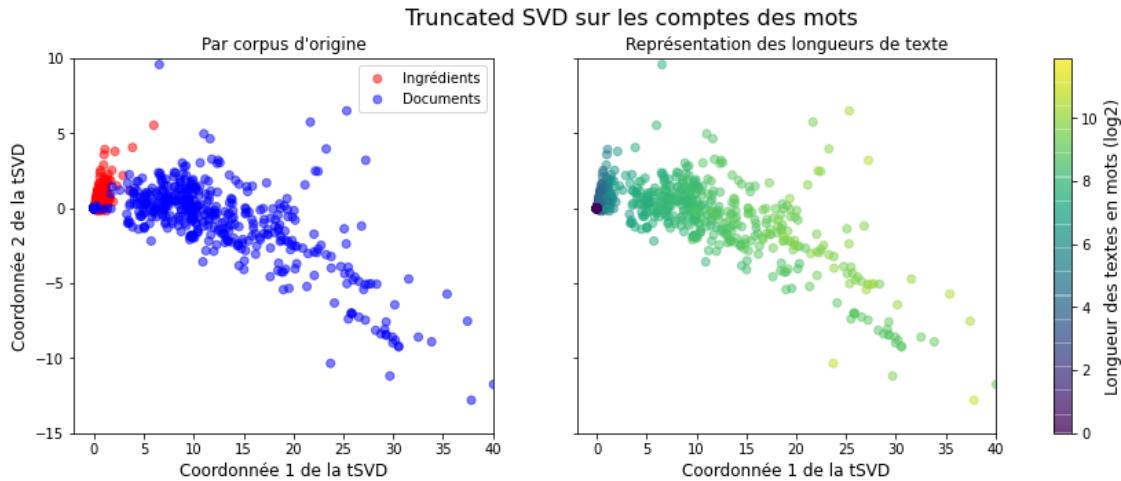


FIGURE 9 – Projection des comptes : Truncated SVD

les résultats de la PCA pourrait tenir pour expliquer cette répartition différenciée.

On peut changer d'espace de départ, en se basant sur les fréquences (« term-frequencies ») d'apparition des mots dans les textes. Cela permet de contourner le problème des longueurs différentes des textes. L'application d'une PCA est présentée à la FIGURE 10 page 26. Les textes correspondant aux ingrédients

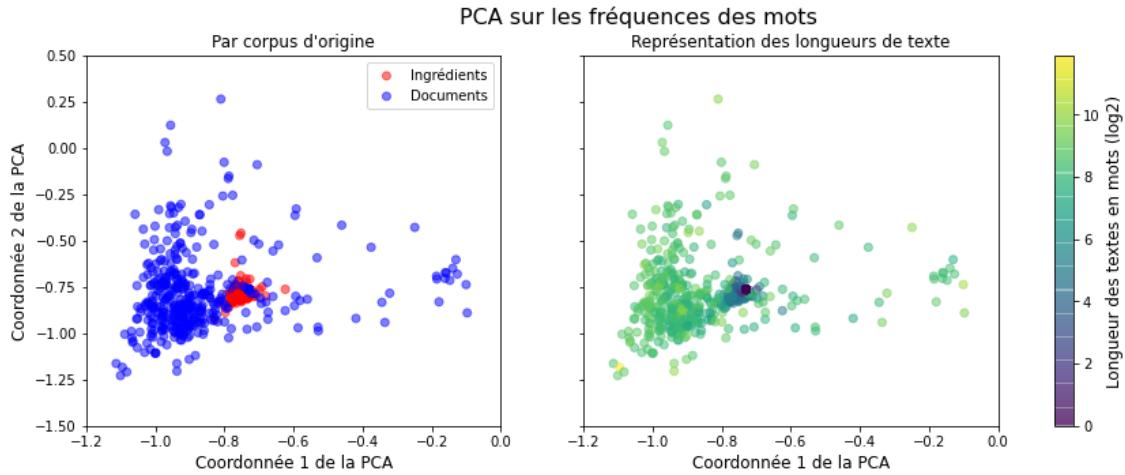


FIGURE 10 – Projection des fréquences : PCA

sont à nouveau localisés dans la même région, bien que cette fois les normes des vecteurs de l'espace de départ soient comparables entre les deux corpus. Une explication serait que les nombreux « trous » dans les vecteurs correspondants aux ingrédients (pour rappel, le vocabulaire des ingrédients est plus de 10 fois plus petit que le vocabulaire des documents, cf. TABLE 6 page 22) les cantonnent à un partie limité de l'espace de départ. D'où la similarité dans l'espace de la PCA.

Enfin, si on applique une Truncated SVD sur les fréquences de mots, on observe à nouveau une séparation franche des corpus. Le résultat est présenté à la FIGURE 11 page 27. Cette fois, c'est le corpus des documents qui occupe une région limitée de la représentation. On peut expliquer ce point par le fait que du fait que les listes d'ingrédients sont courtes, les « term frequencies » sont élevées (le diviseur étant relativement plus petit). Les vecteurs des listes d'ingrédients contribuent donc à des valeurs singulières importantes, et leurs projections dans les espaces correspondant sont plus longues.

On observe de plus deux « moustaches » distinctes (proches des axes de cette projection, cf. FIGURE 12 page 27). Si on compare les textes de ces deux groupes de points, on s'aperçoit que des tendances nettes se dégagent (cf. TABLE 7 page 28) :

- comme anticipé, il s'agit de listes d'ingrédients relativement courtes (d'où leur norme importante dans cet espace)
- la moustache de droite reprend des listes d'ingrédients correspondant principalement à du thon ou des mono-légumes en boîte (des conserves)
- la moustache du haut correspond essentiellement à des pâtes ou des mono-produits d'épicerie (épices,

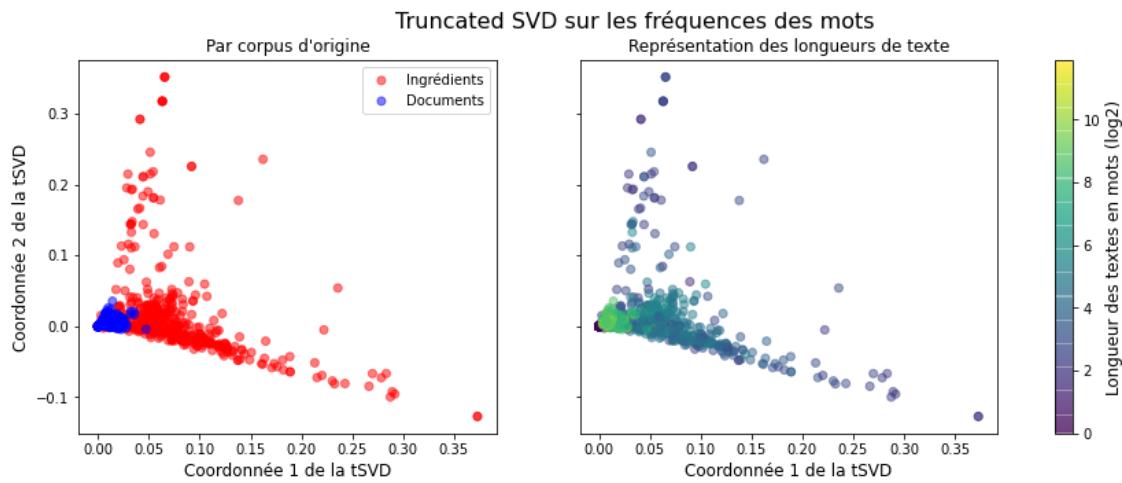


FIGURE 11 – Projection des fréquences : Truncated SVD




FIGURE 12 – Groupes particuliers dans la tSVD des fréquences

farine, thé, café)

	Texte	x	y
Groupe 1	Thon, eau, sel	0.373079	-0.127052
Groupe 1	Pois chiches, eau, sel.	0.266423	-0.084501
Groupe 1	Haricots beurre, eau, sel	0.283409	-0.066561
Groupe 1	Câpres, eau, vinaigre, sel	0.291819	-0.095479
Groupe 1	Thon albacore, eau, sel	0.287423	-0.099627
Groupe 1	Eau, haricots verts, sel.	0.278588	-0.072474
Groupe 1	Pommes de terre, eau, sel.	0.289291	-0.092162
Groupe 1	Carottes rondelles, eau, sel, sucre	0.269849	-0.066600
Groupe 1	Thon, eau, sel	0.373079	-0.127052
Groupe 2	- 100% Semoule de blé dur de qualité supérieure	0.065551	0.351800
Groupe 2	100% haricots blancs	0.051373	0.214921
Groupe 2	100% Semoule de blé dur de qualité supérieure	0.065551	0.351800
Groupe 2	Semoule de blé dur*	0.054211	0.218192
	*issu de l'agriculture biologique		
Groupe 2	Tilleul (100%).	0.041323	0.292199
Groupe 2	100% semoule de blé dur de qualité supérieure	0.065551	0.351800
Groupe 2	Farine de blé T45	0.092002	0.225689
Groupe 2	- Semoule de blé dur de qualité supérieure	0.044446	0.211188
	- 30% oeufs frais		
Groupe 2	- 100% Semoule de blé dur de qualité courante	0.051337	0.245649
	- Contient du gluten		
Groupe 2	SEMOULE DE BLE' DUR de qualité supérieure	0.063201	0.317653
Groupe 2	100% Arabica	0.041324	0.292222
Groupe 2	agar-agar 100%	0.029466	0.214845
Groupe 2	SEMOULE DE BLE' DUR de qualité supérieure	0.063201	0.317653
Groupe 2	SEMOULE DE BLE' DUR de qualité supérieure	0.063201	0.317653
Groupe 2	SEMOULE DE BLE' DUR de qualité supérieure	0.063201	0.317653
Groupe 2	- Semoule de blé dur de qualité supérieure	0.044446	0.211188
	- 30% oeufs frais		
Groupe 2	Farine de blé T45	0.092002	0.225689

TABLE 7 – Illustration des listes d'ingrédients des groupes particuliers

Troisième partie

CONSTRUCTION DU MODÈLE

Chapitre 6

PROTOTYPAGE

6.1 Premier prototype : modèle simple « ouvert »

6.1.1 Principes généraux

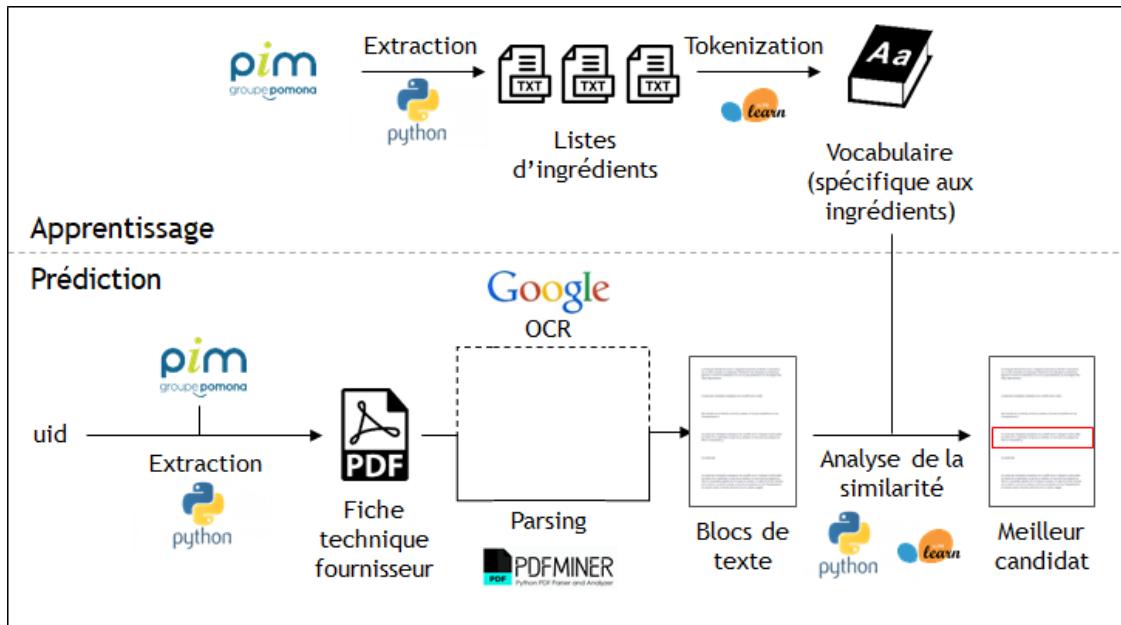


FIGURE 13 – Schéma de principe du « modèle ouvert »

Le fonctionnement global de ce premier modèle (présenté à la FIGURE 13 page 29) ne respecte pas les principes du machine learning. Il permet juste d'éprouver la méthode pressentie, ainsi que de se faire une idée de l'efficacité d'un modèle de ce type. En effet, même si on utilise des fonctionnalités d'extraction de

features depuis des textes classiques dans des modèles de machine learning, il manque une partie de mesure de la performance, indispensable pour pouvoir évaluer et améliorer la pertinence du modèle. Les illustrations de ce chapitre sont issues du notebook présenté en annexe G.2 page 168, et le code des classes utilisées (IngredientExtractor et PIMIngredientExtractor) est inclus dans le module pimest, en annexe H.4 page 277.

La classe PIMIngredientExtractor est juste un habillage du CountVectorizer de la bibliothèque scikit-learn et du Requester construit dans le module pimapi, permettant d'aller récupérer les données du PIM. Ce modèle met en application les principes du « Bag Of Words » [12], à savoir que :

- un vocabulaire est établi à partir de l'ensemble des différents mots du corpus de listes d'ingrédients
- chaque liste d'ingrédients est transformée en un vecteur de nombres entiers qui a la même longueur que le vocabulaire, ou chaque entier est le compte du nombre d'occurrence du mot dans le vocabulaire

Ce modèle n'utilise pas les données étiquetées manuellement (présentées à la section 2.4 page 13), mais se base simplement sur les listes d'ingrédients du PIM. L'hypothèse qui est faite avec ce modèle est la suivante : bien que non parfaitement en qualité (i.e. exactement identiques au contenu des pièces jointes, cf. la comparaison entre la ground truth et le contenu du PIM en section 2.4.5 page 14), les listes d'ingrédients du PIM sont des textes dont le contenu est très similaire à une liste d'ingrédients. Un survol rapide de quelques exemples montre que cette hypothèse semble vérifiée (cf. TABLE 1 page 9).

6.1.2 Entrânement

Périmètre du set d'entraînement

Pour l'entraînement de ce modèle, on va uniquement se limiter aux produits d'épicerie ou de boissons non-alcoolisées. En effet, ce sont pour ces produits que la réglementation impose d'afficher en clair la composition aux consommateurs. On se limitera aussi aux produits qui portent une liste d'ingrédients, et qui sont « En qualité » (cf. les définitions données à la section D.1.2 page 104 sur les statuts des produits). Sur les 13 000+ produits présents dans le PIM, environ 3 400 font partie du périmètre et 9 800 en sont exclus.

Constitution du vocabulaire

La constitution du vocabulaire se fait de manière très basique :

- les listes d'ingrédients sont mises en minuscules
- les mots sont ensuite séparés aux whitespaces (espaces, retours à la ligne, tabulations, ...) et marques de ponctuation

Pour parvenir à ce résultat, on applique simplement la méthode fit de la classe CountVectorizer de la bibliothèque scikit-learn. Aucune des autres fonctionnalités standard (retrait des accents, gestion des stopwords) n'a été activée. Lors de cet apprentissage, le vocabulaire obtenu a une longueur de 2 500 mots environ, et les mots les plus fréquents sont :

- de : 11419 occurrences

- sucre : 2057 occurrences
- sel : 1669 occurrences
- eau : 1288 occurrences
- acide : 1241 occurrences
- lait : 1215 occurrences
- huile : 1214 occurrences
- poudre : 1100 occurrences
- en : 962 occurrences
- arôme : 938 occurrences

(ces valeurs sont susceptibles de changer à la marge par rapport au notebook en annexe, avec les changements potentiels sur les données au sein du PIM) Les stopwords 'de' et 'en' apparaissent dans les mots les plus fréquents.

6.1.3 Prédiction

Parsing des fiches techniques

Les fiches techniques sont extraites sous formes de binaires depuis de le PIM via des appels API. On utilise ensuite la bibliothèque PDFMiner.six pour récupérer le texte de la fiche technique sous forme d'un long string. Cette étape fait appel à la méthode statique PDFDecoder.content du module pimpdf, présenté en annexe H.3 page 277. On découpe ensuite ce long string en une liste de string plus court, en considérant comme séparateur la présence de deux retours à la ligne consécutifs. Ce choix de séparateur a été fait car les textes produits par PDFMiner.six portent des retours à la ligne à la fin de chaque ligne typographiée, même si la phrase continue sur la ligne suivante. Cette étape fournit pour chaque fiche technique le texte contenu sous forme d'une liste de strings (les blocs de texte de la FIGURE 13 page 29).

Sélection du meilleur candidat

Principe L'identification du meilleur candidat parmi les blocs de texte se fait de la manière suivante :

- on calcule une similarité avec le vocabulaire des ingrédients pour chacun des blocs de texte
- on retourne le bloc de texte avec la similarité la plus élevée

La formule de calcul de la similarité utilisée dans ce modèle a été trouvée par chance (ou plutôt par erreur, pour être honnête). Néanmoins, elle donne des résultats plutôt encourageants. D'autres modes de calcul de la similarité seront présentés dans la suite de ce rapport.

La formule de calcul de la similarité est :

$$\frac{\text{Nombre de mots du candidat qui sont des ingrédients}}{\text{Norme euclidienne du vecteur du candidat}}$$

Attention, la norme du vecteur du candidat s'entend *indépendamment du vocabulaire des ingrédients*, c'est

à dire que tous les mots comptent, y compris ceux n'appartenant pas au vocabulaire.

Exemple Si on illustre par un exemple fictif : imaginons que le vocabulaire des ingrédients soit composé des mots « *eau* », « *sucré* » et « *farine* ». Le bloc de texte candidat est « *Sucré et farine sont biologiques. La farine est équitable.* » Si on vectorise ce bloc de texte *sur son propre vocabulaire*, on obtient le vecteur suivant :

sucre	et	farine	sont	biologiques	la	est	équitable
1	1	2	1	1	1	1	1

TABLE 8 – Exemple de vectorisation d'un texte

Sa norme euclidienne [19] se calcule de la manière suivante (en notant x_i le compte des mots) :

$$\sqrt{\sum_i x_i^2} = \sqrt{1 + 1 + 4 + 1 + 1 + 1 + 1 + 1} \approx 3.317$$

Le bloc contient 9 mots, dont 3 sont des ingrédients (« *farine* » est mentionné deux fois). La similarité pour cet exemple vaut donc :

$$\frac{3}{3.317} \approx 0.905$$

Étant donné son mode de calcul, cette similarité peut tout à fait être supérieure à 1.

6.1.4 Illustration des résultats obtenus

Périmètre du test

Pour éviter de surestimer la performance du modèle, on le fait tourner sur des produits n'ont pas fait partie du set d'entraînement. Comme ce modèle ne permet de toute façon pas de fournir de résultats qui permettent de mesurer la performance, on ne le fera tourner que sur un échantillon réduit de produits, soit 5 d'entre eux.

Résultats

Les résultats obtenus sont les suivants :

```
Fetching data from PIM for uid d9b233a6-b455-4af6-afb4-623f1f7f62a6...
Done
-----
Ingredient list from PIM is :

Ingrédients: Huile de tournesol, oignon, curry (11,2%) (ail, coriandre, curcuma, gingembre, paprika, poivre, cumin, poivre de Cayenne, fenouil, cardamome, noix de muscade, canelle, clous de girofle, safran), pomme, sel, exhausteur de goût (glutamate de sodium), sucre, huile de colza totalement hydrogénée, extrait de levure, ail.
-----
Downloading content of technical datasheet file...
Done!
-----
Parsing content of technical datasheet file...
Done!
```

Ingredient list extracted from technical datasheet:

Liste d'ingrédients : Huile de tournesol, oignon, curry (11,2%) (ail, coriandre, curcuma, gingembre, paprika, poivre, cumin, poivre de Cayenne, fenouil, cardamome, noix de muscade, canelle, clous de girofle, safran), pomme, sel, exhausteur de goût (glutamate de sodium), sucre, huile de colza totalement hydrogénée, extrait de levure, ail

=====

=====
Fetching data from PIM for uid 5666235b-9e78-44f2-8e0e-1de53f88fe04...
Done

=====

Ingredient list from PIM is :

Ingrediénts : Sucre, Gomme base, Sirop de glucose, Arômes, Humectant (E422), Antioxydant (E321), Colorant (E141).

=====

Downloading content of technical datasheet file...
Done!

=====

Parsing content of technical datasheet file...
Done!

=====

Ingredient list extracted from technical datasheet:

INGRÉDIENTS : Sucre, Gomme base, Sirop de glucose, Arômes, Humectant (E422),
Antioxydant (E321), Colorant (E141).

=====

=====
Fetching data from PIM for uid 6e976147-adeb-4d2d-925a-cb7c58c111a2...
Done

=====

Ingredient list from PIM is :

Maltodextrine, amidon de maïs, sel, farine de BLE, colorant : caramel ordinaire ; arômes (BLE,CELERI), huile de palme, épaississant : gomme guar ; oignon, féculé de pomme de terre, extrait de levure, jus de cuisson de viande de boeuf (0,9%), acidifiant : acide citrique ; extrait de vin blanc, extraits d'ail, de thym et de poivre. Peut contenir : LAIT, OEUFS.

=====

Downloading content of technical datasheet file...
Done!

=====

Parsing content of technical datasheet file...
Done!

=====

Ingredient list extracted from technical datasheet:

Maltodextrine, amidon de maïs, sel, farine de blé, colorant : caramel ordinaire ; arômes (blé,céleri), huile de palme, épaississant : gomme guar ; oignon, féculé de pomme de terre, extrait de levure, jus de cuisson de viande de bœuf (0,9%), acidifiant : acide citrique ; extrait de vin blanc, extraits d'ail, de thym et de poivre.
Peut contenir : lait, œuf.

=====

=====
Fetching data from PIM for uid db449562-d16d-4f72-b7a5-c0d487bc8206...
Done

=====

Ingredient list from PIM is :

Huile d'ARACHIDE

=====

Downloading content of technical datasheet file...
Done!

=====

Parsing content of technical datasheet file...
Done!

=====

Ingredient list extracted from technical datasheet:

*Selon le règlement UE n°1259-2011 / In accordance with regulation UE n°1259-2011

CARACTÉRISTIQUES MICROBIOLOGIQUES

L'huile étant un milieu anhydre, tout développement bactérien est impossible (cf. ouvrage de référence dans ce domaine "La qualité microbiologique des aliments" CNERMA-CNRS coordonné par Jean-louis Jouve).

ORIGINES/ ORIGIN

- Amérique du Sud majoritairement
- Afrique de l'Ouest

AUTRES INFORMATIONS

```
-----  
=====  
=====  
Fetching data from PIM for uid f2af54a2-6820-4f1b-99e7-d6e64642bdf3...  
Done  
-----  
Ingredient list from PIM is :  
None  
-----  
Downloading content of technical datasheet file...  
Done!  
-----  
Parsing content of technical datasheet file...  
Done!  
-----  
Ingredient list extracted from technical datasheet:  
mini 16,56 ( - 10 % )  
-----  
=====
```

Pistes d'améliorations identifiées

En plus de la mesure de la performance, qui est indispensable avant de pouvoir procéder à des ajustements, les pistes identifiées à sont les suivantes :

- Faire un découpage plus élaboré du texte des pièces jointes en blocs, potentiellement avec des expressions régulières
- Essayer d'autres manières de vectoriser les textes (utiliser un comptage de mots binaire : présence/absence, calculer l'inverse document frequency, ...)
- Essayer une autre manière de calculer la similarité
- Utiliser des fonctions plus élaborées de text preprocessing (retrait des stopwords, ...)

6.2 Second prototype : industrialisation

L'objectif de ce second prototype est de permettre est d'industrialiser un peu le code afin :

- d'être en mesure inspecter les résultats obtenus et pouvoir donner des explications sur la réponse donnée par le modèle
- de pouvoir utiliser des fonctionnalités de mesure de la performance du modèle

- d'être en mesure de faire varier les paramètres du modèle en vue de l'optimiser

Comme présenté à la section 2.4.5 page 14 relative à la comparaison entre les données du PIM et celles récupérées lors de l'étiquetage, il y a un grand nombre d'écart. Or, si on entraîne le modèle et qu'on mesure sa performance sur des données de mauvaise qualité, on aura de mauvais résultats. Ce second modèle se basera sur les données manuellement étiquetées, afin d'avoir une base de comparaison dans la mesure de la performance. Le fonctionnement de ce modèle est présentés à la FIGURE 14 page 35. La méthodologie utilisée à cette partie est présentée dans le notebook « Modèle basé sur les données manuellement étiquetées » en annexe G.3 page 176. Les différents transformateurs et estimateurs spécifiques sont définis dans le module pimest, inclu en annexe H.4 page 277.

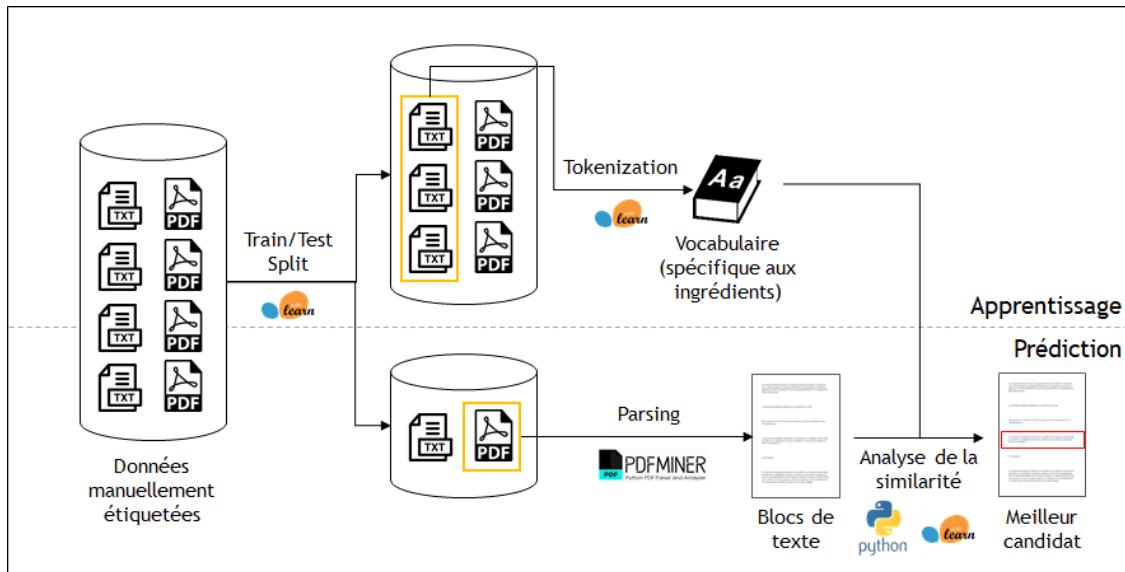


FIGURE 14 – Schéma de principe du modèle basé sur les données étiquetées

6.2.1 Chargement des données manuellement étiquetées

La toute première étape est la constitution d'un dataframe contenant :

- les uid pour indexer les produits
- les listes d'ingrédients manuellement étiquetées depuis les fiches techniques
- le contenu de chacune des fiches techniques au format texte

On commence par charger les données du fichier csv contenant les uid et les listes d'ingrédients. Ensuite, un pipeline scikit learn d'acquisition des données est lancé. Il s'agit de 4 transformateurs en série, qui effectuent les travaux suivants :

- construction du chemin pointant vers les fiches techniques (sur la base des uid)
- construction d'une feature contenant les données des fichiers, en binaire
- construction du texte complet de la fiche technique (en se basant sur la library pdfminer.six)

Le résultat du lancement de ce pipeline est présenté à la TABLE 9 page 36.

text
<p>NESCAFÉ® SPÉCIAL FILTRE\n\nDose individuelle de 2 g\nTechnologie micro-grains\n\nCODE EAN (UC)\n\n3033710076017\n\nDENOMINATION LEGALE DU PRODUIT\n\nDESCRIPTION DU PRODUIT\n\nCafé instantané et café torréfié moulu.\n\nUne dominante Arabica pour l'arôme et une pointe de Robusta pour le \ncorsé, associés à une torréfaction légère pour un café équilibré et peu \namer.\n\nSachet dose pour une tasse.\n\nDOSAGE PRECONISÉ\n\nMODE OPERATOIRE\n\nPour obtenir\n\n1 café Court (DA)\n\n1 café Long (DA)\n\nEau\n\n12\n\nncl\n\nncl\n\nNESCAFÉ®\n\nSPÉCIAL FILTRE\n\n2\n\nn2\n\nng\n\nng\n\nA reconstituer avec de l'eau.\n\nTempérature de l'eau : 75°C\nPour une qualité optimale, utilisez de l'eau filtrée.\n\nIngrédients : Café instantané, café torréfié moulu (3%).\n\nINGRÉDIENTS\n\nPROFIL GUSTATIF\n\nIntensité\n\nConditionné sous atmosphère protectrice.\n\nENGAGEMENT QUALITÉ\n\nNESTLÉ a un système de management de la qualité, le NMS (NESTLÉ \nManagement System), en cohérence avec les systèmes ISO 9001 ...</p> <p>LENTILLES BLONDES 4mm\n\nRéférence PQG007-3.22.1\nVersion d'application : \nPage 1/2\n\nG\n\n15/10/2019\n\nPrésentation\n\nCaractéristiques\n\nphysico-chimiques\n\nDéfinition\n\nOrigine\n\nDénomination légale\n\nLentilles de couleur brun clair. Elles sont de forme biconvexe et \nposseident une peau assez épaisse. Leur diamètre est compris \nentre 4mm et 5mm\n\nChine, Canada, France, Italie, USA, Turquie\n\nLentilles blondes\n\nProcessus\n\nNettoyage, épierrage, triages\n\nConservation\n\n36 mois à l'abri de la chaleur et de l'humidité\n\nCritères d'analyses\n\nMoyenne/Tolérance\n\nMéthodes\n\nHumidité\n\nMatières minérales étrangères\n\nMatières végétales étrangères\n\nGraines\n\nImpropres\n\nBrisées\n\nGermées\n\nCalibre 4-5 mm\n\n11,5% / 16%max\n\n0,05% / 1%max\n\n0,15% / 0,5%max\n\n0,5% / 1%max\n\n0,4% / 1%max\n\n0,05% / 1%max\n\n90%min\n\nNF V03707\n\nMicrobiologie\n\nIl n'existe pas de réglementation concernant les exigences microbiologiques \npour ce produit.\n\nPesticides\n\nMét...</p> <p>FICHE TECHNIQUE\n\nPRODUIT FINI\n\nPurée de Poire Sans Sucres Ajoutés\n\nDate d'application : 05/05/2014\n\nPage : 1/2\n\nCoupelles Aluminium 120 x 95 g\n\nCe produit est une purée de fruits obtenue à partir des parties comestibles des fruits (après broyage et sans \nconcentration notable).\nCe produit est sans sucres ajoutés : il contient uniquement les sucres naturellement présents dans les fruits.\nLa purée présente une texture homogène et légèrement granuleuse.\n\nLa stabilité du produit est obtenue par pasteurisation et dosage à chaud.\n\nAspects nutritionnels\n\nDésignation et liste des ingrédients\n\nValeurs nutritionnelles (pour 100 g)\n\nDésignation légale : Purée de Poires sans sucres ajoutés *\n* Contient les sucres naturellement présents dans \nles fruits\n\nListe des ingrédients : Poire 99,9%, antioxydant : acide ascorbique.\n\nMatières grasses\n\nEnergie\n\n65 kcal\n\n273 kJ\n\nont acides gras saturés\n\nGlucides\n\nFibres alimentaires\n\nPro...</p>

TABLE 9 – Exemples du contenu de fiches techniques au format texte (tronqués)

6.2.2 Découpage des textes en blocs

Le second travail est le découpage des textes en blocs. Cette étape étant peu couteuse en temps de calcul, elle est réalisée sur l'ensemble du dataset avant le split entre set d'entraînement et set de test. Dans un premier temps, on va simplement effectuer ce découpage en coupant le texte lorsque deux retours à la ligne successifs sont détectés, comme cela avait été fait pour le premier prototype. Il est maintenant possible d'inspecter les résultats de cette étape, un exemple de découpage est présenté ci-dessous.

30/12/19	Nom latin (si disponible) / EAN Code	Nomenclature douanière / Customs code
Date d'impression :	Code barre	Conditions idéales de stockage / Conditions of storage
Remarque :	/ KEREX Code	Ingrédients :
Les informations contenues dans cette fiche technique sont données de bonne foi, en l'état actuel de nos connaissances, et selon les indications communiquées par le producteur ou le fournisseur. Il appartient au client de vérifier la conformité de la marchandise par rapport à l'usage qu'il en fait.	/(Latin name)	Conserver dans un endroit frais et sec Store in a cool dry place
Création :	TEEPTRAPPEUR X 3760063322262	5 ans / 5 years 0910999900
12/06/12	Poids net	Sucre, poivre noir, coriandre, légumes déshydratés (ail, oignon, poivron rouge), sel de mer, sucre d'érable, arôme d'érale naturel, huile végétale (canola)
12 rue René Cassin 37390 NOTRE DAME	Poids brut	Sugar, black pepper, coriander, dehydrated vegetables (garlic, onion, red bell pepper), sea salt, maple sugar, natural maple aroma, vegetable oil (canola)
Tél : 02 47 85 55 00 Fax : 02 47 41 33 32	Origin	/ Ingredients
FICHE TECHNIQUE	/ net weight	Contaminants / Contaminating
Mélange du trappeur, 70 g Trapper blend, 70g	/ gross weight	Ionisation / Irradiation
Code article KEREX	/ Origin	OGM / GMO
	0,07 Kilogramme 0,125 Kilogramme CANADA	
	/ General information	
	Informations générales DLUO conseillée / "Best before date" recommended	

Pesticides/ Pesticides	Sulfites	Caractères microbiologiques
Métaux Lourds	Lupin	/ Microbiological characteristics
/ Heavy Metals	Mollusques	
Allergènes et leurs dérivés (si présents)	/ Gluten	Microorganismes aérobies 30 °C
/ Allergens (if existing)	/ Crustaceans	Escherichia coli
Conformité à la directive 1999/2/CE (22/02/99)	/ Eggs	Salmonelles
Produit non ionisé et ne contenant pas d'ingrédients ionisés.	/ Fish	Levures
Not irradiated	/ Soy	Moisiures
accordingly with the Reg 1999/2/CE (22/02/99).	/ Milk	Aflatoxine Total
Free from GMO	/ Peanuts and Treenuts	Aflatoxine B1
Ne contient pas d'OGM, est non soumis à l'étiquetage sur les OGM	/ Celery and celeriac	
Conforme à la directive 396/2005 /CE	/ Mustarde	/ Total plat count (APC)
In accordance with Reg 396/2005 /CE.	/ Sésame	E. Coli
Conforme au règlement 1881/2006 /CE	/ Sulphites	/
In accordance with Reg 1881/2006 /CE..	/ Lupin	/ Salmonella
Gluten	/ Shellfish	/ Yeasts
Crustacés	Absence	/ Moulds
Oeufs	Absence	/ Total aflatoxin
Poisson	Absence	B1 aflatoxin
Soja	Absence	
Lait	Absence	NF V05-051 < 6 000 000 / g
Fruits à coque - Arachides	Absence	NF V08-053 < 10 / g
Céleri	Absence	NF V08-052 Absence dans 25g
Moutarde	Absence	NF V08-059 < 10 000 / g
Sésame	Absence	NF V08-059 < 10 000 / g

On constate que le découpage n'est pas idéal, cf. la fiche technique de ce produit, présentée en annexe E.1.7 page 123. Les séparations des cellules des tableaux de cette fiche ne sont pas prises en compte, et on a des blocs trop étendus.

6.2.3 Entrainement et prédition

Dans la mesure où l'on possède assez peu de données, on va conserver un échantillon assez important dans le jeu d'entraînement : 400 produits (soit 80% des données disponibles). Comme cela a été présenté ci-dessus, l'entraînement ne consiste qu'en la détermination du vocabulaire des ingrédients à partir des textes manuellement étiquetés. On fait tourner de la même manière que sur le modèle dit « ouvert », à savoir qu'on ne préprocesse que peu les données avant d'appliquer le CountVectorizer. Sur le set d'entraînement retenu, on a un vocabulaire d'ingrédients représentant 1204 mots.

La prédition du meilleur candidat se fait de la même manière que dans le cadre du prototype précédent (cf. section 6.1.3 page 31) : on compare la norme du vecteur du bloc avec le nombre de mots appartenant au vocabulaire des ingrédients. La représentation des textes sous forme de vecteur se fait simplement via les comptes de chacun des mots du texte.

6.2.4 Illustration des prédictions obtenues

Un échantillon des prédictions obtenues est présenté dans la TABLE 10 page 38. Pour éviter d'avoir des listes d'ingrédients prédites prenant trop de place dans cette table, celles dont la longueur dépasse 500 caractères ont été filtrées avant génération de cet échantillon. Les résultats présentés à cette table sont donc vraisemblablement biaisés, dans la mesure où les très longues listes prédites doivent avoir plus de chance d'être erronées.

Les grandes tendances qui se dégagent à l'analyse de cette liste sont les suivantes :

- globalement, les résultats sont bons. On retrouve régulièrement des morceaux de texte qui sont similaires à la liste cible
- une erreur qui revient régulièrement est le fait que le découpage en blocs est parfois imparfait, on sélectionne « trop large »
- à l'inverse, le modèle n'a pas retiré des listes d'ingrédients prédictes des mentions qui ont été retirées lors de l'étiquetage manuel (cf. les règles d'annotation présentées en annexe E.3.1 page 130) : les préfixes de type « Liste d'ingrédients : », les allégations telles que « Teneur totale en sucres : 60g pour 100g »
- ...
- le modèle semble plus performant lorsque la liste d'ingrédients réelle est longue. On le vérifiera dans le chapitre relatif à la mesure de la performance du modèle

Un mot sur les cas où la liste d'ingrédients cible ou prédictive sont vides :

- Les listes d'ingrédients cible sont vides lorsque la pièce jointe ne mentionnait pas de liste d'ingrédients. Cela peut arriver, et les produits concernés n'ont pas été sortis de l'échantillon. Il est important de pouvoir aussi mesurer les faux positifs, qui sont nombreux avec cette technique de choix systématique du meilleur candidat
- Les listes d'ingrédient prédictives sont vides lorsque l'outil de parsing des pdf (pdfminer.six) n'a extrait aucun texte. C'est le cas quand la pièce jointe était un document imprimé qui a été scanné. Le texte n'est présent que sous forme d'image (cf. la fiche technique du sel en annexe E.1.1 page 112)

TABLE 10 – Extrait des résultats de la prédiction

Liste d'ingrédients cible	Liste d'ingrédients prédictive
sucré*, LAIT en poudre*, beurre de cacao*, pâte de cacao*, émulsifiant : lécithine de tournesol (E322), extrait de vanille* * matière première issue de l'agriculture biologique cacao : 27% minimum <rien>	Liste des Ingrédients : sucré*, LAIT en poudre*, beurre de cacao*, pâte de cacao*, émulsifiant : lécithine de tournesol (E322), extrait de vanille* * matière première issue de l'agriculture biologique <rien>
Amidon de maïs* - Lait écrémé* - Sel - Fécule de pomme de terre* - Tomate* - Oignon* - Arômes naturels - Poivres* 3 % (poivre vert*, poivre blanc*, poivre noir*) - Huile de tournesol* - Extrait de levure* - Sucre caramélisé* - Ail* - Maltodextrine de maïs*. * issus de l'agriculture biologique	Amidon de maïs* - Lait écrémé* - Sel - Fécule de pomme de terre* - Tomate* - Oignon* - Arômes naturels - Poivres* 3 % (poivre vert*, poivre blanc*, poivre noir*) - Huile de tournesol* - Extrait de levure* - Sucre caramélisé* - Ail* - Maltodextrine de maïs*. * issus de l'agriculture biologique
semoule de blé dur supérieure et de l'eau <rien>	Ingrediénts : semoule de blé dur supérieure et de l'eau Boisson gazeuse aromatisée au jus de fruit à base de concentré S.Pellegrino Orange 33 cl (Aranciata) S.Pellegrino Citron 33 cl (Limonata) Le plaisir des fruits à l'italienne
Eau, maltodextrine, sel, arômes, sucre, arôme naturel de citronnelle, amidon modifié, ail en poudre, épices (com-bava, curcuma), extraits d'épices (gingembre, poivre), stabilisant (gomme xanthane).	Eau, maltodextrine, sel, arômes, sucre, arôme naturel de citronnelle, amidon modifié, ail en poudre, épices (com-bava, curcuma), extraits d'épices (gingembre, poivre), stabilisant (gomme xanthane).
Sucre, cacao maigre en poudre (beurre de cacao : 11% minimum), arôme vanille. Cacao : 32% minimum	Sucre, cacao maigre en poudre (beurre de cacao : 11% minimum), arôme vanille.

Continued on next page

Liste d'ingrédients cible	Liste d'ingrédients prédicté
Sucre ; sirop de glucose ; graisse de palme ; humectant : sirop de sorbitol ; gélatine ; acidifiant : acide citrique ; arôme.	<rien>
Gésier de dinde émincé 50%, graisse de canard 47%, sel, arômes naturels de poivre.	Gésier de dinde émincé 50%, graisse de canard 47%, sel, arômes naturels de poivre.
Purée de tomates mi réduite (64%), sucre, vinaigre, amidon modifié, sel, acidifiant : acide citrique	Liste des ingrédients : Purée de tomates mi réduite (64%), sucre, vinaigre, amidon modifié, sel, acidifiant : acide citrique
<rien>	Boisson gazeuse aromatisée au jus de fruit à base de concentré S.Pellegrino Orange 33 cl (Aranciata) S.Pellegrino Citron 33 cl (Limonata) Le plaisir des fruits à l'italienne
Sirop de glucose-fructose, framboises 35%, sucre, gélijifiant : pectines, acidifiant : acide citrique.	Liste ingrédients : Sirop de glucose-fructose, framboises 35%, sucre, gélijifiant : pectines, acidifiant : acide citrique. Préparée avec 35g de fruits pour 100g de produit fini. Teneur totale en sucres : 60g pour 100g.
Café instantané, café torréfié moulu (3%).	- NESTLÉ a un système de management de la qualité, le NMS (NESTLÉ Management System), en cohérence avec les systèmes ISO 9001 et ISO 22000. - Etiquetage conforme à la réglementation en vigueur sur les OGM - Ce produit ne contient pas d'ingrédients ionisés. - Certifications usines : ISO 9001, FSSC 22000, ISO 14001 et OHSAS 18001. - Agrément sanitaire : site non soumis à agrément sanitaire
sucre, pâte de cacao, beurre de cacao, cacao maigre en poudre, émulsifiant : lécithine de tournesol (E322), arôme vanille cacao : 50% minimum	Liste des Ingrédients : sucre, pâte de cacao, beurre de cacao, cacao maigre en poudre, émulsifiant : lécithine de tournesol (E322), arôme vanille
Eau, huile de tournesol, beurre 9,5 %, jaune d'oeuf 6 %, amidon modifié, sel, jus de citron concentré, amidon de maïs, épaississants (gomme guar, gomme xanthane), protéines de pois, sucre, arôme naturel, curcuma, extrait de paprika.	Eau, huile de tournesol, beurre 9,5 %, jaune d'oeuf 6 %, amidon modifié, sel, jus de citron concentré, amidon de maïs, épaississants (gomme guar, gomme xanthane), protéines de pois, sucre, arôme naturel, curcuma, extrait de paprika.
Piment rouge fort équeuté* (85%), cumin, ail moulu (3%), eau, arôme naturel d'ail, sel, sorbate de potassium. (* présence de sulfites)	A) Ingrédients : Piment rouge fort équeuté* (85%), cumin, ail moulu (3%), eau, arôme naturel d'ail, sel, sorbate de potassium. (* présence de sulfites)
	B) Origines des ingrédients : - Piments : Maroc - Ail : chine - Sel, arôme, épices, sorbate de potassium : Europe
	I) A) Critères Physico-chimiques :
	B) Critères microbiologiques :
Sucre, amidon de maïs, arôme vanille	ajouter le produit à la préparation avec les autres ingrédients de la recette et mélanger pour homogénéiser
Salicornes de culture, eau, sel, acide citrique	Se consomment en légumes d'accompagnement avec toutes préparations de poissons ou crustacés ou aussi avec des viandes blanches

Continued on next page

Liste d'ingrédients cible	Liste d'ingrédients prédicté
cèpes 70% (Boletus edulis et respective famille), huile de tournesol, blanquette 5% (Tuber borchii Vitt.), oignon, beurre, sel, protéines du lait, farine de riz, amidon de maïs, dextrose, extrait de levure, épices, arôme truffée, arômes naturels, antioxydant : acide l-ascorbique (E 300).	CODE DU PRODUIT : NOME DU PRODUIT : FORMAT : BARCODE (EAN13) : NOMENCLATURE COMBINÉE :
	Ingrediénts : cèpes 70% (Boletus edulis et respective famille), huile de tournesol, blanquette 5% (Tuber borchii Vitt.), oignon, beurre, sel, protéines du lait, farine de riz, amidon de maïs, dextrose, extrait de levure, épices, arôme truffée, arômes naturels, antioxydant : acide l-ascorbique (E 300).
Eau, haricots verts, sel.	Allergène Égoutter, ne pas rincer. Faire sauter 3 minutes avec de la matière grasse.

Chapitre 7

MESURE DE LA PERFORMANCE

Comme vu aux chapitre précédents, il est indispensable de mesurer la performance de nos modèles. On le fera sur la base du modèle précédent, se basant sur les données manuellement étiquetées. Le principe est présenté à la FIGURE 15 page 41.

7.1 Accuracy

La métrique qui tombe le plus sous le sens est l'accuracy (on utilisera le terme anglais pour éviter les confusions avec la notion de « precision » telle qu'elle est utilisée par exemple dans le f1-score). On mesure simplement la proportion de prédictions qui sont égales à la ground truth. La méthodologie utilisée est détaillée dans le notebook « Mesure de la performance » présenté en annexe G.4 page 189.

7.1.1 Approche naïve

Description de cette approche

L'approche « naïve » consiste simplement à mesurer la proportion de textes prédits strictement égaux à la ground truth. Or, comme cela a été vu précédemment :




FIGURE 15 – Illustration de la méthodologie de mesure de la performance

- les règles d'étiquetage manuel, détaillées à l'annexe E.3.1 page 130, montrent que des transformations sont parfois appliquées au contenu des listes d'ingrédients des pièces jointes avant d'établir la ground truth
- les textes à comparer sont longs (jusqu'à quelques centaines de caractères), cf. TABLE 10 page 38
- la mise en forme, en particulier les retours à la ligne, ne sont pas positionnés aux mêmes endroits. Dans le parsing des documents pdf, lorsque le texte revient à la ligne après avoir atteint le bord de la page, on a un retour à la ligne. Ce comportement n'a pas été reproduit dans l'établissement de la ground truth
- le découpage en blocs de texte, de manière simple, produit des textes qui ne sont pas toujours le reflet du contenu spatialisé de ce document (cf. l'exemple donné à la section 6.2.2 page 36, et la fiche technique associée en annexe E.1.7 page 123)

On s'attend donc à avoir une « accuracy naïve » faible.

Les résultats obtenus

Comme présenté dans notebook « Analyse de la performance » (cf. annexe G.4 page 189), les résultats obtenus sont conformes à l'attendu : l'accuracy est très faible. Elle vaut 1% (1 échantillon sur 100 produits) lorsqu'on la mesure sur l'échantillon de test après entraînement sur l'échantillon d'entraînement. Le seul

produit pour lequel la liste d'ingrédients a été correctement identifiée porte les ingrédients suivants.

Sirop de glucose, sucre, eau, stabilisants (E440i, E440ii, E415), acidifiants (E330, E450i), conservateur (E202).

Si on effectue une cross-validation sur l'ensemble des données étiquetées, en appliquant un découpage en 10 folds, on obtient une accuracy moyenne de $1.80\% \pm 1.89\%$.

Nécessité d'améliorer cette métrique

On a vu que l'accuracy calculée de manière naïve porte un jugement sévère sur la performance du modèle. Par exemple, à la troisième ligne de la TABLE 10 page 38, on voit bien que la liste d'ingrédients prédite est identique à la ground truth, si ce n'est qu'les retours à la ligne ne sont pas positionnés exactement au même endroit. Comme on souhaite pouvoir ajuster le modèle, il est nécessaire d'avoir une métrique de mesure de la performance qui soit plus précise.

7.1.2 Avec du « text-postprocessing »

Le principe

Afin de pallier ces problèmes de mise en forme de texte, on assouplit un peu les contraintes par rapport à l'égalité stricte. En effectuant un traitement de text processing, à la fois sur la ground truth et les résultats du modèle, on va comparer des textes un peu plus « standardisés ». Les traitements effectués sont les suivants :

- On passe le texte en minuscules
- On retire la ponctuation
- On remplace tous les « whitespaces » (retours à la ligne, espaces multiples, tabulations, ...) par des espaces simples
- On retire les accents

L'ensemble de ces transformations sont faites en utilisant les fonctionnalités proposées par le CountVectorizer de la bibliothèque scikit-learn (cf. le notebook en annexe G.4 page 189 et le module pimest inclus en annexe H.4 page 277).

Les résultats

Si on évalue cette nouvelle accuracy avec le text processing, sur l'échantillon d'entraînement après entraînement sur l'échantillon d'entraînement, on obtient une accuracy de 14% (14 listes d'ingrédients correctement prédites sur 100). Ces 14 listes d'ingrédients sont présentées à la TABLE 11 page 43.

De la même manière que précédemment, si on fait une cross-validation sur l'ensemble des données manuellement étiquetées, on obtient une accuracy de $16.60\% \pm 3.35\%$.

Liste d'ingrédients cible	Liste d'ingrédients prédicté
Gésier de dinde émincé 50%, graisse de canard 47%, sel, arômes naturels de poivre.	Gésier de dinde émincé 50%, graisse de canard 47%, sel, arômes naturels de poivre.
Edulcorants sorbitol, isomalt, sirop de maltitol, aspartame, mannitol, sel d'aspartame-acesulfame, acesulfame-k, sucralose; gomme base (contient de la lecithine de SOJA), aromes, épaississant gomme arabique, humectant glycerol, colorant E171, agent d'enrobage cire de carnauba, colorant E163, antioxygène BHA. Contient une source de PHENYLALANINE.	Edulcorants sorbitol, isomalt, sirop de maltitol, aspartame, mannitol, sel d'aspartame-acesulfame, acesulfame-k, sucralose; gomme base (contient de la lecithine de SOJA), aromes, épaississant gomme arabique, humectant glycerol, colorant E171, agent d'enrobage cire de carnauba, colorant E163, antioxygène BHA. Contient une source de PHENYLALANINE.
mini poivrons jaunes, eau, sucre, sel, affermissant chlorure de calcium : E509, acidifiant : acide citrique, vinaigre, antioxydant : vitamine C E330	mini poivrons jaunes, eau, sucre, sel, affermissant chlorure de calcium : E509, acidifiant : acide citrique, vinaigre, antioxydant : vitamine C E330
Farine de BLE, huile de colza non hydrogénée, OEUFS de poules élevées en plein air (21%), sucre, stabilisant : glycérol, sirop de glucose-fructose, émulsifiant : mono- et diglycérides d'acides gras, poudres à lever : diphosphates et carbonates de sodium (BLE), féculle, sel, arôme.	Farine de BLE, huile de colza non hydrogénée, OEUFS de poules élevées en plein air (21%), sucre, stabilisant : glycérol, sirop de glucose-fructose, émulsifiant : mono- et diglycérides d'acides gras, poudres à lever : diphosphates et carbonates de sodium (BLE), féculle, sel, arôme.
Pommes de terre 59,5 % - Céleris 40 % - Amidon de maïs - Sirop de glucose de maïs - Huile de colza - Emulsifiants : E322, E471 - Stabilisant : E450i - Curcuma - Conservateur : E223 - Antioxydant : E304 - Acidifiant : E330.	Pommes de terre 59,5 % - Céleris 40 % - Amidon de maïs - Sirop de glucose de maïs - Huile de colza - Emulsifiants : E322, E471 - Stabilisant : E450i - Curcuma - Conservateur : E223 - Antioxydant : E304 - Acidifiant : E330.
<rien>	<rien>
Amidon de maïs* - Lait écrémé* - Sel - Fécule de pomme de terre* - Tomate* - Oignon* - Arômes naturels - Poivres* 3 % (poivre vert*, poivre blanc*, poivre noir*) - Huile de tournesol* - Extrait de levure* - Sucre caramélisé* - Ail* - Maltodextrine de maïs*. * issus de l'agriculture biologique	Amidon de maïs* - Lait écrémé* - Sel - Fécule de pomme de terre* - Tomate* - Oignon* - Arômes naturels - Poivres* 3 % (poivre vert*, poivre blanc*, poivre noir*) - Huile de tournesol* - Extrait de levure* - Sucre caramélisé* - Ail* - Maltodextrine de maïs*. * issus de l'agriculture biologique
Farine de FROMENT, poudre de LACTOSERUM, sucre, poudre d'OEUF entier, poudres à lever : (E450, E500), matière grasse LAITIERE, sel. Peut contenir des traces de : soja, fruits à coques, lupin.	Farine de FROMENT, poudre de LACTOSERUM, sucre, poudre d'OEUF entier, poudres à lever : (E450, E500), matière grasse LAITIERE, sel. Peut contenir des traces de : soja, fruits à coques, lupin.
Eau, maltodextrine, sel, arômes, sucre, arôme naturel de citronnelle, amidon modifié, ail en poudre, épices (com-bava, curcuma), extraits d'épices (gingembre, poivre), stabilisant (gomme xanthane).	Eau, maltodextrine, sel, arômes, sucre, arôme naturel de citronnelle, amidon modifié, ail en poudre, épices (com-bava, curcuma), extraits d'épices (gingembre, poivre), stabilisant (gomme xanthane).
OEUFS, farine de BLE, sucre, amidon de BLE, stabilisants : sorbitols- glycérol, cacao maigre en poudre (3,5%), émulsifiants : E472b - E477, poudres à lever : E450 - E500, sirop de glucose, LAIT écrémé en poudre, sel, conservateur : E202, épaississant : E410, arôme.	OEUFS, farine de BLE, sucre, amidon de BLE, stabilisants : sorbitols- glycérol, cacao maigre en poudre (3,5%), émulsifiants : E472b - E477, poudres à lever : E450 - E500, sirop de glucose, LAIT écrémé en poudre, sel, conservateur : E202, épaississant : E410, arôme.
Sirop de glucose, sucre, eau, stabilisants (E440i, E440ii, E415), acidifiants (E330, E450i), conservateur (E202).	Sirop de glucose, sucre, eau, stabilisants (E440i, E440ii, E415), acidifiants (E330, E450i), conservateur (E202).
Flageolets verts. Jus : eau, sel, affermissant : chlorure de calcium (E509)	Flageolets verts. Jus : eau, sel, affermissant : chlorure de calcium (E509)
Carottes, eau, sucre, sel, vinaigre d'alcool, acidifiant : acide lactique. Présence fortuite de CELERI	Carottes, eau, sucre, sel, vinaigre d'alcool, acidifiant : acide lactique. Présence fortuite de CELERI
Légumes 43,2 % (pomme de terre, oignon, carotte, tomate, poireau) - Amidon modifié de pomme de terre - Extrait de levure - Sirop de glucose de maïs - Huile de colza - Sucre - Arôme naturel - Ail - Curcuma.	Légumes 43,2 % (pomme de terre, oignon, carotte, tomate, poireau) - Amidon modifié de pomme de terre - Extrait de levure - Sirop de glucose de maïs - Huile de colza - Sucre - Arôme naturel - Ail - Curcuma.

TABLE 11 – Prédictions identifiées comme correctes après postprocessing

Les limites de cette métrique

Cette métrique est déjà plus intéressante que l'approche naïve, mais elle a quand même un défaut majeur : elle a une vision encore trop binaire des résultats. En effet, que le texte soit identique à un préfixe près (cf. la quatrième ligne de la TABLE 10 page 38), ou qu'il n'ait rien à voir (d'autres exemples sont présents dans cette même table), elle considérera la prédiction comme erronée. Or, il est important d'identifier les cas où le modèle s'est complètement trompé par rapport à ceux où il a quand même identifié le bon bloc contenant les ingrédients.

7.2 Fonctions de « similarité » spécifiques

On peut définir des fonctions de similarité, qui permettent d'être plus fin qu'une simple évaluation binaire du résultat du modèle. Cela permet de prendre plus finement en compte les cas où le modèle a identifié un bloc très similaire à la ground truth. On va pour cela s'appuyer sur diverses métriques permettant de mesurer l'écart entre des chaînes de caractères. À chaque fois, on définira une fonction de scoring qui sera une similarité : « higher is better ». De plus, elles seront normées pour prendre leurs valeurs entre 0 (chaînes de caractères totalement différentes) et 1 (chaînes identiques), ce qui permettra d'exprimer ces métriques en pourcentage. Ces similarités seront calculées après application du text-postprocessing, comme décrit à la section 7.1.2 page 42. L'ensemble de ces similarités seront calculées sur les caractères (on pourrait envisager de les calculer sur les mots).

7.2.1 Similarité basée sur la distance de Levenshtein

La distance de Levenshtein [17] entre deux chaînes de caractères est la distance d'édition pour passer de l'une à l'autre en prenant en compte les transformations suivantes :

- insertion d'un caractère
- suppression d'un caractère
- substitution d'un caractère par un autre

Cette distance possède les caractéristiques suivantes :

- elle peut se calculer entre deux chaînes de longueur différentes
- elle a pour minimum 0 (si et seulement si les deux chaînes sont identiques)
- a pour majorant la longueur de la plus longue des deux chaînes

Pour construire une fonction de similarité telle que présentée en introduction de cette section, on appliquera la transformation suivante :

$$sim_{lev}(s_1, s_2) = 1 - \frac{dist_{lev}(s_1, s_2)}{\max(\len(s_1), \len(s_2))}$$

en notant $dist_{lev}$ la distance de Levenshtein, $\len(s)$ la longueur de la chaîne s , et s_1 et s_2 les chaînes de caractères à comparer. Par exemple, la distance entre les chaînes « rateaux » et « chameau » vaut 4 :

- substitution du « r » par un « c »
- insertion du « h »
- substitution du « t » par un « m »
- suppression du « x »

7.2.2 Similarité basée sur la distance de Damerau-Levenshtein

La distance de Damerau-Levenshtein [13] est une variante de la distance de Levenshtein. Elle calcule également une distance d'édition, mais en ajoutant une transformation possible : l'interversion de deux caractères successifs. Les transformations possibles pour cette transformation sont :

- insertion d'un caractère
- suppression d'un caractère
- substitution d'un caractère par un autre
- interverson de deux caractères successifs

Ses caractéristiques sont les mêmes que la distance de Levenshtein (minimum, maximum) ; et elle est toujours inférieure ou égale à la distance de Levenshtein. On convertit cette distance en similarité de la même manière que la distance de Levenshtein.

7.2.3 Similarité de Jaro

La similarité de Jaro [14] est une fonction permettant de mesurer une similarité entre 0 (chaînes complètement différentes) et 1 (chaînes parfaitement identiques). L'heuristique derrière cette similarité est de considérer qu'entre deux chaînes, un caractère est « correspondant » (« matching ») s'il est déplacé de moins de la moitié de la longueur de la plus longue des deux chaînes. Ensuite, la similarité est fonction croissante du nombre de caractères « correspondants » et décroissante du nombre de caractères « correspondants » mais mal placés. Sur des chaînes longues de quelques dizaines de caractères, la quasi-totalité des caractères seront « correspondants ». Elle est en général plutôt adaptée à des comparaison de chaînes courtes telles que des noms propres ou des mots de passe.

7.2.4 Similarité de Jaro-Wrinkler

La similarité de Jaro-Winkler [15] est une variante de la similarité de Jaro. Elle possède la même heuristique que la distance de Jaro, avec en plus comme caractéristique de donner un poids plus important aux 4 caractères qui font le début de la chaîne de caractères. Cette métrique est encore moins adaptée au cas d'usage que la précédente.

7.2.5 Évaluation de ces similarités sur la ground truth

Les résultats de l'évaluation de chacune de ces similarités sont présentés à la TABLE 12 page 46. On

	train/test set	cross validation
Levenshtein	48.86%	49.79% +/-3.73%
Damerau-Levenshtein	48.86%	49.80% +/-3.72%
Jaro	63.56%	62.78% +/-3.28%
Jaro-Winkler	65.67%	64.40% +/-3.50%

TABLE 12 – Évaluation du modèle en utilisant les métriques de similarité

constate que :

- les similarités de Levenshtein et Damerau-Levenshtein donnent des résultats identiques
- les similarités de Jaro et de Jaro-Winkler donnent des évaluations très généreuses de la performance du modèle, comme on pouvait s'y attendre sur la base de textes longs

7.2.6 Décision sur la métrique à utiliser et illustration

Les similarités de Jaro et Jaro-Winkler sont abandonnées car non pertinentes pour notre cas d'usage, qui se base sur des textes de plusieurs dizaines de caractères. Les similarités de Levenshtein et Damerau-Levenshtein donnant des résultats identiques, on choisira plutôt la distance de Levenshtein car son implémentation en C (bibliothèque python-Levenshtein) semble plus performante que celle en C++ de la bibliothèque Jellyfish.

Des exemples du début, du milieu et du bas du classement en termes de similarité de Levenshtein sur le jeu de test, après entraînement sur le jeu d'entraînement, sont présentés à la TABLE 13 page 47.

7.2.7 Performance en fonction de la longueur de la liste d'ingrédients

À la section 6.2.4 page 37, on avait mentionné le fait que le modèle semblait moins performant lorsque la liste d'ingrédients cible était courte. Maintenant que nous avons une fonctionnalité de mesure de la performance, il est possible de confirmer ou d'infirmier ce point. La représentation de ce lien est présentée en FIGURE 16 page 47. Il y a bien une corrélation positive entre longueur de la liste d'ingrédients et performance du modèle ($r^2 \approx 0.340$, après retrait des outliers). Le mode de production de ce graphe est présenté à la fin du notebook « Mesure de la performance » inclus en annexe G.4 page 189.

Listes d'ingrédients cibles	Listes d'ingrédients prédites	Lev	Dam-Lev	Jaro	Jaro-Win
Gésier de dinde émincé 50%, graisse de canard 47%, sel, arômes naturels de poivre.	Gésier de dinde émincé 50%, graisse de canard 47%, sel, arômes naturels de poivre.	100.00%	100.00%	100.00%	100.00%
mini poivrons jaunes, eau, sucre, sel, affermissant chlorure de calcium : E509, acidifiant : acide citrique, vinaigre, antioxydant : vitamine C E330	mini poivrons jaunes, eau, sucre, sel, affermissant chlorure de calcium : E509, acidifiant : acide citrique, vinaigre, antioxydant : vitamine C E330	100.00%	100.00%	100.00%	100.00%
Farine de BLE, huile de colza non hydrogénée, OEUFS de poules élevées en plein air (21%), sucre, stabilisant : glycérol, sirop de glucose-fructose, émulsifiant : mono- et diglycérides d'acides gras, poudres à lever : diphosphates et carbonates de sodium (BLE), féculé, sel, arôme.	Farine de BLE, huile de colza non hydrogénée, OEUFS de poules élevées en plein air (21%), sucre, stabilisant : glycérol, sirop de glucose-fructose, émulsifiant : mono- et diglycérides d'acides gras, poudres à lever : diphosphates et carbonates de sodium (BLE), féculé, sel, arôme.	100.00%	100.00%	100.00%	100.00%
Pommes de terre, eau, sel.	Anhydride sulfureux et sulfites en concentrations de plus de 10 mg/kg exprimé en SO2	15.48%	15.48%	48.29%	48.29%
AMANDES décortiquées	Valeur énergétique : Matières grasses : dont ac gras saturés : Glucides : dont sucres : Fibres alimentaires : Dietary fibre Protéines : Sel :	12.80%	12.80%	46.93%	46.93%
Poire 99,9%, antioxydant : acide ascorbique.	Ce produit est une purée de fruits obtenue à partir des parties comestibles des fruits (après broyage et sans concentration notable). Ce produit est sans sucres ajoutés : il contient uniquement les sucres naturellement présents dans les fruits. La purée présente une texture homogène et légèrement granuleuse.	9.67%	9.67%	43.73%	43.73%
100% haricots blancs bio	Les légumes secs sont mis en avant par tous les nutritionnistes pour leurs apports en protéines et fibres. Ils s'inscrivent parfaitement dans le PNNS. Les légumes secs bio bénéficient également d'une agriculture résonnée et donne des garanties en termes de développement durable.	6.62%	6.62%	35.47%	35.47%
Persil	Céréales contenant du gluten (à savoir blé, seigle, orge, avoine, épeautre, Kamut ou leurs souches hybrides) et Produits à base de ces Céréales.	4.55%	4.55%	50.76%	50.76%

TABLE 13 – Illustration de l'évaluation du modèle à l'aide des métriques de similarité

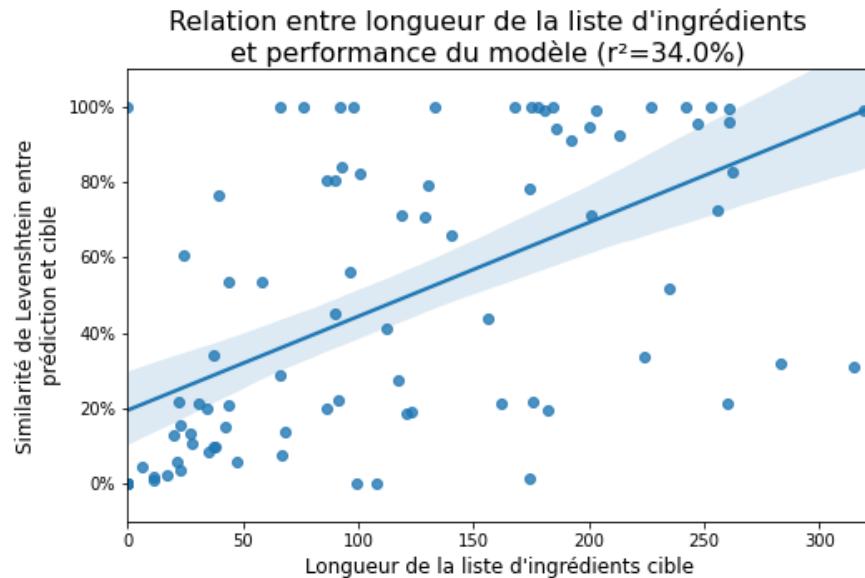


FIGURE 16 – Performance du modèle en fonction de la longueur des listes d'ingrédients

Chapitre 8

AJUSTEMENT DES PARAMÈTRES

8.1 Description des paramètres ajustables

Les paramètres ajustables sur le modèle présenté ci-dessus sont multiples (text-preprocessing, découpage des textes en blocs, calcul de similarité, ...). Maintenant qu'un pipeline équipé d'une fonctionnalité de mesure de la performance est disponible, on va pouvoir faire varier les paramètres et évaluer l'impact sur la performance du modèle.

8.1.1 Text-preprocessing

L'étape de text-preprocessing vise à nettoyer et standardiser le contenu des textes. Elle est appliquée aux textes avant entraînement et avant prédiction. Il est nécessaire de bien appliquer les mêmes règles à ces deux étapes. Parmi les fonctionnalités classiques de texte préprocessing, on va procéder de la manière suivante :

Mise en minuscule : On appliquera systématiquement la mise en minuscule. La casse est plutôt un facteur qui va pénaliser l'interprétation du texte, en contribuant à la création artificielle de mots synonymes.

Retrait des accents : L'impact du retrait des accents sera mesuré sur la performance du modèle. En effet, même s'il peut amener à la création d'homonymes, sur des textes en français inclus dans des pdf et issus de multiples sources cette fonctionnalité peut avoir une influence positive.

Gestion des stopwords : On vérifiera l'impact de retirer les stopwords (mots fréquents peu porteurs de sens) de l'ensemble des textes (listes d'ingrédients cible, contenu des documents) avant entraînement ou prédiction. On se basera sur une liste déterminée à partir des mots les plus fréquents dans le corpus des documents, qui ne portent pas de signification. Il est pressenti que ces stopwords risquent d'avoir un impact important sur le résultat de l'algorithme, en ajoutant dans l'ensemble des blocs candidats un grand nombre de mots étant considérés comme des ingrédients.

8.1.2 Découpage du texte des documents en blocs

On peut envisager d'autres méthodes de découpage des textes complets des documents en blocs candidats. Il avait été vu lors du prototypage que cette fonction pouvait influer fortement sur la qualité du résultat (il est inutile de chercher une bonne solution pour trouver le bon candidat si on détermine mal la liste de candidats). On éprouvera les techniques suivantes :

- comme en prototypage, en coupant dès que deux retours à la ligne successifs sont identifiés
- à chaque retour à la ligne

- via une expression régulière, on coupera dès qu'on trouve un ensemble de whitespaces (espaces, retour à la ligne, tabulation, ...) contenant au moins 2 retours à la ligne

8.1.3 Vectorisation des textes

Bag Of Words : Les textes seront représentées sous forme de vecteurs via l'approche « Bag Of Words ».

On évaluera les méthodes suivantes pour la transformation des textes en vecteurs :

- de manière binaire : la coordonnée est à 1 si le mot est présent au moins une fois dans le texte, 0 sinon
- en term-frequency (tf) : la coordonnée correspond à la fréquence d'apparition du mot dans le texte
- en tf-idf, l'inverse document frequency pouvant être calculée en référence au corpus du contenu des documents
- via une fonction de score absolu, tel que décrit dans la partie sur l'analyse des données, à la section 5.2 page 21
- via une fonction de score relatif (décrit dans la même section)

n-grams : On testera également la possibilité de prendre en compte les bigrammes ou les trigrammes de mots et les résultats que cela amène (à la fois dans l'entraînement et dans la prédiction).

Embeddings des mots : Enfin, on procédera aux calculs d'embeddings de mots, en appliquant les méthodes suivantes :

- truncated SVD [16] : on approxime la matrice des textes vectorisés en calculant ses valeurs singulières et en n'en gardant que les 100 plus importantes (valeur choisie arbitrairement). Les embeddings des mots sont récupérable directements depuis le transformateur TruncatedSVD mis à disposition dans la bibliothèque scikit-learn.
- Word2Vec [21] : cette méthode de calcul des embeddings se base sur l'entraînement d'un réseau de neurones pour la prédiction d'un mot à partir des autres mots de son contexte (Continuous Bag Of Words, CBOW), ou de prédire le contexte à partir d'un mot (skip-gram). Les embeddings sont les poids de la couche intermédiaire du réseau de neurones après entraînement. On utilisera l'algorithme CBOW, avec un nombre de features de 100.

Cette manière de représenter les textes et les mots se traduit par une *réduction de la dimensionnalité*, qui passe du nombre de mots dans le vocabulaire (plus de 10 000 dans notre cas) au nombre de features conservées (on en gardera 100).

8.1.4 Calcul de similarité

Similarité cosinus

Cette méthode nécessite de représenter le vocabulaire des ingrédients sous la forme d'un vecteur, d'une des manières présentées à la section précédente. On calcule le cosinus de l'angle entre le vecteur du vocabulaire et celui du candidat. Plus ce cosinus est élevé, plus la similarité est importante. Cette similarité n'a pas

de paramètre, une fois que les vecteurs ont été calculés. Il est possible d'appliquer ce calcul de similarité y compris après application d'un embedding des vecteurs de texte (ex : Word2Vec, tSVD, ...). Une illustration de la similarité cosinus est proposée à la FIGURE 17 page 51. Enfin, ce mode de calcul de la similarité permet d'ajuster la direction du vecteur cible en fonction de divers critère (fonctions de scoring spécifiques, cf. section 8.1.3 page 49 sur la vectorisation des textes)

Par projection

Cette méthode nécessite uniquement de projeter le candidat sur le sous espace généré par les mots du vocabulaire des ingrédients. On fait ensuite le rapport entre la norme du vecteur initial, à celle de sa projection. On peut envisager cette similarité un peu comme un calcul de l'angle entre le vecteur candidat et le sous-espace cible. Attention, si on utilise la même norme pour mesurer le vecteur initial et sa projection, on choisira toujours les candidats dont aucun mot n'est hors du vocabulaire (cf. l'illustration présentée à la FIGURE 18 page 51). Une manière de s'affranchir de ceci est choisir pour mesurer le vecteur initial une norme L_p et pour sa projection une norme L_q avec $p > q$. En effet, un résultat d'algèbre linéaire [10] montre que :

$$\forall x \in \mathbb{R}^n, p > q \Rightarrow \|x\|_p \leq \|x\|_q$$

Pour rappel, la norme L_p d'un vecteur x est définie par :

$$\|x\|_p = \left(\sum_i |x_i|^p \right)^{1/p}$$

où les x_i sont les coordonnées de x . Ce calcul de similarité ne peut se faire que dans l'espace initial, où les vecteurs représentant les textes peuvent être projetés sur un espace généré par des mots. Si une réduction de la dimensionnalité a eu lieu, par exemple via le calcul d'embeddings, il n'est pas possible de déterminer un sous-espace généré par les mots du vocabulaire des ingrédients. De plus, contrairement au calcul de similarité cosinus, il n'est pas possible de pondérer les différents mots du vocabulaire des ingrédients (via un calcul de score spécifique, un tf-idf, ...). Ce mode de calcul est paramétrique, c'est à dire qu'il faut définir la norme de l'espace de départ et la norme dans le sous-espace de projection. Par exemple, le mode de calcul retenu dans les prototypes décrits précédemment (chapitre 6 page 29) est un calcul de similarité par projection utilisant les normes L_2 sur l'espace initial et L_1 sur le sous-espace de projection. La formule de calcul était :

$$\frac{\text{Nombre de mots du candidat qui sont des ingrédients}}{\text{Norme euclidienne du vecteur du candidat}} = \frac{\|\text{Vecteur projeté}\|_1}{\|\text{Vecteur initial}\|_2}$$

où le vecteur initial est la matrice des textes avec les comptes de mots.

Illustration de ces calculs de similarité

On illustre ces deux manières de mesurer la similarité en prenant l'exemple suivant. Le vocabulaire des ingrédients est constitué des mots « eau » et « sucre », et le mot « eau » est 2 fois plus représenté que le mot « sucre ». Les textes candidats sont « sucre eau sucre » et « commercial commercial sucre ». Ces deux exemples sont présentés en FIGURE 17 page 51 et FIGURE 18 page 51. Sur ces figures, la similarité correspond aux angles matérialisés en vert. Si on récapitule les valeurs respectives des similarités, on obtient les résultats présentés à la TABLE 14 page 52

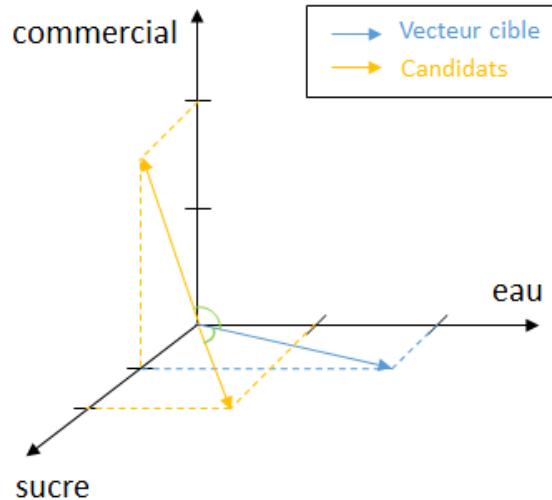


FIGURE 17 – Illustration de la similarité cosinus

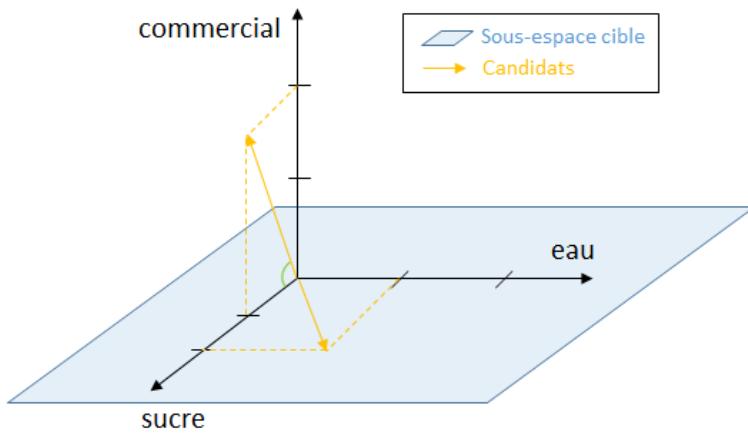


FIGURE 18 – Illustration de la similarité projection

Candidats	Cosinus	Projection L_1/L_1	Projection L_2/L_1	Projection L_3/L_1
sucré eau sucre	0,8	1,	1,34	1,44
commercial commercial sucre	0,2	0,33	0,45	0,48

TABLE 14 – Exemples de calculs de similarité

8.2 Ajustements et résultats

On peut, dans l’optique d’améliorer la performance du modèle, ajuster certains paramètres et d’évaluer l’impact via une grid search. Pour l’ensemble des ajustements, on travaillera uniquement sur le set d’entraînement (400 échantillons) afin de se prémunir des effets de data leaking (qui amènerait à surestimer la performance lors de l’évaluation finale). On travaillera avec 8 folds de cross-validation, afin de rester sur des ordres de grandeurs comparables à ce qui avait été fait lors de l’évaluation du second prototype (10 folds sur 500 échantillons). Enfin, on effectuera une évaluation finale sur le set de test, après entraînement du modèle avec les meilleures performances sur le set d’entraînement. La sélection des meilleurs paramètres se fera sur la base de la similarité de Levenshtein (cf. chapitre 7 page 40), mais on illustrera également la performance via l’accuracy avec text-postprocessing. L’ensemble des résultats présentés à cette section sont issus du notebook « Tuning du modèle » présenté en annexe G.5 page 203.

8.2.1 Ajustement du text-preprocessing

Les résultats de la grid search sur le text-preprocessing sont présentés à la FIGURE 19 page 54. Dans l’ensemble des représentations de ce chapitre, chaque point du swarmplot représente une cross validation de l’ensemble du set de test. Les folds individuels ne sont pas représentés, l’écart type pour un jeu de paramètres donné n’est donc pas représenté (le détail est présenté dans le notebook mentionné précédemment). Dans ce premier run, les paramètres explorés sont :

gestion des accents : conservation ou retrait des accents sur les textes

gestion des stopwords : conservation ou retrait des stopwords ('pas', 'le', 'en', 'pour', 'ou', 'ce', 'de', 'dans', 'du', 'and', 'un', 'sur', 'et', 'of', 'est', 'par', 'la', 'les', 'dont', 'au', 'des', 'que') des textes

constitution des ngrams : seulement les monogrammes, puis monogrammes et bigrammes, puis monogrammes et bigrammes et trigrammes

découpage des textes en blocs : comparatif des trois fonction présentées précédemment à la section 8.1.2 page 48

fonctions de similarité : identification du meilleur candidat par similarité cosinus, ou par projection L_2/L_1

soit un total de 72 jeux de paramètres testés. Il apparaît que :

- le retrait des stopwords a un impact fortement positif sur la performance de l’algorithme

- le retrait des accents a un impact positif mais relativement marginal
- l'écart-type sur la similarité est très élevé au sein d'un jeu de paramètre testé : il se situe systématiquement aux alentours de 5-6% pour une valeur moyenne autour de 50%

8.2.2 Tuning du découpage du texte des documents

On se sert des résultats de la grid search présentée précédemment. Les résultats sont présentés à la FIGURE 20 page 55. On en déduit que la fonction qui présente les meilleurs résultats est la troisième fonction (via une expression régulière avec 2 retours à la ligne). L'écart n'est pas énorme avec la fonction 1 (1 à 2% sur l'accuracy moyenne), mais il est présent de manière consistante.

8.2.3 Comparatif des fonctions de similarité

Dans ce run, on va comparer les similarité cosinus et projection, en faisant varier les paramètres de la similarité projection (normes de l'espace complet et du sous-espace de projection). Les résultats sont présentés à la FIGURE 21 page 57. Ils sont issus d'une grid search lors de laquelle on a fixé :

- la tokenisation avec des monogrammes et des bigrammes
- le retrait des accents
- le retrait des stopwords
- la fonction de découpage en blocs numéro 3

et on a fait varier :

- les fonctions de similarité, cosinus ou projection
- les normes utilisées, pour les fonctions de projection
- la construction de la matrice des textes entre les comptes de mots, ou l'identification uniquement de la présence / absence d'un terme (« binary Bag Of Word »)

Dans la représentation qui en a été faite, on a regroupé ensemble les similarité projection en fonction de l'écart de valeur entre les normes dans l'espace initial et le sous-espace de projection (ex : pour la similarité projection L_3/L_1 cet écart vaut 2) ; En peut en tirer des conclusions intéressantes :

- les écarts-types au sein d'une cross-validation sont toujours importants (5-6% environ, sur la similarité de Levenshtein)
- la similarité par projection surperforme nettement la similarité cosinus
- comme on pouvait s'y attendre, les performances sont catastrophiques si on applique la même norme dans l'espace de départ et le sous-espace de projection (on choisira toujours un texte qui n'a aucun mot hors du vocabulaire des ingrédients, peu importe sa longueur)
- des tendances régulières se dessinent parmi les groupes avec un delta constant, bien visibles sur l'indicateur de performance en similarité :
 - les performances semblent suivre deux tendances polynomiales avec des coefficient d'ordre maximal négatif, différentes selon que la tokenisation est binaire ou non

Comparaison des fonctions de preprocessing




FIGURE 19 – Résultats du tuning du preprocessing

Comparaison des fonctions de découpage




FIGURE 20 – Résultats du tuning du découpage des textes des documents

- la tokenisation binaire est systématiquement meilleure que la tokenisation par comptes
- on atteint un maximum de performance aux alentours des projections L_4/L_3 , L_6/L_4 , L_8/L_5

8.2.4 Comparaison des méthodes de vectorisation

Inverse document frequency

On peut apprécier l'impact de la prise en compte de l'inverse document frequency lors de la vectorisation, sur la performance du modèle. Cette inverse document frequency se calcule par rapport à la présence des termes dans le corpus des textes des documents. Les résultats sont présentés à la FIGURE 22 page 58, sur la base d'une grid search faisant varier :

- le type de similarité : cosinus ou projection L_4/L_3
- l'utilisation ou non de l'inverse document frequency
- la prise en compte de ngrams, avec des ngrams de longueur de 1 à 5

L'impact est très différent selon qu'on identifie le meilleur candidat via le cosinus, plutôt que via la projection. La qualité des prédictions s'améliore en utilisant l'inverse document frequency couplée à la similarité cosinus, mais est très fortement dégradée dans le cas de la projection.

Prise en compte des n-grams

La vectorisation des textes peut également être ajustée, en ajoutant en tant que features des ngrams de longueur variable. L'impact de la prise en compte de ngrams de plus en plus long (de 1 à 5 mots) est illustré à la FIGURE 23 page 59.

On peut constater que :

- la prise en compte de ces ngrams a des effets mitigés dans le cas du cosinus
- elle est par contre bénéfique pour la projection, avec une saturation à partir des trigrammes

Fonctions de scoring spécifique

Les fonctions de scoring « absolu » et « relatif » ont été présentées dans le chapitre sur l'analyse des données, à la section 5.2 page 21. Elles permettent de calculer un score pour chaque mot, afin de quantifier son « affinité » pour les listes d'ingrédients. L'utilisation d'un score relatif, qui peut être négatif (i.e. le mot concerné est plus souvent présent dans le corps du texte des documents que dans les listes d'ingrédients), et donc pénaliser le candidat. C'est par exemple le cas du mot « sel », qui est évidemment un ingrédient mais qui est également très représenté par ailleurs dans le contenu des fiches techniques. L'utilisation de ces scores ne se peut faire que pour la similarité cosinus, de la même manière qu'ilustré à la FIGURE 24 page 60 (qui montre la « négativité » du score du mot « sel »). Il est même possible que la similarité du candidat avec le vecteur cible soit négative.

Comparaison des méthodes d'identification du meilleur candidat

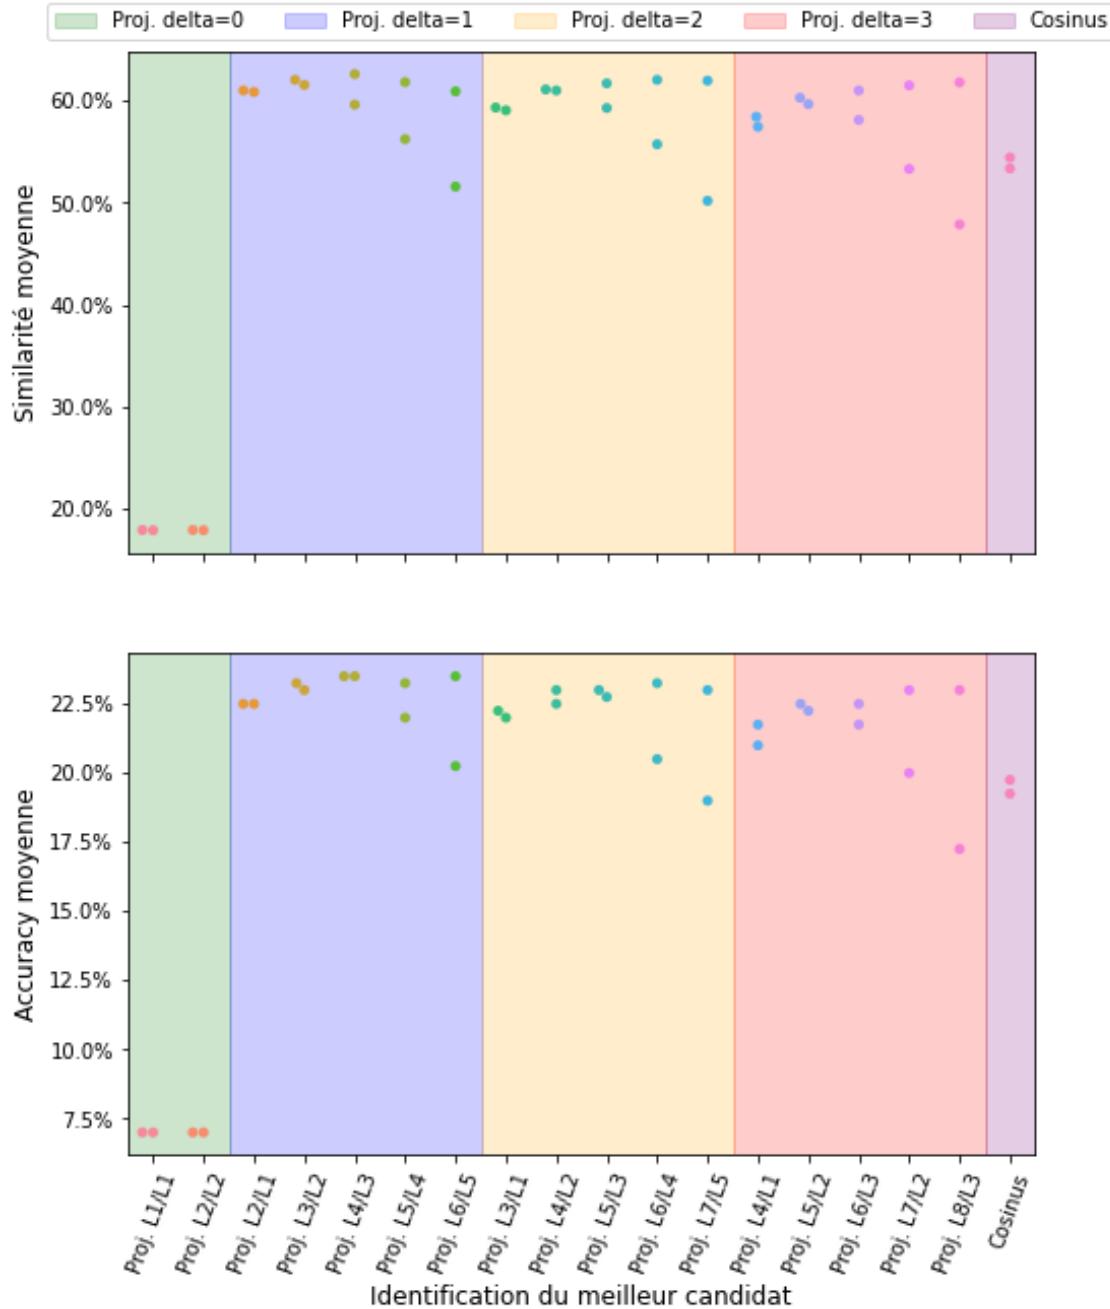


FIGURE 21 – Résultats du tuning des fonctions de similarité

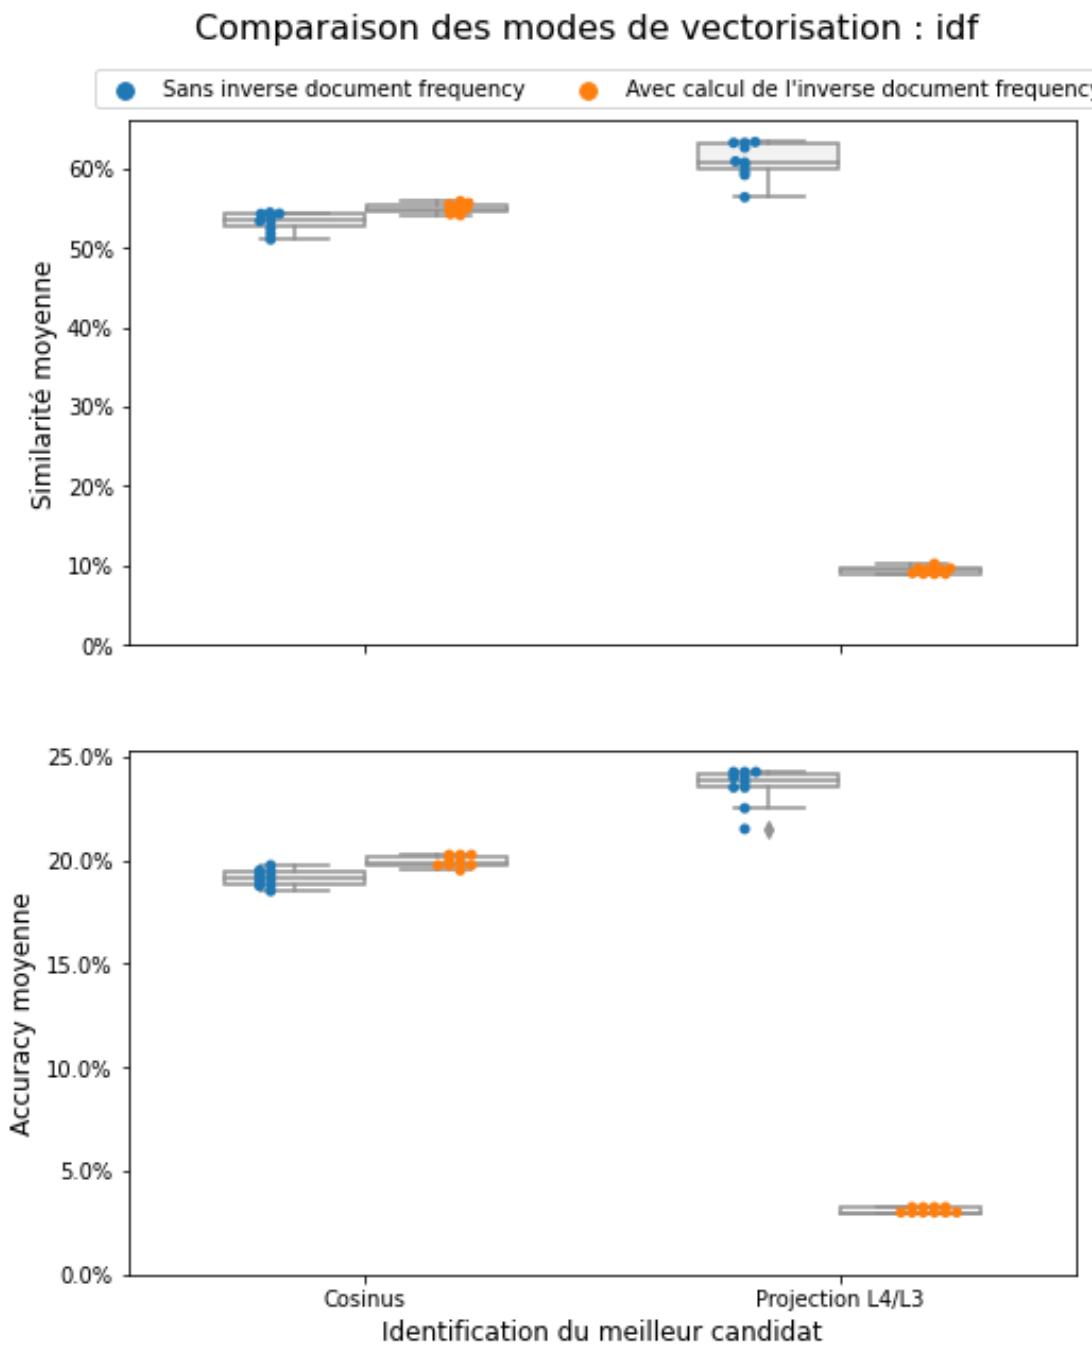


FIGURE 22 – Résultats du tuning de l'utilisation de l'inverse document frequency

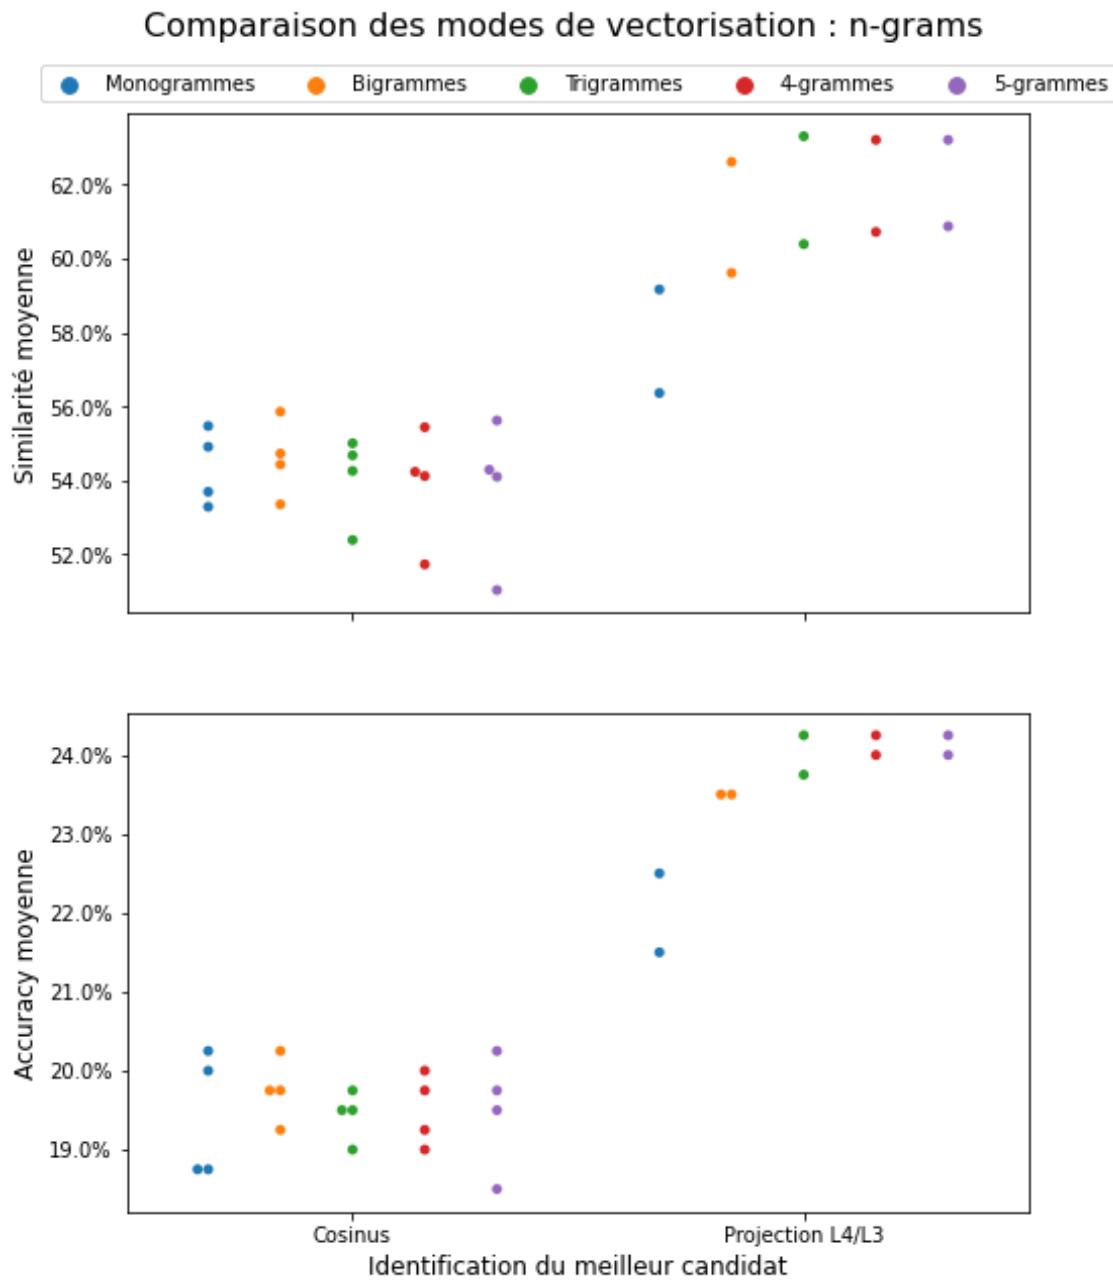


FIGURE 23 – Résultats du tuning de l'utilisation de l'inverse document frequency

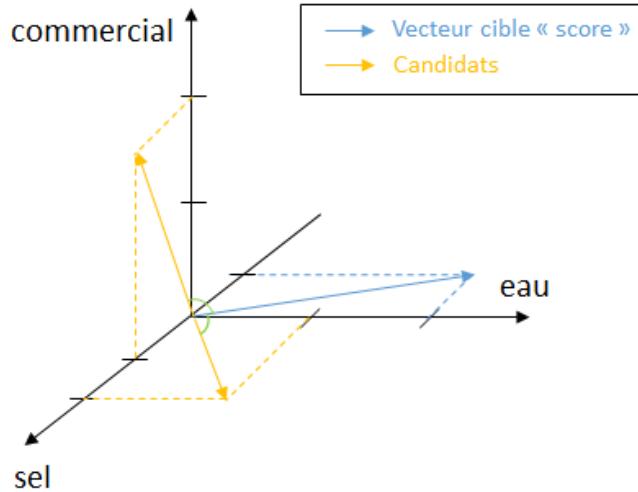


FIGURE 24 – Illustration de la similarité cosinus avec score relatif

L’impact des fonctions de scoring a été illustré sur la base d’une grid search s’appliquant uniquement au mode d’identification cosinus, sans n-grams, avec retrait des stopwords et des accents. Elle fait varier :

- la comptabilisation des mots de manière binaire ou via les comptes
- la détermination ou non de l’inverse document frequency
- les scores : sans, avec le score absolu ou avec le score relatif
- les embeddings de mots : sans, Word2Vec, truncated SVD

Les résultats sont présentés à la FIGURE 25 page 61. On constate que :

- l’utilisation du score relatif dégrade très fortement la performance du modèle
- l’utilisation de l’idf avec le score absolu dégrade légèrement la performance
- le seul impact positif à l’utilisation d’une fonction de scoring est que score absolu améliore marginalement la performance en l’absence d’idf

La cause de la très faible performance du score relatif semble être la suivante : comme illustré précédemment à la FIGURE 6 page 23, du fait de l’écart entre la taille des vocabulaires ingrédients et documents, les scores relatifs sont en moyenne négatifs. Par conséquent, plus ils sont longs, plus les vecteurs candidats ont en moyenne un produit scalaire négatif avec le vecteur cible. Ce qui signifie que le choix du meilleur candidat revient à prendre en compte le vecteur le moins négatif, voire un bloc de texte vide ou constitué de mots inconnus à l’entraînement…

8.2.5 Utilisation d’embeddings

L’utilisation d’embeddings a été évaluée via la même grid search que pour l’évaluation du scoring. Les résultats sont illustrés à la FIGURE 26 page 62. On constate que :

- les embeddings issus de la truncated SVD sous-performent par rapport aux autres méthodes (sans

Comparaison des modes de vectorisation : Scores spécifiques

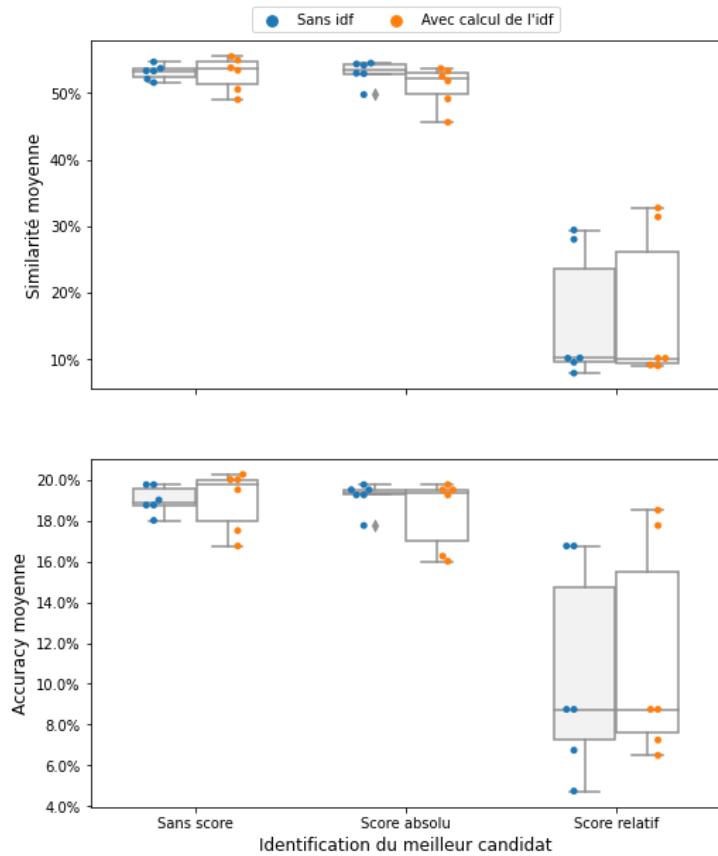


FIGURE 25 – Illustration de la similarité cosinus avec score relatif

embeddings ou Word2vec)

- l'utilisation de Word2vec n'augmente globalement pas la performance du modèle

L'utilisation de ces embeddings, entraînés sur notre jeu de données uniquement, n'est pas concluant.




FIGURE 26 – Illustration de la similarité cosinus avec score relatif

8.3 Conclusion, et évaluation finale de la performance

On peut tirer les enseignements suivants des travaux menés :

- des gains rapides ont été obtenus en travaillant sur le preprocessing de base : stopwords, gestion des accents, découpage en blocs
- la similarité projection sur-performe nettement la similarité cosinus
- l'utilisations d'algorithmes plus complexes (embeddings et scoring) ne suffit pas à compenser cet écart de performance

Les paramètres ayant obtenu la meilleure performance ($63.31\% \pm 3.83\%$) sur la grid search sont :

- similarité projection, avec les normes L_4/L_3

- retrait des stopwords, des accents
- découpage en blocs via la fonction 3 (avec expression régulière)
- vectorisation des textes binaire, sans appliquer l'inverse document frequency
- prise en compte des monogrammes, bigrammes et trigrammes

Si on entraîne un modèle avec ces paramètres sur le set d'entraînement, et qu'on évalue sa performance sur le set de test (qui n'a pas été utilisé lors du tuning des paramètres), on obtient les résultats suivants :

- Similarité de Levenshtein moyenne : 67.18%
- Accuracy postprocessée : 27%

Ces résultats sont globalement bons, et illustrés en annexe à la TABLE 29 page 134. Pour rappel, la performance initiale d'un modèle avant ajustement des paramètres était de 48.86% (cf. TABLE 12 page 46). Il apparaît que les principales améliorations passeraient par la mise en place de fonctions de découpage plus précises, de fonctionnalités de text postprocessing pour éliminer les préfixes, et d'OCR pour prendre en compte les documents numérisés.

Quatrième partie

TRAVAUX SUBSÉQUENTS

Chapitre 9 EXTENSION DES FONCTIONNALITÉS OFFERTES

9.1 Amélioration de la performance du modèle

Même si les résultats se montrent désormais très encourageants, il reste encore quelques améliorations à apporter pour que les utilisateurs y trouvent un réel intérêt. Avec une accuracy à 27%, il y a encore trop de corrections manuelles à apporter. Pour chacune des pistes d'amélioration identifiées, il faudra évidemment procéder à une vérification de l'impact via une cross validation sur le set d'entraînement.

9.1.1 Découpage du contenu des documents en blocs de textes

L'essentiel des erreurs vient de soucis sur le découpage du texte en blocs. Cela dégrade à la fois la performance en termes de similarité et d'accuracy, mais pénalise également la fonctionnalité d'identification du meilleur candidat. Plusieurs pistes d'amélioration sont offertes pour améliorer ce point :

- analyser les cas d'erreurs, et complexifier un peu l'expression régulière servant à découper le texte des documents en blocs
- multiplier les candidats pour une même fiche technique : on pourrait appliquer plusieurs fonctions de découpage différentes sur le document, et proposer l'ensemble des candidats obtenus au sélecteur
- dans la même logique, la constitution de « ngrams de blocs » pourrait compenser les cas de mauvais découpages car trop fins, et multiplierait également le nombre de candidats proposés au sélecteur
- enfin, il faudrait se pencher sur les fonctionnalités de clustering des objets (caractères en mots, mots en lignes, lignes en paragraphes) proposées par les bibliothèques de mining de pdf. Les blocs candidats pourraient correspondre aux paragraphes identifiés par l'outil mining.

De plus, il apparaît qu'une partie des écarts se situent en début ou en fin de texte (préfixes conservés alors qu'il aurait fallu les supprimer,) pourrait être corrigés s'il était possible de « tailler » le début et la fin du texte. On pourrait là encore procéder par apprentissage en déterminant :

- une liste de mentions qui améliorent la performance lorsqu'elles sont retirées
- ou d'autres critères (document frequency dans les textes des fiches techniques, document frequency dans les listes d'ingrédients, ...)

9.1.2 Amélioration de l'identification par similarité

Dans les résultats sur le set de test, il reste encore des blocs incorrectement identifiés alors que la liste d'ingrédients était bien présente par ailleurs. Même si l'écart entre similarité cosinus et projection est important, on suspecte qu'il existe des manières plus performantes d'ajuster la manière de représenter les textes. En particulier, l'utilisation du scoring relatif (cf. section 5.2 page 21) semblait prometteuse. Peut-être que tester une version où les scores relatifs sont calculés pour ne pas décaler les produits scalaires des candidats vers les valeurs négatives en moyenne pourrait être pertinente.

Une autre piste serait de faire tourner en parallèles plusieurs sélecteurs de blocs, et d'appliquer une méthode ensembliste, par exemple en les faisant voter. La performance du modèle est bonne sur les produits dont les listes d'ingrédients sont relativement longues, mais moins pertinente pour les produits plus bruts. L'identification d'un modèle performant sur les listes d'ingrédients courtes permettrait de pallier ce point et il faudrait l'associer au modèle actuel.

9.1.3 Filtrage des similarités trop basses

Un irritant majeur pour les utilisateurs est d'avoir un résultat complètement impertinent. Il serait intéressant d'identifier les cas où le modèle a retourné un candidat qui ne correspond pas à une liste d'ingrédients. On pourrait ensuite filtrer la proposition, et afficher à l'utilisateur que le traitement a échoué et que le modèle n'a pas réussi à extraire la liste d'ingrédients du document soumis. Une telle fonctionnalité pourrait également améliorer la performance du modèle, en couvrant les cas où le document fourni ne comporte pas de liste d'ingrédients. Cela pourrait se faire :

- en fixant un seuil minimum de similarité (cosinus et/ou projection)
- en utilisant d'autres critères (longueur du candidat, document frequency moyenne des mots qui le composent, ...)

9.2 Extension du périmètre couvert avec la méthode « textuelle »

Avant de pouvoir mettre en production des fonctionnalités de types extraction de connaissance depuis des documents, il serait intéressant d'en étoffer le périmètre. L'approche présentée dans ce document consiste à interpréter uniquement le texte brut, sans avoir recours à des fonctionnalités de spatialisation au sein du document.

9.2.1 Prise en compte de nouveaux types de pièces jointes

Les étiquettes produit doivent porter l'ensemble des informations réglementaires (données nutritionnelles, composition, allergènes, ..., cf. section 2.2.2 page 11). Même si les étiquettes ont plus tendance à être des documents pdf dont le contenu textuel n'est pas extractible sans faire appel à des fonctionnalités d'OCR (cf. TABLE 4 page 16). La performance de l'identification des listes d'ingrédients devrait être d'ailleurs assez bonne sur les étiquettes, dans la mesure où il s'agit de documents bien moins verbeux.

9.2.2 Utilisation d'outil d'OCR pour les pdf non structurés

L'utilisation d'outils d'OCR pourrait venir compléter les fonctionnalités de pdfminer.six, en permettant l'extraction des textes depuis les documents non structurés. La suite du traitement pourrait rester parfaitement identique, en traitant uniquement le contenu textuel extrait, sans notion de spatialisation. De plus, cela complémenterait parfaitement l'extension des fonctionnalités aux étiquettes produits.

9.2.3 Évaluation de la performances sur d'autres familles de produits

Le modèle a été construit sur la base des données de la branche ÉpiSaveurs (cf. la description des branches du groupe, en annexe B.1.2 page 78). Cette branche ne commercialise que des produits stockés à température ambiante (pas de produit frais ou surgelés). Il serait intéressant de tester ce modèle sur les données des autres branches du groupe, dans l'optique de vérifier que les fonctionnalités pourraient leur être étendues. Un point à vérifier sur cette extension serait si la performance serait meilleure en construisant des modèles séparés, en fonction de la famille de produit, ou un modèle général qui tournerait sur l'ensemble des données.

Les produits de chimie (cf. annexe C.1 page 97), commercialisés par la branche ÉpiSaveurs, font également l'objet d'une déclaration de composition obligatoire sur l'emballage. On pourrait envisager de faire la même évaluation du modèle sur ces produits. Comme les « ingrédients » des produits de chimie sont différents de ceux des produits alimentaires, il faudrait évidemment faire un entraînement particulier sur leurs données.

9.2.4 Récupération des dénominations réglementaires

Il est un autre texte qui est normalement présent sur l'emballage et la fiche technique du produit : la dénomination réglementaire (cf. annexe D.2.1 page 110). Il est envisageable de constituer un modèle qui aurait en charge de récupérer cette information depuis les fiches techniques, ou les étiquettes produit. Comme ces désignations sont en général plus courtes que les liste d'ingrédients, il faudrait prévoir d'ajuster les paramètres du modèle, avec une méthode similaire à ce qui a été fait et présenté au chapitre « Ajustement des paramètres » 8 page 48.

9.3 Changement de méthode

Dans le cadre d'un use case en lien avec l'extraction de connaissance sur les produits depuis des documents pdf, on pourrait également envisager de tout autres méthodes. Cela rendrait accessible un grand nombre d'autres fonctionnalités, voire cas d'usage.

9.3.1 Mise en place d'outil de spatialisation des textes

C'est clairement le sujet le plus prometteur à tester, mais également un des plus complexes à mettre en œuvre. L'idée derrière la spatialisation est de réussir à associer les informations présentes dans les documents entre elles, en fonction de leurs position dans le document. Il s'agit clairement d'un tout nouveau sujet, on passerait d'une problématique de traitement du langage à du traitement d'image. Le sujet est vaste, et il faudrait être en mesure :

- de détecter les tableaux présents dans les documents (voir par exemple la fiche technique des poivrons en annexe E.1.6 page 120) :
- puis de détecter les entêtes de lignes ou de colonnes, pour avoir une représentation à simple ou double entrée de l'information
- de construire les relations entre les niveaux hiérarchiques d'indexation dans ces tableaux (ex : Valeurs nutritionnelles > Énergie = 109 kJ)
- de comprendre la structure du document, et les liens entre les titres entre les contenus des différentes sections (cf. la fiche technique de la panna cotta, en annexe E.1.3 page 114)

Il s'agit d'un sujet ambitieux, mais qui aurait en plus l'avantage de pouvoir être étendu à la quasi totalité des cas métier où des documents sont interprétés. Dans le cas précis de la gestion de l'information produit, cela permettrait d'aller récupérer les données nutritionnelles par exemple (cf. annexe B.2.1 page 84).

9.3.2 Aides pour le contrôle de cohérence

Toujours dans l'optique d'améliorer la qualité des données des produits, on pourrait changer de sujet et passer à des contrôles de cohérence entre les données elles-mêmes. Par exemple, il est normalement possible

pour un utilisateur correctement formé de déterminer l'ensemble des allergènes du produit à la lecture de la liste d'ingrédients (sous réserve qu'elle mentionne bien également les contaminations croisées). On pourrait envisager de déterminer quels mots ou expressions parmi les listes d'ingrédients permettent d'identifier tel ou tel allergène réglementaire (cf. annexe B.2.1 page 83 pour plus de détail sur les allergènes).

Il serait également possible de déterminer, par des méthodes de classification, si un produit se qualifie pour une allégation nutritionnelle quelconque (ex : faible en sel), sur la base de ses données nutritionnelles, afin de contrôler si une allégation qui a été transmise par le fournisseur est cohérente.

Chapitre 10

DÉPLOIEMENT OPÉRATIONNEL DE

L'OUTIL

10.1 Mise en place d'une organisation projet

10.1.1 Sponsor et Client

La toute première étape pour le lancement d'un projet visant à mettre en œuvre ce modèle, serait d'identifier un sponsor capable de mobiliser une enveloppe budgétaire, et de prendre les décisions de niveau stratégique. Ensuite, il faudrait identifier quelques représentant métier (gestionnaires de référentiel, ingénieurs qualité, acheteurs, ...) qui seraient capable de se prononcer sur les règles de gestion et les décisions organisationnelles. Il est indispensable d'avoir ces deux niveaux engagés dans le projet dès son lancement.

La toute première décision attendu du sponsor serait le choix du cas d'usage, tel que décrit au chapitre 1 page 5 sur le cas d'usage. Souhaite-t-on mettre à disposition des fonctionnalité de préalimentation des informations produit ou bien faciliter et fiabiliser le contrôle ?

10.1.2 Choix techniques et technologiques

Les autres grandes décisions à prendre en compte en début de projet sont d'ordre techniques et technologiques. La première est de savoir dans quel langage le modèle de production serait développé. Poursuivre en python aurait l'avantage de pouvoir capitaliser sur les travaux déjà effectués, et de se baser sur les bibliothèques qui ont fait leurs preuves (essentiellement numpy et scikit-learn). De plus, il faudrait dès le début du projet définir la criticité de ces fonctionnalités, et prévoir dès le départ le mode de redondance et l'éventuel plan de reprise d'activité. Enfin, même si les travaux effectués ont montré que le modèle en l'état était peu

gourmand en mémoire et puissance de calcul, il faudrait extrapolier le dimensionnement nécessaire pour tenir la charge pour l'ensemble des branches du groupe.

10.1.3 Développement microservice ?

Tant la préalimentation, que l'aide au contrôle des données seraient implantables comme un service. Il suffirait pour cela de publier un service, qui fonctionnerait de la manière suivante (illustré à la FIGURE 27 page 69) :

- le PIM appelle le service, avec un message contenant l'uid du produit à contrôler ou préalimenter
- le serveur récupère du PIM les données nécessaires au contrôle ou à la préalimentation
- en retour, il renvoie au PIM soit l'état du contrôle (OK, erreur, avertissement, avec les précisions nécessaires), soit les données telles qu'elles doivent être préalimentées
- le PIM, sur la base de ce retour, affiche le résultat du contrôle ou bien alimente les données et les présente à l'utilisateur




FIGURE 27 – Diagramme de séquence des échanges entre PIM et le service

Ce mode de fonctionnement nécessiterait des développements supplémentaires au niveau du PIM :

- appel du service lorsque les conditions sont réunies (ex : lancement du contrôle des données par l'acheteur)
- intégration des données retournées si le cas d'usage est la préalimentation
- affichage à l'utilisateur du résultat du contrôle si le cas d'usage est l'appui au contrôle

10.2 Maintien en condition opérationnelle

10.2.1 Mise à niveau

Si le projet devait se poursuivre en python, afin de disposer d'un outil restant maintenu au fil du temps, il est nécessaire d'industrialiser ce prototype. Pour cela, il faudrait :

- procéder au refactoring de certaines classes. Le requester porte trop de responsabilités (requêteage des données du PIM, conversion en DataFrame, conservation persistantes des données stockées localement, ...) et devrait être séparé en classes plus petites. Le calcul de similarité par projection devrait être réécrit, pour éviter d'utiliser deux TFIDFVectorizer, mais plutôt d'effectuer une projection par produit de matrices.
- mettre en place les fonctionnalités de typage statique
- poursuivre la rédaction de tests unitaires, avec une cible de couverture à 80%
- revoir ou réécrire l'ensemble des docstrings, et générer la documentation du code via des outils tels que Sphinx

10.2.2 Intégration et déploiement continu

En parallèle de l'écriture des tests et du passage au typage statique, il faudrait mettre en place un pipeline d'intégration et déploiement continu. Celui-ci permettrait d'identifier au plus tôt les problèmes en :

- procédant dès la production du code à la vérification du typage
- contrôlant la qualité de l'écriture du code (linting)
- faisant tourner les tests unitaires pour éviter les régressions

Le déploiement continu permettrait de mettre à disposition régulièrement et rapidement les améliorations et corrections aux utilisateurs

10.2.3 Monitoring de la performance du modèle

Un point crucial pour que le projet soit un succès est la surveillance de la performance du modèle. Il est possible que des dérives apparaissent, par exemple si au fil du temps les caractéristiques des données étaient modifiées (par exemple, de nouvelles manières de nommer les ingrédients apparaissaient, les règles de gestion changeaient, ...). Il faudrait être capable d'identifier ce phénomène, pour pouvoir prendre les actions correctrices nécessaires :

- changement des paramètres du modèle
- réentraînement sur des données plus récentes
- construction de nouveaux modèles pour gérer des domaines spécifiques

Un point à trancher est la manière de monitorer la performance. Une façon de faire serait de capturer les décisions prises par les utilisateurs après que le modèle a tourné. Par exemple, dans le cadre de l'aide au

contrôle, est-ce que l'utilisateur a décidé de passer outre l'avertissement qui lui a été remonté par le système ? Dans le cas de la préalimentation d'information, l'utilisateur a-t-il corrigé la valeur qui lui a été fournie ? Ces décisions devraient être enregistrées, puis analysées afin de s'assurer que la performance du modèle ne se dégrade pas au fil du temps.

Cinquième partie

ANNEXES

Annexe A FIGURES, TABLEAUX ET BIBLIOGRAPHIE

LISTE DES TABLEAUX

1	Exemples de listes d'ingrédients	9
2	Analyse volumétrique des pièces jointes	12
3	Exemples d'écart entre les données étiquetées et celles du PIM	15
4	Pièces jointes dont les textes ne sont pas extractibles	16
5	Longueur des textes dans le dataset	20
6	Caractéristiques des vocabulaires	22
7	Illustration des listes d'ingrédients des groupes particuliers	28
8	Exemple de vectorisation d'un texte	32
9	Exemples du contenu de fiches techniques au format texte (tronqués)	36
10	Extrait des résultats de la prédiction	38
11	Prédictions identifiées comme correctes après postprocessing	43
12	Évaluation du modèle en utilisant les métriques de similarité	46
13	Illustration de l'évaluation du modèle à l'aide des métriques de similarité	47
14	Exemples de calculs de similarité	52
15	Exemple de tableau de données nutritionnelles	85

16	Volumétrie article par branche	99
17	Utilisation des variables catégorielles article au sein des branches RHD	102
18	Répartition des produits par statut	104
19	Répartition des produits par statut de migration	105
20	Répartition des produits par « qualité des données »	105
21	Nombre de produits par GTIN	106
22	Exemples de codes d'identification	107
23	Description des codes d'identification sur le dataframe	107
24	Exemples de dimensions	108
25	Description des dimensions sur le dataframe	108
26	Exemples de conservation	109
27	Description des conservations sur le dataframe	109
28	Exemples de libellés produit	110
29	Prédictions du meilleur modèle sur le set de test	134

TABLE DES FIGURES

1	Étapes du processus article pouvant être améliorées	7
2	Le Pareto des produits en fonction des fournisseur	17
3	Distribution des longueurs de textes	20
4	Corrélation entre longueurs des textes	20
5	Exemples de scores absolus de mots	22
6	Exemples de scores relatifs de mots	23
7	Projection des embeddings Word2Vec	24
8	Projection des comptes : PCA	25
9	Projection des comptes : Truncated SVD	25
10	Projection des fréquences : PCA	26
11	Projection des fréquences : Truncated SVD	27
12	Groupes particuliers dans la tSVD des fréquences	27
13	Schéma de principe du « modèle ouvert »	29
14	Schéma de principe du modèle basé sur les données étiquetées	35
15	Illustration de la méthodologie de mesure de la performance	41
16	Performance du modèle en fonction de la longueur des listes d'ingrédients	47

17	Illustration de la similarité cosinus	51
18	Illustration de la similarité projection	51
19	Résultats du tuning du preprocessing	54
20	Résultats du tuning du découpage des textes des documents	55
21	Résultats du tuning des fonctions de similarité	57
22	Résultats du tuning de l'utilisation de l'inverse document frequency	58
23	Résultats du tuning de l'utilisation de l'inverse document frequency	59
24	Illustration de la similarité cosinus avec score relatif	60
25	Illustration de la similarité cosinus avec score relatif	61
26	Illustration de la similarité cosinus avec score relatif	62
27	Diagramme de séquence des échanges entre PIM et le service	69
28	Les flux métier avec les partenaires commerciaux	77
29	La répartition de l'activité des branches	80
30	Le maillage régional de la branche ÉpiSaveurs	82
31	La distinction entre produit et article	89
32	Le processus de création article	91
33	Une capture d'écran du PIM	93
34	L'intégration du PIM au sein des systèmes du Groupe Pomona	94
35	Schéma de principe de la GDSN	96
36	L'uid d'un produit	96
37	Volumétrie article par branche	99
38	Recouvrements entre branches RHD	100
39	Répartition des articles en fonction des variables catégorielles	101
40	Répartition des produits par statut	104
41	Nombre de produits par GTIN	106
42	Distribution des fournisseurs par nombre de produits	106

BIBLIOGRAPHIE

- [1] Conseil de l'Union Européenne. Règlement n°1333/2008 sur les additifs alimentaires, dec 2008. <https://eur-lex.europa.eu/LexUriServ/LexUriServ.do?uri=OJ:L:2008:354:0016:0033:FR:PDF>.
- [2] Conseil de l'Union Européenne. Règlement n°1907/2006 dit REACH, dec 2006. <https://bit.ly/2Jm05v9>.

- [3] Conseil de l'Union Européenne. Règlement n°1169/2011 dit INCO, nov 2011. https://www.senat.fr/europe/textes_europeens/ue0120.pdf.
- [4] Direction Générale de la Concurrence, de la Consommation et de la Répression des Fraudes. Étiquetage des denrées alimentaires : nouvelles règles européennes, jan 2015. <https://www.economie.gouv.fr/dgccrf/etiquetage-des-denrees-alimentaires-nouvelles-regles-europeennes>.
- [5] Direction Générales des Douanes et Droits Indirects. Notions essentielles sur la Déclaration d'Échanges de Biens. <https://www.douane.gouv.fr/notions-essentielles-sur-la-declaration-dechangers-de-biens>.
- [6] GS1. GDSN Trade Item Implementation Guide, nov 2019. https://www.gs1.org/docs/gdsn/tiig/3_1/GDSN_Trade_Item_Implementation_Guide.pdf.
- [7] GS1 France. Le réseau GDSN, le canal pour l'échange d'informations produits. <https://www.gs1.fr/Notre-offre/Le-reseau-GDSN-le-canal-pour-l-echange-d-informations-produits>.
- [8] GS1 Global. Global Data Synchronisation Network. <https://www.gs1.org/services/gdsn>.
- [9] GS1 Global. GS1 General Specifications. https://www.gs1.org/docs/barcodes/GS1_General_Specifications.pdf.
- [10] Jean-François Burnol. Normes Lp. <http://jf.burnol.free.fr/agregnormeslp.pdf>.
- [11] Groupe Pomona. Site institutionnel du groupe pomona. <https://www.groupe-pomona.fr/>.
- [12] Wikipedia. Bag-of-words model. https://en.wikipedia.org/wiki/Bag-of-words_model.
- [13] Wikipedia. Damerau–Levenshtein distance. https://en.wikipedia.org/wiki/Damerau%E2%80%93Levenshtein_distance.
- [14] Wikipedia. Jaro Similarity. https://en.wikipedia.org/wiki/Jaro%E2%80%93Winkler_distance#Jaro_Similarity.
- [15] Wikipedia. Jaro–Winkler Similarity. https://en.wikipedia.org/wiki/Jaro%E2%80%93Winkler_distance#Jaro%E2%80%93Winkler_Similarity.
- [16] Wikipedia. Latent Semantic Analysis. https://en.wikipedia.org/wiki/Latent_semantic_analysis.
- [17] Wikipedia. Levenshtein distance. https://en.wikipedia.org/wiki/Levenshtein_distance.
- [18] Wikipedia. Liste des additifs alimentaires. https://fr.wikipedia.org/wiki/Liste_des_additifs_alimentaires.
- [19] Wikipedia. Norm (mathematics). [https://en.wikipedia.org/wiki/Norm_\(mathematics\)#Euclidean_norm](https://en.wikipedia.org/wiki/Norm_(mathematics)#Euclidean_norm).
- [20] Wikipedia. Optical character recognition. https://en.wikipedia.org/wiki/Optical_character_recognition.
- [21] Wikipedia. Word2vec. <https://en.wikipedia.org/wiki/Word2vec>.

Annexe B

CONTEXTE MÉTIER : LE GROUPE, INFORMATION PRODUIT ET GÉNÉRALITÉS SUR LES DONNÉES

L'objet de l'ensemble de cette annexe est de donner sur le Groupe Pomona et la gestion de l'information produit. des éclairages nécessaires à la compréhension du cas d'usage développé. Bien d'autres aspects sur la société, pourraient être mentionnés (ex : des indicateurs sur l'activité, l'histoire du groupe...) mais ils seront omis car non indispensables à la compréhension du sujet. Plus de détails sur le groupe sont accessibles sur le site web de la société[11].

B.1 Description du groupe

B.1.1 Le métier du Groupe Pomona

Le Groupe Pomona est une société de distribution livrée de produits alimentaires à destination des professionnels des métiers de bouche. L'activité du groupe consiste uniquement à acheter et revendre de la marchandise, à l'exclusion de toute activité de fabrication ou de transformation¹. Le groupe Pomona est une société de *distribution*. Elle ne possède d'ailleurs pas d'actif industriel (autre que des entrepôts logistiques) ni d'agrément pour transformer les marchandises.

Cette activité d'achat/vente se fait dans la majorité des cas sous le régime du *négoce*, à savoir que le groupe acquiert la propriété des marchandises qu'il commercialise avant de la céder à ses clients. L'autre régime est celui dit de la *prestation (logistique)*. Dans ce cas, par le jeux d'écritures comptables, la valorisation du stock disparaît des comptes du groupe. Néanmoins, indépendamment de cet aspect purement comptable, l'ensemble :

des flux de documents : commandes d'achat, factures fournisseur, commandes de vente, factures clients

des flux financiers : paiements fournisseur, paiements client

des flux physiques : réception et stockage, préparation et expédition

restent largement inchangés.

^{1.} de très rares cas de transformation existent (ex : mûrissement de fruits, filetage de poisson) mais sont extrêmement exceptionnels

Pour résumer, l'activité de l'ensemble des entités du groupe pourraient se résumer via le schéma présenté à la FIGURE 28 page 77




FIGURE 28 – Les flux métier avec les partenaires commerciaux

Le métier du groupe est d'être un grossiste, qui achète et revend des produits alimentaires² sans produire ou transformer quoi que ce soit.

B.1.2 La décentralisation

Le Groupe Pomona est un groupe fortement décentralisé, avec des organisations largement indépendantes les unes des autres.

Les Directions fonctionnelles

Pour des raisons évidentes de recherche de synergies ou de conformité réglementaires, certaines activités restent toutefois mutualisées à la maille du groupe. Il s'agit des organisations suivantes :

La Direction Administrative et Financière (DAF) : regroupe les équipes comptables groupe, l'audit interne et la consolidation financière

La Direction Qualité Sécurité et Environnement (DQSE) : est en charge de définir et contrôler l'application des standard de qualité

2. dans la grande majorité des cas, cf. *Les produits non-alimentaires* C.1 page 97

La Direction des Systèmes d'Information (DSI) : développe et maintient en condition opérationnelles les systèmes d'information du groupe

La Direction Technique et Logistique (DTL) : est en charge des projets immobiliers (entrepôts), des négociations avec les transporteurs et joue un rôle de conseil interne sur les sujets logistiques

La Direction des Ressources Humaines : se charge de l'ensemble des aspects en lien avec le recrutement, la paye et les sujets sociaux

La Direction Commerciale groupe (DCG) : définit une stratégie et des bonnes pratiques commerciales et marketing

Les clients du groupe

Afin de comprendre l'organisation du groupe, il est nécessaire de connaître la typologie de ses clients. Comme mentionné précédemment, le groupe s'adresse exclusivement aux professionnels des métiers de bouche. Aucune marchandise n'est vendue à des particuliers. Les principales typologies de clients sont les suivantes :

Les Sociétés de Restauration : elles exploitent les restaurants d'entreprise, certaines cantines d'établissements d'enseignement, les maisons de retraite, ...

Les Marchés Publics : regroupent les clients qui dépendent des collectivités (écoles, hôpitaux, prisons, ...)

La restauration commerciale : est l'ensemble des restaurants à vocation commerciale, qu'ils soient chainés (hippopotamus, O'Tacos, ...) ou indépendants (« le restaurant du coin »)

Les spécialistes : il s'agit des détaillants spécialisés qui s'adressent aux particuliers. Boulanger, pâtissier, bouchers, traiteurs, vente à emporter, ...

Les Grandes et Moyennes surfaces (la GMS) : sont les enseignes de la grande distribution. En général, l'accès à ces clients est compliqué par les règles mises en place par leurs centrales d'achat. Il représentent en général qu'un canal de vente d'opportunité.

Les trois premières de ces catégories représentent ce que l'on appelle la *Restauration Hors Domicile (RHD)* (ou parfois également la Restauration Hors Foyer, RHF).

Premier niveau de décentralisation : les branches

Le Groupe Pomona est divisé en branches, qui sont des unités opérationnelles indépendantes, et qui ont toute latitude pour gérer leurs stratégie et politique commerciales, la gestion de leurs achats, leur stratégie marketing, ... En particulier, les systèmes d'information ne sont pas identiques entre les différentes branches. Afin d'éviter de se concurrencer entre elles, leurs domaines d'activité respectifs ont été partitionnés par familles de produit commercialisés, segments client cibles et géographie.

Les branches RHD Les branches RHD s'adressent aux clients de la Restauration Hors Domicile (cf. section B.1.2 page 78) en France. Elles se répartissent ce marché en travaillant des gammes de produits distinctes. Il s'agit des branches historiques du groupe, qui représentent l'essentiel de son chiffre d'affaire. La répartition par produit est la suivante :

PassionFroid : spécialiste des *produits surgelés, de la viande fraîche et des produits laitiers*

ÉpiSaveurs : spécialiste des produits qui se conservent à température ambiante : *produits d'épicerie, conserves, boissons et consommables de cuisine non-alimentaires*

TerreAzur : spécialistes des *Fruits et Légumes frais, et Produits De la Mer frais*

La non-concurrence entre les branches est assurée par le fait qu'elles ne commercialisent pas les mêmes produits. Bien que nommées RHD, elles peuvent également vendre leurs produits à la grande distribution (GMS : Grandes et Moyennes Surfaces), mais généralement ces marchés sont verrouillés par les centrales d'achat des grandes enseignes. La branche TerreAzur arrive toutefois à prendre des parts de marché significatives sur ce segment. Les branches RHD utilisent le logiciel SAP comme système de gestion. La branche TerreAzur est en cours de déploiement, en 2020 environ les 2 tiers des succursales travaillent avec ce logiciel.

Les branches spécialistes Les branches spécialistes s'adressent aux clients dits spécialistes (cf. section B.1.2 page 78) en France. Elles sont en mesure de commercialiser tout type de produit pour répondre aux besoins de leurs clients. En particulier, elles peuvent tout à fait commercialiser certains produits qui sont également vendus par les branches RHD. Elles se répartissent la clientèle spécialiste de la manière suivante :

Délice et Crédit : s'adresse aux *Boulanger et Pâtissier*

Saveurs d'Antoine : s'adresse aux *Bouchers, Charcutiers et Traiteurs*

Relais d'Or : s'adresse à la *restauration commerciale indépendante*

Comme pour les branches RHD, ces branches peuvent lorsqu'elles en ont l'opportunité vendre leurs produits à la GMS.

L'étranger Bien que le Groupe Pomona soit une société dont l'essentiel de l'activité est faite sur le marché français, deux réseaux sont en cours de constitution sur des pays limitrophes. Ces branches sont susceptibles de travailler tout type de produit, à destination de tout type de client. Elles sont positionnées sur les marchés suivants :

Pomona Suisse : présente sur le marché Suisse

Pomona Iberia : présente sur le marché Espagnol

On peut synthétiser la répartition de l'activité par branche de la manière présentée à la FIGURE 29 page 80.




FIGURE 29 – La répartition de l'activité des branches

Le second niveau de décentralisation : les succursales

Chacune des branches est elle-même à son tour décentralisée en un réseau d'entrepôts régionaux : les succursales (parfois également appelées simplement « régions »). Ces succursales sont gérées comme des PME indépendantes, avec un directeur et un compte de résultat qui leur est propre. Si certaines négociations avec des fournisseurs ou des clients nationaux sont parfois menées par les branches, les succursales sont autonomes dans :

- la définition de leur assortiment, même si des contraintes s'appliquent
- la stratégie de développement commercial
- la négociation des prix d'achat
- la négociation des prix de vente
- la politique de rémunération de leurs employés

À ce titre, elles ont leurs propres équipes d'achat, leurs équipes commerciales (télévente et vente route), leurs équipes administratives et évidemment leurs équipes logistiques (essentiellement en entrepôt et les chauffeurs livreurs en charge des livraisons client).

Certaines activités restent de la responsabilité des équipes centrales des branches, comme : la négociation avec les clients ou les fournisseurs nationaux, la constitution de l'assortiment commun (les produits que toutes les succursales doivent détenir), la gestion des référentiels de données de base métier, ...

Un exemple de maillage régional est présenté en FIGURE 30 page 82, sachant que ce maillage régional est différent pour chacune des branches.

B.2 La gestion de l'information produit

B.2.1 L'information produit

Utilisations de l'information produit

Conformité réglementaire La gestion de l'information produit est essentiellement une contrainte réglementaire à statisfaire. Comme mentionné au préambule, la réglementation autour de l'information des consommateur s'est sans cesse complétée au cours des dernières années. Un des textes centraux est le règlement n°1169/2011 dit INCO (INformation COnsommateur)[3][4]. C'est ce règlement qui définit l'ensemble des informations qui doivent être étiquetées sur le produit (liste d'ingrédients, tableau de données nutritionnelles, ...), mais également affichée au client lors de commande en ligne sur les sites de e-commerce. Il s'agit principalement d'informations relatives à la sécurité alimentaire (ex : les allergènes) ou la santé (ex : informations nutritionnelles).

Attentes client Les consommateurs finaux (les « convives ») étant de plus en plus sensibles au contenu de leur assiette, les clients du groupe sont de plus en plus demandeurs d'informations relatives aux produits qu'ils



FIGURE 30 – Le maillage régional de la branche ÉpiSaveurs

commandent. Ils demandent donc régulièrement des informations qui vont au-delà de ce qui est normalement prévu par la réglementation.

De plus, sur certains marchés pour lesquels des contrats courant sur de longues périodes - jusqu'à un an - sont établis (les marchés publics sont très concernés), il n'y a pas d'échantillonnage des produits. La seule manière pour ces clients d'évaluer la qualité des produits est de se référer aux documents contenant les informations produit, fournis par les distributeurs.

Gestion Certaines informations relatives aux produits sont nécessaires pour des raisons de gestion administrative. Par exemple, la gestion des taxes sur les produits alimentaires est complexe :

- les taux de TVA sont variables en fonction du type de produit
- des taxes spécifiques s'appliquent aux produits contenant de l'huile ou de la farine
- des règlements particuliers s'appliquent aux alcools
- ...

D'autres informations, comme la nomenclature douanière, sont nécessaires pour effectuer les déclarations auprès des douanes européennes.

Un autre type d'information capital pour la gestion des flux d'achat et de vente sont les informations logistiques, qui définissent par exemple le nombre d'unités consommateur dans le colis, le nombre de colis sur une palette, ... Une gestion rigoureuse de ces informations est indispensable pour que les flux d'achat ou de vente soient correctement exécutés (que les quantités commandées soient les bonnes, que les montants facturés soient corrects, ...).

Des produits bruts aux produits transformés

Le niveau d'exigence en termes d'information produit est variable en fonction du niveau de transformation de ce produit. Par exemple, sur des fruits et légumes frais, à peu de choses près seul le pays d'origine doit être affiché au client. Sur une barre chocolatée, ou un plat cuisiné, il sera nécessaire d'afficher :

- une liste d'ingrédients (mettant en évidence les allergènes)
- un tableau de données nutritionnelles (protéines, glucides, ...)
- une dénomination réglementaire

Les grands types d'information

On se focalisera dans ce paragraphe sur les informations relatives aux *produits alimentaires*.

La composition La première grande famille de données réglementaires sont les données de composition. Elles détaillent quels sont les ingrédients qui sont mis en œuvre dans la fabrication des produits. Évidemment, la composition a en général plus de sens pour les produits transformés que pour les produits bruts. Elle peut prendre la forme d'un texte listant la liste des ingrédients (l'étiquetage de ce texte est en général obligatoire sur les emballages des produits), ou d'un tableau.

Les ingrédients incluent également les additifs. Il s'agit de substances ajoutées à la recette pour répondre à des fonctions particulières (colorant, exhausteur de goût, émulsifiant, ...). Elles ne représentent en général qu'un pourcentage en masse négligeable dans la composition totale du produit.

Le pourcentage en masse est parfois inclus sur certains ingrédients. La réglementation l'oblige dans certains cas, par exemple quand l'ingrédient en question est mentionné dans la dénomination du produit (pour une *tarte aux framboises*, la proportion de framboise doit être mentionnée dans la composition).

Enfin, un aspect à la fois réglementaire et particulièrement important est la présence d'allergènes dans la composition. Le règlement INCO[3][4] impose de mettre en évidence les allergènes relevant d'une des 14 catégories suivantes :

1. Céréales contenant du gluten, à savoir blé, seigle, orge, avoine, épeautre, kamut ou leurs souches hybrides, et produits à base de ces céréales
2. Crustacés et produits à base de crustacés
3. Œufs et produits à base d'œufs
4. Poissons et produits à base de poissons
5. Soja et produits à base de soja
6. Lait et produits à base de lait (y compris le lactose)
7. Fruits à coque, à savoir : amandes, noisettes, noix, noix de cajou, noix de pécan, noix du Brésil, pistaches, noix de Macadamia ou du Queensland, et produits à base de ces fruits
8. Céleri et produits à base de céleri
9. Moutarde et produits à base de moutarde
10. Graines de sésame et produits à base de graines de sésame
11. Anhydride sulfureux et sulfites
12. Lupin et produits à base de lupin
13. Mollusques et produits à base de mollusques

Il peut y avoir deux niveaux de présence d'un allergène dans un produit (au-delà de la simple absence) :

intentionnellement mis en œuvre : dans le cas où un ingrédient allergène fait volontairement partie de la recette. Ex : présence de moutarde dans un plat cuisiné.

contamination croisée : par exemple lorsque le produit fini est issu d'une chaîne de transformation qui traite un ingrédient allergène, mais que cet ingrédient ne fait pas partie de la recette. Ce cas de figure est en général mis en évidence par des mentions telles que "*Peut contenir des traces de soja*" ou bien "*Transformé dans un atelier processant également des fruits à coques et du sésame*".

Les informations nutritionnelles Une autre grande famille d'information produit sont les informations nutritionnelles. Elles détaillent la quantité des principaux nutriments contenus dans les produits. Certains

d'entre eux sont rendus obligatoires par le règlement INCO [3][4] cf. l'exemple de tableau à la TABLE 15 page 85, et d'autres sont optionnels, comme par exemple la quantité de fer, de calcium, ...

Informations nutritionnelles	Pour 100g	Pour un biscuit	% des AJR pour un biscuit
Énergie	1674 kJ 398 kcal	209 kJ 50 kcal	3 %
Protéines	3.0 g	1.0 g	3 %
Matières grasses	13.0 g	1.6 g	2 %
dont acides gras saturés	5.8 g	0.7 g	4 %
Glucides	66 g	8.2 g	3 %
dont sucres	48 g	6.1 g	7 %
Fibres alimentaires	2.5 g	0.3 g	
Protéines	3.3 g	0.4 g	1 %
Sel	0.41 g	0.05 g	1 %

TABLE 15 – Exemple de tableau de données nutritionnelles

La réglementation rend obligatoire de mentionner les informations nutritionnelles de cette table pour 100g, ou 100mL de produit (pour les boissons).

Les informations nutritionnelles peuvent également se présenter sous forme d'allégations, qui ont des définitions précises dans la réglementation. Ces allégations peuvent être : *sans sel, faible en sucres, riche en fibres, ...*

Les origines Du fait de la complexification des opérations de transformation et de la complexification des flux d'échanges de marchandises, l'origine des produits alimentaires est une notion qui n'est pas définie avec précision dans l'absolu. Il n'y a donc pas non plus de réglementation précise sur le sujet, si ce n'est que l'information produit doit toujours être présentée de manière loyale au consommateur. On peut se donner une règle simple pour définir l'origine d'un produit alimentaire : plus il est brut, plus va compter l'origine de ses ingrédients ; plus il est transformé, plus va compter le lieu de dernière transformation.

Par exemple, sur des morceaux piés de viande fraîche, on aura des origines multiples en fonction du pays de naissance, d'élevage ou d'abattage de la bête. Et à l'inverse, sur un steak haché cette information n'aura aucun sens dans la mesure où il est produit d'un assemblage de « minéraux » pouvant provenir de multiples pays. L'industriel pourra choisir de communiquer sur le fait que la viande a été transformée en steak dans telle usine par exemple.

Les données logistiques On appelle données logistiques essentiellement le plan de palettisation et de conditionnement du produit. Il s'agit de la définition de la « hiérarchie logistique » du produit. Cette hiérarchie se base d'abord sur la définition d'une « unité de base » qui est la plus petite unité légalement détaillable (i.e. qui porte l'ensemble des informations réglementaire pour sa commercialisation). Ces notions ont été standardisées par l'organisme international de standardisation GS1[6]. Deux exemples pour illustrer :

- pour un boîte de sachets de thé, l'unité de base est la boîte car les sachets de thé ne portent pas les informations nécessaires à leur commercialisation
- pour un paquet de barres chocolatées (comme celles qu'on peut trouver au détail en boulangerie), l'unité de base est la barre car elle porte l'ensemble des mentions réglementaires sur son emballage

La hiérarchie logistique est à la fois :

- la définition des niveaux successifs d'emballage des produits : combien d'unités de base dans un paquet, combien de paquets dans un carton, combien de cartons sur une palette, ...
- la définition du contenu de l'unité de base (ex : le nombre de sachets de thé, le nombre de doses dans une boîte d'aides culinaires, ...)

Les données logistiques concernent également les durées de vie du produit (qu'il s'agisse de Date Limite de Consommation ou Date de Durabilité Minimale) :

- la durée de vie totale à fin de production
- la durée de vie garantie à la livraison

Parfois, certaines contraintes d'approvisionnement peuvent être mentionnées :

- unités commandables (ex : on ne peut commander que des cartons complets)
- multiples de commande (ex : on ne peut commander les cartons que 10 par 10 pour des raisons de montage des palettes)
- minimum de commande (ex : il faut commander au minimum 30 cartons)

mais elles sont dépendantes d'un accord entre l'industriel et son client distributeur et ne sont donc pas à proprement parler des informations produit.

Les données administratives et financières Les données dites administratives et financières regroupent le reste des informations de gestion pour lesquelles il existe des contraintes réglementaires. Il s'agit :

- du taux de TVA du produit
- de sa nomenclature douanière et du pays d'origine au sens de la déclaration d'échange de biens^[5]
- de toute autre taxe applicable au produit

Les labels Afin de garantir des qualités spécifiques à certains produits, des organismes de certification ont mis en place des labels pouvant s'appliquer aux produits. En général, ils se basent sur des cahiers des charges et peuvent être assortis d'audits de certification ou de contrôle. Ils peuvent garantir des méthodes de production ou transformation, des lieux de production, des caractéristiques de leurs ingrédients, des pratiques commerciales équitables, ... Les types de labels les plus connus sont :

- les produits Biologiques
- les origines protégées (Appellation d'Origine Protégée, Indication Géographique Protégée, viandes de France, Bleu Blanc Cor, Régions UltraPériphériques d'Europe...)
- les pratiques commerciales équitables (Max Havelaar, ...)

- les modes de production respectueux de l'environnement (Aquaculture Stewardship Council, Marine Stewardship Council, Roundtable on Sustainable Palm Oil, Nordic Swan, ...)
- la qualité « générale » des produits (Label Rouge, ...)

Les données marketing Certaines données marketing font également partie de l'information produit. La plus évidente est la marque commerciale du produit, qui parfois définit totalement le produit. Par exemple, on sait ce qu'est un Snickers, de la Mousline, du Nutella, ... Les produits peuvent également porter d'autres allégations marketing, non réglementaires ou labelisantes : Élu produit de l'année, Vu à la télé, Issu de notre savoir-faire centenaire, ...

B.2.2 Le processus

Le fournisseur est propriétaire des informations produit

Comme présenté à la section B.1.1 page 76, le Groupe Pomona n'a pas d'activité de fabrication ou de transformation de marchandises. À ce titre, l'ensemble des données produits ne peuvent être déterminées que par les fournisseurs de ces produits. L'ensemble des entités du groupe s'appuient donc sur les données transmises par les industriels ou producteurs de marchandises.

Il peut arriver que certains produits soient achetés par Pomona à d'autres négociants non-producteurs. Dans ce cas, de la même manière que le groupe Pomona a la responsabilité de collecter puis transmettre les informations produit à ses clients, ces fournisseurs négociants doivent eux-même aller chercher l'information produit et la transmettre à Pomona.

Dans tous les cas, c'est le fournisseur qui est responsable de produire et de transmettre l'information produit aux entités du groupe Pomona.

La notion de produit et d'article

Un mot sur la modélisation des données adoptée est nécessaire pour comprendre les grandes lignes du processus. Comme il a été vu à la section B.1.2 page 78, certains produits sont susceptibles d'être commercialisés par plusieurs branches du groupe.

De plus, du fait que les systèmes d'information ne sont pas identiques entre les branches, certaines contraintes imposent parfois des différences de modélisation, des duplications volontaires de codes pour répondre à ces contraintes. Une illustration de ce point pour clarifier : la facturation client pour une canette de soda peut se faire au litre (permet de comparer les prix entre les différents conditionnements et les différentes marques) ou à la cannette (permet de faire une idée du coût portion d'un produit). Or, la possibilité de pouvoir facturer un même article dans plusieurs unités différentes n'est pas une fonctionnalité offerte par tous les systèmes d'information. En particulier, ÉpiSaveurs peut gérer dans ce cas un unique article et le facturer dans l'unité de son choix en fonction des demandes des clients. Mais Délice et Création (qui possède

un système d'information différent) doit dupliquer cet article car une seule unité de facturation est possible pour un article donné.

Enfin, au-delà des contraintes liées au SI, certaines pratiques imposent de laisser aux branches une indépendance forte dans la gestion de leurs référentiels articles. Il faut savoir que commercialiser sous un même code article des produits qui sont similaires permet d'obtenir des gains de productivité à plusieurs niveaux :

- on économise des emplacements en entrepôt (un emplacement ne peut contenir qu'un article)
- on gagne du temps administratif dans la gestion des prix : le foisonnement d'articles impose de gérer plus de prix client
- ...

La contrepartie à adopter cette pratique est qu'il n'est alors plus possible de différencier ces produits similaires, par exemple pour leur appliquer des prix de vente distincts, ou bien offrir la possibilité à un vendeur de garantir au client la livraison d'un produit plutôt que l'autre. Néanmoins, en fonction de la clientèle adressée, certains produits pourront être considérés comme similaires, alors que pour d'autres ils ne seront pas interchangeables.

Cet exemple est détaillé dans la FIGURE 31 page 89.

On différencie donc les deux notions suivantes :

les produits : ils représentent une marchandise physique produite par un fournisseur. Ce sont les produits qui portent les *informations produit* décrites à la section B.2.1 page 83. Un produit ne peut appartenir qu'à un seul fournisseur. Le référentiel produit est unique pour l'ensemble du groupe.

les articles : ce sont les objets qui sont gérés par les branches dans leurs systèmes de gestion respectifs. Leurs attributs sont très liés au système d'information qui les porte. Chaque branche gère de manière autonome son référentiel article, incluant les liens qui sont faits entre produits et articles.


Cette modélisation permet de répondre à l'ensemble des contraintes présentées dans ce paragraphe.

Les acteurs

L'acheteur L'acheteur peut être en succursale, ou à la centrale d'achat de la branche (cf. B.1.2 page 78 et B.1.2 page 81). Il est responsable de l'assortiment, i.e. des articles qui sont commercialisés par sa branche, ou sa succursale. Il est à l'origine de la création d'un nouveau produit, dans la mesure où c'est lui qui va décider de le référencer ou pas. La gestion de l'information produit ne représente qu'une petite partie de l'ensemble de ses responsabilités (qui peuvent inclure négociations fournisseurs, gestion du sourcing, gestion des approvisionnements, prévisions d'évolution des prix, ...).

Le fournisseur Il a été vu que le Groupe Pomona - dans sa qualité de distributeur - n'est pas en mesure de déterminer seul les informations produit sur les marchandises qu'il commercialise. À ce titre, les équipes des fournisseurs sont en charge de transmettre les informations produit à Pomona. En général, ce sont deux types de profil qui effectuent cette tâche :

- les commerciaux (aux sens large, incluant les assistants commerciaux)



Dans cet exemple fictif, le type de conditionnement du lait n'a aucun impact sur les clients de la branche Délice et Crédit. Elle commercialise donc sous un même code article deux produits distincts.

Pour des raisons de contrainte de conservation, la branche PassionFroid a quant à elle choisi de ne commercialiser qu'un seul produit - en brique. Elle pourrait choisir d'ouvrir un nouveau code article pour le lait en bouteille (non représenté sur le schéma ci-dessus).

FIGURE 31 – La distinction entre produit et article

— les ingénieurs qualité

Le gestionnaire de référentiel - SEGER Le gestionnaire de référentiel travail au SErvice de GEstion des Référentiels (SEGER), qui sont des équipes positionnées au niveau des branches (cf. B.1.2 page 78). Ils sont responsables de la qualité des données dans les référentiels métier (articles, fournisseurs, clients, ...). La gestion des données de base dans les référentiels est leur mision principale.

L'ingénieur qualité L'ingénieur qualité travaille à la DQSE ou en succursale (cf. B.1.2 page 77 et B.1.2 page 81). Dans le processus de gestion de l'information produit, il est en charge de contrôler la qualité des données, mais également leur conformité réglementaire (ex : on ne peut qualifier un produit de « faible en sel » que s'il comporte moins de n grammes de sel pour 100 grammes de produit.) La gestion de l'information produit ne représente qu'une partie des responsabilités de l'ingénieur qualité.

Les contrôles

Comme cela a été vu dans la section B.2.1 page 81, il est nécessaire que les différentes entités du groupe soient en possession d'une information produit fiable. Or, avoir des données de qualité nécessite des efforts de la part des métiers, en particulier lorsque le processus n'est pas entièrement porté en interne dans la société. À ce titre, plusieurs étapes de contrôle ont été définies dans le processus de gestion du référentiel de données produit et article :

lorsque le fournisseur a saisi les données produit : la personne à l'origine de la demande de référencement (en général, un acheteur) doit contrôler la cohérence des données produit

lorsque le demandeur a demandé la création d'un article : le gestionnaire de référentiel valide à nouveau la cohérence des informations produit

après la création article, de manière asynchrone : le service qualité contrôle par échantillonnage les données d'une partie des produits et articles qui ont été modifiés pendant une période.

Le retour d'expérience montre que ces contrôles, loin d'être redondants, sont nécessaires pour avoir une qualité de données acceptable. Ces processus de contrôle sont décrits à la FIGURE 32 page 91.

Les contrôles effectués à chacune des étapes sont les suivants :

contrôle de la complétude des données : vérification que les données transmises comportent l'ensemble des données attendues

contrôle de cohérence entre les données : vérification que les informations transmises sont cohérentes entre elles (ex : un allergène présent dans la liste d'ingrédients du produit a bien été signalé comme allergène par ailleurs)

contrôle de la cohérence avec les pièces jointes : en plus de données structurées, les fournisseurs transmettent également des fichiers portant des informations produit (ex : l'étiquette produit ou le




FIGURE 32 – Le processus de création article

visuel de l'emballage). Ces pièces jointes sont décrites à la section 2.2 page 9. La personne en charge du contrôle vérifie que les données transmises sont cohérentes avec ces documents.

B.2.3 Les outils informatiques associés

Comme vu dans la description des branches du groupe (voir section B.1.2 page 78), les outils informatiques ne sont pas tous les mêmes sur l'ensemble des branches. Ainsi, les outils utilisés pour la gestion de l'information produit ne sont pas les mêmes.

Les branches faiblement outillées

Les branches étrangères (Pomona Suisse, Pomona Iberia), spécialistes (Délice et Création, Saveurs d'Antoine) et la branche TerreAzur sont aujourd'hui faiblement outillées. Cela signifie que l'information produit est en général stockée uniquement sous la forme de fichiers (essentiellement les pièces jointes, décrites à la section 2.2 page 9). L'ensemble des échanges avec les fournisseurs se font par mail, et les articles sont créés directement dans les systèmes de gestion par les gestionnaires de référentiel. Les liens entre les articles et les informations produit ne sont pas matérialisés dans les systèmes informatiques.

Le GIP

Le GIP (Gestion de l'Information Produit) est utilisé sur la branche PassionFroid. C'est un système de gestion de l'information produit qui est maintenant obsolescent et en cours de remplacement. Il a toutefois le mérite de permettre le stockage dans une application des données et des pièces jointes relatives aux produits, avec la possibilité d'accéder aux informations produit à partir des identifiants des articles. C'est ce système qui a permis de pouvoir alimenter les sites de e-commerce PassionFroid et ÉpiSaveurs avec les informations produit. Il est toutefois ancien, et ne propose pas de fonctionnalité d'export en masse fiable. Il s'agit d'une application qui n'est pas ouverte aux utilisateurs externes au groupe, et les échanges avec les fournisseurs passent donc par des échanges de mails.

Le PIM

Le PIM (Product Information Management) est un système de gestion de l'information produit qui a été mis en production en mai 2019, pour la branche ÉpiSaveurs. Il a vocation à être déployé sur l'ensemble des branches du groupe. En terme de responsabilités, il vise à gérer la totalité des informations produit, mais également d'être maître sur les référentiels articles. Ce sera le système de référence pour tous les autres systèmes consommant de l'information produit, ou des données article.

Description générale de l'outil C'est un système qui porte l'ensemble du processus de gestion de l'information produit, tel que décrit à la FIGURE 32 page 91. Il est accessible aux fournisseurs du groupe, qui

viennent directement mettre à disposition les données et les pièces jointes. Les fonctionnalités caractéristiques de ce système par rapport à d'autres systèmes informatiques sont :

- la gestion de workflows (processus), qui permet d'orchestrer l'activité de l'ensemble des acteurs du système
- la possibilité de paramétriser un modèle de données relativement complet, avec des centaines de métadonnées sur les différents objets
- la présentation de l'interface utilisateur via le navigateur, qui permet de s'adresser simplement à des acteurs hors du groupe (pas de client lourd à installer)
- la gestion performante de pièces jointes (documents informatiques) en grandes quantité
- Une gestion de versions des objets robuste, permettant d'auditer l'historique ou de restaurer des données dans un état précédent

Cet outil porte entre autres les fonctionnalités de contrôle des informations, comme illustré à la FIGURE 33 page 93. L'intégration du PIM au sein des systèmes informatiques du Groupe Pomona est décrite dans la FIGURE 34 page 94.

The screenshot shows a web-based PIM application interface. At the top, there's a navigation bar with links like 'ESPACE FOURNISSEURS', 'SMILDE FOODS', 'ROMI HEALTHY BLUE HUILE DE FRITURE LONGUE DURÉE À LA GRASSE DE BOEUF EN BIB 15 L', and a date '2019-11-29_CONTROLE_QUALITE'. The main area is titled 'CONTROLES QUALITÉ' and shows a product detail page for 'ROMI HEALTHY BLUE HUILE DE FRITURE LONGUE DURÉE À LA GRASSE DE BOEUF EN BIB 15 L'. It displays nutritional information (Voedingswaarde / 100 g) and ingredients (antischuimmiddelet: dimethylpolysiloxaan; antimoessant: dimethylpolysiloxane). To the right, a large green bar indicates 'NUTRITION: OK'. Below this, there's a section for 'Déclaratif des données nutritionnelles' with tabs for '100g' and '100ml'. The nutritional data table includes columns for 'VALEURS NUTRITIONNELLES POUR 100 G' and 'INGREDIENTS'. The 'INGREDIENTS' column lists vegetable oils (90%), including sunflower oil (60%), olive oil (20%), and colza oil (10%). The 'VALEURS NUTRITIONNELLES POUR 100 G' table shows values like 3700 kJ / 900 Kcal, 100 g, 14 g, 42 g, 43 g, 0 g, 0 g, 0 g, 0 g, and 0 g. At the bottom, there are sections for 'DONNEES LOGISTIQUES' and 'ALLERGENES'.

Cette capture d'écran montre l'outil de contrôle des données produit. Sur la partie gauche, le contenu des pièces jointes est affiché (visuel de l'emballage en haut, fiche technique en bas), sur la droite les données qui ont été transmises par le fournisseur.

FIGURE 33 – Une capture d'écran du PIM

Le socle technologique (et un mot de vocabulaire) Ce logiciel a été construit sur la base de l'outil de gestion de contenu généraliste Nuxeo. Il s'agit d'un outil de GED (Gestion Électronique de Documents), et tous les objets (produits, fournisseurs, articles, ...) qu'il stocke sont nommés « documents ». Dans le cadre du PIM, ce qui est habituellement appelé « document » au sens d'un fichier informatique (document pdf,

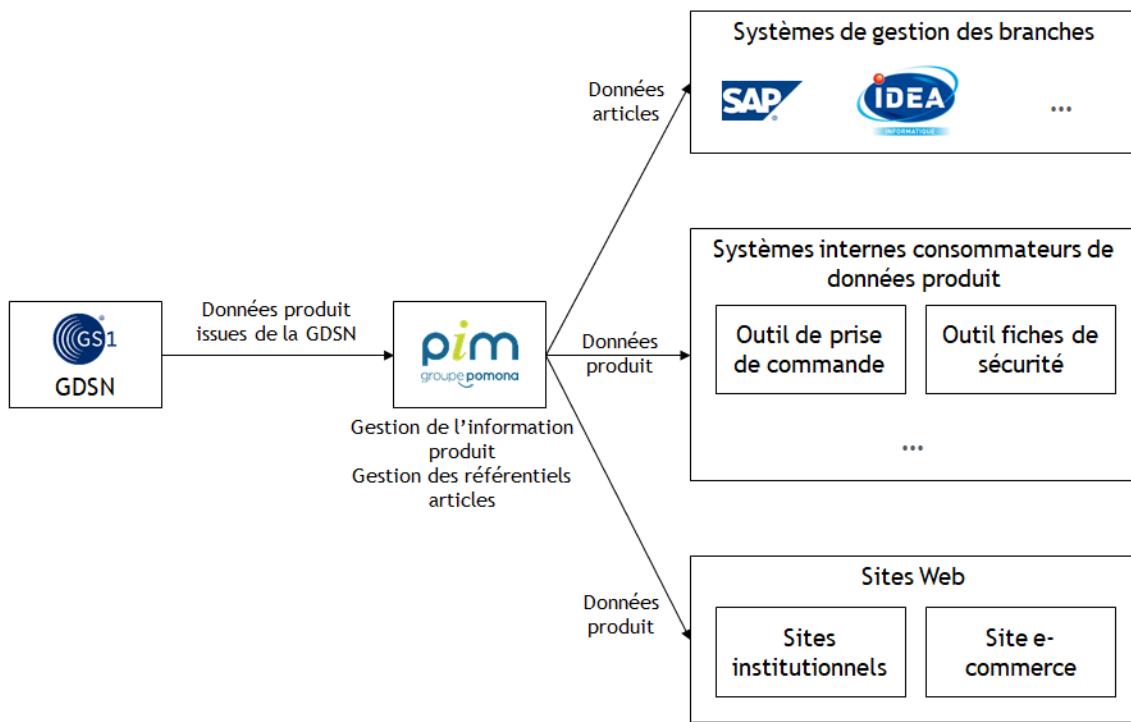


FIGURE 34 – L'intégration du PIM au sein des systèmes du Groupe Pomona

image png, vidéo, ...) est appelé « pièce jointe ». On utilisera ce vocabulaire dans le présent rapport.

Le logiciel Nuxeo est adapté par une société - Keendoo - qui pré-paramètre la solution généraliste Nuxeo pour en faire un outil spécialisé dans la gestion d'information pour les produits alimentaires.

La dernière « couche » de développement a été réalisé de manière spécifique par les équipes de développement du Groupe Pomona.

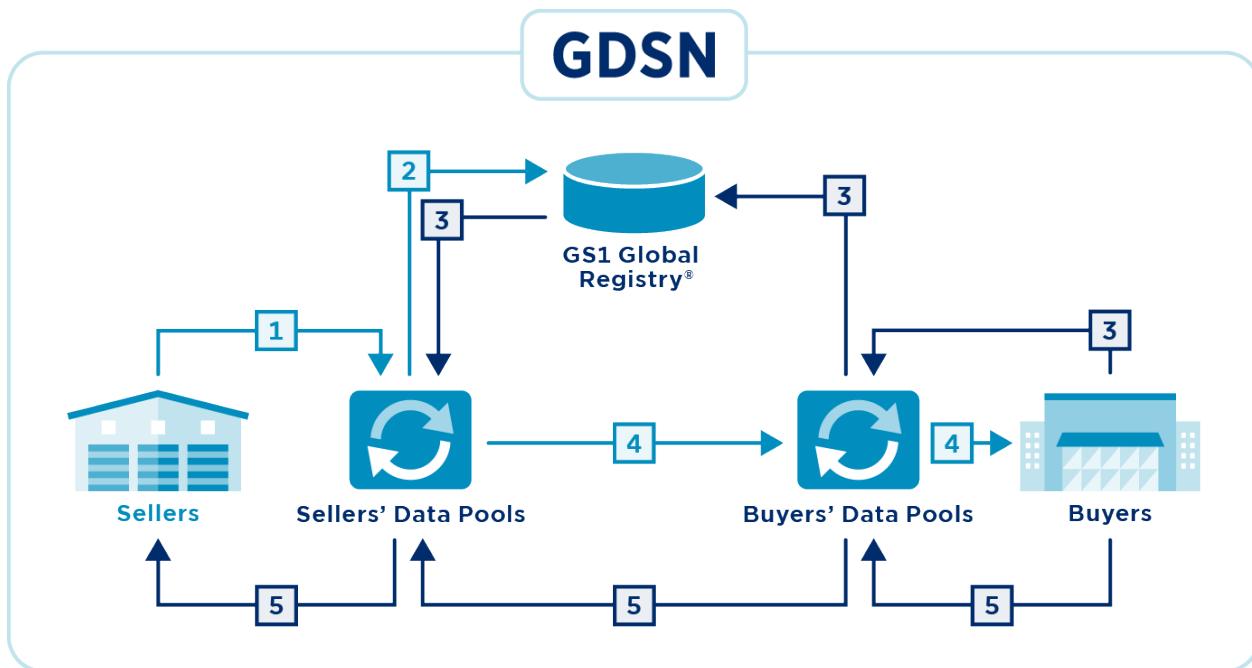
La base de données sous-jacente à l'application est une base NoSQL MongoDB.

La GDSN La GDSN (Global Data Synchronization Network) est un réseau d'échange de données produit entre industriels, distributeurs, restaurateurs, ... Ce réseau est exploité par des opérateurs privés, mais le format et la chorégraphie des échanges ont été standardisés par l'organisme de standardisation GS1. Son schéma de principe est décrit à la FIGURE 35 page 96. Sans rentrer dans le détail, au sein du Groupe Pomona l'utilisation qui en est faite est de récupérer les informations depuis ce réseau d'échange, afin de préalimenter les données produit pour les fournisseurs. Cette fonctionnalité permet de faire gagner du temps aux fournisseurs pour leur éviter une partie de ressaisie, mais également de limiter les erreurs. Toutefois, cette fonctionnalité ne permet pas à elle seule de garantir une parfaite qualité de données. Il s'agit uniquement d'un « tuyau », si les données en entrée ne sont pas correctes, elles ne seront pas correctes en sortie. Pour aller plus loin dans la compréhension de ce réseau, il est possible de consulter les ressources mises en ligne par GS1 [7][8].

L'identification des objets dans le PIM Un dernier point à connaître à propos du PIM, est la manière d'identifier l'ensemble des objets en son sein. Chaque objet géré (ainsi que toute version archivée) porte un identifiant unique, nommé *uid* qui est totalement univoque. Pour la suite, on se basera sur ces uid pour faire référence à des produits stockés dans le PIM. Une illustration est présentée à la FIGURE 36 page 96.

Les API Un des aspects intéressants du PIM pour l'exploitation en masse des données produit, est qu'il expose des API permettant d'aller requérir l'ensemble de son contenu. Cela concerne à la fois les données dites structurées, mais également les pièces jointes. Cela rend les données produit de la branche ÉpiSaveurs bien plus simplement accessibles que celles des autres branches.

La reprise de données initiale et la migration Un point à avoir également en tête est le mode d'alimentation initial du PIM pour ÉpiSaveurs et le processus dit d'enrichissement qui ont été décidés. Les données ont été transférées du système de gestion historique (le GIP, cf. section B.2.3 page 92) vers le PIM, sans transformation métier. Cela signifie qu'il n'y a eu ni correction, ni enrichissement de données lors du chargement initial. Il a été décidé de lancer ces travaux après le démarrage, directement dans le système PIM, en utilisant les fonctionnalités de sollicitation des fournisseurs qu'il propose. La manière de procéder est la suivante :



1. Loading of company data
2. Registering of company data
3. Subscription to seller's data pool
4. Publishing of company data
5. Confirmation receipt of company data

FIGURE 35 – Schéma de principe de la GDSN

The screenshot shows a web-based application for managing product data. The URL in the browser is <https://produits.groupe-pomona.fr/nuxeo/ui/#!/doc/a2b33d4b-5c39-404c-aa65-a41e87bac7e9>. The page displays a product card for "PIM'S ORANGE EN PAQUET 150 G LU". The card includes a thumbnail image, the product name, a small "VALIDÉ" badge with "VERSION 1.1", and the identifier "PIMP-000005795". On the left, there is a vertical sidebar with icons for navigation. At the bottom, there are three tabs: "ADMINISTRATION POMONA", "FICHES DE CONTRÔLES", and "IDENTIFICATION PRODUIT".

L'uid du produit affiché est mis en évidence dans l'url

FIGURE 36 – L'uid d'un produit

- les produits qui ont été créés lors de la reprise de données initiale sont envoyés aux fournisseurs pour qu'ils corrigent et complètent les informations produit
- le processus est ensuite le même que pour un nouveau référencement (en particulier, les contrôles et les renvois au fournisseur, tels que présenté à la FIGURE 32 page 91)
- lorsque la validation finale des gestionnaires de référentiels est effectuée, le produit est considéré comme « migré » et ses données sont réputées correctes

Les données du PIM étaient donc incomplètes et vraisemblablement incorrectes au démarrage, et en juin 2020, ces travaux sont toujours en cours. Il existe donc des produits dans le systèmes, pour lesquels la revue et la correction des données n'a pas encore eu lieu.

Annexe C

LE PÉRIMÈTRE PRODUIT

C.1 Les produits non-alimentaires

Un petit aparté est nécessaire concernant les produits non-alimentaires. Si l'essentiel des produits commercialisés par les branches du groupe sont des produits alimentaires, comme évoqué précédemment une partie de l'activité commerciale se fait tout de même autour de produits non-alimentaires. Ces produits restent malgré tout destinés exclusivement aux professionnels des métiers de bouche, et il s'agit de consommables (par opposition à des articles d'électroménager, de la vaisselle non-jetable, ...).

On distingue en général deux catégories de produits non-alimentaires :

- les produits dits « d'hygiène »
- les produits dits « de chimie »

Les produits de chimie regroupent les produits qui doivent faire l'objet d'une fiche de données de sécurité au sens du règlement Européen No 1907/2006 dit « REACH » (Registration, Evaluation, Authorisation and Restriction of Chemicals) [2].

On appelle produits d'hygiène tous les autres produits non-alimentaires. L'appellation « d'hygiène » est donc réductrice, dans la mesure où cette large famille regroupe les consommables de nettoyage (éponges, papiers absorbants, ...) mais également tout type d'autres consommables (serviettes de tables, gobelets en plastiques, pics à brochettes, boîtes de produits à emporter, ...).

La commercialisation de produits non-alimentaires existe au sein du groupe, mais on se focalisera pour la suite sur les produits alimentaires qui reste le cœur de métier.

C.2 Accessibilité de la donnée en fonction des branches

Comme vu à la section B.2.3 page 92, les systèmes d'information associés à la gestion de l'information produit offrent des niveaux d'accès hétérogènes à la donnée produit. Le récapitulatif par branche est le suivant :

ÉpiSaveurs : on peut simplement accéder à l'ensemble des données produit, structurées, non structurées (i.e. textes longs) et pièces jointes

PassionFroid : on a uniquement la possibilité d'exporter manuellement les données structurées articles depuis le système de gestion SAP. Elles permettent de produire quelques analyses quantitatives. Il est difficile de faire des exports en masse de l'outil de gestion de l'information produit GIP (cf. section B.2.3 page 92).

TerreAzur : idem PassionFroid, si ce n'est qu'en plus le système GIP n'est pas utilisé au sein de cette branche.

Délice et Création : le système d'information ne permet pas d'exporter les données et donc de produire des indicateurs détaillés. On peut toutefois avoir des informations quantitatives de la part des opérationnels.

Saveurs d'Antoine : idem Délice et Création

Pomona Suisse : la branche est en cours de structuration, et les référentiels articles ne sont pas partagés entre les succursales. Il n'est pas possible d'obtenir d'information quantitative sur ces données.

Pomona Iberia : idem Pomona Suisse

Pour les analyses quantitatives, on pourra se baser sur des extractions uniquement pour les branches RHD (ÉpiSaveurs, PassionFroid, TerreAzur). L'ensemble des analyses portant sur les branches RHD sont produites sur la base d'extractions de leur système de gestion SAP.

C.3 Analyses quantitatives

Les graphes de cette section ont été produits via le code présenté en annexe, au chapitre G.6 page 245. Les données pour les branches spécialistes (Délice et Création et Saveurs d'Antoine) sont issues d'informations fournies par le métier, hors système. Dans l'ensemble de cette section, on raisonnera à la maille *article* (cf. la définition article vs. produits, présentée à la section B.2.2 page 87).

C.3.1 Comparatifs entre les branches

En termes de volumétrie article (cf. FIGURE 37 page 99, c'est TerreAzur qui possède le référentiel le plus étendu (environ 62 000 articles de marchandises actifs). Cela s'explique par le fait que cette branche commercialise essentiellement des produits bruts, non-préemballés (ex : des cagettes de fruits ou de légumes).

Or, ces produits ne sont pas clairement identifiés, par exemple par un GTIN. Au démarrage de SAP pour cette branche, afin de limiter la charge sur les gestionnaires de référentiels, le parti a été pris de créer en avance de phase l'ensemble des articles susceptibles d'être commercialisés. Cela s'est traduit par la création d'un grand nombre d'articles, du fait de l'application « brutale » de la combinatoire des différents critères pouvant définir un produit. Un exemple (fictif) serait, sur les pommes :

- 8 variétés possibles (Gala, Golden, ...)
- 4 calibres possibles
- 6 conditionnements possibles (plateau 6kg, plateau 4,5kg, ...)
- 2 catégories (I, II)
- 8 origines (France, Espagne, ...)

ce qui donne un total de 3072 articles uniquement sur cette gamme de produits.

Viennent ensuite PassionFroid, et ÉpiSaveurs, qui sont les autres « grosses » branches historiques du Groupe.




FIGURE 37 – Volumétrie article par branche

Une analyse du recouvrement des référentiels montre que dans l'ensemble, les branches ne travaillent pas les mêmes articles (cf. FIGURE 38 page 100). PassionFroid commercialise certains produits des branches ÉpiSaveurs et TerreAzur, mais cela s'explique par une petite entité luxembourgeoise qui travaille des produits de tout type de stockage. Une réserve toutefois par rapport à cette analyse de recouvrement produit : elle sous-estime vraisemblablement lesdits recouvrements, dans la mesure où la présence de doublons n'est pas prise en compte.

C.3.2 Les grands types de produits

Comme montré à la FIGURE 39 page 101, on voit bien (en plus du fait que les articles étaient peu partagés entre les branches) que :

- les deux types d'articles (négocie et presté) sont utilisés par les 3 branches

Branche	Total	Actifs	Marchandises
PassionFroid	48478	24898	24554
ÉpiSaveurs	22498	12798	12241
TerreAzur	73804	62789	62710
Délice et Crédit	10000	-	-
Saveurs d'Antoine	12000	-	-

TABLE 16 – Volumétrie article par branche

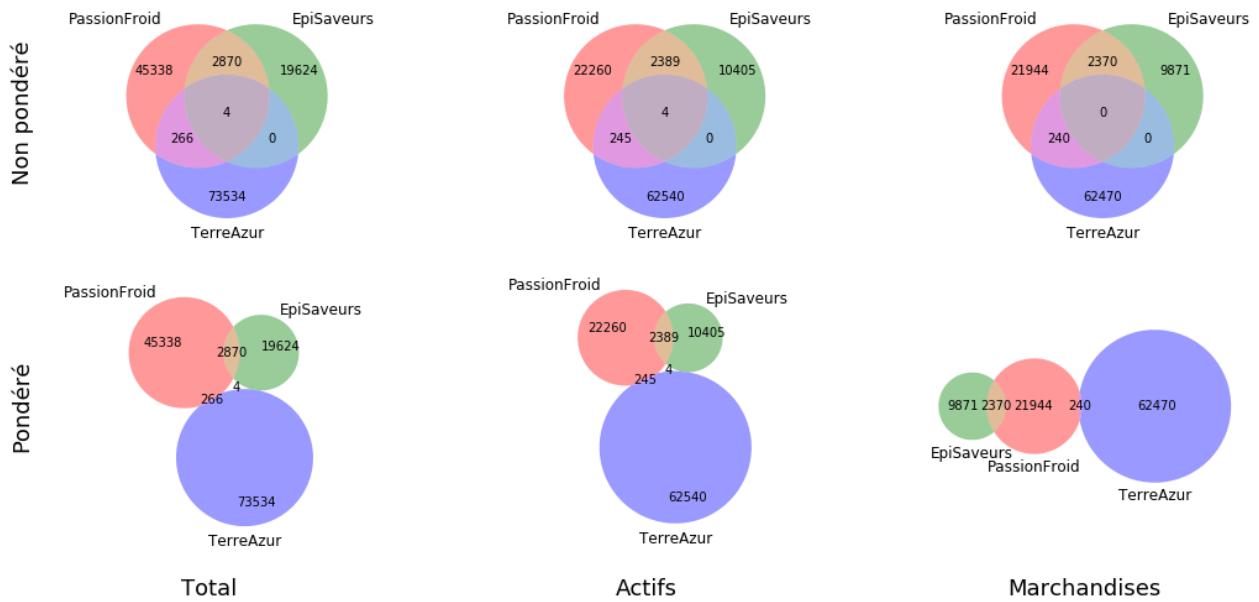


FIGURE 38 – Recouvrements entre branches RHD

- c'est tout de même PassionFroid qui fait l'utilisation majoritaire d'articles prestés
- les branches *ne partagent pas* l'utilisation des autres « catégories » (groupe de marchandises, conditions de stockage, hiérarchie produit, ...)

Les indicateurs sont également récapitulés dans la TABLE 17 page 102.

Possibilité d'extension : - ajouter la vision produit (via les FIA) - faire une sorte d'heatmap qui montre la forte correlation entre les différentes variables catégorielles (et les définitions associées. Ex : ZELAB + SA = Saurisserie, etc...)

Annexe D

LES DONNÉES UTILISABLES, ISSUES DU PIM

Comme vu au chapitre C page 97, les données produit ne sont simplement accessibles que pour la branche ÉpiSaveurs. On se focalisera donc sur cette branche pour la suite de cette étude, ainsi que sur les produits alimentaires (en excluant donc les produits d'hygiène et de chimie, cf. section C.1 page 97). Contrairement au chapitre précédent, ici on travaillera à la maille *produit* (cf. la distinction produit vs. article section B.2.2 page 87). L'ensemble des

Répartition des articles selon les features catégorielles

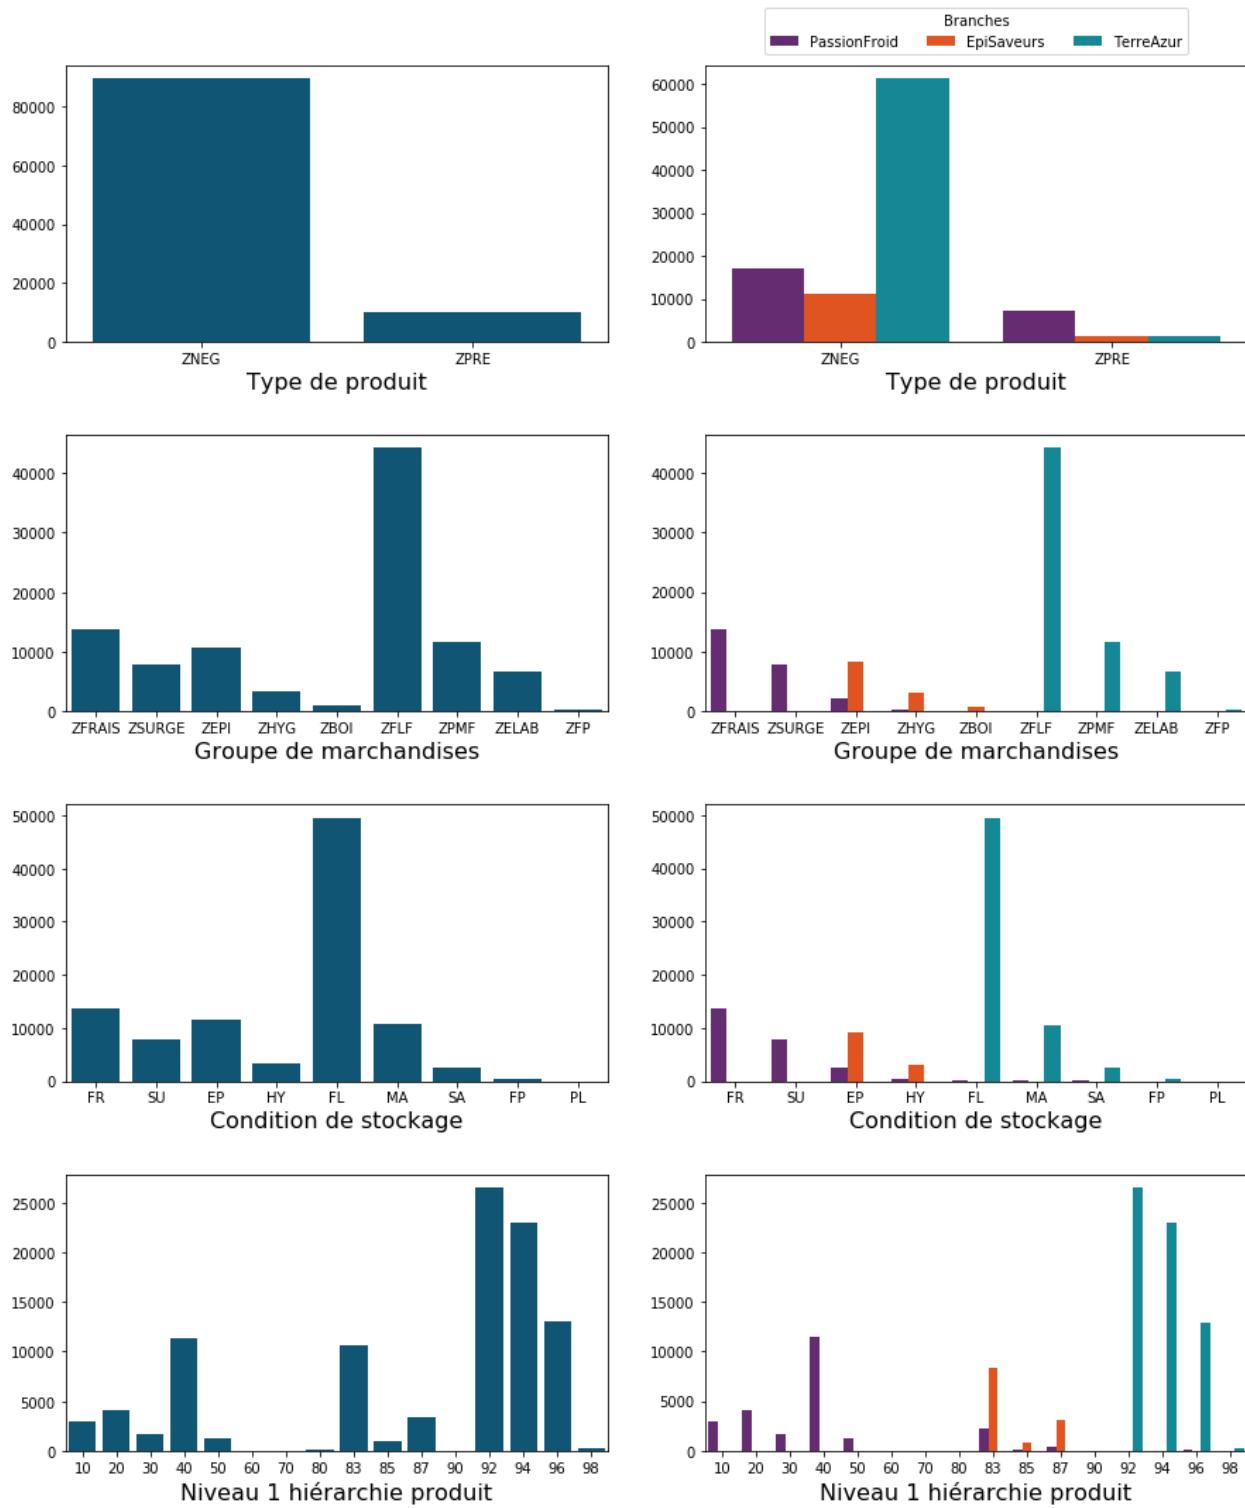


FIGURE 39 – Répartition des articles en fonction des variable catégorielles

Branche Type de produit	PassionFroid	EpiSaveurs	TerreAzur	Total
ZNEG - Article de négoce	17166	11048	61273	89487
ZPRE - Article de prestation	7388	1193	1437	10018
Branche Groupe de marchandises	PassionFroid	EpiSaveurs	TerreAzur	Total
ZSURGE - Surgelés	7756	-	-	7756
ZFRAIS - Frais	13785	6	4	13795
ZEPI - Epicerie	2298	8305	-	10603
ZBOI - Boissons	126	826	-	952
ZHYG - Hygiène	350	3078	-	3428
ZFLF - Fruits et Légumes	4	-	44133	44137
ZPMF - Produits de la mer	142	-	11594	11736
ZELAB - Produits élaborés	91	-	6644	6735
ZFP - Fleurs et plantes	-	-	297	297
ZAUTRE - Autres	2	26	38	66
Branche Condition de stockage	PassionFroid	EpiSaveurs	TerreAzur	Total
SU - Surgelés	7758	-	-	7758
FR - Frais	13781	6	3	13790
EP - Epicerie	2430	9155	-	11585
HY - Hygiène	344	3080	-	3424
FL - Fruits et légumes	78	-	49508	49586
MA - Marée	126	-	10501	10627
FP - Fleurs et plantes	-	-	286	286
SA - Saurisserie	34	-	2408	2442
PL - Publicié	2	-	1	3
Branche Niveau 1 hiérarchie produit	PassionFroid	EpiSaveurs	TerreAzur	Total
10 - Beurre, oeufs, fromage	3010	6	1	3017
20 - Elaborés	4150	2	6	4158
30 - Garnitures et fruits	1701	-	-	1701
40 - Produits carnés	11413	-	-	11413
50 - Produits de la mer	1214	-	2	1216
60 - Consommables	1	-	-	1
70 - Emballage	-	1	-	1
80 - Publicité sur le lieu de vente	34	25	37	96
83 - Epicerie	2306	8296	-	10602
85 - Liquides	135	836	-	971
87 - Hygiène et entretien	348	3075	-	3423
90 - Services	10	-	-	10
92 - Fruits	35	-	26543	26578
94 - Légumes	37	-	22929	22966
96 - Produits de la mer Frais	160	-	12891	13051
98 - Fleurs - plantes	-	-	301	301

TABLE 17 – Utilisation des variables catégorielles article au sein des branches RHD

tableaux et graphes de ce chapitre ont été produit via le notebook "Analyse des données du PIM", présenté en annexe G.7 page 255.

D.1 Données structurées

D.1.1 Description des données structurées

Les données dites structurées sont l'ensemble des données qui peuvent prendre leurs valeurs dans un domaine restreint. Par exemple, ce sont les données booléennes, les choix issus de listes déroulantes, les valeurs numériques... Les principales données structurées pour les produits alimentaires dans le PIM sont :

le code du produit : calculé par le système

le fournisseur : référence croisée vers le code du fournisseur

le type de produit : épicerie, boisson alcoolisée, hygiène, chimie, boisson non-alcoolisée

le GTIN du produit : identifiant numérique unique, utilisé entre autres pour l'étiquetage sous forme de code à barres [9]

le type d'unité de base : paquet, boîte, sachet, rouleau, bouteille, pot, ...

les poids : brut, net, net égoutté (pour les conserves)

le volume : pour les produits liquides

les durées de vie : le type (Date Limite de Consommation ou Date de Durabilité Minimale) et la durée (totale à fin de production, garantie à livraison)

les modes de conservation avant/après ouverture : à température ambiante, au réfrigérateur puis à consommer sous 2 jours, ...

les labels : le(s) label(s) s'appliquant au produit (cf. section B.2.1 page 86)

les régimes particuliers : Halal, Casher, Sans porc, Végétarien, Végétalien, ...

les caractéristiques spéciales : sans OGM, non traité par ionisation

la présence d'allergènes : le niveau de présence de chacun des 14 allergènes réglementés (cf. section B.2.1 page 83) : absence, présence ou traces

les matières grasses utilisées : palme, beurre, coco, tournesol, palmiste, ...

les additifs présents : les codes Exxx et les fonctions des additifs mis en oeuvre [1][18]

les données nutritionnelles obligatoires : pour 100g ou 100mL, valeur énergétique (en kJ et kcal), matières grasses, dont acides gras saturés, Glucides, dont sucres simples, Fibres, Protéines, simplement

les données nutritionnelles facultatives : vitamines, minéraux, omégas, ...

les allégations nutritionnelles : riche en, faible en, sans,... associé à un nutriment défini dans les 2 points précédents

le nutriscore : note allant de A à E, définie dans la loi Santé de janvier 2016

le taux de TVA : un des quatre taux définis dans la réglementation française

le code nomenclature douanière : code identifiant les marchandises défini par les douanes pour la Déclaration d'Échange de Biens [5]

le pays d'origine pour la DEB : le pays d'origine à déclarer dans la Déclaration d'Échange de Biens [5]

les informations logistiques : il s'agit du plan de conditionnement et de palettisation du produit. Elles regroupent les différents niveaux et les quantités pour passer de l'un à l'autre (ex : 3 boites dans un cartons, 64 cartons dans une palette), les poids et dimensions de ces niveaux logistiques, leurs GTIN,

...

D.1.2 Analyse de ces données structurées

Le statut des produits

Comme cela a été présenté à la FIGURE 32 page 91, le processus de gestion de l'information produit fait intervenir de multiples acteurs et peut donc être assez long. Un produit qui n'est pas arrivé au bout du processus et fait l'objet de contrôles et validations successives n'est pas réputé comme portant des informations correctes. Dans le PIM, la « localisation » du produit dans le processus est portée par son statut (c'est une simple donnée catégorielle). Seuls les produits au statut « Validé » sont considérés comme portant des données valides. La répartition des produits pour chacun des statuts est présenté à la FIGURE 40 page 104.




FIGURE 40 – Répartition des produits par statut

state
product.validate
product.waiting.supplier.validation
product.waiting.pomona.validation.niv3
product.correct
product.controlAnoMinor
product.waiting.sending.supplier
product.controlQualityInProgress
product.controlWaitingPomonaValidation
product.waiting.pomona.validation.niv2
product.waiting.pomona.validation
product.inactive
product.validate.reserve
product.controlAnoMajor

TABLE 18 – Répartition des produits par statut

De plus, comme cela a été présenté dans la section migration B.2.3 page 95, certains produits ont fait l'objet d'un contrôle et d'une correction après le démarrage, mais d'autres non. Il est nécessaire de prendre également cet aspect en compte si l'on souhaite avoir la vision des produits qui sont censés avoir des données correctes. La détermination du statut des produits vis-à-vis du processus de migration se fait au travers de facettes :

- les produits qui ont été créés lors de la reprise de données initiale portent une facette "beginningMigration"
- les produits créés dans le PIM après le démarrage (cas des nouveaux référencements) ne portent pas cette facette

- les produits issus de la migration (portant la facette "beginningMigration") sont envoyés aux fournisseurs pour qu'ils complètent les données
- une fois que le processus de validation de l'information produit est terminé (validation des gestionnaires de référentiels), une facette "endMigration" est apposée sur le produit

La répartition des produits fonction de leurs statuts de migration est présenté à la TABLE 19 page 105. Les produits portant des données correctes, du point de vue de la migration, sont :

- ceux qui ont été créés après le démarrage (donc qui ont été créés avec le processus et les règles de gestion cible)
- ceux qui ont été créés à la reprise, mais qui sont identifiés comme ayant terminé le processus de migration (portant la facette de fin)

	Facette fin de migration : Non	Facette fin de migration : Oui
Créé après le démarrage	1680	0
Créé au démarrage	7210	4345

TABLE 19 – Répartition des produits par statut de migration

Si on combine le statut des produits avec leurs statut de migration, on peut calculer un statut « Données valides » qui doit permettre d'identifier des produits avec des données de qualité. C'est ce statut qui sera utilisé dans les paragraphes suivants, lorsqu'on fera des analyses relatives à la qualité des données. On nommera ces statuts « En qualité » et « Hors qualité » pour la suite de ce document. La volumétrie des produits en fonction de chacun de ces statuts est présentée à la TABLE 20 page 105.

	Répartition produit par qualité
Hors qualité	8722
En qualité	4513

TABLE 20 – Répartition des produits par « qualité des données »

Données d'identification


Un exemple et une description statistique de ces données est présentées aux TABLE 22 page 107 et TABLE 23 page 107. On peut en tirer les conclusions suivantes :

- Les codes produits sont bien des identifiants uniques des produits : on a autant de valeurs uniques que de valeurs renseignées
- Une proportion importante de produits (91%) porte un GTIN (cf. [9]), ce qui reflète une « maturité » des filières produits avec lesquelles travaille ÉpiSaveurs.
- Ces GTIN sont également censés être des identifiants uniques des produits. Néanmoins, comme présenté à la FIGURE 41 page 106, il peut arriver que le même GTIN soit présent sur plusieurs produits. Quelques

illustrations et explications sont présentées en annexe, dans le notebook d'analyse des données.

- La distribution numérique des produits par fournisseur est importante. Il existe plus de 600 fournisseurs pour les 13000 produits, et l'essentiel des fournisseurs n'ont qu'un nombre très limité de produits. On peut avoir une vision à la FIGURE 42 page 106 ou à la FIGURE 2 page 17.

TODO : illustrer ici les graphes suivants.



Nb de GTIN	
Pdt portant le GTIN	Nb de GTIN
1	11089
2	228
3	21
4	20
5	1

TABLE 21 – Nombre de produits par GTIN

FIGURE 41 – Nombre de produits par GTIN

Distribution des fournisseurs fonction du nombre de produit par fournisseur




FIGURE 42 – Distribution des fournisseurs par nombre de produits

TODO : continuer l'analyse par domaine de données.

uid	Code produit	Code fournisseur	Type de produit	GTIN	data_ok
e24ff685-40da-4fc8-8454-ec70282552be	PIMP-00000009877	PIMF-0000000483	alcoholicDrink	3387210001261	True
a4e317c3-8fd6-441d-82fc-13f528ba137	PIMP-0000013133	PIMF-0000000283	hygiene	3342690134229	False
729883ee-8d83-45a3-a7c7-015b22473ac9	PIMP-0000007508	PIMF-0000000378	grocery	3077317520227	True
4312cd74-4708-4216-a56e-fbc404c5afa0	PIMP-0000012015	PIMF-0000000596	nonAlcoholicDrink	3230140003938	True
2581a202-7737-448f-9e2d-eb5a02472101	PIMP-0000008730	PIMF-0000000311		5449000227089	True

TABLE 22 – Exemples de codes d’identification

data_ok	Code produit	Code fournisseur	Type de produit	GTIN
Hors qualité	count	8722	8722	7663
	unique	8722	551	7445
	top	PIMP-0000008549	PIMF-0000000250	
En qualité	freq	1	313	
	count	4513	4513	67
	unique	4513	339	4382
	top	PIMP-0000008225	PIMF-0000000179	4062
	freq	1	305	285

TABLE 23 – Description des codes d’identification sur le dataframe

uid	Unité de base	Poids net	Poids brut	Poids net égoutté	Volume	data_ok
e24f685-40da-4fc8-8454-ec70282552be	BIB	5.00	5.300	-	5.0	True
a4e317c3-f8d6-441d-82ff-13f5288ba137	SAC	125.00	0.130	-	-	False
729883ee-8d83-45a3-a7c7-015b22473ac9	BT.	0.50	0.825	-	-	True
4312cd74-4708-4216-a56e-fbc404c5afa0	SEA	1.10	1.242	-	-	True
2581a202-7737-448f-9e2d-eb5a02472101	BT.	0.51	0.530	-	0.5	True

TABLE 24 – Exemples de dimensions

data_ok	Unité de base	Poids net	Poids brut	Poids net égoutté	Volume
Hors qualité	count	8722	8341.000	8341.000	728.000
	unique	29	-	-	-
	top	BTE	-	-	-
	freq	2260	-	-	-
	mean	-	3.616	3.304	1.567
	std	-	73.871	52.238	1.057
	min	-	0.000	0.000	0.000
	25%	-	0.500	0.550	0.500
	50%	-	1.000	1.149	1.600
	75%	-	3.000	3.368	2.458
En qualité	max	-	4900.000	4730.500	6.050
	count	4513	4513.000	4513.000	299.000
	unique	26	-	-	-
	top	SAC	-	-	-
	freq	1075	-	-	-
	mean	-	2.174	2.394	1.246
	std	-	3.127	3.324	1.273
	min	-	0.000	0.000	0.000
	25%	-	0.440	0.514	0.350
	50%	-	1.000	1.070	0.560
	75%	-	3.000	3.120	2.210
	max	-	33.474	40.589	10.000

TABLE 25 – Description des dimensions sur le dataframe

uid	Durée de vie totale	Durée minimale restante	Type de conservation	Conservation avant ouv.	Conservation après ouv.	Température	data_ok
e24f6685-40da-4fc8-8454-ec70282552be	-	-	AM	coolAndDryPlace	-	True	
a4e317c3-88d6-441d-82ff-13f5288ba137	-	-	AM	-	-	False	
729883ee-8d83-45a3-a7c7-015b22473ac9	-	-	AM	ambientTemperatureoolAndDryPlace	-	True	
4312cd74-4708-4216-a56e-fbc404c5afa0	365.0	243.0	AM	noConcerned	coldIfO3Months	-	True
2581a202-7737-448f-9e2d-eb5a02472101	180.0	120.0	AM	ambientTemperature notConcerned	-	True	

TABLE 26 – Exemples de conservation

data_ok	Durée de vie totale	Durée minimale restante	Type de conservation	Conservation avant ouv.	Conservation après ouv.	Température
count	5601.000	6068.000	8320	6369	6348	8
unique	-	-	2	7	18	8
top	-	-	AM	ambientTemperature	coolAndDryPlace	ambianté
freq	650.149	345.489	8299	5731	2781	1
mean	490.058	371.169	-	-	-	-
std	0.000	0.000	-	-	-	-
min	360.000	160.000	-	-	-	-
25%	540.000	270.000	-	-	-	-
50%	900.000	480.000	-	-	-	-
75%	9999.000	9999.000	-	-	-	-
max	3342.000	3408.000	4513	3614	3607	13
count	-	-	2	7	18	5
unique	-	-	AM	ambientTemperature	coolAndDryPlace	<10°C
top	-	-	4500	2532	1733	5
freq	655.031	362.071	-	-	-	-
mean	482.709	395.676	-	-	-	-
std	0.000	0.000	-	-	-	-
min	360.000	180.000	-	-	-	-
25%	540.000	360.000	-	-	-	-
50%	730.000	480.000	-	-	-	-
75%	9999.000	9999.000	-	-	-	-
max	-	-	-	-	-	-

TABLE 27 – Description des conservations sur le dataframe

D.2 Données non structurées

D.2.1 Les libellés

Plusieurs libellés permettent de faire référence à chaque produit, avec des usages distincts :

Libellé temporaire unité de besoin : il s'agit simplement d'un libellé qui est choisi par la personne à l'origine de la demande de référencement produit (souvent l'acheteur, cf. FIGURE 32 page 91), afin que le fournisseur comprenne sur quel produit porte le référencement.

Désignation du produit fournisseur : c'est le libellé qui est donné par le fournisseur afin d'identifier simplement son produit.

Code article interne fournisseur : c'est l'identifiant du produit, dans le système de gestion du fournisseur. Il s'agit généralement de codes, avec autant de formats distincts que de fournisseur venant contribuer.

Marque commerciale du produit : il s'agit du nom de la marque commerciale du produit.

Dénomination réglementaire : c'est le libellé qui doit décrire de manière neutre le produit, sans notion liée au marketing (telle que la marque, entre autres), et qui doit obligatoirement figurer sur l'emballage du produit.

Des exemples de libellés sont présentés à la TABLE 28 page 110.

Libellé temporaire	Désignation produit fournisseur	Code interne fournisseur	Marque commerciale	com-	Dénomination réglementaire
VIN BEAUJO NOUVEAU(75CLX6) D MOREL	BEAUJOLAIS NOUVEAU	BN 2019	DOMINIQUE MOREL		VIN AOP
COCKTAIL FRT NATUREL BTE 5/1X3 DUNE	COCKTAIL DE FRUITS A L'EAU - FORMAT 5/1	COCEODUR	DUNE Restau- ration	COCKTAIL DE FRUITS A L'EAU	DE
Sauce barbecue en coupelle 20 g GYMA	Sauce barbecue en coupelle 20 g GYMA	400937	GYMA		Sauce Barbecue
Confiture abricot en bocal 450 g VALADE	Confiture abricot en bocal 450 g VALADE	PF100006	VALADE EN CORREZE		Confiture d'abricots
Confiture extra de figue en bocal verre	BONNE MAMAN CONF FIGUES VIOLETTTE 370	20000929	BONNE MAN		Confiture Extra de Figues violettes.

TABLE 28 – Exemples de libellés produit

D.3 Analyse qualitative des données

D.3.1 Évaluation de la qualité des données

Montrer qu'un sondage basique fait que la qualité actuelle est perfectible

D.3.2 Types de pdf possédés

Une information intéressante est de faire le point sur la possibilité ou non d'extraire les textes des pdf possédés. En effet, cela permet d'en exporter le contenu avec plus de simplicité et de fiabilité qu'en ayant recours à des fonctionnalités d'OCR (Optical Caracter Recognition [20]). Pour obtenir cet indicateur, on a procédé de la manière suivante :

- extraction des fichiers pdf correspondant aux étiquettes et aux fiches techniques des produits appartenant à l'échantillon de données manuellement étiquetées (la ground truth, cf. la section à venir 2.4 page 13)
- application des traitements d'extractions de textes depuis les pdf sur l'ensemble de ces fichiers
- comptage de ceux parmi eux qui apparaissent « vides », c'est à dire dont le retour de ces fonctionnalités les affiche comme contenant uniquement des whitespaces (espaces, tabulation, retours à la ligne, « form feed caracters », ...)

L'application de cette méthode est présentée à la fin du notebook « Génération de l'échantillon de données manuellement étiquetées » présenté en annexe G.1 page 140. Les résultats de cette analyse sont présentés à la TABLE 4 page 16.

On en déduit :

- que la très grande majorité des fiches techniques ont un contenu textuel extractible (96%)
- que les étiquettes, en plus d'être moins représentées que les fiches techniques, ont pour les deux tiers d'entre elles un contenu qui n'est pas exploitables par les outils de pdfmining

Annexe E EXEMPLES DE PIÈCES JOINTES ET GROUND TRUTH

E.1 Fiches techniques

E.1.1 Fiche technique sel Cerebos



Fiche technique

CEREBOS® Sel Gros Alimentaire



Version 1.9

Page 1 / 1

date d'impression: 26.10.2010

No.-CAS:	7647-14-5	No.-EINECS:	231-598-3
Apparence:			produit blanc, cristallin
Analyses chimiques	Spécification	Typique	Méthodes
• Chlorure de sodium	> 99,8 %	99,9 %	ASTM 534-98
• Teneur en eau	< 0,1 %	0,02 %	ISO 2483
• Insolubles dans l'eau	< 0,01 %	0,005 %	ISO 2479
• Anti-agglomérant E 535	< 20 mg/kg		EuSalt AS 004

Granulométrie	Typique	Méthodes
• > 3,15 mm	1 %	EN 1235
• 1,00 - 3,15 mm	89 %	
• < 1,00 mm	10 %	

Propriétés physiques:	Méthodes
• Masse volumique apparente	1.100 - 1.300 kg/m ³ EN 1236

Sur demande:	Méthodes
• Iode (sous la forme de NaI) exprimé en I	15 - 20 mg/kg EN 1236
• Fluor (sous la forme KF)	250 mg/kg EuSalt AS 017
• Législation nationale: 212,5 - 287,5 mg F/kg	

Réglementation sur les denrées alimentaires, Impuretés et contaminants:

Conforme au CODEX ALIMENTARIUS.

Domaine d'application

Sel gros de table ou de cuisine de qualité alimentaire pouvant être supplémenté en iode ou en iodure et fluor.

Site de conditionnement

Salines Cérébos et de Bayonne à Dombasle (France 54) et à Mouguerre (France 64) -
Groupe esco

Stockage

Il est conseillé de ne pas gerber les palettes. Le CHLORURE DE SODIUM étant un produit hygroscopique, tout conditionnement ouvert devra être stocké à l'abri de l'humidité.

Moyens de livraison

- sur demande

Les données précédentes résultent de nos contrôles qualité. Ces données ne dispensent pas l'utilisateur d'un contrôle à réception et ne sont pas forcément des garanties de vente. L'utilisateur est seul responsable du choix du produit en fonction de l'application souhaitée

esco - european salt company GmbH & Co.KG
 Headquarters • Landschaftstraße 1 • 30159 • Hannover • Allemagne • +49-(0)511-85030-0 ...-131
 esco benelux nv • Park Lane, Culliganlaan 2G bus 1 • B-1831 • Diegem • Belgique • +32-2711-0160 ...-0161
 esco france s.a.s • 49 Avenue Georges Pompidou • F-92693 • Levallois-Perret Cedex • France • +33(0)1.49.64.59.00 ...-1.49.64.59.10
 Vatel S.A. • Apartado 211-Sobralinho • P-2616-956 • Álverca • Portugal • +35-1219-5184-20 ...-39
 esco Espagne S.L. • Joan d'Austria, 39-47 • 08005 • Barcelona • Espagne • +34 (93) 2247238 ...+34 (93) 2214193
 esco Nordic AB • Drakegatan 10 • 401 23 • Göteborg • La Suède • +46-31 773 70-01 ...-02
 www.esco-salt.com Certification EN ISO 9001:2008

E.1.2 Fiche technique olives Valtonia

copram	FICHE TECHNIQUE	Date : 10/12/2019	V 1.2
	OLIVES NOIRES CONFITES DENOYAUTEES 4/4 VALTONIA		

INGREDIENTS :	Olives, eau, sel, stabilisateur de couleur : E579
---------------	---

MARQUE :	VALTONIA
BOITAGE :	4/4
ORIGINE :	Espagne
EAN 13 :	3061435001137
EAN colis :	3061435101134

CARACTERISTIQUES PHYSICO-CHIMIQUES ET ORGANOLEPTIQUES	
PH :	5.5 à 8.0
TAUX DE SEL :	2.0 à 3.5 %
Calibre :	30/33 unités / 100 g d'olives entières
ODEUR ET SAVEUR :	Franche et caractéristique
COULEUR :	Noire à robe de moine
PRÉSENCE DE NOYAUX :	1 noyau pour 100 fruits 2 fragments pour 100 fruits
DEFAUTS AUTRES CRITERES	Se référer au code des olives

CARACTERISTIQUES MICROBIOLOGIQUES	
Produit conforme à l'arrêté d'octobre 1997 relatif au contrôle de la stabilité des produits appétisés et assimilés (Norme AFNOR NF V08-401).	

VALEURS NUTRITIVES MOYENNES POUR 100 G DE PRODUIT EGOUTTE								
Kj	Kcal	Protéines	Matières grasses	Dont AGS	Glucides	Dont sucres	Sel	Fibres
515	125	0.5 g	13.0 g	2.2 g	0 g	0 g	2.0 g	3.0 g
INFORMATIONS COMPLEMENTAIRES								
Présence d'allergènes :	Non			Pesticides :	Conforme à la législation en vigueur.			
OGM et ionisation :	Absence			Métaux lourds :	Conforme à la législation en vigueur.			

CONDITIONNEMENT		
Contenance :	Poids net :	Poids net égoutté :
850 ml	800 g	360 g
Nombre de boîtes / carton :	Nombre de cartons /couche :	Nombre de couches / palettes :
6	12	12

CONSERVATION	
DLUO avant ouverture	3 ans. Stocker à température ambiante à l'abri de l'humidité
Après ouverture	au réfrigérateur dans un récipient alimentaire avec son liquide de couverture une semaine

Les informations contenues dans cette fiche sont celles dont nous disposons à la date de validation. Elles sont donc susceptibles d'être modifiées ultérieurement. Pour toute réclamation ou demande d'information merci de préciser impérativement le lot et/ou date de fabrication portés sur le couvercle.

Copram - Société de commercialisation des produits alimentaires du Maroc
 17, Quatrième Rue-Zone industrielle B.P. 168 – 13745 VITROLLES cedex – France
 RC Salon B 315 712/299 - Siret : 315 712 299 00017
 NAF : 511N - N° T.V.A. FR 03 315 712 299

E.1.3 Fiche technique Panna Cotta Nestlé



**Panna Cotta
NESTLÉ Docello®
Etui de 600 g (2 x 300g)
pour 50 portions**

Nestlé
docello®

CODE EAN
9002100034771

DESCRIPTION DU PRODUIT

Préparation en poudre pour Panna Cotta.

Avec arôme naturel.
Facile à mettre en œuvre et à personnaliser.

INGRÉDIENTS

Sucre, dextrose, maltodextrine, stabilisants (E460, E450, E516, E401, E404), épaississant (E407), arôme naturel (**lait**).
Peut contenir : **fruits à coque, œuf, soja et gluten**.

ALLERGÈNES MAJEURS

Conformément aux réglementations vigueur :

- Allergènes présents dans la recette ou dans un de ses ingrédients : **lait**
- Allergènes potentiellement présents : **fruits à coque, œuf, soja et gluten**.

Merci de vérifier ces informations sur l'étiquette de votre produit, car seules celles-ci font foi.

ENGAGEMENT QUALITÉ

NESTLÉ a un système de management de la Qualité certifié par les normes ISO 9001 et FSSC 22000.
Etiquetage conforme à la réglementation en vigueur sur les OGM.
Ce produit ne contient pas d'ingrédients ionisés.

MODE D'EMPLOI

1. Porter à ébullition le mélange de lait et de crème liquide.
 2. Hors du feu, verser en pluie tout en fouettant la préparation pour Panna Cotta puis mélanger jusqu'à parfaite homogénéisation. Porter à nouveau le mélange à ébullition.
 3. Verser la préparation dans des ramequins, faire refroidir puis stocker en chambre froide (entre 0°C et +3°C). Servir frais.
- Suggestion: pour une Panna Cotta encore plus onctueuse vous pouvez réduire le dosage à 130g par litre de liquide.

DOSAGES

Produit déshydraté	Dosages			
	Base	Lait	Crème liquide	Nombre de portions (90g)
Panna Cotta	150 g	0,5 L	0,5 L	12
	300 g	1 L	1 L	25
	600 g	2 L	2 L	50

UTILISATION

Pour une texture plus souple et un rendement amélioré : un sachet (300 g) + 2 L de crème liquide + 1 L de lait = 36 portions (90 g).

Idéal dans la composition d'un café gourmand.

Facilement personnalisable, ce dessert se consomme nature ou parfumé (thé vert, cardamome, badiane, pulpe de fruits...), mais également accompagné de fruits frais, de Sauces Desserts NESTLE Docello®, de coulis de fruit...



**Panna Cotta
NESTLÉ Docelio®
Etui de 600 g (2 x 300g)
pour 50 portions**

Nestlé
docelio®

CODE EAN
9002100034771

DÉCLARATION NUTRITIONNELLE

	Pour 100 g	Par portion (90 g)*	
Énergie	1563 kJ 368 kcal	811 kJ 195 kcal	
Matières grasses	0 g	14 g	
- dont acides gras saturés	0 g	9,0 g	
Glucides	91 g	14 g	
- dont sucres	86 g	14 g	
Fibres alimentaires	2,1 g	0,3 g	
Protéines	0 g	2,2 g	
Sel	0,87 g	0,19 g	

*préparée avec du lait demi-écrémé et de la crème liquide (34% de matières grasses)

Bénéfices nutritionnels

Ce produit entre dans la catégorie GEMRCN** des desserts à limiter à hauteur de 3/20 repas maximum.

3/20 repas maximum

**Groupe d'Étude des Marchés Restauration Collective et Nutrition

AVANTAGES ET BENEFICES DU PRODUIT

Crémeux et fondant, ce dessert est facile et rapide à mettre en œuvre.

CONSERVATION - STOCKAGE

Durabilité minimale : 24 mois

À conserver au sec et à l'abri de la chaleur dans son emballage d'origine. Bien refermer après chaque utilisation.

DONNÉES LOGISTIQUES

	Type UC / UD	Code EAN	Poids Net	Poids Brut	Dimensions (L x l x H) en mm
Unité consommateur (UC)	Boîte	9002100034771	600 g	691 g	80 x 185 x 200
Unité de distribution (UD)	Carton	9002100034788	3,6 kg	4,49 kg	388 x 253 x 216
Palette - Gerbabilité : OUI	Palette	7613033074578	129,6 kg	187 kg	1200 x 800 x 1014

Codes internes Nestlé			Code Douanier	Pays de production	Nbre UC par UD	Nbre UD par Couche	Couches par Palette	Nbre UD par Palette	Nbre UC par Palette
M74C/09	12202814	43825851	2106909855	Serbie	6	9	4	36	216

Nestlé France S.A.S. Noisiel 542 014 428 RCS MEAUX, NOISIEL © Reg. Trademark of Société des Produits Nestlé S.A.



Nestlé
PROFESSIONAL

Créateur de Solutions Culinaires & Boissons

Version du 05/07/2018

Les dernières mises à jour sont disponibles sur notre site internet www.nestleprofessional.fr

Page 2 / 2

E.1.4 Fiche technique confiture Andros



Route de Oinville
28 700 AUNEAU
Tél : + 33 2 37 33 16 33 - Fax : + 33 2 37 33 16 91



	05/01/2017
	-

DENOMINATION COMMERCIALE
Colis assorti de 60 bocaux de confitures et marmelade 30g Bonne Maman
15 Confiture Myrtilles et Cassis + 15 Confiture Fraises et Groseilles + 15 Confiture Abricots et Pêches + 15 Marmelade Oranges et Mandarines

DENOMINATION LEGALE DE VENTE
Confiture de Myrtilles et de Cassis - Confiture de Fraises et de Groseilles - Confiture d'Abricots et de Pêches - Marmelade d'Oranges et de Mandarines

CARACTERISTIQUES			
Variété(s) :	myrtille cassis, fraises groseilles, abricots pêches, oranges mandarines		
Conservation :	A conserver au frais après ouverture.	Date de durabilité minimale :	Voir sur unité de vente
Gencod :	3 60858 082942 3	Code article :	50082942
Codes douaniers :	Confiture Myrtilles et Cassis: 20079939 Confiture Fraises et Groseilles: 20079933 Confiture Abricots et Pêches: 20079939 Marmelade Oranges et Mandarines: 2007993110		
Confiture de myrtilles et de cassis			
Confiture de fraises et de groseilles			
Confiture d'abricots et de pêches			
Marmelade d'oranges douces et de mandarines			

ARGUMENTAIRE PRODUIT
Les confitures Bonne Maman duo, des alliances subtiles où le deuxième fruit vient rehausser la saveur et la gourmandise du premier fruit

VALEURS NUTRITIONNELLES MOYENNES													
		Myrtilles Cassis			Fraises Groseilles			Abricots Pêches			Oranges Mandarines		
		pour 100 g	pour 30 g	% AR*	pour 100 g	pour 30 g	% AR*	pour 100 g	pour 30 g	% AR*	pour 100 g	pour 30 g	% AR* par ration
ENERGIE	En kJoules (kJ) :	1016	305	4%	1018	305	4%	1031	309	4%	1022	307	4%
	En kcalories (kcal) :	239	72	4%	240	72	4%	243	73	4%	241	72	4%
Matières grasses (g) :		0,2	0	0%	0,3	0	0%	0,2	0	0%	0,1	0	0%
Dont Acides Gras saturés		0	0	0%	0	0	0%	0	0	0%	0	0	0%
Glucides (g) :		58	17	7%	58	17	7%	59	18	7%	59	18	7%
Dont sucres:		58	17	19%	58	17	19%	59	18	20%	59	18	20%
Fibres (g):		1,8	1	—	1,5	0	—	1,3	0	—	1	0	—
Protéines (g):		0,5	0	0,3%	0,5	0	1,0%	0,6	0	0,4%	0,4	0	0,2%
Sel (g):		0	0	0%	0	0	0%	0	0	0%	0	0	0

* Apports de Référence (Apports de référence pour un adulte type (8400kJ/2000kcal)). Ces valeurs et les portions peuvent varier selon l'âge, le sexe et l'activité physique

CARACTERISTIQUES PHYSICO - CHIMIQUES et ORGANOLEPTIQUES				
Parfums	Myrtilles Cassis	Fraises Groseilles	Abricots Pêches	Oranges Mandarines
Texture	onctueuse			gélifiée
Brix	60 ° brix			
Goût	Caractéristique des fruits			
Couleur	noire	rouge vif	orange	orange
pH	3,00 à 3,4	3,00 à 3,15	3,20 à 3,40	3,00 à 3,15

MENTIONS COMPLEMENTAIRES				
Allergène(s) obligatoire(s) présent(s) :	NON			
Allergène(s) obligatoire(s) pouvant être introduit(s) de manière non intentionnelle :				
Présence OGM, ionisation :				
Les produits ANDROS sont exempts :				
- d'Organisme Génétiquement Modifié et / ou d'ingrédients provenant d'Organisme Génétiquement Modifié				
- d'ingrédient ionisé y compris dans les matières premières et les ingrédients utilisés.				

RECOMMANDATIONS				
GEMRCN	—	Programme 1 fruit pour la récré		

CONDITIONNEMENT et PALETTISATION				
Bocal verre 44 ml / Capsule métallique TO 48 BM				
		Unité	COLIS	PALETTE
Format :	1 colis assorti de 60 pots de 30 g			
GENCOD :	3 60858 082942 3			03 60858 814419 1
Poids net (Kg) :	1,800			280,800
Poids brut (Kg) :	4,843			778,000
Largeur (mm) :	236			800
Longueur (mm) :	146			1200
Hauteur (mm) :	219			1459
Nombre de pièces :				156
Nombre de colis :				156
Nombre de couches :				6
Nombre de colis par couche :				26

COMMENTAIRES :				
En cas d'incohérence entre la fiche technique et l'emballage, veuillez noter que seul l'emballage fait foi.				

E.1.5 Fiche technique ciboulette La case aux épices

	FICHE TECHNIQUE		117801 Indice : f Date : 20/11/2014 Page : 1 / 2
	CIBOULETTE TUBULAIRE FLAPPERS		
DESCRIPTION DU PRODUIT			
 CARTONS de 8 Flapper's			<p>Liste des ingrédients</p> <p>Ciboulette</p>
<p>Caractéristiques organoleptiques</p> <p>La Ciboulette tubulaire est constituée de feuilles séchées de l'Allium schoenoprasum.</p>			
Dénomination légale			
Ciboulette tubulaire			
Conservation : DDM (Date de Durabilité Minimale)		Commentaires	
DDM :	36 mois	Origine :	Chine
DDM minimum à réception :	18 mois		
Conditions de stockage			
A conserver dans un endroit frais et sec			
CARACTERISTIQUES PHYSICO-CHIMIQUES		VALEURS NUTRITIONNELLES MOYENNES pour 100g	
Humidité :	max 8 %	Valeur énergétique :	- kcal - kJ
aW :	-	Matières grasses :	- g
Cendres totales :	max 13 %	dont acides gras saturés :	- g
Cendres ins. dans l'acide :	max 2 %	Glucides :	- g
Huiles essentielles :	- mL/100g	dont sucres :	- g
		Protéines :	- g
		Sel :	- g
		Fibres alimentaires :	- g
Commentaires Physico-chimie			
CARACTERISTIQUES MICROBIOLOGIQUES		Critères	
Flore totale / g		-	-
Entérobactéries / g		1 000	10 000
Coliformes totaux / g		-	-
Escherichia coli / g		100	1 000
Salmonella		absence dans 25g	-
Staphylocoques à coagulase positive / g		100	10 000
Listeria monocytogenes		absence dans 1g	100 / g
Anaérobies sulfito-réducteurs /g		-	-
Clostridium perfringens /g		1 000	10 000
Bacillus cereus /g		1 000	5 000
Levures /g		-	-
Moisiresses /g		-	-
Commentaires Microbiologie			
			
Epicez, saucez, dosez !			



FICHE TECHNIQUE
CIBOULETTE TUBULAI RE FLAPPERS

117801
Indice : f
Date : 20/11/2014
Page : 2 / 2

CONDITIONNEMENT	Emballage primaire	Emballage secondaire	Emballage tertiaire	Palette
Poids net	60 g	0.48 kg	- kg	47.04 kg
Poids brut	123 g	1.184 kg	- kg	139.03 kg
Longueur	- mm	315 mm	- cm	120 cm
Largeur	- mm	160 mm	- cm	80 cm
Hauteur	215 mm	220 mm	- cm	175 cm
Materiel	-	Carton	-	-
Marquage	-	-	-	-
GENCOD	3344540027736	3344540026111	-	-
Nb. emballages primaires	-	8	-	-
Plan de palettisation	Nb colis par rangée : 14	Nb rangées par palette : 7	Nb total colis par palette :	98

ALLERGENES (selon la directive 2007/68/CE)

Présence

All1	Céréales contenant du gluten (à savoir blé, seigle, orge, avoine, épeautre, Kamut ou leurs souches hybrides) et Produits à base de ces Céréales.	Non
All2	Poissons et Produits à base de Poissons.	Non
All3	Crustacés et Produits à base de Crustacés.	Non
All4	Oeufs et Produits à base d'Oeufs.	Non
All5	Arachides et Produits à base d'Arachides.	Non
All6	Soja et Produits à base de Soja.	Non
All7	Lait et Produits à base de lait (y compris lactose)	Non
All8	Fruits à coque, à savoir amandes, noisettes, noix, noix de cajou, noix de pécan, noix du Brésil, pistaches, noix de macadamia et noix du Queensland et Produits à base de ces fruits.	Non
All9	Graines de sésame et Produit à base de graines de sésame.	Non
All10	Céleri et Produits à base de céleri.	Non
All11	Moutarde et Produits à base de moutarde.	Non
All12	Anhydride sulfureux et sulfites en concentrations de plus de 10 mg/kg ou 10 mg/l exprimées en SO2.	Non
All13	Lupin et Produits à base de lupin.	Non
All14	Mollusques et produits à base de mollusques.	Non

Commentaires Allergènes

ATTESTATIONS

Conformément à la réglementation européenne sur les OGM (règlements CE n°1829/2003 et 1830/2003), ce produit est un ingrédient conventionnel et ne nécessite donc pas d'étiquetage spécifique.

Conformément à la directive 1999/2/CE, ce produit n'est pas ionisé et ne contient aucun ingrédient soumis à ionisation.

Cette fiche technique est conforme au règlement UE 1169/2011.

CERTIFICATIONS



Une gamme complète de sauces et d'épices pour les professionnels de la restauration...



E.1.6 Fiche technique poivron El Arenal

CONSERVAS EL ARENAL S.L.	FICHES TECHNIQUES POIVRONS ROUGES ENTIERS	<i>Date création: 10/02/2015 Date révision: 10/02/2015 Version: 1</i>								
Nom du produit	POIVRONS ROUGES ENTIERS	FORMAT								
DESCRIPTION		<i>PRODUIT CONSISTANT DE POIVRONS ROUGES ENTIERS DE LA VARIETE CAPSICUM ANNUM L, PELÉS DEPOURVUS DU CALICE ET TIGE ET PRACTIQUEMENT DE GRAINES CONSERVÉS DANS UNE SAUMURE COMPOSÉE D'EAU, DE SEL, ET D'ACIDE CITRIQUE DANS DES BOÎTES HERMETIQUES ET PASTEURISÉES JUSQU'A OBTENIR LEUR STERILITÉ COMMERCIALE</i>								
INGRÉDIENTS		<table border="1"> <tr> <td>POIVRONS ROUGES</td><td>62,50%</td></tr> <tr> <td>EAU</td><td>36,96%</td></tr> <tr> <td>SEL</td><td>0,34%</td></tr> <tr> <td>ACIDE CITRIQUE</td><td>0,20%</td></tr> </table>	POIVRONS ROUGES	62,50%	EAU	36,96%	SEL	0,34%	ACIDE CITRIQUE	0,20%
POIVRONS ROUGES	62,50%									
EAU	36,96%									
SEL	0,34%									
ACIDE CITRIQUE	0,20%									
DURÉE DE CONSERVATION	<i>LA DATE LIMITE DE CONSOMMATION EST DETERMINÉE PAR LA MANIPULATION ET LES CONDITIONS DE TRANSPORT ET DE STOCKAGE. DANS DES CONDITIONS NORMALES (TEMPÉRATURE ENTRE 10-25 °C ET HUMIDITÉ INFÉRIEURE À 75 %) ELLE EST DE 36 MOIS</i>									
CONDITIONS DE STOCKAGE ET RECOMMANDATIONS D'UTILISATION	<i>Protéger de la lumière, et garder à température ambiante, une fois ouvert, garder au frais dans un récipient non métallique à une température entre 1 - 3° C, pendant une période maximum de 3 jour.</i>									
INFORMATION DIÉTÉTIQUE	<i>Produit sans conservant ni colorants. Produit apte pour les végétariens</i>									
SPECIFICATIONS DE FERMETURES	<table border="1"> <tr> <td>Pourcentage minimum d'embrochement</td><td>45%</td></tr> <tr> <td>Pourcentage minimum de compacité</td><td>80%</td></tr> </table>		Pourcentage minimum d'embrochement	45%	Pourcentage minimum de compacité	80%				
Pourcentage minimum d'embrochement	45%									
Pourcentage minimum de compacité	80%									

CONSERVAS EL ARENAL S.L.

**FICHES TECHNIQUES
POIVRONS ROUGES ENTIERS**

*Date création: 10/02/2015
Date révision: 10/02/2015
Version: 1*

DESTINATION

Consommation humaine en général

NORMES DE QUALITÉ

CONTENU	1/2 KG
POIDS NET (g)	400
POIDS ÉGOUTTÉ (g)	250
ESPACE DE TÊTE (MM)	< 15
VACUUM (CM Hg)	> 10
PH	4.0 ± 0.3
ODEUR	TYPIQUE
COULEUR	BRILLANT ROUGE FONCÉ
TEXTURE	TYPIQUE
SAVEUR	TYPIQUE

VALEURS NUTRITIONNELLES
En accord avec le règlement CE 1169/2011

Energie	109 kJ
Energie	26 Kcal
Graisses	0,2 G
Dont saturées	0 G
Carbohydrates	4,5 G
Dont sucre	2 G
Fibre	1,5 G
Protéines	0,8 G
Sel	0,4 G

MINERAUX/VITAMINES
(valeur moyenne/100g poids égoutté)

SODIUM (mg)	160
CALCIUM mg)	20
FER (mg)	0,4
VIT. A (IU)	520
VIT.C (mg)	45

CONSERVAS EL ARENAL S.L.	FICHES TECHNIQUES POIVRONS ROUGES ENTIERS	<i>Date création: 10/02/2015 Date révision: 10/02/2015 Version: 1</i>
---------------------------------	--	---

PARAMÉTRES MICROBIOLOGIQUES	INCUBATION A 37°C PENDANT 7 JOURS (AFNOR V08-408)	SANS ALTERATION
------------------------------------	---	-----------------

INFORMATION ALLERGÉNIQUE	Liste des composants qui causent des allergies ou une hypersensibilité (CE Régulation 1169/2011. Annexe II)	<i>Présent dans le produit</i>	
		<i>oui / Non</i>	<i>Ingrédients</i>
	Céréales contenant du gluten et produits à base de céréales contenant du gluten (blé, maïs, seigle, orge, avoine, épeautre, Canut ou de leurs hybrides)	NON	
	Crustacés et fruits de mer	NON	
	Les oeuf et produits dérivés	NON	
	Les poissons et produits dérivés	NON	
	Cacahuète et produits dérivés	NON	
	Soja et produits à base de soja, à l'exception de l'huile et de graisse de soja entièrement raffinées	NON	
	Lait, produits laitiers et dérivés (inclus la lactose et les protéines de lait)	NON	
	Noix: amandes, noisettes, noix, noix de cajou, noix de pécan, noix du Brésil, noix de pistaches, noix de macadamia, et produits dérivés	NON	
	Céleri et produit dérivés	NON	
	Moutarde et produits dérivés	NON	
	Graines de sésame et produit dérivés	NON	
	Le dioxyde de soufre et sulfites en concentrations de plus de 10 mg / kg ou 10 mg / litre en termes de total SO	NON	
	Lupin et produits dérivés	NON	
	Molusques et produits dérivés	NON	

CONFORMITÉ	Ne contient pas et n'a pas été fabriqué avec des produits GMO
	Conforme à la législation pour les pesticides
	Conforme avec la législation de résidus de métaux
	Conforme avec la législation de traçabilité Règlement CE 178/2002) et HACCP's (Règlement CE 852/2004).

E.1.7 Fiche technique mélange trappeur Terre Exotique



Date d'impression : 30/12/19

Création : 12/06/12

Remarque :

Les informations contenues dans cette fiche technique sont données de bonne foi, en l'état actuel de nos connaissances, et selon les indications communiquées par le producteur ou le fournisseur. Il appartient au client de vérifier la conformité de la marchandise par rapport à l'usage qu'il en fait.

FICHE TECHNIQUE Mélange du trappeur, 70 g

Trapper blend, 70g

Code article KEREX / KEREX Code	TEEPTRAPPEUR	Poids net / net weight	0,07 Kilogramme
Nom latin (si disponible) / (Latin name)	X	Poids brut / gross weight	0,125 Kilogramme
Code barre / EAN Code	3760063322262	Origine / Origin	CANADA

Informations générales / General information

DLUO conseillé / "Best before date" recommended	5 ans / 5 years
Nomenclature douanière / Customs code	0910999900
Conditions idéales de stockage / Conditions of storage	Conserver dans un endroit frais et sec Store in a cool dry place
Ingrédients : / Ingredients	Sucre, poivre noir, coriandre, légumes déshydratés (ail, oignon, poivron rouge), sel de mer, sucre d'érythritol, arôme d'érythritol naturel, huile végétale (canola) Sugar, black pepper, coriander, dehydrated vegetables (garlic, onion, red bell pepper), sea salt, maple sugar, natural maple aroma, vegetable oil (canola)

Contaminants / Contaminating

Ionisation / Irradiation	Conformité à la directive 1999/2/CE (22/02/99) Produit non ionisé et ne contenant pas d'ingrédients ionisés. Not irradiated accordingly with the Reg 1999/2/CE (22/02/99).		
OGM / GMO	Free from GMO Ne contient pas d'OGM, est non soumis à l'étiquetage sur les OGM		
Pesticides/ Pesticides	Conforme à la directive 396/2005 /CE In accordance with Reg 396/2005 /CE.		
Métaux Lourds / Heavy Metals	Conforme au règlement 1881/2006 /CE In accordance with Reg 1881/2006 /CE..		
Allergènes et leurs dérivés (si présents) / Allergens (if existing)	Gluten	/ Gluten	Absence
	Crustacés	/ Crustaceans	Absence
	Oeufs	/ Eggs	Absence
	Poisson	/ Fish	Absence
	Soja	/ Soy	Absence
	Lait	/ Milk	Absence
	Fruits à coque - Arachides	/ Peanuts and Treenuts	Absence
	Céleri	/ Celery and celeriac	Absence
	Moutarde	/ Mustarde	Absence
	Sésame	/ Sésame	Absence
	Sulfites	/ Sulphites	Absence
	Lupin	/ Lupin	Absence
	Mollusques	/ Shellfish	Absence

Caractères microbiologiques / Microbiological characteristics


Microorganismes aérobies 30 °C	/ Total plat count (APC)	NF V05-051 < 6 000 000 / g
Escherichia coli	/ E. Coli	NF V08-053 < 10 / g
Salmonelles	/ Salmonella	NF V08-052 Absence dans 25g
Levures	/ Yeasts	NF V08-059 < 10 000 / g
Moisiures	/ Moulds	NF V08-059 < 10 000 / g
Aflatoxine Total	/ Total aflatoxin	Kit Enzymatique < 10 ppb
Aflatoxine B1	/ B1 aflatoxin	Kit Enzymatique < 5 ppb

E.2 Étiquettes produit

E.2.1 Étiquette curry Grain d'ailleurs



E.2.2 Étiquette madeleines Saint Michel




E.2.3 Étiquette lentilles Soufflet

**LENTELLER LINSEN 4mm
GREEN LENTILS 4mm
LINZEN 4mm**

Trace possible de céréales contenant du gluten - Possible traces of gluten containing cereals

Mögliche Spuren von Getreide, die Gluten enthalten - Mogelijk spoor van graangewassen met gluten



5 KG

VP

E.2.4 Étiquette pannacotta Nestlé



E.2.5 Étiquette sauce soja Kikkoman



E.2.6 Étiquette mélange trappeur Terre Exotique



E.3 Étiquetage manuel des données

E.3.1 Règles de gestion pour l'étiquetage

#	REGLES DE GESTION
REGLES GENERALES SUR L'INTERPRETATION DU DOCUMENT	
020	Si la liste d'ingrédients n'est pas présente sur le document, on laisse le champ vide. Ex : 21233a00-bc20-40fc-acb9-ee2e2321cac2
026	Si un document est visiblement corrompu (ex : ne contient rien), on le garde dans le jeu de test, avec aucune liste d'ingrédients en cible. Ex : 8e8bbc12-7e4b-4fff-a111-f7c8ae35129a
027	En règle générale, on ne récupère que ce qui est mentionné dans le bloc 'Ingrédients' ou 'Composition' de la fiche technique. Et ce, même si on aurait gardé le texte d'un autre bloc s'il avait été avec le texte de la liste d'ingrédients. Ex : Composition typique (Données inappropriées pour la demande des restitutions) pâte de cacao Tanzanie 69,5% ; sucre 21,5% ; beurre de cacao 9,0% ; vanille naturelle en poudre <1% Contact croisé d'allergènes possible au cours du process Peut contenir : Lait => on ne garde que : pâte de cacao Tanzanie 69,5% ; sucre 21,5% ; beurre de cacao 9,0% ; vanille naturelle en poudre <1% Ingrédients: SEMOULE DE BLE' DUR de qualité supérieure Origine des matières premières Blé cultivé en UE et Hors UE, moulu en Italie => on ne garde que : SEMOULE DE BLE' DUR de qualité supérieure
028	Si la fiche ne contient qu'un tableau récapitulatif des ingrédients, et pas la liste des ingrédients telle qu'elle doit être imprimée sur l'étiquette, on ne récupère rien. Ex : bc48d583-edf0-460e-a536-58f347ba6823
032	Si la liste d'ingrédients ne concerne qu'un seul composant et qu'elle est préfixée par le nom du produit, on ne garde que la liste d'ingrédients en tant que telle. Ex : CARACTERISTIQUES TECHNIQUES Ingrédients Sauce tomate, fumée et pimentée :Vinaigre d'alcool, eau, purée de tomates concentré (17%), sucre, purée de datte, pâte de piment Chipotle (5%, purée de tomates, piments Jalapeno fumé, eau, oignon, vinaigre d'acétol, sucre, poivres, sel, ail, épices, persil, extrait d'épice), amidon modifié, sel, jus de pomme concentré, poudre de Chili, arôme de fumée, épice, poudre d'ail, poudre d'oignon, conservateur (sorbate de potassium), extrait d'épice. On ne garde que : Vinaigre d'alcool, eau, purée de tomates concentré (17%), ...
039	Si la liste d'ingrédient mentionne une interprétation de la liste (un synonyme plus parlant), on ne reprend pas cette mention. Ex : 100% tourteau de cacao maigre = poudre de cacao pure Peut contenir des traces d'arachide et de lait devient : 100% tourteau de cacao maigre Peut contenir des traces d'arachide et de lait
LANGUES	
029	Si la fiche technique est en anglais, on ne récupère rien. Ex : 45aaafdde-9ca7-42ab-973f-70d6fa402e17
037	Si la liste d'ingrédients est présente en plusieurs langues, on ne garde que le français. Y compris si les textes sont "mélangés". Ex : Ingrédients - Ingredients: semoule de blé dur de qualité supérieure, issu de la filière Alpina durum wheat premium semolina from Alpina durum wheat channel Peut contenir des traces d'œufs - May contain traces of eggs devient : semoule de blé dur de qualité supérieure, issu de la filière Alpina Peut contenir des traces d'œufs
MISE EN PAGE ET FORMAT	
001	On conserve les retours à la ligne qui correspondent à un retour chariot volontaire. On garde sur une unique ligne les longues suites de mots qui sont visuellement retournées à la ligne parce qu'on arrive "au bout de la zone". Ex : Aubergine 60,5% (aubergine, huile de tournesol), eau, oignon, huile de tournesol, jus de citron, concentré de tomate, huile d'olive vierge extra (2%), ail, sel, persil, basilic, poivre, thym, romarin. devient : Aubergine 60,5% (aubergine, huile de tournesol), eau, oignon, huile de tournesol, jus de citron, concentré de tomate, huile d'olive vierge extra (2%), ail, sel, persil, basilic, poivre, thym, romarin.
002	Si des tirets, des puces ou des listes numérotées sont présentes, on garde le marqueur de début de ligne tel quel. Ex : - 100% Semoule de BLE dur de qualité supérieure - Contient du gluten Si le numéro de lot contient la lettre N : peu contenir de l'œuf
003	La casse et les accents sont conservés tels quels. Si le copier / coller depuis pdf ajoute des espaces ou autres artefacts, on les corrige pour avoir un texte qui correspond à ce qui est lu par un utilisateur Ex : A u b e r g i n e 6 0 , 5 % (aubergine, huile de tournesol), ... devient: Aubergine 60,5% (aubergine, huile de tournesol),
005	La ponctuation est conservée telle quelle, en particulier on garde le point final s'il est présent.
008	On garde les fautes d'orthographe
010	On remplace l'accent aigu sans lettre ' par une apostrophe normale : '

	011	Remplacer l'e dans l'o (œ) par oe
	012	Pas de multiples retours à la ligne successifs (même s'ils apparaissent à la lecture)
014		<p>Si les ingrédients sont séparés par des retours chariot, on conserve cette mise en forme.</p> <p>Ex : eau sucre étrait de thé noir (1,4g/l) acidifiant (acide citrique) jus de citron à base de concentré (0,1%) arôme correcteur d'acidité (citrate trisodique) antioxydant (acide ascorbique)</p>
		PREFIXES A LA LISTE
036	006	<p>On ne garde pas les préfixes du type "Ingrédients :" ou "Composition :"</p> <p>Si le bloc d'ingrédient fait référence au règlement INCO, on ne conserve pas cette mention.</p> <p>Ex : Déclaration d'étiquetage Selon le règlement 1169/2011 UE : ananas, jus d'ananas, antioxydant : acide ascorbique, acidifiant : acide citrique</p>
		On ne garde que : ananas, jus d'ananas, antioxydant : acide ascorbique, acidifiant : acide citrique
		MENTION DES ALLERGENES
007	007	<p>On garde les précisions relatives aux traces d'allergènes, aux risques de contamination croisées, ...</p> <p>Ex : Fabriqué dans une usine utilisant des FRUITS à COQUE, SOJA et ARACHIDES => On garde.</p>
017b		<p>Si une note de bas de page précise la présence d'un composant dans un ingrédient, on le mentionne.</p> <p>Ex : Eau, huile de colza, vinaigre d'alcool, MOUTARDE de Dijon (eau, graines de MOUTARDE, vinaigre d'alcool, sel, correcteur d'acidité : E330, conservateur : E224*), sel, sucre*, acidifiant : E330, épice, stabilisants : E412 et E415. *Contient : SULFITES. <=> On garde cette ligne</p>
035	008	<p>On ne garde pas de mention précisant l'absence d'allergènes :</p> <p>Ex : Filets de maquereaux scomber scombrus 60% (Pêchés en Atlantique Nord-Est), eau, concentré de tomates (30% de la sauce), huile de colza, vinaigre, sel, épaississant : gomme xanthane, arômes naturels. Allergènes majeurs (hors poisson) : absence. ==> on ne garde pas cette mention</p>
035b	009	<p>On conserve les mentions précisant la présence d'un allergène si jamais la liste d'ingrédients ne permet pas de le déduire (sulfites uniquement ?)</p> <p>Ex : Huile de colza, à Aceto Balsamico di Modena IGP » (25%) (vinaigre de vin, moût de raisin cuit, colorant E-150d), huile d'olive vierge extra. Contient sulfites. <=> on garde cette ligne.</p>
		PRECISIONS SUR LA COMPOSITION - PRESENCE DE COMPOSANTS SPECIFIQUES HORS ALLERGENES
017	017	<p>On mentionne les composants et les recommandations qui peuvent être présentes.</p> <p>Ex : Maltodextrine, carraghénane E407a, amidon de blé, colorant : jus concentré de betterave E162, édulcorant : aspartame E951* (0,37%), arôme goût framboise (substances aromatisantes, substances aromatisantes naturelles). *Contient une source de phénylalanine, ne convient pas aux femmes enceintes. ==> On garde cette ligne</p>
		PRECISIONS SUR LA COMPOSITION - PROPORTIONS
009	009	<p>On garde les précisions relatives au détail de la composition (en particulier le taux de cacao)</p> <p>Ex : Taux de coumarine compris entre 1 et 3,5 % ==> on garde</p> <p>----- sucre, pâte de cacao, beurre de cacao, émulsifiant : lécithine de tournesol (E322), arôme vanille cacao : 40%minimum ==> on garde</p> <p>----- chocolat supérieur au lait 39% (sucre, lait en poudre, beurre de cacao, pâte de cacao, émulsifiants : lécithines [soja], vanilline), sucre, lait écrémé en poudre, huile de palme, beurre concentré, émulsifiants : lécithines [soja], vanilline. Sur le total : produits laitiers 33 % (lait écrémé en poudre, lait en poudre : 27,4 %, beurre concentré 5,6 %) - cacao 12,5 %. Le chocolat utilisé est un chocolat pur beurre de cacao. <=> On garde cette seconde partie</p> <p>----- eau, sirop de glucose-fructose, sucre, épaississant : amidon modifié, graisse végétale non hydrogénée de noix de coco, jus concentré de citron 2%, gélifiant : pectines de fruits, arôme naturel de citron, émulsifiants E472C et E473, arôme, conservateur : sorbate de potassium, sel, colorant : E161b. Teneur en Lutéine : moins de 5 mg/kg <=> On garde cette partie</p>
009b	009b	<p>Y compris lorsqu'accompagnée de mise en garde particulière :</p> <p>TENEUR ÉLEVÉE EN CAFÉINE, DÉCONSEILLÉ AUX ENFANTS ET AUX FEMMES ENCEINTES OU ALLAITANTES OU AUX PERSONNES SENSIBLES À LA CAFÉINE (21mg/100ml). CONSOMMER AVEC MODÉRATION. <=> On garde cette ligne</p>
		MENTIONS CONDITIONNELLES
034	034	<p>Si une mention précise une condition pour la présence d'un ingrédient, on conserve cette mention.</p> <p>Ex : Pommes 21%, poires 39%, eau, sucre, arôme, antioxydant : acide ascorbique, acidifiant : acide citrique (si le fruit n'en contient pas suffisamment). On garde la mention : (si le fruit n'en contient pas suffisamment)</p>
034b	034b	<p>Si une mention précise une condition pour la présence d'une trace d'allergène, on conserve cette mention.</p> <p>Ex : - 100% Semoule de BLE dur de qualité supérieure - Contient du gluten Si le numéro de lot contient la lettre N : peu contenir de l'œuf ==> on conserve cette mention.</p>
034c	034c	<p>Si une mention précise une condition pour la présence d'additif, on conserve cette mention.</p> <p>Ex : INGRÉDIENTS : Segments de pamplemousse, eau, sucre, acidifiant : acide citrique*, agent de fermeté : chlorure de calcium*. * En fonction des origines, des additifs peuvent être ajoutés. <=> On garde cette mention</p>
009c	009c	<p>Si une note de bas de page précise la variabilité du taux dans la liste d'ingrédients, on conserve cette note.</p> <p>Ex : pulpe de pommes (50%)*, sucre, sirop de glucose, gélifiant : pectines, acidifiant : acide citrique, arômes, colorants : E100 - E163 - E160c - E141. * Pourcentage à la mise en œuvre pour chaque parfum. <=> On conserve cette ligne.</p>
		LISTES D'INGRÉDIENTS MULTIPLES POUR UNE MÊME FICHE TECHNIQUE

	Dans le cas d'assortiments, s'il y a plusieurs listes d'ingrédients successives, on les listes toutes en gardant les entêtes qui définissent le produit. Ex : Confiture de myrtilles et de cassis Ingrédients : fruits (myrtilles 41%, cassis 9%), sucre, sucre roux de canne, jus de citrons concentré, gélifiant : pectine de fruits. Confiture de fraises et de groseilles Ingrédients : fruits (fraises 27 %, groseilles 23 %), sucre, sucre roux de canne, jus de citrons concentré, gélifiant : pectine de fruits. Confiture d'abricots et de pêches fruits (abricots 34%, pêches 16%), sucre, sucre roux de canne, jus de citrons concentré, gélifiant : pectine de fruits. Malgré tous nos soins, cette confiture peut contenir des noyaux. Marmelade d'oranges douces et de mandarines Ingrédients : fruits (oranges douces 37%, mandarines 3%), sucre, sucre roux de canne, jus de citrons concentré, gélifiant : pectine de fruits.
013b	S'il existe plusieurs manières différentes de présenter le produit, chacune avec sa liste d'ingrédients, on conserve les 2 de la même manière que lorsqu'il y a plusieurs composants. Ex: Vinaigre de vin rouge au jus d'échalote 7% d'acidité Vinaigre de vin rouge (sulfites), jus d'échalote (0,5%), arôme*, conservateur: sulfite acide de sodium Vinaigre de vin rouge aromatisé à l'échalote 7% d'acidité Vinaigre de vin rouge (sulfites), arômes échalote (1%), conservateur: sulfite acide de sodium
040	Si une liste d'ingrédient possède une variante en fonction du conditionnement, on conserve les informations relatives à ces précisions. Ex : Eau de source*/Eau**; jus de fruits à base de concentrés 12.4% (orange 11.4%, ananas 1%); sucre; acidifiants: acide citrique, acide malique; extraits d'orange; arômes; antioxydant: acide ascorbique; stabilisant: gomme arabique. *PET **CAN => On conserve les 2 dernières lignes qui définissent pour quel type de conditionnement la variante s'applique.
	ORIGINES
015	Si une mention de l'origine de transformation est faite, on NE récupère PAS. Ex : Sucre, amidon de FROMENT, farine de FROMENT, amidon modifié, fibres solubles, poudre à lever : (E450, E500, E341), poudre de LAIT écrémé, émulsifiants : (E471, E472e), amidon, farine de FROMENT pré gélatinisée, sel, arôme naturel. Fabriqué en France. => on ne garde pas le "Fabriqué en France"
016	Si une mention de l'origine des ingrédients est faite, on la récupère. Ex : Pomme 77% (origine 100% France), abricot 20% (origine 100% France), sucre (origine 100% France), jus concentré de carotte, antioxydant: acide ascorbique. Certains ingrédients de ce produit de proviennent pas de France. => On garde cette ligne.
016b	En particulier, pour les produits qui contiennent du poisson, si la zone de pêche est présente on la récupère. Ex : Sardines (Sardina pilchardus) 70 %, huile de tournesol, sel. Zone de pêche : Océan Atlantique Centre Est => On conserve cette mention
038	Si la liste d'ingrédients précise l'origine végétale ou animale des ingrédients, on conserve cette information. Ex : 100% thé noir Origine végétale
	DETAIL PAR PHASE
018	Si une partie de la recette est détaillée, on conserve également la description de cette sous-partie. Ex : Légumes (pommes de terre (14%), carottes (10%), champignons (9%), haricots verts, persil), sauce, thon* (22%). Composition de la sauce : Eau, huile de tournesol, vinaigre, moutarde de Dijon (eau, graines de moutarde, vinaigre, sel), sel, arômes, amidons transformés de maïs, épaississants : gomme guar et gomme xanthane. => On garde la composition de la sauce
	PRECISION SUR L'IDENTIFICATION D'UN COMPOSANT
019	Si une note de bas de paragraphe précise le nom latin du poisson, on conserve cette note de bas de page. Ex : Légumes (pommes de terre (14%), carottes (10%), champignons (9%), haricots verts, persil), sauce, thon* (22%). *Euthynnus (Katsuwonus) pelamis
019'	Si le nom latin d'un ingrédient hors poisson est présent dans la liste des ingrédients, on le conserve. Ex : semoule de blé dur blanche biologique (Triticum durum) <= On conserve Triticum durum
	LABELS DES INGREDIENTS
019b	Si une note de bas de paragraphe précise les ingrédients d'origine biologique, on conserve cette mention. Ex : Pur thé vert* (100%). (*) Ingrediénts issus de l'Agriculture Biologique => on garde cette mention
019b'	Si la note de bas de page mentionne également les références du certificat bio, on NE garde PAS ces références. Ex : Semoule de blé dur précurte* (gluten) (44,5%), semoule de blé dur complète précurte* (gluten) (29,5%), flocons de soja* (15%), flocons de céréales* (gluten) (blé* (3%), orge*, avoine*, seigle* (2,2%), riz* (0,7%). * Ingrediénts issus de l'Agriculture Biologique => On garde cette mention Produit issu de l'agriculture biologique certifié bio par Ecocert FR-BIO 01 – N/N identification ECOCERT : 44/20349 => On NE garde PAS cette mention
019c	Si une note de bas de paragraphe précise un label sur un des ingrédients, on conserve cette mention. Ex : infusion de thé noir 94% (eau, infusion intense de thé noir*), sucre, jus de pêche à base de concentré 1%, arômes naturels de thé, acidifiants: acide malique et acide citrique, arômes naturels, correcteur d'acidité: citrate de sodium, antioxydant: acide ascorbique. *Vérifié Rainforest Alliance => on garde cette mention
	ALLEGATIONS ET RESERVES
021	On NE mentionne PAS les réserves relatives au traitement physique. Ex : On NE garde PAS ceci Malgré tous les soins apportés à nos produits, leur caractère naturel n'exclut pas la présence éventuelle de noyaux, de pépins, de restes de peaux ou de parties fibreuses.
022	On NE mentionne PAS l'absence d'OGM ou d'ingrédients ionisés. Ex : On NE garde PAS ceci Le produit ne contient ni OGM, ni ingrédients ionisés.

024	On NE récupère PAS d'information de composition qui ne sont pas spécifiques à un ingrédient. Ex : Préparée avec 35g de fruits pour 100g de produit fini. ==> on ne récupère pas
025	On NE récupère PAS d'information en lien avec les données nutritionnelles. Ex : Teneur totale en sucres : 60g pour 100g. ==> on ne récupère pas.
030	On NE conserve PAS les informations relatives au processus de fabrication ou de conditionnement. Ex : Conditionné sous atmosphère protectrice.
031	On NE conserve PAS les consignes de conservation. Ex : A conserver à l'abri de la chaleur et de l'humidité.
033	On ne conserve pas les précisions d'utilisation positionnées dans la liste d'ingrédients. Ex : Ingrediénts : Ingrédients : Colorant : Caramel de sulfite caustique E150b (contient des sulfites), eau. Pour denrées alimentaires. On ne garde pas "Pour denrées alimentaires."

Annexe F

RÉSULTATS DU MODÈLE RETENU

TABLE 29 – Prédiction du meilleur modèle sur le set de test

Liste d'ingrédients prédicté	Liste d'ingrédients cible
Ingrediens : Café instantané, café torréfié moulu (3%). 36 mois à l'abri de la chaleur et de l'humidité Poire 99,9%, antioxydant : acide ascorbique. Gésier de dinde émincé 50%, graisse de canard 47%, sel, arômes naturels de poivre. Edulcorants sorbitol, isomalt, sirop de maltitol, aspartame, mannitol, sel d'aspartame-acesulfame, acesulfame-k, sucralose ; gomme base (contient de la lecithine de SOJA), arômes, épaisseur gomme arabique, humectant glycerol, colorant E171, agent d'enrobage cire de carnauba, colorant E163, antioxygène BHA. Contient une source de PHENYLALANINE.	Café instantané, café torréfié moulu (3%). Lentilles blondes Poire 99,9%, antioxydant : acide ascorbique. Gésier de dinde émincé 50%, graisse de canard 47%, sel, arômes naturels de poivre. Edulcorants sorbitol, isomalt, sirop de maltitol, aspartame, mannitol, sel d'aspartame-acesulfame, acesulfame-k, sucralose ; gomme base (contient de la lecithine de SOJA), arômes, épaisseur gomme arabique, humectant glycerol, colorant E171, agent d'enrobage cire de carnauba, colorant E163, antioxygène BHA. Contient une source de PHENYLALANINE.
Z16005 / 002 sucre, amidon modifié, LACTOSÉRUM en poudre, dextrose (contient GLUTEN), CRÈME en poudre, LACTOSE, LAIT écrémé en poudre, émulsifiants (E 472a, E 472b, E 339), sirop de glucose, correcteur d'acidité (E 263), arômes (contient LAIT), colorants (E160 b, E 101i), Traces éventuelles de FRUITS À COQUES, OEUFS.	sucré, amidon modifié, LACTOSÉRUM en poudre, dextrose (contient GLUTEN), CRÈME en poudre, LACTOSE, LAIT écrémé en poudre, émulsifiants (E 472a, E 472b, E 339), sirop de glucose, correcteur d'acidité (E 263), arômes (contient LAIT), colorants (E160 b, E 101i), Traces éventuelles de FRUITS À COQUES, OEUFS.
Gluten Crustacés Oeufs Poisson Soja Lait Fruits à coque - Arachides Céleri Moutarde Sésame Sulfites Lupin Mollusques	paprika, poivre noir, coriandre, cumin, ail semoule, carvi noir cannelle, clou de girofle, muscade
Maltodextrine, amidon de maïs, sel, farine de blé, colorant : caramel ordinaire ; arômes (blé, céleri), huile de palme, épaisseur : gomme guar ; oignon, féculé de pomme de terre, extrait de levure, jus de cuisson de viande de bœuf (0,9%), acidifiant : acide citrique ; extrait de vin blanc, extraits d'ail, de thym et de poivre. Peut contenir : lait, œuf.	Maltodextrine, amidon de maïs, sel, farine de blé, colorant : caramel ordinaire ; arômes (blé, céleri), huile de palme, épaisseur : gomme guar ; oignon, féculé de pomme de terre, extrait de levure, jus de cuisson de viande de bœuf (0,9%), acidifiant : acide citrique ; extrait de vin blanc, extraits d'ail, de thym et de poivre. Peut contenir : lait, œuf.
Boisson gazeuse aromatisée au jus de fruit à base de concentré S.Pellegrino Orange 33 cl (Aranciata) S.Pellegrino Citron 33 cl (Limonata) Le plaisir des fruits à l'italienne	<rien>
LISTE D'INGRÉDIENTS Les ingrédients mis en œuvre pour fabriquer le produit sont les suivants (ordre d'importance pondérale décroissant) : Farine de BLÉ 20% - Huile de colza - OEUFS entiers 17,5% - Sucre - Graines de tournesol caramélisées (graines de tournesol 3,5%, sucre) - Stabilisant : glycérol - Farine de BLÉ complet 4,5% - Poudres à lever : diposphates, carbonates de sodium - Flocons d'AVOINE 1% - Poudre de LAIT écrémé - Protéines de LAIT - Emulsifiants : mono- et diglycérides d'acides gras (origine végétale) - Sel - Arômes naturels (contient alcool).	Farine de BLÉ 20% - Huile de colza - OEUFS entiers 17,5% - Sucre - Graines de tournesol caramélisées (graines de tournesol 3,5%, sucre) - Stabilisant : glycérol - Farine de BLÉ complet 4,5% - Poudres à lever : diposphates, carbonates de sodium - Flocons d'AVOINE 1% - Poudre de LAIT écrémé - Protéines de LAIT - Emulsifiants : mono- et diglycérides d'acides gras (origine végétale) - Sel - Arômes naturels (contient alcool).
Persil feuilles mini poivrons jaunes, eau, sucre, sel, affermissant chlorure de calcium : E509, acidifiant : acide citrique, vinaigre, antioxydant : vitamine C E330	Persil mini poivrons jaunes, eau, sucre, sel, affermissant chlorure de calcium : E509, acidifiant : acide citrique, vinaigre, antioxydant : vitamine C E330
HARICOTS BLANCS BIO 5Kg INGREDIENTS : Poudre de lait écrémé, anti-agglomérant : E551 [nano]	100% haricots blancs bio Poudre de lait écrémé, anti-agglomérant : E551 [nano] Lait origine France

Continued on ne

Liste d'ingrédients prédicté

Liste d'ingrédients cible

Ingrediénts : sucre ; sirop de glucose ; amidon de maïs ; humectant : sirop de sorbitol ; farine de blé ; eau ; acidifiants : acide citrique, acide malique ; agent d'enrobage : cire de carnauba ; correcteurs d'acidité : citrate tricalcique, malate acide de sodium ; émulsifiant : mono- et diglycérides d'acides gras ; arôme ; concentrés de fruits et de plantes : cassis, baie de sureau, aronia, raisin ; extrait de baie de sureau ; colorants : curcumine, bleu patenté V.	HAPPY CHERRY sirop de glucose ; sucre ; gélatine ; dextrose ; acidifiant : acide citrique ; arôme ; concentrés de fruits et de plantes : carthame, pomme, spiruline ; colorant : anthocyanes ; agents d'enrobage : cire d'abeille blanche et jaune, cire de carnauba ; sirop de sucre inverti. WORMS sirop de glucose ; sucre ; gélatine ; acidifiant : acide citrique ; arôme ; concentrés de fruits et de plantes : carthame, spiruline, pomme, kiwi, carotte, hibiscus, cassis, baie de sureau, aronia, raisin, orange, citron, mangue, fruit de la passion ; extrait de baie de sureau ; sirop de caramel ; agents d'enrobage : cire d'abeille blanche et jaune, cire de carnauba. OEUFS AU PLAT sucre ; sirop de glucose ; dextrose ; gélatine ; acidifiant : acide citrique ; arôme ; colorants : carotènes végétaux, anthocyanes ; agents d'enrobage : cire d'abeille blanche et jaune, cire de carnauba. L'OURS D'OR sirop de glucose ; sucre ; gélatine ; dextrose ; acidifiant : acide citrique ; jus de fruits concentrés : pomme, orange, citron, fraise, framboise, ananas ; arôme ; concentrés de fruits et de plantes : carthame, spiruline, pomme, kiwi, orange, baie de sureau, citron, mangue, fruit de la passion, cassis, aronia, raisin ; agents d'enrobage : cire d'abeille blanche et jaune, cire de carnauba. HAPPY COLA sirop de glucose ; sucre ; gélatine ; dextrose ; acidifiant : acide citrique ; sirop de caramel ; arôme ; agents d'enrobage : cire d'abeille blanche et jaune, cire de carnauba. CROCO sirop de glucose ; sucre ; dextrose ; gélatine ; acidifiant : acide citrique ; concentrés de fruits et de plantes : carthame, spiruline, pomme ; sirop de sucre inverti ; arôme ; colorants : carotènes végétaux, lutéine, anthocyanes ; agents d'enrobage : cire d'abeille blanche et jaune, cire de carnauba. RAINBOW PIK sucre ; sirop de glucose ; amidon de maïs ; humectant : sorbitols ; farine de blé ; dextrose ; amidon de blé ; graisse de palme ; acidifiants : acide citrique, acide malique ; correcteurs d'acidité : citrate tricalcique, malate acide de sodium, citrate trisodique ; agent d'enrobage : cire de carnauba ; gélatine ; émulsifiant : mono- et diglycérides d'acides gras ; arôme ; ...
Farine de BLE, huile de colza non hydrogénée, OEUFS de poules élevées en plein air (21%), sucre, stabilisant : glycérol, sirop de glucose-fructose, émulsifiant : mono- et diglycérides d'acides gras, poudres à lever : diphosphates et carbonates de sodium (BLE), féculé, sel, arôme.	Farine de BLE, huile de colza non hydrogénée, OEUFS de poules élevées en plein air (21%), sucre, stabilisant : glycérol, sirop de glucose-fructose, émulsifiant : mono- et diglycérides d'acides gras, poudres à lever : diphosphates et carbonates de sodium (BLE), féculé, sel, arôme.
MENTIONS D'ETIQUETAGE- LABELS MENTIONS INGREDIENTS : SIROP DE GLUCOSE / SUCRE / AROMES / ACIDIFIANT : ACIDE CITRIQUE E 330 / CONCENTRES (CASSIS, CAROTTE, POMME, CARTHAME, SPIRULINE, HIBISCUS)	SIROP DE GLUCOSE / SUCRE / AROMES / ACIDIFIANT : ACIDE CITRIQUE E 330 / CONCENTRES (CASSIS, CAROTTE, POMME, CARTHAME, SPIRULINE, HIBISCUS)
Ingrediénts Olives vertes 98%denoyautées , huile tournesol, piments, sel ,poivre,(cayenne,noire) acides (citrique,LACTIQUE,ascorbyque), paprika rouge, poireau, oignon, persil, ail, tomate, bouillon (hydrolysat de protéines, SOYA et maïs, graisse de palme RPSO).	Olives vertes 98%denoyautées , huile tournesol, piments, sel ,poivre,(cayenne,noire) acides (citrique,LACTIQUE,ascorbyque), paprika rouge, poireau, oignon, persil, ail, tomate, bouillon (hydrolysat de protéines, SOYA et maïs, graisse de palme RPSO), noix de muscade, Conservateur :E220.
Pommes de terre 59,5 % - Céleris 40 % - Amidon de maïs - Sirop de glucose de maïs - Huile de colza - Emulsifiants : E322, E471 - Stabilisant : E450i - Curcuma - Conservateur : E223 - Antioxydant : E304 - Acidifiant : E330.	Pommes de terre 59,5 % - Céleris 40 % - Amidon de maïs - Sirop de glucose de maïs - Huile de colza - Emulsifiants : E322, E471 - Stabilisant : E450i - Curcuma - Conservateur : E223 - Antioxydant : E304 - Acidifiant : E330.
Eau ; jus de fruit de la passion ; sucre ; épaisseur : pectine ; antioxydant : acide ascorbique	Eau ; jus de fruit de la passion ; sucre ; épaisseur : pectine ; antioxydant : acide ascorbique
Eau, huile de tournesol, beurre 9,5 %, jaune d'oeuf 6 %, amidon modifié, sel, jus de citron concentré, amidon de maïs, épaisseurs (gomme guar, gomme xanthane), protéines de pois, sucre, arôme naturel, curcuma, extrait de paprika.	Eau, huile de tournesol, beurre 9,5 %, jaune d'oeuf 6 %, amidon modifié, sel, jus de citron concentré, amidon de maïs, épaisseurs (gomme guar, gomme xanthane), protéines de pois, sucre, arôme naturel, curcuma, extrait de paprika.
Composition typique (Données inappropriées pour la demande des restitutions) pâte de cacao 50,5%; sucre 47,5%; beurre de cacao 1,5%; émulsifiant : lécithine de soja <1%; arôme naturel de vanille <1%	pâte de cacao 50,5%; sucre 47,5%; beurre de cacao 1,5%; émulsifiant : lécithine de soja <1%; arôme naturel de vanille <1%
<rien>	<rien>
Pommes de terre, eau, sel.	Pommes de terre, eau, sel.
Farine de pois chiche	Farine de pois chiche
Lentilles, eau, sel, arôme naturel (céleri)	Lentilles, eau, sel, arôme naturel (céleri)
* Produits issus de l'Agriculture Biologique.	Sucre roux de canne* (64%), amidon de maïs*, poudre de LAIT écrémé*, poudre d'OEufs entiers*, gélifiants : carraghénanes, agaragar* ; arôme naturel de vanille* et autres arômes naturels*, poudre de gousset de vanille*, curcuma*.
° Ingrédient issu du commerce équitable. 65,1% des ingrédients d'origine agricole sont issus du commerce équitable (Sucre : Paraguay).	* Produits issus de l'Agriculture Biologique. ° Ingrédient issu du commerce équitable. 65,1% des ingrédients d'origine agricole sont issus du commerce équitable (Sucre : Paraguay).
Ingrediénts : Chocolat au lait (sucre, beurre de cacao, LAIT entier en poudre, pâte de cacao, lactose (LAIT), lactosérum en poudre (LAIT), émulsifiant : lécithine de SOJA), chocolat noir (pâte de cacao, sucre, beurre concentré (LAIT), beurre de cacao, émulsifiant : lécithine de SOJA), praliné 7% (sucre, AMANDES, NOISETTES), pâte d'amande 5% (sucre, AMANDES, eau, sirop de sucre inverti, sirop de glucose, humectant : sorbitol, conservateur : sorbate de potassium), beurre concentré (LAIT), chocolat noir origine Madagascar 3% (pâte de cacao de Madagascar, sucre, beurre de cacao, émulsifiant : lécithine de SOJA), sucre, pâte de figues 1,5%, sirop de glucose, humectant : sorbitol, sirop de sucre inverti, beurre de cacao, LAIT concentré écrémé sucré, crème stérilisée (LAIT), LAIT entier en poudre, lactosérum en poudre (LAIT), graisses végétales (palme et palmiste), caramel aromatique (sucre, eau), meringues cacaotées 0,4% (sucre, cacao en poudre, blanc d'OEUF amidon de BLE, arôme), huile de tournesol, purée de PISTACHE, cacao maigre en poudre, émulsifiants : monostéarate de glycérrol, lécithine de SOJA, fleur de sel de Guérande, sel, arômes naturels, arôme, enzyme : invertase, farine de BLE, malt d'ORGE.	Chocolat au lait (sucre, beurre de cacao, LAIT entier en poudre, pâte de cacao, lactose (LAIT), lactosérum en poudre (LAIT), émulsifiant : lécithine de SOJA), chocolat noir (pâte de cacao, sucre, beurre concentré (LAIT), beurre de cacao, émulsifiant : lécithine de SOJA), praliné 7% (sucre, AMANDES, NOISETTES), pâte d'amande 5% (sucre, AMANDES, eau, sirop de sucre inverti, sirop de glucose, humectant : sorbitol, conservateur : sorbate de potassium), beurre concentré (LAIT), chocolat noir origine Madagascar 3% (pâte de cacao de Madagascar, sucre, beurre de cacao, émulsifiant : lécithine de SOJA), sucre, pâte de figues 1,5%, sirop de glucose, humectant : sorbitol, sirop de sucre inverti, beurre de cacao, LAIT concentré écrémé sucré, crème stérilisée (LAIT), LAIT entier en poudre, lactosérum en poudre (LAIT), graisses végétales (palme et palmiste), caramel aromatique (sucre, eau), meringues cacaotées 0,4% (sucre, cacao en poudre, blanc d'OEUF amidon de BLE, arôme), huile de tournesol, purée de PISTACHE, cacao maigre en poudre, émulsifiants : monostéarate de glycérrol, lécithine de SOJA, fleur de sel de Guérande, sel, arômes naturels, arôme, enzyme : invertase, farine de BLE, malt d'ORGE. Contient lait, soja, amande, noisette, pistache, blé, orge et oeuf. Présence possible d'arachide, noix, noix de cajou et noix de pécan.

Continued on next page

Liste d'ingrédients prédicté	Liste d'ingrédients cible
Le chocolat utilisé est un chocolat pur beurre de cacao.	pâte à tartiner aux noisettes et au cacao 81,5 % (sucre, huile de palme, noisettes 13%, lait écrémé en poudre 8,7%, cacao maigre 7,4%, émulsifiants : lécithines [soja]; vanilline), farine de froment 16%, levure de bière, extrait de malt d'orge, sel, lait écrémé en poudre, émulsifiants : lécithines [soja]; protéines de froment, protéines de lait, eau.
Sucre, farine de FROMENT, poudre d'OEUFS entiers, amidon de FROMENT, poudre de LAIT fermenté, poudre à lever : (E500, E341, E450), amidon modifié, émulsifiants : (E472e, E472a, E472b), sel, poudre de LAIT écrémé, arôme. Fabriqué en France.	Le chocolat utilisé est un chocolat pur beurre de cacao.
Amidon de maïs* - Lait écrémé* - Sel - Fécule de pomme de terre* - Tomate* - Oignon* - Arômes naturels - Poivres* 3 % (poivre vert*, poivre blanc*, poivre noir*) - Huile de tournesol* - Extrait de levure* - Sucre caramélisé* - Ail* - Maltodextrine de maïs*. * issus de l'agriculture biologique	Sucre, farine de FROMENT, poudre d'OEUFS entiers, amidon de FROMENT, poudre de LAIT fermenté, poudre à lever : (E500, E341, E450), amidon modifié, émulsifiants : (E472e, E472a, E472b), sel, poudre de LAIT écrémé, arôme.
<10% tolerance + 3%	Amidon de maïs* - Lait écrémé* - Sel - Fécule de pomme de terre* - Tomate* - Oignon* - Arômes naturels - Poivres* 3 % (poivre vert*, poivre blanc*, poivre noir*) - Huile de tournesol* - Extrait de levure* - Sucre caramélisé* - Ail* - Maltodextrine de maïs*. * issus de l'agriculture biologique
<rien>	NOISETTES entières décortiquées.
Gastronome 70%A/30% R	Sucre; sirop de glucose; graisse de palme; humectant : sirop de sorbitol; gélatine; acidifiant : acide citrique; arôme.
- 100% Semoule de BLE dur de qualité supérieure	100% Arabica
- Contient du gluten	- 100% Semoule de BLE dur de qualité supérieure
Si le numéro de lot contient la lettre N : peu contenir de l'oeuf	- Contient du gluten
Liste d'ingrédients : Lait écrémé 59,5%, lait en poudre reconstitué 20,5%, sucre, crème, semoule de blé, poudre de lait, extrait aromatique rhum orange (rum, infusion d'écorces d'oranges douces, alcool), épaisseur : alginate de sodium, rhum, correcteur d'acidité : citrate de sodium.	Si le numéro de lot contient la lettre N : peu contenir de l'oeuf
Liste d'ingrédients : Lait écrémé 72%, caramel 10% crème, sucre, amidon transformé, beurre demi-sel 2%, sel, épaisseur : gomme xanthane, correcteur d'acidité : citrate de sodium.	Lait écrémé 59,5%, lait en poudre reconstitué 20,5%, sucre, crème, semoule de blé, poudre de lait, extrait aromatique rhum orange (rum, infusion d'écorces d'oranges douces, alcool), épaisseur : alginate de sodium, rhum, correcteur d'acidité : citrate de sodium.
Liste d'ingrédients : Pommes 89%, purée de fraises à base de concentré 6%, sirop de glucose-fructose, arôme naturel, jus concentré de carotte pourpre, antioxydant : acide ascorbique, acidifiant : acide citrique (si le fruit n'en contient pas suffisamment).	Pommes 89%, purée de fraises à base de concentré 6%, sirop de glucose-fructose, arôme naturel, jus concentré de carotte pourpre, antioxydant : acide ascorbique, acidifiant : acide citrique (si le fruit n'en contient pas suffisamment).
- Soja fermenté naturellement (soja, sel, eau)	- Soja fermenté naturellement (soja, sel, eau)
- Extrait de Blé	- Extrait de Blé
- Extrait de Légumes (Oignon, Radis, Ail, Varech, Cive, Chou, Carotte, Gingembre, Shiitake)	- Extrait de Légumes (Oignon, Radis, Ail, Varech, Cive, Chou, Carotte, Gingembre, Shiitake)
- Extrait de Pollen Fermenté	- Extrait de Pollen Fermenté
Farine de FROMENT, poudre de LACTOSERUM, sucre, poudre d'OEUF entier, poudres à lever : (E450, E500), matière grasse LAITIERE, sel. Peut contenir des traces de : soja, fruits à coques, lupin.	Farine de FROMENT, poudre de LACTOSERUM, sucre, poudre d'OEUF entier, poudres à lever : (E450, E500), matière grasse LAITIERE, sel. Peut contenir des traces de : soja, fruits à coques, lupin.
1/2 1/4 1/8 1/16 1/32	Débris de truffes d'hiver, jus de truffes, sel
Liste d'ingrédients : Maltodextrine, amidon modifié de pomme de terre, lentilles (10%), roux (10%) (farine de FROMENT, graisse de palme), LAIT fermenté traité thermiquement, sel iodé, sucre, tomate (4%), oignon (4%), LACTOSE, sel, amidon de pomme de terre, extrait de levure, paprika (2,2%), purée de tomates (2%), protéines de LAIT, ail, arômes, gingembre, farine de riz, cumin, jus d'oignon concentré, fructose, sauce soja (fève de SOJA, FROMENT), cannelle, jus de betteraves, huile de tournesol, jus de citron, persil tubéreux, dextrose. Peut contenir : œuf, céleri, moutarde.	Maltodextrine, amidon modifié de pomme de terre, lentilles (10%), roux (10%) (farine de FROMENT, graisse de palme), LAIT fermenté traité thermiquement, sel iodé, sucre, tomate (4%), oignon (4%), LACTOSE, sel, amidon de pomme de terre, extrait de levure, paprika (2,2%), purée de tomates (2%), protéines de LAIT, ail, arômes, gingembre, farine de riz, cumin, jus d'oignon concentré, fructose, sauce soja (fève de SOJA, FROMENT), cannelle, jus de betteraves, huile de tournesol, jus de citron, persil tubéreux, dextrose. Peut contenir : œuf, céleri, moutarde.
Assaisonnement poudre de curry	Graine de coriandre (19,5%), ail déshydraté, curcuma (14,5%), cumin (13,5%), gingembre, graine de moutarde, piment, fenugrec, sel, macis, oignon déshydraté, fenouil, piment de la Jamaïque, girofle, laurier.
- 100% Semoule de BLE dur de qualité supérieure	- 100% Semoule de BLE dur de qualité supérieure
- Contient du gluten	- Contient du gluten
Si le numéro de lot contient la lettre N : peu contenir de l'oeuf	Si le numéro de lot contient la lettre N : peu contenir de l'oeuf
Ingrediénts : cèpes 70% (Boletus edulis et respective famille), huile de tournesol, blanquette 5% (Tuber borchii Vitt.), oignon, beurre, sel, protéines du lait, farine de riz, amidon de maïs, dextrose, extrait de levure, épices, arôme truffée, arômes naturels, antioxydant : acide l-ascorbique (E 300).	cèpes 70% (Boletus edulis et respective famille), huile de tournesol, blanquette 5% (Tuber borchii Vitt.), oignon, beurre, sel, protéines du lait, farine de riz, amidon de maïs, dextrose, extrait de levure, épices, arôme truffée, arômes naturels, antioxydant : acide l-ascorbique (E 300).
Haricots blancs issus de l'Agriculture Biologique	Haricots blancs issus de l'Agriculture Biologique
Eau, maltodextrine, sel, arômes, sucre, arôme naturel de citronnelle, amidon modifié, ail en poudre, épices (combava, curcuma), extraits d'épices (gingembre, poivre), stabilisant (gomme xanthane).	Eau, maltodextrine, sel, arômes, sucre, arôme naturel de citronnelle, amidon modifié, ail en poudre, épices (combava, curcuma), extraits d'épices (gingembre, poivre), stabilisant (gomme xanthane).
COD. PRODUIT : CPGLLAB 49	Sucre, huiles végétales (Colza), noisettes (13%), poudre de cacao maigre (7%), lait écrémé en poudre, lactosérum en poudre, lactose. Emulsifiant lécithine de tournesol. Arôme : vanilline
DESCRIPTION : Pâte à tartiner au noisettes – Squeezed de 1 kg	Allergènes : Le produit peut contenir traces éventuelles de soja arachide et autre fruits à coque.
CODE ET DESCRIPTION CREME : pâte à tartiner 13 % noisettes	
INGREDIENTS : Sucre, huiles végétales (Colza), noisettes (13%), poudre de cacao maigre (7%), lait écrémé en poudre, lactosérum en poudre, lactose. Emulsifiant lécithine de tournesol. Arôme : vanilline	
Allergènes : Le produit peut contenir traces éventuelles de soja arachide et autre fruits à coque.	
10	<rien>
70	
THON ALBACORE MORCEAUX NATUREL EN	Thon Albacore (92%), eau (7%), sel (1%)

Continued on ne

Liste d'ingrédients prédicté	Liste d'ingrédients cible
Croustilles de céréales enrobées de chocolat au lait et de pâte de spéculoos Ingrédients : chocolat au lait 68% (sucre, beurre de cacao, poudre de lait entier, pâte de cacao, émulsifiant : lécithines (soja), arôme naturel de vanille), pâte de spéculoos 16% [Spéculoos 60% (farine de blé, sucre, huiles et graisses végétales (palme, colza), sirop de candi, poudres à lever : E500(ii) - carbonate acide d'ammonium, sel, cannelle), huiles et graisses végétales partiellement hydrogénées (tournesol, colza), palme], sucre, émulsifiants : lécithines – E472c, correcteur d'acidité : E330], céréales croustillantes 12% (farine de blé, gluten de blé, sucre, farine de malt de blé, poudre à lever : E500(ii), sel, correcteur d'acidité : E170), beurre de cacao, sucre glace, cannelle moulue. Chocolat au lait : 33% de cacao min. Traces éventuelles de : œufs, fruits à coque.	Croustilles de céréales enrobées de chocolat au lait et de chocolat blanc arôme café chocolat blanc arôme café 48% (sucre, beurre de cacao, poudre de lait entier, arômes), chocolat au lait 38% (sucre, beurre de cacao, poudre de lait entier, pâte de cacao, émulsifiant : lécithines (soja), arôme naturel de vanille), céréales croustillantes 12% (farine de blé, gluten de blé, sucre, farine de malt de blé, poudre à lever : E500(ii), sel, correcteur d'acidité : E170), sucre glace. Chocolat au lait et blanc : cacao 33% min. Traces éventuelles de : œufs, fruits à coque. Croustilles de céréales enrobées de chocolat au lait et de pâte de spéculoos chocolat au lait 68% (sucre, beurre de cacao, poudre de lait entier, pâte de cacao, émulsifiant : lécithines (soja), arôme naturel de vanille), pâte de spéculoos 16% [Spéculoos 60% (farine de blé, sucre, huiles et graisses végétales (palme, colza), sirop de candi, poudres à lever : E500(ii) - carbonate acide d'ammonium, sel, cannelle), huiles et graisses végétales partiellement hydrogénées (tournesol, colza, palme), sucre, émulsifiants : lécithines - E472c, correcteur d'acidité : E330], céréales croustillantes 12% (farine de blé, gluten de blé, sucre, farine de malt de blé, poudre à lever : E500(ii), sel, correcteur d'acidité : E170), beurre de cacao, sucre glace, cannelle moulue. Chocolat au lait : 33% de cacao min. Traces éventuelles de : œufs, fruits à coque. Croustilles de céréales enrobées de praliné et de chocolat au lait avec praliné grain chocolat au lait 65% (sucre, beurre de cacao, poudre de lait entier, pâte de cacao, émulsifiant : lécithines (soja), arôme naturel de vanille), praliné 12% (noisettes 50%, sucre, émulsifiant : lécithines (soja), arôme naturel de vanille), céréales croustillantes 12% (farine de blé, gluten de blé, sucre, farine de malt de blé, poudre à lever : E500(ii), sel, correcteur d'acidité : E170), praliné grain 8% (sucre, amandes et noisettes torréfiées), beurre de cacao, agents d'enrobage : E414-E904. Chocolat au lait : cacao 33% min. Traces éventuelles de : œufs, autres fruits à coque.
Ingrédients : sucre ; sirop de glucose ; dextrose ; gélatine ; acidifiant : acide citrique ; arôme ; sirop de caramel ; colorants : lutéine, charbon végétal ; agents d'enrobage : cire d'abeille blanche et jaune, cire de carnauba.	sucre ; sirop de glucose ; dextrose ; gélatine ; acidifiant : acide citrique ; arôme ; sirop de caramel ; colorants : lutéine, charbon végétal ; agents d'enrobage : cire d'abeille blanche et jaune, cire de carnauba.
Huile de colza, eau, vinaigre d'alcool, jaunes d'œufs, sucre, estragon (2,5%), échalote (2,4%), sel, cerfeuil, jus de citron à base de concentré, piment de Cayenne, arômes, amidon modifié, colorant : béta-carotène, conservateur : sorbate de potassium. Ce produit peut contenir des traces de moutarde.	Huile de colza, eau, vinaigre d'alcool, jaunes d'œufs, sucre, estragon (2,5%), échalote (2,4%), sel, cerfeuil, jus de citron à base de concentré, piment de Cayenne, arômes, amidon modifié, colorant : béta-carotène, conservateur : sorbate de potassium. Ce produit peut contenir des traces de moutarde.
Liste d'ingrédients : sel, exhausteurs de goût : glutamate, inosinate et guanylate de sodium, graisse de palme, amidon modifié de pomme de terre, viande de poule : 3,9%, graisse de poule : 3,5%, arômes, huile de tournesol, oignon, épices et aromates (curcuma, poivre, persil), caramel, maltodextrine, extrait de levure, antioxydant : extrait de romarin. Peut contenir : céleri.	sel, exhausteurs de goût : glutamate, inosinate et guanylate de sodium, graisse de palme, amidon modifié de pomme de terre, viande de poule : 3,9%, graisse de poule : 3,5%, arômes, huile de tournesol, oignon, épices et aromates (curcuma, poivre, persil), caramel, maltodextrine, extrait de levure, antioxydant : extrait de romarin. Peut contenir : céleri.
OEUFS, farine de BLE, sucre, amidon de BLE, stabilisants : sorbitols- glycérol, cacao maigre en poudre (3,5%), émulsifiants : E472b - E477, poudres à lever : E450 - E500, sirop de glucose, LAIT écrémé en poudre, sel, conservateur : E202, épaisseur : E410, arôme.	OEUFS, farine de BLE, sucre, amidon de BLE, stabilisants : sorbitols- glycérol, cacao maigre en poudre (3,5%), émulsifiants : E472b - E477, poudres à lever : E450 - E500, sirop de glucose, LAIT écrémé en poudre, sel, conservateur : E202, épaisseur : E410, arôme.
Liste des ingrédients : Purée de tomates mi réduite (64%), sucre, vinaigre, amidon modifié, sel, acidifiant : acide citrique	Purée de tomates mi réduite (64%), sucre, vinaigre, amidon modifié, sel, acidifiant : acide citrique
Suillus luteus (40%), Volvariella volvacea (25%), Pleurotus ostreatus (20%), lactarius deliciosus (10%), pholiota mutabilis (5%), eau, sel, acide citrique Chine, Vietnam, Chili, Europe de l'est	Suillus luteus (40%), Volvariella volvacea (25%), Pleurotus ostreatus (20%), lactarius deliciosus (10%), pholiota mutabilis (5%), eau, sel, acide citrique
Liste des Ingrédients : Filets de maquereaux (61 %), eau, concentré de tomate (15%), huile de tourneisol, vinaigre d'alcool, vinaigre de vin blanc, sel, vin blanc, épaisseur : gomme xanthane, arômes.	Filets de maquereaux (61 %), eau, concentré de tomate (15%), huile de tourneisol, vinaigre d'alcool, vinaigre de vin blanc, sel, vin blanc, épaisseur : gomme xanthane, arômes.
Salicornes de culture, eau, sel, acide citrique	Salicornes de culture, eau, sel, acide citrique
Ingrédients : semoule de blé dur supérieure et de l'eau	semoule de blé dur supérieure et de l'eau
Mélange de semoule de blé dur, lentilles, flocons de soja d'orge et d'avoine, carotte, petit pois, oignon et poireau déshydratés légèrement aromatisé	Semoule de blé dur (71%), lentilles vertes précuites (6%), arômes naturels, flocon de soja (3%), carotte déshydraté (3%), petits pois déshydraté (2%), oignon rissolé déshydraté (1%) (oignon, huile de tourneisol, antioxydant : extrait de romarin), huile de colza (1%), oignon déshydraté (1%), flocon d'orge (1%), flocon d'avoine (1%), poireau déshydraté.
Boisson gazeuse aromatisée au jus de fruit à base de concentré S.Pellegrino Orange 33 cl (Aranciata) S.Pellegrino Citron 33 cl (Limonata) Le plaisir des fruits à l'italienne	<rien>
Ingrediénts : Cerises noires 65%, sucre, gélifiant : pectine. Traces de beurre. Teneur totale en sucres : 50g pour 100g.	Cerises noires 65%, sucre, gélifiant : pectine. Traces de beurre.
Eau, purée de tomate à base de concentré*, sucre, vinaigre, amidon modifié	Eau, purée de tomate à base de concentré*, sucre, vinaigre, amidon modifié de maïs, sel, conservateurs : E202-E211, arôme naturel
INGREDIENTS : Pêches et poires en cubes (avec leur jus d'origine naturelle 6,25%), segments d'ananas, raisins, eau, sirop de glucose-fructose, sucre, arôme naturel, acidifiant : acide citrique. *Sur une base de 100% de pêches et poires.	Pêches et poires en cubes (avec leur jus d'origine naturelle 6,25%), segments d'ananas, raisins, eau, sirop de glucose-fructose, sucre, arôme naturel, acidifiant : acide citrique. *Sur une base de 100% de pêches et poires.
Sirope de glucose, sucre, eau, stabilisants (E440i, E440ii, E415), acidifiants (E330, E450i), conversateur (E202).	Sirope de glucose, sucre, eau, stabilisants (E440i, E440ii, E415), acidifiants (E330, E450i), conversateur (E202).
- 100% Semoule de blé dur de qualité supérieure - Contient du gluten - Fabriqué en France	- 100% Semoule de blé dur de qualité supérieure
Farine de blé, beurre en poudre (7 %), sucre, émulsifiants, sel, dextrose, poudre de blancs d'œufs, lactose, gluten de blé, poudre à lever : (E450, E500), arôme, antioxygène : E300, alpha amylase, hémicellulase.	Farine de blé, beurre en poudre (7 %), sucre, émulsifiants, sel, dextrose, poudre de blancs d'œufs, lactose, gluten de blé, poudre à lever : (E450, E500), arôme, antioxygène : E300, alpha amylase, hémicellulase.
LISTE DES INGREDIENTS SUCRE DE CANNE, EAU, JUS DE KIWI A BASE DE CONCENTRE (10%), ACIDI-FIANT : ACIDE CITRIQUE, AROME, COLORANTS : E 102, E 133.	SUCRE DE CANNE, EAU, JUS DE KIWI A BASE DE CONCENTRE (10%), ACIDI-FIANT : ACIDE CITRIQUE, AROME, COLORANTS : E 102, E 133.
Flageolets verts. Jus : eau, sel, affermissant : chlorure de calcium (E509) <rien>	Flageolets verts. Jus : eau, sel, affermissant : chlorure de calcium (E509) Huile de tourneisol, huile de tourneisol hautement oléique, huile de pépins de raisins, antimoussant E-900
Graine de courge, canneberge, graine de tourneisol, graine de moutarde	Graine de courge, canneberge, graine de tourneisol, graine de moutarde
Liste d'ingrédients : vinaigre d'alcool, piment jalapeno, eau, sel, épaisseur (E1422,E415) ,antioxydant (acide ascorbique).	vinaigre d'alcool, piment jalapeno, eau, sel, épaisseur (E1422,E415) ,antioxydant (acide ascorbique).
40% Tolérance +5%	AMANDES décortiquées
Riz long grain de qualité supérieure	<rien>
mg/kg	100% Huile d'ARACHIDE raffinée

Continued on ne

Liste d'ingrédients prédicté

Liste d'ingrédients cible

Ingrediénts : Sucre, sirop de glucose, farine de BLÉ, graisse de coco totalement hydrogénée, pâte de cacao, LAIT concentré sucré, sirop de sucre inverti, beurre de cacao, LAIT écrémé en poudre, poudre de lactosérum (de LAIT), matière grasse LAITIERE, huiles végétales (illipé,mangue,sal,karité et palme en proportions variables), huile de colza, sirop de sucre candi, cacao maigre en poudre, émulsifiant (lécithine de SOJA), lactose et protéines de LAIT, LAIT entier en poudre, sel, colorant (E150c), poudre à lever (carbonates acide d'ammonium, carbonate acide de sodium), arômes.PEUT CONTENIR OEUFS ET SESAME

Oeuf(Poudre de blanc d'oeuf)

Sucre, amidon de maïs, arôme vanille
à 32% minimum de cacao fortement dégraissé

Sucre, sirop de glucose, farine de BLÉ, graisse de coco totalement hydrogénée, pâte de cacao, LAIT concentré sucré, sirop de sucre inverti, beurre de cacao, LAIT écrémé en poudre, poudre de lactosérum (de LAIT), matière grasse LAITIERE, huiles végétales (illipé,mangue,sal,karité et palme en proportions variables), huile de colza, sirop de sucre candi, cacao maigre en poudre, émulsifiant (lécithine de SOJA), lactose et protéines de LAIT, LAIT entier en poudre, sel, colorant (E150c), poudre à lever (carbonates acide d'ammonium, carbonate acide de sodium), arômes.PEUT CONTENIR OEUFS ET SESAME

<rien>

Sucre, amidon de maïs, arôme vanille
Sucre, cacao maigre en poudre (beurre de cacao : 11% minimum), arôme vanille.

Cacao : 32% minimum

Tofu* 76.6% (eau, soja* dépelliculé 20.7% , gélifiants : sulfate de Calcium, Nigari), Oignons* 7.5%, Concentré de tomate* 7.5%, Flocons d'avoine* complète, Sauce de soja* (eau, soja* entier, blé* entier, sel marin, alcool*, ferment), Basilic*. Amidon de blé*, Flocons de millet*. Protéine de soja* texturée, Ail*, Persil*, Sel de mer, Huile de tournesol*, Ciboulette*, Extrait de levure*, Poivre*, Thym*, Origan*.

CocaCola Light mini 8 x 150 ml EAN5449000239808 Marché(s) cible(s) FRELémentsIngrédientsezéfinécoloriant : E150dacidifiants : acide phosphorique, acide citrique, édulcorants : aspartame, acésulfameKarômes naturels dont caféine ne contient une source de phénylalanineNutritionPour : 100ml Pour : 150ml(%*)Energie : 1kJ / 1.5kJ / 0.2kcal0.3kcal(0%)Matières grasses : 0g(0%)dont protéines : 0g(0%)Glucides : 0g(0%)dont sucres : 0g(0%)Protéines : 0g(0%)Sel : 0g(0%)Énergie : 150ml(%*)Energie : 1kJ / 1.5kJ / 0.2kcal0.3kcal(0%)Matières grasses : 0g(0%)dont acides gras saturés (g)0Gluclides (g)0Protéines (g)0Sel (g)0Nutrition sur le devant de l'emballagePar portion150ml1,5kJ0,3kcal0%g0%g0%g0%g0%100ml : 1kJ / 0.2kcal.*Apports de référence pour un adulte type (8400kJ / 2000 kcal). Valeur nutritionnelle calculée pour 100mlPour : 150mlÉnergie (kJ)11,5Énergie (kcal)0,20,3Matières grasses (g)00dont acides gras saturés (g)0Gluclides (g)0Protéines (g)0Sel (g)0Nutrition sur le devant de l'emballagePar portion150ml1,5kJ0,3kcal0%g0%g0%g0%g0%100ml : 1kJ / 0.2kcal.*Apports de référence pour un adulte type (8400kJ / 2000 kcal). Description du produit Marque Coca-Cola Caractéristiques Goût léger Sans calorie Marque normalisée Marque - CocaCola Sous marques Sous marques Light Nom de produit réglementé Boisson rafraîchissante aux extraits végétaux, avec édulcorants. Commercialisation Nom de la société CocaCola European Partners France Adresse de la société 9 chemin de Bretagne CS 80050 92784 Issy les Moulineaux, CEDEX 9 Informations diverses Conditionné avec l'autorisation de The Coca-Cola Company. Description supplémentaire Pensez au tri ! Consigne pouvant varier localement > www.consignesdetri.fr Trademark Information Coca-Cola light est une marque déposée de The CocaCola Company. © 2018 The Coca-Cola Company Allégations Nutritionnelles Sans calorie Hygiène & Mode de vie Additifs-sédulcorants artificiels Contenant Stockage et Utilisation Type De Stockage Type Température ambiante Préparation et utilisation Ne pas agiter. Se boit très frais Stockage Conserver dans un endroit tempéré, sec et sans odeur. Pack Taille du paquet les 8 canettes de 150mL Dimension Numérique Dimension numérique 150 Infos Recyclage Carton Recyclable Pays d'origine France Type d'Emballage Type Boîte Origine Texte libre sur l'origine Produit en France Recyclage Aut...

BISCUITS AU CHOCOLAT AU LAIT

Ingrediénts : chocolat au lait (38%)(sucre, beurre de cacao, pâte de cacao, lait écrémé en poudre, beurre pâtissier, émulsifiant : lécithine de soja, arôme) - farine de blé - sucre - graisse végétale (palme, colza) - sel - lactose et protéines de lait - lait entier en poudre - émulsifiant : lécithine de soja - poudres à lever : carbonates de sodium, carbonates d'ammonium, diphosphate disodique - noix de coco - arôme - œuf entier en poudre. Peut contenir des traces de sésame, de fruits à coque, d'avoine, d'orge et d'autres gluten.

Filets de maquereaux scomber scombrus 60% (Pêchés en Atlantique Nord-Est), eau, concentré de tomates (30% de la sauce), huile de colza, vinaigre, sel, épaisseur : gomme xanthane, arômes naturels.

Allergènes majeurs (hors poisson) : absence.

Absence d'OGM.

Carottes, eau, sucre, sel, vinaigre d'alcool, acidifiant : acide lactique. Présence forteuite de CELERI

Riz long étuvé de qualité supérieure issu de l'Agriculture Biologique

Liste des Ingrediénts : sucre*, LAIT en poudre*, beurre de cacao*, pâte de cacao*, émulsifiant : lécithine de tournesol (E322), extrait de vanille*
* matière première issue de l'agriculture biologique

76 g dont

sucres 0 g

Graisses

Noix

Eau, haricots verts, sel.

Légumes 43,2 % (pomme de terre, oignon, carotte, tomate, poireau) - Amidon modifié de pomme de terre - Extrait de levure - Sirop de glucose de maïs - Huile de colza - Sucre - Arôme naturel - Ail - Curcuma.

Liste des Ingrediénts : sucre, pâte de cacao, beurre de cacao, cacao maigre en poudre, émulsifiant : lécithine de tournesol (E322), arôme vanille

100 g de sucre

Farine de BLÉ 63%, eau, sucre, huile de colza, sel, vinaigre, levure, farine de fèves, gluten de BLÉ, arôme (contient alcool), extrait d'acérola. Peut contenir

Croquant sésame chocolat Barre croquante au sésame et au chocolat, source de fibres et riche en magnésium.
Composition : Graines de sésame 37%, chocolat de couverture 25% (sucre, pâte de cacao, beurre de cacao, émulsifiant : lécithines de soja, E476, arôme), sirop de glucose, sucre.

Sucre, sirop de glucose, farine de BLÉ, graisse de coco totalement hydrogénée, pâte de cacao, LAIT concentré sucré, sirop de sucre inverti, beurre de cacao, LAIT écrémé en poudre, poudre de lactosérum (de LAIT), matière grasse LAITIERE, huiles végétales (illipé,mangue,sal,karité et palme en proportions variables), huile de colza, sirop de sucre candi, cacao maigre en poudre, émulsifiant (lécithine de SOJA), lactose et protéines de LAIT, LAIT entier en poudre, sel, colorant (E150c), poudre à lever (carbonates acide d'ammonium, carbonate acide de sodium), arômes.PEUT CONTENIR OEUFS ET SESAME

<rien>

Sucre, amidon de maïs, arôme vanille

Sucre, cacao maigre en poudre (beurre de cacao : 11% minimum), arôme vanille. Cacao : 32% minimum

Tofu* 76.6% (eau, soja* dépelliculé 20.7% , gélifiants : sulfate de Calcium, Nigari), Oignons* 7.5%, Concentré de tomate* 7.5%, Flocons d'avoine* complète, Sauce de soja* (eau, soja* entier, blé* entier, sel marin, alcool*, ferment), Basilic*. Amidon de blé*, Flocons de millet*. Protéine de soja* texturée, Ail*, Persil*, Sel de mer, Huile de tournesol*, Ciboulette*, Extrait de levure*, Poivre*, Thym*, Origan*.* Ingrédients issus de l'agriculture biologique

en graissifiée

colorant : E150d

acidifiants : acide phosphorique, acide citrique

édulcorants : aspartame, acésulfameK

acides gras naturels dont caféine

épice à base de source de phénylalanine

* Ingrédients issus de l'agriculture biologique

chocolat au lait (38%)(sucre, beurre de cacao, pâte de cacao, lait écrémé en poudre, beurre pâtissier, émulsifiant : lécithine de soja, arôme) - farine de blé - sucre - graisse végétale (palme, colza) - sel - lactose et protéines de lait - lait entier en poudre - émulsifiant : lécithine de soja - poudres à lever : carbonates de sodium, carbonates d'ammonium, diphosphate disodique - noix de coco - arôme - œuf entier en poudre. Peut contenir des traces de sésame, de fruits à coque, d'avoine, d'orge et d'autres glutens.

Filets de maquereaux scomber scombrus 60% (Pêchés en Atlantique Nord-Est), eau, concentré de tomates (30% de la sauce), huile de colza, vinaigre, sel, épaisseur : gomme xanthane, arômes naturels.

Filets de maquereaux scomber scombrus 60% (Pêchés en Atlantique Nord-Est), eau, concentré de tomates (30% de la sauce), huile de colza, vinaigre, sel, épaisseur : gomme xanthane, arômes naturels.

Riz long étuvé de qualité supérieure issu de l'Agriculture Biologique

sucre*, LAIT en poudre*, beurre de cacao*, pâte de cacao*, émulsifiant : lécithine de tournesol (E322), extrait de vanille*

* matière première issue de l'agriculture biologique

cacao : 27% minimum

<rien>

Tilleul (100%).

<rien>

Eau, haricots verts, sel.

Légumes 43,2 % (pomme de terre, oignon, carotte, tomate, poireau) - Amidon modifié de pomme de terre - Extrait de levure - Sirop de glucose de maïs - Huile de colza - Sucre - Arôme naturel - Ail - Curcuma.

sucre, pâte de cacao, beurre de cacao, cacao maigre en poudre, émulsifiant : lécithine de tournesol (E322), arôme vanille

cacao : 50% minimum

Maltodextrine, édulcorant : sucralose (1,23%).

Farine de BLÉ 63%, eau, sucre, huile de colza, sel, vinaigre, levure, farine de fèves, gluten de BLÉ, arôme (contient alcool), extrait d'acérola. Peut contenir des traces d'ŒUFS, SOJA, LAIT, FRUITS À COQUE, GRAINES DE SÉSAME.

Graines de sésame 37%, chocolat de couverture 25% (sucre, pâte de cacao, beurre de cacao, émulsifiant : lécithines de soja, E476, arôme), sirop de glucose, sucre.

Fabriqué dans un atelier qui utilise de l'arachide, des fruits à coque et du lait.

Continued on next page

Liste d'ingrédients prédicté	Liste d'ingrédients cible
Liste ingrédients : Sirop de glucose-fructose, framboises 35%, sucre, gélifiant : pectines, acidifiant : acide citrique. Préparés avec 35g de fruits pour 100g de produit fini. Teneur totale en sucres : 60g pour 100g.	Sirop de glucose-fructose, framboises 35%, sucre, gélifiant : pectines, acidifiant : acide citrique.
INGREDIENTS : Jus d'orange à base de concentré	Jus d'orange à base de concentré
Ingédients : Farine de BLÉ, sucre, huile de colza,, cacao maigre en poudre 6,5 %, sirop de glucose-fructose, amidon de BLÉ, poudre à lever (carbonate de potassium, carbonate d'ammonium, carbonate de sodium),huile de palme,sel, émulsifiants (lécithine de SOJA), arôme .PEUT CONTENIR LAIT.	Farine de BLÉ, sucre, huile de colza,, cacao maigre en poudre 6,5 %, sirop de glucose-fructose, amidon de BLÉ, poudre à lever (carbonate de potassium, carbonate d'ammonium, carbonate de sodium),huile de palme,sel, émulsifiants (lécithine de SOJA), arôme .PEUT CONTENIR LAIT.
Piment rouge fort équeuté* (85%), cumin, ail moulu (3%), eau, arôme naturel d'ail, sel, sorbate de potassium. (* présence de sulfites)	Piment rouge fort équeuté* (85%), cumin, ail moulu (3%), eau, arôme naturel d'ail, sel, sorbate de potassium. (* présence de sulfites)

Annexe G

LES NOTEBOOKS DE CE PROJET

ground_truth_constitution

Pierre MASSÉ

May 12, 2020

1 Constitution de l'échantillon de données étiquetées

L'objet de ce notebook est de produire un échantillon données du PIM, avec les fiches techniques associées. Elles seront ensuite associées manuellement à la liste d'ingrédients qu'elles contiennent.

1.1 Récupération des données

1.1.1 Préambule technique

```
[1]: # setting up sys.path for relative imports
from pathlib import Path
import sys
project_root = str(Path(sys.path[0]).parents[1].absolute())
if project_root not in sys.path:
    sys.path.append(project_root)
```

```
[36]: # imports and customization of display
import os
import pandas as pd
pd.options.display.min_rows = 6
pd.options.display.width=108
from sklearn.model_selection import train_test_split
from sklearn.pipeline import make_pipeline

from src.pimapi import Requester
from src.pimest import ContentGetter, PDFContentParser
```

1.1.2 Récupération des données, et de la présences de fiches techniques

Pour constituer l'échantillon, on va d'abord extraire quelques informations du PIM, et particulièrement le type de produit. On récupèrera aussi le fait que les produits ont ou non une fiche technique fournisseur associée.

```
[7]: requester = Requester('prd')
# Let's fetch the full content of PIM system
requester.fetch_all_from_PIM()
requester.result
```

Done

```
[7]: [<Response [200]>,
<Response [200]>]
```

```
<Response [200]>

[8]: mapping = {'uid': 'uid',
              'designation': 'title',
              'state': 'state',
              'ingredients': 'properties.pprod.ingredientsList',
              'type': 'properties.pprodtop:typeOfProduct'}
df = requester.file_report_from_result(mapping=mapping, index='uid') # , record_path='entries')
df
```

	designation \
uid	
afee12c7-177e-4a68-9539-8cbb68442503	DESTR D'ODEURS AIR&TEXTILES 750CCX6 DESODOR U2
7d390121-17e8-43bf-a357-9d06b79d2d47	THÉ VERT AGRUME BTE 25S FRAICH LIPTON
f234cd84-c8f6-433f-85ec-6e0b6980adc6	T WHEAT 30 A 18X6 52C MISSION 1620
..	..
ef42a938-2203-446e-8d28-9fd27c6d3146	3D VENT FRAIS 5LX4 DESODOR U2
68f5d81b-7f91-40a0-8504-0ec320a86de4	NETTOYANT INOX 500ML LOT 2X6 KING
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a	DESINFECTANT 3D+ 750CCX6 DESODOR U2
	state \
uid	
afee12c7-177e-4a68-9539-8cbb68442503	product.waiting.supplier.validation
7d390121-17e8-43bf-a357-9d06b79d2d47	product.waiting.supplier.validation
f234cd84-c8f6-433f-85ec-6e0b6980adc6	product.waiting.supplier.validation
..	..
ef42a938-2203-446e-8d28-9fd27c6d3146	product.waiting.supplier.validation
68f5d81b-7f91-40a0-8504-0ec320a86de4	product.waiting.supplier.validation
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a	product.waiting.supplier.validation
	ingredients type \
uid	
afee12c7-177e-4a68-9539-8cbb68442503	None chemistry
7d390121-17e8-43bf-a357-9d06b79d2d47	None grocery
f234cd84-c8f6-433f-85ec-6e0b6980adc6	WHEAT flour (55%), water, vegetable fat (palm)... grocery
..
ef42a938-2203-446e-8d28-9fd27c6d3146	None chemistry
68f5d81b-7f91-40a0-8504-0ec320a86de4	None chemistry
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a	None chemistry
	has_supplierdatasheet has_supplierlabel
uid	
afee12c7-177e-4a68-9539-8cbb68442503	False False
7d390121-17e8-43bf-a357-9d06b79d2d47	False False
f234cd84-c8f6-433f-85ec-6e0b6980adc6	True True
..
ef42a938-2203-446e-8d28-9fd27c6d3146	False False
68f5d81b-7f91-40a0-8504-0ec320a86de4	False False
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a	False False

[13212 rows x 6 columns]

1.2 Constitution de l'échantillon

On va constituer l'échantillon en appliquant les règles suivantes : - on construit un échantillon de 500 produits - on conserve les produits de type Epicerie et Boisson non alcoolisée - on conserve les produits qui possèdent une fiche technique fournisseur - on fait un échantillon stratifié par type de produit (Epicerie / Boisson)

```
[12]: filtered_df = df.loc[(df.type.isin(['grocery', 'nonAlcoholicDrink'])) & (df.has_supplierdatasheet)]
train, ground_truth_df = train_test_split(filtered_df, test_size=500, random_state=42, stratify=filtered_df.type)
ground_truth_df
```

```
[12]: designation \
uid
49428283-104a-4092-966f-07b974112836 Jus de pomme Granny Smith en bouteille verre 1...
c679c923-cf39-4e40-b072-7474928450c6 Purée de pomme de terre en sac 5 kg LUTOSA
ef8afbbb-efbc-4fdf-aa1c-6f664f2c1073 CÂPRE FINE AU VINAIGRE EN BOÎTE 4/4 VITALY'S
...
aff93d0f-a94c-4e9b-a6ca-d69115e3d2eb Thon Listao en morceaux au naturel en boîte 4/...
a01039be-eb79-454f-a384-c142d1d80d0c Tajine végétarienne en barquette 2,3 kg CHRIST
97c80844-08c7-45c6-82ac-43ab8a45f2e4 Spécialité pomme-fraise en gourde 90 g ANDROS

state \
uid
49428283-104a-4092-966f-07b974112836 product.validate
c679c923-cf39-4e40-b072-7474928450c6 product.validate
ef8afbbb-efbc-4fdf-aa1c-6f664f2c1073 product.validate
...
aff93d0f-a94c-4e9b-a6ca-d69115e3d2eb product.validate
a01039be-eb79-454f-a384-c142d1d80d0c product.validate
97c80844-08c7-45c6-82ac-43ab8a45f2e4 product.waiting.pomona.validation.niv3

ingredients \
uid
49428283-104a-4092-966f-07b974112836 100 % pur jus de Pommes Granny Smith.
c679c923-cf39-4e40-b072-7474928450c6 Pommes de terre déshydratées (99 %), émulsifia...
ef8afbbb-efbc-4fdf-aa1c-6f664f2c1073 Câpres, eau, vinaigre, sel
...
aff93d0f-a94c-4e9b-a6ca-d69115e3d2eb THON listao, eau, sel
a01039be-eb79-454f-a384-c142d1d80d0c Légumes 48,1% : pommes de terre 18,2%, carotte...
97c80844-08c7-45c6-82ac-43ab8a45f2e4 Ingrédients : Pommes 74%, fraises 20%, sucre, ...

type has_supplierdatasheet has_supplierlabel
uid
49428283-104a-4092-966f-07b974112836 nonAlcoholicDrink True False
c679c923-cf39-4e40-b072-7474928450c6 grocery True True
ef8afbbb-efbc-4fdf-aa1c-6f664f2c1073 grocery True False
...
aff93d0f-a94c-4e9b-a6ca-d69115e3d2eb grocery ...
a01039be-eb79-454f-a384-c142d1d80d0c grocery True True
97c80844-08c7-45c6-82ac-43ab8a45f2e4 grocery True True
```

[500 rows x 6 columns]

Remarque : malgré l'utilisation d'un `random_state` fixé, l'échantillon généré n'est pas toujours le même à chaque exécution. En effet, comme la liste de produits varie au fil du temps (nouveaux référencements, périmètre des filtres qui change), le résultat du `train_test_split` peut varier.

Il s'agit ici seulement d'illustrer la méthode utilisée.

1.3 Export des pièces jointes du PIM et constitution du fichier d'étiquettes

On exporte ensuite le contenu du PIM sur le disque, afin d'avoir les fiches techniques simplement à disposition.

```
[14]: requester.fetch_list_from_PIM(ground_truth_df.index, batch_size=20)
requester.dump_data_from_result(update_directory=False, root_path=os.path.join('.', 'ground_truth_to_del'))
requester.dump_files_from_result(update_directory=False, root_path=os.path.join('.', 'ground_truth_to_del'))
```

```
Done
Done
Launching 25 threads.
Thread complete!
```

```

Thread complete!
Done

```

On exporte également au format csv les uids des produits et les libellés associés (pour s'assurer qu'il n'y a pas eu de confusion lorsqu'on lit une fiche technique).

```
[15]: ground_truth_df['designation'].to_csv(os.path.join('..', 'ground_truth_to_del', 'uid.csv'),
                                         header=True,
                                         encoding='utf-8-sig')
```

On teste également la possibilité de recharger les données depuis le fichier csv, une fois qu'il a été renseigné à la main dans excel.

```
[20]: pd.read_csv(os.path.join('..', '..', 'ground_truth', 'manually_labelled_ground_truth.csv'),
                 sep=';',
                 encoding='latin-1',
                 index_col='uid')
```

```
[20]:          designation \
uid
a0492df6-9c76-4303-8813-65ec5ccbf70 Concentré liquide Asian en bouteille 980 ml CHEF
d183e914-db2f-4e2f-863a-a3b2d054c0b8 Pain burger curry 80 g CREATIV BURGER
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8 Macaroni en sachet 500 g PANZANI
...
e67341d8-350f-46f4-9154-4dbbb8035621 PRÉPARATION POUR CRÈME BRÛLÉE BIO 6L
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3 Céréales instantanées en poudre saveur caramel...
0faad739-ea8c-4f03-b62e-51ee592a0546 FARINE DE BLÉ TYPE 45, 10KG

          ingredients
uid
a0492df6-9c76-4303-8813-65ec5ccbf70 Eau, maltodextrine, sel, arômes, sucre, arôme ...
d183e914-db2f-4e2f-863a-a3b2d054c0b8 Farine de blé T65, eau, levure, vinaigre de ci...
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8 - 100% Semoule de BLE dur de qualité supérieur...
...
e67341d8-350f-46f4-9154-4dbbb8035621 Sucre roux de canne*° (64%), amidon de maïs*, ...
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3 Farine 87,1 % (Blé (GLUTEN), Blé hydrolysé (GL...
0faad739-ea8c-4f03-b62e-51ee592a0546 Farine de blé T45

[500 rows x 2 columns]
```

1.4 Résultat de l'étiquetage manuel

Le résultat de l'étiquetage manuel est le suivant :

```
[3]: df_gt = pd.read_csv(os.path.join('..', '..', 'ground_truth', 'manually_labelled_ground_truth.csv'),
                      sep=';',
                      encoding='latin-1',
                      index_col='uid')

def to_latex_newline(text):
```

```

    return(text.replace('\n', ' '))

with pd.option_context("max_colwidth", 1000):
    print(df_gt)
    df_gt.to_latex(Path('..') / 'tbls' / 'ground_truth.tex',
                    index=False,
                    index_names=False,
                    column_format='p{5cm}p{10cm}',
                    formatters=[to_latex_newline, to_latex_newline],
                    longtable=True,
                    na_rep='--',
                    escape=True,
                    )

```

designation

```

\

uid
a0492df6-9c76-4303-8813-65ec5ccbf70 Concentré liquide Asian en bouteille 980 ml CHEF
d183e914-db2f-4e2f-863a-a3b2d054c0b8 Pain burger curry 80 g CREATIV BURGER
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8 Macaroni en sachet 500 g PANZANI
...
e67341d8-350f-46f4-9154-4dbbb8035621 PRÉPARATION POUR CRÈME BRÛLÉE BIO 6L
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3 Céréales instantanées en poudre saveur caramel en boîte 400 g BLEDDINA
0faad739-ea8c-4f03-b62e-51ee592a0546 FARINE DE BLÉ TYPE 45, 10KG

ingredients
uid
a0492df6-9c76-4303-8813-65ec5ccbf70 Eau, maltodextrine, sel, arômes, sucre, arôme naturel de citronnelle, amidon modifié, ail en poudre, épices (combava, curcuma), extraits d'épices (gingembre, poivre), stabilisant (gomme xanthane).
d183e914-db2f-4e2f-863a-a3b2d054c0b8 Farine de blé T65, eau, levure, vinaigre de cidre, huile de colza, assaisonnement poudre de curry, sel, acide ascorbique, émulsifiant : E471.
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8
- 100% Semoule de BLE dur de qualité supérieure\n- Contient du gluten\nSi le numéro de lot contient la lettre N : peu contenir de l'oeuf
...
e67341d8-350f-46f4-9154-4dbbb8035621 Sucre roux de canne* (64%), amidon de maïs*, poudre de LAIT écrémé*, poudre d'OEUFFS entiers*, gélifiants : carraghénanes, agar-agar* ; arôme naturel de vanille* et autres arômes naturels*, poudre de goussettes de vanille*, curcuma*. \n* Produits issus de l'Agriculture Biologique.\n* Ingrédient issu du commerce équitable. 65.1% des ingrédients d'origine agricole sont issus du commerce équitable (Sucre : Paraguay).
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3 Farine 87,1 % (Blé (GLUTEN), Blé hydrolysé (GLUTEN)) - Sucre - Caramel 5,00 % - Arôme - Vitamines (C, B1) - Diphosphate ferrique
0faad739-ea8c-4f03-b62e-51ee592a0546 Farine de blé T45

[500 rows x 2 columns]

```

1.5 Comparatif entre les données étiquetées et le contenu du PIM

On peut comparer le contenu des listes d'ingrédients du PIM et les données étiquetées.

```
[5]: requester = Requester('prd')
requester.fetch_all_from_PIM()
requester.result
```

Done

On récupère le contenu du PIM

```
[7]: df = requester.result_to_dataframe()
pim_ds = df['properties.pprodct:ingredientsList']
```

[7]:

```

entity-type repository \
uid
afee12c7-177e-4a68-9539-8cbb68442503 document default
7d390121-17e8-43bf-a357-9d06b79d2d47 document default
f234cd84-c8f6-433f-85ec-6e0b6980adc6 document default
... ...
ef42a938-2203-446e-8d28-9fd27c6d3146 document default
68f5d81b-7f91-40a0-8504-0ec320a86de4 document default
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a document default

path type \
uid
afee12c7-177e-4a68-9539-8cbb68442503 /default-domain/pomSupplierWorkspace/SICO/DEST... pomProduct
7d390121-17e8-43bf-a357-9d06b79d2d47 /default-domain/pomSupplierWorkspace/UNILEVER... pomProduct
f234cd84-c8f6-433f-85ec-6e0b6980adc6 /default-domain/pomSupplierWorkspace/AZTECA_FO... pomProduct
... ...
ef42a938-2203-446e-8d28-9fd27c6d3146 /default-domain/pomSupplierWorkspace/SICO/DETE... pomProduct
68f5d81b-7f91-40a0-8504-0ec320a86de4 /default-domain/pomSupplierWorkspace/SICO/NETT... pomProduct
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a /default-domain/pomSupplierWorkspace/SICO/SPRA... pomProduct

state \
uid
afee12c7-177e-4a68-9539-8cbb68442503 product.waiting.supplier.validation
7d390121-17e8-43bf-a357-9d06b79d2d47 product.waiting.supplier.validation
f234cd84-c8f6-433f-85ec-6e0b6980adc6 product.waiting.supplier.validation
... ...
ef42a938-2203-446e-8d28-9fd27c6d3146 product.waiting.supplier.validation
68f5d81b-7f91-40a0-8504-0ec320a86de4 product.waiting.supplier.validation
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a product.waiting.supplier.validation

parentRef isCheckedOut isVersion \
uid
afee12c7-177e-4a68-9539-8cbb68442503 a58845c0-cab3-492f-b48d-531f146c3777 True False
7d390121-17e8-43bf-a357-9d06b79d2d47 a37abc27-f485-4ae9-921b-f761f16c8c1c False False
f234cd84-c8f6-433f-85ec-6e0b6980adc6 3ff7819a-a392-493f-beb8-0b323ac331c7 True False
... ...
ef42a938-2203-446e-8d28-9fd27c6d3146 a58845c0-cab3-492f-b48d-531f146c3777 ... ...
68f5d81b-7f91-40a0-8504-0ec320a86de4 a58845c0-cab3-492f-b48d-531f146c3777 True False
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a a58845c0-cab3-492f-b48d-531f146c3777 True False

isProxy changeToken ... \
uid
afee12c7-177e-4a68-9539-8cbb68442503 False 17-0 ...
7d390121-17e8-43bf-a357-9d06b79d2d47 False 15-0 ...
f234cd84-c8f6-433f-85ec-6e0b6980adc6 False 33-0 ...
... ...
ef42a938-2203-446e-8d28-9fd27c6d3146 False ... ...
68f5d81b-7f91-40a0-8504-0ec320a86de4 False 17-0 ...
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a False 17-0 ...

properties.pprodqmdd:manufacturingDiagram.length \
uid
afee12c7-177e-4a68-9539-8cbb68442503 NaN
7d390121-17e8-43bf-a357-9d06b79d2d47 NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6 NaN
... ...
ef42a938-2203-446e-8d28-9fd27c6d3146 NaN
68f5d81b-7f91-40a0-8504-0ec320a86de4 NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a NaN

properties.pprodqmdd:manufacturingDiagram.data \
uid
afee12c7-177e-4a68-9539-8cbb68442503 NaN
7d390121-17e8-43bf-a357-9d06b79d2d47 NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6 NaN
... ...
ef42a938-2203-446e-8d28-9fd27c6d3146 NaN

```

properties.pprodqmdd:secondaryPackagingPhoto.name	
68f5d81b-7f91-40a0-8504-0ec320a86de4	NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a	NaN
uid	
afee12c7-177e-4a68-9539-8cbb68442503	NaN
7d390121-17e8-43bf-a357-9d06b79d2d47	NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6	NaN
...	...
ef42a938-2203-446e-8d28-9fd27c6d3146	NaN
68f5d81b-7f91-40a0-8504-0ec320a86de4	NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a	NaN
properties.pprodqmdd:secondaryPackagingPhoto.mime-type	\
uid	
afee12c7-177e-4a68-9539-8cbb68442503	NaN
7d390121-17e8-43bf-a357-9d06b79d2d47	NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6	NaN
...	...
ef42a938-2203-446e-8d28-9fd27c6d3146	NaN
68f5d81b-7f91-40a0-8504-0ec320a86de4	NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a	NaN
properties.pprodqmdd:secondaryPackagingPhoto.encoding	\
uid	
afee12c7-177e-4a68-9539-8cbb68442503	NaN
7d390121-17e8-43bf-a357-9d06b79d2d47	NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6	NaN
...	...
ef42a938-2203-446e-8d28-9fd27c6d3146	NaN
68f5d81b-7f91-40a0-8504-0ec320a86de4	NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a	NaN
properties.pprodqmdd:secondaryPackagingPhoto.digestAlgorithm	\
uid	
afee12c7-177e-4a68-9539-8cbb68442503	NaN
7d390121-17e8-43bf-a357-9d06b79d2d47	NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6	NaN
...	...
ef42a938-2203-446e-8d28-9fd27c6d3146	NaN
68f5d81b-7f91-40a0-8504-0ec320a86de4	NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a	NaN
properties.pprodqmdd:secondaryPackagingPhoto.digest	\
uid	
afee12c7-177e-4a68-9539-8cbb68442503	NaN
7d390121-17e8-43bf-a357-9d06b79d2d47	NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6	NaN
...	...
ef42a938-2203-446e-8d28-9fd27c6d3146	NaN
68f5d81b-7f91-40a0-8504-0ec320a86de4	NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a	NaN
properties.pprodqmdd:secondaryPackagingPhoto.length	\
uid	
afee12c7-177e-4a68-9539-8cbb68442503	NaN
7d390121-17e8-43bf-a357-9d06b79d2d47	NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6	NaN
...	...
ef42a938-2203-446e-8d28-9fd27c6d3146	NaN
68f5d81b-7f91-40a0-8504-0ec320a86de4	NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a	NaN
properties.pprodqmdd:secondaryPackagingPhoto.data	\
uid	
afee12c7-177e-4a68-9539-8cbb68442503	NaN
7d390121-17e8-43bf-a357-9d06b79d2d47	NaN

```

f234cd84-c8f6-433f-85ec-6e0b6980adc6           NaN
...
ef42a938-2203-446e-8d28-9fd27c6d3146           ...
68f5d81b-7f91-40a0-8504-0ec320a86de4           NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a           NaN

properties.notif:notifications

uid
afee12c7-177e-4a68-9539-8ccb68442503           NaN
7d390121-17e8-43bf-a357-9d06b79d2d47           NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6           NaN
...
ef42a938-2203-446e-8d28-9fd27c6d3146           ...
68f5d81b-7f91-40a0-8504-0ec320a86de4           NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a           NaN

[13212 rows x 487 columns]

```

On charge le csv des données étiquetées :

```
[61]: df_gt = pd.read_csv(os.path.join('..', '..', 'ground_truth', 'manually_labelled_ground_truth.csv'),
                        sep=';',
                        encoding='latin-1',
                        index_col='uid')
df_gt
```

	designation \
uid	
a0492df6-9c76-4303-8813-65ec5ccbfa70	Concentré liquide Asian en bouteille 980 ml CHEF
d183e914-db2f-4e2f-863a-a3b2d054c0b8	Pain burger curry 80 g CREATIV BURGER
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8	Macaroni en sachet 500 g PANZANI
...	...
e67341d8-350f-46f4-9154-4dbbb8035621	PRÉPARATION POUR CRÈME BRÛLÉE BIO 6L
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3	Céréales instantanées en poudre saveur caramel...
0faad739-ea8c-4f03-b62e-51ee592a0546	FARINE DE BLÉ TYPE 45, 10KG
	ingredients
uid	
a0492df6-9c76-4303-8813-65ec5ccbfa70	Eau, maltodextrine, sel, arômes, sucre, arôme ...
d183e914-db2f-4e2f-863a-a3b2d054c0b8	Farine de blé T65, eau, levure, vinaigre de ci...
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8	- 100% Semoule de BLE dur de qualité supérieur...
...	...
e67341d8-350f-46f4-9154-4dbbb8035621	Sucre roux de canne*° (64%), amidon de maïs*, ...
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3	Farine 87,1 % (Blé (GLUTEN), Blé hydrolysé (GL...
0faad739-ea8c-4f03-b62e-51ee592a0546	Farine de blé T45

[500 rows x 2 columns]

Comme l'index de la series des données issues du PIM, et du dataframe de la ground truth est le même (l'uid du produit), on peut faire très simplement la jointure via la méthode join :

```
[62]: merged = (df_gt.join(pim_ds)
              .rename({'ingredients': 'Ingrédients de la ground truth',
                      'properties.pprod:ingredientsList': 'Ingrédients du PIM'},
                     axis=1)
              )
merged
```

	designation \
uid	
a0492df6-9c76-4303-8813-65ec5ccbfa70	Concentré liquide Asian en bouteille 980 ml CHEF
d183e914-db2f-4e2f-863a-a3b2d054c0b8	Pain burger curry 80 g CREATIV BURGER
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8	Macaroni en sachet 500 g PANZANI
...	...
e67341d8-350f-46f4-9154-4dbbb8035621	PRÉPARATION POUR CRÈME BRÛLÉE BIO 6L
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3	Céréales instantanées en poudre saveur caramel...

```
0faad739-ea8c-4f03-b62e-51ee592a0546
```

```
FARINE DE BLÉ TYPE 45, 10KG
```

```
Ingrédients de la ground truth \n
uid
a0492df6-9c76-4303-8813-65ec5ccbfa70 Eau, maltodextrine, sel, arômes, sucre, arôme ...
d183e914-db2f-4e2f-863a-a3b2d054c0b8 Farine de blé T65, eau, levure, vinaigre de ci...
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8 - 100% Semoule de BLE dur de qualité supérieure...
...
e67341d8-350f-46f4-9154-4dbbb8035621 Sucre roux de canne*° (64%), amidon de maïs*, ...
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3 Farine 87,1 % (Blé (GLUTEN), Blé hydrolysé (GL...
0faad739-ea8c-4f03-b62e-51ee592a0546 Farine de blé T45

Ingrédients du PIM
uid
a0492df6-9c76-4303-8813-65ec5ccbfa70 Eau, maltodextrine, sel, arômes, sucre, arôme ...
d183e914-db2f-4e2f-863a-a3b2d054c0b8 Farine de BLE T65, eau, levure, huile de colz...
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8 100% Semoule de BLE dur de qualité supérieure...
...
e67341d8-350f-46f4-9154-4dbbb8035621 Sucre roux de canne*°(64%), amidon de maïs*, p...
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3 Farine 87,1 % (BLE (GLUTEN), BLE hydrolysé (GL...
0faad739-ea8c-4f03-b62e-51ee592a0546 farine de BLE T45
```

```
[500 rows x 3 columns]
```

On peut compter les égalités strictes entre les ingrédients du PIM et ceux de la ground truth :

```
[63]: merged['equals'] = (merged['Ingrédients du PIM'] == merged['Ingrédients de la ground truth'])
merged['equals'].value_counts()
```

```
[63]: False    450
      True     50
      Name: equals, dtype: int64
```

Seules 50 listes d'ingrédients sont strictement identiques. Si on compare les listes qui ne le sont pas, on obtient :

```
[64]: diff = merged.loc[~merged['equals'], ['Ingrédients du PIM', 'Ingrédients de la ground truth']]
for i in range(20):
    print('+'*50)
    print('Issu du PIM :')
    print(diff.iloc[i].loc['Ingrédients du PIM'])
    print('-----')
    print('Issu de la ground truth :')
    print(diff.iloc[i].loc['Ingrédients de la ground truth'])
    print('+'*50)

+++++
Issu du PIM :
Farine de BLE T65, eau, levure, huile de colza, sel, vinaigre de cidre, assaisonnement poudre de curry, agent de traitement de la farine : acide ascorbique, émulsifiant : E471
-----
Issu de la ground truth :
Farine de blé T65, eau, levure, vinaigre de cidre, huile de colza, assaisonnement poudre de curry, sel, acide ascorbique, émulsifiant : E471.
+++++
+++++
Issu du PIM :
100% Semoule de BLE dur de qualité supérieure
-----
Issu de la ground truth :
- 100% Semoule de BLE dur de qualité supérieure
- Contient du gluten
Si le numéro de lot contient la lettre N : peu contenir de l'oeuf
+++++
+++++
Issu du PIM :
```

Fève de tonka, taux de coumarine compris entre 1 et 3,5%

Issu de la ground truth :

fève de tonka (graines ridées de 25 à 50mm de long)
Taux de coumarine compris entre 1 et 3,5 %
+++++

+++++

Issu du PIM :

Aubergine 60,5% (aubergine, huile de tournesol), eau, oignon, huile de tournesol, jus de citron, concentré de tomate, huile d'olive vierge extra 2%, ail, sel, persil, basilic, poivre, thym, romarin.

Issu de la ground truth :

Aubergine 60,5% (aubergine, huile de tournesol), eau, oignon, huile de tournesol, jus de citron, concentré de tomate, huile d'olive vierge extra (2%), ail, sel, persil, basilic, poivre, thym, romarin.
+++++

+++++

Issu du PIM :

Ingédients : Myrtille Cassis : Fruits (myrtilles 41%, cassis 9%), sucre, sucre roux de canne, jus de citrons concentré, gélifiant : pectines de fruits. Fraise Groseille : Fruits (fraises 27 %, groseilles 23 %), sucre, sucre roux de canne, jus de citrons concentré, gélifiant : pectines de fruits. Abricot Pêche : Fruits (abricots 34%, pêches 16%), sucre, sucre roux de canne, jus de citrons concentré, gélifiant : pectines de fruits. Orange Douce Mandarine : Fruits (oranges douces 37%, mandarines 3%), sucre, sucre roux de canne, jus de citrons concentré, gélifiant : pectines de fruits.

Issu de la ground truth :

Confiture de myrtilles et de cassis
fruits (myrtilles 41%, cassis 9%), sucre, sucre roux de canne, jus de citrons concentré, gélifiant : pectine de fruits.

Confiture de fraises et de groseilles

fruits (fraises 27 %, groseilles 23 %), sucre, sucre roux de canne, jus de citrons concentré, gélifiant : pectine de fruits.

Confiture d'abricots et de pêches

fruits (abricots 34%, pêches 16%), sucre, sucre roux de canne, jus de citrons concentré, gélifiant : pectine de fruits.

Marmelade d'oranges douces et de mandarines

fruits (oranges douces 37%, mandarines 3%), sucre, sucre roux de canne, jus de citrons concentré, gélifiant : pectine de fruits.

+++++

+++++

Issu du PIM :

Pommes 95%, sirop de glucose-fructose, arôme, antioxydant : acide ascorbique

Issu de la ground truth :

Pommes 95%, sirop de glucose-fructose, arôme, antioxydant: acide ascorbique.

+++++

+++++

Issu du PIM :

Riz, sucre, cacao maigre en poudre, Maltodextrine, pâte de cacao, sel, arôme de malt d'ORGE, arôme, arôme naturel. Vitamines et Minéraux : carbonate de calcium, vitamines (niacine, B6, B2, B1, acide folique, D, B12), fer.

Issu de la ground truth :

Riz, Sucre, Cacao maigre en poudre, Maltodextrine, Pâte de cacao, Sel, Arôme de malt d'orge, Arôme, Arôme naturel.

+++++

+++++

Issu du PIM :

jus d'orange issu de l'agriculture biologique

Issu de la ground truth :

jus d'orange issu de l'agriculture biologique.

+++++

++++++
Issu du PIM :
Persil.

Issu de la ground truth :
Persil
++++++

++++++
Issu du PIM :
Pommes de terre, huile de tournesol 35%, assaisonnement poulet (maltodextrine, farine de BLE, dextrose, extrait de levure, arôme, sel, oignon déshydraté, viande et graisse de poulet, ail, colorant : extrait de paprika E160c, Antioxydant : extrait de romarin E392), sel,

Issu de la ground truth :
Pommes de terre, huile de tournesol (35%), assaisonnement poulet (maltodextrine, farine de blé, dextrose, extrait de levure, arôme, sel, oignon déshydraté, viande et graisse de poulet, ail, colorant : extrait de paprika E160c, Antioxydant : extrait de romarin E392), sel
Traces éventuelles de moutarde et lait
++++++

++++++
Issu du PIM :
Sucre, huiles végétales (Colza), NOISETTES (13%), poudre de cacao maigre (7%), LAIT écrémé en poudre , LACTOSERUM en poudre, lactose. Emulsifiant lécithine de tournesol. Arôme : vanilline

Issu de la ground truth :
Sucre, huiles végétales (Colza), noisettes (13%), poudre de cacao maigre (7%), lait écrémé en poudre , lactosérum en poudre, lactose. Emulsifiant lécithine de tournesol. Arôme : vanilline
Allergènes : Le produit peut contenir traces éventuelles de soja arachide et autre fruits à coque.
++++++

++++++
Issu du PIM :
Huile d'olive vierge extra 99.5%, Arôme

Issu de la ground truth :
Huile d'olive vierge extra 99,5%, Arôme
++++++

++++++
Issu du PIM :
Huile de colza, extrait naturel de piment de Cayenne.

Issu de la ground truth :
Huile de colza, extrait naturel de piment de Cayenne
++++++

++++++
Issu du PIM :
Piment rouge fort équeuté* (85%), cumin, ail moulu (3%), eau, arôme naturel d'ail, sel, sorbate de potassium. (* présence de sulfites)

Issu de la ground truth :
Piment rouge fort équeuté* (85%), cumin, ail moulu (3%), eau, arôme naturel d'ail, sel, sorbate de potassium. (* présence de sulfites)
++++++

++++++
Issu du PIM :
Sucre de canne, eau, sirop de fructose-glucose, arômes, colorant : caramel ordinaire, arôme naturel de vanille.

Issu de la ground truth :
SUCRE DE CANNE, EAU, AROME, COLORANT : E 150a, AROME NATUREL DE VANILLE.
++++++

Issu du PIM :
Baie des Batak 100%

Issu de la ground truth :
Baie des Batak
+++++

Issu du PIM :
FILETS DE MAQUEREAUX 61%, eau, concentré de tomate 15%, huile de tournesol, vinaigre d'alcool, vinaigre de vin blanc, sel, vin blanc, épaississant : gomme xanthane, arômes.

Issu de la ground truth :
Filets de maquereaux (61 %), eau, concentré de tomate (15%), huile de tournesol, vinaigre d'alcool, vinaigre de vin blanc, sel, vin blanc, épaississant : gomme xanthane, arômes.
+++++

Issu du PIM :
Mélange de blés de pays

Issu de la ground truth :
Mélange de Blés de pays recommandés par la meunerie .
+++++

Issu du PIM :
LAIT entier 88%, sucre, poudre de chocolat 3,1% (sucre, poudre de cacao), amidon modifié de manioc, chocolat au LAIT 0,57% (sucre, pâte de cacao, poudre de LAIT entier, beurre de cacao, poudre de LAIT écrémé), arôme naturel, épaississants : gomme gellane et gomme guar, correcteur d'acidité : citrate de sodium, concentré de minéraux du LAIT, vitamine D3.

Issu de la ground truth :
Lait entier (88%) ; sucre ; poudre de chocolat (3.1%) (sucre, poudre de cacao) ; amidon modifié de manioc ; chocolat au lait (0,57%) (sucre, pâte de cacao, poudre de lait entier, beurre de cacao, poudre de lait écrémé) ; arôme naturel ; épaississants : gomme gellane, gomme guar ; correcteur d'acidité : citrate tri-sodique ; concentré de minéraux du lait ; vitamine D3.
+++++

Issu du PIM :
Ingrédients : Sirop de glucose-fructose, farine de BLÉ , sucre, purée d'orange 5,4 %, jus d'orange concentré 1,5 % (équivalent jus d'orange 8 %), huile de colza, jaunes d' OEUFS en poudre, stabilisant (glycérol), poudre à lever (carbonate acide d'ammonium), gélifiant (pectines), acidifiant (acide citrique), arômes, colorant (rocou), conservateur (sorbate de potassium). PEUT CONTENIR LAIT, FRUITS À COQUE, SÉSAME.

Issu de la ground truth :
Sirop de glucose-fructose, farine de BLÉ , sucre, purée d'orange 5,4 %, jus d'orange concentré 1,5 % (équivalent jus d'orange 8 %), huile de colza, jaunes d' OEUFS en poudre, stabilisant (glycérol), poudre à lever (carbonate acide d'ammonium), gélifiant (pectines), acidifiant (acide citrique), arômes, colorant (rocou), conservateur (sorbate de potassium). PEUT CONTENIR LAIT, FRUITS À COQUE, SÉSAME.
+++++

On peut sortir un tableau des données en écart, de manière basique :

```
[97]: with pd.option_context("max_colwidth", 100000):
    tex_str = (
        diff.sample(10, random_state=44)
        .to_latex(index=False,
                  index_names=False,
                  column_format='p{7cm}p{7cm}',
                  na_rep='-', )
        .replace(r'\textbackslash n', '\\newline ')
    )
    print(tex_str)
```

```
with open(Path('..') / 'tbls' / 'ingredient_comparison.tex', 'w') as file:
    file.write(tex_str)
```

\begin{tabular}{p{7cm}p{7cm}}

\toprule

 Ingrédients du PIM &

 Ingrédients de la ground truth \\

 \midrule

 Céréales (farine de FROMENT (27,5\%), céréales complètes (15,1\%) (farine complète de FROMENT (15\%), farine complète de SEIGLE, farine complète d'ORGE) sucre graisses végétales (palme, palmiste, colza) poudre de cacao maigre (5,1\%) amidon de BLE LAIT écrémé en poudre (équivalent lait 16\%) amidon de pomme de terre poudres à lever (carbonates de sodium et d'ammonium, diphosphates) LACTOSE et protéines de LAIT sel arôme émulsifiant : lécithine de tournesol agent de traitement de la farine : E223 (SULFITES). &

 Céréales [farine de froment (27.5\%), céréales complètes (15.1\%) (farine complète de froment (15 \%), farine complète de seigle , farine complète d'orge)] sucre graisses végétales (palme, palmiste, colza) poudre de cacao maigre (5.1\%) amidon de blé lait écrémé en poudre (équivalent lait 16\%) amidon de pomme de terre poudres à lever (carbonates de sodium et d'ammonium, diphosphates) lactose et protéines de lait sel arôme émulsifiant : lécithine de tournesol agent de traitement de la farine : E223 (sulfites)\newline Peut contenir des traces de fruits à coque, de soja, d'oeuf et de sésame \\

 cheddar fondu(44\%) (eau, LACTOSERUM, cheddar(5\%) (LAIT, ferment, acidifiant (sulfates de sodium (\newline E514)), enzymes), LAIT écrémé, maltodextrine, antioxydant (phosphate de sodium (E339)), CREME, épaississants (\newline octényle succinate d'amidon sodique (E1450), gomme xanthane (E415)), acidifiant (sulfates de sodium (E514))), eau,\newline huile de palme, épaississants (amidon modifié de tapioca, amidon modifié de maïs), maltodextrine, acidifiants (sulfates de\nline sodium (E514), citrate de sodium (E331), acide phosphorique (E338), acide lactique (E270)), arôme, antioxydant (\newline phosphate de sodium (E339)), colorants (bête carotène (E160a), annatto (E160b), extrait de paprika (E160c)), émulsifiant\nline (stéaroyl-2-lactylate de sodium (E481), mono et diglycérides d'acides gras alimentaires (E471)) & cheddar fondu (44\%) (eau, lactosérum, cheddar (5\%) (lait, ferment, acidifiant (sulfates de sodium (E514)), enzymes), lait écrémé, maltodextrine, antioxydant (phosphate de sodium (E339)), crème, épaississants (octényle succinate d'amidon sodique (E1450), gomme xanthane (E415)), acidifiant (sulfates de sodium (E514))), eau, huile de palme, épaississants (amidon modifié de tapioca, amidon modifié de maïs), maltodextrine, acidifiants (sulfates de sodium (E514), citrate de sodium (E331), acide phosphorique (E338), acide lactique (E270)), arôme, antioxydant (phosphate de sodium (E339)), colorants (bête carotène (E160a), annatto (E160b), extrait de paprika (E160c)), émulsifiants (stéaroyl-2-lactylate de sodium (E481), mono et diglycérides d'acides gras alimentaires (E471)) \\

 Pommes* (80\%), framboises* (20\%) &

 pommes* (80\%), framboises* (20\%)\newline *Ingrédient issu de l'agriculture biologique \\

 Eau, graines de MOUTARDE, vinaigre d'alcool, sel, vin blanc (contient SULFITES), sucre, épices, acidifiant (acide citrique), conservateur (DISULFITE de potassium) &

 Eau, graines de moutarde, vinaigre d'alcool, sel, vin blanc (contient sulfites), sucre, épices, acidifiant (acide citrique), conservateur (disulfite de potassium) \\

 Pâte à tartiner aux NOISETTES et au cacao 81,5 \% (sucre, huile de palme, NOISETTES 13\%, LAIT écrémé en poudre 8,7\%, cacao maigre 7,4\%, émulsifiants : lécithines [SOJA] , vanilline), farine de FROMENT 16\%, levure de bière, extrait de malt d'ORGE, sel, LAIT écrémé en poudre, émulsifiants : lécithines [SOJA] , protéines de FROMENT, protéines de LAIT, eau. &

 pâte à tartiner aux noisettes et au cacao 81,5 \% (sucre, huile de palme, noisettes 13\%, lait écrémé en poudre 8,7\%, cacao maigre 7,4\%, émulsifiants : lécithines [soja] ; vanilline), farine de froment 16\%, levure de bière, extrait de malt d'orge, sel, lait écrémé en poudre, émulsifiants : lécithines [soja] ; protéines de froment, protéines de lait, eau.\newline Le chocolat utilisé est un chocolat pur beurre de cacao. \\

 Sirop de glucose, sucre, amidons transformés, acidifiants: acide citrique, acide malique, correcteurs d'acidité: citrate tricalcique, malate acide de sodium, agent d'enrobage: cire de carnauba, arôme, concentrés de fruits et de plantes: carthame, citron, colorants: carmins, bleu patenté V, lutéine, sirop de sucre inverti. &

 sirop de glucose; sucre; amidons transformés; acidifiants: acide citrique, acide malique; correcteurs d'acidité: citrate tricalcique, malate acide de sodium; agent d'enrobage: cire de carnauba; arôme; concentrés de fruits et de plantes: carthame, citron; colorants: carmins, bleu patenté V, lutéine; sirop de sucre inverti. \\

 Huile de colza, jaunes d'OEUVFS, purée de tomates, eau, vinaigre, câpres (2.8 \%) (câpres, eau, sel), cornichons (2.8 \%) (cornichons, vinaigre, sel), sucre, sel, amidon modifié, acidifiant : glucono-delta-lactone, conservateur : sorbate de potassium, antioxydant : E385, épice, arôme naturel aneth. &

 Huile de colza (70.45 \%), jaunes d'oeufs (6.2 \%), purée de tomates, eau, vinaigre, câpres (2.8 \%) (câpres, eau, sel), cornichons (2.8 \%) (cornichons, vinaigre, sel), sucre, sel, amidon modifié, acidifiant

```

: glucono-delta-lactone, conservateur : sorbate de potassium, antioxydant : E385 (74 mg/kg), épice, arôme
naturel aneth. \\

Lentilles, eau,
sel, arôme naturel (CELERI) &
Lentilles, eau, sel, arôme naturel (céleri) \\

Ingrédients: Sucre, pâte de cacao, NOISETTES (23%), beurre de cacao, BEURRE concentré, émulsifiant
(lécithine de SOJA), arôme, LAIT écrémé en poudre. Cacao: 46% minimum dans le chocolat noir. PEUT CONTENIR
AUTRES FRUITS À COQUE.\textbackslash t\textbackslash t\textbackslash t\newline &
Sucre, pâte de cacao, NOISETTES (23%), beurre de cacao, BEURRE concentré, émulsifiant (lécithine de SOJA),
arôme, LAIT écrémé en poudre. Cacao: 46% minimum dans le chocolat noir. PEUT CONTENIR AUTRES FRUITS À
COQUE. \\

Huile de
colza, eau, vinaigre d'alcool, jaunes d'OEUFFS, sucre, estragon (2,5%), échalote (2,4%), sel, cerfeuil, jus
de citron à base de concentré, piment de Cayenne, arômes, amidon modifié, colorant : bêta-carotène,
conservateur : sorbate de potassium. &
Huile de colza, eau, vinaigre d'alcool, jaunes d'oeufs, sucre, estragon (2,5%), échalote (2,4%), sel,
cerfeuil, jus de citron à base de concentré, piment de Cayenne, arômes, amidon modifié, colorant : bêta-
carotène, conservateur : sorbate de potassium.Ce produit peut contenir des traces de moutarde. \\

\bottomrule
\end{tabular}

```

1.6 Analyse du contenu des pièces jointes téléchargées

On peut faire une estimation des pièces jointes dont les textes sont extractibles. On commence simplement par lister les pièces jointes relatives à la ground truth qui ont été téléchargées.

```

[5]: p = Path('..') / 'ground_truth_to_del'
list(p.glob('**/*.pdf'))

[5]: [PosixPath('ground_truth_to_del/1bca5540-b129-4593-a1e9-fa909234ad39/FTF.pdf'),
PosixPath('ground_truth_to_del/1bca5540-b129-4593-a1e9-fa909234ad39/Etiquette.pdf'),
PosixPath('ground_truth_to_del/0111c5f2-f00b-4fba-a266-716b3909f4b5/FTF.pdf'),
PosixPath('ground_truth_to_del/026ab402-d218-432d-98f8-05641dadcc48e/FTF.pdf'),
PosixPath('ground_truth_to_del/00debff6c-51b4-4aa5-a6f6-9ce853e4f411/FTF.pdf'),
PosixPath('ground_truth_to_del/00debff6c-51b4-4aa5-a6f6-9ce853e4f411/Etiquette.pdf'),
PosixPath('ground_truth_to_del/1929e781-ca8a-4942-9f68-a7cc639f182c/FTF.pdf'),
PosixPath('ground_truth_to_del/0c6e3b79-1260-4ff9-ad9b-3d44cf3b93ca/FTF.pdf'),
PosixPath('ground_truth_to_del/05fa67dc-01e6-4f13-9aea-87801a96ce3c/FTF.pdf'),
PosixPath('ground_truth_to_del/05fa67dc-01e6-4f13-9aea-87801a96ce3c/Etiquette.pdf'),
PosixPath('ground_truth_to_del/1c9701d0-24fd-4563-b4aa-5a9b91a6f4d5/FTF.pdf'),
PosixPath('ground_truth_to_del/1c9701d0-24fd-4563-b4aa-5a9b91a6f4d5/Etiquette.pdf'),
PosixPath('ground_truth_to_del/22dd5f03-d569-471e-ad93-d41d155dd83d/FTF.pdf'),
PosixPath('ground_truth_to_del/22dd5f03-d569-471e-ad93-d41d155dd83d/Etiquette.pdf'),
PosixPath('ground_truth_to_del/02569dca-2c03-477d-88c4-18be0656501a/FTF.pdf'),
PosixPath('ground_truth_to_del/0c011c3b-c853-4772-8a8d-d3cbf0f687cb/FTF.pdf'),
PosixPath('ground_truth_to_del/0c011c3b-c853-4772-8a8d-d3cbf0f687cb/Etiquette.pdf'),
PosixPath('ground_truth_to_del/48287b28-86f1-4b48-a245-2e32a071a80f/FTF.pdf'),
PosixPath('ground_truth_to_del/48287b28-86f1-4b48-a245-2e32a071a80f/Etiquette.pdf'),
PosixPath('ground_truth_to_del/0a062092-0ecc-47ad-91e0-6f1264945b9d/FTF.pdf'),
PosixPath('ground_truth_to_del/0a062092-0ecc-47ad-91e0-6f1264945b9d/Etiquette.pdf'),
PosixPath('ground_truth_to_del/100c3211-9dc2-48e9-a2d6-0a7384b8ab52/FTF.pdf'),
PosixPath('ground_truth_to_del/2e1cc245-640a-4606-9a5f-b10946b713f3/FTF.pdf'),
PosixPath('ground_truth_to_del/244e14b8-8291-4315-8ca8-53fa85cf23f6/FTF.pdf'),
PosixPath('ground_truth_to_del/04c269e6-4945-464e-b96c-25c2db7fd4f6/FTF.pdf'),
PosixPath('ground_truth_to_del/04c269e6-4945-464e-b96c-25c2db7fd4f6/Etiquette.pdf'),
PosixPath('ground_truth_to_del/00a73829-0c98-4cc3-8def-3fa23db75d61/FTF.pdf'),
PosixPath('ground_truth_to_del/0a063984-09db-4a1e-9cf7-5e24e7344f88/FTF.pdf'),
PosixPath('ground_truth_to_del/0a063984-09db-4a1e-9cf7-5e24e7344f88/Etiquette.pdf'),
PosixPath('ground_truth_to_del/1322376b-b265-43b4-aabb-8db866e95c59/FTF.pdf'),
PosixPath('ground_truth_to_del/0b032b82-46e0-42e2-95ea-e23eab4eba86/FTF.pdf'),
PosixPath('ground_truth_to_del/0b032b82-46e0-42e2-95ea-e23eab4eba86/Etiquette.pdf'),
PosixPath('ground_truth_to_del/0a8990fd-e183-4090-873c-9938213a7304/FTF.pdf'),
PosixPath('ground_truth_to_del/0a8990fd-e183-4090-873c-9938213a7304/Etiquette.pdf'),
PosixPath('ground_truth_to_del/22cad046-2fc8-4fa3-a107-931940eeaa68/FTF.pdf'),
PosixPath('ground_truth_to_del/22cad046-2fc8-4fa3-a107-931940eeaa68/Etiquette.pdf'),
PosixPath('ground_truth_to_del/0be5ad15-7d67-450c-86ff-7c01cbab6473/FTF.pdf'),

```

```

PosixPath('ground_truth_to_del/0be5ad15-7d67-450c-86ff-7c01cbab6473/Etiquette.pdf'),
PosixPath('ground_truth_to_del/4ebddd6c-9133-4775-bffd-4663605ecfbf/FTF.pdf'),
PosixPath('ground_truth_to_del/4ebddd6c-9133-4775-bffd-4663605ecfbf/Etiquette.pdf'),
PosixPath('ground_truth_to_del/02a69b7d-6e93-455a-b96a-ebfdf855c6d9/FTF.pdf'),
PosixPath('ground_truth_to_del/45ae52df-63de-4ce6-8fa0-4906c2803cbf/FTF.pdf'),
PosixPath('ground_truth_to_del/02b82a6e-a117-4f2d-9cc2-eea3da1197ad/FTF.pdf'),
PosixPath('ground_truth_to_del/02b82a6e-a117-4f2d-9cc2-eea3da1197ad/Etiquette.pdf'),
PosixPath('ground_truth_to_del/149bccae-7e12-456d-9ad0-f1457413b43e/FTF.pdf'),
PosixPath('ground_truth_to_del/149bccae-7e12-456d-9ad0-f1457413b43e/Etiquette.pdf'),
PosixPath('ground_truth_to_del/125e2f84-cbd9-4791-9921-b3d4ca5b11a4/FTF.pdf'),
PosixPath('ground_truth_to_del/125e2f84-cbd9-4791-9921-b3d4ca5b11a4/Etiquette.pdf'),
PosixPath('ground_truth_to_del/32ac61fe-a3c2-4505-9ceb-8c736416757b/FTF.pdf'),
PosixPath('ground_truth_to_del/32ac61fe-a3c2-4505-9ceb-8c736416757b/Etiquette.pdf'),
PosixPath('ground_truth_to_del/01e05d014-0db5-4d1f-abe5-e362b0d6f430/FTF.pdf'),
PosixPath('ground_truth_to_del/2810842-30dd-443c-93d4-4dd5df000a88/FTF.pdf'),
PosixPath('ground_truth_to_del/14d6a5a3-8bc2-4f5d-bb34-e5d8672cb879/FTF.pdf'),
PosixPath('ground_truth_to_del/14d6a5a3-8bc2-4f5d-bb34-e5d8672cb879/Etiquette.pdf'),
PosixPath('ground_truth_to_del/11a83eff-a28f-4ec4-9bb3-b336f3678939/FTF.pdf'),
PosixPath('ground_truth_to_del/11a83eff-a28f-4ec4-9bb3-b336f3678939/Etiquette.pdf'),
PosixPath('ground_truth_to_del/15ad3194-90d5-4adf-9be2-2e8df66932a5/FTF.pdf'),
PosixPath('ground_truth_to_del/15ad3194-90d5-4adf-9be2-2e8df66932a5/Etiquette.pdf'),
PosixPath('ground_truth_to_del/11019003-a800-4b3a-928a-9a0690f03fae/FTF.pdf'),
PosixPath('ground_truth_to_del/2c5ee725-e96c-4fae-b6b8-40346ca7e07e/FTF.pdf'),
PosixPath('ground_truth_to_del/4f2b1a1d-2209-4edf-9a61-e1dc07851729/FTF.pdf'),
PosixPath('ground_truth_to_del/4f2b1a1d-2209-4edf-9a61-e1dc07851729/Etiquette.pdf'),
PosixPath('ground_truth_to_del/3076fdbd6-0237-4c00-8682-f80b7548e6d4/FTF.pdf'),
PosixPath('ground_truth_to_del/3076fdbd6-0237-4c00-8682-f80b7548e6d4/Etiquette.pdf'),
PosixPath('ground_truth_to_del/092bf667-1b90-4f8d-96bc-43a55f639600/FTF.pdf'),
PosixPath('ground_truth_to_del/092bf667-1b90-4f8d-96bc-43a55f639600/Etiquette.pdf'),
PosixPath('ground_truth_to_del/19962287-c922-4101-b780-05c1ade60515/FTF.pdf'),
PosixPath('ground_truth_to_del/19962287-c922-4101-b780-05c1ade60515/Etiquette.pdf'),
PosixPath('ground_truth_to_del/15881feb-7045-40d7-968f-7931fb47f3c3/FTF.pdf'),
PosixPath('ground_truth_to_del/15881feb-7045-40d7-968f-7931fb47f3c3/Etiquette.pdf'),
PosixPath('ground_truth_to_del/19b5d0e3-b127-4092-9b59-b6e8027a0819/FTF.pdf'),
PosixPath('ground_truth_to_del/19b5d0e3-b127-4092-9b59-b6e8027a0819/Etiquette.pdf'),
PosixPath('ground_truth_to_del/0992f070-d0a7-4e90-8d3c-ecbf0c98ade0/FTF.pdf'),
PosixPath('ground_truth_to_del/0992f070-d0a7-4e90-8d3c-ecbf0c98ade0/Etiquette.pdf'),
PosixPath('ground_truth_to_del/53e8aad3-3a56-417e-b408-2bba685810ec/FTF.pdf'),
PosixPath('ground_truth_to_del/53e8aad3-3a56-417e-b408-2bba685810ec/Etiquette.pdf'),
PosixPath('ground_truth_to_del/26802761-5cd1-4242-9ee4-a479d1078f68/FTF.pdf'),
PosixPath('ground_truth_to_del/298053ff-a315-4099-9d2f-eca842508bb3/FTF.pdf'),
PosixPath('ground_truth_to_del/2cb689bd-1e39-4a63-bcde-4669741505c1/FTF.pdf'),
PosixPath('ground_truth_to_del/2cb689bd-1e39-4a63-bcde-4669741505c1/Etiquette.pdf'),
PosixPath('ground_truth_to_del/2cd5567a-bee6-46f2-a4bd-19d2b42ec001/FTF.pdf'),
PosixPath('ground_truth_to_del/2cd5567a-bee6-46f2-a4bd-19d2b42ec001/Etiquette.pdf'),
PosixPath('ground_truth_to_del/29e1fb47-6399-4c5f-af77-670efb956cff/FTF.pdf'),
PosixPath('ground_truth_to_del/29e1fb47-6399-4c5f-af77-670efb956cff/Etiquette.pdf'),
PosixPath('ground_truth_to_del/0da4b0fb-6d0c-4c6f-9b03-53164c5d8a2a/FTF.pdf'),
PosixPath('ground_truth_to_del/0da4b0fb-6d0c-4c6f-9b03-53164c5d8a2a/Etiquette.pdf'),
PosixPath('ground_truth_to_del/38f8155f-6bb8-422e-ada2-d0a5c8e88441/FTF.pdf'),
PosixPath('ground_truth_to_del/38f8155f-6bb8-422e-ada2-d0a5c8e88441/Etiquette.pdf'),
PosixPath('ground_truth_to_del/1f835883-dbcd-4382-8a0b-e6fd2573218e/FTF.pdf'),
PosixPath('ground_truth_to_del/197fee12-be3f-4d33-8b0c-c1d0ba19676a/FTF.pdf'),
PosixPath('ground_truth_to_del/197fee12-be3f-4d33-8b0c-c1d0ba19676a/Etiquette.pdf'),
PosixPath('ground_truth_to_del/2130ca8e-2e65-4b6c-9565-cf632171b985/FTF.pdf'),
PosixPath('ground_truth_to_del/2130ca8e-2e65-4b6c-9565-cf632171b985/Etiquette.pdf'),
PosixPath('ground_truth_to_del/25d86724-04a4-4366-acc5-253903585d5c/FTF.pdf'),
PosixPath('ground_truth_to_del/25d86724-04a4-4366-acc5-253903585d5c/Etiquette.pdf'),
PosixPath('ground_truth_to_del/550758b8-b60c-441d-a5b1-63c21788cd02/FTF.pdf'),
PosixPath('ground_truth_to_del/550758b8-b60c-441d-a5b1-63c21788cd02/Etiquette.pdf'),
PosixPath('ground_truth_to_del/02c7e9c8-2013-4fb2-b974-a796fc34bd66/FTF.pdf'),
PosixPath('ground_truth_to_del/131be880-9b1d-431f-bee9-2457085d395d/FTF.pdf'),
PosixPath('ground_truth_to_del/41e97cfe-b706-4892-b17a-c4487b5dd064/FTF.pdf'),
PosixPath('ground_truth_to_del/1e15f399-f050-4adf-b9b6-d48304ad7479/FTF.pdf'),
PosixPath('ground_truth_to_del/1bc3e6a1-69fd-4153-86c0-1c07be001387/FTF.pdf'),
PosixPath('ground_truth_to_del/2dc151f7-9d2a-4cc9-aa6c-8b89c7abb5ee/FTF.pdf'),
PosixPath('ground_truth_to_del/0b97d339-6eb7-4ea6-9751-47a54eaf74c5/FTF.pdf'),

```

```

PosixPath('ground_truth_to_del/1d34af67-1d8b-4919-a6ef-50e5551c3083/FTF.pdf'),
PosixPath('ground_truth_to_del/42f765ff-4b6d-4cb6-a11c-0e0e4aa975da/FTF.pdf'),
PosixPath('ground_truth_to_del/42f765ff-4b6d-4cb6-a11c-0e0e4aa975da/Etiquette.pdf'),
PosixPath('ground_truth_to_del/3eac86f3-abe6-4da3-b292-32133b463538/FTF.pdf'),
PosixPath('ground_truth_to_del/3eac86f3-abe6-4da3-b292-32133b463538/Etiquette.pdf'),
PosixPath('ground_truth_to_del/04aaf9f1-fd47-4771-a069-40ef8aea6afa/FTF.pdf'),
PosixPath('ground_truth_to_del/04aaf9f1-fd47-4771-a069-40ef8aea6afa/Etiquette.pdf'),
PosixPath('ground_truth_to_del/60dc13af-c086-4c62-b8f2-e151cf37573a/FTF.pdf'),
PosixPath('ground_truth_to_del/05a99af9-9ee7-46d6-9ad9-2708d856869f/FTF.pdf'),
PosixPath('ground_truth_to_del/05a99af9-9ee7-46d6-9ad9-2708d856869f/Etiquette.pdf'),
PosixPath('ground_truth_to_del/076c4376-b56c-4aea-ad0d-d22e20ed26b5/FTF.pdf'),
PosixPath('ground_truth_to_del/689e9b73-e6fd-4828-bae7-c0ea20b71e11/FTF.pdf'),
PosixPath('ground_truth_to_del/2e7c56ca-e1c3-4b37-8b5b-e8f1c6b15d25/FTF.pdf'),
PosixPath('ground_truth_to_del/2e7c56ca-e1c3-4b37-8b5b-e8f1c6b15d25/Etiquette.pdf'),
PosixPath('ground_truth_to_del/30c7d834-60a6-47ee-b4c1-fcc0522958f6/FTF.pdf'),
PosixPath('ground_truth_to_del/30c7d834-60a6-47ee-b4c1-fcc0522958f6/Etiquette.pdf'),
PosixPath('ground_truth_to_del/27e61b5a-9b04-487f-80bb-8364d7e51730/FTF.pdf'),
PosixPath('ground_truth_to_del/27e61b5a-9b04-487f-80bb-8364d7e51730/Etiquette.pdf'),
PosixPath('ground_truth_to_del/1327ed8d-8649-4c96-ad36-6cbab2e758fb/FTF.pdf'),
PosixPath('ground_truth_to_del/1327ed8d-8649-4c96-ad36-6cbab2e758fb/Etiquette.pdf'),
PosixPath('ground_truth_to_del/2e0dbfcf-e2c1-478d-a46f-fcccd2cd7871a/FTF.pdf'),
PosixPath('ground_truth_to_del/2e0dbfcf-e2c1-478d-a46f-fcccd2cd7871a/Etiquette.pdf'),
PosixPath('ground_truth_to_del/67f0bf07-73f6-42ad-a744-1dd68867410a/FTF.pdf'),
PosixPath('ground_truth_to_del/67f0bf07-73f6-42ad-a744-1dd68867410a/Etiquette.pdf'),
PosixPath('ground_truth_to_del/219dee1e-2ffb-4ed7-98f1-18e60082248d/FTF.pdf'),
PosixPath('ground_truth_to_del/3fd073bb-a4a2-46fa-819c-0136316bf2b0/FTF.pdf'),
PosixPath('ground_truth_to_del/3fd073bb-a4a2-46fa-819c-0136316bf2b0/Etiquette.pdf'),
PosixPath('ground_truth_to_del/322b1c1e-a071-443b-8a51-ac7e85fb8d48/FTF.pdf'),
PosixPath('ground_truth_to_del/322b1c1e-a071-443b-8a51-ac7e85fb8d48/Etiquette.pdf'),
PosixPath('ground_truth_to_del/000000a9-630d-4926-bfe0-ae2b381086c2/FTF.pdf'),
PosixPath('ground_truth_to_del/000000a9-630d-4926-bfe0-ae2b381086c2/Etiquette.pdf'),
PosixPath('ground_truth_to_del/25d13244-0f2f-40ef-9fd7-81fe42ce51a8/FTF.pdf'),
PosixPath('ground_truth_to_del/25d13244-0f2f-40ef-9fd7-81fe42ce51a8/Etiquette.pdf'),
PosixPath('ground_truth_to_del/13d6546c-40a8-44f0-880f-040bc0432214/FTF.pdf'),
PosixPath('ground_truth_to_del/13d6546c-40a8-44f0-880f-040bc0432214/Etiquette.pdf'),
PosixPath('ground_truth_to_del/273ce11f-6613-4ed7-a0cd-557fe22607d3/FTF.pdf'),
PosixPath('ground_truth_to_del/273ce11f-6613-4ed7-a0cd-557fe22607d3/Etiquette.pdf'),
PosixPath('ground_truth_to_del/40a3a41b-13d2-4d4f-a2db-d0402c58a237/FTF.pdf'),
PosixPath('ground_truth_to_del/26a802e8-434b-40ed-9e46-db95f381bf83/FTF.pdf'),
PosixPath('ground_truth_to_del/26a802e8-434b-40ed-9e46-db95f381bf83/Etiquette.pdf'),
PosixPath('ground_truth_to_del/0c35ae62-0106-467e-8120-62de6388e069/FTF.pdf'),
PosixPath('ground_truth_to_del/69b8d433-ab6d-4234-a9dc-cd85e9adc4cd/FTF.pdf'),
PosixPath('ground_truth_to_del/69b8d433-ab6d-4234-a9dc-cd85e9adc4cd/Etiquette.pdf'),
PosixPath('ground_truth_to_del/6bbc4cc6-a945-4689-880a-9d1f771a39a0/FTF.pdf'),
PosixPath('ground_truth_to_del/6bbc4cc6-a945-4689-880a-9d1f771a39a0/Etiquette.pdf'),
PosixPath('ground_truth_to_del/3ba0fde6-fa1d-4f80-a0f2-82764a918415/FTF.pdf'),
PosixPath('ground_truth_to_del/3ba0fde6-fa1d-4f80-a0f2-82764a918415/Etiquette.pdf'),
PosixPath('ground_truth_to_del/20e25e6c-5476-4ef4-bf38-66e7a171f2e7/FTF.pdf'),
PosixPath('ground_truth_to_del/20e25e6c-5476-4ef4-bf38-66e7a171f2e7/Etiquette.pdf'),
PosixPath('ground_truth_to_del/50b11cd7-3ff5-4477-a934-ec42bb875833/FTF.pdf'),
PosixPath('ground_truth_to_del/18e1d863-b0be-4a62-97b6-c2245d525300/FTF.pdf'),
PosixPath('ground_truth_to_del/07219ad0-57a9-4ffd-a75c-64141a9ad8c5/FTF.pdf'),
PosixPath('ground_truth_to_del/07219ad0-57a9-4ffd-a75c-64141a9ad8c5/Etiquette.pdf'),
PosixPath('ground_truth_to_del/434872d4-c0ae-4617-95e9-e2e3164e0c86/FTF.pdf'),
PosixPath('ground_truth_to_del/451f5c8e-71df-428f-9a22-b93d75bec151/FTF.pdf'),
PosixPath('ground_truth_to_del/451f5c8e-71df-428f-9a22-b93d75bec151/Etiquette.pdf'),
PosixPath('ground_truth_to_del/27b7340a-f561-4c9d-9e3e-e3bec8444ac7/FTF.pdf'),
PosixPath('ground_truth_to_del/27b7340a-f561-4c9d-9e3e-e3bec8444ac7/Etiquette.pdf'),
PosixPath('ground_truth_to_del/2f2baaf2-2c4d-4b6b-90ce-f4e5036695f4/FTF.pdf'),
PosixPath('ground_truth_to_del/2f2baaf2-2c4d-4b6b-90ce-f4e5036695f4/Etiquette.pdf'),
PosixPath('ground_truth_to_del/0cce54bb-25d4-44d4-b288-9c90a3095010/FTF.pdf'),
PosixPath('ground_truth_to_del/0cce54bb-25d4-44d4-b288-9c90a3095010/Etiquette.pdf'),
PosixPath('ground_truth_to_del/49428283-104a-4092-966f-07b974112836/FTF.pdf'),
PosixPath('ground_truth_to_del/25c9c49d-aae8-4d71-b210-3f35009ef278/FTF.pdf'),
PosixPath('ground_truth_to_del/25c9c49d-aae8-4d71-b210-3f35009ef278/Etiquette.pdf'),
PosixPath('ground_truth_to_del/32c98c8d-e91f-4220-aaac-b36f04155cc2/FTF.pdf'),
PosixPath('ground_truth_to_del/32c98c8d-e91f-4220-aaac-b36f04155cc2/Etiquette.pdf'),

```

```

PosixPath('ground_truth_to_del/82307cf9-358e-4171-8f0c-2f208db137bc/FTF.pdf'),
PosixPath('ground_truth_to_del/4e42c18f-a60f-4289-aef6-3123dde4315b/FTF.pdf'),
PosixPath('ground_truth_to_del/46a60365-334f-42e1-8680-a093d189a5c3/FTF.pdf'),
PosixPath('ground_truth_to_del/46a60365-334f-42e1-8680-a093d189a5c3/Etiquette.pdf'),
PosixPath('ground_truth_to_del/27ee0827-7fc6-4729-8743-04b20cef7538/FTF.pdf'),
PosixPath('ground_truth_to_del/2638e812-6885-414e-b305-8d58e6e926fd/FTF.pdf'),
PosixPath('ground_truth_to_del/2bf4277e-2f57-4fe9-b15f-8e91b0c93d3b/FTF.pdf'),
PosixPath('ground_truth_to_del/0ae99429-81c7-484b-b346-7258c8171e6a/FTF.pdf'),
PosixPath('ground_truth_to_del/15b4f659-1180-485e-bfeb-b3b8874cb36d/FTF.pdf'),
PosixPath('ground_truth_to_del/15b4f659-1180-485e-bfeb-b3b8874cb36d/Etiquette.pdf'),
PosixPath('ground_truth_to_del/42113a2e-dc24-429f-8e8b-1bf047cec24f/FTF.pdf'),
PosixPath('ground_truth_to_del/49c2ad64-f922-450f-a40e-9d74c8931bc1/FTF.pdf'),
PosixPath('ground_truth_to_del/49c2ad64-f922-450f-a40e-9d74c8931bc1/Etiquette.pdf'),
PosixPath('ground_truth_to_del/309d18c7-e7bd-4b4b-b56e-118dc44746ec/FTF.pdf'),
PosixPath('ground_truth_to_del/7d329752-38dc-44f7-b078-52d08a601d0f/FTF.pdf'),
PosixPath('ground_truth_to_del/7d329752-38dc-44f7-b078-52d08a601d0f/Etiquette.pdf'),
PosixPath('ground_truth_to_del/0f99e057-ea63-4388-8445-6ea7363a4d47/FTF.pdf'),
PosixPath('ground_truth_to_del/0f99e057-ea63-4388-8445-6ea7363a4d47/Etiquette.pdf'),
PosixPath('ground_truth_to_del/6c07fd47-116d-4531-a164-d4f4040f212e/FTF.pdf'),
PosixPath('ground_truth_to_del/160228a5-239f-4429-8efa-4ad3be0fcd57/FTF.pdf'),
PosixPath('ground_truth_to_del/160228a5-239f-4429-8efa-4ad3be0fcd57/Etiquette.pdf'),
PosixPath('ground_truth_to_del/3f3ef2e9-da15-45d6-bdf3-0dfd7b19c767/FTF.pdf'),
PosixPath('ground_truth_to_del/3f3ef2e9-da15-45d6-bdf3-0dfd7b19c767/Etiquette.pdf'),
PosixPath('ground_truth_to_del/4c4e18bc-bcfa-4a88-b6aa-a84c6e85a1c2/FTF.pdf'),
PosixPath('ground_truth_to_del/4c4e18bc-bcfa-4a88-b6aa-a84c6e85a1c2/Etiquette.pdf'),
PosixPath('ground_truth_to_del/17309800-4d7c-47e1-85fa-9cf8ae2bb621/FTF.pdf'),
PosixPath('ground_truth_to_del/17309800-4d7c-47e1-85fa-9cf8ae2bb621/Etiquette.pdf'),
PosixPath('ground_truth_to_del/31a3bf71-261b-44f1-85cc-483c31e9d419/FTF.pdf'),
PosixPath('ground_truth_to_del/20d90cae-b0e0-479d-99f8-cb1bfff4ddad7/FTF.pdf'),
PosixPath('ground_truth_to_del/20d90cae-b0e0-479d-99f8-cb1bfff4ddad7/Etiquette.pdf'),
PosixPath('ground_truth_to_del/60918355-2b47-44a5-9e22-1bbdcbb05303/FTF.pdf'),
PosixPath('ground_truth_to_del/53cf5759-1acf-441c-a21c-aa40e8d968f4/FTF.pdf'),
PosixPath('ground_truth_to_del/49662aea-bbc0-4b2c-b37a-4aab42aaaf1b/FTF.pdf'),
PosixPath('ground_truth_to_del/49662aea-bbc0-4b2c-b37a-4aab42aaaf1b/Etiquette.pdf'),
PosixPath('ground_truth_to_del/330a43f2-8093-4331-a799-6f45f4484f38/FTF.pdf'),
PosixPath('ground_truth_to_del/330a43f2-8093-4331-a799-6f45f4484f38/Etiquette.pdf'),
PosixPath('ground_truth_to_del/4abc922f-2486-4281-8c8e-7a9f7de5e03b/FTF.pdf'),
PosixPath('ground_truth_to_del/8c147f0a-2388-4b1a-ac4a-51febcb602278/FTF.pdf'),
PosixPath('ground_truth_to_del/1630ce16-2dac-4a53-8392-1d926f30cfe7/FTF.pdf'),
PosixPath('ground_truth_to_del/30374c15-6ad7-4c36-b589-4f3e5392b7d2/FTF.pdf'),
PosixPath('ground_truth_to_del/1a10fad3-dd3f-4dac-956c-d5b08c467df2/FTF.pdf'),
PosixPath('ground_truth_to_del/14ca0c03-51fe-4e64-ad35-dda02886edd7/FTF.pdf'),
PosixPath('ground_truth_to_del/14ca0c03-51fe-4e64-ad35-dda02886edd7/Etiquette.pdf'),
PosixPath('ground_truth_to_del/350af4b5-8de5-41cc-857c-c9a640af7068/FTF.pdf'),
PosixPath('ground_truth_to_del/350af4b5-8de5-41cc-857c-c9a640af7068/Etiquette.pdf'),
PosixPath('ground_truth_to_del/3fb2b967-5f30-4698-8e65-02a5bd1b73dd/FTF.pdf'),
PosixPath('ground_truth_to_del/3fb2b967-5f30-4698-8e65-02a5bd1b73dd/Etiquette.pdf'),
PosixPath('ground_truth_to_del/357780c6-5fe4-4329-87f4-6783fc4656ce/FTF.pdf'),
PosixPath('ground_truth_to_del/357780c6-5fe4-4329-87f4-6783fc4656ce/Etiquette.pdf'),
PosixPath('ground_truth_to_del/34a97260-e036-4dd4-a23d-bbab0bd4339c/FTF.pdf'),
PosixPath('ground_truth_to_del/34a97260-e036-4dd4-a23d-bbab0bd4339c/Etiquette.pdf'),
PosixPath('ground_truth_to_del/50c8ae3f-e589-4194-8ade-3305af661f89/FTF.pdf'),
PosixPath('ground_truth_to_del/50c8ae3f-e589-4194-8ade-3305af661f89/Etiquette.pdf'),
PosixPath('ground_truth_to_del/8c764293-ba0a-4103-8465-23a4f5eff7bb/FTF.pdf'),
PosixPath('ground_truth_to_del/6dd82dd2-91fc-44f6-b50c-1d5df25475d4/FTF.pdf'),
PosixPath('ground_truth_to_del/6dd82dd2-91fc-44f6-b50c-1d5df25475d4/Etiquette.pdf'),
PosixPath('ground_truth_to_del/2faae9e1-c7d0-490d-9636-91eb60f4dc5e/FTF.pdf'),
PosixPath('ground_truth_to_del/2faae9e1-c7d0-490d-9636-91eb60f4dc5e/Etiquette.pdf'),
PosixPath('ground_truth_to_del/4c04d80a-1f91-4c80-a6cd-4baea44c7ae1/FTF.pdf'),
PosixPath('ground_truth_to_del/194419d0-d9f2-4799-81ac-d9e3aa77fd27/FTF.pdf'),
PosixPath('ground_truth_to_del/194419d0-d9f2-4799-81ac-d9e3aa77fd27/Etiquette.pdf'),
PosixPath('ground_truth_to_del/93a2a28e-1ce3-4dc5-b176-4bc04d8c4e7e/FTF.pdf'),
PosixPath('ground_truth_to_del/93a2a28e-1ce3-4dc5-b176-4bc04d8c4e7e/Etiquette.pdf'),
PosixPath('ground_truth_to_del/2247f845-90bc-4e18-91a1-3746a849abdb/FTF.pdf'),
PosixPath('ground_truth_to_del/2247f845-90bc-4e18-91a1-3746a849abdb/Etiquette.pdf'),
PosixPath('ground_truth_to_del/4e2d4896-cd72-4fdf-b96c-e88da0ed65a5/FTF.pdf'),
PosixPath('ground_truth_to_del/4a9ffba0-fe45-4480-baf92c9d8a7ef27/FTF.pdf'),

```

```

PosixPath('ground_truth_to_del/509bf984-f920-42a9-963f-1dec33f62b29/FTF.pdf'),
PosixPath('ground_truth_to_del/36433128-b2c2-47e4-b735-f4a78acee4a8/FTF.pdf'),
PosixPath('ground_truth_to_del/36433128-b2c2-47e4-b735-f4a78acee4a8/Etiquette.pdf'),
PosixPath('ground_truth_to_del/543ba5a9-c8dc-40cc-b8d8-f7acb88e38ed/FTF.pdf'),
PosixPath('ground_truth_to_del/543ba5a9-c8dc-40cc-b8d8-f7acb88e38ed/Etiquette.pdf'),
PosixPath('ground_truth_to_del/65bd9493-e7d5-4cb6-be09-5013874edb2e/FTF.pdf'),
PosixPath('ground_truth_to_del/210fb9db-e28c-4e45-853c-29ef31e1a492/FTF.pdf'),
PosixPath('ground_truth_to_del/353afc3a-8fac-4114-bf61-b7a48f65a9ba/FTF.pdf'),
PosixPath('ground_truth_to_del/346dbe48-c849-4ff9-b4e3-3255e1c07516/FTF.pdf'),
PosixPath('ground_truth_to_del/346dbe48-c849-4ff9-b4e3-3255e1c07516/Etiquette.pdf'),
PosixPath('ground_truth_to_del/6181934e-84b3-47cc-afb2-e5a63e424556/FTF.pdf'),
PosixPath('ground_truth_to_del/8c387fb2-80f8-4a78-90e5-23120a26849f/FTF.pdf'),
PosixPath('ground_truth_to_del/8c387fb2-80f8-4a78-90e5-23120a26849f/Etiquette.pdf'),
PosixPath('ground_truth_to_del/36271221-0c81-4cde-b343-0a5ae772bb85/FTF.pdf'),
PosixPath('ground_truth_to_del/36271221-0c81-4cde-b343-0a5ae772bb85/Etiquette.pdf'),
PosixPath('ground_truth_to_del/920c062b-5c0d-47a7-8ccb-4a982e8f69ba/FTF.pdf'),
PosixPath('ground_truth_to_del/920c062b-5c0d-47a7-8ccb-4a982e8f69ba/Etiquette.pdf'),
PosixPath('ground_truth_to_del/3e6b9803-e32d-4152-82a8-e42213f23528/FTF.pdf'),
PosixPath('ground_truth_to_del/247e3d71-60ed-4cda-8faf-8600cb9e1ffc/FTF.pdf'),
PosixPath('ground_truth_to_del/5075bdf8-5bb7-4f17-9a1a-19f6b284af96/FTF.pdf'),
PosixPath('ground_truth_to_del/1f785e1c-4893-45a8-8c3f-7fd77c29e977/FTF.pdf'),
PosixPath('ground_truth_to_del/1f785e1c-4893-45a8-8c3f-7fd77c29e977/Etiquette.pdf'),
PosixPath('ground_truth_to_del/6b873d7d-0082-4d92-be34-b35d012fac16/FTF.pdf'),
PosixPath('ground_truth_to_del/a30ac485-5444-4105-a4b3-cad6b578ac44/FTF.pdf'),
PosixPath('ground_truth_to_del/59b9ef51-b664-47fd-bb29-3abf5625dc27/FTF.pdf'),
PosixPath('ground_truth_to_del/59b9ef51-b664-47fd-bb29-3abf5625dc27/Etiquette.pdf'),
PosixPath('ground_truth_to_del/57877d62-ace0-44ad-81bf-ed63b7a37877/FTF.pdf'),
PosixPath('ground_truth_to_del/99635842-8237-4296-89a7-27d8a31c2485/FTF.pdf'),
PosixPath('ground_truth_to_del/337085e0-4d69-4b74-8dc6-16ebe9be2f71/FTF.pdf'),
PosixPath('ground_truth_to_del/337085e0-4d69-4b74-8dc6-16ebe9be2f71/Etiquette.pdf'),
PosixPath('ground_truth_to_del/44c7c329-23f4-4337-b280-aa0dc5d6944f/FTF.pdf'),
PosixPath('ground_truth_to_del/3b6cac59-060c-48ff-b38d-bf2c039d45a1/FTF.pdf'),
PosixPath('ground_truth_to_del/354ac61a-2ee4-4040-ac9f-19ba20bbc0b/FTF.pdf'),
PosixPath('ground_truth_to_del/354ac61a-2ee4-4040-ac9f-19ba20bbc0b/Etiquette.pdf'),
PosixPath('ground_truth_to_del/56cee616-2687-487c-ae3e-a5f5bcd5c8eb/FTF.pdf'),
PosixPath('ground_truth_to_del/56cee616-2687-487c-ae3e-a5f5bcd5c8eb/Etiquette.pdf'),
PosixPath('ground_truth_to_del/1c9dd33d-86df-44ad-9c56-e5c773f0503f/FTF.pdf'),
PosixPath('ground_truth_to_del/1c9dd33d-86df-44ad-9c56-e5c773f0503f/Etiquette.pdf'),
PosixPath('ground_truth_to_del/4f084a5d-06c1-4f51-a3df-a6966467cd13/FTF.pdf'),
PosixPath('ground_truth_to_del/9c5fafc6-b8e9-4259-a847-3888e2f63302/FTF.pdf'),
PosixPath('ground_truth_to_del/9c5fafc6-b8e9-4259-a847-3888e2f63302/Etiquette.pdf'),
PosixPath('ground_truth_to_del/55e3353d-b1aa-4bb4-bdb8-8cfaf8431a5b/FTF.pdf'),
PosixPath('ground_truth_to_del/55e3353d-b1aa-4bb4-bdb8-8cfaf8431a5b/Etiquette.pdf'),
PosixPath('ground_truth_to_del/5c6c9d6d-542c-4f22-9731-5f9a78337808/FTF.pdf'),
PosixPath('ground_truth_to_del/5c6c9d6d-542c-4f22-9731-5f9a78337808/Etiquette.pdf'),
PosixPath('ground_truth_to_del/6cfe21c5-c2a4-4fb0-95f4-e83b1e4c52bd/FTF.pdf'),
PosixPath('ground_truth_to_del/6cfe21c5-c2a4-4fb0-95f4-e83b1e4c52bd/Etiquette.pdf'),
PosixPath('ground_truth_to_del/71224717-db75-49cf-a6fd-17b7be2a4c0c/FTF.pdf'),
PosixPath('ground_truth_to_del/91e56966-5e1b-478c-9a21-ed95ac5a1f1e/FTF.pdf'),
PosixPath('ground_truth_to_del/36673905-c961-41cd-81c3-dc5346a91188/FTF.pdf'),
PosixPath('ground_truth_to_del/327bee17-4b4e-4bbb-a357-23969466d458/FTF.pdf'),
PosixPath('ground_truth_to_del/6b841ff4-f060-4c1c-b4aa-ca0dbc8b580f/FTF.pdf'),
PosixPath('ground_truth_to_del/6b841ff4-f060-4c1c-b4aa-ca0dbc8b580f/Etiquette.pdf'),
PosixPath('ground_truth_to_del/528e0d02-f2c4-4e9c-abc0-3e995e710fe3/FTF.pdf'),
PosixPath('ground_truth_to_del/528e0d02-f2c4-4e9c-abc0-3e995e710fe3/Etiquette.pdf'),
PosixPath('ground_truth_to_del/37015ff1-f6ae-474a-9371-3fa09c083946/FTF.pdf'),
PosixPath('ground_truth_to_del/37015ff1-f6ae-474a-9371-3fa09c083946/Etiquette.pdf'),
PosixPath('ground_truth_to_del/480b5e3e-ebae-49e9-b0d9-9e320bd5b0e0/FTF.pdf'),
PosixPath('ground_truth_to_del/6c441199-d8f5-4b72-baac-7365dbb1ca1e/FTF.pdf'),
PosixPath('ground_truth_to_del/6c441199-d8f5-4b72-baac-7365dbb1ca1e/Etiquette.pdf'),
PosixPath('ground_truth_to_del/40d3743b-9fa5-4d3b-9a9f-291fc03371a/FTF.pdf'),
PosixPath('ground_truth_to_del/40d3743b-9fa5-4d3b-9a9f-291fc03371a/Etiquette.pdf'),
PosixPath('ground_truth_to_del/52e7af3-1cc7-4352-a637-375634317263/FTF.pdf'),
PosixPath('ground_truth_to_del/52e7af3-1cc7-4352-a637-375634317263/Etiquette.pdf'),
PosixPath('ground_truth_to_del/a4b7ddcf-6add-4599-b27f-b09a633cf5a0/FTF.pdf'),
PosixPath('ground_truth_to_del/76ccde5e-20b2-4003-8956-56c412e77577/FTF.pdf'),
PosixPath('ground_truth_to_del/76ccde5e-20b2-4003-8956-56c412e77577/Etiquette.pdf'),

```

```

PosixPath('ground_truth_to_del/58f0adec-3b79-4e4a-b17e-01831bef8007/FTF.pdf'),
PosixPath('ground_truth_to_del/58f0adec-3b79-4e4a-b17e-01831bef8007/Etiquette.pdf'),
PosixPath('ground_truth_to_del/2a94de43-bb23-428f-bee4-9fbe94e5f101/FTF.pdf'),
PosixPath('ground_truth_to_del/50bf4229-ebff-481d-8bbf-2f2e218b62bf/FTF.pdf'),
PosixPath('ground_truth_to_del/50bf4229-ebff-481d-8bbf-2f2e218b62bf/Etiquette.pdf'),
PosixPath('ground_truth_to_del/4228e795-15a5-46e1-bff8-28f7ddfc0a2d/FTF.pdf'),
PosixPath('ground_truth_to_del/4cbab858-9753-4eaf-9133-b2fe65a746bb/FTF.pdf'),
PosixPath('ground_truth_to_del/4cbab858-9753-4eaf-9133-b2fe65a746bb/Etiquette.pdf'),
PosixPath('ground_truth_to_del/433368e8-0dff-45df-836c-1537f6980b09/FTF.pdf'),
PosixPath('ground_truth_to_del/734f6ec1-a195-4b2f-8b92-6036a87c21d6/FTF.pdf'),
PosixPath('ground_truth_to_del/7560a4e3-f77-4977-b794-2b383fc0ac2d/FTF.pdf'),
PosixPath('ground_truth_to_del/7560a4e3-f77-4977-b794-2b383fc0ac2d/Etiquette.pdf'),
PosixPath('ground_truth_to_del/4ead23e7-e7c1-42b6-8cca-4b3176aae494/FTF.pdf'),
PosixPath('ground_truth_to_del/4ead23e7-e7c1-42b6-8cca-4b3176aae494/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b03fd457-359a-43b0-bf12-3600ab33273a/FTF.pdf'),
PosixPath('ground_truth_to_del/b03fd457-359a-43b0-bf12-3600ab33273a/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b1bf8df1-23c3-4b28-b609-0721cf0ecde2/FTF.pdf'),
PosixPath('ground_truth_to_del/5e973636-5c0e-4919-9223-ec5335ff19ce/FTF.pdf'),
PosixPath('ground_truth_to_del/5e973636-5c0e-4919-9223-ec5335ff19ce/Etiquette.pdf'),
PosixPath('ground_truth_to_del/48bbc56d-563d-4e76-a07d-600d812605f3/FTF.pdf'),
PosixPath('ground_truth_to_del/48bbc56d-563d-4e76-a07d-600d812605f3/Etiquette.pdf'),
PosixPath('ground_truth_to_del/5931aecc-fa96-45a1-9ff6-e039365bc2cf/FTF.pdf'),
PosixPath('ground_truth_to_del/5931aecc-fa96-45a1-9ff6-e039365bc2cf/Etiquette.pdf'),
PosixPath('ground_truth_to_del/613e730b-c787-44f5-aaaa-008f94e595c4/FTF.pdf'),
PosixPath('ground_truth_to_del/613e730b-c787-44f5-aaaa-008f94e595c4/Etiquette.pdf'),
PosixPath('ground_truth_to_del/70ea16bc-a683-47cf-b260-b8b6bcd9818/FTF.pdf'),
PosixPath('ground_truth_to_del/7106ae76-4234-488b-bd3f-91d86b5a851b/FTF.pdf'),
PosixPath('ground_truth_to_del/64fcc771-b750-4cf1-ad96-cb2c0f0cd7a2/FTF.pdf'),
PosixPath('ground_truth_to_del/31e8646c-aa62-4b70-84c3-5445af1d0c5/FTF.pdf'),
PosixPath('ground_truth_to_del/31e8646c-aa62-4b70-84c3-5445af1d0c5/Etiquette.pdf'),
PosixPath('ground_truth_to_del/4750ea5e-29ba-4967-8cd6-cd8b5a63edec/FTF.pdf'),
PosixPath('ground_truth_to_del/4750ea5e-29ba-4967-8cd6-cd8b5a63edec/Etiquette.pdf'),
PosixPath('ground_truth_to_del/7dc6655c-9c78-48da-8aa2-15f63bbcde02/FTF.pdf'),
PosixPath('ground_truth_to_del/7dc6655c-9c78-48da-8aa2-15f63bbcde02/Etiquette.pdf'),
PosixPath('ground_truth_to_del/5e289fdf-adeb-4421-b472-c6d9fb7786c3/FTF.pdf'),
PosixPath('ground_truth_to_del/5c5b0c6a0-0be0-4fd7-9666-bbb691718073/FTF.pdf'),
PosixPath('ground_truth_to_del/5c5b0c6a0-0be0-4fd7-9666-bbb691718073/Etiquette.pdf'),
PosixPath('ground_truth_to_del/4575534d-3065-405f-8be3-fe79e9f71e40/FTF.pdf'),
PosixPath('ground_truth_to_del/4575534d-3065-405f-8be3-fe79e9f71e40/Etiquette.pdf'),
PosixPath('ground_truth_to_del/5cdbae3e-f495-4112-bcea-63e97eceed97/FTF.pdf'),
PosixPath('ground_truth_to_del/77941f87-4e69-4441-bf8b-7d9a14e9675d/FTF.pdf'),
PosixPath('ground_truth_to_del/5795ef7f-2160-4c8a-954e-71e6904eb44a/FTF.pdf'),
PosixPath('ground_truth_to_del/b4a91b86-6b0c-43ad-b14c-431c9144e6cf/FTF.pdf'),
PosixPath('ground_truth_to_del/b4a91b86-6b0c-43ad-b14c-431c9144e6cf/Etiquette.pdf'),
PosixPath('ground_truth_to_del/5a9d851f-34e4-4a53-a162-1e31da8782fb/FTF.pdf'),
PosixPath('ground_truth_to_del/5a9d851f-34e4-4a53-a162-1e31da8782fb/Etiquette.pdf'),
PosixPath('ground_truth_to_del/7b4b2030-63f3-416c-b3a7-b20204a748ef/FTF.pdf'),
PosixPath('ground_truth_to_del/7b4b2030-63f3-416c-b3a7-b20204a748ef/Etiquette.pdf'),
PosixPath('ground_truth_to_del/739457ba-df36-4c6e-a07a-ba04708aa2d6/FTF.pdf'),
PosixPath('ground_truth_to_del/739457ba-df36-4c6e-a07a-ba04708aa2d6/Etiquette.pdf'),
PosixPath('ground_truth_to_del/6e0567db-47c0-49b8-9589-05332599d2e2/FTF.pdf'),
PosixPath('ground_truth_to_del/6e0567db-47c0-49b8-9589-05332599d2e2/Etiquette.pdf'),
PosixPath('ground_truth_to_del/83b3d811-83df-4b11-ab96-46e34b895d5/FTF.pdf'),
PosixPath('ground_truth_to_del/83b3d811-83df-4b11-ab96-46e34b895d5/Etiquette.pdf'),
PosixPath('ground_truth_to_del/66d06c78-276a-4988-927b-8ea3f9aeee4c6/FTF.pdf'),
PosixPath('ground_truth_to_del/6a137b2b-1fc5-4979-8267-1b75e5e83d2e/FTF.pdf'),
PosixPath('ground_truth_to_del/80980681-f722-409e-9365-f9fe2cc42c41/FTF.pdf'),
PosixPath('ground_truth_to_del/80980681-f722-409e-9365-f9fe2cc42c41/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b96f8d92-e322-4109-8c12-65e6c735b305/FTF.pdf'),
PosixPath('ground_truth_to_del/69445ef4-ae14-4f74-b9f7-122234fc6832/FTF.pdf'),
PosixPath('ground_truth_to_del/69445ef4-ae14-4f74-b9f7-122234fc6832/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b70ed045-57ec-497d-bf18-af14fbbe955/FTF.pdf'),
PosixPath('ground_truth_to_del/b70ed045-57ec-497d-bf18-af14fbbe955/Etiquette.pdf'),
PosixPath('ground_truth_to_del/7bc91203-9fcc-4196-9272-cce06003af8e/FTF.pdf'),
PosixPath('ground_truth_to_del/81caa29a-9555-4186-927d-d2655eff703f1/FTF.pdf'),
PosixPath('ground_truth_to_del/81caa29a-9555-4186-927d-d2655eff703f1/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b340b56a-d41c-41a2-ad33-2ba068a8e25d/FTF.pdf'),

```

```

PosixPath('ground_truth_to_del/8ed11887-e517-4789-b209-a55e1863b448/FTF.pdf'),
PosixPath('ground_truth_to_del/8ed11887-e517-4789-b209-a55e1863b448/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b3d7d0a3-4bbf-410d-98f3-1c1e77b36ff8/FTF.pdf'),
PosixPath('ground_truth_to_del/5dec11b2-998f-4d8a-abb3-d90c54bf450f/FTF.pdf'),
PosixPath('ground_truth_to_del/5dec11b2-998f-4d8a-abb3-d90c54bf450f/Etiquette.pdf'),
PosixPath('ground_truth_to_del/7be3a43d-8831-4fc9-99aa-dd14e6f6cd14/FTF.pdf'),
PosixPath('ground_truth_to_del/71f0f1e7-2479-453c-891d-5fb606cede0a/FTF.pdf'),
PosixPath('ground_truth_to_del/71f0f1e7-2479-453c-891d-5fb606cede0a/Etiquette.pdf'),
PosixPath('ground_truth_to_del/37414f17-d8e2-4e48-968a-89ae5447a3a7/FTF.pdf'),
PosixPath('ground_truth_to_del/37414f17-d8e2-4e48-968a-89ae5447a3a7/Etiquette.pdf'),
PosixPath('ground_truth_to_del/492a794f-6fee-4cc0-b997-d4df71590c2f/FTF.pdf'),
PosixPath('ground_truth_to_del/492a794f-6fee-4cc0-b997-d4df71590c2f/Etiquette.pdf'),
PosixPath('ground_truth_to_del/67e19102-1797-4f87-a4dd-1e9aed6d72cb/FTF.pdf'),
PosixPath('ground_truth_to_del/a096d6b7-872d-4595-a1ae-7a264075375e/FTF.pdf'),
PosixPath('ground_truth_to_del/6857bda9-20d7-430b-b4db-4e0a53629d48/FTF.pdf'),
PosixPath('ground_truth_to_del/6857bda9-20d7-430b-b4db-4e0a53629d48/Etiquette.pdf'),
PosixPath('ground_truth_to_del/8096226d-b553-4d19-9103-906ce5681f5e/FTF.pdf'),
PosixPath('ground_truth_to_del/6a7a36d7-dbd6-49bb-88cc-f3481bc4835c/FTF.pdf'),
PosixPath('ground_truth_to_del/6a7a36d7-dbd6-49bb-88cc-f3481bc4835c/Etiquette.pdf'),
PosixPath('ground_truth_to_del/78bc67de-868d-4bfa-8ad8-ccb48e8536cd/FTF.pdf'),
PosixPath('ground_truth_to_del/78bc67de-868d-4bfa-8ad8-ccb48e8536cd/Etiquette.pdf'),
PosixPath('ground_truth_to_del/567b8f78-f542-4dc4-9221-69818ddecda5/FTF.pdf'),
PosixPath('ground_truth_to_del/88c2830c-1fd8-46fb-a004-559c7bb7eb41/FTF.pdf'),
PosixPath('ground_truth_to_del/5d7ad3d0-8a88-45d9-804b-21adaca086a1/FTF.pdf'),
PosixPath('ground_truth_to_del/5d7ad3d0-8a88-45d9-804b-21adaca086a1/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b81e2160-01a0-4ad3-8c8e-312222e4ec6a/FTF.pdf'),
PosixPath('ground_truth_to_del/8e5e297a-1c21-4f37-851f-d5102c6cbbf2/FTF.pdf'),
PosixPath('ground_truth_to_del/8e5e297a-1c21-4f37-851f-d5102c6cbbf2/Etiquette.pdf'),
PosixPath('ground_truth_to_del/beb14373-60c2-4585-963f-412baef18df6/FTF.pdf'),
PosixPath('ground_truth_to_del/beb14373-60c2-4585-963f-412baef18df6/Etiquette.pdf'),
PosixPath('ground_truth_to_del/bac7db53-f887-4a02-b053-d498e070970d/FTF.pdf'),
PosixPath('ground_truth_to_del/bac7db53-f887-4a02-b053-d498e070970d/Etiquette.pdf'),
PosixPath('ground_truth_to_del/8230db40-e470-41cf-8b58-56346f898f60/FTF.pdf'),
PosixPath('ground_truth_to_del/8230db40-e470-41cf-8b58-56346f898f60/Etiquette.pdf'),
PosixPath('ground_truth_to_del/6de6d561-d182-40c8-99c5-c720f5e1a134/FTF.pdf'),
PosixPath('ground_truth_to_del/7cef5ce6-5fb7-4562-926d-da66fe25b77c/FTF.pdf'),
PosixPath('ground_truth_to_del/7cef5ce6-5fb7-4562-926d-da66fe25b77c/Etiquette.pdf'),
PosixPath('ground_truth_to_del/89c23d8c-09b1-4aaa-abc9-f1b5034a1995/FTF.pdf'),
PosixPath('ground_truth_to_del/60f12f53-8edb-4321-962c-a6085f00260c/FTF.pdf'),
PosixPath('ground_truth_to_del/60f12f53-8edb-4321-962c-a6085f00260c/Etiquette.pdf'),
PosixPath('ground_truth_to_del/71e44ced-1093-48a4-9cb0-8a3ef60a5634/FTF.pdf'),
PosixPath('ground_truth_to_del/71e44ced-1093-48a4-9cb0-8a3ef60a5634/Etiquette.pdf'),
PosixPath('ground_truth_to_del/bcc8b13e-ecdd-405a-a59e-4a50f40cdb4f/FTF.pdf'),
PosixPath('ground_truth_to_del/bcc8b13e-ecdd-405a-a59e-4a50f40cdb4f/Etiquette.pdf'),
PosixPath('ground_truth_to_del/7fd81ebe-8140-4fa5-9cd3-70246b314017/FTF.pdf'),
PosixPath('ground_truth_to_del/9c974127-70ac-4af5-ae03-143b198de045/FTF.pdf'),
PosixPath('ground_truth_to_del/9c974127-70ac-4af5-ae03-143b198de045/Etiquette.pdf'),
PosixPath('ground_truth_to_del/c014e0bb-296e-4e54-8d9e-0a85abfdee24/FTF.pdf'),
PosixPath('ground_truth_to_del/c014e0bb-296e-4e54-8d9e-0a85abfdee24/Etiquette.pdf'),
PosixPath('ground_truth_to_del/8e51b4dc-349f-4cf6-9810-ad9057a86512/FTF.pdf'),
PosixPath('ground_truth_to_del/8e51b4dc-349f-4cf6-9810-ad9057a86512/Etiquette.pdf'),
PosixPath('ground_truth_to_del/7fe8681e-07d3-4bc0-95f9-8b987e63d958/FTF.pdf'),
PosixPath('ground_truth_to_del/7fe8681e-07d3-4bc0-95f9-8b987e63d958/Etiquette.pdf'),
PosixPath('ground_truth_to_del/4a005925-14ba-4e3d-be17-5c2d12f93854/FTF.pdf'),
PosixPath('ground_truth_to_del/8db71cc9-7d65-4af9-944c-75289cf11ff9/FTF.pdf'),
PosixPath('ground_truth_to_del/8db71cc9-7d65-4af9-944c-75289cf11ff9/Etiquette.pdf'),
PosixPath('ground_truth_to_del/8bda6efa-40ac-4ee0-b88f-639881ce46f0/FTF.pdf'),
PosixPath('ground_truth_to_del/8bda6efa-40ac-4ee0-b88f-639881ce46f0/Etiquette.pdf'),
PosixPath('ground_truth_to_del/8b1d68b6-28f1-4d08-8669-55d2ec75b177/FTF.pdf'),
PosixPath('ground_truth_to_del/8b1d68b6-28f1-4d08-8669-55d2ec75b177/Etiquette.pdf'),
PosixPath('ground_truth_to_del/6f95c8aa-4047-4715-a12e-865fd6b78116/FTF.pdf'),
PosixPath('ground_truth_to_del/7f45cb4e-e7e9-4688-ae7f-e3ecfcf04955/FTF.pdf'),
PosixPath('ground_truth_to_del/7f45cb4e-e7e9-4688-ae7f-e3ecfcf04955/Etiquette.pdf'),
PosixPath('ground_truth_to_del/96bb11da-fd24-410d-b0ce-5910c0afdf583/FTF.pdf'),
PosixPath('ground_truth_to_del/96bb11da-fd24-410d-b0ce-5910c0afdf583/Etiquette.pdf'),
PosixPath('ground_truth_to_del/893dfedc-4757-48e4-9fb4-d9406a3eeffd/FTF.pdf'),
PosixPath('ground_truth_to_del/893dfedc-4757-48e4-9fb4-d9406a3eeffd/Etiquette.pdf'),

```

```

PosixPath('ground_truth_to_del/c2bd1bbc-eef8-4651-a5a2-1698d3946f97/FTF.pdf'),
PosixPath('ground_truth_to_del/c2bd1bbc-eef8-4651-a5a2-1698d3946f97/Etiquette.pdf'),
PosixPath('ground_truth_to_del/ab072de9-3f14-4123-9f48-96526fca6c56/FTF.pdf'),
PosixPath('ground_truth_to_del/ab072de9-3f14-4123-9f48-96526fca6c56/Etiquette.pdf'),
PosixPath('ground_truth_to_del/788b79c1-7c76-437b-8efd-6236719ef581/FTF.pdf'),
PosixPath('ground_truth_to_del/788b79c1-7c76-437b-8efd-6236719ef581/Etiquette.pdf'),
PosixPath('ground_truth_to_del/7bb00c28-475c-439b-850e-934523586183/FTF.pdf'),
PosixPath('ground_truth_to_del/7bb00c28-475c-439b-850e-934523586183/Etiquette.pdf'),
PosixPath('ground_truth_to_del/53c960e0-44c1-45f4-8c7d-14bf0e0f9320/FTF.pdf'),
PosixPath('ground_truth_to_del/ad79138e-76b3-4c61-9f99-274f37106b5d/FTF.pdf'),
PosixPath('ground_truth_to_del/ad79138e-76b3-4c61-9f99-274f37106b5d/Etiquette.pdf'),
PosixPath('ground_truth_to_del/63cdfed5-ac3c-40dd-ba18-cb6c2fcfc720/FTF.pdf'),
PosixPath('ground_truth_to_del/63cdfed5-ac3c-40dd-ba18-cb6c2fcfc720/Etiquette.pdf'),
PosixPath('ground_truth_to_del/bdb32964-19a8-428e-96b6-d154cf75c21e/FTF.pdf'),
PosixPath('ground_truth_to_del/bdb32964-19a8-428e-96b6-d154cf75c21e/Etiquette.pdf'),
PosixPath('ground_truth_to_del/839b3c90-8ba5-43e9-9ef1-c8df822c32ad/FTF.pdf'),
PosixPath('ground_truth_to_del/839b3c90-8ba5-43e9-9ef1-c8df822c32ad/Etiquette.pdf'),
PosixPath('ground_truth_to_del/8a29bd5b-af54-4aad-92ec-be412aa23762/FTF.pdf'),
PosixPath('ground_truth_to_del/8a29bd5b-af54-4aad-92ec-be412aa23762/Etiquette.pdf'),
PosixPath('ground_truth_to_del/67eefe23-cf12-467d-b29c-a3f5cd83b6c/FTF.pdf'),
PosixPath('ground_truth_to_del/8e7c1d8f-4fda-4887-a586-bfd1a7c602ef/FTF.pdf'),
PosixPath('ground_truth_to_del/8e7c1d8f-4fda-4887-a586-bfd1a7c602ef/Etiquette.pdf'),
PosixPath('ground_truth_to_del/a5798100-3aa4-4379-a135-47f1db0c71c6/FTF.pdf'),
PosixPath('ground_truth_to_del/a5798100-3aa4-4379-a135-47f1db0c71c6/Etiquette.pdf'),
PosixPath('ground_truth_to_del/a2231e61-2af0-455e-8d9e-4829fb07fc95/FTF.pdf'),
PosixPath('ground_truth_to_del/738a965a-d13e-41d7-9abd-cc57057f09bc/FTF.pdf'),
PosixPath('ground_truth_to_del/738a965a-d13e-41d7-9abd-cc57057f09bc/Etiquette.pdf'),
PosixPath('ground_truth_to_del/4e0f9670-6b07-44ba-b090-0adb00fa3e52/FTF.pdf'),
PosixPath('ground_truth_to_del/4e0f9670-6b07-44ba-b090-0adb00fa3e52/Etiquette.pdf'),
PosixPath('ground_truth_to_del/caeeba53-d36d-4c6a-9bb2-01453d676a8a/FTF.pdf'),
PosixPath('ground_truth_to_del/caeeba53-d36d-4c6a-9bb2-01453d676a8a/Etiquette.pdf'),
PosixPath('ground_truth_to_del/7f21e89e-0d2e-4964-9c48-77be40d1da23/FTF.pdf'),
PosixPath('ground_truth_to_del/7f21e89e-0d2e-4964-9c48-77be40d1da23/Etiquette.pdf'),
PosixPath('ground_truth_to_del/c0367c75-f8a0-483e-b8c2-6aeedd9db67f7/FTF.pdf'),
PosixPath('ground_truth_to_del/9ae869e-8b7d-4aa0-b8e1-b2f04ab93619/FTF.pdf'),
PosixPath('ground_truth_to_del/83e87248-e70a-4380-9740-d9e3a3c5a8a6/FTF.pdf'),
PosixPath('ground_truth_to_del/83e87248-e70a-4380-9740-d9e3a3c5a8a6/Etiquette.pdf'),
PosixPath('ground_truth_to_del/8ba80236-7350-47e5-ba91-4f233356accb/FTF.pdf'),
PosixPath('ground_truth_to_del/8ba80236-7350-47e5-ba91-4f233356accb/Etiquette.pdf'),
PosixPath('ground_truth_to_del/a7390dc4-26ca-4088-935c-e7f64e2d7992/FTF.pdf'),
PosixPath('ground_truth_to_del/a7390dc4-26ca-4088-935c-e7f64e2d7992/Etiquette.pdf'),
PosixPath('ground_truth_to_del/a1b06a39-74aa-4cd2-9710-c5be4b94aa49/FTF.pdf'),
PosixPath('ground_truth_to_del/a1b06a39-74aa-4cd2-9710-c5be4b94aa49/Etiquette.pdf'),
PosixPath('ground_truth_to_del/bf72f2fe-4d69-495b-91e5-b47fa1d479c1/FTF.pdf'),
PosixPath('ground_truth_to_del/bf72f2fe-4d69-495b-91e5-b47fa1d479c1/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b8e69083-7e07-47c1-abc5-58e232aa1993/FTF.pdf'),
PosixPath('ground_truth_to_del/c2ec5b62-ad27-431e-ab73-01f825d281d3/FTF.pdf'),
PosixPath('ground_truth_to_del/c2ec5b62-ad27-431e-ab73-01f825d281d3/Etiquette.pdf'),
PosixPath('ground_truth_to_del/ca5ff900-9b29-4199-8038-c035b2f6cd10/FTF.pdf'),
PosixPath('ground_truth_to_del/ca5ff900-9b29-4199-8038-c035b2f6cd10/Etiquette.pdf'),
PosixPath('ground_truth_to_del/58d5b983-2e5d-4c55-8302-1c7d8527c90f/FTF.pdf'),
PosixPath('ground_truth_to_del/7b506f91-9fbe-41ea-a2d3-a884ea8cbf0e/FTF.pdf'),
PosixPath('ground_truth_to_del/7b506f91-9fbe-41ea-a2d3-a884ea8cbf0e/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b2f92312-662f-4de4-81b8-5d942a787147/FTF.pdf'),
PosixPath('ground_truth_to_del/863f940d-68e0-46e5-801d-61eb3f6a198a/FTF.pdf'),
PosixPath('ground_truth_to_del/863f940d-68e0-46e5-801d-61eb3f6a198a/Etiquette.pdf'),
PosixPath('ground_truth_to_del/968e17f6-d12b-4044-b09e-09d207363969/FTF.pdf'),
PosixPath('ground_truth_to_del/90071ca9-6ebd-472e-aae1-10b75115ed5d/FTF.pdf'),
PosixPath('ground_truth_to_del/a88c4d42-c6dd-4625-bafb-b9c7538774fe/FTF.pdf'),
PosixPath('ground_truth_to_del/a88c4d42-c6dd-4625-bafb-b9c7538774fe/Etiquette.pdf'),
PosixPath('ground_truth_to_del/c4afdf49b-aac9-4071-a168-d0ba79ab93e6/FTF.pdf'),
PosixPath('ground_truth_to_del/c4afdf49b-aac9-4071-a168-d0ba79ab93e6/Etiquette.pdf'),
PosixPath('ground_truth_to_del/9a4c3a22-1b37-40fe-8125-bd894beb666c/FTF.pdf'),
PosixPath('ground_truth_to_del/9a4c3a22-1b37-40fe-8125-bd894beb666c/Etiquette.pdf'),
PosixPath('ground_truth_to_del/af64570e-5db8-4725-9ab6-abb6b64a352a/FTF.pdf'),
PosixPath('ground_truth_to_del/6dfae8fd-6111-4a57-862e-c20a39a195e0/FTF.pdf'),
PosixPath('ground_truth_to_del/6dfae8fd-6111-4a57-862e-c20a39a195e0/Etiquette.pdf'),

```

```

PosixPath('ground_truth_to_del/b5070184-c3d7-4bfe-b9ec-fb4a736078e9/FTF.pdf'),
PosixPath('ground_truth_to_del/b5070184-c3d7-4bfe-b9ec-fb4a736078e9/Etiquette.pdf'),
PosixPath('ground_truth_to_del/c9cb10ba-8e0e-4cd6-95c3-0384492e16a2/FTF.pdf'),
PosixPath('ground_truth_to_del/c9cb10ba-8e0e-4cd6-95c3-0384492e16a2/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b0a36564-0484-4dbd-a650-fb47dc4479d4/FTF.pdf'),
PosixPath('ground_truth_to_del/b0a36564-0484-4dbd-a650-fb47dc4479d4/Etiquette.pdf'),
PosixPath('ground_truth_to_del/6bcfefa9-ad6a-455f-8082-a62ec93fbfed/FTF.pdf'),
PosixPath('ground_truth_to_del/6bcfefa9-ad6a-455f-8082-a62ec93fbfed/Etiquette.pdf'),
PosixPath('ground_truth_to_del/a7b44e3a-f21a-48e3-b795-df68fd0abbfc/FTF.pdf'),
PosixPath('ground_truth_to_del/cfa42938-99ff-4cd0-a17f-eba8e02b80bc/FTF.pdf'),
PosixPath('ground_truth_to_del/cfa42938-99ff-4cd0-a17f-eba8e02b80bc/Etiquette.pdf'),
PosixPath('ground_truth_to_del/8e8b62fd-aa70-48ce-8327-8273de0953fc/FTF.pdf'),
PosixPath('ground_truth_to_del/8e8b62fd-aa70-48ce-8327-8273de0953fc/Etiquette.pdf'),
PosixPath('ground_truth_to_del/983acaaa-5ecc-436c-9337-559445b5d574/FTF.pdf'),
PosixPath('ground_truth_to_del/983acaaa-5ecc-436c-9337-559445b5d574/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b561ec1e-619d-45cb-8187-6c34b72e5709/FTF.pdf'),
PosixPath('ground_truth_to_del/b561ec1e-619d-45cb-8187-6c34b72e5709/Etiquette.pdf'),
PosixPath('ground_truth_to_del/c37a1706-b948-4715-a32d-b2f6d2713090/FTF.pdf'),
PosixPath('ground_truth_to_del/c37a1706-b948-4715-a32d-b2f6d2713090/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b3e30acc-1c11-454d-b961-b722176ddbaa/FTF.pdf'),
PosixPath('ground_truth_to_del/8260bf89-a518-4db1-83c0-2cd0c6c7ec31/FTF.pdf'),
PosixPath('ground_truth_to_del/8260bf89-a518-4db1-83c0-2cd0c6c7ec31/Etiquette.pdf'),
PosixPath('ground_truth_to_del/8e39f272-8661-4849-ae00-fae4f9d3b8f4/FTF.pdf'),
PosixPath('ground_truth_to_del/8e39f272-8661-4849-ae00-fae4f9d3b8f4/Etiquette.pdf'),
PosixPath('ground_truth_to_del/782ced59-6480-40df-8ed9-7481326cb36e/FTF.pdf'),
PosixPath('ground_truth_to_del/7894f932-cb83-46b8-bea2-ea8ea9406cdc/FTF.pdf'),
PosixPath('ground_truth_to_del/7894f932-cb83-46b8-bea2-ea8ea9406cdc/Etiquette.pdf'),
PosixPath('ground_truth_to_del/8ea164ed-0cdc-4411-bb6e-5f2829380fde/FTF.pdf'),
PosixPath('ground_truth_to_del/8ea164ed-0cdc-4411-bb6e-5f2829380fde/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b39c6669-4c36-485c-b8a7-9443eeb13d21/FTF.pdf'),
PosixPath('ground_truth_to_del/b39c6669-4c36-485c-b8a7-9443eeb13d21/Etiquette.pdf'),
PosixPath('ground_truth_to_del/c87e2024-93ea-4ee9-b44c-4f0342547e15/FTF.pdf'),
PosixPath('ground_truth_to_del/c87e2024-93ea-4ee9-b44c-4f0342547e15/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b86530a4-de47-494a-8a6b-6dcf16941c19/FTF.pdf'),
PosixPath('ground_truth_to_del/b86530a4-de47-494a-8a6b-6dcf16941c19/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b9b0b026-46e2-4a0c-a825-1644c2a7d62f/FTF.pdf'),
PosixPath('ground_truth_to_del/b9b0b026-46e2-4a0c-a825-1644c2a7d62f/Etiquette.pdf'),
PosixPath('ground_truth_to_del/78f66d90-aeab-4f15-8130-0c418955b79a/FTF.pdf'),
PosixPath('ground_truth_to_del/cb015766-94a6-48e0-8fac-78bd5db2728e/FTF.pdf'),
PosixPath('ground_truth_to_del/cb015766-94a6-48e0-8fac-78bd5db2728e/Etiquette.pdf'),
PosixPath('ground_truth_to_del/9c1dcef2-8bca-4e23-b91f-81c62c528c2e/FTF.pdf'),
PosixPath('ground_truth_to_del/7f0bbe42-b8e2-49a0-ac04-04f65ca87b4e/FTF.pdf'),
PosixPath('ground_truth_to_del/7f0bbe42-b8e2-49a0-ac04-04f65ca87b4e/Etiquette.pdf'),
PosixPath('ground_truth_to_del/cc4680e4-7d20-4a2c-9bec-5c595bfb8526/FTF.pdf'),
PosixPath('ground_truth_to_del/b60a24c8-0b3b-4a9f-905a-11429661f10b/FTF.pdf'),
PosixPath('ground_truth_to_del/b60a24c8-0b3b-4a9f-905a-11429661f10b/Etiquette.pdf'),
PosixPath('ground_truth_to_del/bbff7cc2-9cb3-4749-b999-aa8be91d3ccb/FTF.pdf'),
PosixPath('ground_truth_to_del/bbff7cc2-9cb3-4749-b999-aa8be91d3ccb/Etiquette.pdf'),
PosixPath('ground_truth_to_del/9926b0bc-dc03-421e-9013-717de629b4b3/FTF.pdf'),
PosixPath('ground_truth_to_del/d25690a9-3420-407b-9f39-bdac27594020/FTF.pdf'),
PosixPath('ground_truth_to_del/d25690a9-3420-407b-9f39-bdac27594020/Etiquette.pdf'),
PosixPath('ground_truth_to_del/dad4dfb5-37a7-4ca3-921b-d687051cf91b/FTF.pdf'),
PosixPath('ground_truth_to_del/dad4dfb5-37a7-4ca3-921b-d687051cf91b/Etiquette.pdf'),
PosixPath('ground_truth_to_del/9ada31f4-aef5-46ce-b1ef-e7288589191d/FTF.pdf'),
PosixPath('ground_truth_to_del/9ada31f4-aef5-46ce-b1ef-e7288589191d/Etiquette.pdf'),
PosixPath('ground_truth_to_del/9bfe7487-3e9d-489c-a42e-8663f3ce473a/FTF.pdf'),
PosixPath('ground_truth_to_del/9bfe7487-3e9d-489c-a42e-8663f3ce473a/Etiquette.pdf'),
PosixPath('ground_truth_to_del/97927229-25b0-4fa7-9a34-0cf7a48bc6d1/FTF.pdf'),
PosixPath('ground_truth_to_del/97927229-25b0-4fa7-9a34-0cf7a48bc6d1/Etiquette.pdf'),
PosixPath('ground_truth_to_del/cbb0ff54-fd0d-4e56-a87d-5e9d80d71d20/FTF.pdf'),
PosixPath('ground_truth_to_del/cbb0ff54-fd0d-4e56-a87d-5e9d80d71d20/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b7a5df3b-42b4-4cde-ae39-18f0e7a5f776/FTF.pdf'),
PosixPath('ground_truth_to_del/b7a5df3b-42b4-4cde-ae39-18f0e7a5f776/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b6ea6ae1-4ce2-4cab-8ce3-cbbf3c3ceb57/FTF.pdf'),
PosixPath('ground_truth_to_del/bb77c7b0-9c63-4869-9ab1-823ba1158f53/FTF.pdf'),
PosixPath('ground_truth_to_del/707dac16-6545-4cbd-94db-279f0306964f/FTF.pdf'),
PosixPath('ground_truth_to_del/707dac16-6545-4cbd-94db-279f0306964f/Etiquette.pdf'),

```

```

PosixPath('ground_truth_to_del/cdd9fa40-2400-4019-aae1-a108a0ab85df/FTF.pdf'),
PosixPath('ground_truth_to_del/d4c8d13b-3436-4fac-aaa0-5fb6bcfc512e/FTF.pdf'),
PosixPath('ground_truth_to_del/d4c8d13b-3436-4fac-aaa0-5fb6bcfc512e/Etiquette.pdf'),
PosixPath('ground_truth_to_del/9d5115c2-2d09-4332-8251-4dd0e50062c2/FTF.pdf'),
PosixPath('ground_truth_to_del/9d5115c2-2d09-4332-8251-4dd0e50062c2/Etiquette.pdf'),
PosixPath('ground_truth_to_del/97c80844-08c7-45c6-82ac-43ab8a45f2e4/FTF.pdf'),
PosixPath('ground_truth_to_del/97c80844-08c7-45c6-82ac-43ab8a45f2e4/Etiquette.pdf'),
PosixPath('ground_truth_to_del/bca98605-c6d9-48e7-abcb-ed6ae683e7c3/FTF.pdf'),
PosixPath('ground_truth_to_del/bca98605-c6d9-48e7-abcb-ed6ae683e7c3/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b3c92704-1d91-4d73-a66a-167327e355b2/FTF.pdf'),
PosixPath('ground_truth_to_del/b3c92704-1d91-4d73-a66a-167327e355b2/Etiquette.pdf'),
PosixPath('ground_truth_to_del/7a435ec1-a768-452b-bb9e-dda2e647c61c/FTF.pdf'),
PosixPath('ground_truth_to_del/7a435ec1-a768-452b-bb9e-dda2e647c61c/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b9e7afcd-3c0b-411d-805f-a51c4c8436c5/FTF.pdf'),
PosixPath('ground_truth_to_del/b9e7afcd-3c0b-411d-805f-a51c4c8436c5/Etiquette.pdf'),
PosixPath('ground_truth_to_del/f3b89340-1516-42c3-bd93-a9e9da47af54/FTF.pdf'),
PosixPath('ground_truth_to_del/f3b89340-1516-42c3-bd93-a9e9da47af54/Etiquette.pdf'),
PosixPath('ground_truth_to_del/a99724f6-f303-4041-a63f-ad3dc7c529f6/FTF.pdf'),
PosixPath('ground_truth_to_del/aa237379-7a35-4fcfd-9225-906222bcf55a/FTF.pdf'),
PosixPath('ground_truth_to_del/aa237379-7a35-4fcfd-9225-906222bcf55a/Etiquette.pdf'),
PosixPath('ground_truth_to_del/f14c6afc-dac9-4e89-8fec-7ac66627f52d/FTF.pdf'),
PosixPath('ground_truth_to_del/cfeeb3b22-4088-48e3-89d8-02e78af07054/FTF.pdf'),
PosixPath('ground_truth_to_del/84343728-020d-4ded-ae19-eaf71395756f/FTF.pdf'),
PosixPath('ground_truth_to_del/ce1ce2e3-d28d-44da-a0f3-df99846904b6/FTF.pdf'),
PosixPath('ground_truth_to_del/ce1ce2e3-d28d-44da-a0f3-df99846904b6/Etiquette.pdf'),
PosixPath('ground_truth_to_del/c31db91f-753f-4938-8ab6-2923579476dc/FTF.pdf'),
PosixPath('ground_truth_to_del/c31db91f-753f-4938-8ab6-2923579476dc/Etiquette.pdf'),
PosixPath('ground_truth_to_del/e8483810-e780-4497-b8a1-a5aa7b5eb36c/FTF.pdf'),
PosixPath('ground_truth_to_del/e8483810-e780-4497-b8a1-a5aa7b5eb36c/Etiquette.pdf'),
PosixPath('ground_truth_to_del/cf01abbe-bf45-4e36-ba64-f4d5b673b361/FTF.pdf'),
PosixPath('ground_truth_to_del/c4e2c917-88e6-4f7c-be63-979305c633ac/FTF.pdf'),
PosixPath('ground_truth_to_del/dbfc7769-f4d4-4167-99e3-f79f5896bef9/FTF.pdf'),
PosixPath('ground_truth_to_del/b919bb22-4f3f-4981-8ba7-5ebce3a53f9b/FTF.pdf'),
PosixPath('ground_truth_to_del/d4650e67-9bc8-477d-952e-c7d0a1507521/FTF.pdf'),
PosixPath('ground_truth_to_del/d4650e67-9bc8-477d-952e-c7d0a1507521/Etiquette.pdf'),
PosixPath('ground_truth_to_del/a67e1ede-379d-499a-af95-50b94fdbd93c4/FTF.pdf'),
PosixPath('ground_truth_to_del/a67e1ede-379d-499a-af95-50b94fdbd93c4/Etiquette.pdf'),
PosixPath('ground_truth_to_del/bb30962c-f1c3-4c0b-a3f0-122928af3573/FTF.pdf'),
PosixPath('ground_truth_to_del/bb30962c-f1c3-4c0b-a3f0-122928af3573/Etiquette.pdf'),
PosixPath('ground_truth_to_del/a01039be-eb79-454f-a384-c142d1d80d0c/FTF.pdf'),
PosixPath('ground_truth_to_del/a01039be-eb79-454f-a384-c142d1d80d0c/Etiquette.pdf'),
PosixPath('ground_truth_to_del/d3565933-8ed8-483d-9bcd-177ca1376aa3/FTF.pdf'),
PosixPath('ground_truth_to_del/d3565933-8ed8-483d-9bcd-177ca1376aa3/Etiquette.pdf'),
PosixPath('ground_truth_to_del/80aa76b6-8fe9-48ea-b33d-56b14cd1107f/FTF.pdf'),
PosixPath('ground_truth_to_del/80aa76b6-8fe9-48ea-b33d-56b14cd1107f/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b638ab96-427c-4d5f-9a19-74684eec3b8e/FTF.pdf'),
PosixPath('ground_truth_to_del/b638ab96-427c-4d5f-9a19-74684eec3b8e/Etiquette.pdf'),
PosixPath('ground_truth_to_del/8eff65aa-c812-4c63-9d86-91b247e8d6d8/FTF.pdf'),
PosixPath('ground_truth_to_del/8eff65aa-c812-4c63-9d86-91b247e8d6d8/Etiquette.pdf'),
PosixPath('ground_truth_to_del/be0e1b79-7360-4264-8f79-a018c55d9976/FTF.pdf'),
PosixPath('ground_truth_to_del/be0e1b79-7360-4264-8f79-a018c55d9976/Etiquette.pdf'),
PosixPath('ground_truth_to_del/c3e1e0b-4b56-40a0-9721-bfc7c7ec0ac7/FTF.pdf'),
PosixPath('ground_truth_to_del/cea79935-0f0b-4ee1-bd64-c4528c1d0577/FTF.pdf'),
PosixPath('ground_truth_to_del/cea79935-0f0b-4ee1-bd64-c4528c1d0577/Etiquette.pdf'),
PosixPath('ground_truth_to_del/a815ca2b-a478-4262-8555-04d684383eb0/FTF.pdf'),
PosixPath('ground_truth_to_del/a815ca2b-a478-4262-8555-04d684383eb0/Etiquette.pdf'),
PosixPath('ground_truth_to_del/8885c209-a0b8-47cb-88cf-3a3b99eaecd/FTF.pdf'),
PosixPath('ground_truth_to_del/8885c209-a0b8-47cb-88cf-3a3b99eaecd/Etiquette.pdf'),
PosixPath('ground_truth_to_del/c96f95bb-46ab-475e-a272-7c8116595a96/FTF.pdf'),
PosixPath('ground_truth_to_del/a22ecb09-c5ad-44f1-bbcf-22800e37a328/FTF.pdf'),
PosixPath('ground_truth_to_del/c6e9b9a0-9dd6-4894-bd10-7dce4c87d168/FTF.pdf'),
PosixPath('ground_truth_to_del/c6e9b9a0-9dd6-4894-bd10-7dce4c87d168/Etiquette.pdf'),
PosixPath('ground_truth_to_del/dab3c8e0-7918-4f5c-bd0b-7d9451016f23/FTF.pdf'),
PosixPath('ground_truth_to_del/f9da27e6-8d1e-474b-95db-0a8dee4a3f16/FTF.pdf'),
PosixPath('ground_truth_to_del/f9da27e6-8d1e-474b-95db-0a8dee4a3f16/Etiquette.pdf'),
PosixPath('ground_truth_to_del/d6c22c1e-596c-407a-a2e3-f42925a6fd8b/FTF.pdf'),
PosixPath('ground_truth_to_del/d6c22c1e-596c-407a-a2e3-f42925a6fd8b/Etiquette.pdf'),

```

```

PosixPath('ground_truth_to_del/d0aa2c1c-4317-4e5f-8a18-82e56976da22/FTF.pdf'),
PosixPath('ground_truth_to_del/d0aa2c1c-4317-4e5f-8a18-82e56976da22/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b475b46b-93f4-42fb-872f-e6a1ca3981df/FTF.pdf'),
PosixPath('ground_truth_to_del/b475b46b-93f4-42fb-872f-e6a1ca3981df/Etiquette.pdf'),
PosixPath('ground_truth_to_del/dbecb512-cf81-4b1b-b007-8c86e00baf29/FTF.pdf'),
PosixPath('ground_truth_to_del/dbecb512-cf81-4b1b-b007-8c86e00baf29/Etiquette.pdf'),
PosixPath('ground_truth_to_del/fd93a14a-cd9f-413a-89fd-8cb998430bd0/FTF.pdf'),
PosixPath('ground_truth_to_del/df964d22-740e-4580-9338-24fd1ec1c61c/FTF.pdf'),
PosixPath('ground_truth_to_del/bc885cccd-fbfd-41c8-8dd7-9ac5d4749b94/FTF.pdf'),
PosixPath('ground_truth_to_del/cfe1ffaa-5b83-43aa-a360-c9a6b97c2de3/FTF.pdf'),
PosixPath('ground_truth_to_del/e4ba93f3-d844-4b6c-8f98-40e43971b730/FTF.pdf'),
PosixPath('ground_truth_to_del/e0a6ed2b-a780-4732-90b8-5201e856bf95/FTF.pdf'),
PosixPath('ground_truth_to_del/e0a6ed2b-a780-4732-90b8-5201e856bf95/Etiquette.pdf'),
PosixPath('ground_truth_to_del/f636ba33-394e-47c9-9384-cf973acdf679/FTF.pdf'),
PosixPath('ground_truth_to_del/f636ba33-394e-47c9-9384-cf973acdf679/Etiquette.pdf'),
PosixPath('ground_truth_to_del/aff93d0f-a94c-4e9b-a6ca-d69115e3d2eb/FTF.pdf'),
PosixPath('ground_truth_to_del/aff93d0f-a94c-4e9b-a6ca-d69115e3d2eb/Etiquette.pdf'),
PosixPath('ground_truth_to_del/caac2411-37de-4acc-ba20-16793ce994b2/FTF.pdf'),
PosixPath('ground_truth_to_del/c623b01e-ed13-4019-b4c4-3801022e997a/FTF.pdf'),
PosixPath('ground_truth_to_del/c623b01e-ed13-4019-b4c4-3801022e997a/Etiquette.pdf'),
PosixPath('ground_truth_to_del/fa661e96-0fbd-4556-a05e-8c214e1fea55/FTF.pdf'),
PosixPath('ground_truth_to_del/bc0aa8ac-d655-466e-8218-2ab125161864/FTF.pdf'),
PosixPath('ground_truth_to_del/bc0aa8ac-d655-466e-8218-2ab125161864/Etiquette.pdf'),
PosixPath('ground_truth_to_del/dd3034af-995e-46a9-a843-3594d0a016d6/FTF.pdf'),
PosixPath('ground_truth_to_del/e22b43ec-9483-467b-9ed7-3114ffe07471/FTF.pdf'),
PosixPath('ground_truth_to_del/e22b43ec-9483-467b-9ed7-3114ffe07471/Etiquette.pdf'),
PosixPath('ground_truth_to_del/bb97d002-80ee-4b67-84fe-e90dc17b6131/FTF.pdf'),
PosixPath('ground_truth_to_del/c9710e1e-2460-404d-8646-d158fe0c47a5/FTF.pdf'),
PosixPath('ground_truth_to_del/c9710e1e-2460-404d-8646-d158fe0c47a5/Etiquette.pdf'),
PosixPath('ground_truth_to_del/a4b49c76-7a12-444c-bd12-76a29e18a8fa/FTF.pdf'),
PosixPath('ground_truth_to_del/a4b49c76-7a12-444c-bd12-76a29e18a8fa/Etiquette.pdf'),
PosixPath('ground_truth_to_del/86614ab1-35ec-449e-807d-22b5486f0792/FTF.pdf'),
PosixPath('ground_truth_to_del/86614ab1-35ec-449e-807d-22b5486f0792/Etiquette.pdf'),
PosixPath('ground_truth_to_del/fddb2a79-96a7-4de4-80d4-3f8f30e29bb4/FTF.pdf'),
PosixPath('ground_truth_to_del/fddb2a79-96a7-4de4-80d4-3f8f30e29bb4/Etiquette.pdf'),
PosixPath('ground_truth_to_del/d4e2059a-d5ff-491a-ab21-990e548a5d64/FTF.pdf'),
PosixPath('ground_truth_to_del/bb9fff12-bac3-4032-863e-9059d92f1826/FTF.pdf'),
PosixPath('ground_truth_to_del/bb9fff12-bac3-4032-863e-9059d92f1826/Etiquette.pdf'),
PosixPath('ground_truth_to_del/c36d6a1a-7270-4827-b08a-df429ee7d632/FTF.pdf'),
PosixPath('ground_truth_to_del/c36d6a1a-7270-4827-b08a-df429ee7d632/Etiquette.pdf'),
PosixPath('ground_truth_to_del/e9e5c115-bdf5-401e-a08f-3a333e5de258/FTF.pdf'),
PosixPath('ground_truth_to_del/e011e426-9bfe-4bc7-ae48-250b8627d91d/FTF.pdf'),
PosixPath('ground_truth_to_del/e011e426-9bfe-4bc7-ae48-250b8627d91d/Etiquette.pdf'),
PosixPath('ground_truth_to_del/f8e45e3d-1b59-4e0b-b829-17691eaef73d/FTF.pdf'),
PosixPath('ground_truth_to_del/c9c05f33-afc1-4b78-8391-2bcba74887a7/FTF.pdf'),
PosixPath('ground_truth_to_del/c9c05f33-afc1-4b78-8391-2bcba74887a7/Etiquette.pdf'),
PosixPath('ground_truth_to_del/dad957b1-4be6-4879-8ea2-f071075e538a/FTF.pdf'),
PosixPath('ground_truth_to_del/e018cf7b-1a4a-41d1-94c6-77094ff00d96/FTF.pdf'),
PosixPath('ground_truth_to_del/fd8d7574-7623-45a9-8c10-87d04b2b0116/FTF.pdf'),
PosixPath('ground_truth_to_del/fd8d7574-7623-45a9-8c10-87d04b2b0116/Etiquette.pdf'),
PosixPath('ground_truth_to_del/9e17df34-5dcf-476d-a344-149cd4bb1f3/FTF.pdf'),
PosixPath('ground_truth_to_del/ed51940f-60cf-45a6-922a-7fee0309e6ed/FTF.pdf'),
PosixPath('ground_truth_to_del/eda2d8db-110c-4c97-a7a0-4ff1f3eff74c/FTF.pdf'),
PosixPath('ground_truth_to_del/eda2d8db-110c-4c97-a7a0-4ff1f3eff74c/Etiquette.pdf'),
PosixPath('ground_truth_to_del/df1caa23-9714-4659-803b-33501d64eedad/FTF.pdf'),
PosixPath('ground_truth_to_del/df1caa23-9714-4659-803b-33501d64eedad/Etiquette.pdf'),
PosixPath('ground_truth_to_del/d3a5d9b9-1d0d-4ac8-917c-e1d05954fa21/FTF.pdf'),
PosixPath('ground_truth_to_del/b5893ad9-59a8-412d-a88d-4e10617f9e29/FTF.pdf'),
PosixPath('ground_truth_to_del/bca406a2-8e27-4229-b3e7-505006f2551d/FTF.pdf'),
PosixPath('ground_truth_to_del/bca406a2-8e27-4229-b3e7-505006f2551d/Etiquette.pdf'),
PosixPath('ground_truth_to_del/a9403de3-26d5-4461-bbc6-53980b502b99/FTF.pdf'),
PosixPath('ground_truth_to_del/a9403de3-26d5-4461-bbc6-53980b502b99/Etiquette.pdf'),
PosixPath('ground_truth_to_del/bf3d495d-550a-4c2d-b06d-c44339cc565a/FTF.pdf'),
PosixPath('ground_truth_to_del/bf3d495d-550a-4c2d-b06d-c44339cc565a/Etiquette.pdf'),
PosixPath('ground_truth_to_del/bdd6a678-5952-4162-9322-bccaf90657be/FTF.pdf'),
PosixPath('ground_truth_to_del/bdd6a678-5952-4162-9322-bccaf90657be/Etiquette.pdf'),
PosixPath('ground_truth_to_del/d12dcce0-f2a7-4417-89d3-ee7437d30b84/FTF.pdf'),

```

```

PosixPath('ground_truth_to_del/d41a751b-8a77-4cf0-85f5-a4c23a6459d9/FTF.pdf'),
PosixPath('ground_truth_to_del/d41a751b-8a77-4cf0-85f5-a4c23a6459d9/Etiquette.pdf'),
PosixPath('ground_truth_to_del/b7094b50-62d5-4cf2-859d-326b6bcc1a1f/FTF.pdf'),
PosixPath('ground_truth_to_del/ed183968-fd85-422f-9b0b-756c0d80be85/FTF.pdf'),
PosixPath('ground_truth_to_del/99ef557a-2e7c-481c-a7b0-6cfa69968ccf/FTF.pdf'),
PosixPath('ground_truth_to_del/99ef557a-2e7c-481c-a7b0-6cfa69968ccf/Etiquette.pdf'),
PosixPath('ground_truth_to_del/f53d1e57-aef7-45a3-8cdc-d36d044384d0/FTF.pdf'),
PosixPath('ground_truth_to_del/f53d1e57-aef7-45a3-8cdc-d36d044384d0/Etiquette.pdf'),
PosixPath('ground_truth_to_del/ed969c94-33a2-4a82-bc84-0d4adc908f5c/FTF.pdf'),
PosixPath('ground_truth_to_del/ed969c94-33a2-4a82-bc84-0d4adc908f5c/Etiquette.pdf'),
PosixPath('ground_truth_to_del/f42e19ae-d433-410d-a28d-ca01127b0ded/FTF.pdf'),
PosixPath('ground_truth_to_del/f42e19ae-d433-410d-a28d-ca01127b0ded/Etiquette.pdf'),
PosixPath('ground_truth_to_del/dbe7543f-247d-4c5b-ae19-f775bc72d7bf/FTF.pdf'),
PosixPath('ground_truth_to_del/dbe7543f-247d-4c5b-ae19-f775bc72d7bf/Etiquette.pdf'),
PosixPath('ground_truth_to_del/f538d88b-d6ba-4be7-af1d-f951da2f23ac/FTF.pdf'),
PosixPath('ground_truth_to_del/f538d88b-d6ba-4be7-af1d-f951da2f23ac/Etiquette.pdf'),
PosixPath('ground_truth_to_del/d8a87d0c-26f6-4e3f-b50a-250fcf5ff879/FTF.pdf'),
PosixPath('ground_truth_to_del/d8a87d0c-26f6-4e3f-b50a-250fcf5ff879/Etiquette.pdf'),
PosixPath('ground_truth_to_del/ec583f94-8e7f-42ff-945b-06a302dfb927/FTF.pdf'),
PosixPath('ground_truth_to_del/ec583f94-8e7f-42ff-945b-06a302dfb927/Etiquette.pdf'),
PosixPath('ground_truth_to_del/aa0fabcd-8858-42fa-84ce-f73df50d113e/FTF.pdf'),
PosixPath('ground_truth_to_del/aa0fabcd-8858-42fa-84ce-f73df50d113e/Etiquette.pdf'),
PosixPath('ground_truth_to_del/dc1728ee-6c93-4230-b0ce-a66c244a541a/FTF.pdf'),
PosixPath('ground_truth_to_del/dc1728ee-6c93-4230-b0ce-a66c244a541a/Etiquette.pdf'),
PosixPath('ground_truth_to_del/db65f752-6e5b-4099-a5cc-00e1d39fbdf8/FTF.pdf'),
PosixPath('ground_truth_to_del/e011208a-0a43-44be-b9a3-3b21e19b21a2/FTF.pdf'),
PosixPath('ground_truth_to_del/f4992fdb-3c1c-4bf0-8a8a-39984a903d44/FTF.pdf'),
PosixPath('ground_truth_to_del/fffff282d-55d7-4551-b1f0-ef71ac1a06f7/FTF.pdf'),
PosixPath('ground_truth_to_del/fffff282d-55d7-4551-b1f0-ef71ac1a06f7/Etiquette.pdf'),
PosixPath('ground_truth_to_del/efa73d98-2771-4d61-8e86-bfe8dd5c8c1a/FTF.pdf'),
PosixPath('ground_truth_to_del/efa73d98-2771-4d61-8e86-bfe8dd5c8c1a/Etiquette.pdf'),
PosixPath('ground_truth_to_del/cb641c37-2769-49e2-96dc-a0685c24baf2/FTF.pdf'),
PosixPath('ground_truth_to_del/da73df6-37a7-469c-85e5-b1b2ca5b8eb3/FTF.pdf'),
PosixPath('ground_truth_to_del/da73df6-37a7-469c-85e5-b1b2ca5b8eb3/Etiquette.pdf'),
PosixPath('ground_truth_to_del/e6adf15b-64a2-4551-9692-55e64f527310/FTF.pdf'),
PosixPath('ground_truth_to_del/e6adf15b-64a2-4551-9692-55e64f527310/Etiquette.pdf'),
PosixPath('ground_truth_to_del/cdc90ab0-4d7c-400c-abb1-6dad87a1f546/FTF.pdf'),
PosixPath('ground_truth_to_del/cdc90ab0-4d7c-400c-abb1-6dad87a1f546/Etiquette.pdf'),
PosixPath('ground_truth_to_del/ad2dc48-b6af-48f1-8644-67313012369d/FTF.pdf'),
PosixPath('ground_truth_to_del/addbd338-494e-4298-bc81-931b354bec13/FTF.pdf'),
PosixPath('ground_truth_to_del/addbd338-494e-4298-bc81-931b354bec13/Etiquette.pdf'),
PosixPath('ground_truth_to_del/eac51cd5-6d9f-4dec-b2b5-84127e0792c8/FTF.pdf'),
PosixPath('ground_truth_to_del/eac51cd5-6d9f-4dec-b2b5-84127e0792c8/Etiquette.pdf'),
PosixPath('ground_truth_to_del/a9dab01d-54dd-4b3b-a654-f2b0bcbac48f/FTF.pdf'),
PosixPath('ground_truth_to_del/a9dab01d-54dd-4b3b-a654-f2b0bcbac48f/Etiquette.pdf'),
PosixPath('ground_truth_to_del/f81aea52-37aa-44e7-bdd4-1fad066a1a3f/FTF.pdf'),
PosixPath('ground_truth_to_del/f81aea52-37aa-44e7-bdd4-1fad066a1a3f/Etiquette.pdf'),
PosixPath('ground_truth_to_del/f1309778-89e6-4e4f-96ff-e9cfaf2f577c/FTF.pdf'),
PosixPath('ground_truth_to_del/e2f325c7-3a48-45bd-84ba-c9da92150af5/FTF.pdf'),
PosixPath('ground_truth_to_del/eb0ae514-ab4d-4c01-908a-fb6ed0788697/FTF.pdf'),
PosixPath('ground_truth_to_del/c679c923-cf39-4e40-b072-7474928450c6/FTF.pdf'),
PosixPath('ground_truth_to_del/c679c923-cf39-4e40-b072-7474928450c6/Etiquette.pdf'),
PosixPath('ground_truth_to_del/ebdaef9f-936f-45fc-9ea3-a3c7b56e8ce7/FTF.pdf'),
PosixPath('ground_truth_to_del/fe2463ab-0d5d-435d-9dbb-83193fe7d881/FTF.pdf'),
PosixPath('ground_truth_to_del/fe2463ab-0d5d-435d-9dbb-83193fe7d881/Etiquette.pdf'),
PosixPath('ground_truth_to_del/f9771288-d694-4dbd-92e2-7d2a1c7f91b3/FTF.pdf'),
PosixPath('ground_truth_to_del/f9771288-d694-4dbd-92e2-7d2a1c7f91b3/Etiquette.pdf'),
PosixPath('ground_truth_to_del/e20486db-56a2-4f68-81c7-1e65a00240ab/FTF.pdf'),
PosixPath('ground_truth_to_del/e20486db-56a2-4f68-81c7-1e65a00240ab/Etiquette.pdf'),
PosixPath('ground_truth_to_del/dea3a70b-abde-4694-9df3-dd668029ea6a/FTF.pdf'),
PosixPath('ground_truth_to_del/dea3a70b-abde-4694-9df3-dd668029ea6a/Etiquette.pdf'),
PosixPath('ground_truth_to_del/f4b720ef-4123-4aed-95c2-c01fc911ca86/FTF.pdf'),
PosixPath('ground_truth_to_del/f4b720ef-4123-4aed-95c2-c01fc911ca86/Etiquette.pdf'),
PosixPath('ground_truth_to_del/e2543a15-0c76-4aac-b351-29f7bf4a39fc/FTF.pdf'),
PosixPath('ground_truth_to_del/e2543a15-0c76-4aac-b351-29f7bf4a39fc/Etiquette.pdf'),
PosixPath('ground_truth_to_del/faa4ec95-528d-49da-92ef-818f0730a3f7/FTF.pdf'),
PosixPath('ground_truth_to_del/faa4ec95-528d-49da-92ef-818f0730a3f7/Etiquette.pdf'),

```

```

PosixPath('ground_truth_to_del/fc04906f-ed9c-4a63-8b0e-aefb6c8a88e9/FTF.pdf'),
PosixPath('ground_truth_to_del/e6fc0e9b-7683-40d8-8806-2a8f56338972/FTF.pdf'),
PosixPath('ground_truth_to_del/e6fc0e9b-7683-40d8-8806-2a8f56338972/Etiquette.pdf'),
PosixPath('ground_truth_to_del/d1365e91-a8d5-4dcf-8e65-fb2ce58149cb/FTF.pdf'),
PosixPath('ground_truth_to_del/d1365e91-a8d5-4dcf-8e65-fb2ce58149cb/Etiquette.pdf'),
PosixPath('ground_truth_to_del/be74795-a388-4d89-b245-f067c2323907/FTF.pdf'),
PosixPath('ground_truth_to_del/b74d5082-3335-4547-9624-ec5fcbb8b803b/FTF.pdf'),
PosixPath('ground_truth_to_del/b74d5082-3335-4547-9624-ec5fcbb8b803b/Etiquette.pdf'),
PosixPath('ground_truth_to_del/fdfdb6f7-296d-410c-baa3-34c422889aa9/FTF.pdf'),
PosixPath('ground_truth_to_del/dddacc22-387d-4a6e-bc83-b6df62f8dd77/FTF.pdf'),
PosixPath('ground_truth_to_del/dddacc22-387d-4a6e-bc83-b6df62f8dd77/Etiquette.pdf'),
PosixPath('ground_truth_to_del/ea0c2ff0-d1e4-48d9-bfbc-c023cb69e9b5/FTF.pdf'),
PosixPath('ground_truth_to_del/ea0c2ff0-d1e4-48d9-bfbc-c023cb69e9b5/Etiquette.pdf'),
PosixPath('ground_truth_to_del/f81724f9-8342-4976-89a5-c97a687c4d41/FTF.pdf'),
PosixPath('ground_truth_to_del/f81724f9-8342-4976-89a5-c97a687c4d41/Etiquette.pdf'),
PosixPath('ground_truth_to_del/f0666c76-b95b-473b-9df6-dd14c95c0de1/FTF.pdf'),
PosixPath('ground_truth_to_del/eff84bd9-7753-474d-9e0e-b1f538f01eb3/FTF.pdf'),
PosixPath('ground_truth_to_del/eff84bd9-7753-474d-9e0e-b1f538f01eb3/Etiquette.pdf'),
PosixPath('ground_truth_to_del/bb3b8b35-c277-4cc7-870f-83589d30f155/FTF.pdf'),
PosixPath('ground_truth_to_del/bb3b8b35-c277-4cc7-870f-83589d30f155/Etiquette.pdf'),
PosixPath('ground_truth_to_del/f7815bab-7817-41e9-a32b-42db912f303f/FTF.pdf'),
PosixPath('ground_truth_to_del/e36a5a29-5080-4b71-a1e3-ad2532efbd6c/FTF.pdf'),
PosixPath('ground_truth_to_del/e36a5a29-5080-4b71-a1e3-ad2532efbd6c/Etiquette.pdf'),
PosixPath('ground_truth_to_del/c26ac97a-cb9e-471c-9539-3465ece703e9/FTF.pdf'),
PosixPath('ground_truth_to_del/c26ac97a-cb9e-471c-9539-3465ece703e9/Etiquette.pdf'),
PosixPath('ground_truth_to_del/fbee557f-b7ca-4139-bd1a-74b72e038abb/FTF.pdf'),
PosixPath('ground_truth_to_del/d4a3d3bae-54e5-48e8-8aba-0775ea2e8ea8/FTF.pdf'),
PosixPath('ground_truth_to_del/f3a20b67-2867-4c50-84a6-788d775ad141/FTF.pdf'),
PosixPath('ground_truth_to_del/f9b848ba-78ba-46f1-834c-48282ff7689b/FTF.pdf'),
PosixPath('ground_truth_to_del/ef8afbbb-efbc-4fdf-aa1c-6f664f2c1073/FTF.pdf'),
PosixPath('ground_truth_to_del/d5f1fddc-8be7-4acd-a138-4a13ba4d26bf/FTF.pdf'),
PosixPath('ground_truth_to_del/febcb6e6f-dec9-4759-a2e2-407bb23ae878/FTF.pdf'),
PosixPath('ground_truth_to_del/febcb6e6f-dec9-4759-a2e2-407bb23ae878/Etiquette.pdf'),
PosixPath('ground_truth_to_del/fb158edf-043b-48a5-afa5-90a5eb9d6d6a/FTF.pdf'),
PosixPath('ground_truth_to_del/f69fbcb61-7c0b-41d1-826f-a377c32331d8/FTF.pdf'),
PosixPath('ground_truth_to_del/f69fbcb61-7c0b-41d1-826f-a377c32331d8/Etiquette.pdf'),
PosixPath('ground_truth_to_del/d8232b0f-8dd5-417f-8691-1018681bc434/FTF.pdf'),
PosixPath('ground_truth_to_del/d8232b0f-8dd5-417f-8691-1018681bc434/Etiquette.pdf'),
PosixPath('ground_truth_to_del/feb1a72c-02b7-43b0-a3ab-14eb6d574d5b/FTF.pdf'),
PosixPath('ground_truth_to_del/feb1a72c-02b7-43b0-a3ab-14eb6d574d5b/Etiquette.pdf'),
PosixPath('ground_truth_to_del/fd60af94-6874-4592-b1b6-faf00e7f03d9/FTF.pdf')

```

```

[33]: files_df = pd.DataFrame(list(p.glob('**/*.pdf')), columns=['path'])
files_df['type'] = files_df['path'].apply(lambda x: x.name).apply(lambda x: x.split('.')[0])
files_df['uid'] = files_df['path'].apply(lambda x: x.parent.name)
files_df.set_index('uid', inplace=True)
files_df

```

	path	type
uid		
1bca5540-b129-4593-a1e9-fa909234ad39	ground_truth_to_del/1bca5540-b129-4593-a1e9-fa...	FTF
1bca5540-b129-4593-a1e9-fa909234ad39	ground_truth_to_del/1bca5540-b129-4593-a1e9-fa... Etiquette	
0111c5f2-f00b-4fba-a266-716b3909f4b5	ground_truth_to_del/0111c5f2-f00b-4fba-a266-71...	FTF
...
feb1a72c-02b7-43b0-a3ab-14eb6d574d5b	ground_truth_to_del/feb1a72c-02b7-43b0-a3ab-14...	FTF
feb1a72c-02b7-43b0-a3ab-14eb6d574d5b	ground_truth_to_del/feb1a72c-02b7-43b0-a3ab-14... Etiquette	
fd60af94-6874-4592-b1b6-faf00e7f03d9	ground_truth_to_del/fd60af94-6874-4592-b1b6-fa...	FTF

[815 rows x 2 columns]

On utilise les transformateur du module pimest pour récupérer le contenu de ces fichiers dans le datafram.

```

[41]: transformer = make_pipeline(ContentGetter(), PDFContentParser())
files_df = transformer.fit_transform(files_df)
files_df

```

Launching 8 processes.

```
[41]:
```

uid	path	type	\
1bca5540-b129-4593-a1e9-fa909234ad39	ground_truth_to_del/1bca5540-b129-4593-a1e9-fa...	FTF	
1bca5540-b129-4593-a1e9-fa909234ad39	ground_truth_to_del/1bca5540-b129-4593-a1e9-fa...	Etiquette	
0111c5f2-f00b-4fba-a266-716b3909f4b5	ground_truth_to_del/0111c5f2-f00b-4fba-a266-71...	FTF	
...	
feb1a72c-02b7-43b0-a3ab-14eb6d574d5b	ground_truth_to_del/feb1a72c-02b7-43b0-a3ab-14...	FTF	
feb1a72c-02b7-43b0-a3ab-14eb6d574d5b	ground_truth_to_del/feb1a72c-02b7-43b0-a3ab-14...	Etiquette	
fd60af94-6874-4592-b1b6-faf00e7f03d9	ground_truth_to_del/fd60af94-6874-4592-b1b6-fa...	FTF	
	content	\	
uid			
1bca5540-b129-4593-a1e9-fa909234ad39	b'PDF-1.7\r%\xe2\xe3\xcf\xd3\r\n1765 0 obj\r<...		
1bca5540-b129-4593-a1e9-fa909234ad39	b'PDF-1.5\r%\xe2\xe3\xcf\xd3\r\n20 0 obj\r<<...		
0111c5f2-f00b-4fba-a266-716b3909f4b5	b'PDF-1.3\n%\xe2\xe3\xcf\xd3\n5 0 obj\n<<\n/L...		
...	
feb1a72c-02b7-43b0-a3ab-14eb6d574d5b	b'PDF-1.7\r\n%\xb5\xb5\xb5\r\n1 0 obj\r\n...		
feb1a72c-02b7-43b0-a3ab-14eb6d574d5b	b'PDF-1.3\n%\xc4\xe5\xf2\xe5\xeb\x a7\xf3\x a0\...		
fd60af94-6874-4592-b1b6-faf00e7f03d9	b'PDF-1.5\r%\xe2\xe3\xcf\xd3\r\n418 0 obj\r<<...		
	text		
uid			
1bca5540-b129-4593-a1e9-fa909234ad39	McCormick 315, Rue Marcel Demonque - Site Agr...		
1bca5540-b129-4593-a1e9-fa909234ad39			
0111c5f2-f00b-4fba-a266-716b3909f4b5	FICHE PRODUIT \n\n \n\n \n \n \n \n\n9 002 515 ...		
...	
feb1a72c-02b7-43b0-a3ab-14eb6d574d5b	FICHE TECHNIQUE\n\nRIZ CARNAROLI GRAN RISERVA ...		
feb1a72c-02b7-43b0-a3ab-14eb6d574d5b			
fd60af94-6874-4592-b1b6-faf00e7f03d9	Sauce Armoricaine		\n\nboite 4...
[815 rows x 4 columns]			
uid	path	type	\
1bca5540-b129-4593-a1e9-fa909234ad39	ground_truth_to_del/1bca5540-b129-4593-a1e9-fa...	FTF	
1bca5540-b129-4593-a1e9-fa909234ad39	ground_truth_to_del/1bca5540-b129-4593-a1e9-fa...	Etiquette	
0111c5f2-f00b-4fba-a266-716b3909f4b5	ground_truth_to_del/0111c5f2-f00b-4fba-a266-71...	FTF	
...	
feb1a72c-02b7-43b0-a3ab-14eb6d574d5b	ground_truth_to_del/feb1a72c-02b7-43b0-a3ab-14...	FTF	
feb1a72c-02b7-43b0-a3ab-14eb6d574d5b	ground_truth_to_del/feb1a72c-02b7-43b0-a3ab-14...	Etiquette	
fd60af94-6874-4592-b1b6-faf00e7f03d9	ground_truth_to_del/fd60af94-6874-4592-b1b6-fa...	FTF	
	content	\	
uid			
1bca5540-b129-4593-a1e9-fa909234ad39	b'PDF-1.7\r%\xe2\xe3\xcf\xd3\r\n1765 0 obj\r<...		
1bca5540-b129-4593-a1e9-fa909234ad39	b'PDF-1.5\r%\xe2\xe3\xcf\xd3\r\n20 0 obj\r<<...		
0111c5f2-f00b-4fba-a266-716b3909f4b5	b'PDF-1.3\n%\xe2\xe3\xcf\xd3\n5 0 obj\n<<\n/L...		
...	
feb1a72c-02b7-43b0-a3ab-14eb6d574d5b	b'PDF-1.7\r\n%\xb5\xb5\xb5\r\n1 0 obj\r\n...		
feb1a72c-02b7-43b0-a3ab-14eb6d574d5b	b'PDF-1.3\n%\xc4\xe5\xf2\xe5\xeb\x a7\xf3\x a0\...		
fd60af94-6874-4592-b1b6-faf00e7f03d9	b'PDF-1.5\r%\xe2\xe3\xcf\xd3\r\n418 0 obj\r<<...		
	text empty		
uid			
1bca5540-b129-4593-a1e9-fa909234ad39	McCormick 315, Rue Marcel Demonque - Site Agr... False		
1bca5540-b129-4593-a1e9-fa909234ad39			
	True		

```

0111c5f2-f00b-4fba-a266-716b3909f4b5  FICHE PRODUIT \n\n \n\n \n \n\n \n\n 002 515 ... False
...
feb1a72c-02b7-43b0-a3ab-14eb6d574d5b  FICHE TECHNIQUE\n\nRIZ CARNAROLI GRAN RISERVA ... False
feb1a72c-02b7-43b0-a3ab-14eb6d574d5b
    True
fd60af94-6874-4592-b1b6-faf00e7f03d9  Sauce Armoricaine
                                         \n\nboite 4... False

[815 rows x 5 columns]

```

```

[65]: (files_df.pivot_table(values='empty',
                           index='type',
                           aggfunc=['sum', 'count', 'mean'],
                           )
       .swaplevel(axis=1)
       .rename({'empty': 'Fichiers "vides"',
                 'sum': 'Nombre de fichiers vides',
                 'count': 'Nombre total de fichiers',
                 'mean': 'Taux de vides',
                 }, axis=1)
       .rename({'Etiquette': 'Etiquettes',
                 'FTF': 'Fiches techniques',
                 })
       .to_latex(#Path('..') / 'tbls' / 'empty_attached_files.tex',
                  column_format='lccc',
                  bold_rows=True,
                  index_names=False,
                  formatters=[lambda x: str(int(x)),
                             lambda x: str(int(x)),
                             lambda x: f'{int(x * 100):d}%',
                             ]
                 )
)

```

```

[63]: (files_df.pivot_table(values='empty',
                           index='type',
                           aggfunc=['sum', 'count', 'mean'],
                           )
       .swaplevel(axis=1)
       .rename({'empty': 'Fichiers "vides"',
                 'sum': 'Nombre de fichiers vides',
                 'count': 'Nombre total de fichiers',
                 'mean': 'Taux de vides',
                 }, axis=1)
       .rename({'Etiquette': 'Etiquettes',
                 'FTF': 'Fiches techniques',
                 })
)

```

	Documents vides	Nombre de documents vides	Nombre total de documents	Taux de vides
type				
Etiquettes	214.0		315	0.679365
Fiches techniques	22.0		500	0.044000

open_model

Pierre MASSÉ

May 12, 2020

1 Modèle “ouvert”

L'objet de ce notebook est de démontrer la faisabilité de prédire les listes d'ingrédients depuis des fiches techniques

1.1 Préambule technique

```
[1]: # setting up sys.path for relative imports
from pathlib import Path
import sys
project_root = str(Path(sys.path[0]).parents[1].absolute())
if project_root not in sys.path:
    sys.path.append(project_root)
```

```
[40]: # imports and customization of display
# import os
# from functools import partial
import numpy as np
import pandas as pd
pd.options.display.min_rows = 6
pd.options.display.width=108
# from sklearn.feature_extraction.text import CountVectorizer
# from sklearn.model_selection import train_test_split
# from sklearn.model_selection import cross_val_score, cross_validate
# from sklearn.pipeline import Pipeline
# from matplotlib import pyplot as plt

from src.pimapi import Requester
from src.pimest import PIMIngredientExtractor
# from src.pimest import ContentGetter
# from src.pimest import PathGetter
# from src.pimest import PDFContentParser
# from src.pimest import BlockSplitter
# from src.pimest import SimilaritySelector
# from src.pimest import custom_accuracy
```

1.2 Extraction des données

On extrait les données depuis le PIM :

```
[5]: requester = Requester('prd')
requester.fetch_all_from_PIM()
requester.result
```

Done

```
[5]: [<Response [200]>,
<Response [200]>,
```

```

<Response [200]>,
<Response [200]>

```

[6]: df = requester.result_to_dataframe(record_path='entries', index='uid')
df

```

[6]:
entity-type repository \
uid
afee12c7-177e-4a68-9539-8ccb68442503 document default
7d390121-17e8-43bf-a357-9d06b79d2d47 document default
f234cd84-c8f6-433f-85ec-6e0b6980adc6 document default
...
ef42a938-2203-446e-8d28-9fd27c6d3146 document ...
68f5d81b-7f91-40a0-8504-0ec320a86de4 document default
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a document default

path type \
uid
afee12c7-177e-4a68-9539-8ccb68442503 /default-domain/pomSupplierWorkspace/SICO/DEST... pomProduct
7d390121-17e8-43bf-a357-9d06b79d2d47 /default-domain/pomSupplierWorkspace/UNILEVER_... pomProduct
f234cd84-c8f6-433f-85ec-6e0b6980adc6 /default-domain/pomSupplierWorkspace/AZTECA_FO... pomProduct
...
ef42a938-2203-446e-8d28-9fd27c6d3146 /default-domain/pomSupplierWorkspace/SICO/DETE... pomProduct
68f5d81b-7f91-40a0-8504-0ec320a86de4 /default-domain/pomSupplierWorkspace/SICO/NETT... pomProduct
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a /default-domain/pomSupplierWorkspace/SICO/SPRA... pomProduct

state \
uid
afee12c7-177e-4a68-9539-8ccb68442503 product.waiting.supplier.validation
7d390121-17e8-43bf-a357-9d06b79d2d47 product.waiting.supplier.validation
f234cd84-c8f6-433f-85ec-6e0b6980adc6 product.waiting.supplier.validation
...
ef42a938-2203-446e-8d28-9fd27c6d3146 product.waiting.supplier.validation
68f5d81b-7f91-40a0-8504-0ec320a86de4 product.waiting.supplier.validation
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a product.waiting.supplier.validation

parentRef isCheckedOut isVersion \
uid
afee12c7-177e-4a68-9539-8ccb68442503 a58845c0-cab3-492f-b48d-531f146c3777 True False
7d390121-17e8-43bf-a357-9d06b79d2d47 a37abc27-f485-4ae9-921b-f761f16c8c1c False False
f234cd84-c8f6-433f-85ec-6e0b6980adc6 3ff7819a-a392-493f-beb8-0b323ac331c7 True False
...
ef42a938-2203-446e-8d28-9fd27c6d3146 a58845c0-cab3-492f-b48d-531f146c3777 ...
68f5d81b-7f91-40a0-8504-0ec320a86de4 a58845c0-cab3-492f-b48d-531f146c3777 ...
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a a58845c0-cab3-492f-b48d-531f146c3777 ...

isProxy changeToken ... \
uid
afee12c7-177e-4a68-9539-8ccb68442503 False 17-0 ...
7d390121-17e8-43bf-a357-9d06b79d2d47 False 15-0 ...
f234cd84-c8f6-433f-85ec-6e0b6980adc6 False 33-0 ...
...
ef42a938-2203-446e-8d28-9fd27c6d3146 False 17-0 ...
68f5d81b-7f91-40a0-8504-0ec320a86de4 False 17-0 ...
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a False 17-0 ...

properties.pprodqmd:manufacturingDiagram.length \
uid
afee12c7-177e-4a68-9539-8ccb68442503 ...
7d390121-17e8-43bf-a357-9d06b79d2d47 ...
f234cd84-c8f6-433f-85ec-6e0b6980adc6 ...
...
```

ef42a938-2203-446e-8d28-9fd27c6d3146	NaN
68f5d81b-7f91-40a0-8504-0ec320a86de4	NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a	NaN
properties.pprodqmdd:manufacturingDiagram.data \	
uid	
afee12c7-177e-4a68-9539-8cbb68442503	NaN
7d390121-17e8-43bf-a357-9d06b79d2d47	NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6	NaN
...	...
ef42a938-2203-446e-8d28-9fd27c6d3146	NaN
68f5d81b-7f91-40a0-8504-0ec320a86de4	NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a	NaN
properties.pprodqmdd:secondaryPackagingPhoto.name \	
uid	
afee12c7-177e-4a68-9539-8cbb68442503	NaN
7d390121-17e8-43bf-a357-9d06b79d2d47	NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6	NaN
...	...
ef42a938-2203-446e-8d28-9fd27c6d3146	NaN
68f5d81b-7f91-40a0-8504-0ec320a86de4	NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a	NaN
properties.pprodqmdd:secondaryPackagingPhoto.mime-type \	
uid	
afee12c7-177e-4a68-9539-8cbb68442503	NaN
7d390121-17e8-43bf-a357-9d06b79d2d47	NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6	NaN
...	...
ef42a938-2203-446e-8d28-9fd27c6d3146	NaN
68f5d81b-7f91-40a0-8504-0ec320a86de4	NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a	NaN
properties.pprodqmdd:secondaryPackagingPhoto.encoding \	
uid	
afee12c7-177e-4a68-9539-8cbb68442503	NaN
7d390121-17e8-43bf-a357-9d06b79d2d47	NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6	NaN
...	...
ef42a938-2203-446e-8d28-9fd27c6d3146	NaN
68f5d81b-7f91-40a0-8504-0ec320a86de4	NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a	NaN
properties.pprodqmdd:secondaryPackagingPhoto.digestAlgorithm \	
uid	
afee12c7-177e-4a68-9539-8cbb68442503	NaN
7d390121-17e8-43bf-a357-9d06b79d2d47	NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6	NaN
...	...
ef42a938-2203-446e-8d28-9fd27c6d3146	NaN
68f5d81b-7f91-40a0-8504-0ec320a86de4	NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a	NaN
properties.pprodqmdd:secondaryPackagingPhoto.digest \	
uid	
afee12c7-177e-4a68-9539-8cbb68442503	NaN
7d390121-17e8-43bf-a357-9d06b79d2d47	NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6	NaN
...	...
ef42a938-2203-446e-8d28-9fd27c6d3146	NaN
68f5d81b-7f91-40a0-8504-0ec320a86de4	NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a	NaN
properties.pprodqmdd:secondaryPackagingPhoto.length \	
uid	
afee12c7-177e-4a68-9539-8cbb68442503	NaN

```

7d390121-17e8-43bf-a357-9d06b79d2d47           NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6           NaN
...
ef42a938-2203-446e-8d28-9fd27c6d3146           ...
68f5d81b-7f91-40a0-8504-0ec320a86de4           NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a           NaN
properties.pprodqmd:secondaryPackagingPhoto.data \
uid
afee12c7-177e-4a68-9539-8cbb68442503           NaN
7d390121-17e8-43bf-a357-9d06b79d2d47           NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6           NaN
...
ef42a938-2203-446e-8d28-9fd27c6d3146           ...
68f5d81b-7f91-40a0-8504-0ec320a86de4           NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a           NaN
properties.notif:notifications
uid
afee12c7-177e-4a68-9539-8cbb68442503           NaN
7d390121-17e8-43bf-a357-9d06b79d2d47           NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6           NaN
...
ef42a938-2203-446e-8d28-9fd27c6d3146           ...
68f5d81b-7f91-40a0-8504-0ec320a86de4           NaN
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a           NaN
[13228 rows x 487 columns]

```

1.3 Constitution du périmètre

On conserve les produits qui : - sont de type Epicerie ou Boisson non alcoolisée - portent une liste d'ingrédients - sont en qualité : - soit ont terminé le processus de migration, soit ont été créés après la reprise initiale - et ont le statut "Validé"

```
[13]: # filter by product type
type_mask = df['properties.pprodtop:typeOfProduct'].isin(['grocery', 'nonAlcoholicDrink'])

# keep only those who have ingredients
ingredient_mask = pd.notna(df['properties.pprodc:ingredientsList'])

# filter out those who have not finished migration
df['begin_mig'] = df['facets'].apply(lambda x: 'beginningMigration' in x)
df['end_mig'] = df['facets'].apply(lambda x: 'endMigration' in x)
migration_mask = df.loc[:, 'end_mig'] | ~df.loc[:, 'begin_mig']

# filter out those who are not validated
status_mask = (df.loc[:, 'state'] == 'product.validate')

scope_mask = type_mask & ingredient_mask & migration_mask & status_mask

scope_df = df.loc[scope_mask]
print(f'After filters, there are {len(scope_df)} records in the dataset,')
out_of_scope_df = df.loc[~df.index.isin(scope_df.index)]
print(f'and {len(out_of_scope_df)} records left out.')

```

After filters, there are 3412 records in the dataset,
and 9816 records left out.

1.4 Entraînement : constitution du vocabulaire

On entraîne le modèle sur les listes d'ingrédients du périmètre. Cela revient à fitter le CountVectorizer sous-jacent.

```
[17]: model = PIMIngredientExtractor('prd')
model.fit(scope_df['properties.pprodc:ingredientsList'])
```

```
[17]: <src.pimest.PIMIngredientExtractor at 0x7ff2b555db50>
```

On peut imprimer une partie du vocabulaire qui a été construit :

```
[48]: print(f'Vocabulary consists in {len(model._count_vect.vocabulary_)} words.\n')
print('Some words examples are :')

for i, word in enumerate(model._count_vect.vocabulary_.keys()):
    print('-', word)
    if i > 6:
        break
```

Vocabulary consists in 2509 words.

Some words examples are :

- morilles
- eau
- de
- source
- kombu
- déshydraté
- 100
- graines

On peut également afficher les mots les plus fréquents dans le corpus de listes d'ingrédients d'entraînement. On constitue d'abord la matrice des textes transformés :

```
[26]: vectorized = model._count_vect.transform(scope_df['properties.pprod:ingredientsList'])
vectorized.shape
```

```
[26]: (3412, 2509)
```

On a bien 3412 documents projetés sur 2509 mots. Si on extrait les plus fréquents, on obtient :

```
[59]: inverse_voc = {val: key for key, val in model._count_vect.vocabulary_.items()}
word_counts = np.asarray(vectorized.sum(axis=0)).squeeze()
print('Most frequent words in vocabulary are:')
for idx in word_counts.argsort()[:-10:-1]:
    print(f'{inverse_voc[idx].ljust(7)}: {word_counts[idx]:5} occurrences')
```

Most frequent words in vocabulary are:

de	:	11419	occurrences
sucré	:	2057	occurrences
sel	:	1669	occurrences
eau	:	1288	occurrences
acide	:	1241	occurrences
lait	:	1215	occurrences
huile	:	1214	occurrences
poudre	:	1100	occurrences
en	:	962	occurrences
arôme	:	938	occurrences

1.5 Prédiction

Le wrapper PIMIngredientExtractor permet de simplement récupérer les informations du PIM et les pièces jointes associées, et de faire tourner le modèle pour extraire le bloc le plus similaire aux listes d'ingrédients.

```
[81]: print(len('====='))
```

13

```
[82]: exec_count = 5
uids = list(out_of_scope_df.sample(exec_count, random_state=41).index)

for uid in uids:
    model.compare_uid_data(uid)
```

```
↳ print('\'\n=====\\n=====')
```

Fetching data from PIM for uid d9b233a6-b455-4af6-afb4-623f1f7f62a6...
Done

Ingredient list from PIM is :

Ingrédients: Huile de tournesol, oignon, curry (11,2%) (ail, coriandre, curcuma, gingembre, paprika, poivre, cumin, poivre de Cayenne, fenouil, cardamome, noix de muscade, canelle, clous de girofle, safran), pomme, sel, exhausteur de goût (glutamate de sodium), sucre, huile de colza totalement hydrogénée, extrait de levure, ail.

Supplier technical datasheet from PIM for uid d9b233a6-b455-4af6-afb4-623f1f7f62a6 is:
<https://produits.groupe-pomona.fr/nuxeo/nxfile/default/d9b233a6-b455-4af6-afb4-623f1f7f62a6/pprodad:technica1Sheet/FT%20-15838201-%20Mise%20en%20Place%20Curry%20KNORR%20mars%202020.pdf?changeToken=58-0>

Downloading content of technical datasheet file...
Done!

Parsing content of technical datasheet file...
Done!

Ingredient list extracted from technical datasheet:

Liste d'ingrédients : Huile de tournesol, oignon, curry (11,2%) (ail, coriandre, curcuma, gingembre, paprika, poivre, cumin, poivre de Cayenne, fenouil, cardamome, noix de muscade, canelle, clous de girofle, safran), pomme, sel, exhausteur de goût (glutamate de sodium), sucre, huile de colza totalement hydrogénée, extrait de levure, ail

=====

Fetching data from PIM for uid 5666235b-9e78-44f2-8e0e-1de53f88fe04...
Done

Ingredient list from PIM is :

Ingrédients : Sucre, Gomme base, Sirop de glucose, Arômes, Humectant (E422), Antioxydant (E321), Colorant (E141).

Supplier technical datasheet from PIM for uid 5666235b-9e78-44f2-8e0e-1de53f88fe04 is:
https://produits.groupe-pomona.fr/nuxeo/nxfile/default/5666235b-9e78-44f2-8e0e-1de53f88fe04/pprodad:technica1Sheet/FT-136899_Chewing%20gum%20menthe%20bte%202000U%20Malabar_Carambar.pdf?changeToken=32-0

Downloading content of technical datasheet file...
Done!

Parsing content of technical datasheet file...
Done!

Ingredient list extracted from technical datasheet:

INGRÉDIENTS : Sucre, Gomme base, Sirop de glucose, Arômes, Humectant (E422), Antioxydant (E321), Colorant (E141).

=====

Fetching data from PIM for uid 6e976147-adcb-4d2d-925a-cb7c58c111a2...

Done

Ingredient list from PIM is :

Maltodextrine, amidon de maïs, sel, farine de BLE, colorant : caramel ordinaire ; arômes (BLE,CELERI), huile de palme, épaississant : gomme guar ; oignon, féculé de pomme de terre, extrait de levure, jus de cuisson de viande de bœuf (0,9%), acidifiant : acide citrique ; extrait de vin blanc, extraits d'ail, de thym et de poivre. Peut contenir : LAIT, OEUFS.

Supplier technical datasheet from PIM for uid 6e976147-adeb-4d2d-925a-cb7c58c111a2 is:
<https://produits.groupe-pomona.fr/nuxeo/nxfile/default/6e976147-adeb-4d2d-925a-cb7c58c111a2/pprodad:technica1Sheet/FT%20MAGGI%20Fonds%20Brun%20Li%C3%A9%20-%20Bo%C3%A9t%C3%A9%20de%20750g.pdf?changeToken=142-0>

Downloading content of technical datasheet file...

Done!

Parsing content of technical datasheet file...

Done!

Ingredient list extracted from technical datasheet:

Maltodextrine, amidon de maïs, sel, farine de blé, colorant : caramel ordinaire ; arômes (blé,céleri), huile de palme, épaississant : gomme guar ; oignon, féculé de pomme de terre, extrait de levure, jus de cuisson de viande de bœuf (0,9%), acidifiant : acide citrique ; extrait de vin blanc, extraits d'ail, de thym et de poivre.

Peut contenir : lait, œuf.

=====

=====

Fetching data from PIM for uid db449562-d16d-4f72-b7a5-c0d487bc8206...

Done

Ingredient list from PIM is :

Huile d'ARACHIDE

Supplier technical datasheet from PIM for uid db449562-d16d-4f72-b7a5-c0d487bc8206 is:
https://produits.groupe-pomona.fr/nuxeo/nxfile/default/db449562-d16d-4f72-b7a5-c0d487bc8206/pprodad:technica1Sheet/FT-7744.%20Huile%20arachide%20bid%205L_HUILERIES%20DE%20SERIGNAN.pdf?changeToken=22-0

Downloading content of technical datasheet file...

Done!

Parsing content of technical datasheet file...

Done!

Ingredient list extracted from technical datasheet:

*Selon le règlement UE n°1259-2011 / In accordance with regulation UE n°1259-2011

CARACTERISTIQUES MICROBIOLOGIQUES

L'huile étant un milieu anhydre, tout développement bactérien est impossible (cf. ouvrage de référence dans ce domaine "La qualité microbiologique des aliments" CNERMA-CNRS coordonné par Jean-louis Jouve).

ORIGINES/ ORIGIN

- Amérique du Sud majoritairement
- Afrique de l'Ouest

AUTRES INFORMATIONS

```
-----  
=====  
=====  
Fetching data from PIM for uid f2af54a2-6820-4f1b-99e7-d6e64642bdf3...  
Done  
-----  
Ingredient list from PIM is :  
  
None  
-----  
Supplier technical datasheet from PIM for uid f2af54a2-6820-4f1b-99e7-d6e64642bdf3 is:  
https://produits.groupe-pomona.fr/nuxeo/nxfile/default/f2af54a2-6820-4f1b-99e7-d6e64642bdf3/pprodad:technicalSheet/FT-163146\_Hous%20echel%20GNZ%20PE%2020u%2025U\_Barbier.pdf?changeToken=78-0  
-----  
Downloading content of technical datasheet file...  
Done!  
-----  
Parsing content of technical datasheet file...  
Done!  
-----  
Ingredient list extracted from technical datasheet:  
  
mini 16,56 ( - 10 % )  
-----  
=====
```

gt_based_model

Pierre MASSÉ

June 3, 2020

1 Modèle basé sur les données manuellement étiquetées

L'objet de ce notebook est de mettre en place le modèle basé sur les données manuellement étiquetées.

1.1 Récupération des données

1.1.1 Préambule technique

```
[1]: # setting up sys.path for relative imports
from pathlib import Path
import sys
project_root = str(Path(sys.path[0]).parents[1].absolute())
if project_root not in sys.path:
    sys.path.append(project_root)
```

```
[2]: # imports and customization of display
import os
import pandas as pd
pd.options.display.min_rows = 6
pd.options.display.width = 108
pd.options.display.latex.repr = True
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.pipeline import Pipeline

from src.pimapi import Requester
from src.pimest import ContentGetter
from src.pimest import PathGetter
from src.pimest import PDFContentParser
from src.pimest import BlockSplitter
from src.pimest import SimilaritySelector
```

1.1.2 Chargement du fichier des données manuellement étiquetées

On commence par charger le fichier csv contenant les données manuellement étiquetées.

```
[3]: ground_truth_df = pd.read_csv(Path('..') / '..' / 'ground_truth' / 'manually_labelled_ground_truth.csv',
                                    sep=';',
                                    encoding='latin-1',
                                    index_col='uid')
ground_truth_df.head()
```

uid	designation	ingredients
a0492df6-9c76-4303-8813-65ec5ccbfa70	Concentré liquide Asian en bouteille 980 ml CHEF	Eau, maltodextrine, sel, arômes, sucre
d183e914-db2f-4e2f-863a-a3b2d054c0b8	Pain burger curry 80 g CREATIV BURGER	Farine de blé T65, eau, levure, vinaigre
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8	Macaroni en sachet 500 g PANZANI	- 100% Semoule de BLE dur de qualité
528d4be3-425c-4f8b-8a87-12f1bc645ddd	Fève de Tonka en sachet 100 g COMPTOIR COLONIAL	fève de tonka (graines ridées de 25 %
51b38427-b2ea-4c56-93e8-4242361ef31b	Caviar d'aubergine en pot 500 g PUGET RESTAURA...	Aubergine 60,5% (aubergine, huile de sésame)

```
[4]: ground_truth_uids = list(ground_truth_df.index)
      ground_truth_uids[:5]
```

```
[4]: ['a0492df6-9c76-4303-8813-65ec5ccbfa70',
      'd183e914-db2f-4e2f-863a-a3b2d054c0b8',
      'ab48a1ed-7a3d-4686-bb6d-ab4f367cada8',
      '528d4be3-425c-4f8b-8a87-12f1bc645ddd',
      '51b38427-b2ea-4c56-93e8-4242361ef31b']
```

1.1.3 Pipeline d'acquisition du contenu des données

On commence par construire un premier pipeline d'acquisition des données. Il fonctionne en 3 étapes : - détermination du chemin vers lequel aller chercher les fiches techniques - récupération du contenu binaire du fichier - conversion de ce contenu binaire en texte

```
[5]: acqui_pipe = Pipeline([('PathGetter', PathGetter(ground_truth_uids=ground_truth_uids,
                                                       train_set_path=Path('..') / '..' / 'ground_truth',
                                                       ground_truth_path=Path('..') / '..' / 'ground_truth',
                                                       )),
                           ('ContentGetter', ContentGetter(missing_file='to_nan')),
                           ('ContentParser', PDFContentParser(None_content='to_empty')),
                           ],
                           verbose=True)
```

```
[6]: texts_df = acqui_pipe.fit_transform(ground_truth_df)
      texts_df
```

```
[Pipeline] ... (step 1 of 3) Processing PathGetter, total= 0.1s
[Pipeline] ... (step 2 of 3) Processing ContentGetter, total= 0.1s
Launching 8 processes.
[Pipeline] ... (step 3 of 3) Processing ContentParser, total= 37.2s
```

```
[6]:
```

uid	designation	ingredients
a0492df6-9c76-4303-8813-65ec5ccbfa70	Concentré liquide Asian en bouteille 980 ml CHEF	Eau, maltodextrine, sel, arômes, su...
d183e914-db2f-4e2f-863a-a3b2d054c0b8	Pain burger curry 80 g CREATIV BURGER	Farine de blé T65, eau, levure, vinaig...
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8	Macaroni en sachet 500 g PANZANI	- 100% Semoule de BLE dur de qualité
528d4be3-425c-4f8b-8a87-12f1bc645ddd	Fève de Tonka en sachet 100 g COMPTOIR COLONIAL	fève de tonka (graines ridées de 25 mm)
51b38427-b2ea-4c56-93e8-4242361ef31b	Caviar d'aubergine en pot 500 g PUGET RESTAURA...	Aubergine 60,5% (aubergine, huile de tourn...
e4c8c61f-a401-4384-8128-181447e5bdd2	Confitures assorties en bocaux 30 g BONNE MAMAN	Confiture de myrtilles et de cassis 50%
50766d10-6135-4958-b743-1cddfcb7c230	Spécialité pomme saveur biscuitée en boîte 5/1...	Pommes 95%, sirop de glucose-fructose 5%
bb9f3995-57b3-429d-b075-2d81a90e406f	Coco Pops en sachet 500 g KELLOGG'S	Riz, Sucre, Cacao maigre en poudre, eau, j...
52bf5f5a-79f2-4652-8eac-2b80c697269b	PUR JUS ORANGE DE MÉDITERRANÉE 3L	Jus d'orange issu de l'agriculture biologique
04235024-80f3-46c2-bad0-aae0d5fab024	Persil feuilles en boîte 80 g LA CASE AUX EPICES	Persil
93a5d344-4ab0-48de-bbb0-fec8117d07a2	Chips saveur poulet braisé en sachet 25 g SIBELL	Pommes de terre, huile de tournesol, sel, sucre
440ca0b4-1c79-433f-ac8d-6e2ae77d3288	Pâte à tartiner noisette en bouteille squeezer...	Sucre, huiles végétales (Colza), huile de can...
7b9cf3b3-bf4b-408c-b8c8-807a09745979	Sauce Sweet chili en flacon souple 875 ml HEINZ	Sucre, eau, vinaigre d'alcool, purée de tomate
b638ab96-427c-4d5f-9a19-74684eec3b8e	PRÉPARATION CULINAIRE À BASE D'HUILE D'OLIVE E...	Huile d'olive vierge extra 99,5%, huile de tourn...
8bb101c0-8c6e-4665-8310-1a2d13257b2e	Huile pimentée spicy'piz en dose 3 ml SAVEURS ...	Huile de colza, extrait naturel de poivron
54f40033-f9cf-411c-81a5-11974f6715aa	Harissa en siccato de 3 kg PROVENCE OLIVES	Piment rouge fort équarri (85%), huile de tourn...
2405356e-ecc9-404f-8279-16fdf168b73	1883 VANILLE 100 CL	SUCRE DE CANNE, EAU, AROME, COLORANT
c57be8e4-30e0-417b-90fa-b60d9f9ece48	Baie des Batak en sachet 250 g TERRE EXOTIQUE	Baie des Batak
6622442d-d88f-4b90-9414-b91c9e8e5296	Filet de maquereau à la tomate en poche 4/4 FU...	Filets de maquereaux (61%), eau, sel, huile de
507b428e-e99d-464b-b9d3-50629fe4e4355	Farine de blé type 00 pour pizza en sachet 1 k...	Mélange de Blés de pays recommandés
545e8bc5-15fd-458a-8c9f-b18faecc2016	GOURDES AU CHOCOLAT P'TITS TOQUES YABON 4X80G	Lait entier (88%) ; sucre ; poudre de cacao
b45b3942-accd-4115-8f1f-736dbd42a35a	CHAMONIX*2 25G	Sirop de glucose-fructose, farine de blé, sucre
6c07fd47-116d-4531-a164-d4f4040f212e	Thon Albacore en morceaux au naturel en poche ...	Thon Albacore (92%), eau (7%), sel (1%), huile de
ca711137-4644-45b7-9928-456a09d9746a	THE BISCUITS POCKET 22 GR	Farine de BLÉ 67 %, sucre, huile de tournesol
e70d347d-5e91-4e0f-b396-b9bb4b09da29	Galette des rois à la crème frangipane avec fève...	Crème frangipane 39% (sucre, BEURRE, eau)
70500268-802d-4211-93ba-9edbfb6e0e7a3	COLIS KERMESSE 2019 A.P " 22+8"	TAGADA\nsucre; sirop de glucose; gélatine; eau\nnsucre\nretreat de thé noir (1,4g), sucre, semoule de blé dur blanche biologique
60ab6264-3aae-4f82-8828-9abd606683f5	Ice Tea citron-citron vert en bouteille 50 cl ...	Riz à grain long précuit (65%), feuilles de
380ee776-b92f-4378-a14b-c33622327b09	Couscous blanc BIO en sac 5 kg MARKAL	jus de fruits à base de concentrés : sucre, eau
7a8f6966-3710-4e3e-b656-a0f4ec271d1	Feuilles de vigne farcies au riz en boîte 2/1 ...	Olives vertes dénoyautées , huile de tournesol
5f3aba4a-b591-43b6-af5d-0d3304b263e3	Spécialité au citron en bouteille verre 70 cl ...	Poivrons rouge et vert, tomate en purée
adb90cc7-4b91-4771-b505-61a207cc1f96	Olivettes vertes piquantes dénoyautées en siccato	Sucre, texturants : alginate de sodium, cèpes 70% (Boletus edulis et respectueux)
3caac27c-704b-4f83-9203-482219d73d02	Mélange d'épices italien en boîte 200 g DUCROS	Sirop de glucose, purée de fraises et de
9b4cd824-bbb4-4cc9-be85-790988a803fd	Entremet parfum caramel en sachet 1 kg NUTRACY	Sirop de glucose-fructose, sucre, eau, sel
046cdb1f-1915-4916-8874-902cc5ec73be	Crème de cèpes à la truffe en boîte 4/4 DEMETRA	Eau, graines de moutarde 16%, vinaigre de
8f7c1e03-64c4-41cd-b557-53e559a39290	Sauce dessert fraise en bouteille 1 kg NESTLÉ ...	Crème 70% (Boletus edulis et respectueux)
b3ba5dbb-78cf-40ce-97a3-b7847977e6e7	Mini marshmallows en boîte 150 g VAHINE	Sirop de glucose, purée de fraises et de
a6c2eefb-0046-4c1f-998c-d90bbd560f16	Moutarde en stick 10,5 g HEINZ	Sirop de glucose-fructose, sucre, eau, sel
7b4b2030-63f3-416c-b3a7-b20204a748ef	Entremet parfum vanille en sachet 750 g NUTRACY	Eau, graines de moutarde 16%, vinaigre de
7e5ff57f-5a13-46bf-bb1c-b59b40727515	Thon listao en morceaux au naturel en boîte 4/...	Sucre, gélifiant : alginate de sodium
4f83306f-66de-4545-9b12-7790b57b61ae	Nappage miroir neutre en siccato 7 kg ANCEL	Thon, eau, sel
f254910f-8562-431e-a499-cae5e67158b7	Sauce diable en boîte 800 g NEFF MADA	Sirop de glucose, sucre, eau, stabilisateurs
acba6c83-385c-405a-ac35-96e3c2828683	Purée de cassis sucrée en poche 1 kg LEONCE BLANC	Maltodextrine de blé - Amidon de maïs - Cassis 89,3%\n1, sucre.\n*1 : Variabil
bdcf718d-968f-4ad0-bad5-805f5a505c69	Oasis orange en bouteille 2 L OASIS	eau de source 80%, jus de fruits à base de
e6eb7635-748d-424f-a1e2-b47a010a31e0	Muffin Gourmet en sac 10 kg COMPLET	Sucre, amidon de FROMENT, farine de blé
30778190-c91f-4942-bf6c-2b07640d4d12	Miso en poudre en boîte 250 g ARIAKE	Miso (95%) (eau, fèves de soja, riz, sel)
007f266f-fc64-4b0d-98d1-0d1e5650ec5b	Tarte sablée sucrée au beurre en forme de cœur...	farine de BLE enrichie (farine de blé, sel)
8afeb736-1b04-4aa7-9b25-fa534a177019	Beignets au beurre en sachet 10 kg COMPLET	Farine de blé, beurre en poudre (7 %), sel, blé
100c3211-9dc2-48e9-a2d6-0a7384b85ab2	Semoule de blé fine BIO en sac 5 kg MARKAL	dur biologique (triticum durum) - Amidon de
42c360ae-7bcc-4671-81b9-f6170eadd007	Jus de rôti de boeuf hyposodé en boîte 800 g N...	maïs - Arômes - Sirop de glucose-fructose
ecc3c180-51dd-4070-bdfe-abbd3344626d	Moutarde forte de Dijon en tube 105 g REINE DE...	Eau, graines de moutarde, vinaigre de
7f8c0f20-50d9-4b18-9c25-4074f10b6f3e	Céleri râpé en boîte 5/1 EPISAVEURS	Céleri rave, eau, vinaigre d'alcool, sel, cheddar
19f93f6d-2168-43c5-9713-4be564f51185	CHEEDDAR CHEESE SAUCE 1.420 KG	fondu (44%) (eau, lactosérum, sel, sucre)
321363df-147c-4e4d-bf1a-c982c0ce9951	Brandade de morue en boîte 5/1 RAYMOND GEOFFROY	Huile de colza, morue (32%), eau, sel, sucre
b7a5df3b-42b4-4cde-ae39-18f0e7a5f776	OLIVES NOIRES CONFITES DENOYAUTÉES 4/4	Olives, eau, sel, stabilisateur de texture
81lee31fb-37cc-4093-89cd-5aaeae7c1add	Sauce algérienne en flacon souple 850 g COLONA	Huile de colza (48 %), sucre, eau, vinaigre
41da4d6f-7e9f-4f95-bf2a-2acdd7138cd9	Ketchup en flacon souple 970 ml CALIFORNIA	Purée de tomates mi réduite (64%), sucre, eau
00a76c54-b2f6-4c4d-a97e-bd9a9cd2f112	Protéine de soja BIO en sac 10 kg MARKAL	soja jaune biologique (glycine max)
9f7f946c-dd35-41ae-815e-ad3181e96d5d	Spécialité pomme-abricot allégée en coupelle 9...	Pomme 77% (origine 100% France), abricot
ceeb8b03-8e6d-43f3-9594-410085c71b3	Barre pâtissière 800 g COQUELIN	Farine de BLÉ - Sucre - ŒUFS - Huile de
820a65ca-5112-404c-a79a-953db0c4e989	Compote poire allégée en boîte 5/1 LA PULPE	Poires, sirop de glucose-fructose, sucre, eau
7c1d47f4-a2ca-4579-9687-a4e31d97647f	Pois chiches en boîte 1/2 MAINGOURD	Pois chiches, eau, sel.
ce71ed2f-fb3f-48bb-b2c5-b9b911f78adb	Bâton chocolat noir 40% cacao en boîte 1,6 kg ...	sucre, pâte de cacao, beurre de cacao, amidon
6c7987c9-22f1-40d5-99cf-927c31c7db5c	Potage aux 9 légumes en sachet 20 g NEFF MADA	modifié de pomme de terre - Invert
b8cbe6f9-71d4-4e51-a169-1c163d49a561	Pancake en sachet 1 kg COMPLET	Farine de FROMENT, poudre de LACTOSE
ade044fc-a734-4633-b1fa-8f724e943aeb	Mirabelle dénoyautée au naturel en boîte 2/1 0...	Mirabelles (55%), eau, acidifiant : acide
0e736da3-faa6-4e57-a777-e354e29ca219	Soupe de poissons et langoustines au sel de Gu...	Eau, poissons 35%, langoustines 5% (langouste)
4c8fccdb-1c40-479f-84f7-589bd764b59e	PRÉPARATION DÉSHYDRATÉE POUR FLAN 5 PARFUMS ÉD...	FRAMBOISE\nMaltodextrine, carraghénane, eau
2b055200-0c27-4274-b976-7ec71d9ad15	Saladière parisienne en coupelle 220 g SAUPIQUET	Légumes (pommes de terre (14%), carotte, eau)
21233a00-bc20-40fc-acb9-ee2e2321cac2	San Pellegrino 78monata en canette 33 cl SAN P...	NaN
9fa94fea-6315-4439-b976-0730d37522c9	Chapelure Batter Mix en sachet de 4,2 kg GRIFFITH...	NaN
6566e18d-3bdd-43d8-ab0c-de51894621f9	SPÉCIALITÉ POMME-FRAISE ALLÉGÉE EN SUCRES EN B...	Pommes 89%, purée de fraises à base de
b988521e-1191-472f-ad90-5afcc8c2a57b8	MOUTARDE DE DIJON SEAU 5KG - EDMOND FALLOT	Eau, graines de moutarde, vinaigre, sel
846db626-d8a9-49b2-be8d-7d724adeaff3	Assortiment Mix Turbine 3 saveurs en colis MON...	Croustilles de céréales enrobées de sucre

On peut afficher quelques textes récupérés par le pipeline :

```
[19]: with pd.option_context("max_colwidth", 1000):
    pass
#     print(texts_df.sample(3, random_state=42)['text'])
#     (texts_df.sample(3, random_state=42)['text']
#      .to_latex(Path('..') / 'tbls' / 'processed_FT.tex',
#                 index=False,
#                 index_names=False,
#                 column_format='p{\linewidth}',
#                 na_rep='--',
#                 escape=True,
#                 )
#     )
```

1.2 Découpage en blocs

On découpe les longs textes en blocs. Chaque texte devient une liste de strings plus court.

```
[22]: def splitter(text):
    return(text.split('\n\n'))
```

```
[23]: split_transfo = BlockSplitter(splitter_func=splitter)
splitted_df = split_transfo.fit_transform(texts_df)
splitted_df
```

Launching 8 processes.

```
[23]:
```

uid	designation	ingredients
a0492df6-9c76-4303-8813-65ec5ccbfa70	Concentré liquide Asian en bouteille 980 ml CHEF	Eau, maltodextrine, sel, arômes, su...
d183e914-db2f-4e2f-863a-a3b2d054c0b8	Pain burger curry 80 g CREATIV BURGER	Farine de blé T65, eau, levure, vinaig...
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8	Macaroni en sachet 500 g PANZANI	- 100% Semoule de BLE dur de qualité
528d4be3-425c-4f8b-8a87-12f1bc645ddd	Fève de Tonka en sachet 100 g COMPTOIR COLONIAL	fève de tonka (graines ridées de 25 mm)
51b38427-b2ea-4c56-93e8-4242361ef31b	Caviar d'aubergine en pot 500 g PUGET RESTAURA...	Aubergine 60,5% (aubergine, huile de colza)
e4c8c61f-a401-4384-8128-181447e5bdd2	Confitures assorties en bocaux 30 g BONNE MAMAN	Confiture de myrtilles et de cassis
50766d10-6135-4958-b743-1cddfcb7c230	Spécialité pomme saveur biscuitée en boîte 5/1...	Pommes 95%, sirop de glucose-fructose
bb9f3995-57b3-429d-b075-2d81a90e406f	Coco Pops en sachet 500 g KELLOGG'S	Riz, Sucre, Cacao maigre en poudre, jus d'orange issu de l'agriculture biologique
52bf5f5a-79f2-4652-8eac-2b80c697269b	PUR JUS ORANGE DE MÉDITERRANÉE 3L	Persil
04235024-80f3-46c2-bad0-aae0d5fab024	Persil feuilles en boîte 80 g LA CASE AUX EPICES	Pommes de terre, huile de tournesol
93a5d344-4ab0-48de-bbb0-fec8117d07a2	Chips saveur poulet braisé en sachet 25 g SIBELL	Sucre, huiles végétales (Colza), noix
440ca0b4-1c79-433f-ac8d-6e2ae77d3288	Pâte à tartiner noisette en bouteille squeezer...	Sucre, eau, vinaigre d'alcool, purée de pomme
7b9cf3b3-bf4b-408c-b8c8-807a09745979	Sauce Sweet chili en flacon souple 875 ml HEINZ	Huile d'olive vierge extra 99,5%, Aromates
b638ab96-427c-4d5f-9a19-74684eec3b8e	PRÉPARATION CULINAIRE À BASE D'HUILE D'OLIVE E...	Huile de colza, extrait naturel de poivron
8bb101c0-8c6e-4665-8310-1a2d13257b2e	Huile pimentée spicy'piz en dose 3 ml SAVEURS ...	Piment rouge fort équeuté (85%), huile de
54f40033-f9cf-411c-81a5-11974f6715aa	Harissa en seau de 3 kg PROVENCE OLIVES	SUCRE DE CANNE, EAU, AROME, COLORANT
2405356e-ecc9-404f-8279-16fdf168b73	1883 VANILLE 100 CL	Baie des Batak
c57be8e4-30e0-417b-90fa-b60d9f9ece48	Baie des Batak en sachet 250 g TERRE EXOTIQUE	Filets de maquereaux (61 %), eau, colorant
6622442d-d88f-4b90-9414-b91c9e8e5296	Filet de maquereau à la tomate en poche 4/4 FU...	Mélange de Blés de pays recommandés
507b428e-e99d-464b-b9d3-50629fe4e4355	Farine de blé type 00 pour pizza en sachet 1 k...	Lait entier (88%) ; sucre ; poudre de lait
545e8bc5-15fd-458a-8c9f-b18faecc2016	GOURDES AU CHOCOLAT P'TITS TOQUES YABON 4X80G	Sirop de glucose-fructose, farine de blé
b45b3942-accd-4115-8f1f-736dbd42a35a	CHAMONIX*2 25G	Thon Albacore (92%), eau (7%), sel (1%),
6c07fd47-116d-4531-a164-d4f4040f212e	Thon Albacore en morceaux au naturel en poche ...	Farine de BLÉ 67 %, sucre, huile de colza
ca711137-4644-45b7-9928-456a09d9746a	THE BISCUITS POCKET 22 GR	Crème frangipane 39% (sucre, BEURRE)
e70d347d-5e91-4e0f-b396-b9bb4b09da29	Galette des rois à la crème frangipane avec fève...	TAGADA\nsucre; sirop de glucose; gélatine
70500268-802d-4211-93ba-9edbfb6e0e7a3	COLIS KERMESSE 2019 A.P " 22+8"	eau\nsucre\nretrait de thé noir (1,4g), semoule de blé dur blanche biologique
60ab6264-3aae-4f82-8828-9abd606683f5	Ice Tea citron-citron vert en bouteille 50 cl ...	Riz à grain long précuit (65%), feuilles de
380ee776-b92f-4378-a14b-c33622327b09	Couscous blanc BIO en sac 5 kg MARKAL	jus de fruits à base de concentrés : sucre, eau
7a8f6966-3710-4e3e-b656-a0f4eec271d1	Feuilles de vigne farcies au riz en boîte 2/1 ...	Olives vertes dénoyautées , huile de
5f3aba4a-b591-43b6-af5d-0d3304b263e3	Spécialité au citron en bouteille verre 70 cl ...	Poivrons rouge et vert, tomate en purée
adb90cc7-4b91-4771-b505-61a207cc1f96	Olivettes piquantes dénoyautées en seau 3,...	Sucre, texturants : alginate de sodium, cèpes 70% (Boletus edulis et respectueux)
3caac27c-704b-4f83-9203-482219d73d02	Mélange d'épices italien en boîte 200 g DUCROS	Sirop de glucose, purée de fraises et de
9b4cd824-bbb4-4cc9-be85-790988a803fd	Entremet parfum caramel en sachet 1 kg NUTRACY	Sirop de glucose-fructose, sucre, eau, colorant
046cdb1f-1915-4916-8874-902cc5ec73be	Crème de cèpes à la truffe en boîte 4/4 DEMETRA	Eau, graines de moutarde 16%, vinaigre de
8f7c1e03-64c4-41cd-b557-53e559a39290	Sauce dessert fraise en bouteille 1 kg NESTLÉ ...	Sucre, gélifiant : alginate de sodium
b3ba5dbb-78cf-40ce-97a3-b7847977e6e7	Mini marshmallows en boîte 150 g VAHINE	Thon, eau, sel
a6c2eefb-0046-4c1f-998c-d90bbd560f16	Moutarde en stick 10,5 g HEINZ	Sirop de glucose, sucre, eau, stabilisateurs
7b4b2030-63f3-416c-b3a7-b20204a748ef	Entremet parfum vanille en sachet 750 g NUTRACY	Maltodextrine de blé - Amidon de maïs
7e5ff57f-5a13-46bf-bb1c-b59b40727515	Thon listao en morceaux au naturel en boîte 4/...	Cassis 89,3%\n1, sucre.\n*1 : Variabil
4f83306f-66de-4545-9b12-7790b57b61ae	Nappage miroir neutre en seau 7 kg ANCEL	eau de source 80%, jus de fruits à base de
f254910f-8562-431e-a499-cae5e67158b7	Sauce diable en boîte 800 g NEFF MADA	Sucre, amidon de FROMENT, farine de blé
acba6c83-385c-405a-ac35-96e3c2828683	Purée de cassis sucrée en poche 1 kg LEONCE BLANC	Miso (95%) (eau, fèves de soja, riz, farine de BLE enrichie (farine de blé),
bdcf718d-968f-4ad0-bad5-805f5a505c69	Oasis orange en bouteille 2 L OASIS	Farine de blé, beurre en poudre (7 %), blé dur biologique (triticum durum)
e6eb7635-748d-424f-a1e2-b47a010a31e0	Muffin Gourmet en sac 10 kg COMPLET	Amidon de maïs - Arômes - Sirop de glucose
30778190-c91f-4942-bf6c-2b07640d4d12	Miso en poudre en boîte 250 g ARIAKE	Eau, graines de moutarde, vinaigre de
007f266f-fc64-4b0d-98d1-0d1e5650ec5b	Tarte sablée sucrée au beurre en forme de cœur...	Céleri rave, eau, vinaigre d'alcool, cheddar fondu (44%) (eau, lactosérum)
8afeb736-1b04-4aa7-9b25-fa534a177019	Beignet au beurre en sachet 10 kg COMPLET	Huile de colza, morue (32%), eau, purée de
100c3211-9dc2-48e9-a2d6-07a384b85ab2	Semoule de blé fine BIO en sac 5 kg MARKAL	Olives, eau, sel, stabilisateur de
42c360ae-7bcc-4671-81b9-f6170eadd007	Jus de rôti de boeuf hyposodé en boîte 800 g N...	Huile de colza (48 %), sucre, eau, vinaigre
ecc3c180-51dd-4070-bdfe-abbd3344626d	Moutarde forte de Dijon en tube 105 g REINE DE...	Purée de tomates mi réduite (64%), sucre, soja jaune biologique (glycine max)
7f8c0f20-50d9-4b18-9c25-4074f10b6f3e	Céleri râpé en boîte 5/1 EPISAVEURS	Pomme 77% (origine 100% France), abricot
19f93f6d-2168-43c5-9713-4be564f51185	CHEEDDAR CHEESE SAUCE 1.420 KG	Farine de BLÉ - Sucre - ŒUFS - Huile de
321363df-147c-4e4d-bf1a-c982c0ce9951	Brandade de morue en boîte 5/1 RAYMOND GEOFFROY	Poires, sirop de glucose-fructose, eau, Pois chiches, eau, sel.
b7a5df3b-42b4-4cde-ae39-18f0e7a5f776	OLIVES NOIRES CONFITES DENOYAUTEES 4/4	sucre, pâte de cacao, beurre de cacao, amidon modifié de pomme de terre - I
81ee31fb-37cc-4093-89cd-5aaeae7c1add	Sauce algérienne en flacon 850 g COLONA	Farine de FROMENT, poudre de LACTOSE
41da4d6f-7e9f-4f95-bf2a-2acdd7138cd9	Ketchup en flacon souple 970 ml CALIFORNIA	Mirabelles (55%), eau, acidifiant : acide
00a76c54-b2f6-4c4d-a97e-bd9a9cd2f112	Protéine de soja BIO en sac 10 kg MARKAL	Eau, poisssons 35%, langoustines 5%, FRAMBOISE\nMaltodextrine, carraghénate
9f7f946c-dd35-41ae-815e-ad3181e96d5d	Spécialité pomme-abricot allégée en coupelle 9...	Légumes (pommes de terre (14%), carbo
ceeb8b03-8e6d-43f3-9594-410085c71b3	Barre pâtissière 800 g COQUELIN	NaN
820a65ca-5112-404c-a79a-953db0c4e989	Compote poire allégée en boîte 5/1 LA PULPE	NaN
7c1d47f4-a2ca-4579-9687-a4e31d97647f	Pois chiches en boîte 1/2 MAINGOURD	Pommes 89%, purée de fraises à base de
ce71ed2f-fb3f-48bb-b2c5-b9b911f78adb	Bâton chocolat noir 40% cacao en boîte 1,6 kg ...	Eau, graines de moutarde, vinaigre, Croustilles de céréales enrobées de
6c7987c9-22f1-40d5-99cf-927c31c7db5c	Potage aux 9 légumes en sachet 20 g NEFF MADA	sucre, eau, vinaigre, huile de
b8cbe6f9-71d4-4e51-a169-1c163d49a561	Pancake en sachet 1 kg COMPLET	colza, huile de
ade044fc-a734-4633-b1fa-8f724e943aeb	Mirabelle dénoyautée au naturel en boîte 2/1 0...	olives, eau, sel, stabilisateurs de
0e736da3-faa6-4e57-a777-e354e29ca219	Soupe de poissons et langoustines au sel de Gu...	Huile de colza (48 %), sucre, eau, vinaigre
4c8fccdb-1c40-479f-84f7-589bd764b59e	PRÉPARATION DÉSHYDRATÉE POUR FLAN 5 PARFUMS ÉD...	Purée de tomates mi réduite (64%), sucre, soja jaune biologique (glycine max)
2b055200-0c27-4274-b976-7ec71d9ad15	Saladière parisienne en coupelle 220 g SAUPIQUET	Pomme 77% (origine 100% France), abricot
21233a00-bc20-40fc-acb9-ee2e2321cac2	San Pellegrino 800mlmonata en canette 33 cl SAN P...	Farine de BLÉ - Sucre - ŒUFS - Huile de
9fa94fea-6315-4439-b976-0730d37522c9	Chapelure Batter Mix en sac de 4,2 kg GRIFFITH...	Poires, sirop de glucose-fructose, eau, vinaigre
6566e18d-3bdd-43d8-ab0c-de51894621f9	SPÉCIALITÉ POMME-FRAISE ALLÉGÉE EN SUCRES EN B...	Pois chiches, eau, sel.
b988521e-1191-472f-ad90-5afc8c2a57b8	MOUTARDE DE DIJON SEAU 5KG - EDMOND FALLOT	sucre, pâte de cacao, beurre de cacao, amidon modifié de pomme de terre - I
846db626-d8a9-49b2-be8d-7d724adeaff3	Assortiment Mix Turbine 3 saveurs en colis MON...	Farine de FROMENT, poudre de LACTOSE

On peut afficher un exemple de texte découpé en blocs :

```
[24]: sep = '\n-----\n'
sample = splitted_df.sample(1, random_state=39)[['blocks']].iloc[0]
print(sep.join(sample))

tex_str = (
    pd.DataFrame(sample, columns=['Bloc'])
    .to_latex(column_format='p{10cm}', 
               index=False,
               index_names=False,
               escape=True,
               )
    .replace(r'\textbackslash n', '\\newline ')
)

#with open(Path('..') / 'tbls' / 'block_example.tex', mode='w') as file:
#    file.write(sep.join(sample).replace('\n', r' \newline '))
```

30/12/19

Date d'impression :
Remarque :
Les informations contenues dans cette fiche technique sont données de bonne foi, en l'état actuel de nos connaissances, et selon les indications communiquées par le producteur ou le fournisseur. Il appartient au client de vérifier la conformité de la marchandise par rapport à l'usage qu'il en fait.

Création :

12/06/12

12 rue René Cassin
37390 NOTRE DAME

Tél :
02 47 85 55 00
Fax :02 47 41 33 32

FICHE TECHNIQUE

Mélange du trappeur, 70 g
Trapper blend, 70g

Code article KEREX
Nom latin (si disponible)
/ EAN Code
Code barre

/ KEREX Code

/ (Latin name)

TEEPTRAPPEUR
X
3760063322262

Poids net
Poids brut
Origine

/ net weight
/ gross weight
/ Origin

0,07 Kilogramme

0,125 Kilogramme
CANADA

/ General information

Informations générales

DLUO conseillée / "Best before date" recommended

Nomenclature douanière / Customs code

Conditions idéales de stockage

/ Conditions of storage

Ingrédients :

Conserver dans un endroit frais et sec
Store in a cool dry place

5 ans / 5 years

0910999900

Sucre, poivre noir, coriandre, légumes déshydratés (ail, oignon, poivron rouge), sel de mer, sucre d'érable, arôme d'érable naturel, huile végétale (canola)

Sugar, black pepper, coriander, dehydrated vegetables (garlic, onion, red bell pepper), sea salt, maple sugar, natural maple aroma, vegetable oil (canola)

/ Ingredients

Contaminants / Contaminating

Ionisation / Irradiation

OGM / GMO

Pesticides/ Pesticides

Métaux Lourds

/ Heavy Metals

Allergènes et leurs dérivés (si présents)

/ Allergens (if existing)

Conformité à la directive 1999/2/CE (22/02/99)

Produit non ionisé et ne contenant pas d'ingrédients ionisés.

Not irradiated

accordingly with the Reg 1999/2/CE (22/02/99).

Free from GMO

Ne contient pas d'OGM, est non soumis à l'étiquetage sur les OGM

Conforme à la directive 396/2005 /CE

In accordance with Reg 396/2005 /CE.

Conforme au règlement 1881/2006 /CE

In accordance with Reg 1881/2006 /CE..

Gluten

Crustacés

Oeufs

Poisson

Soja

Lait

Fruits à coque - Arachides

Céleri

Moutarde

Sésame

Sulfites

Lupin

Mollusques

/ Gluten

/ Crustaceans

```

/ Eggs
/ Fish
/ Soy
/ Milk
/ Peanuts and Treenuts
/ Celery and celeriac
/ Mustarde
/ Sésame
/ Sulphites
/ Lupin
/ Shellfish
-----
Absence
-----
Caractères microbiologiques
-----
/ Microbiological characteristics
-----
Microorganismes aérobies 30 °C
Escherichia coli
Salmonelles
Levures
Moisissures
Aflatoxine Total
Aflatoxine B1
-----
/ Total plat count (APC)
E. Coli
/
/ Salmonella
/ Yeasts
/ Moulds
/ Total aflatoxin
B1 aflatoxin
/
-----
NF V05-051 < 6 000 000 / g
NF V08-053 < 10 / g
NF V08-052 Absence dans 25g
NF V08-059 < 10 000 / g
NF V08-059 < 10 000 / g
Kit Enzymatique < 10 ppb
Kit Enzymatique < 5 ppb
-----
```

1.3 Train / Test split

On procède au découpage en un jeu d'entraînement et un jeu de test en gardant 400 produits pour l'entraînement et 100 produits pour le test :

```
[25]: train, test = train_test_split(splitted_df, train_size=400, random_state=42)
```

1.4 Entraînement sur le jeu d'entraînement

On entraîne un modèle `SimilaritySelector`, sur le set d'entraînement :

```
[26]: model = SimilaritySelector()  
  
[27]: model.fit(train['blocks'], train['ingredients'])  
  
[27]: <src.pimest.SimilaritySelector at 0x7f0ebad7bb80>  
  
[28]: len(model.count_vect.vocabulary_)  
  
[28]: 1204  
  
[29]: predicted = pd.Series(model.predict(test['blocks']),  
                           index=test.index,  
                           name='predicted'  
                           )  
predicted = pd.concat([test['ingredients'], predicted], axis=1)  
predicted
```

[29]:

uid	ingredients	predicted
2892dd68-e3a6-474c-b543-3ebfd3490658	Café instantané, café torréfié moulu (3%).	- NESTLÉ a un système de management...
a57c1561-b88e-4694-8bd8-55623f2afa17	Lentilles blondes	Cette fiche technique n'a pas de va...
3634fb1e-ee79-41d1-8aaa-084c1fae5bd5	Poire 99,9%, antioxydant: acide ascorbique.	Ce produit est une purée de fruits...
345591f4-d887-4ddc-bb40-21337fa9269d	Gésier de dinde émincé 50%, graisse de canard ...	Gésier de dinde émincé 50%, graisse de...
13980d31-9002-457d-8d49-b451f08f473c	Edulcorants sorbitol, isomalt, sirop de maltit... sucre, amidon modifié, LACTOSÉRUM en poudre, d...	Edulcorants sorbitol, isomalt, sirop de maltit... sucre, amidon modifié, LACTOSÉRUM en poudre, d...
74297717-3fa8-4aed-95cc-e8737c1a6157	... paprika, poivre noir, coriandre, cumin, ail se...	... paprika, poivre noir, coriandre, cumin, ail se...
9458a288-04f0-49fc-9d92-d88c696ab085	Maltodextrine, amidon de maïs, sel, farine de ...	Maltodextrine, amidon de maïs, sel, farine de ...
6e976147-adeb-4d2d-925a-cb7c58c111a2	NaN	Boisson gazeuse aromatisée au jus de ...
21233a00-bc20-40fc-acb9-ee2e2321cac2	Farine de BLÉ 20% - Huile de colza - OEUFS ent...	LISTE D'INGREDIENTS\nLes ingrédients:
c2ef743e-f3f2-4e8a-aab0-1e6cbeb71666	Persil	Céréales contenant du gluten (à savo...
04235024-80f3-46c2-bad0-aae0d5fab024	mini poivrons jaunes, eau, sucre, sel, affermim...	mini poivrons jaunes, eau, sucre, sel, affermim...
c3b6b4df-e586-4f10-8e58-15fb0f0816acb	100% haricots blancs bio	Les légumes secs sont mis en avant
8d833da0-610f-4045-9877-adf8ad9ea56c	Poudre de lait écrémé, anti-agglomérant : E551...	DESCRIPTION DU PRODUIT : Poudre de lait écrémé
209431f8-9436-49cb-a6fe-16225deb5c3f	HAPPY CHERRY\nsirop de glucose; sucre; gélatin...	Ingrédients: sucre; sirop de glucose; gélatin...
aeda7bf1-4d4d-44bb-8518-2e91fc6fd76c	Farine de BLE, huile de colza non hydrogénée, ...	Farine de BLE, huile de colza non hydrogénée, ...
0481d91b-9653-42e7-b525-9dc9b87b06f2	SIROP DE GLUCOSE / SUCRE / AROMES / ACIDIFIANT...	MENTIONS D'ÉTIQUETAGE- LABELS MENTIONNÉS :
7c709ab6-b913-4a02-9396-a6469b09482a	Olivs vertes 98%denoyautées , huile tournesol...	\n Ingrédients \nOlivs vertes 98%denoyautées , huile tournesol...
adb90cc7-4b91-4771-b505-61a207cc1f96	Pommes de terre 59,5 % - Céleris 40 % - Amidon...	Pommes de terre 59,5 % - Céleris 40 % - Amidon...
484ac00a-a670-46a9-a9c4-5114174d9e3b	Eau ; jus de fruit de la passion ; sucre ; épau...	Céréales contenant du gluten (2) \n
d8b0687e-5e25-4ff9-9384-087f993218bc	Eau, huile de tournesol, beurre 9,5 %, jaune d...	Une sauce onctueuse et savoureuse a...
7f622727-e4ad-45cc-9af4-4509acf91154	pâte de cacao 50,5% ; sucre 47,5% ; beurre de ...	Composition typique (Données inappro...
46211a29-279c-4c8f-9f06-635d61f83d66	NaN	Anhydride sulfureux et sulfites en
49b11281-34ea-44b0-a11c-4ae21d4c58e3	Pommes de terre, eau, sel.	Une poudre superfine sans grumeaux
194419d0-d9f2-4799-81ac-d9e3aa77fd27	Farine de pois chiche	Pour 100 g*AR**Pour 100 g*AR**Energie
c6fd7472-f363-4aaf-8702-bd56e2e139de	Lentilles, eau, sel, arôme naturel (céleri)	* Produits issus de l'Agriculture Bio
8065d4f6-0731-4018-9bcb-f654466badb0	Sucre roux de canne* (64%), amidon de maïs*, ...	Ingrédients : Chocolat au lait (sucr...
e67341d8-350f-46f4-9154-4dbbb8035621	Chocolat au lait (sucre, beurre de cacao, LAIT...)	Ingrédients : pâte à tartiner aux noisettes
09cf7d7b-4cf9-4885-a2b2-da65a4cfe5c3	pâte à tartiner aux noisettes et au cacao 81,5...	Sucre, farine de FROMENT, poudre d'OEUVFS entie...
1868226c-812c-438d-bba4-6b046537d0cd	Sucre, farine de FROMENT, poudre d'OEUVFS entie...	Amidon de maïs* - Lait écrémé* - Sel - Fécule ...
2cd5567a-bee6-46f2-a4bd-19d2b42ec001	Amidon de maïs* - Lait écrémé* - Sel - Fécule ...	NOISETTES entières décortiquées.
d59d96cb-0230-4090-8220-78ce8496fd91	NOISETTES entières décortiquées.	Sucre; sirop de glucose; graisse de palme; hum...
de22b1fa-039d-479e-b36e-608946b75bb8	100% Arabica	100% Arabica
8dec0469-c9f5-4139-be25-efa258959444	- 100% Semoule de BLE dur de qualité supérieur...	- 100% Semoule de BLE dur de qualité supérieur...
2ca5dc9e-8058-499a-affe-3ec9c06d55b7	Lait écrémé 59,5%, lait en poudre reconstitué ...	Lait écrémé 59,5%, lait en poudre reconstitué ...
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8	Lait écrémé 72%, caramel 10% crème, sucre, ami...	Lait écrémé 72%, caramel 10% crème, sucre, ami...
3b7deab3-349b-4b0d-b4d8-c4ba53e61b58	Pommes 89%, purée de fraises à base de concentr...	Pommes 89%, purée de fraises à base de concentr...
22663c1d-2580-40b3-b4a0-ed8ba1054980	- Soja fermenté naturellement (soja, sel, eau)...	- Soja fermenté naturellement (soja, sel, eau)...
6566e18d-3-bdd-43d8-ab0c-de51894621f9	Farine de FROMENT, poudre de LACTOSERUM, sucre...	Farine de FROMENT, poudre de LACTOSERUM, sucre...
eadb972c-6623-472d-a11d-489a7faf6f11	Débris de truffes d'hiver, jus de truffes, sel	\nOrigine Truffes et Sel : ...
b8cbe6f9-71d4-4e51-a169-1c163d49a561	Maltodextrine, amidon modifié de pomme de terr...	INFORMATIONS PRODUIT \n \nDénomination
e51b7fd6-d878-47f8-a36b-f10f8d4087bd	Graine de coriandre (19,5%), ail déshydraté, c...	GRAINS\nMaïs (grain) et produits à
78665d97-164a-4c23-956b-3e41f5f7e423	- 100% Semoule de BLE dur de qualité supérieur...	Conforme à : \n- Décret « Pâtes Alimentaires
6dc9277e-3cd7-415b-a4c7-33ec3a0ba705	cèpes 70% (Boletus edulis et respective famill...)	Dénomination légale : Crème dessert
f4c16bbd-130d-4e12-b2a0-541853dd560d	Haricots blancs issus de l'Agriculture Biologique	Liste ingrédients : Pommes 89%, purée de fraise...
046cdcb1f-1915-4916-8874-902cc5ec73be	Eau, maltodextrine, sel, arômes, sucre, arôme ...	Céréales contenant du gluten \net de l'amidon
c91c8d53-4260-4d9c-851e-7756672a8941	Sucre, huiles végétales (Colza), noisettes (1...	Farine de FROMENT, poudre de LACTOSERUM, sucre...
a0492df6-9c76-4303-8813-65ec5ccbfa70	NaN	\nOrigine Truffes et Sel : ...
440ca0b4-1c79-433f-ac8d-6e2ae77d3288	Thon Albacore (92%), eau (7%), sel (1%)	INFORMATIONS PRODUIT \n \nDénomination
f1982954-f091-4aa1-addb-6659062e0f66	Croustilles de céréales enrobées de chocolat a...	GRAINS\nMaïs (grain) et produits à
6c07fd47-116d-4531-a164-d4f4040f212e	sucre; sirop de glucose; dextrose; gélatine; a...	Conforme à : \n- Décret « Pâtes Alimentaires
846db626-d8a9-49b2-be8d-7d724adeaff3	Huile de colza, eau, vinaigre d'alcool, jaunes...	Dénomination légale : Crème dessert
f45db604-11ad-4756-aeab-3a5a1a34f914	sel, exhausteurs de goût : glutamate, inosinat...	Liste ingrédients : Pommes 89%, purée de fraise...
c8b299c5-22d3-40ae-8df3-ad638507803f	OEUVFS, farine de BLE, sucre, amidon de BLE, st...	Céréales contenant du gluten \net de l'amidon
0eb6fa2e-c9e5-4d99-984e-625b1e6bb136	Purée de tomates mi réduite (64%), sucre, vina...	Farine de FROMENT, poudre de LACTOSERUM, sucre...
09e45b38-4da1-4eb5-888a-3ebd437a2291	Suillus luteus (40%), Volvariella volvacea (25...	\nOrigine Truffes et Sel : ...
41da4d6f-7e9f-4f95-bf2a-2acdd7138cd9	Filets de maquereaux (61 %), eau, concentré de...	INFORMATIONS PRODUIT: \nNOM DU PRODUIT:
14c9068c-633a-4eea-bb4a-6ac5de09a32	Salicornes de culture, eau, sel, acide citrique	Cette fiche technique n'a pas de va...
6622442d-d88f-4b90-9414-b91c9e8e5296	semoule de blé dur supérieure et de l'eau	Eau, maltodextrine, sel, arômes, sucre, arôme ...
a2418174-e16a-41e0-ac14-c87208fb3529	Semoule de blé dur (71%), lentilles vertes pré...	\nCOD. PRODUIT : CPGLLAB 49 \nDESCRIPTION
5adc7512-6168-4966-ae3f-f6ec133bf56e	NaN	10\n70
b4b57208-278a-489e-9814-f8a5ae5f44cf	Cerises noires 65%, sucre, gélifiant : pectine...	THON ALBACORE MORCEAUX NATUREL EN
75088d85-f350-4d81-a7f4-954411ba089e	Eau, purée de tomate à base de concentré*, suc...	\nCroustilles de céréales enrobées de
064d3b22-c1cc-41bd-bd03-56e8829bd4cd	Pêches et poires en cubes (avec leur jus d'ori...	Ingrédients: sucre; sirop de glucose; dextrose;
c5344fe1-ac16-4630-824e-6036ae491399	Sirop de glucose, sucre, eau, stabilisants (E4...	Huile de colza, eau, vinaigre d'alcool, sel, ...
2286f782-9d2e-410f-84c4-4ab88003a002	- 100% Semoule de blé dur de qualité supérieure	Dénomination légale du produit : bo
4f83306f-66de-4546-9b12-7790b57b61ae	Farine de blé, beurre en poudre (7 %), sucre, ...	OEUVFS, farine de BLE, sucre, amidon de
42094f22-5907-4089-bdad-0a19f09b3f8	SUCRE DE CANNE\EAU, JUS DE KIWI A BASE DE CON...	Liste des ingrédients : Purée de tomate, ...
8afeb736-1b04-4aa7-9b25-fa534a177019	Flageolets verts. Jus : eau, sel, affermissant...	Suillus luteus (40%), Volvariella volvacea (25...
eb5bb1e3-0a86-46cb-9d76-3a965cf20c4b	Huile de tournesol, huile de tournesol hauteme...	\nFormat : \n \nLieu de fabrication
5cee689e-6fb1-493c-b232-1d8fb1f88a57	Graine de courge, canneberge, graine de tourne...	Se consomment en légumes d'accompagnement
3624dd37-f88e-47c0-9e9c-bb5163bfbcaca	vinaigre d'alcool, piment jalapeno, eau, sel, ...	Ingrédients: semoule de blé dur supérieure et de
1268d9ef-d848-41ad-973c-7f9e694a4625	NaN	Semoule de blé dur (71%), lentilles vertes pré...
6bdb201d-5879-423b-96b8-3ae88b857818	Cerises noires 65%, sucre, gélifiant : pectine...	Boisson gazeuse aromatisée au jus de ...

```
[30]: predicted['pred_len'] = predicted['predicted'].apply(len)
sub_sample = predicted.loc[predicted['pred_len'] <= 500, ['ingredients', 'predicted']]
```

```
[30]:
```

uid	ingredients	predicted
2892dd68-e3a6-474c-b543-3ebfd3490658	Café instantané, café torréfié moulu (3%).	- NESTLÉ a un système de management...
3634fb1e-ee79-41d1-8aaa-084c1fae5bd5	Poire 99,9%, antioxydant: acide ascorbique.	Ce produit est une purée de fruits...
345591f4-d887-4ddc-bb40-21337fa9269d	Gésier de dinde émincé 50%, graisse de canard ...	Gésier de dinde émincé 50%, graisse...
13980d31-9002-457d-8d49-b451f08f473c	Edulcorants sorbitol, isomalt, sirop de maltit... sucre, amidon modifié, LACTOSÉRUM en poudre, d...	Edulcorants sorbitol, isomalt, siro...
74297717-3fa8-4aed-95cc-e8737c1a6157	paprika, poivre noir, coriandre, cumin, ail se...	Z16005 / 002\nsucre, amidon modifié...
9458a288-04f0-49fc-9d92-d88c696ab085	Maltodextrine, amidon de maïs, sel, farine de ...	Gluten\nCrustacés\nOeufs\nPoisson\nMaltodextrine, amidon de maïs, sel,
6e976147-adeb-4d2d-925a-cb7c58c111a2	Nan	Boisson gazeuse aromatisée au jus d...
21233aa00-bc20-40fc-acb9-ee2e2321cac2	Persil	Céréales contenant du gluten (à savo...
04235024-80f3-46c2-bad0-aae05fab024	mini poivrons jaunes, eau, sucre, sel, affermi...	mini poivrons jaunes, eau, sucre, s...
c3b6b4df-e586-4f10-8e58-15fb0816acb	100% haricots blancs bio	Les légumes secs sont mis en avant...
8d833da0-610f-4045-9877-adf8ad9ea56c	HAPPY CHERRY\nsirop de glucose; sucre; gélatin...	Ingrédients: sucre; sirop de glucos...
aeda7bf1-4d4d-44bb-8518-2e91fc6fd76c	Farine de BLE, huile de colza non hydrogénée, ...	Farine de BLE, huile de colza non h...
0481d91b-9653-42e7-b525-9dc9b87b0f6f2	SIROP DE GLUCOSE / SUCRE / AROMES / ACIDIFIANT...	MENTIONS D'ÉTIQUETAGE- LABELS MENTI...
7c709a5e-b913-4a02-9396-a6469b09482a	Olives vertes 98%denoyautées , huile tournesol...	\n Ingrédients \nOlives vertes 98%de...
adb90cc7-4b91-4771-b505-61a207cc1f96	Pommes de terre 59,5 % - Céleris 40 % - Amidon...	Pommes de terre 59,5 % - Céleris 40%
484ac00a-a670-46a9-a9c4-5114174d9e3b	Eau ; jus de fruit de la passion ; sucre ; épau...	Céréales contenant du gluten (2) \n...
d8b0687e-5e25-4ff9-9384-087f1993218bc	pâte de cacao 50,5% ; sucre 47,5% ; beurre de ...	Composition typique (Données inapp...
46211a29-279c-4c8f-9f06-635d61f83d66	Nan	Anhydride sulfureux et sulfites en...
49b11281-34ea-44b0-a11c-4ae21d4c58e3	Pommes de terre, eau, sel.	Une poudre superfine sans grumeaux...
194419d0-d9f2-4799-81ac-d9e3aa77fd27	Farine de pois chiche	Pour 100 g*AR**Pour 100 g*AR**Ener...
c6fd7472-f363-4aa9-8702-bd56e2e139de	Lentilles, eau, sel, arôme naturel (céleri)	* Produits issus de l'Agriculture Bio...
8065d46f-0731-4018-9bcb-f654466badb0	Sucre roux de canne*° (64%), amidon de maïs*, ...	Ingrédients : pâte à tartiner aux r...
e67341d8-350f-46f4-9154-4dbbb8035621	pâte à tartiner aux noisettes et au cacao 81,5...	Sucre, farine de FROMENT, poudre d'OEufs entie...
1868226c-812c-438d-bba4-6b046537d0cd	Sucre, farine de FROMENT, poudre d'OEUF entier...	Amidon de maïs* - Lait écrémé* - Sel - Fécul...
2cd5567a-bee6-46f2-a4bd-19d2b42ec001	Amidon de maïs* - Lait écrémé* - Sel - Fécul...	Sucre; sirop de glucose; graisse de palme; hum...
d59d96cb-0230-4090-8220-78ce8496fd91	Sucre; sirop de glucose; graisse de palme; hum...	Lait écrémé 72%, caramel 10% crème, sucre, ami...
8dec0469-c9f5-4139-be25-efa258959444	Lait écrémé 72%, caramel 10% crème, sucre, ami...	Pommes 89%, purée de fraises à base de concentr...
22663c1d-2580-40b3-b4a0-ed8ba1054980	Farine de FROMENT, poudre de LACTOSERUM, sucre...	Farine de FROMENT, poudre de LACTOS...
6566e18d-3-bdd-43d8-ab0c-de51894621f9	Débris de truffes d'hiver, jus de truffes, sel	\nOrigine Truffes et Sel : ...
b8cbe6f9-71d4-4e51-a169-1c163d49a561	cèpes 70% (Boletus edulis et respective famill...	CODE DU PRODUIT: \nNOME DU PRODUIT:
e51b7fd6-d878-47f8-a36b-f10f8d4087bd	Eau, maltodextrine, sel, arômes, sucre, arôme ...	Eau, maltodextrine, sel, arômes, su...
046cdb1f-1915-4916-8874-902cc5ec73be	Nan	10\n70
a0492df6-9c76-4303-8813-65ec5ccbfa70	Thon Albacore (92%), eau (7%), sel (1%)	THON ALBACORE MORCEAUX NATUREL EN
f1982954-f091-4aa1-addb-6659062e0f66	sucre; sirop de glucose; dextrose; gélatine; a...	Ingrédients: sucre; sirop de glucos...
6c07fd47-116d-4531-a164-d4f4040f212e	Huile de colza, eau, vinaigre d'alcool, jaunes...	Huile de colza, eau, vinaigre d'alco...
f45db604-11ad-4756-aea3-3a5a1a34f914	OEufs, farine de BLE, sucre, amidon de BLE, st...	OEufs, farine de BLE, sucre, amidon...
c8b299c5-22d3-40ae-8df3-ad638507803f	Purée de tomates mi réduite (64%), sucre, vina...	Liste des ingrédients : Purée de to...
09e45b38-4da1-4eb5-888a-3ebd437a2291	Suillus luteus (40%), Volvariella volvacea (25...	Suillus luteus (40%), Volvariella v...
41da46f6-7e9f-4f95-bf2a-2acdd7138cd9	Filets de maquereaux (61 %), eau, concentré de...	\nFormat : \n \nLieu de fabrication : ...
14c9068c-633a-4eea-bb4a-6ac5de0e9a32	Salicornes de culture, eau, sel, acide citrique	Se consomment en légumes d'accompagn...
6622442d-d88f-4b90-9414-b91c9e8e5296	semoule de blé dur supérieure et de l'eau	Ingrédients: semoule de blé dur sup...
a2418174-e16a-41e0-ac14-c87208fb3529	Nan	Boisson gazeuse aromatisée au jus d...
5adc7512-6168-4966-ae3f-f6ec133bf56e	Cerises noires 65%, sucre, gélifiant : pectine...	Ingrédients : Cerises noires 65%, s...
75088d85-f350-4d81-a7f4-954411ba089e	Eau, purée de tomate à base de concentré*, suc...	de maïs, sel, conservateurs : E202-...
064d3b22-c1cc-41bd-bd03-56e8829bd4cd	Pêches et poires en cubes (avec leur jus d'ori...	INGREDIENTS: Pêches et poires en cu...
c5344fe1-ac16-4630-824e-6036ae491399	Sirop de glucose, sucre, eau, stabilisants (E4...	Sirop de glucose, sucre, eau, stabili...
2286f782-9d2e-410f-84c4-4ab88003a002	- 100% Semoule de blé dur de qualité supérieure	\n- 100% Semoule de blé dur de qual...
4f83306f-66de-4545-9b12-7790b57b61ea	Farine de blé, beurre en poudre (7 %), sucre, ...	Farine de blé, beurre en poudre (7 %)
42094f22-5907-4089-bdfa-0a19ff09b3fe	SUCRE DE CANNE, EAU, JUS DE KIWI A BASE DE CON...	LISTE DES INGREDIENTS\nSUCRE DE CAN...
8afeb736-1b04-4aa7-9b25-fa534a177019	Flageolets verts. Jus : eau, sel, affermissant...	Flageolets verts. Jus : eau, sel, ...
eb5bb1e3-0a86-46cb-9d76-3a965cf20c4b	Huile de tournesol, huile de tournesol hauteme...	Gluten\nCrustacés\nOeufs\nPoisson\n
5cee689e-6fb1-493c-b232-1d8fb1f88a57	Graine de courge, canneberge, graine de tourne...	Liste d'ingrédients : vinaigre d'al...
3624dd37-f88e-47c0-9e9c-bb5163bfbaca	vinaigre d'alcool, piment jalapeno, eau, sel, ...	Valeur énergétique : \n Matières gr...
1268d9ef-d848-41ad-973c-7f9e694a4625	AMANDES décortiquées	ajouter le produit à la préparation
6bdb201d-5879-423b-9b68-3ae88b857818	Sucre, amidon de maïs, arôme vanille	Sucre, cacao maigre en poudre (beurre de cacao...
1de02b1c-f17e-4d46-b90f-3a6c37cef6aa	Sucre, cacao maigre en poudre (beurre de cacao...	Si le produit est vendu en Espagne
536361db-1bbb-4e64-ae53-d970eeac7db2	Tofu* 76.6% (eau, soja* dépelliculé 20.7%, gél...	Carottes, eau, sucre, sel, vinaigre
e521bd01-f2bb-4e00-9ae0-0151a1c7a047	Carottes, eau, sucre, sel, vinaigre d'alcool, ...	Liste des Ingrédients:\nsucre*, LAIT
8278ffc7-c82b-44b9-9e4d-9150943faaf1	sucre*, LAIT en poudre*, beurre de cacao*, pât...	Les points forts de ce riz \n• Un p...
63968dc3-6e7c-4056-bd53-820c6cc925be	Nan	Dans le cadre des recommandations d...
d1be6f74-1e0e-4631-bb4a-6b16b9fc908f	Tilleul (100%).	Égoutter, ne pas\nrincer. Faire sa...
64836dd3-5b4f-42ff-862a-31ee19cefda4	Eau, haricots verts, sel.	Légumes 43,2 % (pomme de terre, oignon, carott...
bb77c7b0-9c63-4869-9ab1-823ba1158f53	Légumes 43,2 % (pomme de terre, oignon, carott...	Liste des Ingrédients:\nsucre, pâte de
b7d7621a-fcdd-4487-9b38-e07fae698c4a	sucré, pâte de cacao, beurre de cacao, cacao m...	listé des ingrédients :\nMaltodextrin...
dc536305-82fd-4afe-a472-5056ca0e21ea	Maltodextrine, édulcorant : sucralose (1,23%).	Farine de BLÉ 63%, eau, sucre, huile
df1caa23-9714-4659-803b-33501d64eead	Farine de BLÉ 63%, eau, sucre, huile de colza, ...	Croquant sésame chocolat\nBarre cro...
272246a4-d79d-47fc-a475-7b873b6bb47f	Graines de sésame 37%, chocolat de couverture ...	Liste ingrédients : Sirop de glucos...
6dfae8fd-6111-4a57-862e-c20a39a195e0	Sirop de glucose-fructose, framboises 35%, suc...	\n \nVALEURS NUTRITIONNELLES pour 1
8f9f7f4e-da12-4cc2-9d02-b9e06d659f4	Jus d'orange à base de concentré	Ingrédients : Farine de BLÉ, sucre,
9ef0d351-4982-4a2d-88a9-85573dc396dc	Farine de BLÉ, sucre, huile de colza,, cacao m...	A) Ingrédients : \n \nPiment rouge
ebfc9e73-5d91-4b45-8331-8c8f9bed3bb3	Piment rouge fort équeuté* (85%), cumin, ail m...	
c33aa83e-a502-4339-a8e0-c56db2e59e69		
54f40033-f9cf-411c-81a5-11974f6715aa		

On constitue une table pour intégration dans le rapport :

```
[31]: with pd.option_context("max_colwidth", 100000):
    tex_str = (
        sub_sample.sample(20, random_state=41)
            .replace(r'^\s*$', np.nan, regex=True)
            .to_latex(index=False,
                       index_names=False,
                       column_format='p{7cm}p{7cm}',
                       na_rep='<rien>',
                       longtable=True,
                       header=["Liste d'ingrédients cible", "Liste d'ingrédients prédictive"],
                       label='tbl:GT_prediction_sample',
                       caption="Extrait des résultats de la prédition",
            )
            .replace(r'\textbackslash n', r' \newline ')
            .replace(r'\\', r'\\ \hline')
    )

# with open(Path('..') / 'tbls' / 'GT_prediction_sample.tex', 'w') as file:
#     file.write(tex_str)
```

Performance_measurement

Pierre MASSÉ

May 12, 2020

1 Mesure de la performance du modèle

L'objet de ce notebook est d'illustrer la méthodologie de mesure de la performance du modèle.

1.1 Préambule technique

```
[1]: # setting up sys.path for relative imports
from pathlib import Path
import sys
project_root = str(Path(sys.path[0]).parents[1].absolute())
if project_root not in sys.path:
    sys.path.append(project_root)

[2]: # imports and customization of display
import os
from functools import partial
import numpy as np
import pandas as pd
pd.options.display.min_rows = 6
pd.options.display.width=108
from sklearn.feature_extraction.text import CountVectorizer
from sklearn.model_selection import train_test_split
from sklearn.model_selection import cross_val_score, cross_validate
from sklearn.pipeline import Pipeline
from matplotlib import pyplot as plt

from src.pimest import ContentGetter
from src.pimest import PathGetter
from src.pimest import PDFContentParser
from src.pimest import BlockSplitter
from src.pimest import SimilaritySelector
from src.pimest import custom_accuracy
from src.pimest import text_sim_score
from src.pimest import text_similarity
from src.pimest import build_text_processor
```

1.2 Acquisition des données

On récupère les données manuellement étiquetées et on les intègre dans un dataframe

```
[3]: ground_truth_df = pd.read_csv(Path('..') / '..' / 'ground_truth' / 'manually_labelled_ground_truth.csv',
                                    sep=';',
                                    encoding='latin-1',
                                    index_col='uid')
ground_truth_uids = list(ground_truth_df.index)

acqui_pipe = Pipeline([('PathGetter', PathGetter(ground_truth_uids=ground_truth_uids,
                                                train_set_path=Path('..') / '..' / 'ground_truth',
                                                ground_truth_path=Path('..') / '..' / 'ground_truth',
                                                )),
                      ('ContentGetter', ContentGetter(missing_file='to_nan')),
                      ('ContentParser', PDFContentParser(None_content='to_empty')),
```

```

        ],
        verbose=True)

texts_df = acqui_pipe.fit_transform(ground_truth_df)
texts_df

```

[Pipeline] ... (step 1 of 3) Processing PathGetter, total= 0.1s
[Pipeline] ... (step 2 of 3) Processing ContentGetter, total= 0.7s
Launching 8 processes.
[Pipeline] ... (step 3 of 3) Processing ContentParser, total= 37.3s

[3]:

	designation \
uid	
a0492df6-9c76-4303-8813-65ec5ccbfa70	Concentré liquide Asian en bouteille 980 ml CHEF
d183e914-db2f-4e2f-863a-a3b2d054c0b8	Pain burger curry 80 g CREATIV BURGER
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8	Macaroni en sachet 500 g PANZANI
...	...
e67341d8-350f-46f4-9154-4dbbb8035621	PRÉPARATION POUR CRÈME BRÛLÉE BIO 6L
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3	Céréales instantanées en poudre saveur caramel...
Ofaad739-ea8c-4f03-b62e-51ee592a0546	FARINE DE BLÉ TYPE 45, 10KG

	ingredients \
uid	
a0492df6-9c76-4303-8813-65ec5ccbfa70	Eau, maltodextrine, sel, arômes, sucre, arôme ...
d183e914-db2f-4e2f-863a-a3b2d054c0b8	Farine de blé T65, eau, levure, vinaigre de ci...
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8	- 100% Semoule de BLE dur de qualité supérieur...
...	...
e67341d8-350f-46f4-9154-4dbbb8035621	Sucre roux de canne*° (64%), amidon de maïs*, ...
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3	Farine 87,1 % (Blé (GLUTEN), Blé hydrolysé (GL...
Ofaad739-ea8c-4f03-b62e-51ee592a0546	Farine de blé T45

	path \
uid	
a0492df6-9c76-4303-8813-65ec5ccbfa70	.../ground_truth/a0492df6-9c76-4303-8813-65e...
d183e914-db2f-4e2f-863a-a3b2d054c0b8	.../ground_truth/d183e914-db2f-4e2f-863a-a3b...
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8	.../ground_truth/ab48a1ed-7a3d-4686-bb6d-ab4...
...	...
e67341d8-350f-46f4-9154-4dbbb8035621	.../ground_truth/e67341d8-350f-46f4-9154-4db...
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3	.../ground_truth/a8f6f672-20ac-4ff8-a8f2-3bc...
Ofaad739-ea8c-4f03-b62e-51ee592a0546	.../ground_truth/Ofaad739-ea8c-4f03-b62e-51e...

	content \
uid	
a0492df6-9c76-4303-8813-65ec5ccbfa70	b'%PDF-1.5\r\n%\xb5\xb5\xb5\xb5\r\n1 0 obj\r\n...
d183e914-db2f-4e2f-863a-a3b2d054c0b8	b'%PDF-1.5\r%\xe2\xe3\xcf\xd3\r\n4 0 obj\x<</L...
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8	b'%PDF-1.4\r%\xc7\xec\x8f\xa2\xn5 0 obj\x<</Len...
...	...
e67341d8-350f-46f4-9154-4dbbb8035621	b'%PDF-1.7\r\n%\xb5\xb5\xb5\xb5\r\n1 0 obj\r\n...
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3	b'%PDF-1.5\r\n%\xb5\xb5\xb5\xb5\r\n1 0 obj\r\n...
Ofaad739-ea8c-4f03-b62e-51ee592a0546	b'%PDF-1.5\r\n%\xb5\xb5\xb5\xb5\r\n1 0 obj\r\n...

	text
uid	
a0492df6-9c76-4303-8813-65ec5ccbfa70	Concentré Liquide Asian CHEF® \n\nBouteille de...
d183e914-db2f-4e2f-863a-a3b2d054c0b8	
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8	Direction Qualité \n\n \n\n \nPATES ALIMENTA...
...	...
e67341d8-350f-46f4-9154-4dbbb8035621	FICHE TECHNIQUE \n\nCREME BRÛLÉE 6L \n\nREF : ...
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3	81 rue de Sans Souci - CS13754 - 69576 Limones...
Ofaad739-ea8c-4f03-b62e-51ee592a0546	\n1050/10502066400 \n\n10502055300/1050202520...

[500 rows x 5 columns]

On splitte les textes en blocs de manière basique.

```
[4]: def splitter(text):
    return(text.split('\n\n'))

split_transfo = BlockSplitter(splitter_func=splitter)
splitted_df = split_transfo.fit_transform(texts_df)
splitted_df
```

Launching 8 processes.

```
[4]: designation \
uid
a0492df6-9c76-4303-8813-65ec5ccbfa70 Concentré liquide Asian en bouteille 980 ml CHEF
d183e914-db2f-4e2f-863a-a3b2d054c0b8 Pain burger curry 80 g CREATIV BURGER
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8 Macaroni en sachet 500 g PANZANI
...
e67341d8-350f-46f4-9154-4dbbb8035621 PRÉPARATION POUR CRÈME BRÛLÉE BIO 6L
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3 Céréales instantanées en poudre saveur caramel...
0faad739-ea8c-4f03-b62e-51ee592a0546 FARINE DE BLÉ TYPE 45, 10KG

ingredients \
uid
a0492df6-9c76-4303-8813-65ec5ccbfa70 Eau, maltodextrine, sel, arômes, sucre, arôme ...
d183e914-db2f-4e2f-863a-a3b2d054c0b8 Farine de blé T65, eau, levure, vinaigre de ci...
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8 - 100% Semoule de BLE dur de qualité supérieure...
...
e67341d8-350f-46f4-9154-4dbbb8035621 Sucre roux de canne*° (64%), amidon de maïs*, ...
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3 Farine 87,1 % (Blé (GLUTEN)), Blé hydrolysé (GL...
0faad739-ea8c-4f03-b62e-51ee592a0546 Farine de blé T45

path \
uid
a0492df6-9c76-4303-8813-65ec5ccbfa70 ../../ground_truth/a0492df6-9c76-4303-8813-65e...
d183e914-db2f-4e2f-863a-a3b2d054c0b8 ../../ground_truth/d183e914-db2f-4e2f-863a-a3b...
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8 ../../ground_truth/ab48a1ed-7a3d-4686-bb6d-ab4...

...
e67341d8-350f-46f4-9154-4dbbb8035621 ../../ground_truth/e67341d8-350f-46f4-9154-4db...
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3 ../../ground_truth/a8f6f672-20ac-4ff8-a8f2-3bc...
0faad739-ea8c-4f03-b62e-51ee592a0546 ../../ground_truth/0faad739-ea8c-4f03-b62e-51e...

content \
uid
a0492df6-9c76-4303-8813-65ec5ccbfa70 b'%PDF-1.5\r\n%\xb5\xb5\xb5\xb5\r\n1 0 obj\r\n...
d183e914-db2f-4e2f-863a-a3b2d054c0b8 b'%PDF-1.5\r%\xe2\xe3\xcf\xd3\r\n4 0 obj\r\n<</Len...
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8 b'%PDF-1.4\n%\xc7\xec\x8f\x a2\n5 0 obj\r\n<</Len...

...
e67341d8-350f-46f4-9154-4dbbb8035621 b'%PDF-1.7\r\n%\xb5\xb5\xb5\xb5\r\n1 0 obj\r\n...
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3 b'%PDF-1.5\r\n%\xb5\xb5\xb5\xb5\r\n1 0 obj\r\n...
0faad739-ea8c-4f03-b62e-51ee592a0546 b'%PDF-1.5\r\n%\xb5\xb5\xb5\xb5\r\n1 0 obj\r\n...

text \
uid
a0492df6-9c76-4303-8813-65ec5ccbfa70 Concentré Liquide Asian CHEF® \n\nBouteille de...
d183e914-db2f-4e2f-863a-a3b2d054c0b8

ab48a1ed-7a3d-4686-bb6d-ab4f367cada8 Direction Qualité \n\n \n\n \nPATES ALIMENTA...
...
e67341d8-350f-46f4-9154-4dbbb8035621 FICHE TECHNIQUE \n\nCREME BRÛLÉE 6L \n\nREF : ...
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3 81 rue de Sans Souci - CS13754 - 69576 Limones...
0faad739-ea8c-4f03-b62e-51ee592a0546 \n1050/10502066400 \n\n10502055300/1050202520...

blocks
uid
a0492df6-9c76-4303-8813-65ec5ccbfa70 [Concentré Liquide Asian CHEF®, Bouteille de ...
d183e914-db2f-4e2f-863a-a3b2d054c0b8 [
]
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8 [Direction Qualité , , , PATES ALIMENTAIRES ...
...
```

```
e67341d8-350f-46f4-9154-4dbbb8035621 [FICHE TECHNIQUE , CREME BRÛLÉE 6L , REF : NAP...
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3 [81 rue de Sans Souci - CS13754 - 69576 Limone...
0faad739-ea8c-4f03-b62e-51ee592a0546 [ \n1050/10502066400 , 10502055300/10502025200...
```

[500 rows x 6 columns]

1.3 Train/Test split, entraînement et transformation

On effectue classiquement les étapes de train/test split, on entraîne le modèle sur le set d'entraînement et on le lance sur le set de test.

```
[5]: train, test = train_test_split(splitted_df, train_size=400, random_state=42)
model = SimilaritySelector(similarity='projection')
model.fit(train[['blocks']], train[['ingredients']])
predicted = pd.Series(model.predict(test['blocks']),
                       index=test.index,
                       name='predicted'
                      )
predicted = pd.concat([test['ingredients'], predicted], axis=1)
predicted
```

```
[5]: ingredients \
uid
2892dd68-e3a6-474c-b543-3ebfd3490658 Café instantané, café torrefié moulu (3%).
a57c1561-b88e-4694-8bd8-55623f2afa17 Lentilles blondes
3634fb1e-ee79-41d1-8aaa-084c1fae5bd5 Poire 99,9%, antioxydant: acide ascorbique.
...
ebfc9e73-5d91-4b45-8331-8c8f9bed3bb3 Jus d'orange à base de concentré
c33aa83e-a502-4339-a8e0-c56db2e59e69 Farine de BLÉ, sucre, huile de colza,, cacao m...
54f40033-f9cf-411c-81a5-11974f6715aa Piment rouge fort équarillé* (85%), cumin, ail m...

predicted
uid
2892dd68-e3a6-474c-b543-3ebfd3490658 - NESTLÉ a un système de management de la qual...
a57c1561-b88e-4694-8bd8-55623f2afa17 Cette fiche technique n'a pas de valeur contra...
3634fb1e-ee79-41d1-8aaa-084c1fae5bd5 Ce produit est une purée de fruits obtenue à p...
...
ebfc9e73-5d91-4b45-8331-8c8f9bed3bb3 \n\nVALEURS NUTRITIONNELLES pour 100mL / NUT...
c33aa83e-a502-4339-a8e0-c56db2e59e69 Ingrédients : Farine de BLÉ, sucre, huile de c...
54f40033-f9cf-411c-81a5-11974f6715aa A) Ingrédients : \n\nPiment rouge fort équ...
```

[100 rows x 2 columns]

1.4 Mesure de la performance : Précision

1.4.1 Approche naïve

Dans cette première version, on calculera une précision brute, où seuls les strings parfaitement identiques sont considérés comme ok.

```
[6]: predicted['result'] = (predicted['ingredients'].fillna('') == predicted['predicted'].fillna(''))
predicted['result'].value_counts()
```

```
[6]: False    99
      True     1
      Name: result, dtype: int64
```

On a une précision très faible, 1%. L'unique liste d'ingrédients du set de test correctement prédite est la suivante :

```
[7]: print(predicted[predicted['result']].iloc[0, 0])
```

```
Sirup de glucose, sucre, eau, stabilisants (E440i, E440ii, E415), acidifiants (E330, E450i), conservateur (E202).
```

1.4.2 Cross-validation de l'approche naïve

Pour avoir une vision plus précise de la performance du modèle, on peut effectuer une cross-validation sur le set d'entraînement.

On commence par définir une fonction de scoring, qui pourra être appelée par la fonction standard de cross-validation de scikit-learn. Comme précédemment, il s'agit d'une fonction d'accuracy basique :

```
[8]: def accuracy_scorer(estim, X, y):
    y_pred = estim.predict(X)
    return((y_pred == y).mean())
```

On retrouve évidemment le même score que précédemment lorsqu'on utilise cette fonction sur le set de test :

```
[9]: accuracy_scorer(model, test.reset_index()['blocks'], test.reset_index()['ingredients'])
```

```
[9]: 0.01
```

Si on lance la cross-validation avec les paramètres par défaut ($cv=5$), on obtient le résultat suivant :

```
[10]: X = splitted_df.reset_index()['blocks'].copy()
y = splitted_df.reset_index()['ingredients'].copy()

cross_val = cross_validate(model,
                            X=X,
                            y=y,
                            scoring=accuracy_scorer,
                            )
print(f'Strict accuracy yields a result of {np.mean(cross_val["test_score"]):.2%} +/-{np.
    -std(cross_val["test_score"]):.2%}')
print(cross_val['test_score'])
```

```
Strict accuracy yields a result of 2.20% +/-0.75%
[0.03 0.03 0.02 0.01 0.02]
```

On voit que sur chacun des 5 folds (validation sur 400 produits), l'accuracy varie entre 1 et 3%.

Si on trace l'accuracy et la standard deviation pour plusieurs valeurs de cv , on obtient les résultats suivants :

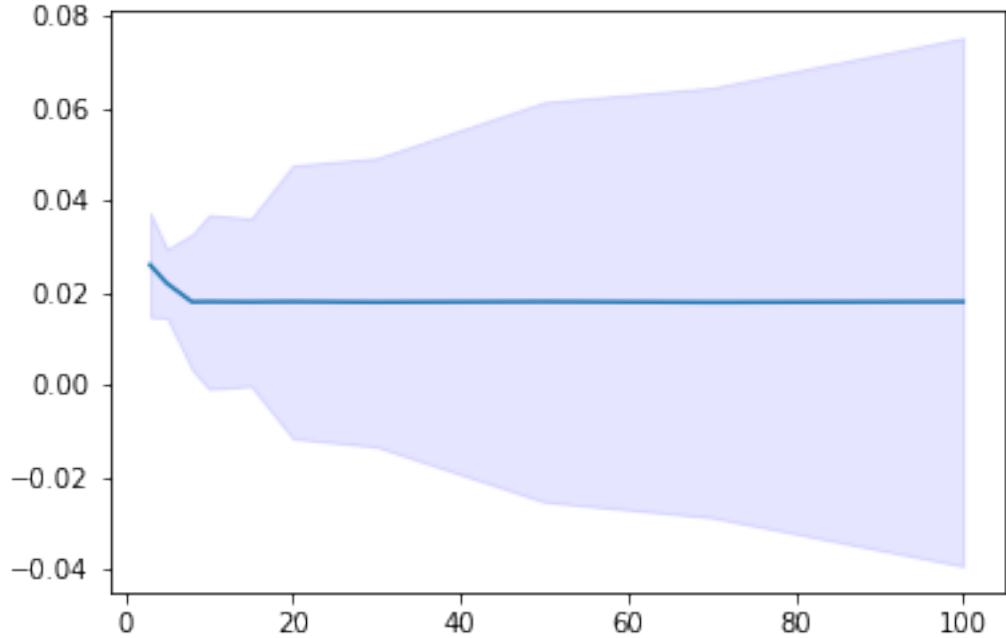
```
[11]: x = [3, 5, 8, 10, 15, 20, 30, 50, 70, 100]
mean = np.array([])
std = np.array([])
for n_cv in x:
    cross_val = cross_validate(model,
                                X=splitted_df['blocks'],
                                y=splitted_df['ingredients'],
                                scoring=accuracy_scorer,
                                cv=n_cv,
                                )
    mean = np.append(mean, [np.mean(cross_val['test_score'])], axis=0)
    std = np.append(std, [np.std(cross_val['test_score'])], axis=0)

print('mean:', mean, '\nstandard dev:', std)
```

```
mean: [0.02598418 0.022      0.01795315 0.018      0.01794415 0.018
       0.01789216 0.018      0.01785714 0.018      ]
standard dev: [0.01126571 0.00748331 0.01470225 0.01886796 0.01816919 0.0295973
   0.03127858 0.04331282 0.04656573 0.05723635]
```

```
[12]: fig, ax = plt.subplots()
ax.plot(x, mean)
ax.fill_between(x, (mean - std), (mean + std), color='b', alpha=.1)
```

```
[12]: <matplotlib.collections.PolyCollection at 0x7f5005cccd90>
```



Il apparaît que l'accuracy se situe aux alentours de 2%, avec un écart type important si on le compare à cette accuracy.

```
[13]: cross_val = cross_validate(model,
                               X=splitted_df['blocks'],
                               y=splitted_df['ingredients'],
                               scoring=accuracy_scorer,
                               cv=10,
                               )
print(f'Strict accuracy yields a result of {np.mean(cross_val["test_score"]):.2%} +/-{np.
->std(cross_val["test_score"]):.2%}')
print(cross_val['test_score'])
```

```
Strict accuracy yields a result of 1.80% +/-1.89%
[0.04 0. 0. 0.06 0.02 0.02 0. 0.02 0. 0.02]
```

1.4.3 Ajout d'une étape de text-postprocessing

On utilise la fonction `custom_accuracy` définie dans le module pimest pour calculer l'accuracy avec du text processing. Elle prend en paramètre les mêmes attributs que le `CountVectorizer` de scikit-learn, en plus d'un attribut “`tokenize`” qui va tokeniser le résultat (pour prise en compte des whitespace et de la ponctuation).

```
[14]: custom_accuracy(model,
                      test['blocks'].fillna(''),
                      test['ingredients'].fillna(''),
                      tokenize=True,
                      strip_accents='unicode',
                      lowercase=True,
                      )
```

```
[14]: 0.14
```

L'accuracy est maintenant estimée à 14% (vs. 1%) sur le set de test, après entraînement sur le set d'entraînement.

On peut manuellement inspecter les blocks identique, en reproduisant le comportement de la fonction d'accuracy :

```
[15]: def text_processor(text, **kwargs):
    unused_model = CountVectorizer(**kwargs)
```

```

    prepro = unused_model.build_preprocessor()
    token = unused_model.build_tokenizer()
    return(' '.join(token(prepro(text)))))

partial_processor = partial(text_processor, strip_accents='unicode', lowercase=True)

```

[16]: prediction = model.predict(test['blocks'].fillna('')).rename('predicted')
processed_prediction = prediction.apply(partial_processor)
processed_prediction.head(3)

[16]: uid
2892dd68-e3a6-474c-b543-3ebfd3490658 nestle un systeme de management de la qualite ...
a57c1561-b88e-4694-8bd8-55623f2afa17 cette fiche technique pas de valeur contractue...
3634fb1e-ee79-41d1-8aaa-084c1fae5bd5 ce produit est une puree de fruits obtenue par...
Name: predicted, dtype: object

[17]: processed_ground_truth = test['ingredients'].fillna('').apply(partial_processor)
processed_ground_truth.head(3)

[17]: uid
2892dd68-e3a6-474c-b543-3ebfd3490658 cafe instantane cafe torrefie moulu
a57c1561-b88e-4694-8bd8-55623f2afa17 lentilles blondes
3634fb1e-ee79-41d1-8aaa-084c1fae5bd5 poire 99 antioxydant acide ascorbique
Name: ingredients, dtype: object

[18]: corrects = test.join(prediction).loc[processed_prediction == processed_ground_truth , ['ingredients','predicted']]
corrects

[18]: ingredients \
uid
345591f4-d887-4ddc-bb40-21337fa9269d Gésier de dinde émincé 50%, graisse de canard ...
13980d31-9002-457d-8d49-b451f08f473c Edulcorants sorbitol, isomalt, sirop de maltit...
c3b6b4df-e586-4f10-8e58-15fb0f816acb mini poivrons jaunes, eau, sucre, sel, affermi...
0481d91b-9653-42e7-b525-9dc9b87b06f2 Farine de BLE, huile de colza non hydrogénée, ...
484ac00a-a670-46a9-a9c4-5114174d9e3b Pommes de terre 59,5 % - Céleris 40 % - Amidon...
49b11281-34ea-44b0-a11c-4ae21d4c58e3 NaN
d59d96cb-0230-4090-8220-78ce8496fd91 Amidon de maïs* - Lait écrémé* - Sel - Fécule ...
b8cbe6f9-71d4-4e51-a169-1c163d49a561 Farine de FROMENT, poudre de LACTOSERUM, sucre...
a0492df6-9c76-4303-8813-65ec5ccbfa70 Eau, maltodextrine, sel, arômes, sucre, arôme ...
09e45b38-4da1-4eb5-888a-3ebd437a2291 ŒUFS, farine de BLE, sucre, amidon de BLE, st...
4f83306f-66de-4545-9b12-7790b57b61ae Sirop de glucose, sucre, eau, stabilisants (E4...
5cee689e-6fb1-493c-b232-1d8fb1f88a57 Flageolets verts. Jus : eau, sel, affermissant...
63968dc3-6e7c-4056-bd53-820c6cc925be Carottes, eau, sucre, sel, vinaigre d'alcool, ...
dc536305-82fd-4afe-a472-5056ca0e21ea Légumes 43,2 % (pomme de terre, oignon, carott...

predicted
uid
345591f4-d887-4ddc-bb40-21337fa9269d Gésier de dinde émincé 50%, graisse de canard...
13980d31-9002-457d-8d49-b451f08f473c Edulcorants sorbitol, isomalt, sirop de maltit...
c3b6b4df-e586-4f10-8e58-15fb0f816acb mini poivrons jaunes, eau, sucre, sel, affermi...
0481d91b-9653-42e7-b525-9dc9b87b06f2 Farine de BLE, huile de colza non hydrogénée, ...
484ac00a-a670-46a9-a9c4-5114174d9e3b Pommes de terre 59,5 % - Céleris 40 % - Amidon...
49b11281-34ea-44b0-a11c-4ae21d4c58e3

d59d96cb-0230-4090-8220-78ce8496fd91 Amidon de maïs* - Lait écrémé* - Sel - Fécule ...
b8cbe6f9-71d4-4e51-a169-1c163d49a561 Farine de FROMENT, poudre de LACTOSERUM, sucre...
a0492df6-9c76-4303-8813-65ec5ccbfa70 Eau, maltodextrine, sel, arômes, sucre, arôme ...
09e45b38-4da1-4eb5-888a-3ebd437a2291 ŒUFS, farine de BLE, sucre, amidon de BLE, st...
4f83306f-66de-4545-9b12-7790b57b61ae Sirop de glucose, sucre, eau, stabilisants (E4...
5cee689e-6fb1-493c-b232-1d8fb1f88a57 Flageolets verts. Jus : eau, sel, affermissant...
63968dc3-6e7c-4056-bd53-820c6cc925be Carottes, eau, sucre, sel, vinaigre d'alcool, ...
dc536305-82fd-4afe-a472-5056ca0e21ea Légumes 43,2 % (pomme de terre, oignon, carott...

```
[19]: with pd.option_context("max_colwidth", 100000):
    tex_str = (
        corrects.replace(r'^\s*$', np.nan, regex=True)
        .to_latex(index=False,
                   index_names=False,
                   column_format='p{7cm}p{7cm}',
                   na_rep='rien',
                   longtable=False,
                   header=["Liste d'ingrédients cible", "Liste d'ingrédients prédicté"],
                   # label='tbl:GT_postprocessed_corrects',
                   # caption="Prédictions identifiées comme correctes après postprocessing",
                   )
        .replace(r'\textbackslash n', r' \newline ')
        .replace(r'\\', r'\\ \\hline')
    )

    with open(Path('..') / 'tbls' / 'GT_postprocessed_corrects.tex', 'w') as file:
        file.write(tex_str)
```

1.4.4 Cross-validation de l'approche avec text processing

On fait tourner une cross-validation sur l'ensemble du dataset. On définit d'abord la fonction qui va permettre de calculer le score avec l'ensemble des fonctionnalités de text processing : - retrait des accents - remplacement des whitespaces par des espaces simples - retrait de la ponctuation - mise en minuscule

```
[20]: processed_accuracy = partial(custom_accuracy,
                                 tokenize=True,
                                 strip_accents='unicode',
                                 lowercase=True,
                                 )
cross_val = cross_validate(model,
                           X=splitted_df['blocks'].fillna(''),
                           y=splitted_df['ingredients'].fillna(''),
                           scoring=processed_accuracy,
                           )
print(f'Processed accuracy yields a result of {np.mean(cross_val["test_score"]):.2%} +/-{np.
    -std(cross_val["test_score"]):.2%}')
print(cross_val['test_score'])
```

Processed accuracy yields a result of 17.00% +/-2.45%
[0.2 0.16 0.17 0.13 0.19]

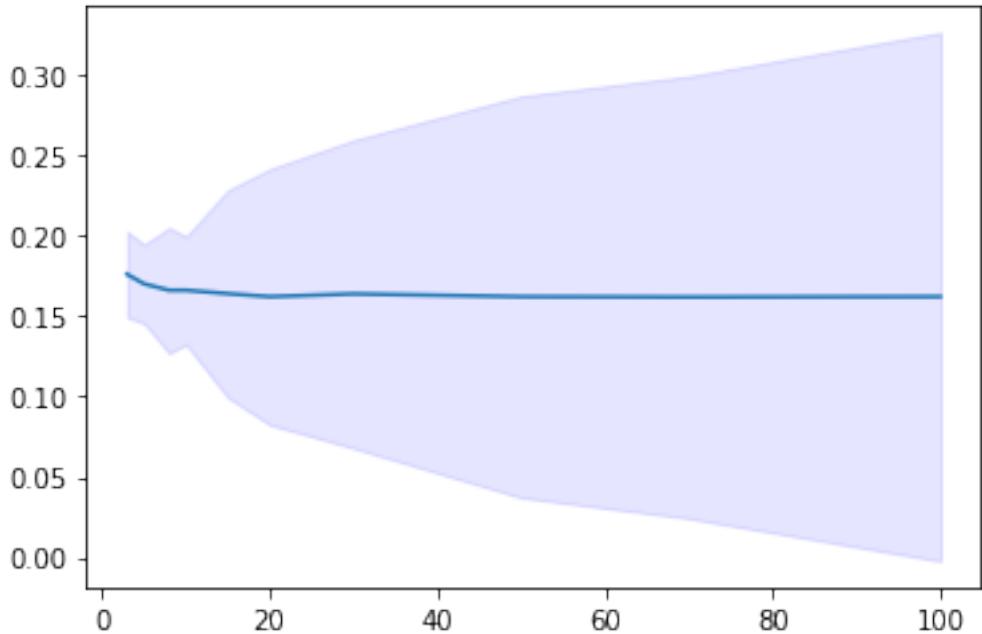
```
[21]: x = [3, 5, 8, 10, 15, 20, 30, 50, 70, 100]
mean = np.array([])
std = np.array([])
for n_cv in x:
    cross_val = cross_validate(model,
                                X=splitted_df['blocks'].fillna(''),
                                y=splitted_df['ingredients'].fillna(''),
                                scoring=processed_accuracy,
                                cv=n_cv,
                                )
    mean = np.append(mean, [np.mean(cross_val['test_score'])], axis=0)
    std = np.append(std, [np.std(cross_val['test_score'])], axis=0)

print('mean:', mean, '\nstandard dev:', std)
```

mean: [0.17593728 0.17 0.166 0.16387403 0.162
0.16372549 0.162 0.16173469 0.162]
standard dev: [0.02658629 0.0244949 0.03903199 0.03352611 0.06445016 0.07947327
0.09572828 0.12472369 0.13735865 0.16418282]

```
[22]: fig, ax = plt.subplots()
ax.plot(x, mean)
ax.fill_between(x, (mean - std), (mean + std), color='b', alpha=.1)
```

```
[22]: <matplotlib.collections.PolyCollection at 0x7f5005d50760>
```



```
[23]: cross_val = cross_validate(model,
                               X=splitted_df['blocks'].fillna(''),
                               y=splitted_df['ingredients'].fillna(''),
                               scoring=processed_accuracy,
                               cv=10,
                               )
print(f'Processed accuracy yields a result of {np.mean(cross_val["test_score"]):.2%} +/-{np.
    +-std(cross_val["test_score"]):.2%}')
print(cross_val['test_score'])
```

Processed accuracy yields a result of 16.60% +/-3.35%
[0.2 0.18 0.18 0.14 0.12 0.22 0.14 0.12 0.16 0.2]

1.5 Mesure de la performance : Similarité

1.5.1 Mesures

On peut également mesurer la similarité plutôt qu'uniquement l'accuracy. Cela permet de valoriser les textes qui "ressemblent" aux listes d'ingrédients cibles plutôt que les compter comme des erreurs.

```
[24]: similarity_kinds = ['levenshtein',
                        'damerau-levenshtein',
                        'jaro',
                        'jaro-winkler',
                        ]
sim_dict = dict()

for similarity in similarity_kinds:
    sim = text_sim_score(model,
                          test['blocks'].fillna(''),
                          test['ingredients'].fillna(''),
                          similarity=similarity,
                          )
    sim_dict[similarity] = f'{sim:.2%}'
```

```
print(f'Similarity with {similarity} similarity is {sim:.2%}')
```

```
Similarity with levenshtein similarity is 48.86%
Similarity with damerau-levenshtein similarity is 48.86%
Similarity with jaro similarity is 63.56%
Similarity with jaro-winkler similarity is 65.67%
```

Les similarités de Levenshtein et Damerau-Levenshtein donnent des résultats identiques, à presque 50% de similarité moyenne. Celles basées sur Jaro tournent aux alentours de 65%, comme on s'y attendait dans la mesure où elle est très “indulgente” sur les textes longs.

Si on effectue des cross validations sur chacune de ces distances sur le dataset complet, on obtient :

```
[25]: similarities = {similarity: partial(text_sim_score, similarity=similarity) for similarity in
    ↪similarity_kinds}

cross_vals = dict()

for similarity in similarity_kinds:
    cross_vals[similarity] = cross_validate(model,
        splitted_df['blocks'].fillna(''),
        splitted_df['ingredients'].fillna(''),
        scoring=similarities[similarity],
        cv=10,
    )
for similarity in similarity_kinds:
    print(f'Model evaluated with {similarity} similarity a result of '
        f'{np.mean(cross_vals[similarity]["test_score"]):.2%} '
        f'+/-{np.std(cross_vals[similarity]["test_score"]):.2%}' )
```

```
Model evaluated with levenshtein similarity a result of 49.79% +/-3.73%
Model evaluated with damerau-levenshtein similarity a result of 49.80% +/-3.72%
Model evaluated with jaro similarity a result of 62.78% +/-3.28%
Model evaluated with jaro-winkler similarity a result of 64.40% +/-3.50%
```

On transforme en tableau latex pour insertion dans le rapport.

```
[26]: result_strings = dict()

for similarity in similarity_kinds:
    result_strings[similarity] = {'train/test set': sim_dict[similarity],
        'cross validation': f'{np.mean(cross_vals[similarity]["test_score"]):.2%} ↪
            ↪+/-{np.std(cross_vals[similarity]["test_score"]):.2%}'}
result_df = pd.DataFrame(result_strings).T
print(result_strings)
labs = {'levenshtein': 'Levenshtein',
    'damerau-levenshtein': 'Damerau-Levenshtein',
    'jaro': 'Jaro',
    'jaro-winkler': 'Jaro-Winkler',
}
(result_df.rename(labs)
    .to_latex(Path('..') / 'tbls' / 'similarities_result.tex',
        column_format='lcc',
        bold_rows=True,
    )
)

{'levenshtein': {'train/test set': '48.86%', 'cross validation': '49.79% +/-3.73%'},
 'damerau-levenshtein': {'train/test set': '48.86%', 'cross validation': '49.80% +/-3.72%'},
 'jaro': {'train/test set': '63.56%', 'cross validation': '62.78% +/-3.28%'},
 'jaro-winkler': {'train/test set': '65.67%', 'cross validation': '64.40% +/-3.50%'}}
```

1.5.2 Illustration

On illustre les différents niveaux de similarité sur le set de test après entraînement sur le set d'entraînement.

```
[33]: # building the dataframe
y_pred = model.predict(test['blocks']).rename('predicted')
comp_df = pd.concat([test['ingredients'].fillna(''), y_pred], axis=1)
processed_df = comp_df.applymap(build_text_processor())

# computing similarities and ranks
sim_funcs = {sim: partial(text_similarity, similarity=sim) for sim in similarity_kinds}
for sim in similarity_kinds:
    processed_df[sim] = processed_df.apply(lambda x: sim_funcs[sim](x['ingredients'], x['predicted']), axis=1)
    processed_df[sim + '_rank'] = processed_df[sim].rank(axis=0, method='first', ascending=False)

[34]: (processed_df.join(comp_df, lsuffix='_')
      .sort_values(['levenshtein'], ascending=False)
      .loc[(processed_df['ingredients'] != '') & (processed_df['predicted'] != '')]
     )

[34]: ingredients_ \
uid
b8cbe6f9-71d4-4e51-a169-1c163d49a561 farine de froment poudre de lactoserum sucre p...
dc536305-82fd-4afe-a472-5056ca0e21ea legumes 43 pomme de terre oignon carotte tomat...
63968dc3-6e7c-4056-bd53-820c6cc925be carottes eau sucre sel vinaigre alcool acidifi...
...
bb77c7b0-9c63-4869-9ab1-823ba1158f53 tilleul 100
6267b9f8-2529-4bc6-ba4b-26760f0522b3 eau gazeifiee colorant e150d acidifiants acide...
2ca5dc9e-8058-499a-affe-3ec9c06d55b7 100 arabica

predicted_ levenshtein \
uid
b8cbe6f9-71d4-4e51-a169-1c163d49a561 farine de froment poudre de lactoserum sucre p... 1.000000
dc536305-82fd-4afe-a472-5056ca0e21ea legumes 43 pomme de terre oignon carotte tomat... 1.000000
63968dc3-6e7c-4056-bd53-820c6cc925be carottes eau sucre sel vinaigre alcool acidifi... 1.000000
...
bb77c7b0-9c63-4869-9ab1-823ba1158f53 dans le cadre des recommandations de sante pub... 0.019185
6267b9f8-2529-4bc6-ba4b-26760f0522b3 coca cola light mini 150 mlean5449000239808mar... 0.012461
2ca5dc9e-8058-499a-affe-3ec9c06d55b7 gammemarqueargumentation commercialepreparatio... 0.011411

damerau-levenshtein jaro jaro-winkler \
uid
b8cbe6f9-71d4-4e51-a169-1c163d49a561 1.000000 1.000000 1.000000
dc536305-82fd-4afe-a472-5056ca0e21ea 1.000000 1.000000 1.000000
63968dc3-6e7c-4056-bd53-820c6cc925be 1.000000 1.000000 1.000000
...
bb77c7b0-9c63-4869-9ab1-823ba1158f53 0.019185 0.259974 0.259974
6267b9f8-2529-4bc6-ba4b-26760f0522b3 0.012461 0.506069 0.506069
2ca5dc9e-8058-499a-affe-3ec9c06d55b7 0.011411 0.372595 0.372595

ingredients \
uid
b8cbe6f9-71d4-4e51-a169-1c163d49a561 Farine de FROMENT, poudre de LACTOSERUM, sucre...
dc536305-82fd-4afe-a472-5056ca0e21ea Légumes 43,2 % (pomme de terre, oignon, carott...
63968dc3-6e7c-4056-bd53-820c6cc925be Carottes, eau, sucre, sel, vinaigre d'alcool, ...
...
bb77c7b0-9c63-4869-9ab1-823ba1158f53 Tilleul (100%).
6267b9f8-2529-4bc6-ba4b-26760f0522b3 eau gazéifiée\ncolorant : E150d\nacidifiants ...
2ca5dc9e-8058-499a-affe-3ec9c06d55b7 100% Arabica

predicted
uid
b8cbe6f9-71d4-4e51-a169-1c163d49a561 Farine de FROMENT, poudre de LACTOSERUM, sucre...
dc536305-82fd-4afe-a472-5056ca0e21ea Légumes 43,2 % (pomme de terre, oignon, carott...
63968dc3-6e7c-4056-bd53-820c6cc925be Carottes, eau, sucre, sel, vinaigre d'alcool, ...
...
bb77c7b0-9c63-4869-9ab1-823ba1158f53 Dans le cadre des recommandations de santé pub...
6267b9f8-2529-4bc6-ba4b-26760f0522b3 CocaCola Light mini 8 x 150 mLEAN544900023980...
```

```
2ca5dc9e-8058-499a-affe-3ec9c06d55b7 gammemarqueargumentation commercialepreparatio...
```

```
[90 rows x 8 columns]
```

```
[67]: comp_df
```

```
[67]:
```

		ingredients \
uid		
2892dd68-e3a6-474c-b543-3ebfd3490658	Café instantané, café torrefié moulu (3%).	
a57c1561-b88e-4694-8bd8-55623f2afa17	Lentilles blondes	
3634fb1e-ee79-41d1-8aaa-084c1fae5bd5	Poire 99,9%, antioxydant: acide ascorbique.	
..	..	
ebfc9e73-5d91-4b45-8331-8c8f9bed3bb3	Jus d'orange à base de concentré	
c33aa83e-a502-4339-a8e0-c56db2e59e69	Farine de BLÉ, sucre, huile de colza,, cacao m...	
54f40033-f9cf-411c-81a5-11974f6715aa	Piment rouge fort équeuté* (85%), cumin, ail m...	
		predicted
uid		
2892dd68-e3a6-474c-b543-3ebfd3490658	- NESTLÉ a un système de management de la qual...	
a57c1561-b88e-4694-8bd8-55623f2afa17	Cette fiche technique n'a pas de valeur contra...	
3634fb1e-ee79-41d1-8aaa-084c1fae5bd5	Ce produit est une purée de fruits obtenue à p...	
..	..	
ebfc9e73-5d91-4b45-8331-8c8f9bed3bb3	\n \nVALEURS NUTRITIONNELLES pour 100mL / NUT...	
c33aa83e-a502-4339-a8e0-c56db2e59e69	Ingrédients : Farine de BLÉ, sucre, huile de c...	
54f40033-f9cf-411c-81a5-11974f6715aa	A) Ingrédients : \n \nPiment rouge fort équ...	

```
[100 rows x 2 columns]
```

```
[79]: # outputing to latex
with pd.option_context("max_colwidth", 100000):
    tex_str = (processed_df.sort_values('levenshtein_rank')
                .loc[(processed_df['ingredients'] != '') &
                      (processed_df['predicted'] != '') &
                      (processed_df['predicted'].apply(len) <=300)]
                .join(comp_df, lsuffix='_')
                .iloc[np.r_[0:3, 50:53, -3:0]]
                .to_latex(columns=['ingredients', 'predicted', 'levenshtein', 'levenshtein_rank',
                                   'damerau-levenshtein', 'damerau-levenshtein_rank', 'jaro',
                                   'jaro_rank', 'jaro-winkler', 'jaro-winkler_rank'],
                           index=False,
                           column_format='p{5cm}p{5cm}ccccccc',
                           formatters={'levenshtein': lambda x: f'{x:.2%}',
                                       'levenshtein_rank': lambda x: f'{x:1.0f}',
                                       'damerau-levenshtein': lambda x: f'{x:.2%}',
                                       'damerau-levenshtein_rank': lambda x: f'{x:1.0f}',
                                       'jaro': lambda x: f'{x:.2%}',
                                       'jaro_rank': lambda x: f'{x:1.0f}',
                                       'jaro-winkler': lambda x: f'{x:.2%}',
                                       'jaro-winkler_rank': lambda x: f'{x:1.0f}'},
                           header=["Listes d'ingrédients cibles", "Listes d'ingrédients prédites",
                                   'Lev', 'rang', 'Dam-Lev', 'rang', 'Jaro', 'rang', 'Jaro-Win', 'rang'],
                           ←'rang'],
                           na_rep = '<rien>',
                           )
                .replace(r'\textbackslash n', r' \newline ').replace(r'\\', r'\\ \hline')
    with open(Path('..') / 'tbls' / 'similarity_illustration.tex' , 'w') as file:
        file.write(tex_str)
```

```
[77]: (processed_df.sort_values('levenshtein_rank')
        .loc[(processed_df['ingredients'] != '') & (processed_df['predicted'] != '') &
              (processed_df['predicted'].apply(len) <=300)]
        .join(comp_df, lsuffix='_')
        .iloc[np.r_[0:3, 50:53, -3:0]]
    )
```

[77] :

	ingredients_ \
345591f4-d887-4ddc-bb40-21337fa9269d c3b6b4df-e586-4f10-8e58-15fb0816acb 0481d91b-9653-42e7-b525-9dc9b87b06f2 d8b0687e-5e25-4ff9-9384-087f993218bc 536361db-1bbb-4e64-ae53-d970eeac7db2 194419d0-d9f2-4799-81ac-d9e3aa77fd27 ebfc9e73-5d91-4b45-8331-8c8f9bed3bb3 3634fb1e-ee79-41d1-8aaa-084c1fae5bd5 04235024-80f3-46c2-bad0-aae0d5fab024	gesier de dinde emince 50 grasse de canard 47... mini poivrons jaunes eau sucre sel affermissan... farine de ble huile de colza non hydrogenee oe... eau jus de fruit de la passion sucre epaississ... sucre amidon de mais arome vanille pommes de terre eau sel jus orange base de concentre poire 99 antioxydant acide ascorbique persil
uid	predicted_ levenshtein \
345591f4-d887-4ddc-bb40-21337fa9269d c3b6b4df-e586-4f10-8e58-15fb0816acb 0481d91b-9653-42e7-b525-9dc9b87b06f2 d8b0687e-5e25-4ff9-9384-087f993218bc 536361db-1bbb-4e64-ae53-d970eeac7db2 194419d0-d9f2-4799-81ac-d9e3aa77fd27 ebfc9e73-5d91-4b45-8331-8c8f9bed3bb3 3634fb1e-ee79-41d1-8aaa-084c1fae5bd5 04235024-80f3-46c2-bad0-aae0d5fab024	gesier de dinde emince 50 grasse de canard 47... 1.000000 mini poivrons jaunes eau sucre sel affermissan... 1.000000 farine de ble huile de colza non hydrogenee oe... 1.000000 cereales contenant du gluten crustaces et prod... 0.200692 ajouter le produit la preparation avec les aut... 0.200000 anhydride sulfureux et sulfites en concentrati... 0.154762 valeurs nutritionnelles pour 100ml nutrition f... 0.104418 ce produit est une puree de fruits obtenue par... 0.096667 cereales contenant du gluten savoir ble seigle... 0.045455
uid	damerau-levenshtein jaro jaro-winkler levenshtein_rank \
345591f4-d887-4ddc-bb40-21337fa9269d c3b6b4df-e586-4f10-8e58-15fb0816acb 0481d91b-9653-42e7-b525-9dc9b87b06f2 d8b0687e-5e25-4ff9-9384-087f993218bc 536361db-1bbb-4e64-ae53-d970eeac7db2 194419d0-d9f2-4799-81ac-d9e3aa77fd27 ebfc9e73-5d91-4b45-8331-8c8f9bed3bb3 3634fb1e-ee79-41d1-8aaa-084c1fae5bd5 04235024-80f3-46c2-bad0-aae0d5fab024	1.000000 1.000000 1.000000 1.0 1.000000 1.000000 1.000000 3.0 1.000000 1.000000 1.000000 4.0 0.200692 0.553928 0.553928 68.0 0.200000 0.491130 0.491130 69.0 0.154762 0.482876 0.482876 73.0 0.104418 0.423567 0.423567 78.0 0.096667 0.437327 0.437327 80.0 0.045455 0.507576 0.507576 86.0
uid	damerau-levenshtein_rank jaro_rank jaro-winkler_rank \
345591f4-d887-4ddc-bb40-21337fa9269d c3b6b4df-e586-4f10-8e58-15fb0816acb 0481d91b-9653-42e7-b525-9dc9b87b06f2 d8b0687e-5e25-4ff9-9384-087f993218bc 536361db-1bbb-4e64-ae53-d970eeac7db2 194419d0-d9f2-4799-81ac-d9e3aa77fd27 ebfc9e73-5d91-4b45-8331-8c8f9bed3bb3 3634fb1e-ee79-41d1-8aaa-084c1fae5bd5 04235024-80f3-46c2-bad0-aae0d5fab024	1.0 1.0 1.0 3.0 3.0 4.0 4.0 4.0 5.0 68.0 64.0 66.0 69.0 75.0 75.0 73.0 76.0 76.0 78.0 83.0 83.0 80.0 82.0 82.0 86.0 73.0 73.0
uid	ingredients \
345591f4-d887-4ddc-bb40-21337fa9269d c3b6b4df-e586-4f10-8e58-15fb0816acb 0481d91b-9653-42e7-b525-9dc9b87b06f2 d8b0687e-5e25-4ff9-9384-087f993218bc 536361db-1bbb-4e64-ae53-d970eeac7db2 194419d0-d9f2-4799-81ac-d9e3aa77fd27 ebfc9e73-5d91-4b45-8331-8c8f9bed3bb3 3634fb1e-ee79-41d1-8aaa-084c1fae5bd5 04235024-80f3-46c2-bad0-aae0d5fab024	Gésier de dinde émincé 50%, graisse de canard ... mini poivrons jaunes, eau, sucre, sel, affermi... Farine de BLE, huile de colza non hydrogénée, ... Eau ; jus de fruit de la passion ; sucre ; ép... Sucre, amidon de maïs, arôme vanille Pommes de terre, eau, sel. Jus d'orange à base de concentré Poire 99,9%, antioxydant: acide ascorbique. Persil
uid	predicted
345591f4-d887-4ddc-bb40-21337fa9269d c3b6b4df-e586-4f10-8e58-15fb0816acb 0481d91b-9653-42e7-b525-9dc9b87b06f2 d8b0687e-5e25-4ff9-9384-087f993218bc 536361db-1bbb-4e64-ae53-d970eeac7db2	Gésier de dinde émincé 50%, graisse de canard... mini poivrons jaunes, eau, sucre, sel, affermi... Farine de BLE, huile de colza non hydrogénée, ... Céréales contenant du gluten (2) \nCrustacés e... ajouter le produit à la préparation avec les a...

194419d0-d9f2-4799-81ac-d9e3aa77fd27 Anhydride sulfureux et sulfites en \nconcentra...
ebfc9e73-5d91-4b45-8331-8c8f9bed3bb3 \n \nVALEURS NUTRITIONNELLES pour 100mL / NUT...
3634fb1e-ee79-41d1-8aaa-084c1fae5bd5 Ce produit est une purée de fruits obtenue à p...
04235024-80f3-46c2-bad0-aae0d5fab024 Céréales contenant du gluten (à savoir blé, se...

1 Tuning du modèle

L'objet de ce notebook est d'illustrer les différentes étapes de tuning du modèle.

1.1 Préambule

1.1.1 Imports

```
[1]: # setting up sys.path for relative imports
from pathlib import Path
import sys
project_root = str(Path(sys.path[0]).parents[1].absolute())
if project_root not in sys.path:
    sys.path.append(project_root)

[2]: # imports and customization of display
# import os
import re
from functools import partial
from itertools import product
import numpy as np
import pandas as pd
pd.options.display.min_rows = 6
pd.options.display.width=108
# from sklearn.feature_extraction.text import CountVectorizer
from sklearn.model_selection import train_test_split
# from sklearn.model_selection import cross_val_score, cross_validate
from sklearn.model_selection import GridSearchCV, RandomizedSearchCV
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import FunctionTransformer
from matplotlib import pyplot as plt
import matplotlib.patches as mpatch
import matplotlib.ticker as mtick
import seaborn as sns

from src.pimest import ContentGetter
from src.pimest import PathGetter
from src.pimest import PDFContentParser
from src.pimest import BlockSplitter
from src.pimest import SimilaritySelector
from src.pimest import custom_accuracy
from src.pimest import text_sim_score
from src.pimest import text_similarity
# from src.pimest import build_text_processor
```

1.1.2 Acquisition des données

On récupère les données manuellement étiquetées et on les intègre dans un dataframe

```
[3]: ground_truth_df = pd.read_csv(Path('..') / '..' / 'ground_truth' / 'manually_labelled_ground_truth.csv',
                                    sep=';',
                                    encoding='latin-1',
                                    index_col='uid')
ground_truth_uids = list(ground_truth_df.index)

acqui_pipe = Pipeline([('PathGetter', PathGetter(ground_truth_uids=ground_truth_uids,
                                                train_set_path=Path('..') / '..' / 'ground_truth',
                                                ground_truth_path=Path('..') / '..' / 'ground_truth',
                                                )),
                      ('ContentGetter', ContentGetter(missing_file='to_nan')),
                      ('ContentParser', PDFContentParser(None_content='to_empty')),
                      ],
                      verbose=True)

texts_df = acqui_pipe.fit_transform(ground_truth_df)
texts_df['ingredients'] = texts_df['ingredients'].fillna('')
```

```
texts_df
```

```
[Pipeline] ... (step 1 of 3) Processing PathGetter, total= 0.1s
[Pipeline] ... (step 2 of 3) Processing ContentGetter, total= 0.6s
Launching 8 processes.
[Pipeline] ... (step 3 of 3) Processing ContentParser, total= 37.0s
```

[3]:

```
designation \
uid a0492df6-9c76-4303-8813-65ec5ccbfa70 Concentré liquide Asian en bouteille 980 ml CHEF
d183e914-db2f-4e2f-863a-a3b2d054c0b8 Pain burger curry 80 g CREATIV BURGER
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8 Macaroni en sachet 500 g PANZANI
...
e67341d8-350f-46f4-9154-4dbbb8035621 PRÉPARATION POUR CRÈME BRÛLÉE BIO 6L
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3 Céréales instantanées en poudre saveur caramel...
Ofaad739-ea8c-4f03-b62e-51ee592a0546 FARINE DE BLÉ TYPE 45, 10KG

ingredients \
uid a0492df6-9c76-4303-8813-65ec5ccbfa70 Eau, maltodextrine, sel, arômes, sucre, arôme ...
d183e914-db2f-4e2f-863a-a3b2d054c0b8 Farine de blé T65, eau, levure, vinaigre de ci...
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8 - 100% Semoule de BLE dur de qualité supérieur...
...
e67341d8-350f-46f4-9154-4dbbb8035621 Sucre roux de canne*° (64%), amidon de mais*, ...
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3 Farine 87,1 % (Blé (GLUTEN), Blé hydrolysé (GL...
Ofaad739-ea8c-4f03-b62e-51ee592a0546 Farine de blé T45

path \
uid a0492df6-9c76-4303-8813-65ec5ccbfa70 ../../ground_truth/a0492df6-9c76-4303-8813-65e...
d183e914-db2f-4e2f-863a-a3b2d054c0b8 ../../ground_truth/d183e914-db2f-4e2f-863a-a3b...
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8 ../../ground_truth/ab48a1ed-7a3d-4686-bb6d-ab4...
...
e67341d8-350f-46f4-9154-4dbbb8035621 ../../ground_truth/e67341d8-350f-46f4-9154-4db...
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3 ../../ground_truth/a8f6f672-20ac-4ff8-a8f2-3bc...
Ofaad739-ea8c-4f03-b62e-51ee592a0546 ../../ground_truth/Ofaad739-ea8c-4f03-b62e-51e...

content \
uid a0492df6-9c76-4303-8813-65ec5ccbfa70 b'%PDF-1.5\r\n%\xb5\xb5\xb5\xb5\r\n1 0 obj\r\n...
d183e914-db2f-4e2f-863a-a3b2d054c0b8 b'%PDF-1.5\r%\xe2\xe3\xcf\xd3\r\n4 0 obj\r<</L...
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8 b'%PDF-1.4%\n%\xc7\xec\x8f\xa2\n5 0 obj\n<</Len...
...
e67341d8-350f-46f4-9154-4dbbb8035621 b'%PDF-1.7\r\n%\xb5\xb5\xb5\xb5\r\n1 0 obj\r\n...
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3 b'%PDF-1.5\r\n%\xb5\xb5\xb5\xb5\r\n1 0 obj\r\n...
Ofaad739-ea8c-4f03-b62e-51ee592a0546 b'%PDF-1.5\r\n%\xb5\xb5\xb5\xb5\r\n1 0 obj\r\n...

text
uid a0492df6-9c76-4303-8813-65ec5ccbfa70 Concentré Liquide Asian CHEF® \n\nBouteille de...
d183e914-db2f-4e2f-863a-a3b2d054c0b8
ab48a1ed-7a3d-4686-bb6d-ab4f367cada8 Direction Qualité \n\n \n\n \nPATES ALIMENTA...
...
e67341d8-350f-46f4-9154-4dbbb8035621 FICHE TECHNIQUE \n\nCREME BRÛLÉE 6L \n\nREF : ...
a8f6f672-20ac-4ff8-a8f2-3bc4306c8df3 81 rue de Sans Souci - CS13754 - 69576 Limones...
Ofaad739-ea8c-4f03-b62e-51ee592a0546 \n1050/10502066400 \n\n10502055300/1050202520...
```

[500 rows x 5 columns]

[19]: import inspect

[26]: print(inspect.getsource(texts_df.to_string))

```
@Substitution(
    header_type="bool or sequence",
```

```

    header="Write out the column names. If a list of strings "
    "is given, it is assumed to be aliases for the "
    "column names",
    col_space_type="int",
    col_space="The minimum width of each column",
)
@Substitution(shared_params=fmt.common_docstring, returns=fmt.return_docstring)
def to_string(
    self,
    buf: Optional[FilePathOrBuffer[str]] = None,
    columns: Optional[Sequence[str]] = None,
    col_space: Optional[int] = None,
    header: Union[bool, Sequence[str]] = True,
    index: bool = True,
    na_rep: str = "NaN",
    formatters: Optional[fmt.formatters_type] = None,
    float_format: Optional[fmt.float_format_type] = None,
    sparsify: Optional[bool] = None,
    index_names: bool = True,
    justify: Optional[str] = None,
    max_rows: Optional[int] = None,
    min_rows: Optional[int] = None,
    max_cols: Optional[int] = None,
    show_dimensions: bool = False,
    decimal: str = ".",
    line_width: Optional[int] = None,
    max_colwidth: Optional[int] = None,
    encoding: Optional[str] = None,
) -> Optional[str]:
    """
    Render a DataFrame to a console-friendly tabular output.

    %(shared_params)s
    line_width : int, optional
        Width to wrap a line in characters.
    max_colwidth : int, optional
        Max width to truncate each column in characters. By default, no limit.

        .. versionadded:: 1.0.0
    encoding : str, default "utf-8"
        Set character encoding.

        .. versionadded:: 1.0
    %(returns)s
    See Also
    -----
    to_html : Convert DataFrame to HTML.

    Examples
    -----
    >>> d = {'col1': [1, 2, 3], 'col2': [4, 5, 6]}
    >>> df = pd.DataFrame(d)
    >>> print(df.to_string())
      col1  col2
    0     1     4
    1     2     5
    2     3     6
    """
    from pandas import option_context

    with option_context("display.max_colwidth", max_colwidth):
        formatter = fmt.DataFrameFormatter(
            self,
            columns=columns,
            col_space=col_space,
            na_rep=na_rep,
            formatters=formatters,
            float_format=float_format,

```

```

        sparsify=sparsify,
        justify=justify,
        index_names=index_names,
        header=header,
        index=index,
        min_rows=min_rows,
        max_rows=max_rows,
        max_cols=max_cols,
        show_dimensions=show_dimensions,
        decimal=decimal,
        line_width=line_width,
    )
    return formatter.to_string(buf=buf, encoding=encoding)

```

1.1.3 Train / Test split

On va appliquer une grid search pour déterminer les meilleurs paramètres de notre modèle. Pour ne pas surestimer la performance du modèle, il est nécessaire de bien séparer le jeu de test du jeu d'entraînement, y compris pour la grid search !

```
[4]: train, test = train_test_split(texts_df, test_size=100, random_state=42)
```

Dans toute la suite, on utilisera le jeu d'entraînement pour effectuer le tuning des hyperparamètres.

1.2 Ajustement de la fonction de découpage des textes

L'objectif de cette partie est d'optimiser la fonction de découpage des textes en blocs. On va tester quelques fonctions candidates, via une GridSearch.

1.2.1 Définition des fonctions candidates

On définit les fonctions de split :

```
[5]: # definitions of splitter funcs
splitter_funcs = []
def split_func1(text):
    return(text.split('\n\n'))
splitter_funcs.append(split_func1)
def split_func2(text):
    return(text.split('\n'))
splitter_funcs.append(split_func2)
def split_func3(text):
    regex = r'\s*\n\s*\n\s*'
    return(re.split(regex, text))
splitter_funcs.append(split_func3)
```

1.2.2 Mise en place du pipeline

On construit ensuite un pipeline de traitement du texte. Le SimilaritySelector prenant en entrée une pandas.Series, on définit entre le BlockSplitter (dont la méthode transform() retourne un pandas.DataFrame) et le SimilaritySelector une fonction utilitaire qui sélectionne la colonne 'blocks'.

```
[6]: def select_col(df, col_name='blocks'):
    return(df[col_name].fillna(' '))
col_selector = FunctionTransformer(select_col)
```

```
[7]: process_pipe = Pipeline([('Splitter', BlockSplitter()),
                           ('ColumnSelector', col_selector),
                           ('SimilaritySelector', SimilaritySelector())
                           ],
                           verbose=False)
```

On peut tester le fonctionnement de ce Pipeline. Attention, les résultats ne sont pas représentatifs, on entraîne et on prédit sur le même jeu de données !

```
[8]: process_pipe.fit(train, train['ingredients'])
process_pipe.predict(train)
```

Launching 8 processes.
Launching 8 processes.

```
[8]: uid
02d5ceb9-21c2-4965-8f65-309bca7638b2    Café chicorée solubles et fibres de chicorée.\...
bbe72396-6ed4-4df1-935b-0c0a7dbd77dc    COMPOSITION\nMélange de Blés de pays recommand...
507b428e-e99d-464b-b9d3-50629efe4355    ...
4b28bb17-1f1d-4cbb-ac3b-80227ef248ab    Gluten\nCrustacés\nOeufs\nPoisson\nSoja\nLait\...
d2137dae-ff21-46ec-83be-7400773c6c3b    Amidon modifié de pomme de terre - Fécule de p...
571d98ae-9647-4bd4-ad1a-a497f93987cb    Composition typique (Données inappropriées pou...
Length: 400, dtype: object
```

1.2.3 Helper fonction

On doit faire varier dans la grid search des paramètres qui sont packés sous forme de dictionnaires avant d'être passés au SimilaritySelector. On construit une fonction qui permet de construire le produit cartésien qui va bien pour ces paramètres.

```
[9]: def prod_params(dict_to_prod):
    """
    In : dict of dicts.
    First level key : parameter name
    Second level key : name of scenario with this parameter value
    Values : parameter value

    Returns a tuple:
        - list of labels to name scenario
        - list of dictionaries to pass to count_vect_kwarg
    """
    label_lists = [list(dict_.keys()) for dict_ in dict_to_prod.values()]
    labels = list(map(lambda x: ', '.join(x), list(product(*label_lists))))
    values_iter = list(product(*[list(dict_.values()) for dict_ in dict_to_prod.values()]))
    parms_names = list(dict_to_prod.keys())
    dict_out = [{key: val for (key, val) in zip(parms_names, values_)} for values_ in values_iter]
    return(labels, dict_out)
```

```
[10]: prod_params({'stop_words': {'no stopwords removal': None, 'with stopwords removal' : {'de', 'le'}},
                  'ngram_ranges': {'no_ngram': (1, 1), 'bigrams': (1, 2)}})
```

```
[10]: (['no stopwords removal, no_ngram',
      'no stopwords removal, bigrams',
      'with stopwords removal, no_ngram',
      'with stopwords removal, bigrams'],
      [{('stop_words': None, 'ngram_ranges': (1, 1)),
        {'stop_words': None, 'ngram_ranges': (1, 2)},
        {'stop_words': {'de', 'le'}, 'ngram_ranges': (1, 1)},
        {'stop_words': {'de', 'le'}, 'ngram_ranges': (1, 2)}}])
```

1.2.4 Stockage des résultats dans un dataframe

Au fil des lancements des grid search, on stockera les données dans un dataframe afin de pouvoir les analyser plus simplement après coup.

```
[11]: result_df = pd.DataFrame()
result_df
```

```
[11]: Empty DataFrame
Columns: []
Index: []
```

1.2.5 Application de la GridSearch : tuning du text preprocessing (run 1)

On applique ensuite une grid search en faisant varier les fonctions de text preprocessing : - fonction de split du texte des documents en blocs - retrait ou non de stopwords - prise en compte de ngrams - juste pour une première comparaison, choix du candidat par projection l1/l2 ou par similarité cosinus

On scorera via la similarité de Levenshtein.

```
[12]: lev_scorer = partial(text_sim_score, similarity='levenshtein')

[13]: stop_words = {'pas', 'le', 'en', 'pour', 'ou', 'ce', 'de', 'dans', 'du', 'and', 'un', 'sur', 'et',
   'of', 'est', 'par', 'la', 'les', 'dont', 'au', 'des', 'que'}

[14]: ngram_ranges = {'no_ngram': (1, 1), 'bigrams': (1, 2), 'trigrams': (1, 3)}

[15]: kwargs_to_prod = prod_params({'stop_words': {'no_stopwords removal': None, 'with_stopwords_removal': _stop_words,
   'ngram_range': ngram_ranges,
   'strip_accents': {'keep_accents': None, 'remove_accents': 'unicode'}}})

[16]: param_grid = [{'_Splitter__splitter_func': splitter_funcs,
   '_SimilaritySelector__similarity': ['projection', 'cosine'],
   '_SimilaritySelector__count_vect_kwarg': kwargs_to_prod[1],
   }]
search = GridSearchCV(process_pipe,
                      param_grid,
                      cv=8,
                      scoring=({'similarity': lev_scorer, 'accuracy': custom_accuracy}),
                      refit='similarity',
                      n_jobs=-1,
                      verbose=1,
                      ).fit(train, train['ingredients'])
```

Fitting 8 folds for each of 72 candidates, totalling 576 fits

```
[Parallel(n_jobs=-1)]: Using backend LokyBackend with 8 concurrent workers.
[Parallel(n_jobs=-1)]: Done  34 tasks      | elapsed:  13.3s
[Parallel(n_jobs=-1)]: Done 184 tasks      | elapsed:  1.2min
[Parallel(n_jobs=-1)]: Done 434 tasks      | elapsed:  2.8min
```

Launching 8 processes.

```
[Parallel(n_jobs=-1)]: Done 576 out of 576 | elapsed:  3.9min finished
```

```
[17]: labels = list(product(kwargs_to_prod[0], ['Projection 12/11', 'Cosinus'], ['Split 1', 'Split 2', 'Split_3']))
labels = list(map(lambda x: ', '.join(x), labels))

[18]: for i in range(len(search.cv_results_['rank_test_similarity'])):
   str_result = f'{search.cv_results_["mean_test_similarity"][i]:.2%} +/- {search.cv_results_["std_test_similarity"][i]:.2%}'
   print(labels[i], str_result)
```

```
no_stopwords_removal, no_ngram, keep_accents, Projection 12/11, Split 1 50.15% +/- 5.61%
no_stopwords_removal, no_ngram, keep_accents, Projection 12/11, Split 2 38.90% +/- 4.52%
no_stopwords_removal, no_ngram, keep_accents, Projection 12/11, Split 3 52.65% +/- 6.09%
no_stopwords_removal, no_ngram, keep_accents, Cosinus, Split 1 40.30% +/- 4.91%
no_stopwords_removal, no_ngram, keep_accents, Cosinus, Split 2 25.87% +/- 2.25%
no_stopwords_removal, no_ngram, keep_accents, Cosinus, Split 3 41.98% +/- 5.27%
no_stopwords_removal, no_ngram, remove_accents, Projection 12/11, Split 1 49.47% +/- 5.77%
no_stopwords_removal, no_ngram, remove_accents, Projection 12/11, Split 2 38.56% +/- 4.19%
no_stopwords_removal, no_ngram, remove_accents, Projection 12/11, Split 3 52.02% +/- 6.05%
```

```

no stopwords removal, no_ngram, remove accents, Cosinus, Split 1 40.93% +/- 5.02%
no stopwords removal, no_ngram, remove accents, Cosinus, Split 2 26.06% +/- 2.00%
no stopwords removal, no_ngram, remove accents, Cosinus, Split 3 42.68% +/- 5.42%
no stopwords removal, bigrams, keep accents, Projection 12/11, Split 1 55.47% +/- 5.22%
no stopwords removal, bigrams, keep accents, Projection 12/11, Split 2 43.12% +/- 2.32%
no stopwords removal, bigrams, keep accents, Projection 12/11, Split 3 58.38% +/- 5.06%
no stopwords removal, bigrams, keep accents, Cosinus, Split 1 41.53% +/- 5.73%
no stopwords removal, bigrams, keep accents, Cosinus, Split 2 26.94% +/- 2.14%
no stopwords removal, bigrams, keep accents, Cosinus, Split 3 43.45% +/- 6.40%
no stopwords removal, bigrams, remove accents, Projection 12/11, Split 1 55.40% +/- 5.11%
no stopwords removal, bigrams, remove accents, Projection 12/11, Split 2 43.27% +/- 2.78%
no stopwords removal, bigrams, remove accents, Projection 12/11, Split 3 58.31% +/- 5.23%
no stopwords removal, bigrams, remove accents, Cosinus, Split 1 41.49% +/- 5.88%
no stopwords removal, bigrams, remove accents, Cosinus, Split 2 27.27% +/- 1.95%
no stopwords removal, bigrams, remove accents, Cosinus, Split 3 43.70% +/- 6.48%
no stopwords removal, trigrams, keep accents, Projection 12/11, Split 1 56.41% +/- 5.05%
no stopwords removal, trigrams, keep accents, Projection 12/11, Split 2 43.75% +/- 3.06%
no stopwords removal, trigrams, keep accents, Projection 12/11, Split 3 59.56% +/- 5.12%
no stopwords removal, trigrams, keep accents, Cosinus, Split 1 41.54% +/- 5.25%
no stopwords removal, trigrams, keep accents, Cosinus, Split 2 26.95% +/- 2.41%
no stopwords removal, trigrams, keep accents, Cosinus, Split 3 43.54% +/- 6.16%
no stopwords removal, trigrams, remove accents, Projection 12/11, Split 1 56.43% +/- 5.07%
no stopwords removal, trigrams, remove accents, Projection 12/11, Split 2 43.83% +/- 3.11%
no stopwords removal, trigrams, remove accents, Projection 12/11, Split 3 59.58% +/- 5.11%
no stopwords removal, trigrams, remove accents, Cosinus, Split 1 42.08% +/- 5.14%
no stopwords removal, trigrams, remove accents, Cosinus, Split 2 27.28% +/- 2.39%
no stopwords removal, trigrams, remove accents, Cosinus, Split 3 44.18% +/- 6.17%
with stopwords removal, no_ngram, keep accents, Projection 12/11, Split 1 54.94% +/- 5.62%
with stopwords removal, no_ngram, keep accents, Projection 12/11, Split 2 42.12% +/- 4.32%
with stopwords removal, no_ngram, keep accents, Projection 12/11, Split 3 58.06% +/- 6.52%
with stopwords removal, no_ngram, keep accents, Cosinus, Split 1 51.06% +/- 6.89%
with stopwords removal, no_ngram, keep accents, Cosinus, Split 2 29.73% +/- 4.76%
with stopwords removal, no_ngram, keep accents, Cosinus, Split 3 53.35% +/- 7.12%
with stopwords removal, no_ngram, remove accents, Projection 12/11, Split 1 54.89% +/- 5.81%
with stopwords removal, no_ngram, remove accents, Projection 12/11, Split 2 42.22% +/- 4.32%
with stopwords removal, no_ngram, remove accents, Projection 12/11, Split 3 57.99% +/- 6.66%
with stopwords removal, no_ngram, remove accents, Cosinus, Split 1 51.40% +/- 6.72%
with stopwords removal, no_ngram, remove accents, Cosinus, Split 2 30.44% +/- 4.69%
with stopwords removal, no_ngram, remove accents, Cosinus, Split 3 53.69% +/- 7.13%
with stopwords removal, bigrams, keep accents, Projection 12/11, Split 1 57.74% +/- 5.74%
with stopwords removal, bigrams, keep accents, Projection 12/11, Split 2 44.54% +/- 3.57%
with stopwords removal, bigrams, keep accents, Projection 12/11, Split 3 61.08% +/- 5.91%
with stopwords removal, bigrams, keep accents, Cosinus, Split 1 52.31% +/- 7.10%
with stopwords removal, bigrams, keep accents, Cosinus, Split 2 26.86% +/- 4.47%
with stopwords removal, bigrams, keep accents, Cosinus, Split 3 54.85% +/- 7.51%
with stopwords removal, bigrams, remove accents, Projection 12/11, Split 1 57.99% +/- 5.69%
with stopwords removal, bigrams, remove accents, Projection 12/11, Split 2 44.43% +/- 3.30%
with stopwords removal, bigrams, remove accents, Projection 12/11, Split 3 60.86% +/- 5.65%
with stopwords removal, bigrams, remove accents, Cosinus, Split 1 51.79% +/- 6.83%
with stopwords removal, bigrams, remove accents, Cosinus, Split 2 26.90% +/- 4.71%
with stopwords removal, bigrams, remove accents, Cosinus, Split 3 54.43% +/- 7.18%
with stopwords removal, trigrams, keep accents, Projection 12/11, Split 1 58.76% +/- 5.47%
with stopwords removal, trigrams, keep accents, Projection 12/11, Split 2 45.36% +/- 3.58%
with stopwords removal, trigrams, keep accents, Projection 12/11, Split 3 61.94% +/- 5.59%
with stopwords removal, trigrams, keep accents, Cosinus, Split 1 51.65% +/- 6.90%
with stopwords removal, trigrams, keep accents, Cosinus, Split 2 25.74% +/- 4.50%
with stopwords removal, trigrams, keep accents, Cosinus, Split 3 54.28% +/- 7.24%
with stopwords removal, trigrams, remove accents, Projection 12/11, Split 1 58.82% +/- 5.48%
with stopwords removal, trigrams, remove accents, Projection 12/11, Split 2 45.54% +/- 3.61%
with stopwords removal, trigrams, remove accents, Projection 12/11, Split 3 62.01% +/- 5.61%
with stopwords removal, trigrams, remove accents, Cosinus, Split 1 51.54% +/- 6.74%
with stopwords removal, trigrams, remove accents, Cosinus, Split 2 26.04% +/- 4.42%
with stopwords removal, trigrams, remove accents, Cosinus, Split 3 54.26% +/- 7.21%

```

On tire de ce premier test: - que le modèle est bien plus performant avec le retrait des stopwords - que le split le plus efficace est la fonction qui applique la regex (deux retours chariots parmi des whitespaces) - split 3 - que la prise en compte de bigrammes améliore, avec les trigrammes en plus on ne gagne rien - que la similarité cosinus semble sensiblement moins performante que le choix par projection (12/11)

Remarque : la standard dev est quand même assez élevée (de l'ordre de 5-6%). Les scénarios avec peu d'écart entre leurs moyennes (2-3%) ne sont pas départageables via cette grid search.

On sauvegarde les résultat dans le dataframe qu'on analysera à la fin

```
[19]: try:
    result_df = result_df.loc[result_df['run'] != 1].copy()
except:
    pass
result_df = pd.DataFrame(search.cv_results_)
result_df['run'] = 1
```

1.2.6 Application de la Grid Search : tuning du calcul de similarité (run 2)

On va maintenant déterminer, sur la base des paramètres déjà retenus, le mode de calcul de similarité le plus performant. Seul le calcul par projection est paramétrique (norme dans l'espace de départ vs. norme sur l'espace projeté), on fera uniquement varier ces paramètres (en plus de la comparaison avec la similarité cosinus).

On comparera également la performance du modèle selon qu'on vectorise les textes via les comptes de mots, ou bien seulement via un identifiant binaire (présence ou absence du mot).

```
[20]: process_pipe.set_params(**{'Splitter__splitter_func': splitter_funcs[2],
                               })
kwargs_to_prod = prod_params({'stop_words': {'with stopwords removal' : stop_words},
                             'ngram_range': {'bigrams': (1, 2)},
                             'binary': {'counts': False, 'binary flag': True},
                             'strip_accents': {'remove accents': 'unicode'}}
                             })
param_grid = [{  'SimilaritySelector__source_norm': ['l1'],
    'SimilaritySelector__projected_norm': ['l1'],
    'SimilaritySelector__similarity': ['projection'],
    'SimilaritySelector__count_vect_kwarg': kwargs_to_prod[1],
  },
  {
    'SimilaritySelector__source_norm': ['l2'],
    'SimilaritySelector__projected_norm': ['l2'],
    'SimilaritySelector__similarity': ['projection'],
    'SimilaritySelector__count_vect_kwarg': kwargs_to_prod[1],
  },
  {
    'SimilaritySelector__source_norm': ['l2'],
    'SimilaritySelector__projected_norm': ['l1'],
    'SimilaritySelector__similarity': ['projection'],
    'SimilaritySelector__count_vect_kwarg': kwargs_to_prod[1],
  },
  {
    'SimilaritySelector__similarity': ['projection'],
    'SimilaritySelector__source_norm': ['l3'],
    'SimilaritySelector__projected_norm': ['l2'],
    'SimilaritySelector__count_vect_kwarg': kwargs_to_prod[1],
  },
  {
    'SimilaritySelector__similarity': ['projection'],
    'SimilaritySelector__source_norm': ['l4'],
    'SimilaritySelector__projected_norm': ['l3'],
    'SimilaritySelector__count_vect_kwarg': kwargs_to_prod[1],
  },
  {
    'SimilaritySelector__similarity': ['projection'],
    'SimilaritySelector__source_norm': ['l5'],
    'SimilaritySelector__projected_norm': ['l4'],
    'SimilaritySelector__count_vect_kwarg': kwargs_to_prod[1],
  },
  {
    'SimilaritySelector__similarity': ['projection'],
```

```

'SimilaritySelector__source_norm': ['16'],
'SimilaritySelector__projected_norm': ['15'],
'SimilaritySelector__count_vect_kwarg': kwargs_to_prod[1],
},
{
'SimilaritySelector__similarity': ['projection'],
'SimilaritySelector__source_norm': ['13'],
'SimilaritySelector__projected_norm': ['11'],
'SimilaritySelector__count_vect_kwarg': kwargs_to_prod[1],
},
{
'SimilaritySelector__source_norm': ['14'],
'SimilaritySelector__projected_norm': ['12'],
'SimilaritySelector__similarity': ['projection'],
'SimilaritySelector__count_vect_kwarg': kwargs_to_prod[1],
},
{
'SimilaritySelector__source_norm': ['15'],
'SimilaritySelector__projected_norm': ['13'],
'SimilaritySelector__similarity': ['projection'],
'SimilaritySelector__count_vect_kwarg': kwargs_to_prod[1],
},
{
'SimilaritySelector__source_norm': ['16'],
'SimilaritySelector__projected_norm': ['14'],
'SimilaritySelector__similarity': ['projection'],
'SimilaritySelector__count_vect_kwarg': kwargs_to_prod[1],
},
{
'SimilaritySelector__source_norm': ['17'],
'SimilaritySelector__projected_norm': ['15'],
'SimilaritySelector__similarity': ['projection'],
'SimilaritySelector__count_vect_kwarg': kwargs_to_prod[1],
},
{
'SimilaritySelector__source_norm': ['14'],
'SimilaritySelector__projected_norm': ['11'],
'SimilaritySelector__similarity': ['projection'],
'SimilaritySelector__count_vect_kwarg': kwargs_to_prod[1],
},
{
'SimilaritySelector__source_norm': ['15'],
'SimilaritySelector__projected_norm': ['12'],
'SimilaritySelector__similarity': ['projection'],
'SimilaritySelector__count_vect_kwarg': kwargs_to_prod[1],
},
{
'SimilaritySelector__source_norm': ['16'],
'SimilaritySelector__projected_norm': ['13'],
'SimilaritySelector__similarity': ['projection'],
'SimilaritySelector__count_vect_kwarg': kwargs_to_prod[1],
},
{
'SimilaritySelector__source_norm': ['17'],
'SimilaritySelector__projected_norm': ['14'],
'SimilaritySelector__similarity': ['projection'],
'SimilaritySelector__count_vect_kwarg': kwargs_to_prod[1],
},
{
'SimilaritySelector__source_norm': ['18'],
'SimilaritySelector__projected_norm': ['15'],
'SimilaritySelector__similarity': ['projection'],
'SimilaritySelector__count_vect_kwarg': kwargs_to_prod[1],
},
{
'SimilaritySelector__similarity': ['cosine'],
'SimilaritySelector__count_vect_kwarg': kwargs_to_prod[1],

```

```

        }
    ]
search = GridSearchCV(process_pipe,
                      param_grid,
                      cv=8,
                      scoring= {'similarity': lev_scorer, 'accuracy': custom_accuracy}),
                      refit='similarity',
                      n_jobs=-1,
                      verbose=1,
).fit(train, train['ingredients'])

```

Fitting 8 folds for each of 36 candidates, totalling 288 fits

[Parallel(n_jobs=-1)]: Using backend LokyBackend with 8 concurrent workers.
[Parallel(n_jobs=-1)]: Done 34 tasks | elapsed: 14.7s
[Parallel(n_jobs=-1)]: Done 184 tasks | elapsed: 1.2min

Launching 8 processes.

[Parallel(n_jobs=-1)]: Done 288 out of 288 | elapsed: 1.8min finished

```
[21]: labels = [
    '11, 11',
    '12, 12',
    '12, 11',
    '13, 12',
    '14, 13',
    '15, 14',
    '16, 15',
    '13, 11',
    '14, 12',
    '15, 13',
    '16, 14',
    '17, 15',
    '14, 11',
    '15, 12',
    '16, 13',
    '17, 14',
    '18, 15',
    'cosine',
]
labels = list(product(labels, kwargs_to_prod[0]))
labels = list(map(lambda x: ', '.join(x), labels))

for i in range(len(search.cv_results_['rank_test_similarity'])):
    str_result = f"{search.cv_results_['mean_test_similarity'][i]:.2%} +/- {search.
    cv_results_['std_test_similarity'][i]:.2%}"
    print(labels[i], str_result)
```

11, 11, with stopwords removal, bigrams, counts, remove accents 17.87% +/- 2.52%
11, 11, with stopwords removal, bigrams, binary flag, remove accents 17.90% +/- 2.55%
12, 12, with stopwords removal, bigrams, counts, remove accents 17.87% +/- 2.52%
12, 12, with stopwords removal, bigrams, binary flag, remove accents 17.90% +/- 2.55%
12, 11, with stopwords removal, bigrams, counts, remove accents 60.86% +/- 5.65%
12, 11, with stopwords removal, bigrams, binary flag, remove accents 61.00% +/- 5.61%
13, 12, with stopwords removal, bigrams, counts, remove accents 61.55% +/- 5.25%
13, 12, with stopwords removal, bigrams, binary flag, remove accents 62.05% +/- 4.73%
14, 13, with stopwords removal, bigrams, counts, remove accents 59.61% +/- 4.00%
14, 13, with stopwords removal, bigrams, binary flag, remove accents 62.61% +/- 4.29%
15, 14, with stopwords removal, bigrams, counts, remove accents 56.23% +/- 3.40%
15, 14, with stopwords removal, bigrams, binary flag, remove accents 61.82% +/- 3.67%
16, 15, with stopwords removal, bigrams, counts, remove accents 51.58% +/- 3.78%
16, 15, with stopwords removal, bigrams, binary flag, remove accents 60.91% +/- 3.62%
13, 11, with stopwords removal, bigrams, counts, remove accents 59.33% +/- 5.34%
13, 11, with stopwords removal, bigrams, binary flag, remove accents 59.06% +/- 5.44%
14, 12, with stopwords removal, bigrams, counts, remove accents 61.11% +/- 5.30%
14, 12, with stopwords removal, bigrams, binary flag, remove accents 61.00% +/- 5.61%

```

15, 13, with stopwords removal, bigrams, counts, remove accents 59.28% +/- 3.60%
15, 13, with stopwords removal, bigrams, binary flag, remove accents 61.70% +/- 5.21%
16, 14, with stopwords removal, bigrams, counts, remove accents 55.73% +/- 4.26%
16, 14, with stopwords removal, bigrams, binary flag, remove accents 62.05% +/- 4.73%
17, 15, with stopwords removal, bigrams, counts, remove accents 50.18% +/- 2.42%
17, 15, with stopwords removal, bigrams, binary flag, remove accents 61.96% +/- 4.23%
14, 11, with stopwords removal, bigrams, counts, remove accents 58.42% +/- 5.53%
14, 11, with stopwords removal, bigrams, binary flag, remove accents 57.44% +/- 5.05%
15, 12, with stopwords removal, bigrams, counts, remove accents 60.29% +/- 4.59%
15, 12, with stopwords removal, bigrams, binary flag, remove accents 59.67% +/- 5.18%
16, 13, with stopwords removal, bigrams, counts, remove accents 58.12% +/- 3.67%
16, 13, with stopwords removal, bigrams, binary flag, remove accents 61.00% +/- 5.61%
17, 14, with stopwords removal, bigrams, counts, remove accents 53.31% +/- 2.96%
17, 14, with stopwords removal, bigrams, binary flag, remove accents 61.50% +/- 5.35%
18, 15, with stopwords removal, bigrams, counts, remove accents 47.87% +/- 2.99%
18, 15, with stopwords removal, bigrams, binary flag, remove accents 61.80% +/- 5.20%
cosine, with stopwords removal, bigrams, counts, remove accents 54.43% +/- 7.18%
cosine, with stopwords removal, bigrams, binary flag, remove accents 53.36% +/- 7.86%

```

On tire de ce second test les conclusions suivantes : - comme lors du premier test, l'identification du meilleur candidat par similarité cosinus est moins performante que par projection - plusieurs configurations de paramètres permettent d'obtenir des performances similaires via la projection : - l2/l1 - l2/l1b - l3/l2 - l3/l2b - l3/l1b - l4/l2 - l4/l2b

```
[22]: result_df = result_df.loc[result_df['run'] != 2].copy()
result_df = pd.concat([result_df, pd.DataFrame(search.cv_results_)], axis=0, ignore_index=True)
result_df['run'] = result_df['run'].fillna(2)
len(result_df)
```

```
[22]: 108
```

1.2.7 Application de la Grid Search : impact des mots non vus en entraînement (run 3)

On va également voir si l'utilisation d'un vectorizer de type HashingVectorizer, qui permet de prendre en compte des mots non vus lors de l'entraînement a un impact sur la performance (ou son écart type, qui est très élevé...).

```
[23]: process_pipe.set_params(**{'Splitter__splitter_func': splitter_funcs[2],
                             })
kwargs_to_prod = prod_params({'stop_words': {'with stopwords removal' : stop_words},
                             'ngram_range': {'bigrams': (1, 2)},
                             'binary': {'counts': False, 'binary flag': True},
                             })
param_grid = [{('SimilaritySelector__count_vect_kwargs': kwargs_to_prod[1],
               'SimilaritySelector__count_vect_type': ['TfidfVectorizer', 'HashingVectorizer'],
               'SimilaritySelector__similarity': ['projection'],
               'SimilaritySelector__source_norm': ['l4'],
               'SimilaritySelector__projected_norm': ['l2'],
               },
               {'SimilaritySelector__count_vect_kwargs': kwargs_to_prod[1],
               'SimilaritySelector__count_vect_type': ['TfidfVectorizer', 'HashingVectorizer'],
               'SimilaritySelector__similarity': ['projection'],
               'SimilaritySelector__source_norm': ['l3'],
               'SimilaritySelector__projected_norm': ['l2'],
               },
               {'SimilaritySelector__count_vect_kwargs': kwargs_to_prod[1],
               'SimilaritySelector__count_vect_type': ['TfidfVectorizer', 'HashingVectorizer'],
               'SimilaritySelector__similarity': ['projection'],
               'SimilaritySelector__source_norm': ['l2'],
               'SimilaritySelector__projected_norm': ['l1'],
               },
               {'SimilaritySelector__count_vect_kwargs': kwargs_to_prod[1],
               'SimilaritySelector__count_vect_type': ['TfidfVectorizer', 'HashingVectorizer'],
               'SimilaritySelector__similarity': ['cosine'],
               'SimilaritySelector__source_norm': ['cosine'],
               }],
```

```

search = GridSearchCV(process_pipe,
                      param_grid,
                      cv=8,
                      scoring= ({'similarity': lev_scorer, 'accuracy': custom_accuracy}),
                      refit='similarity',
                      n_jobs=-1,
                      verbose=1,
                      ).fit(train, train['ingredients'])

```

Fitting 8 folds for each of 16 candidates, totalling 128 fits

[Parallel(n_jobs=-1)]: Using backend LokyBackend with 8 concurrent workers.
[Parallel(n_jobs=-1)]: Done 34 tasks | elapsed: 13.7s

Launching 8 processes.

[Parallel(n_jobs=-1)]: Done 128 out of 128 | elapsed: 52.8s finished

```

[24]: labels = [
    '14/12',
    '13/12',
    '12/11',
    'cosine'
]

labels = list(product(labels, kwargs_to_prod[0], ['TfidfVectorizer', 'HashingVectorizer']))
labels = list(map(lambda x: ', '.join(x), labels))

for i in range(len(search.cv_results_['rank_test_similarity'])):
    str_result = f"[{search.cv_results_['mean_test_similarity'][i]:.2%} +/- {search.
    cv_results_['std_test_similarity'][i]:.2%}]"
    print(labels[i], str_result)

```

14/12, with stopwords removal, bigrams, counts, TfidfVectorizer 61.11% +/- 5.30%
14/12, with stopwords removal, bigrams, counts, HashingVectorizer 52.46% +/- 3.06%
14/12, with stopwords removal, bigrams, binary flag, TfidfVectorizer 61.00% +/- 5.61%
14/12, with stopwords removal, bigrams, binary flag, HashingVectorizer 54.13% +/- 4.12%
13/12, with stopwords removal, bigrams, counts, TfidfVectorizer 61.55% +/- 5.25%
13/12, with stopwords removal, bigrams, counts, HashingVectorizer 43.37% +/- 4.64%
13/12, with stopwords removal, bigrams, binary flag, TfidfVectorizer 62.05% +/- 4.73%
13/12, with stopwords removal, bigrams, binary flag, HashingVectorizer 47.26% +/- 5.17%
12/11, with stopwords removal, bigrams, counts, TfidfVectorizer 60.86% +/- 5.65%
12/11, with stopwords removal, bigrams, counts, HashingVectorizer 57.89% +/- 5.60%
12/11, with stopwords removal, bigrams, binary flag, TfidfVectorizer 61.00% +/- 5.61%
12/11, with stopwords removal, bigrams, binary flag, HashingVectorizer 58.26% +/- 5.01%
cosine, with stopwords removal, bigrams, counts, TfidfVectorizer 54.43% +/- 7.18%
cosine, with stopwords removal, bigrams, counts, HashingVectorizer 53.01% +/- 6.20%
cosine, with stopwords removal, bigrams, binary flag, TfidfVectorizer 53.36% +/- 7.86%
cosine, with stopwords removal, bigrams, binary flag, HashingVectorizer 50.56% +/- 7.20%

L'utilisation d'un HashingVectorizer à la place d'un TfidfVectorizer, pour prendre en compte les mots non vus lors de l'entraînement, n'a pas d'impact positif sur la performance du modèle. Au contraire, elle semble globalement diminuer de quelques points.

```

[25]: result_df = result_df.loc[result_df['run'] != 3].copy()
result_df = pd.concat([result_df, pd.DataFrame(search.cv_results_)], axis=0, ignore_index=True)
result_df['run'] = result_df['run'].fillna(3)
len(result_df)

```

[25]: 124

1.2.8 Application d'une grid search : pondération des mots (run 4)

On va en plus appliquer une pondération absolue et relative des mots, dans la recherche de similarité par cosinus.

Les différentes possibilités pour le vecteur cible sont : - moyenne des vecteurs de textes des listes d'ingrédients, avec uniquement un flag binaire (présence / absence du mot) : la cible est la document frequency moyenne des mots des listes d'ingrédients - moyenne des vecteurs de textes des listes d'ingrédients, avec en prenant en compte les comptes des mots dans chacun des textes : la cible est la term frequency moyenne des mots au sein des listes d'ingrédients - moyenne des scores "absolus" de chacun des mots au sein des listes d'ingrédients. Il s'agit d'une "smooth document frequency" (elle croît logarithmiquement) - moyenne des scores "relatifs" de chacun des mots entre liste d'ingrédients et contenu des fiches techniques. Ici on compare la doc frequency entre les deux corpus, pour donner plus de poids aux mots qui sont plus présents dans les listes d'ingrédients que dans le reste du corps du texte.

On comparera à la projection l4/l2b, qui porte jusque là les meilleurs résultats.

```
[26]: process_pipe.set_params(**{'Splitter__splitter_func': splitter_funcs[2],
                               'SimilaritySelector__count_vect_type': 'TfidfVectorizer',
                               })

kwargs_to_prod = prod_params({'stop_words': {'with stopwords removal' : stop_words},
                             'ngram_range': {'no_ngrams': (1, 1), 'bigrams': (1, 2)},
                             'binary': {'counts': False, 'binary flag': True},
                             'use_idf': {'without idf': False, 'with idf': True},
                             'strip_accents': {'remove accents': 'unicode'},
                             })

param_grid = [{  'SimilaritySelector__count_vect_kwargs': kwargs_to_prod[1],
    'SimilaritySelector__scoring': ['default', 'absolute_score', 'relative_score'],
    'SimilaritySelector__similarity': ['cosine'],
  },
  {'SimilaritySelector__count_vect_kwargs': kwargs_to_prod[1],
    'SimilaritySelector__similarity': ['projection'],
    'SimilaritySelector__source_norm': ['l4'],
    'SimilaritySelector__projected_norm': ['l2'],
  },
]
search = GridSearchCV(process_pipe,
                      param_grid,
                      cv=8,
                      scoring= ({'similarity': lev_scorer, 'accuracy': custom_accuracy}),
                      refit='similarity',
                      n_jobs=-1,
                      verbose=1,
                      ).fit(train, train['ingredients'])
```

Fitting 8 folds for each of 32 candidates, totalling 256 fits

```
[Parallel(n_jobs=-1)]: Using backend LokyBackend with 8 concurrent workers.
[Parallel(n_jobs=-1)]: Done  34 tasks      | elapsed:   15.0s
[Parallel(n_jobs=-1)]: Done 184 tasks      | elapsed:  1.4min
```

Launching 8 processes.

```
[Parallel(n_jobs=-1)]: Done 256 out of 256 | elapsed: 1.8min finished
```

```
[27]: labels = [
    'cosine',
]

labels = list(product(labels, kwargs_to_prod[0], ['default', 'absolute score', 'relative score']))
labels.extend(list(product(['projection l4/l2'], kwargs_to_prod[0])))
labels = list(map(lambda x: ', '.join(x), labels))

for i in range(len(search.cv_results_['rank_test_similarity'])):
    str_result = f"[search.cv_results_['mean_test_similarity'][i]:.2%] +/- {search.
    cv_results_['std_test_similarity'][i]:.2%}"
    print(labels[i], str_result)
```

```

cosine, with stopwords removal, no_ngrams, counts, without idf, remove accents, default 53.69% +/- 7.13%
cosine, with stopwords removal, no_ngrams, counts, without idf, remove accents, absolute score 54.47% +/- 6.87%
cosine, with stopwords removal, no_ngrams, counts, without idf, remove accents, relative score 29.42% +/- 5.32%
cosine, with stopwords removal, no_ngrams, counts, with idf, remove accents, default 55.47% +/- 6.70%
cosine, with stopwords removal, no_ngrams, counts, with idf, remove accents, absolute score 52.47% +/- 6.91%
cosine, with stopwords removal, no_ngrams, counts, with idf, remove accents, relative score 32.73% +/- 5.21%
cosine, with stopwords removal, no_ngrams, binary flag, without idf, remove accents, default 53.29% +/- 7.86%
cosine, with stopwords removal, no_ngrams, binary flag, without idf, remove accents, absolute score 54.15% +/- 8.17%
cosine, with stopwords removal, no_ngrams, binary flag, without idf, remove accents, relative score 28.02% +/- 5.00%
cosine, with stopwords removal, no_ngrams, binary flag, with idf, remove accents, default 54.91% +/- 7.31%
cosine, with stopwords removal, no_ngrams, binary flag, with idf, remove accents, absolute score 51.80% +/- 8.13%
cosine, with stopwords removal, no_ngrams, binary flag, with idf, remove accents, relative score 31.39% +/- 5.59%
cosine, with stopwords removal, bigrams, counts, without idf, remove accents, default 54.43% +/- 7.18%
cosine, with stopwords removal, bigrams, counts, without idf, remove accents, absolute score 55.48% +/- 7.11%
cosine, with stopwords removal, bigrams, counts, without idf, remove accents, relative score 33.39% +/- 6.11%
cosine, with stopwords removal, bigrams, counts, with idf, remove accents, default 55.86% +/- 6.78%
cosine, with stopwords removal, bigrams, counts, with idf, remove accents, absolute score 52.00% +/- 6.91%
cosine, with stopwords removal, bigrams, counts, with idf, remove accents, relative score 39.00% +/- 5.38%
cosine, with stopwords removal, bigrams, binary flag, without idf, remove accents, default 53.36% +/- 7.86%
cosine, with stopwords removal, bigrams, binary flag, without idf, remove accents, absolute score 55.36% +/- 7.36%
cosine, with stopwords removal, bigrams, binary flag, without idf, remove accents, relative score 32.74% +/- 5.87%
cosine, with stopwords removal, bigrams, binary flag, with idf, remove accents, default 54.73% +/- 7.39%
cosine, with stopwords removal, bigrams, binary flag, with idf, remove accents, absolute score 51.12% +/- 6.71%
cosine, with stopwords removal, bigrams, binary flag, with idf, remove accents, relative score 39.45% +/- 5.47%
projection 14/12, with stopwords removal, no_ngrams, counts, without idf, remove accents 57.08% +/- 5.38%
projection 14/12, with stopwords removal, no_ngrams, counts, with idf, remove accents 17.38% +/- 1.45%
projection 14/12, with stopwords removal, no_ngrams, binary flag, without idf, remove accents 57.26% +/- 5.89%
projection 14/12, with stopwords removal, no_ngrams, binary flag, with idf, remove accents 22.50% +/- 4.14%
projection 14/12, with stopwords removal, bigrams, counts, without idf, remove accents 61.11% +/- 5.30%
projection 14/12, with stopwords removal, bigrams, counts, with idf, remove accents 32.00% +/- 3.51%
projection 14/12, with stopwords removal, bigrams, binary flag, without idf, remove accents 61.00% +/- 5.61%
projection 14/12, with stopwords removal, bigrams, binary flag, with idf, remove accents 38.00% +/- 5.85%

```

```
[28]: result_df = result_df.loc[result_df['run'] != 4].copy()
result_df = pd.concat([result_df, pd.DataFrame(search.cv_results_)], axis=0, ignore_index=True)
result_df['run'] = result_df['run'].fillna(4)
len(result_df)
```

[28]: 156

On en déduit : - que la similarité par projection reste le mode de détermination du candidat le plus efficace - que dans ce mode, l'utilisation de l'idf dégrade la performance - néanmoins, dans le cadre de la similarité cosinus, l'utilisation de l'idf a un impact positif pour la fonction de scoring par défaut, ou relative.

1.2.9 Application de la grid search : embeddings des mots (run 5)

On mesure l'impact sur la performance de l'utilisation d'embeddings de mots.

```
[29]: process_pipe.set_params(**{'Splitter__splitter_func': splitter_funcs[2],
                           'SimilaritySelector__count_vect_type': 'TfidfVectorizer',
                           })
kargs_to_prod = prod_params({'stop_words': {'with stopwords removal' : stop_words},
```

```

        'ngram_range': {'no_ngram': (1, 1)},
        'binary': {'counts': False, 'binary_flag': True},
        'use_idf': {'without_idf': False, 'with_idf': True},
        'strip_accents': {'remove accents': 'unicode'},
    })

param_grid = [
    {
        'SimilaritySelector__count_vect_kw_args': kwargs_to_prod[1],
        'SimilaritySelector__scoring': ['default', 'absolute_score', 'relative_score'],
        'SimilaritySelector__similarity': ['cosine'],
        'SimilaritySelector__embedding_method': [None, 'Word2Vec', 'tSVD'],
    },
]
search = GridSearchCV(process_pipe,
                      param_grid,
                      cv=8,
                      scoring=({'similarity': lev_scorer, 'accuracy': custom_accuracy}),
                      refit='similarity',
                      n_jobs=-1,
                      verbose=1,
                      error_score='raise',
                      ).fit(train, train['ingredients'])

```

Fitting 8 folds for each of 36 candidates, totalling 288 fits

```
[Parallel(n_jobs=-1)]: Using backend LokyBackend with 8 concurrent workers.
[Parallel(n_jobs=-1)]: Done  34 tasks      | elapsed:   26.8s
[Parallel(n_jobs=-1)]: Done 184 tasks      | elapsed:  2.3min
```

Launching 8 processes.

```
[Parallel(n_jobs=-1)]: Done 288 out of 288 | elapsed:  3.7min finished
```

```
[30]: labels = ['default', 'absolute_score', 'relative_score']
```

```

labels = list(product(kwargs_to_prod[0],
                     ['No embed', 'Word2Vec', 'tSVD'],
                     ['default', 'absolute score', 'relative score'],
                     ))
# labels.extend(list(product(['projection l4/l2'], kwargs_to_prod[0])))
labels = list(map(lambda x: ', '.join(x), labels))

for i in range(len(search.cv_results_['rank_test_similarity'])):
    str_result = f"[search.cv_results_['mean_test_similarity'][i]:.2%] +/- {search.
    cv_results_['std_test_similarity'][i]:.2%}"
    print(labels[i], str_result)

```

```

with stopwords removal, no_ngram, counts, without_idf, remove accents, No embed, default 53.69% +/- 7.13%
with stopwords removal, no_ngram, counts, without_idf, remove accents, No embed, absolute score 54.47% +/- 6.87%
with stopwords removal, no_ngram, counts, without_idf, remove accents, No embed, relative score 29.42% +/- 5.32%
with stopwords removal, no_ngram, counts, without_idf, remove accents, Word2Vec, default 53.32% +/- 5.99%
with stopwords removal, no_ngram, counts, without_idf, remove accents, Word2Vec, absolute score 52.95% +/- 5.50%
with stopwords removal, no_ngram, counts, without_idf, remove accents, Word2Vec, relative score 10.21% +/- 2.68%
with stopwords removal, no_ngram, counts, without_idf, remove accents, tSVD, default 51.56% +/- 7.38%
with stopwords removal, no_ngram, counts, without_idf, remove accents, tSVD, absolute score 49.75% +/- 7.89%
with stopwords removal, no_ngram, counts, without_idf, remove accents, tSVD, relative score 7.94% +/- 1.56%
with stopwords removal, no_ngram, counts, with_idf, remove accents, No embed, default 55.47% +/- 6.70%
with stopwords removal, no_ngram, counts, with_idf, remove accents, No embed, absolute score 52.47% +/- 6.91%
with stopwords removal, no_ngram, counts, with_idf, remove accents, No embed, relative score 32.73% +/- 5.21%
with stopwords removal, no_ngram, counts, with_idf, remove accents, Word2Vec, default 53.39% +/- 5.76%

```

```

with stopwords removal, no_ngram, counts, with_idf, remove accents, Word2Vec, absolute score 53.66% +/- 6.19%
with stopwords removal, no_ngram, counts, with_idf, remove accents, Word2Vec, relative score 10.17% +/- 2.66%
with stopwords removal, no_ngram, counts, with_idf, remove accents, tSVD, default 48.99% +/- 6.04%
with stopwords removal, no_ngram, counts, with_idf, remove accents, tSVD, absolute score 45.60% +/- 5.59%
with stopwords removal, no_ngram, counts, with_idf, remove accents, tSVD, relative score 9.15% +/- 2.08%
with stopwords removal, no_ngram, binary flag, without_idf, remove accents, No embed, default 53.29% +/- 7.86%
with stopwords removal, no_ngram, binary flag, without_idf, remove accents, No embed, absolute score 54.15% +/- 8.17%
with stopwords removal, no_ngram, binary flag, without_idf, remove accents, No embed, relative score 28.02% +/- 5.00%
with stopwords removal, no_ngram, binary flag, without_idf, remove accents, Word2Vec, default 52.09% +/- 5.94%
with stopwords removal, no_ngram, binary flag, without_idf, remove accents, Word2Vec, absolute score 52.89% +/- 6.00%
with stopwords removal, no_ngram, binary flag, without_idf, remove accents, Word2Vec, relative score 10.18% +/- 2.67%
with stopwords removal, no_ngram, binary flag, without_idf, remove accents, tSVD, default 54.65% +/- 8.83%
with stopwords removal, no_ngram, binary flag, without_idf, remove accents, tSVD, absolute score 54.34% +/- 8.17%
with stopwords removal, no_ngram, binary flag, without_idf, remove accents, tSVD, relative score 9.57% +/- 2.68%
with stopwords removal, no_ngram, binary flag, with_idf, remove accents, No embed, default 54.91% +/- 7.31%
with stopwords removal, no_ngram, binary flag, with_idf, remove accents, No embed, absolute score 51.80% +/- 8.13%
with stopwords removal, no_ngram, binary flag, with_idf, remove accents, No embed, relative score 31.39% +/- 5.59%
with stopwords removal, no_ngram, binary flag, with_idf, remove accents, Word2Vec, default 53.77% +/- 6.61%
with stopwords removal, no_ngram, binary flag, with_idf, remove accents, Word2Vec, absolute score 53.28% +/- 5.81%
with stopwords removal, no_ngram, binary flag, with_idf, remove accents, Word2Vec, relative score 10.17% +/- 2.66%
with stopwords removal, no_ngram, binary flag, with_idf, remove accents, tSVD, default 50.53% +/- 7.48%
with stopwords removal, no_ngram, binary flag, with_idf, remove accents, tSVD, absolute score 49.09% +/- 7.51%
with stopwords removal, no_ngram, binary flag, with_idf, remove accents, tSVD, relative score 9.03% +/- 3.18%

```

```
[31]: result_df = result_df.loc[result_df['run'] != 5].copy()
result_df = pd.concat([result_df, pd.DataFrame(search.cv_results_)], axis=0, ignore_index=True)
result_df['run'] = result_df['run'].fillna(5)
len(result_df)
```

[31]: 192

1.2.10 Random search : validation finale de l'ensemble des critères (run 6)

On applique enfin une random search, afin de voir si les conclusions qui avaient été tirée lors des explorations systématiques de certains domaines sont viables.

```
[32]: kwargs_to_prod = prod_params({'stop_words': {'with_stopwords_removal': stop_words, 'keep_stopwords': None},
                                    'use_idf': {'with_idf': True, 'no_idf': False},
                                    'binary': {'counts': False, 'binary_flag': True},
                                    'ngram_range': {'no_ngram': (1, 1), 'bigrams': (1, 2), 'trigrams': (1, 3)},
                                    'strip_accents': {'remove_accents': 'unicode', 'keep_accents': None},
                                    })
param_grid = [
    {'SimilaritySelector__count_vect_kw_args': kwargs_to_prod[1],
     'SimilaritySelector__scoring': ['default', 'absolute_score', 'relative_score'],
     'SimilaritySelector__similarity': ['cosine'],
     'SimilaritySelector__embedding_method': [None, 'Word2Vec', 'tSVD'],
     },
    {'SimilaritySelector__count_vect_kw_args': kwargs_to_prod[1],
```

```

        'SimilaritySelector__scoring': ['default'],
        'SimilaritySelector__similarity': ['projection'],
        'SimilaritySelector__source_norm': ['l2', 'l3', 'l4', 'l5'],
        'SimilaritySelector__projected_norm': ['l1', 'l2', 'l3', 'l4'],
    },
]
len(kwargs_to_prod[1])

search = RandomizedSearchCV(process_pipe,
                            param_grid,
                            n_iter=50,
                            cv=8,
                            scoring= {'similarity': lev_scorer, 'accuracy': custom_accuracy},
                            refit='similarity',
                            n_jobs=-1,
                            verbose=1,
                            ).fit(train, train['ingredients'])

```

Fitting 8 folds for each of 50 candidates, totalling 400 fits

[Parallel(n_jobs=-1)]: Using backend LokyBackend with 8 concurrent workers.
[Parallel(n_jobs=-1)]: Done 34 tasks | elapsed: 14.5s
[Parallel(n_jobs=-1)]: Done 184 tasks | elapsed: 2.0min

Launching 8 processes.

[Parallel(n_jobs=-1)]: Done 400 out of 400 | elapsed: 5.8min finished

[33]: search.best_params_

```

[33]: {'SimilaritySelector__source_norm': 'l2',
       'SimilaritySelector__similarity': 'projection',
       'SimilaritySelector__scoring': 'default',
       'SimilaritySelector__projected_norm': 'l1',
       'SimilaritySelector__count_vect_kwarg': {'stop_words': {'and',
                                                'au',
                                                'ce',
                                                'dans',
                                                'de',
                                                'des',
                                                'dont',
                                                'du',
                                                'en',
                                                'est',
                                                'et',
                                                'la',
                                                'le',
                                                'les',
                                                'of',
                                                'ou',
                                                'par',
                                                'pas',
                                                'pour',
                                                'que',
                                                'sur',
                                                'un'}},
       'use_idf': False,
       'binary': True,
       'ngram_range': (1, 3),
       'strip_accents': 'unicode'}}

```

[34]: search.best_score_

[34]: 0.619700702176325

1.2.11 Tuning des méthodes de vectorisation (run 7)

```
[35]: process_pipe.set_params(**{'Splitter__splitter_func': splitter_funcs[2],
                                })

kwargs_to_prod = prod_params({'stop_words': {'with stopwords removal' : stop_words},
                             'use_idf': {'with idf': True, 'no idf': False},
                             'binary': {'counts': False, 'binary flag': True},
                             'ngram_range': {'no_ngram': (1, 1),
                                             'bigrams': (1, 2),
                                             'trigrams': (1, 3),
                                             'quadgrams': (1, 4),
                                             'quintgrams': (1, 5)},
                             'strip_accents': {'remove accents': 'unicode'},
                            })

param_grid = [{{
    'SimilaritySelector__count_vect_kwargs': kwargs_to_prod[1],
    'SimilaritySelector__similarity': ['cosine'],
}, {
    'SimilaritySelector__count_vect_kwargs': kwargs_to_prod[1],
    'SimilaritySelector__similarity': ['projection'],
    'SimilaritySelector__source_norm': ['l4'],
    'SimilaritySelector__projected_norm': ['l3'],
}]

search = GridSearchCV(process_pipe,
                      param_grid,
                      cv=8,
                      scoring= ({'similarity': lev_scorer, 'accuracy': custom_accuracy}),
                      refit='similarity',
                      n_jobs=-1,
                      verbose=1,
                      error_score='raise',
                      ).fit(train, train['ingredients'])
```

Fitting 8 folds for each of 40 candidates, totalling 320 fits

```
[Parallel(n_jobs=-1)]: Using backend LokyBackend with 8 concurrent workers.
[Parallel(n_jobs=-1)]: Done  34 tasks      | elapsed:   18.9s
[Parallel(n_jobs=-1)]: Done 184 tasks      | elapsed:  1.5min
```

Launching 8 processes.

```
[Parallel(n_jobs=-1)]: Done 320 out of 320 | elapsed:  2.5min finished
```

```
[36]: labels = list(product(['cosine', 'Proj 14/13'],
                           kwargs_to_prod[0],
                           ))
# labels.extend(list(product(['projection l4/l2'], kwargs_to_prod[0])))
labels = list(map(lambda x: ', '.join(x), labels))

for i in range(len(search.cv_results_['rank_test_similarity'])):
    str_result = f"[search.cv_results_['mean_test_similarity'][i]:.2%] +/- {search.
    cv_results_['std_test_similarity'][i]:.2%}"
    print(labels[i], str_result)
```

```
cosine, with stopwords removal, with idf, counts, no_ngram, remove accents 55.47% +/- 6.70%
cosine, with stopwords removal, with idf, counts, bigrams, remove accents 55.86% +/- 6.78%
cosine, with stopwords removal, with idf, counts, trigrams, remove accents 55.01% +/- 6.50%
cosine, with stopwords removal, with idf, counts, quadgrams, remove accents 55.44% +/- 6.40%
cosine, with stopwords removal, with idf, counts, quintgrams, remove accents 55.62% +/- 6.47%
cosine, with stopwords removal, with idf, binary flag, no_ngram, remove accents 54.91% +/- 7.31%
cosine, with stopwords removal, with idf, binary flag, bigrams, remove accents 54.73% +/- 7.39%
cosine, with stopwords removal, with idf, binary flag, trigrams, remove accents 54.68% +/- 7.98%
cosine, with stopwords removal, with idf, binary flag, quadgrams, remove accents 54.23% +/- 7.59%
```

```

cosine, with stopwords removal, with idf, binary flag, quintgrams, remove accents 54.10% +/- 8.03%
cosine, with stopwords removal, no idf, counts, no_ngram, remove accents 53.69% +/- 7.13%
cosine, with stopwords removal, no idf, counts, bigrams, remove accents 54.43% +/- 7.18%
cosine, with stopwords removal, no idf, counts, trigrams, remove accents 54.26% +/- 7.21%
cosine, with stopwords removal, no idf, counts, quadgrams, remove accents 54.12% +/- 7.28%
cosine, with stopwords removal, no idf, counts, quintgrams, remove accents 54.29% +/- 7.21%
cosine, with stopwords removal, no idf, binary flag, no_ngram, remove accents 53.29% +/- 7.86%
cosine, with stopwords removal, no idf, binary flag, bigrams, remove accents 53.36% +/- 7.86%
cosine, with stopwords removal, no idf, binary flag, trigrams, remove accents 52.39% +/- 7.54%
cosine, with stopwords removal, no idf, binary flag, quadgrams, remove accents 51.73% +/- 7.89%
cosine, with stopwords removal, no idf, binary flag, quintgrams, remove accents 51.04% +/- 8.52%
Proj 14/13, with stopwords removal, with idf, counts, no_ngram, remove accents 10.23% +/- 1.89%
Proj 14/13, with stopwords removal, with idf, counts, bigrams, remove accents 9.05% +/- 2.18%
Proj 14/13, with stopwords removal, with idf, counts, trigrams, remove accents 8.95% +/- 2.33%
Proj 14/13, with stopwords removal, with idf, counts, quadgrams, remove accents 8.97% +/- 2.30%
Proj 14/13, with stopwords removal, with idf, counts, quintgrams, remove accents 8.97% +/- 2.30%
Proj 14/13, with stopwords removal, with idf, binary flag, no_ngram, remove accents 9.50% +/- 1.73%
Proj 14/13, with stopwords removal, with idf, binary flag, bigrams, remove accents 9.28% +/- 2.34%
Proj 14/13, with stopwords removal, with idf, binary flag, trigrams, remove accents 9.49% +/- 2.21%
Proj 14/13, with stopwords removal, with idf, binary flag, quadgrams, remove accents 9.65% +/- 2.34%
Proj 14/13, with stopwords removal, with idf, binary flag, quintgrams, remove accents 9.65% +/- 2.34%
Proj 14/13, with stopwords removal, no idf, counts, no_ngram, remove accents 56.36% +/- 4.14%
Proj 14/13, with stopwords removal, no idf, counts, bigrams, remove accents 59.61% +/- 4.00%
Proj 14/13, with stopwords removal, no idf, counts, trigrams, remove accents 60.39% +/- 3.35%
Proj 14/13, with stopwords removal, no idf, counts, quadgrams, remove accents 60.72% +/- 3.33%
Proj 14/13, with stopwords removal, no idf, counts, quintgrams, remove accents 60.87% +/- 3.19%
Proj 14/13, with stopwords removal, no idf, binary flag, no_ngram, remove accents 59.16% +/- 6.49%
Proj 14/13, with stopwords removal, no idf, binary flag, bigrams, remove accents 62.61% +/- 4.29%
Proj 14/13, with stopwords removal, no idf, binary flag, trigrams, remove accents 63.31% +/- 3.83%
Proj 14/13, with stopwords removal, no idf, binary flag, quadgrams, remove accents 63.21% +/- 3.84%
Proj 14/13, with stopwords removal, no idf, binary flag, quintgrams, remove accents 63.21% +/- 3.83%

```

```
[37]: result_df = result_df.loc[result_df['run'] != 7].copy()
result_df = pd.concat([result_df, pd.DataFrame(search.cv_results_)], axis=0, ignore_index=True)
result_df['run'] = result_df['run'].fillna(7)
len(result_df)
```

[37]: 232

1.2.12 Dépouillement des résultats

Préparation du dataframe On va maintenant interpréter le contenu du dataframe portant les résultats. On commence par renommer les colonnes qui ont de longs noms.

```
[38]: col_rename = {
    'param_SimilaritySelector__similarity': 'similarity',
    'param_Splitter__splitter_func': 'split_func',
    'param_SimilaritySelector__projected_norm': 'projected_norm',
    'param_SimilaritySelector__source_norm': 'source_norm',
    'param_SimilaritySelector__count_vect_type': 'count_vect_type',
    'param_SimilaritySelector__scoring': 'scoring',
    'param_SimilaritySelector__embedding_method': 'embedding_method',
}
result_df.rename(col_rename, axis=1, inplace=True)
```

On récupère maintenant le contenu des dictionnaires en tant que colonnes.

```
[39]: dict_cols = {'param_SimilaritySelector__count_vect_kwargs'}
to_concat = list()
for dict_col in dict_cols:
    to_concat.append(result_df[dict_col].apply(pd.Series))
    result_df.drop(dict_col, axis=1, inplace=True)
result_df = pd.concat([result_df, *to_concat], axis=1)
```

[40]: result_df.sample(3)

```
[40]:      mean_fit_time  std_fit_time  mean_score_time  std_score_time  similarity split_func  \
151      0.814467      0.064605      0.761567      0.066706  projection      NaN
219      1.647092      0.087426      1.187234      0.084328  projection      NaN
140      1.774916      0.102340      1.383115      0.128081  cosine      NaN

                                         params  split0_test_similarity  split1_test_similarity  \
151 {'SimilaritySelector__count_vect_kwargs': {'st...          0.229513          0.266554
219 {'SimilaritySelector__count_vect_kwargs': {'st...          0.114523          0.085755
140 {'SimilaritySelector__count_vect_kwargs': {'st...          0.457836          0.623919

split2_test_similarity ... projected_norm  source_norm  count_vect_type      scoring  \
151          0.227790  ...           12           14          NaN      NaN
219          0.128418  ...           13           14          NaN      NaN
140          0.496019  ...          NaN          NaN          NaN  absolute_score

embedding_method                      stop_words  ngram_range  strip_accents  \
151          NaN  {du, ce, par, de, et, est, la, des, sur, ou, d...  (1, 1)      unicode
219          NaN  {du, ce, par, de, et, est, la, des, sur, ou, d...  (1, 3)      unicode
140          NaN  {du, ce, par, de, et, est, la, des, sur, ou, d...  (1, 2)      unicode

binary  use_idf
151    True    True
219    True    True
140   False   True

[3 rows x 40 columns]
```

On effectue ensuite quelques prétraitements pour améliorer la lisibilité. On renomme les fonctions avec leur nom, et on applique une valeur par défaut.

```
[41]: def rename_funcs(func):
    try:
        return(func.__name__)
    except:
        return('split_func3')
result_df['split_func'] = result_df.loc[:, 'split_func'].apply(rename_funcs)
```

On met 2 critères pour le retrait des stopwords : retrait d'une liste, ou non retrait.

```
[42]: result_df['stop_words'].fillna('no_stopword_removal', inplace=True)
result_df.loc[result_df['stop_words'] != 'no_stopword_removal', 'stop_words'] = 'stop_word_list'
```

On renomme les ngram_ranges

```
[43]: ngram_dict = {(1, 1): 'no_ngram',
                  (1, 2): 'bigrams',
                  (1, 3): 'trigrams',
                  (1, 4): 'quadgrams',
                  (1, 5): 'quintgrams',
                }
result_df['ngram_range'] = result_df['ngram_range'].map(ngram_dict, na_action='ignore')
```

On renomme le retrait des accents.

```
[44]: accent_dict = {None: 'no_accent_removal',
                  'unicode': 'accent_removal',
                }
result_df['strip_accents'] = result_df['strip_accents'].map(accent_dict, na_action='ignore')
```

```
[45]: result_df.drop('params', axis=1, inplace=True)
```

On renomme les embeddings

```
[46]: embed_dict = {None: 'no_embedding',
                  'Word2Vec': 'Word2Vec',
                  'tSVD': 'tSVD',
```

```

        }
result_df['embedding_method'] = result_df['embedding_method'].map(embed_dict, na_action='ignore')

```

On applique ensuite les valeurs par défaut pour les colonnes sur lesquelles on n'a pas fait varier les critères.

```

[47]: # by default, accents are stripped
result_df['strip_accents'] = result_df['strip_accents'].fillna('accent_removal')
# scoring and embedding method are not applicable if projection
result_df.loc[result_df['similarity'] == 'projection', ['scoring', 'embedding_method']] = 'not_applicable'
# add default value to scoring for remainder
result_df.loc[pd.isna(result_df['scoring']), 'scoring'] = 'default'
# default value for embedding for remainder
result_df['embedding_method'] = result_df['embedding_method'].fillna('no_embedding')
# projected and source norm are not applicable if similarity is cosine
result_df.loc[result_df['similarity'] == 'cosine', ['source_norm', 'projected_norm']] = 'not_applicable'
# default value for norms for remainder
result_df['source_norm'] = result_df['source_norm'].fillna('12')
result_df['projected_norm'] = result_df['projected_norm'].fillna('11')

```

```

[48]: fillna_dict = {
    'similarity': 'projection',
    'split_func': 'split_func3',
    'count_vect_type': 'TfidfVectorizer',
    'use_idf': False,
    'binary': False,
}
for key, val in fillna_dict.items():
    result_df[key] = result_df[key].fillna(val)

```

```

[49]: parms = [
    'split_func',
    'stop_words',
    'strip_accents',
    'binary',
    'use_idf',
    'ngram_range',
    'similarity',
    'projected_norm',
    'source_norm',
    'count_vect_type',
    'scoring',
    'embedding_method',
]
result_df.reset_index().set_index(parms).drop('index', axis=1).sort_index()

```

```

[49]:                                mean_fit_time \
split_func  stop_words      strip_accents     binary use_idf ngram_range similarity projected_norm
source_norm   count_vect_type scoring          embedding_method
split_func1 no_stopword_removal accent_removal  False  False   bigrams    cosine    not_applicable
not_applicable TfidfVectorizer default         no_embedding           1.351985
                                                               projection 11               12
TfidfVectorizer not_applicable not_applicable      1.272452
                                                               no_ngram   cosine    not_applicable
not_applicable TfidfVectorizer default         no_embedding           0.858885
...
...
split_func3 stop_word_list      no_accent_removal False  False   no_ngram    projection 11               12
TfidfVectorizer not_applicable not_applicable      0.679841
                                                               trigrams   cosine    not_applicable
not_applicable TfidfVectorizer default         no_embedding           1.396822
                                                               projection 11               12
TfidfVectorizer not_applicable not_applicable      1.398119
                                                               std_fit_time \
split_func  stop_words      strip_accents     binary use_idf ngram_range similarity projected_norm
source_norm   count_vect_type scoring          embedding_method
split_func1 no_stopword_removal accent_removal  False  False   bigrams    cosine    not_applicable

```

```

not_applicable TfidfVectorizer default      no_embedding      0.122508
                                                projection 11      12
TfidfVectorizer not_applicable not_applicable 0.103519
                                                no_ngram cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding      0.061593
...
...
split_func3 stop_word_list      no_accent_removal False  False   no_ngram      projection 11      12
TfidfVectorizer not_applicable not_applicable 0.043345
                                                trigrams cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding      0.111692
                                                projection 11      12
TfidfVectorizer not_applicable not_applicable 0.130913
                                                mean_score_time \
split_func  stop_words      strip_accents binary use_idf ngram_range similarity projected_norm
source_norm  count_vect_type scoring      embedding_method
split_func1 no_stopword_removal accent_removal False False   bigrams cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding      1.624542
                                                projection 11      12
TfidfVectorizer not_applicable not_applicable 0.821700
                                                no_ngram cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding      0.809040
...
...
split_func3 stop_word_list      no_accent_removal False  False   no_ngram      projection 11      12
TfidfVectorizer not_applicable not_applicable 0.570729
                                                trigrams cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding      1.147467
                                                projection 11      12
TfidfVectorizer not_applicable not_applicable 0.751918
                                                std_score_time \
split_func  stop_words      strip_accents binary use_idf ngram_range similarity projected_norm
source_norm  count_vect_type scoring      embedding_method
split_func1 no_stopword_removal accent_removal False False   bigrams cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding      0.318567
                                                projection 11      12
TfidfVectorizer not_applicable not_applicable 0.084806
                                                no_ngram cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding      0.040443
...
...
split_func3 stop_word_list      no_accent_removal False  False   no_ngram      projection 11      12
TfidfVectorizer not_applicable not_applicable 0.058958
                                                trigrams cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding      0.119107
                                                projection 11      12
TfidfVectorizer not_applicable not_applicable 0.079647
                                                split0_test_similarity \
split_func  stop_words      strip_accents binary use_idf ngram_range similarity projected_norm
source_norm  count_vect_type scoring      embedding_method
split_func1 no_stopword_removal accent_removal False False   bigrams cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding      0.383472
                                                projection 11      12
TfidfVectorizer not_applicable not_applicable 0.545019
                                                no_ngram cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding      0.380675
...
...
split_func3 stop_word_list      no_accent_removal False  False   no_ngram      projection 11      12
TfidfVectorizer not_applicable not_applicable 0.542261
                                                trigrams cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding      0.444685
                                                projection 11      12
TfidfVectorizer not_applicable not_applicable 0.565570

```

```

split1_test_similarity \
split_func stop_words      strip_accents binary use_idf ngram_range similarity projected_norm
source_norm  count_vect_type scoring      embedding_method
split_func1 no_stopword_removal accent_removal False False bigrams cosine not_applicable
not_applicable TfidfVectorizer default      no_embedding          0.500577
projection 11                                12
TfidfVectorizer not_applicable not_applicable          0.621710
                                         no_ngram cosine not_applicable
not_applicable TfidfVectorizer default      no_embedding          0.503208
...
...
split_func3 stop_word_list      no_accent_removal False False no_ngram projection 11      12
TfidfVectorizer not_applicable not_applicable          0.653969
                                         trigrams cosine not_applicable
not_applicable TfidfVectorizer default      no_embedding          0.647609
projection 11                                12
TfidfVectorizer not_applicable not_applicable          0.692604

split2_test_similarity \
split_func stop_words      strip_accents binary use_idf ngram_range similarity projected_norm
source_norm  count_vect_type scoring      embedding_method
split_func1 no_stopword_removal accent_removal False False bigrams cosine not_applicable
not_applicable TfidfVectorizer default      no_embedding          0.324671
projection 11                                12
TfidfVectorizer not_applicable not_applicable          0.451395
                                         no_ngram cosine not_applicable
not_applicable TfidfVectorizer default      no_embedding          0.334112
...
...
split_func3 stop_word_list      no_accent_removal False False no_ngram projection 11      12
TfidfVectorizer not_applicable not_applicable          0.484972
                                         trigrams cosine not_applicable
not_applicable TfidfVectorizer default      no_embedding          0.478009
projection 11                                12
TfidfVectorizer not_applicable not_applicable          0.553719

split3_test_similarity \
split_func stop_words      strip_accents binary use_idf ngram_range similarity projected_norm
source_norm  count_vect_type scoring      embedding_method
split_func1 no_stopword_removal accent_removal False False bigrams cosine not_applicable
not_applicable TfidfVectorizer default      no_embedding          0.433144
projection 11                                12
TfidfVectorizer not_applicable not_applicable          0.557046
                                         no_ngram cosine not_applicable
not_applicable TfidfVectorizer default      no_embedding          0.410601
...
...
split_func3 stop_word_list      no_accent_removal False False no_ngram projection 11      12
TfidfVectorizer not_applicable not_applicable          0.573402
                                         trigrams cosine not_applicable
not_applicable TfidfVectorizer default      no_embedding          0.560348
projection 11                                12
TfidfVectorizer not_applicable not_applicable          0.593826

split4_test_similarity \
split_func stop_words      strip_accents binary use_idf ngram_range similarity projected_norm
source_norm  count_vect_type scoring      embedding_method
split_func1 no_stopword_removal accent_removal False False bigrams cosine not_applicable
not_applicable TfidfVectorizer default      no_embedding          0.464408
projection 11                                12
TfidfVectorizer not_applicable not_applicable          0.605446
                                         no_ngram cosine not_applicable
not_applicable TfidfVectorizer default      no_embedding          0.440279
...
...
split_func3 stop_word_list      no_accent_removal False False no_ngram projection 11      12

```

```

TfidfVectorizer not_applicable not_applicable          0.702138
                                         trigrams   cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding          0.662707
                                         projection 11           12
TfidfVectorizer not_applicable not_applicable          0.716421

                                         split5_test_similarity \
split_func stop_words      strip_accents   binary use_idf ngram_range similarity projected_norm
source_norm  count_vect_type scoring      embedding_method
split_func1 no_stopword_removal accent_removal False False  bigrams   cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding          0.367341
                                         projection 11           12
TfidfVectorizer not_applicable not_applicable          0.526797
                                         no_ngram   cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding          0.385640
...
...
split_func3 stop_word_list  no_accent_removal False  False  no_ngram   projection 11           12
TfidfVectorizer not_applicable not_applicable          0.563652
                                         trigrams   cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding          0.518518
                                         projection 11           12
TfidfVectorizer not_applicable not_applicable          0.596413

                                         .. \
split_func stop_words      strip_accents   binary use_idf ngram_range similarity projected_norm
source_norm  count_vect_type scoring      embedding_method ..
split_func1 no_stopword_removal accent_removal False False  bigrams   cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding          ..
                                         projection 11           12
TfidfVectorizer not_applicable not_applicable          ..
                                         no_ngram   cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding          ..
...
...
split_func3 stop_word_list  no_accent_removal False  False  no_ngram   projection 11           12
TfidfVectorizer not_applicable not_applicable          ..
                                         trigrams   cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding          ..
                                         projection 11           12
TfidfVectorizer not_applicable not_applicable          ..

                                         split2_test_accuracy \
split_func stop_words      strip_accents   binary use_idf ngram_range similarity projected_norm
source_norm  count_vect_type scoring      embedding_method
split_func1 no_stopword_removal accent_removal False False  bigrams   cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding          0.12
                                         projection 11           12
TfidfVectorizer not_applicable not_applicable          0.18
                                         no_ngram   cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding          0.12
...
...
split_func3 stop_word_list  no_accent_removal False  False  no_ngram   projection 11           12
TfidfVectorizer not_applicable not_applicable          0.16
                                         trigrams   cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding          0.20
                                         projection 11           12
TfidfVectorizer not_applicable not_applicable          0.24

                                         split3_test_accuracy \
split_func stop_words      strip_accents   binary use_idf ngram_range similarity projected_norm
source_norm  count_vect_type scoring      embedding_method
split_func1 no_stopword_removal accent_removal False False  bigrams   cosine    not_applicable
not_applicable TfidfVectorizer default      no_embedding          0.16
                                         projection 11           12
TfidfVectorizer not_applicable not_applicable          0.16

```

```

not_applicable TfidfVectorizer default      no_embedding      no_ngram    cosine    not_applicable
...                                         ...                         0.16
...
...
split_func3 stop_word_list      no_accent_removal False  False      no_ngram    projection 11      12
TfidfVectorizer not_applicable not_applicable          0.18
trigrams      cosine    not_applicable
0.20
not_applicable TfidfVectorizer default      no_embedding      no_ngram    projection 11      12
TfidfVectorizer not_applicable not_applicable          0.20

split4_test_accuracy \
split_func  stop_words      strip_accents  binary use_idf ngram_range similarity projected_norm
source_norm  count_vect_type scoring      embedding_method
split_func1 no_stopword_removal accent_removal  False  False      bigrams    cosine    not_applicable
0.14
not_applicable TfidfVectorizer default      no_embedding      no_ngram    projection 11      12
TfidfVectorizer not_applicable not_applicable          0.20
no_ngram      cosine    not_applicable
0.12
not_applicable TfidfVectorizer default      no_embedding      no_ngram    cosine    not_applicable
...
...
split_func3 stop_word_list      no_accent_removal False  False      no_ngram    projection 11      12
TfidfVectorizer not_applicable not_applicable          0.24
trigrams      cosine    not_applicable
0.22
not_applicable TfidfVectorizer default      no_embedding      no_ngram    projection 11      12
TfidfVectorizer not_applicable not_applicable          0.26

split5_test_accuracy \
split_func  stop_words      strip_accents  binary use_idf ngram_range similarity projected_norm
source_norm  count_vect_type scoring      embedding_method
split_func1 no_stopword_removal accent_removal  False  False      bigrams    cosine    not_applicable
0.18
not_applicable TfidfVectorizer default      no_embedding      no_ngram    projection 11      12
TfidfVectorizer not_applicable not_applicable          0.26
no_ngram      cosine    not_applicable
0.20
not_applicable TfidfVectorizer default      no_embedding      no_ngram    cosine    not_applicable
...
...
split_func3 stop_word_list      no_accent_removal False  False      no_ngram    projection 11      12
TfidfVectorizer not_applicable not_applicable          0.26
trigrams      cosine    not_applicable
0.20
not_applicable TfidfVectorizer default      no_embedding      no_ngram    projection 11      12
TfidfVectorizer not_applicable not_applicable          0.28

split6_test_accuracy \
split_func  stop_words      strip_accents  binary use_idf ngram_range similarity projected_norm
source_norm  count_vect_type scoring      embedding_method
split_func1 no_stopword_removal accent_removal  False  False      bigrams    cosine    not_applicable
0.12
not_applicable TfidfVectorizer default      no_embedding      no_ngram    projection 11      12
TfidfVectorizer not_applicable not_applicable          0.22
no_ngram      cosine    not_applicable
0.12
not_applicable TfidfVectorizer default      no_embedding      no_ngram    cosine    not_applicable
...
...
split_func3 stop_word_list      no_accent_removal False  False      no_ngram    projection 11      12
TfidfVectorizer not_applicable not_applicable          0.22
trigrams      cosine    not_applicable
0.14
not_applicable TfidfVectorizer default      no_embedding      no_ngram    projection 11      12
TfidfVectorizer not_applicable not_applicable          0.24

split7_test_accuracy \
split_func  stop_words      strip_accents  binary use_idf ngram_range similarity projected_norm

```

```

source_norm      count_vect_type scoring      embedding_method
split_func1 no_stopword_removal accent_removal False False    bigrams      cosine      not_applicable
not_applicable TfidfVectorizer default        no_embedding          0.14
                                                               projection 11           12
TfidfVectorizer not_applicable not_applicable          0.18
                                                               no_ngram      cosine      not_applicable
not_applicable TfidfVectorizer default        no_embedding          0.14
...
...
split_func3 stop_word_list      no_accent_removal False False    no_ngram      projection 11           12
TfidfVectorizer not_applicable not_applicable          0.18
                                                               trigrams      cosine      not_applicable
not_applicable TfidfVectorizer default        no_embedding          0.14
                                                               projection 11           12
TfidfVectorizer not_applicable not_applicable          0.18

                                mean_test_accuracy \
split_func  stop_words      strip_accents      binary use_idf ngram_range similarity projected_norm
source_norm      count_vect_type scoring      embedding_method
split_func1 no_stopword_removal accent_removal False False    bigrams      cosine      not_applicable
not_applicable TfidfVectorizer default        no_embedding          0.1450
                                                               projection 11           12
TfidfVectorizer not_applicable not_applicable          0.2075
                                                               no_ngram      cosine      not_applicable
not_applicable TfidfVectorizer default        no_embedding          0.1450
...
...
split_func3 stop_word_list      no_accent_removal False False    no_ngram      projection 11           12
TfidfVectorizer not_applicable not_applicable          0.2075
                                                               trigrams      cosine      not_applicable
not_applicable TfidfVectorizer default        no_embedding          0.1900
                                                               projection 11           12
TfidfVectorizer not_applicable not_applicable          0.2350

                                std_test_accuracy \
split_func  stop_words      strip_accents      binary use_idf ngram_range similarity projected_norm
source_norm      count_vect_type scoring      embedding_method
split_func1 no_stopword_removal accent_removal False False    bigrams      cosine      not_applicable
not_applicable TfidfVectorizer default        no_embedding          0.019365
                                                               projection 11           12
TfidfVectorizer not_applicable not_applicable          0.031524
                                                               no_ngram      cosine      not_applicable
not_applicable TfidfVectorizer default        no_embedding          0.025981
...
...
split_func3 stop_word_list      no_accent_removal False False    no_ngram      projection 11           12
TfidfVectorizer not_applicable not_applicable          0.031524
                                                               trigrams      cosine      not_applicable
not_applicable TfidfVectorizer default        no_embedding          0.038730
                                                               projection 11           12
TfidfVectorizer not_applicable not_applicable          0.029580

                                rank_test_accuracy \
split_func  stop_words      strip_accents      binary use_idf ngram_range similarity projected_norm
source_norm      count_vect_type scoring      embedding_method
split_func1 no_stopword_removal accent_removal False False    bigrams      cosine      not_applicable
43
not_applicable TfidfVectorizer default        no_embedding
                                                               projection 11           12
TfidfVectorizer not_applicable not_applicable          16
                                                               no_ngram      cosine      not_applicable
43
not_applicable TfidfVectorizer default        no_embedding
...
...
split_func3 stop_word_list      no_accent_removal False False    no_ngram      projection 11           12
TfidfVectorizer not_applicable not_applicable          16
                                                               trigrams      cosine      not_applicable
not_applicable TfidfVectorizer default        no_embedding          27

```

```

TfidfVectorizer not_applicable not_applicable           projection 11      12
source_norm count_vect_type scoring embedding_method
split_func stop_words      strip_accents    binary use_idf ngram_range similarity projected_norm
split_func1 no_stopword_removal accent_removal False False  bigrams cosine not_applicable
not_applicable TfidfVectorizer default      no_embedding 1.0
TfidfVectorizer not_applicable not_applicable           projection 11      12
not_applicable TfidfVectorizer default      no_embedding 1.0
no_ngram cosine not_applicable
...
...
split_func3 stop_word_list      no Accent_removal False False  no_ngram projection 11      12
TfidfVectorizer not_applicable not_applicable 1.0
not_applicable TfidfVectorizer default      no_embedding 1.0
trigrams cosine not_applicable
TfidfVectorizer not_applicable not_applicable           projection 11      12
TfidfVectorizer not_applicable not_applicable 1.0
[232 rows x 27 columns]

```

[50]: result_df.to_csv(Path('.') / 'model_tuning_results.csv')

[51]: result_df = pd.read_csv(Path('.') / 'model_tuning_results.csv')

Sélection des fonctions de preprocessing

```

[52]: fig, axs = plt.subplots(nrows= 2, figsize=(8,10), sharex=True)

feats = ['mean_test_similarity', 'mean_test_accuracy']

parms = {'data': result_df.loc[result_df['run'] == 1],
          'x': 'stop_words',
          'hue': 'strip_accents',
         }

for i, feature in enumerate(feats):
    swarm = sns.swarmplot(**parms,
                          y=feature,
                          dodge=True,
                          #                  color='blue',
                          ax=axs[i],
                         )

    sns.boxplot(**parms,
                y=feature,
                ax=axs[i],
                color='white',
                width=.6,
               )

    axs[i].set_yticks([0, 25, 50, 75, 100])
    axs[i].set_ylabel('Similarité moyenne', fontsize=12)
    axs[i].set_xlabel('Gestion des stopwords', fontsize=12)
    axs[i].set_xticklabels(['Pas de retrait de stopwords', 'Retrait des stopwords'])

    fig.legend(handles=axs[0].get_legend_handles_labels()[0][2:],
               labels=['Conservation des accents', 'Retrait des accents'],
               loc='center',
              )

```



```

    ncol=2,
    bbox_to_anchor=(0, 1, 1, 0.12),
    bbox_transform=axs[0].transAxes,
)

fig.suptitle('Comparaison des fonctions de preprocessing', fontsize=16, y=.95)
fig.savefig(Path('..') / 'img' / 'tuning_prepro.png', bbox_inches='tight')

```

Comparaison des fonctions de preprocessing



Sélection de la fonction de split

```
[53]: fig, axs = plt.subplots(nrows= 2, figsize=(8,10), sharex=True)

feats = ['mean_test_similarity', 'mean_test_accuracy']

parms = {'data': result_df.loc[result_df['run'] == 1],
         'x': 'split_func',
         'hue': None,
         }

for i, feature in enumerate(feats):
    swarm = sns.swarmplot(**parms,
                          y=feature,
                          dodge=True,
                          #                         color='blue',
                          ax=axs[i],
                          )

    sns.boxplot(**parms,
                y=feature,
                ax=axs[i],
                color='white',
                width=.6,
                )


    axs[i].set_yticks([0])
    axs[i].yaxis.set_major_formatter(mtick.PercentFormatter(xmax=1.))
#     axs[i].get_legend().remove()
    axs[i].set_xlabel('')

axs[1].set_xlabel('Fonction de découpage', fontsize=12)
axs[0].set_ylabel('Similarité moyenne', fontsize=12)
axs[1].set_ylabel('Accuracy moyenne', fontsize=12)
axs[1].set_xticklabels(['Fonction 1', 'Fonction 2', 'Fonction 3'])

# fig.legend(handles=axs[0].get_legend_handles_labels()[0][2:],
#            labels=['Conservation des accents', 'Retrait des accents'],
#            loc='center',
#            ncol=2,
#            bbox_to_anchor=(0, 1, 1, 0.12),
#            bbox_transform=axs[0].transAxes,
#            )

fig.suptitle('Comparaison des fonctions de découpage', fontsize=16, y=.92)
fig.savefig(Path('..') / 'img' / 'tuning_split.png', bbox_inches='tight')
```

Comparaison des fonctions de découpage



Comparatif des similarités

```
[54]: result_df['simil_kind'] = result_df['similarity'] + result_df['source_norm'] + result_df['projected_norm']

[55]: result_df['embedding_method'].unique()

[55]: array(['not_applicable', 'no_embedding', 'Word2Vec', 'tSVD'], dtype=object)
```

```

[56]: fig, axs = plt.subplots(nrows= 2, figsize=(8,10), sharex=True)

feats = ['mean_test_similarity', 'mean_test_accuracy']

parms = {'data': result_df.loc[(result_df['run'] == 2) &
                               (result_df['strip_accents'] == 'accent_removal') &
                               (result_df['stop_words'] == 'stop_word_list') &
                               (result_df['scoring'].isin({'default', 'not_applicable'})) &
                               (result_df['embedding_method'].isin({'no_embedding', 'not_applicable'}))],
          'x': 'simil_kind',
          'hue': None,
         }

patch_list = [
    mpatch.Rectangle((-1, 0), 2.5, 1, color='green', alpha=.2, edgecolor=None),
    mpatch.Rectangle((1.5, 0), 5, 1, color='blue', alpha=.2, edgecolor=None),
    mpatch.Rectangle((6.5, 0), 5, 1, color='orange', alpha=.2, edgecolor=None),
    mpatch.Rectangle((11.5, 0), 5, 1, color='red', alpha=.2, edgecolor=None),
    mpatch.Rectangle((16.5, 0), 2, 1, color='purple', alpha=.2, edgecolor=None),
    mpatch.Rectangle((-1, 0), 2.5, 1, color='green', alpha=.2, edgecolor=None),
    mpatch.Rectangle((1.5, 0), 5, 1, color='blue', alpha=.2, edgecolor=None),
    mpatch.Rectangle((6.5, 0), 5, 1, color='orange', alpha=.2, edgecolor=None),
    mpatch.Rectangle((11.5, 0), 5, 1, color='red', alpha=.2, edgecolor=None),
    mpatch.Rectangle((16.5, 0), 2, 1, color='purple', alpha=.2, edgecolor=None),
]

for i, feature in enumerate(feats):
    swarm = sns.swarmplot(**parms,
                          y=feature,
                          dodge=True,
                          #           color='blue',
                          ax=axs[i],
                         )

    axs[i].yaxis.set_major_formatter(mtick.PercentFormatter(xmax=1.))
    axs[i].set_xlabel('')
    for j in range(len(patch_list) // 2):
        axs[i].add_patch(patch_list[i * len(patch_list) // 2 + j])

axs[1].set_xlabel('Identification du meilleur candidat', fontsize=12)
axs[0].set_ylabel('Similarité moyenne', fontsize=12)
axs[1].set_ylabel('Accuracy moyenne', fontsize=12)
labels = ['Proj. L1/L1',
          'Proj. L2/L2',
          'Proj. L2/L1',
          'Proj. L3/L2',
          'Proj. L4/L3',
          'Proj. L5/L4',
          'Proj. L6/L5',
          'Proj. L3/L1',
          'Proj. L4/L2',
          'Proj. L5/L3',
          'Proj. L6/L4',
          'Proj. L7/L5',
          'Proj. L4/L1',
          'Proj. L5/L2',
          'Proj. L6/L3',
          'Proj. L7/L2',
          'Proj. L8/L3',
          'Cosinus']
plt.setp(axs[1].xaxis.get_majorticklabels(), rotation=70)
axs[1].set_xticklabels(labels)
fig.legend(handles=patch_list[len(patch_list) // 2:], labels=['Proj. delta=0', 'Proj. delta=1', 'Proj. delta=2', 'Proj. delta=3', 'Cosinus'],
           loc='center',
           ncol=5,
           bbox_to_anchor=(0, 1, 1, 0.12),

```


```

bbox_transform=axs[0].transAxes,
)

fig.suptitle("Comparaison des méthodes d'identification du meilleur candidat", fontsize=16, y=.945)
fig.savefig(Path('..') / 'img' / 'tuning_similarite.png', bbox_inches='tight')

```

Comparaison des méthodes d'identification du meilleur candidat




[57]: result_df.columns

```
[57]: Index(['Unnamed: 0', 'mean_fit_time', 'std_fit_time', 'mean_score_time', 'std_score_time', 'similarity',  
         'split_func', 'split0_test_similarity', 'split1_test_similarity', 'split2_test_similarity',  
         'split3_test_similarity', 'split4_test_similarity', 'split5_test_similarity',  
         'split6_test_similarity', 'split7_test_similarity', 'mean_test_similarity', 'std_test_similarity',  
         'rank_test_similarity', 'split0_test_accuracy', 'split1_test_accuracy', 'split2_test_accuracy',  
         'split3_test_accuracy', 'split4_test_accuracy', 'split5_test_accuracy', 'split6_test_accuracy',  
         'split7_test_accuracy', 'mean_test_accuracy', 'std_test_accuracy', 'rank_test_accuracy', 'run',  
         'projected_norm', 'source_norm', 'count_vect_type', 'scoring', 'embedding_method', 'stop_words',  
         'ngram_range', 'strip_accents', 'binary', 'use_idf', 'simil_kind'],  
        dtype='object')
```

```
[58]: fig, axs = plt.subplots(nrows= 2, figsize=(8,10), sharex=True)  
  
feats = ['mean_test_similarity', 'mean_test_accuracy']  
  
parms = {'data': result_df.loc[result_df['run'] == 7],  
         'x': 'similarity',  
         'hue': 'use_idf',  
         }  
  
for i, feature in enumerate(feats):  
    swarm = sns.swarmplot(**parms,  
                          y=feature,  
                          dodge=True,  
                          #  
                          color='blue',  
                          ax=axs[i],  
                          )  
  
    sns.boxplot(**parms,  
                y=feature,  
                ax=axs[i],  
                color='white',  
                width=.6,  
                )  
  
    axs[i].set_yticks([0, 1])  
    axs[i].set_ylabels(['Similarité moyenne', 'Accuracy moyenne'])  
    axs[i].set_xticks([0, 1])  
    axs[i].set_xticklabels(['Cosinus', 'Projection L4/L3'])  
  
    if i == 0:  
        axs[i].set_xlabel('Identification du meilleur candidat', fontsize=12)  
        axs[i].set_ylabel('Similarité moyenne', fontsize=12)  
    else:  
        axs[i].set_xlabel('')  
        axs[i].set_ylabel('Accuracy moyenne', fontsize=12)  
        axs[i].set_xticklabels(['Cosinus', 'Projection L4/L3'])  
  
fig.legend(handles=axs[0].get_legend_handles_labels()[0][2:],  
           labels=["Sans inverse document frequency", "Avec calcul de l'inverse document frequency"],  
           loc='center',  
           ncol=2,  
           bbox_to_anchor=(0, 1, 1, 0.12),  
           bbox_transform=axs[0].transAxes,  
           )  
  
fig.suptitle('Comparaison des modes de vectorisation : idf', fontsize=16, y=.95)  
fig.savefig(Path('..') / 'img' / 'tuning_idf.png', bbox_inches='tight')
```

Comparaison des modes de vectorisation : idf



```
[59]: result_df['use_idf']
```

```
[59]: 0    False
1    False
2    False
...
229   False
230   False
231   False
Name: use_idf, Length: 232, dtype: bool
```

```
[60]: fig, axs = plt.subplots(nrows= 2, figsize=(8,10), sharex=True)

feats = ['mean_test_similarity', 'mean_test_accuracy']

parms = {'data': result_df.loc[(result_df['run'] == 7) &
                               ((result_df['similarity'] == 'cosine') | # & result_df['use_idf'] /
                                (result_df['similarity'] == 'projection') & ~result_df['use_idf'])]
         ],
         'x': 'similarity',
         'hue': 'ngram_range',
         }

for i, feature in enumerate(feats):
    swarm = sns.swarmplot(**parms,
                          y=feature,
                          dodge=True,
                          #                      color='blue',
                          ax=axs[i],
                          )

    #    sns.boxplot(**parms,
    #                y=feature,
    #                ax=axs[i],
    #                color='white',
    #                width=.6,
    #                )


    #    axs[i].set_ylim(0,)
    axs[i].yaxis.set_major_formatter(mtick.PercentFormatter(xmax=1.))
    axs[i].get_legend().remove()
    axs[i].set_xlabel('')

axs[1].set_xlabel('Identification du meilleur candidat', fontsize=12)
axs[0].set_ylabel('Similitarité moyenne', fontsize=12)
axs[1].set_ylabel('Accuracy moyenne', fontsize=12)
axs[1].set_xticklabels(['Cosinus', 'Projection L4/L3'])

fig.legend(handles=axs[0].get_legend_handles_labels()[0][:],
           labels=['Monogrammes', 'Bigrammes', 'Trigrammes', '4-grammes', '5-grammes'],
           loc='center',
           ncol=5,
           bbox_to_anchor=(0, 1, 1, 0.12),
           bbox_transform=axs[0].transAxes,
           )

fig.suptitle('Comparaison des modes de vectorisation : n-grams', fontsize=16, y=.95)
fig.savefig(Path('..') / 'img' / 'tuning_ngrams.png', bbox_inches='tight')
```

Comparaison des modes de vectorisation : n-grammes



```
[61]: fig, axs = plt.subplots(nrows= 2, figsize=(8,10), sharex=True)

feats = ['mean_test_similarity', 'mean_test_accuracy']

parms = {'data': result_df.loc[(result_df['run'] == 5)
                               ],
          'x': 'scoring',
          'hue': 'use_idf',
         }

for i, feature in enumerate(feats):
    swarm = sns.swarmplot(**parms,
                          y=feature,
```

```

        dodge=True,
        color='blue',
        ax=axs[i],
    )

sns.boxplot(**parms,
            y=feature,
            ax=axs[i],
            color='white',
            width=.6,
            )

#     axs[i].set_ylim(0,)

axs[i].yaxis.set_major_formatter(mtick.PercentFormatter(xmax=1.))
axs[i].get_legend().remove()
axs[i].set_xlabel('')

axs[1].set_xlabel('Identification du meilleur candidat', fontsize=12)
axs[0].set_ylabel('Similarité moyenne', fontsize=12)
axs[1].set_ylabel('Accuracy moyenne', fontsize=12)
axs[1].set_xticklabels(['Sans score', 'Score absolu', 'Score relatif'])


fig.legend(handles=axs[0].get_legend_handles_labels()[0][2:],
           labels=["Sans idf", "Avec calcul de l'idf"],
           loc='center',
           ncol=5,
           bbox_to_anchor=(0, 1, 1, 0.12),
           bbox_transform=axs[0].transAxes,
           )

fig.suptitle('Comparaison des modes de vectorisation : Scores spécifiques', fontsize=16, y=.95)

fig.savefig(Path('..') / 'img' / 'tuning_score.png', bbox_inches='tight')

```

Comparaison des modes de vectorisation : Scores spécifiques



```
[62]: fig, axs = plt.subplots(nrows= 2, figsize=(8,10), sharex=True)

feats = ['mean_test_similarity', 'mean_test_accuracy']

parms = {'data': result_df.loc[(result_df['run'] == 5)
                               ],
         'x': 'embedding_method',
         'hue': 'scoring',
         }

for i, feature in enumerate(feats):
```

```

swarm = sns.swarmplot(**parms,
                      y=feature,
                      dodge=True,
                      #           color='blue',
                      ax=axs[i],
                      )

sns.boxplot(**parms,
            y=feature,
            ax=axs[i],
            color='white',
            width=.6,
            )

#     axs[i].set_ylim(0,)

axs[i].yaxis.set_major_formatter(mtick.PercentFormatter(xmax=1.))
axs[i].get_legend().remove()
axs[i].set_xlabel('')

axs[1].set_xlabel('Identification du meilleur candidat', fontsize=12)
axs[0].set_ylabel('Similarité moyenne', fontsize=12)
axs[1].set_ylabel('Accuracy moyenne', fontsize=12)
axs[1].set_xticklabels(['Sans embedding', 'Word2Vec', 'tSVD'])


fig.legend(handles=axs[0].get_legend_handles_labels()[0][3:],
           labels=["Sans scoring", "Score absolu", "Score relatif"],
           loc='center',
           ncol=3,
           bbox_to_anchor=(0, 1, 1, 0.12),
           bbox_transform=axs[0].transAxes,
           )

fig.suptitle('Comparaison des modes de vectorisation : embeddings', fontsize=16, y=.95)

fig.savefig(Path('..') / 'img' / 'tuning_embedding.png', bbox_inches='tight')

```

Comparaison des modes de vectorisation : embeddings



1.3 Evaluation finale

On évalue la performance du modèle avec les meilleurs paramètres sur le set de test, après entraînement sur le set d'entraînement.

```
[73]: parm_dict = {'Splitter__splitter_func': splitter_funcs[2],
                 'SimilaritySelector__count_vect_type': 'TfidfVectorizer',
                 'SimilaritySelector__similarity': 'projection',
                 'SimilaritySelector__source_norm': 'l1'}
```

```

        'SimilaritySelector__projected_norm': 'l3',
        'SimilaritySelector__count_vect_kwargs': {'ngram_range': (1, 3),
                                                'stop_words': stop_words,
                                                'strip_accents': 'unicode',
                                                'binary': True,
                                                'use_idf': False,
                                                }
    }

process_pipe.set_params(**parm_dict)
process_pipe.fit(train, train['ingredients'])
print(f"Levenshtein similarity at final evaluation: {lev_scorer(process_pipe, test, test['ingredients']):.2%}")
print(f"Accuracy at final evaluation: {custom_accuracy(process_pipe, test, test['ingredients']):.2%}")

```

Launching 8 processes.
 Launching 8 processes.
 Levenshtein similarity at final evaluation: 67.18%
 Launching 8 processes.
 Accuracy at final evaluation: 27.00%

```
[82]: predicted = process_pipe.predict(test)
lev_sim = partial(text_similarity, similarity='levenshtein')
```

Launching 8 processes.

```
[103]: comparison = (predicted.rename('Predicted')
                     .to_frame()
                     .join(test['ingredients'])
                     .rename({'ingredients': 'Target'}, axis=1))
comparison['Similarity'] = comparison.apply(lambda x: f"{lev_sim(x['Predicted'], x['Target']):.2%}", axis=1)
comparison.sample(5)
```

	Predicted \	Target	Similarity
uid			
5cee689e-6fb1-493c-b232-1d8fb1f88a57	Flageolets verts. Jus : eau, sel, affermissant...		
df1caa23-9714-4659-803b-33501d64eed	Liste des Ingrédients:\nsucre, pâte de cacao, ..		
6dfae8fd-6111-4a57-862e-c20a39a195e0	Farine de BLÉ 63%, eau, sucre, huile de colza,..		
f45db604-11ad-4756-aeab-3a5a1a34f914	Ingrédients: sucre; sirop de glucose; dextrose...		
6bdb201d-5879-423b-96b8-3ae88b857818	Liste d'ingrédients : vinaigre d'alcool, pimen...		

```
[123]: with pd.option_context("max_colwidth", 2100):
    tex_str = (
        comparison.replace(r'\s*$', np.nan, regex=True)
                    .to_latex(index=False,
                               index_names=False,
                               column_format='p{9cm}p{9cm}c',
                               na_rep='<rien>',
                               longtable=True,
                               header=["Liste d'ingrédients prédite", "Liste d'ingrédients cible", "Sim."],
                               label='tbl:final_prediction',
                               caption="Prédictions du meilleur modèle sur le set de test",
                               )
                    .replace(r'\textbackslash', r' \newline ')
```

```
        .replace(r'\\', r'\\ \\hline')
    )
# with open(Path('..') / 'tbls' / 'final_prediction.tex', 'w') as file:
#     file.write(tex_str)
```

Analyse quantitative

Pierre MASSÉ

May 12, 2020

1 Analyse quantitative multibranche

```
[1]: # data analysis
import pandas as pd
pd.options.display.width=108
import numpy as np

# visualization
import matplotlib.pyplot as plt
import seaborn as sns
from matplotlib_venn import venn3_unweighted, venn3
import matplotlib as mpl
# mpl.rcParams['text.usetex'] = True
# plt.rcParams['text.latex.preamble'] = [r'\usepackage{lmodern}']

# utils
from pathlib import Path
```

Définition des couleurs :

```
[2]: c_pomona = tuple(val / 255 for val in [0, 92, 132])
c_terreazur = tuple(val / 255 for val in [0, 152, 170])
c_episaveurs = tuple(val / 255 for val in [255, 69, 0])
c_passionfroid = tuple(val / 255 for val in [109, 32, 124])
c_deliceetcreation = tuple(val / 255 for val in [97, 45, 28])
c_saveursdantoine = tuple(val / 255 for val in [156, 34, 63])
```

On charge les données d'un fichier exporté du système de gestion des branches RHD (SAP).

```
[3]: path = Path('..') / 'data' / 'export2020.csv'

types = {
    'material': 'object',
    'branch': 'int',
    'plant': 'object',
    'type': 'object',
    'designation': 'object',
    'del_mand': 'bool',
    'del_plant': 'bool',
    'march_group': 'object',
    'storage_cond': 'object',
    'hier': 'object',
}
df = pd.read_csv(path,
                  sep=';',
                  encoding='latin-1',
                  engine='python',
                  header=0,
                  skipfooter=1, # footer line with totals in export
                  dtype=types,
                  true_values=['X'], # for del_mand and del_plant
                  false_values=['', np.nan], # for del_mand and del_plant
)
```

```
df = df[types.keys()] #filter and reorder columns
```

Parmi les colonnes conservées, on a : - le code article (material)

- le code de branche de création (branch).
 - 1: PassionFroid
 - 2: EpiSaveurs
 - 3: TerreAzur
- le code d'activation sur une branche (plant).
 - 1PPF: PassionFroid
 - 2PES: EpiSaveurs
 - 3PTA: TerreAzur
- le type d'article (type). Seuls ZNEG et ZPRE représententent des articles de marchandises.
 - ZNEG: Négoce
 - ZPRE: Prestation
 - ZENG: Article d'engagement (fictif pour facturation)
 - ZEMB: Article d'emballage (ex: palette)
 - ZSER: Article de service
- le libellé de l'article (designation)
- si l'article est marqué pour suppression pour toutes les branches (del_mand)
- si l'article est marqué pour suppression sur la branche mentionnée dans la colonne plant (del_plant).
- le groupe de marchandises (march_group) :
 - ZSURGE: Surgelés
 - ZFRAIS: Frais (PassionFroid)
 - ZEPI: Epicerie
 - ZBOI: Boissons
 - ZHYG: Hygiène et chimie
 - ZFLF: Fruits et légumes (TerreAzur)
 - ZPMF: Produits de la mer (TerreAzur)
 - ZFP: Fleurs et plantes
 - ZELAB: Produits élaborés (TerreAzur)
- la condition de stockage (storage_cond) :
 - FR: Frais (PassionFroid)
 - SU: Surgelé,
 - EP: Epicerie,
 - AL: Alcool
 - HY: Hygiène et chimie
 - FL: Fruits et légumes (TerreAzur)
 - FP: Fleurs et plantes
 - MA: Marée
 - SA: Saurisserie (produits élaborés de la mer)
 - SE: Articles de Service
 - PL: Articles de publicité
- la hiérarchie produit (hier). Un plan de classement sur 6 niveaux, représentés par 2 caractères numériques chacun.

On crée une nouvelle feature qui correspond au niveau 1 de la hiérarchie produit.

```
[4]: # Creation of first level of product hierarchy
df.loc[:, 'hier1'] = df.hier.str[:2]
```

On définit un dictionnaire permettant de rappeler les libellés long des divers codes présents dans le dataset.

```
[5]: # Label names
lab = {'type': 'Type de produit',
       'march_group': 'Groupe de marchandises',
       'storage_cond': 'Condition de stockage',
       'hier1': 'Niveau 1 hiérarchie produit',
       '1PPF': 'PassionFroid',
       '2PES': 'EpiSaveurs',
       '3PTA': 'TerreAzur',
       'ZNEG': 'Article de négoce',
       'ZPRE': 'Article de prestation',
       'ZSURGE': 'Surgelés',
       'ZFRAIS': 'Frais',
       'ZEPI': 'Epicerie',
       'ZBOI': 'Boissons',
       'ZHYG': 'Hygiène',
```

```

'ZFLF': 'Fruits et Légumes',
'ZPMF': 'Produits de la mer',
'ZELAB': 'Produits élaborés',
'ZFP': 'Fleurs et plantes',
'ZAUTRE': 'Autres',
'SU': 'Surgelés',
'FR': 'Frais',
'EP': 'Epicerie',
'AL': 'Alcool',
'HY': 'Hygiène',
'FL': 'Fruits et légumes',
'MA': 'Marée',
'FP': 'Fleurs et plantes',
'SA': 'Saurisserie',
'PL': 'Publicié',
'10': 'Beurre, oeufs, fromage',
'20': 'Elaborés',
'30': 'Garnitures et fruits',
'40': 'Produits carnés',
'50': 'Produits de la mer',
'60': 'Consommables',
'70': 'Emballage',
'80': 'Publicité sur le lieu de vente',
'83': 'Epicerie',
'85': 'Liquides',
'87': 'Hygiène et entretien',
'90': 'Services',
'92': 'Fruits',
'94': 'Légumes',
'96': 'Produits de la mer Frais',
'98': 'Fleurs - plantes',
}

```

```
[6]: df.loc[[5000, 90000, 100000, 130000, 110000], :]
```

	material	branch	plant	type	designation	del_mand	del_plant	\
5000	15712	2	2PES	ZNEG	PSVNX CERN BRISURE S/AZ SAC 1KGX12 CERNO	True	True	
90000	153086	3	3PTA	ZNEG	MANGUE KENT 351/550G PAD 12F DELIC BR°	False	False	
100000	165387	1	1PPF	ZNEG	SALADE PLT 1KGX12 HAMAL	False	False	
130000	203582	1	1PPF	ZPRE	EFFILOCHE BOEUF BARBACOA (2KGX6)/12KG CS	False	False	
110000	177238	2	2PES	ZNEG	COMP POIRE ALL BIO BTE 5/1X3 STM	False	False	
					hier hier1			
5000	ZEPI		EP	832020500505	83			
90000	ZFLF		FL	920518010405	92			
100000	ZFRAIS		FR	202520150505	20			
130000	ZSURGE		SU	401015051505	40			
110000	ZEPI		EP	832005451505	83			

On va définir deux masques, permettant de filtrer : - les articles actifs (i.e. non supprimé niveau mandant ni branche) - les articles actifs de marchandises (i.e. qui ne sont pas des articles "spéciaux")

```
[7]: active_mask = ~df.del_mand & ~df.del_plant
active_march_mask = active_mask & df.type.isin(['ZNEG', 'ZPRE'])
```

On peut calculer la volumétrie d'articles et la représenter comme un histogramme. Les données de Délice et Création et Saveurs d'Antoine sont issue d'estimations fournies par le métier.

```
[8]: counts = df.groupby('plant')['material'].count().rename('Total')
filtered_counts = df[active_mask].groupby('plant')['material'].count().rename('Actifs')
filtered_counts2 = df[active_march_mask].groupby('plant')['material'].count().rename('Marchandises')

report = pd.concat([counts, filtered_counts, filtered_counts2], axis=1)
report.loc['Délice et Création', :] = [10000, np.nan, np.nan]
report.loc['Saveurs d\'Antoine', :] = [12000, np.nan, np.nan]
report.rename({'1PPF': 'PassionFroid'},
```

```

        '2PES': 'EpiSaveurs',
        '3PTA': 'TerreAzur'},
    inplace=True)
report.index.rename('Branche', inplace=True)
report = report.astype('Int64')
report.to_latex(Path(..) / 'tbls' / 'Articles par branche.tex',
    bold_rows=True,
    column_format='lccc',
    na_rep='_'
)

```

report

[8]:


Branche	Total	Actifs	Marchandises
PassionFroid	48478	24898	24554
EpiSaveurs	22498	12798	12241
TerreAzur	73804	62789	62710
Délice et Création	10000	Nan	Nan
Saveurs d'Antoine	12000	Nan	Nan

[9]:

```

fig, ax = plt.subplots(figsize=(5,3))
report.plot(kind='bar', ax=ax)
ax.set_title('Nombre d\'articles par branche')
ax.set_xlabel('')
fig.savefig(Path(..) / 'img' / 'Articles par branche.png', bbox_inches='tight')

```



On peut également construire le diagramme de Venn des articles pour les branches RHD :

[10]:

```

# Filtering the dataset with active materials, and active merchandize materials
branch_sets = [set(df.loc[df.plant == branch_, 'material']) for branch_ in ['1PPF', '2PES', '3PTA']]
filtered_df = df.loc[active_mask]

```

```

filtered_sets = [set(filtered_df.loc[filtered_df.plant == branch_, 'material']) for branch_ in ['1PPF', '2PES', '3PTA']]

filtered_march_df = df.loc[active_march_mask]
filtered_march_sets = [set(filtered_march_df.loc[filtered_march_df.plant == branch_, 'material'])
                      for branch_ in ['1PPF', '2PES', '3PTA']]

```

```

[11]: # This function is used to add label on Venn diagrams axes without showing spines
# (matplotlib-venn disables totally axis's, and spines need to get erased after
# axis's reactivation)
def labelize(ax, label, where='bottom', **kwargs):
    ax.set_axis_on()
    for spine in ['top', 'bottom', 'left', 'right']:
        ax.spines[spine].set_visible(False)
    if where == 'bottom':
        ax.set_xlabel(label, **kwargs)
    elif where == 'left':
        ax.set_ylabel(label, **kwargs)
    else:
        raise ValueError(f"Unexpected 'where' argument: {where}")

```

```

[12]: # Construction of the diagrams
scope = ['Total', 'Actifs', 'Marchandises']
types = ['Non pondéré', 'Pondéré']
nrows, ncols = len(types), len(scope)

fig, axs = plt.subplots(nrows, ncols, sharex='col', sharey='row', figsize=(18, 8))


for col, source_df in enumerate([branch_sets, filtered_sets, filtered_march_sets]):
    for row, venn_kind in enumerate([venn3_unweighted, venn3]):
        venn_kind(source_df, set_labels=['PassionFroid', 'EpiSaveurs', 'TerreAzur'], ax=axs[row, col])
        if col == 0:
            labelize(axs[row, col], types[row], where='left', fontsize=18, labelpad=10)
        if row == 1:
            labelize(axs[row, col], scope[col], where='bottom', fontsize=18, labelpad=40)

# Adjusting the min and max of axes lims, as they are not the same by default
xmin = min([axs[row][col].get_xlim()[0] for row in range(nrows) for col in range(ncols)])
xmax = max([axs[row][col].get_xlim()[1] for row in range(nrows) for col in range(ncols)])
ymin = min([axs[row][col].get_ylim()[0] for row in range(nrows) for col in range(ncols)])
ymax = max([axs[row][col].get_ylim()[1] for row in range(nrows) for col in range(ncols)]) + 0.1

for row in range(nrows):
    for col in range(ncols):
        axs[row, col].set_xlim(xmin, xmax)
        axs[row, col].set_ylim(ymin, ymax)

# Saving the file to disk so that it is included in the report
fig.savefig(Path('..') / 'img' / 'Diagrammes de Venn articles.png', bbox_inches='tight')

```



On peut constater que les articles utilisés par les 3 branches RHD sont des articles "spéciaux".

```
[13]: df[df.material.isin(df.material.value_counts()[df.material.value_counts() >= 3].index)]
```

```
[13]:      material branch plant type designation del_mand \
144564    DECOMPTE     1   2PES ZSER ARTICLE DE DECOMPTE CONDITIONS ARRIERES False
144565    DECOMPTE     1   3PTA ZSER ARTICLE DE DECOMPTE CONDITIONS ARRIERES False
144566    DECOMPTE     1   1PPF ZSER ARTICLE DE DECOMPTE CONDITIONS ARRIERES False
144612    FC41849      1   1PPF ZSER RÉGUL SURFACTURATION DÉCONDITIONNEMENT False
144613    FC41849      1   2PES ZSER RÉGUL SURFACTURATION DÉCONDITIONNEMENT False
144614    FC41849      1   3PTA ZSER RÉGUL SURFACTURATION DÉCONDITIONNEMENT False
144642    LOT_ENGT     1   1PPF ZENG LOT ENGAGEMENT False
144643    LOT_ENGT     1   3PTA ZENG LOT ENGAGEMENT False
144644    LOT_ENGT     1   2PES ZENG LOT ENGAGEMENT False
144719 S_PALETTE_PERDUE 3   3PTA ZEMB PALETTE 80X120 PERDUE False
144720 S_PALETTE_PERDUE 3   2PES ZEMB PALETTE 80X120 PERDUE False
144721 S_PALETTE_PERDUE 3   1PPF ZEMB PALETTE 80X120 PERDUE False

      del_plan march_group storage_cond      hier hier1
144564    False    ZAUTRE       NaN 900505050505    90
144565    False    ZAUTRE       NaN 900505050505    90
144566    False    ZAUTRE       NaN 900505050505    90
144612    False    ZAUTRE       NaN 900505050505    90
144613    False    ZAUTRE       NaN 900505050505    90
144614    False    ZAUTRE       NaN 900505050505    90
144642    False        NaN       NaN       NaN       NaN
144643    False        NaN       NaN       NaN       NaN
144644    False        NaN       NaN       NaN       NaN
144719    False    ZAUTRE       NaN 700510050505    70
144720    False    ZAUTRE       NaN 700510050505    70
144721    False    ZAUTRE       NaN 700510050505    70
```

On peut ensuite essayer de représenter les comptages d'articles sur les diverses variables catégorielles.

```
[14]: # Definition of feature and order to show
features = {'type': None,
            'march_group': ['ZFRAIS', 'ZSURGE', 'ZEPI', 'ZHYG', 'ZBOI', 'ZFLF', 'ZPMF', 'ZELAB', 'ZFP'],
            'storage_cond': ['FR', 'SU', 'EP', 'HY', 'FL', 'MA', 'SA', 'FP', 'PL'],
            'hier1': None,
            }
```

```
# Definition of color palette
palette = {'1PPF': c_passionfroid,
           '2PES': c_episaveurs,
           '3PTA': c_terreazur,
          }
```

```
[15]: fig, axs = plt.subplots(nrows=len(features), ncols=2, figsize=(13, 15))
# for each feature, draw counts without and with hue
for idx, (feature, order) in enumerate(features.items()):
    # drawing without hue
    sns.countplot(data=df.loc[active_march_mask],
                  x=feature,
                  order=order,
                  ax=axs[idx][0],
                  color=c_pomona)
    # remove y label, and set x label to full length text
    axs[idx][0].set_ylabel('')
    axs[idx][0].set_xlabel(lab[feature], fontsize=16)
    # drawing with hue
    sns.countplot(data=df.loc[active_march_mask],
                  x=feature,
                  hue='plant',
                  order=order,
                  palette=palette,
                  ax=axs[idx][1],
                  )
    # remove y label, and set x label to full length text
    axs[idx][1].set_ylabel('')
    axs[idx][1].set_xlabel(lab[feature], fontsize=16)
    # hide legend for each axis
    axs[idx][1].legend().set_visible(False)


    # redraw legend for the whole figure, above, centered and
    # expanded
    handles, labels = axs[3][1].get_legend_handles_labels()
    fig.legend(handles,
               [lab[label] for label in labels],
               ncol=len(handles),
               title='Branches',
               loc='center',
               bbox_to_anchor=(0, 1, 1, 0.25),
               bbox_transform=axs[0][1].transAxes,
               # mode='expand',
               )

    # adding a title
    fig.suptitle('Répartition des articles selon les features catégorielles',
                 fontsize=24,
                 y=1.025,
                 va='bottom',
                 )

    # adding padding between plots
    fig.tight_layout(pad=3.0)

    # saving to disk
    fig.savefig(Path('..') / 'img' / 'Repartition articles categories.png', bbox_inches='tight')
```

Répartition des articles selon les features catégorielles



```
[24]: def long_lab(label):
    if label in lab:
        return(label + ' - ' + lab[label])
    else:
        return(label)

for feature in features.keys():
    # Construct the pivot table for the feature
```

```

piv = pd.pivot_table(df.loc[active_march_mask],
                     columns='plant',
                     index=feature,
                     values='material',
                     aggfunc='count',
                     fill_value=0,
                     )
# Add a 'Total' column
piv['Total'] = piv['1PPF'] + piv['2PES'] + piv['3PTA']

# Changing 0s to '-'
piv = piv.replace(0, '-')

# Reorder indices so that they follow the order defined in
# lab dictionary
if np.all(piv.index.isin(lab.keys())): # check to avoid filtering piv!
    piv = piv.reindex([key for key in lab.keys() if key in piv.index])

# Rename indices, columns and axes for pretty printing
piv = (piv.rename(long_lab, axis=0)
       .rename(lab, axis=1)
       .rename_axis(lab[feature])
       .rename_axis('Branche', axis=1))
print(piv)
print('-----')
# Save to LaTeX format to be included in report
piv.to_latex(Path('..') / 'tbls' / ('Repartition par ' + feature + '.tex'),
             bold_rows=True,
             column_format='lcccc',
             na_rep='-', )
)

```

Branche	PassionFroid	EpiSaveurs	TerreAzur	Total
Type de produit				
ZNEG - Article de négoce	17166	11048	61273	89487
ZPRE - Article de prestation	7388	1193	1437	10018

Branche	PassionFroid	EpiSaveurs	TerreAzur	Total
Groupe de marchandises				
ZSURGE - Surgelés	7756	-	-	7756
ZFRAIS - Frais	13785	6	4	13795
ZEPI - Epicerie	2298	8305	-	10603
ZBOI - Boissons	126	826	-	952
ZHYG - Hygiène	350	3078	-	3428
ZFLF - Fruits et Légumes	4	-	44133	44137
ZPMF - Produits de la mer	142	-	11594	11736
ZELAB - Produits élaborés	91	-	6644	6735
ZFP - Fleurs et plantes	-	-	297	297
ZAUTRE - Autres	2	26	38	66

Branche	PassionFroid	EpiSaveurs	TerreAzur	Total
Condition de stockage				
SU - Surgelés	7758	-	-	7758
FR - Frais	13781	6	3	13790
EP - Epicerie	2430	9155	-	11585
HY - Hygiène	344	3080	-	3424
FL - Fruits et légumes	78	-	49508	49586
MA - Marée	126	-	10501	10627
FP - Fleurs et plantes	-	-	286	286
SA - Saurisserie	34	-	2408	2442
PL - Publicié	2	-	1	3

Branche	PassionFroid	EpiSaveurs	TerreAzur	Total
Niveau 1 hiérarchie produit				
10 - Beurre, oeufs, fromage	3010	6	1	3017
20 - Elaborés	4150	2	6	4158
30 - Garnitures et fruits	1701	-	-	1701

40 - Produits carnés	11413	-	-	11413
50 - Produits de la mer	1214	-	2	1216
60 - Consommables	1	-	-	1
70 - Emballage	-	1	-	1
80 - Publicité sur le lieu de vente	34	25	37	96
83 - Epicerie	2306	8296	-	10602
85 - Liquides	135	836	-	971
87 - Hygiène et entretien	348	3075	-	3423
90 - Services	10	-	-	10
92 - Fruits	35	-	26543	26578
94 - Légumes	37	-	22929	22966
96 - Produits de la mer Frais	160	-	12891	13051
98 - Fleurs - plantes	-	-	301	301

Analyse données du PIM

Pierre MASSÉ

May 12, 2020

1 Analyse des données du PIM

1.1 Extraction des données

1.1.1 Préambule technique

```
[1]: # setting up sys.path for relative imports
from pathlib import Path
import sys
project_root = str(Path(sys.path[0]).parents[1].absolute())
if project_root not in sys.path:
    sys.path.append(project_root)
```

```
[2]: # imports and customization of display
import io
import pandas as pd
pd.options.display.min_rows = 6
pd.options.display.width=108
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.ticker as ticker
import matplotlib.patches as mpatch

from src.pimapi import Requester
```

1.1.2 Récupération des données

Le requêtage des données dans le PIM s'appuie sur la classe `Requester` du module `pimapi`.

```
[3]: requester = Requester('prd')
# Let's fetch the full content of PIM system
requester.fetch_all_from_PIM()
requester.result
```

Done

```
[3]: [<Response [200]>,
<Response [200]>]
```

A ce stade, les données sont chargées en mémoire sous la forme de fichiers JSON. La conversion des données récupérées par l'API se fait via la méthode `result_to_dataframe` de la classe `Requester`.

```
[4]: df = requester.result_to_dataframe()
df.head(4)
```

```
[4]:          entity-type repository \
uid
afee12c7-177e-4a68-9539-8cbb68442503    document    default
7d390121-17e8-43bf-a357-9d06b79d2d47    document    default
f234cd84-c8f6-433f-85ec-6e0b6980adc6    document    default
e82a8173-b379-41ac-b319-aa058a04fcfb    document    default

                                         path      type \
uid
afee12c7-177e-4a68-9539-8cbb68442503 /default-domain/pomSupplierWorkspace/SICO/DEST... pomProduct
7d390121-17e8-43bf-a357-9d06b79d2d47 /default-domain/pomSupplierWorkspace/UNILEVER_... pomProduct
f234cd84-c8f6-433f-85ec-6e0b6980adc6 /default-domain/pomSupplierWorkspace/AZTECA_FO... pomProduct
e82a8173-b379-41ac-b319-aa058a04fcfb /default-domain/pomSupplierWorkspace/UVCDR_-... pomProduct

                                         state \
uid
afee12c7-177e-4a68-9539-8cbb68442503 product.waiting.supplier.validation
7d390121-17e8-43bf-a357-9d06b79d2d47 product.waiting.supplier.validation
f234cd84-c8f6-433f-85ec-6e0b6980adc6 product.waiting.supplier.validation
e82a8173-b379-41ac-b319-aa058a04fcfb     product.waiting.sending.supplier

                                         parentRef  isCheckedOut  isVersion \
uid
afee12c7-177e-4a68-9539-8cbb68442503 a58845c0-cab3-492f-b48d-531f146c3777    True    False
7d390121-17e8-43bf-a357-9d06b79d2d47 a37abc27-f485-4ae9-921b-f761f16c8c1c    False   False
f234cd84-c8f6-433f-85ec-6e0b6980adc6 3ff7819a-a392-493f-beb8-0b323ac331c7    True    False
e82a8173-b379-41ac-b319-aa058a04fcfb  e4b5167c-ece2-4f7a-83c1-fb884034a1bf    False   False

                                         isProxy changeToken ... properties.pprodq:visualPhoto.length \
uid
afee12c7-177e-4a68-9539-8cbb68442503    False        17-0 ...                      ...
7d390121-17e8-43bf-a357-9d06b79d2d47    False        15-0 ...                      ...
f234cd84-c8f6-433f-85ec-6e0b6980adc6    False        33-0 ...                      ...
e82a8173-b379-41ac-b319-aa058a04fcfb    False        20-0 ...                      ...

                                         properties.pprodq:visualPhoto.data \
uid
afee12c7-177e-4a68-9539-8cbb68442503                               NaN
7d390121-17e8-43bf-a357-9d06b79d2d47                               NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6                               NaN
e82a8173-b379-41ac-b319-aa058a04fcfb                               NaN

                                         properties.pprodqmdd:secondaryPackagingPhoto.name \
uid
afee12c7-177e-4a68-9539-8cbb68442503                               NaN
7d390121-17e8-43bf-a357-9d06b79d2d47                               NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6                               NaN
e82a8173-b379-41ac-b319-aa058a04fcfb                               NaN

                                         properties.pprodqmdd:secondaryPackagingPhoto.mime-type \
uid
afee12c7-177e-4a68-9539-8cbb68442503                               NaN
7d390121-17e8-43bf-a357-9d06b79d2d47                               NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6                               NaN
e82a8173-b379-41ac-b319-aa058a04fcfb                               NaN

                                         properties.pprodqmdd:secondaryPackagingPhoto.encoding \
uid
afee12c7-177e-4a68-9539-8cbb68442503                               NaN
7d390121-17e8-43bf-a357-9d06b79d2d47                               NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6                               NaN
e82a8173-b379-41ac-b319-aa058a04fcfb                               NaN
```

```

e82a8173-b379-41ac-b319-aa058a04fcfb           NaN
                                                 properties.pprodqmdd:secondaryPackagingPhoto.digestAlgorithm \
uid                                              NaN
afee12c7-177e-4a68-9539-8cbb68442503          NaN
7d390121-17e8-43bf-a357-9d06b79d2d47          NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6          NaN
e82a8173-b379-41ac-b319-aa058a04fcfb           NaN
                                                 properties.pprodqmdd:secondaryPackagingPhoto.digest \
uid                                              NaN
afee12c7-177e-4a68-9539-8cbb68442503          NaN
7d390121-17e8-43bf-a357-9d06b79d2d47          NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6          NaN
e82a8173-b379-41ac-b319-aa058a04fcfb           NaN
                                                 properties.pprodqmdd:secondaryPackagingPhoto.length \
uid                                              NaN
afee12c7-177e-4a68-9539-8cbb68442503          NaN
7d390121-17e8-43bf-a357-9d06b79d2d47          NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6          NaN
e82a8173-b379-41ac-b319-aa058a04fcfb           NaN
                                                 properties.pprodqmdd:secondaryPackagingPhoto.data \
uid                                              NaN
afee12c7-177e-4a68-9539-8cbb68442503          NaN
7d390121-17e8-43bf-a357-9d06b79d2d47          NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6          NaN
e82a8173-b379-41ac-b319-aa058a04fcfb           NaN
                                                 properties.notif:notifications
uid                                              NaN
afee12c7-177e-4a68-9539-8cbb68442503          NaN
7d390121-17e8-43bf-a357-9d06b79d2d47          NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6          NaN
e82a8173-b379-41ac-b319-aa058a04fcfb           NaN
[4 rows x 487 columns]

```

1.2 Définitions pour les mises en formes

1.2.1 Descriptifs longs

On définit un dictionnaire permettant de “traduire” les codes de champs en libellés long.

```
[6]: lab = {
    'code': 'Code produit',
    'supplier': 'Code fournisseur',
    'type': 'Type de produit',
    'GTIN': 'GTIN',
    'base_unit': 'Unité de base',
    'net_weight': 'Poids net',
    'gross_weight': 'Poids brut',
    'dry_weight': 'Poids net égoutté',
    'volume': 'Volume',
    'total_life': 'Durée de vie totale',
    'remaining_life': 'Durée minimale restante',
    'type_cons': 'Type de conservation',
    'before_open': 'Conservation avant ouv.',
    'after_open': 'Conservation après ouv.',
    'cons_temp': 'Température',
    'temp_des': 'Libellé temporaire',
    'supplier_des': 'Désignation produit fournisseur',
    'supplier_code': 'Code interne fournisseur',
    'brand': 'Marque commerciale',
    'regulatory_des': 'Dénomination réglementaire',
    'properties.pprodः:supplierDesignation': 'Désignation produit fournisseur',
```

```
        'properties.pprodः:ingredientsList': "Liste d'ingrédients",
    }
```

1.2.2 Champs intéressants

On liste également les champs intéressants pour un affichage plus court du dataframe.

```
[7]: def_fields = {'properties.vig:code': 'code',
                  'properties.psec:supplierCode': 'supplier',
                  'properties.pprodः:typeOfProduct': 'type',
                  'properties.pprodः:gtin': 'gtin',
                  'properties.pprodः:supplierDesignation': 'designation'}
```

1.3 Description des attributs des produit

1.3.1 Volumétrie des attributs

On constate que chaque produit porte un très grand nombre d'attributs :

```
[8]: print('Count of columns in df:', len(df.columns))
print('\nInfo of df:')
df.info()
```

Count of columns in df: 487

```
Info of df:
<class 'pandas.core.frame.DataFrame'>
Index: 13235 entries, afree12c7-177e-4a68-9539-8cbb68442503 to 6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a
Columns: 487 entries, entity-type to properties.notif:notifications
dtypes: bool(12), float64(60), int64(2), object(413)
memory usage: 48.2+ MB
```

De plus, de par la nature hiérarchique du format JSON, certains attributs dits “multivalués” sont parfois stockés sous forme de liste dans le dataframe “à plat”. Par exemple, on peut voir que le pays de transformation, ou les facettes, peuvent être multivalués.

```
[9]: df.loc[['609af223-2f14-4f83-a553-cef276f2eca7',
            'c94013e4-0dca-441a-85c1-0b29ecb54d0a',
            '82d1af25-2bdd-4315-9670-67784b70dfa7'],
           ['properties.pprodः:transfoCountries',
            'facets']]
```

```
[9]: properties.pprodः:transfoCountries \
      uid
      609af223-2f14-4f83-a553-cef276f2eca7 [PL, FR, ES]
      c94013e4-0dca-441a-85c1-0b29ecb54d0a [DE, NO, BE, RU, CH, BG, LT, GR, FR, UA, HU, E...
      82d1af25-2bdd-4315-9670-67784b70dfa7 [FR]

      facets
      uid
      609af223-2f14-4f83-a553-cef276f2eca7 [Versionable, Folderish, Commentable, beginnin...
      c94013e4-0dca-441a-85c1-0b29ecb54d0a [endMigration, Versionable, Folderish, Comment...
      82d1af25-2bdd-4315-9670-67784b70dfa7 [endMigration, Versionable, Folderish, Comment...
```

De plus, certains attributs sont dits “complexes”, car chacune des valeurs de la liste est elle-même un dictionnaire d'attribut. La combinaison des deux, des attributs “complexes multivalués” existe également. On a alors une liste de dictionnaires. On peut comme ceci imbriquer des niveaux jusqu'à n'importe quelle profondeur.

C'est par exemple le cas des labels qui sont multivalués (un produit peut porter plusieurs labels), qui sont des complexes portant : - le type de label (bio, Label Rouge, ...) - la date de fin de validité du label (si applicable) - le fichier de certification du label (si applicable), qui est lui-même un complexe...

```
[10]: multilabel_ds = df.loc[df['properties.pprodः:labels'].apply(len) > 1, 'properties.pprodः:labels']
for uid, label_list in multilabel_ds.head(3).iteritems():
    print('product uid:', uid)
    for cpt, label in enumerate(label_list):
```

```

print('\n\tlabel', cpt + 1, ':')
for key, val in label.items():
    print('\t\t', key, ':', val)
print('-----')

```

product uid: 362e6230-ba3a-4396-8a47-728b0a1d56db

label 1 :

- labelCertificateEndDate : 2024-12-30T23:00:00.000Z
- typeOfLabel : 80
- labelCertificateFile : {'name': 'KCC Coleshill Tissue Paper Ecolabel Renewal Certificate Mar 2020.pdf', 'mime-type': 'application/pdf', 'encoding': None, 'digestAlgorithm': 'MD5', 'digest': '6615e3027ff2e014fdc3fa37e67851bb', 'length': '425662', 'data': 'https://produits.groupe-pomona.fr/nuxeo/nxfile/default/362e6230-ba3a-4396-8a47-728b0a1d56db/pprod1:labels/0/labelCertificateFile/KCC%20Coleshill%20Tissue%20Paper%20Ecolabel%20Renewal%20Certificate%20Mar%202020.pdf?changeToken=45-0'}

label 2 :

- labelCertificateEndDate : 2022-09-16T22:00:00.000Z
- typeOfLabel : NA
- labelCertificateFile : {'name': 'FCC_DoC_Coleshill Mill_PW_blue_Ref13351_Eng V01.pdf', 'mime-type': 'application/pdf', 'encoding': None, 'digestAlgorithm': 'MD5', 'digest': '78cfcc67b8bf0f693e060088f7d97c48', 'length': '84473', 'data': 'https://produits.groupe-pomona.fr/nuxeo/nxfile/default/362e6230-ba3a-4396-8a47-728b0a1d56db/pprod1:labels/1/labelCertificateFile/FCC_DoC_Coleshill%20Mill_PW_blue_Ref13351_Eng%20V01.pdf?changeToken=45-0'}

product uid: 1b79f14f-7db4-40e2-a590-da271f43b65b

label 1 :

- labelCertificateEndDate : None
- typeOfLabel : 20
- labelCertificateFile : None

label 2 :

- labelCertificateEndDate : 2020-12-30T23:00:00.000Z
- typeOfLabel : 70
- labelCertificateFile : {'name': 'MDCV CERTIFICAT BIO 2019-16-027-83-08 (1).pdf', 'mime-type': 'application/pdf', 'encoding': None, 'digestAlgorithm': 'MD5', 'digest': '54c40f9a5102d03ff70ffb476f52632', 'length': '129476', 'data': 'https://produits.groupe-pomona.fr/nuxeo/nxfile/default/1b79f14f-7db4-40e2-a590-da271f43b65b/pprod1:labels/1/labelCertificateFile/MDCV%20%20CERTIFICAT%20BIO%202019-16-027-83-08%20(1).pdf?changeToken=192-0'}

product uid: 84f6684c-9a4a-4e51-8933-d1bf86ed310a

label 1 :

- labelCertificateEndDate : 2024-10-09T22:00:00.000Z
- typeOfLabel : 120
- labelCertificateFile : {'name': 'Cerrrtificat FSC.pdf', 'mime-type': 'application/pdf', 'encoding': None, 'digestAlgorithm': 'MD5', 'digest': 'eb8153d207c052ee31e01207231d22aa', 'length': '133043', 'data': 'https://produits.groupe-pomona.fr/nuxeo/nxfile/default/84f6684c-9a4a-4e51-8933-d1bf86ed310a/pprod1:labels/0/labelCertificateFile/Cerrrtificat%20FSC.pdf?changeToken=73-0'}

label 2 :

- labelCertificateEndDate : 2019-12-30T23:00:00.000Z
- typeOfLabel : 80
- labelCertificateFile : {'name': 'Certificat Ecolabel 2019.pdf', 'mime-type': 'application/pdf', 'encoding': None, 'digestAlgorithm': 'MD5', 'digest': '213ad130b48693d8b2c7a6478105eecd', 'length': '215427', 'data': 'https://produits.groupe-pomona.fr/nuxeo/nxfile/default/84f6684c-9a4a-4e51-8933-d1bf86ed310a/pprod1:labels/1/labelCertificateFile/Certificat%20Ecolabel%202019.pdf?changeToken=73-0'}

1.3.2 Description des principaux attributs

On commence par déclarer des utilitaires permettant de mettre en forme les représentations.

```
[11]: # Defining main data to explore
mappings = {
    'identification': {
```

```

'properties.vig:code': 'code',
'properties.psec:supplierCode': 'supplier',
'properties.pprodtop:typeOfProduct': 'type',
'properties.pprodःgtin': 'GTIN',
},
'dimensions': {
    'properties.pprodःbaseUnit': 'base_unit',
    'properties.pprodःnetWeight': 'net_weight',
    'properties.pprodःgrossWeight': 'gross_weight',
    'properties.pprodःdryWeight': 'dry_weight',
    'properties.pprodःvolume': 'volume',
},
'conservation': {
    'properties.pprodःtotalLife': 'total_life',
    'properties.pprodःguaranteedLife': 'remaining_life',
    'properties.pprodःtypeOfConservation': 'type_cons',
    'properties.pprodःconservationBeforeOpening': 'before_open',
    'properties.pprodःconservationAfterOpening': 'after_open',
    'properties.pprodःconservationTemperature': 'cons_temp',
},
'designation': {
    'properties.pprodःtemporaryUnitLabel': 'temp_des',
    'properties.pprodःsupplierDesignation': 'supplier_des',
    'properties.pprodःinternalSupplierProductCode': 'supplier_code',
    'properties.pprodःsupplierCommercialBrand': 'brand',
    'properties.pprodःregulatoryName': 'regulatory_des',
}
}

# Helper function to transform pandas `to_latex` method output to a tabularx env instead.
def to_tabularx(stringio):
    text = StringIO.getvalue()
    text = text.replace(r'\begin{tabular}', r'\begin{tabularx}{\linewidth}')
    text = text.replace(r'\end{tabular}', r'\end{tabularx}')
    return(text)

# Function that saves dataframe as Latex tabularx files as input
def save_to_disk(df, path, lab=lab, tex_label=None):
    text = io.StringIO()
    c_format = 'l' + 'X' * len(df.columns)
    (df.rename(lab, axis=1)
     .to_latex(text,
                bold_rows=True,
                column_format=c_format,
                na_rep='-' ,
                label=tex_label,
                ))
    with open(path, mode='w') as file:
        file.write(to_tabularx(text))

```

1.3.3 Analyses spécifiques : Statuts

On commence par s'intéresser aux différents statuts des produits. On commence récupérer certaines valeurs de facettes intéressantes : - “beginningMigration”: elle signifie que le produit a été repris du système historique (le GIP) - “endMigration”: elle signifie que le produit qui a été créé par reprise fait l'objet d'un processus complet de récupération des données et de contrôle par Pomona

```
[12]: df['begin_mig'] = df['facets'].apply(lambda x: 'beginningMigration' in x)
df['end_mig'] = df['facets'].apply(lambda x: 'endMigration' in x)
print(
(df.loc[:, ['begin_mig', 'end_mig']]
 .reset_index()
 .pivot_table(values='uid',
              index=['begin_mig'],
              aggfunc='count',
              columns='end_mig',
              fill_value=0,
```

```

        )
    .rename({True: 'Créé au démarrage', False: 'Créé après le démarrage'}, axis=0)
    .rename({True: 'Facette fin de migration : Oui', False: 'Facette fin de migration : Non'}, axis=1)
)
)

(df.loc[:, ['begin_mig', 'end_mig']]
.reset_index()
.pivot_table(values='uid',
            index=['begin_mig'],
            aggfunc='count',
            columns='end_mig',
            fill_value=0,
            )
.rename({True: 'Créé au démarrage', False: 'Créé après le démarrage'}, axis=0)
.rename({True: 'Facette fin de migration : Oui', False: 'Facette fin de migration : Non'}, axis=1)
).to_latex(
    Path('..') / 'tbls' / 'migration_status.tex',
    index_names=False,
    column_format='lcc',
    bold_rows=True,
)
)

```

	Facette fin de migration : Non	Facette fin de migration : Oui
begin_mig		
Créé après le démarrage	1680	0
Créé au démarrage	7210	4345


On peut également voir les statuts courants des produits dans le PIM.

```
[13]: print(df['state'].value_counts())
df['state'].value_counts().to_frame().to_latex(
    Path('..') / 'tbls' / 'products_status.tex',
    column_format = 'lc',
    bold_rows=True,
)
```

product.validate	6162
product.waiting.supplier.validation	4833
product.waiting.pomona.validation.niv3	968
product.correct	653
product.controlAnoMinor	246
product.waiting.sending.supplier	195
product.controlQualityInProgress	84
product.controlWaitingPomonaValidation	32
product.waiting.pomona.validation.niv2	28
product.waiting.pomona.validation	18
product.inactive	12
product.validate.reserve	3
product.controlAnoMajor	1
Name: state, dtype: int64	

```
[14]: fig, ax = plt.subplots(figsize=(8,5))
color = ['orange'] * len(df['state'].value_counts())
color[-1] = 'g'
incorrect_data = mpatch.Patch(color='orange', label='Données non validées')
correct_data = mpatch.Patch(color='g', label='Données validées')
df['state'].value_counts().sort_values().plot.bart(ax=ax, color=color)
fig.suptitle('Répartition des produits en fonction de leurs statuts',
             fontsize=16)
ax.legend(handles=[correct_data, incorrect_data])
fig.savefig(Path('..') / 'img' / 'products_status.png', bbox_inches='tight')
```

Répartition des produits en fonction de leurs statuts



On calcule un statut spécifique à la validité des données en combinant le statut de migration et le statut du produit.

```
[15]: migration_mask = df.loc[:, 'end_mig'] | ~df.loc[:, 'begin_mig']
status_mask = (df.loc[:, 'state'] == 'product.validate')
df['data_ok'] = migration_mask & status_mask
```

```
[16]: cur_df = (df.loc[:, 'data_ok']
              .value_counts()
              .rename({False: 'Hors qualité', True: 'En qualité'})
              .rename('Répartition produit par qualité')
              .to_frame()
            )

print(cur_df)

cur_df.to_latex(Path('..') / 'tbls' / 'products_quality.tex',
                bold_rows=True,
                column_format='lc',
                na_rep='-', 
                index=True,
                index_names=True,
```

Répartition produit par qualité	
Hors qualité	8722
En qualité	4513

```
[17]: (df.groupby('data_ok')
      [['properties.pprodq:conservationBeforeOpening',
        'properties.pprodg:guaranteedLife']]
      .describe(include='all')
      .stack()
    )
```

	properties.pprodq:conservationBeforeOpening	properties.pprodg:guaranteedLife
data_ok		
False	count	6369
	unique	7
	top	ambientTemperature
	freq	5731
		6068.000000
		NaN
		NaN
		NaN

	mean	NaN	345.489288
	std	NaN	371.169490
	min	NaN	0.000000
	25%	NaN	160.000000
	50%	NaN	270.000000
	75%	NaN	480.000000
	max	NaN	9999.000000
True	count	3614	3408.000000
	unique	7	NaN
	top	ambientTemperature	NaN
	freq	2532	NaN
	mean	NaN	362.071009
	std	NaN	395.675769
	min	NaN	0.000000
	25%	NaN	180.000000
	50%	NaN	360.000000
	75%	NaN	480.000000
	max	NaN	9999.000000

1.3.4 Exports des exemples et des descriptions des données structurées

On boucle sur les différents mappings, et on les sauvegarde dans des tableaux latex pour intégration au rapport.

```
[18]: df_dict = dict()

for map_type, mapping in mappings.items():
    cur_df = df.loc[:, list(mapping.keys()) + ['data_ok']].rename(mapping, axis=1).fillna(np.nan)
    df_dict[map_type] = cur_df.copy()
    desc = cur_df.groupby('data_ok').describe(include='all').stack()
    samp = cur_df.sample(n=5, random_state=42)
    print(map_type)
    print(samp.rename(lab, axis=1))
    print('-----')
    print(desc.rename(lab, axis=1)
          .round(3))
    )
print('-----')

# Writing dataframes to .tex files
text = io.StringIO()
c_format = 'l' + 'X' * len(cur_df.columns)
(samp.rename(lab, axis=1)
 .to_latex(text,
            bold_rows=True,
            column_format=c_format,
            na_rep='-' ))
with open(Path('..') / 'tbls' / ('Exemple ' + map_type + '.tex'), mode='w') as file:
    file.write(to_tabularx(text))

text = io.StringIO()
(desc.rename(lab, axis=1)
 .rename({False: 'Hors qualité', True: 'En qualité'})
 .round(3)
 .to_latex(text,
            bold_rows=True,
            column_format=c_format,
            na_rep='-' ,
            #index_names=False,
            multirow=True,
            )))
with open(Path('..') / 'tbls' / ('Desc ' + map_type + '.tex'), mode='w') as file:
    file.write(to_tabularx(text))
```

identification

Code produit	Code fournisseur	Type de produit	GTIN \
--------------	------------------	-----------------	--------

```

uid
e24f6685-40da-4fc8-8454-ec70282552be PIMP-0000009877 PIMF-0000000483 alcoholicDrink 3387210001261
a4e317c3-f8d6-441d-82fc-13f5288ba137 PIMP-0000013133 PIMF-0000000283 hygiene 3342690134229
729883ee-8d83-45a3-a7c7-015b22473ac9 PIMP-0000007508 PIMF-0000000378 grocery 3077317320227
4312cd74-4708-4216-a56e-fbc404c5afa0 PIMP-0000012015 PIMF-0000000596 grocery 3230140003938
2581a202-7737-448f-9e2d-eb5a02472101 PIMP-0000008730 PIMF-0000000311 nonAlcoholicDrink 5449000227089

data_ok
uid
e24f6685-40da-4fc8-8454-ec70282552be True
a4e317c3-f8d6-441d-82fc-13f5288ba137 False
729883ee-8d83-45a3-a7c7-015b22473ac9 True
4312cd74-4708-4216-a56e-fbc404c5afa0 True
2581a202-7737-448f-9e2d-eb5a02472101 True
-----
          Code produit Code fournisseur Type de produit GTIN
data_ok
False   count           8722           8722           8722  7663
        unique          8722           551             5  7445
        top    PIMP-0000008549 PIMF-0000000250      grocery
        freq            1            313           5755   67
True    count           4513           4513           4513  4382
        unique          4513           339             5  4062
        top    PIMP-0000008225 PIMF-0000000179      grocery
        freq            1            305           3007  285
-----
dimensions
                               Unité de base Poids net Poids brut Poids net égoutté Volume \
uid
e24f6685-40da-4fc8-8454-ec70282552be           BIB      5.00     5.300       NaN  5.0
a4e317c3-f8d6-441d-82fc-13f5288ba137           SAC     125.00     0.130       NaN  NaN
729883ee-8d83-45a3-a7c7-015b22473ac9           BT.      0.50     0.825       NaN  NaN
4312cd74-4708-4216-a56e-fbc404c5afa0           SEA     1.10     1.242       NaN  NaN
2581a202-7737-448f-9e2d-eb5a02472101           BT.      0.51     0.530       NaN  0.5

data_ok
uid
e24f6685-40da-4fc8-8454-ec70282552be True
a4e317c3-f8d6-441d-82fc-13f5288ba137 False
729883ee-8d83-45a3-a7c7-015b22473ac9 True
4312cd74-4708-4216-a56e-fbc404c5afa0 True
2581a202-7737-448f-9e2d-eb5a02472101 True
-----
                               Unité de base Poids net Poids brut Poids net égoutté Volume
data_ok
False   count           8722  8341.000  8341.000      728.000  866.000
        unique          29    NaN        NaN        NaN        NaN
        top    BTE      NaN        NaN        NaN        NaN
        freq            2260   NaN        NaN        NaN        NaN
        mean           NaN     3.616     3.304      1.567    5.330
        std             NaN    73.871    52.238      1.057   43.624
        min             NaN    0.000    0.000      0.000    0.000
        25%            NaN    0.500    0.550      0.500    0.500
        50%            NaN    1.000    1.149      1.600    0.900
        75%            NaN    3.000    3.368      2.458    4.124
        max             NaN   4900.000  4730.500      6.050  1000.000
True    count           4513  4513.000  4513.000     299.000  1053.000
        unique          26    NaN        NaN        NaN        NaN
        top    SAC      NaN        NaN        NaN        NaN
        freq            1075   NaN        NaN        NaN        NaN
        mean           NaN     2.174     2.394      1.246    9.810
        std             NaN    3.127    3.324      1.273   98.786
        min             NaN    0.000    0.000      0.000    0.000
        25%            NaN    0.440    0.514      0.350    0.500
        50%            NaN    1.000    1.070      0.560    0.975
        75%            NaN    3.000    3.120      2.210    2.000
        max             NaN   33.474   40.589     10.000  3100.000
-----
```

conservation					
	Durée de vie totale	Durée minimale restante	Type de conservation	\	
uid					
e24f6685-40da-4fc8-8454-ec70282552be		NaN	NaN		AM
a4e317c3-f8d6-441d-82fc-13f5288ba137		NaN	NaN		AM
729883ee-8d83-45a3-a7c7-015b22473ac9		NaN	NaN		AM
4312cd74-4708-4216-a56e-fbc404c5afa0	365.0	243.0			AM
2581a202-7737-448f-9e2d-eb5a02472101	180.0	120.0			AM

	Conservation avant ouv.	Conervation après ouv.	Température	data_ok	
uid					
e24f6685-40da-4fc8-8454-ec70282552be	coolAndDryPlace	coolAndDryPlace		NaN	True
a4e317c3-f8d6-441d-82fc-13f5288ba137		NaN		NaN	False
729883ee-8d83-45a3-a7c7-015b22473ac9	ambientTemperature	coolAndDryPlace		NaN	True
4312cd74-4708-4216-a56e-fbc404c5afa0	noConcerned	coldFor3Months		NaN	True
2581a202-7737-448f-9e2d-eb5a02472101	ambientTemperature	notConcerned		NaN	True

	Durée de vie totale	Durée minimale restante	Type de conservation	Conservation avant ouv.	\
data_ok					
False	count	5601.000	6068.000	8320	6369
	unique	NaN	NaN	2	7
	top	NaN	NaN	AM	ambientTemperature
	freq	NaN	NaN	8299	5731
	mean	650.149	345.489	NaN	NaN
	std	490.058	371.169	NaN	NaN
	min	0.000	0.000	NaN	NaN
	25%	360.000	160.000	NaN	NaN
	50%	540.000	270.000	NaN	NaN
	75%	900.000	480.000	NaN	NaN
	max	9999.000	9999.000	NaN	NaN
True	count	3342.000	3408.000	4513	3614
	unique	NaN	NaN	2	7
	top	NaN	NaN	AM	ambientTemperature
	freq	NaN	NaN	4500	2532
	mean	655.031	362.071	NaN	NaN
	std	482.709	395.676	NaN	NaN
	min	0.000	0.000	NaN	NaN
	25%	360.000	180.000	NaN	NaN
	50%	540.000	360.000	NaN	NaN
	75%	730.000	480.000	NaN	NaN
	max	9999.000	9999.000	NaN	NaN

	Conervation après ouv.				
data_ok	Température				
False	count	6348	8		
	unique	18	8		
	top	coolAndDryPlace	ambiente		
	freq	2781	1		
	mean	NaN	NaN		
	std	NaN	NaN		
	min	NaN	NaN		
	25%	NaN	NaN		
	50%	NaN	NaN		
	75%	NaN	NaN		
	max	NaN	NaN		
True	count	3607	13		
	unique	18	5		
	top	coolAndDryPlace	<10°C		
	freq	1733	5		
	mean	NaN	NaN		
	std	NaN	NaN		
	min	NaN	NaN		
	25%	NaN	NaN		
	50%	NaN	NaN		
	75%	NaN	NaN		
	max	NaN	NaN		

designation					

Libellé temporaire \

uid	e24f6685-40da-4fc8-8454-ec70282552be	Pays d'OC Viognier blanc IGP en BIB 5 L
	a4e317c3-f8d6-441d-82fc-13f5288ba137	COUVERCLE GOBELET 8 OZ
	729883ee-8d83-45a3-a7c7-015b22473ac9	Vinaigre de riz en bouteille 50 CL BEAU
	4312cd74-4708-4216-a56e-fbc404c5afa0	MOUTARDE BOURGOGNE IGP SEAU 1.1KG FALLOT
	2581a202-7737-448f-9e2d-eb5a02472101	Citronnade en bouteille 50 cl MINUTE MA

Désignation produit fournisseur \

uid	e24f6685-40da-4fc8-8454-ec70282552be	Pays d'OC Viognier blanc IGP en BIB 5 L VINS P..
	a4e317c3-f8d6-441d-82fc-13f5288ba137	COUVERCLE PR GOBELET CARTON 8OZ
	729883ee-8d83-45a3-a7c7-015b22473ac9	Vinaigre de riz en bouteille 50 CL BEAUFOR
	4312cd74-4708-4216-a56e-fbc404c5afa0	MOUTARDE DE BOURGOGNE IGP SEAU PLASTIQUE 1.1KG..
	2581a202-7737-448f-9e2d-eb5a02472101	Citronnade en bouteille 50 cl MINUTE MAID

Code interne fournisseur Marque commerciale \

uid	e24f6685-40da-4fc8-8454-ec70282552be	126 PERRET
	a4e317c3-f8d6-441d-82fc-13f5288ba137	COVGM80Z ALPHAFORM
	729883ee-8d83-45a3-a7c7-015b22473ac9	1217322022 BEAUFOR
	4312cd74-4708-4216-a56e-fbc404c5afa0	393 EDMOND FALLOT
	2581a202-7737-448f-9e2d-eb5a02472101	461020 MINUTE MAID

Dénomination réglementaire data_ok

uid	e24f6685-40da-4fc8-8454-ec70282552be	Vin de pays d'OC blanc True
	a4e317c3-f8d6-441d-82fc-13f5288ba137	COUVERCLE PR GOBELET CARTON 8OZ False
	729883ee-8d83-45a3-a7c7-015b22473ac9	Vinaigre de riz 5% d'acidite True
	4312cd74-4708-4216-a56e-fbc404c5afa0	MOUTARDE DE BOURGOGNE IGP True
	2581a202-7737-448f-9e2d-eb5a02472101	Boisson rafraîchissante avec jus de citrons, a... True

Libellé temporaire \

data_ok	False count	8722
	unique	8069
	top Eau minérale naturelle gazeuse en boute	
	freq	23
True	count	4513
	unique	4341
	top Barquette gastronomique thermoscellable e	
	freq	13

Désignation produit fournisseur Code interne fournisseur \

data_ok	False count	8348	7545
	unique	8108	7451
	top Cacao Barry Chocolate Pistoles	000	
	freq	8	10
True	count	4513	4490
	unique	4471	4434
	top Sac poubelle lien classique noir 130 L en roule...		
	freq	3	5

data_ok	Marque commerciale	Dénomination réglementaire
False count	8338	7901
unique	1194	6166
top CGMP	Préparation déshydratée	
freq	217	40
True count	4472	4513
unique	946	3765
top NEFF MADA	Potage instantané déshydraté	
freq	296	60

1.3.5 Analyses spécifiques : GTIN

On peut mettre en évidence les produits qui portent les mêmes GTIN en double. En y jetant un oeil rapide, quelques explications peuvent être trouvées : - il peut s'agir d'un changement de code fournisseur (les 2 premières lignes ne portent pas le même code fournisseur) - il peut s'agir d'un changement de recette côté industriel, qui a décidé de conserver le même GTIN (second couple) - il peut s'agir d'une erreur, et de produits en doublon dans le système (troisième couple) - ...

```
[19]: GTIN_mask = (df['properties.pprod:gtin'] != '') & ~pd.isna(df['properties.pprod:gtin'])
dups_mask = df.loc[GTIN_mask, 'properties.pprod:gtin'].duplicated(keep=False)
examples = (df.loc[GTIN_mask & dups_mask, def_fields.keys()]
    .rename(def_fields, axis=1)
    .sort_values('gtin')
    .head(8))
save_to_disk(examples,
    Path('..') / 'tbls' / 'Duplicated_GTIN.tex',
    lab={},
    tex_label='tab:dup_gtin',
)
print(examples)
```

uid	code	supplier	type	gtin \
048712e3-f145-4f40-b8ad-7c0b912983bd	PIMP-0000009515	PIMF-0000000420	grocery	0020176760607
4de8ce87-8df5-440c-959d-3d77d59bb4f3	PIMP-0000013159	PIMF-0000000182	grocery	0020176760607
7e455046-def3-4526-a28b-bc5c0e6e64fc	PIMP-0000011456	PIMF-0000000290	grocery	03344540125906
a92c6ac5-d5be-4f92-98b3-9f6c588f7613	PIMP-0000013198	PIMF-0000000290	grocery	03344540125906
66590f04-5eae-4829-b0da-c899a18dd9cb	PIMP-0000010839	PIMF-0000000250	grocery	3011360083845
27e20042-dc53-46b4-874c-f970db554aec	PIMP-0000001494	PIMF-0000000250	grocery	3011360083845
52d3f309-e402-4931-974c-b6b6fa721aff	PIMP-0000002337	PIMF-0000000348	grocery	3038353024906
02803e27-487a-43e3-9324-9ad1660b63b2	PIMP-0000002338	PIMF-0000000348	grocery	3038353024906
designation				
uid				
048712e3-f145-4f40-b8ad-7c0b912983bd		42 QUICHE FEUILL SG 11CM		
4de8ce87-8df5-440c-959d-3d77d59bb4f3		QUICHE FEUILLETEE		
7e455046-def3-4526-a28b-bc5c0e6e64fc	622028	SAUCE FUEGO SQUEEZE DE 580 G "O'TACOS"		
a92c6ac5-d5be-4f92-98b3-9f6c588f7613	622029	SAUCE FUEGO (NR) SQUEEZE DE 580 G "O'TA...		
66590f04-5eae-4829-b0da-c899a18dd9cb		Jus de poulet en boîte 750g KNORR		
27e20042-dc53-46b4-874c-f970db554aec		Jus de poulet en boîte 750 g KNORR		
52d3f309-e402-4931-974c-b6b6fa721aff		Tagliatelle aux œufs en colis 5 kg PANZANI		
02803e27-487a-43e3-9324-9ad1660b63b2		Torti aux œufs en sac 5 kg PANZANI		

Si l'on produit la répartition du nombre de produit portant un GTIN donné dans le système, on obtient :

```
[20]: df2 = (df.pivot_table(values='properties.vig:code',
                           index='properties.pprod:gtin',
                           aggfunc='count')
        .rename({'properties.vig:code': 'code_count'}, axis=1)
        )

df2 = (df2.reset_index()
       .loc[df2.index != '']
       .pivot_table(index='code_count',
                    aggfunc='count',
                    values='code_count')
       .rename({'properties.pprod:gtin': 'Nb de GTIN'},
              axis=1)
)
df2.index.rename('Pdt portant le GTIN', inplace=True)


print(df2)

save_to_disk(df2,
            Path('..') / 'tbls' / 'gtin_counts.tex')

fig, ax = plt.subplots(figsize=(5,3))
```

```
df2.plot(kind='bar', legend=None, title='Nombre de produit par GTIN', ax=ax)
fig.savefig(Path('..') / 'img' / 'repartition_gtin.png', bbox_inches='tight')
```

	Nb de GTIN
Pdt portant le GTIN	
1	11089
2	228
3	21
4	20
5	1



1.3.6 Analyse spécifique : distribution par fournisseur

On peut représenter la distribution produit, par fournisseur.

```
[21]: # construction the counts
counts = (df.loc[:, list(def_fields.keys())]
           .rename(def_fields, axis=1)
           .pivot_table(values='code',
                        index='supplier',
                        aggfunc='count')
           .reset_index()
           .pivot_table(values=['supplier', 'code'],
                        index='code',
                        aggfunc={'supplier': 'count',
                                 'code': 'sum'})
          )

# aligning index to have it continuous
new_idx = pd.RangeIndex(start=1, stop=max(counts.index) + 1)

counts = (counts.reindex(new_idx)
           .fillna(0)
          )

counts = pd.concat([counts,
                    counts.cumsum().rename({'code': 'cum_code', 'supplier': 'cum_supplier'},
                                         axis=1),
                   ],
                  axis=1)
```

```

for feature in ['supplier', 'code']:
    counts['cump_' + feature] = 100 * counts['cum_' + feature] / counts.loc[:, 'cum_' + feature].iloc[-1]

counts

[21]:   code  supplier  cum_code  cum_supplier  cump_supplier  cump_code
1     78.0      78.0      78.0        78.0      12.850082  0.589346
2    140.0      70.0     218.0       148.0      24.382208  1.647148
3    183.0      61.0     401.0       209.0      34.431631  3.029845
...
368     ..      ...      ...      ...      ...
369     0.0      0.0    12496.0      605.0     99.670511  94.416320
369    369.0      1.0    12865.0      606.0     99.835255  97.204382
370    370.0      1.0    13235.0      607.0    100.000000 100.000000

[370 rows x 6 columns]

[22]: fig, axs = plt.subplots(nrows=2,
                           ncols=2,
                           figsize=(14, 6),
                           gridspec_kw= {'width_ratios': [2, 1]})

axs2 = [[ax.twinx() for ax in axrow] for axrow in axs]

for i, feature in enumerate(['supplier', 'code']):
    axs[i][0].bar(data=counts.loc[:, feature].reset_index(), x='index', height=feature)
    axs2[i][0].plot('index', 'cump_' + feature, data=counts.loc[:, 'cump_' + feature].reset_index(),
                    color='red', linestyle='--')
    axs2[i][0].grid(True, axis='y', color='red', alpha=0.5, linestyle='--')

    axs[i][1].bar(data=counts.loc[:, feature].reset_index(), x='index', height=feature)
    axs2[i][1].plot('index', 'cump_' + feature, data=counts.loc[:, 'cump_' + feature].reset_index(),
                    color='red', linestyle='--')
    axs2[i][1].grid(True, axis='y', color='red', alpha=0.5, linestyle='--')

    axs[i][1].set_xlim(0, 30)

for i in range(len(axs)):
    for j in range(len(axs[i])):
        axs2[i][j].set_ylim(0, 100)
        # remove all bottom ticks except for bottom line
        # set_yticks does not work as it removes the grid
        if i < len(axs) - 1:
            axs[i][j].set_xticklabels([])
            for tic in axs[i][j].xaxis.get_major_ticks():
                tic.tick1line.set_visible(False)
                tic.tick2line.set_visible(False)
        # remove all right ticks except for right column
        # set_yticks does not work as it removes the grid
        if j < len(axs[i]) - 1:
            axs2[i][j].set_yticklabels([])
            for tic in axs2[i][j].yaxis.get_major_ticks():
                tic.tick1line.set_visible(False)
                tic.tick2line.set_visible(False)
        # remove all left ticks except for first column
        if j > 0:
            axs[i][j].set_yticks([])
        if j == len(axs[i]) - 1:
            axs2[i][j].tick_params(axis='y', colors='red')
            axs2[i][j].yaxis.set_major_formatter(ticker.PercentFormatter())
            axs2[i][j].set_ylabel('Proportion en cumul', color='red')
            axs[i][j].grid(True, axis='x', color='k', alpha=0.5, linestyle='--')
        if j == 0:
            axs[i][j].tick_params(axis='y', colors='blue')
            if i == 0:
                axs[i][j].set_ylabel('Nombre de fournisseurs', color='blue')
            if i == 1:

```

```


        axs[i][j].set_ylabel('Nombre de produits représentés', color='blue')
        axs[1][0].set_xlabel('Nombre de produit par fournisseur',
                             fontsize=12,
                             labelpad=8,
                             )
    axs[1][1].set_xlabel('Focus sur les fournisseurs à 30 produits ou moins',
                         fontsize=12,
                         labelpad=8,
                         )

fig.suptitle('Distribution des fournisseurs fonction du nombre de produit par fournisseur',
             fontsize=16,
             )

fig.savefig(Path('..') / 'img' / 'distribution_fournisseurs_par_prd_count.png', bbox_inches='tight')

```

Distribution des fournisseurs fonction du nombre de produit par fournisseur



On peut également représenter le nombre de produits “récupérés” si on prend les fournisseurs par nombre de produits décroissant.

```
[23]: # construction the counts
counts = (df.loc[:, list(def_fields.keys())]
          .rename(def_fields, axis=1)
          .pivot_table(values='code',
                      index='supplier',
                      aggfunc='count')
          .sort_values('code', ascending=False)
          )
counts['code_cumsum'] = counts['code'].cumsum()
counts
```

```
[23]:      code  code_cumsum
supplier
PIMF-0000000179    370        370
PIMF-0000000250    369        739
PIMF-0000000283    366       1105
...
PIMF-0000000522     1       13233
PIMF-0000000233     1       13234
PIMF-0000000005     1       13235
```


[607 rows x 2 columns]

```
[24]: fig, axs = plt.subplots(nrows=1,
                           ncols=2,
                           figsize=(14, 3),
                           gridspec_kw= {'width_ratios': [2, 1]})

for j in range(len(axs)):
    axs[j].plot('index',
                'code_cumsum',
                data=counts.reset_index().reset_index(),
                color='red',
                linestyle='--',
                )
    axs[j].set_xlabel('Nombre de fournisseurs', fontsize=12)
    axs[j].set_ylimit(0)
    axs[j].set_xlim(0)
    axs[j].grid(True)
    axs[j].yaxis.set_ticks(np.arange(0, 14000, 1000))

axs[0].set_ylabel('Nombre de produits cumulés')
axs[1].set_xlim(0, 30)
axs[1].set_xlabel('Nombre de fournisseurs (limite 30)', fontsize=12)
axs[1].set_yticklabels([])
for tic in axs[1].yaxis.get_major_ticks():
    tic.tick1line.set_visible(False)
    tic.tick2line.set_visible(False)

fig.suptitle('"Rappel" des produits en fonction des fournisseurs', fontsize=16)
fig.savefig(Path('..') / 'img' / 'rappel_produit_par_fournisseur.png', bbox_inches='tight')
```



1.3.7 Export de quelques désignations et listes d'ingrédients

On exporte quelques désignations pour illustrer.

```
[25]: df_des = df_dict['designation']
export_df = (df_des.loc[df_des['data_ok'],
                       ['temp_des',
                        'supplier_des',
                        'supplier_code',
                        'brand',
                        'regulatory_des']]
             .rename(lab, axis=1)
             .sample(5, random_state=40))
print(export_df)

# Do not overwrite current saved file!
# It has been corrected manually (midrule was not well placed)
#export_df.to_latex(Path('..') / 'tbls' / 'designation_example.tex',
#                   index=False,
#                   column_format='p{4cm}p{4cm}p{2cm}p{2cm}p{3cm}',
```

```

#           index_names=False,
#
#           )

Libellé temporaire \
uid
cfb2279a-b1c6-4bab-b21d-dedd4b725e5b Confiture de mûre en bocal verre 370 g
b660f69a-577f-4ff1-b67c-da16698135de Fond de volaille lié hyposodé en boîte
5ad96ecc-72e2-4716-988b-ea7980649832 Raisins secs golden en sachet 1 kg DOMI
1417374f-ea74-4274-b20d-e6b4d6626bbd   Fanta citron en canette 33 cl FANTA
18d09479-6d53-414d-9c71-eb421ba4931f   DIST M4 REFLEX TURQUOISE - 473180

Désignation produit fournisseur \
uid
cfb2279a-b1c6-4bab-b21d-dedd4b725e5b BONNE MAMAN CONF MURES 370G
b660f69a-577f-4ff1-b67c-da16698135de Fond de volaille lié hyposodé en boîte 800 g N...
5ad96ecc-72e2-4716-988b-ea7980649832 INDET RAISIN GOLDEN 1000G INDETERMINEE
1417374f-ea74-4274-b20d-e6b4d6626bbd   Fanta citron en canette 33 cl FANTA
18d09479-6d53-414d-9c71-eb421ba4931f   TORK REFLEX DISTRIBUTEUR À DÉVIDAGE CENTRAL FE...

Code interne fournisseur Marque commerciale \
uid
cfb2279a-b1c6-4bab-b21d-dedd4b725e5b 20002224 BONNE MAMAN
b660f69a-577f-4ff1-b67c-da16698135de 7701 NEFF MADA
5ad96ecc-72e2-4716-988b-ea7980649832 188670001 INDETERMINEE
1417374f-ea74-4274-b20d-e6b4d6626bbd 405278 FANTA
18d09479-6d53-414d-9c71-eb421ba4931f 473180 Tork Reflex

Dénomination réglementaire
uid
cfb2279a-b1c6-4bab-b21d-dedd4b725e5b Confiture Extra de Mûres.
b660f69a-577f-4ff1-b67c-da16698135de Fond de sauce déshydraté
5ad96ecc-72e2-4716-988b-ea7980649832 Raisins Secs Golden
1417374f-ea74-4274-b20d-e6b4d6626bbd Boisson rafraîchissante avec jus de citron, av...
18d09479-6d53-414d-9c71-eb421ba4931f TORK REFLEX DISTRIBUTEUR À DÉVIDAGE CENTRAL FE...

```

```
[27]: ingred_mask = df['data_ok'] & ~pd.isna(df['properties.pprodः:ingredientsList'])

sample_ingred = (df.loc[ingred_mask, ['properties.pprodः:supplierDesignation',
                                         'properties.pprodः:ingredientsList']]
                  .rename(lab, axis=1)
                  .sample(10, random_state=42))

with pd.option_context("max_colwidth", 1000):
    print(sample_ingred)
#     sample_ingred.to_latex(Path('..') / 'tbls' / 'ingredient_example.tex',
#     index=False,
#     index_names=False,
#     column_format='p{5cm}p{10cm}',
#     )

```

```

fournisseur \
uid
1ad9f10d-fe01-44a2-8a7b-293522f65628 PAPILLONS SEMI-COMPLETS
BIOLOGIQUE 4KG CORN
87d82c80-9c5f-4b6c-94d8-d84dcac8aff7
FLAKES 24G Crème de volaille en sachet 20 g
NEFF MADA Lipton Ice Tea saveur pêche
b826fe4b-7978-4ea6-84da-51adcbf7b04b
33 cl
ed8512da-c1f1-4f9a-9161-fce8d1e6267a ASSORTIMENT 4 VARIÉTÉS DE PURÉES SANS SUCRES AJOUTES COUPELLES
ALUMINIUM 95G
4b895a76-050d-4e34-badf-f1a639462348 Fond de volaille BIO en sachet doypack 550 g ALLIANCE
GASTRONOMIE
67b51476-bde8-4df0-af87-3f18bdbaae90 Biscuits nappés au chocolat

```

au lait
 d6763699-0ac2-4d7e-b80c-725987a756fb BN goût fraise en paquet
 295 g BN
 ec917c4b-f1bc-4f00-aa4c-89b14e521e01 Arôme vanille en bouteille 1 L
 MARMITON
 50bbae68-33a4-4f5f-a320-04cf2b11dde9 Méditerranée rouge IGP en bouteille 25 cl CŒUR DE
 MEDITERRANEE

Liste d'ingrédients

uid
 1ad9f10d-fe01-44a2-8a7b-293522f65628
 Semoule de BLE DUR SEMI-COMPLETE biologique (contient du GLUTEN, traces OEUFS et SOJA)
 87d82c80-9c5f-4b6c-94d8-d84dcac8aff7
 Maïs, sucre, arôme de malt d'ORGE, sel, Vitamines et Minéraux : vitamines (niacine, B6, B2, B1, acide folique, D, B12), fer.
 6620f892-1959-468e-872b-588a07511892
 Amidon modifié de pomme de terre - Sirops de glucose de maïs et de blé - Arômes - Huile de tournesol - Sel - Graisse de poulet 3 % - Oignon - Extrait de levure - Viande de poule 0,8 % - Protéines de LAIT - Curcuma.
 b826fe4b-7978-4ea6-84da-51adcbf7b04b
 eau,sucre,fructose,acidifiants (acide citrique, acide malique),extrait de thé noir (1,4g/l),jus de pêche à base de concentré (0,1%),correcteur d'acidité (citrate trisodique),arômes,antioxydant (acide ascorbique),édulcorant (glycosides de stéviol)
 ed8512da-c1f1-4f9a-9161-fce8d1e267a
 Pommes : Pomme 100%, antioxydant : acide ascorbique.\nPomme / banane : Pomme 84%, banane 15%, antioxydant : acide ascorbique, acidifiant: acide citrique.\nPoire : Poire 100%, antioxydant : acide ascorbique, acidifiant : acide citrique.\nPomme / pruneau : Pomme 90%, purée de pruneau 10%\n(pruneau 5%, eau 5%), antioxydant : acide ascorbique.
 4b895a76-050d-4e34-badf-f1a639462348
 Maltodextrine de maïs*, féculle de pomme de terre*, poulet* lyophilisé origine UE (10%), sel, extrait de levure*, oignon*, ail* et poivre blanc*. (*ingrédients issus de l'agriculture biologique). 100% des ingrédients sont issus de l'agriculture biologique.
 67b51476-bde8-4df0-af87-3f18bdbaae90
 Farine de BLE, chocolat (sucre, beurre de cacao, poudre de LAIT entier, masse de cacao, émulsifiant : lécithines [SOJA], arôme naturel de vanille), sucre, huile de colza, amidon de BLE, BEURRE pâtissier, nougatine (sucre, AMANDES, NOISETTES), poudre à lever : (carbonates d'ammonium et de sodium, acide citrique), sirop de sucre inverti, sel, arôme.
 d6763699-0ac2-4d7e-b80c-725987a756fb Ingrédients : Céréales [farine de FROMENT (33%), céréales complètes (15.1%) (farine complète de FROMENT (15 %), farine complète de SEIGLE, farine complète d'ORGE)] - sirop de glucose-fructose - sucre - matière grasse végétale (palme) - stabilisant : glycérol - sirop de glucose - pulpe de fraise concentrée (équivalent fraise 5 %) - amidon - LACTOSE et protéines de LAIT - poudres à lever : carbonates d'ammonium et de sodium - sel - LAIT entier en poudre - acidifiants : acide citrique, citrate trisodique - colorant : rouge de betterave - gélifiant : pectine - arôme - épaisseur : amidon modifié. Peut contenir des traces de FRUITS A COQUE, de SOJA, d'OEUF et de SESAME
 ec917c4b-f1bc-4f00-aa4c-89b14e521e01
 Eau osmosée, Sucre Cristallisé, Propylène glycol, Glycérine Naturelle, vanilline, arômes, colorant caramel E150b
 50bbae68-33a4-4f5f-a320-04cf2b11dde9
 raisin - SULFITES

1.4 Analyse de la complétude des pièces jointes

On jette un oeil au niveau de renseignement des pièces jointes dans le PIM.

```
[49]: file_df = requester.file_report_from_result(mapping={'uid': 'uid'}, index='uid', record_path='entries')
file_df
```

	has_supplierdatasheet	has_supplierlabel
uid		
afee12c7-177e-4a68-9539-8cbb68442503	False	False
7d390121-17e8-43bf-a357-9d06b79d2d47	False	False
f234cd84-c8f6-433f-85ec-6e0b6980adc6	True	True
...
ef42a938-2203-446e-8d28-9fd27c6d3146	False	False
68f5d81b-7f91-40a0-8504-0ec320a86de4	False	False
6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a	False	False

[13235 rows x 2 columns]

```
[50]: file_df = file_df.join(df)

[113]: total_df = file_df.groupby('properties.pprodtop:typeOfProduct').size().to_frame(name='total')
new_idx = pd.MultiIndex.from_tuples([('total', 'total')])
total_df.columns = new_idx
total_df

[113]:          total
              total
properties.pprodtop:typeOfProduct
alcoholicDrink           607
chemistry                 459
grocery                  8762
hygiene                  2501
nonAlcoholicDrink         906

[156]: report_df = (
    file_df.pivot_table(values=['has_supplierdatasheet', 'has_supplierlabel'],
                         columns=['data_ok', ],
                         index=['properties.pprodtop:typeOfProduct'],
                         aggfunc=['sum', 'count'],
                         margins=True,
                         )
)
report_df2 = report_df.swaplevel(axis=1, i=0, j=2).sort_index(axis=1).stack([0, 1])
report_df2['percent'] = report_df2['sum'] / report_df2['count']
report_df3 = report_df2.unstack(level=[-2, -1]).swaplevel(axis=1, i=0, j=1).swaplevel(axis=1, i=2, j=1).
    sort_index(axis=1)
report_df3.columns.rename(['data_ok', 'attached', 'func'], inplace=True)
report_df3
```

		False			has_supplierlabel			
		has_supplierdatasheet	count	percent	sum	count	percent	
properties.pprodtop:typeOfProduct	All		8722	0.844302	7364.0	8722	0.312543	
	alcoholicDrink		354	0.836158	296.0	354	0.209040	
	chemistry		329	0.942249	310.0	329	0.386018	
	grocery		5755	0.832493	4791.0	5755	0.333797	
	hygiene		1733	0.870744	1509.0	1733	0.242354	
	nonAlcoholicDrink		551	0.831216	458.0	551	0.333938	

		True			has_supplierlabel			
		has_supplierdatasheet	count	percent	sum	count		
properties.pprodtop:typeOfProduct	All	2726.0	4513	1.0	4513.0	4513		
	alcoholicDrink	74.0	253	1.0	253.0	253		
	chemistry	127.0	130	1.0	130.0	130		
	grocery	1921.0	3007	1.0	3007.0	3007		
	hygiene	420.0	768	1.0	768.0	768		
	nonAlcoholicDrink	184.0	355	1.0	355.0	355		

		All			
		has_supplierdatasheet	count	percent	sum
properties.pprodtop:typeOfProduct	All	0.979171	4419.0	13235	0.897393 11877.0
	alcoholicDrink	1.000000	253.0	607	0.904448 549.0
	chemistry	1.000000	130.0	459	0.958606 440.0
	grocery	0.996342	2996.0	8762	0.889979 7798.0
	hygiene	0.895833	688.0	2501	0.910436 2277.0
	nonAlcoholicDrink	0.991549	352.0	906	0.897351 813.0

		has_supplierlabel	
data_ok	attached		

```

func                               count   percent    sum
properties.pprodtop:typeOfProduct
All                                13235  0.539856  7145.0
alcoholicDrink                      607   0.538715  327.0
chemistry                           459   0.559913  257.0
grocery                            8762  0.561173  4917.0
hygiene                            2501  0.443023  1108.0
nonAlcoholicDrink                   906   0.591611  536.0

```

```

[165]: type_index = pd.Index(['grocery', 'nonAlcoholicDrink', 'alcoholicDrink', 'hygiene', 'chemistry', 'All'],  
                           name='type')
idxs = [[True, False, 'All'], ['has_supplierdatasheet', 'has_supplierlabel'], ['sum', 'count', 'percent']]
col_index = pd.MultiIndex.from_product(idxs, names=['data_ok', 'attached', 'func'])
report_df4 = report_df3.reindex(col_index, axis=1).reindex(type_index)
report_df4

```

		True						
attached	has_supplierdatasheet	sum	count	percent	has_supplierlabel	sum	count	percent
func								
type								
grocery		3007.0	3007	1.0		2996.0	3007	0.996342
nonAlcoholicDrink		355.0	355	1.0		352.0	355	0.991549
alcoholicDrink		253.0	253	1.0		253.0	253	1.000000
hygiene		768.0	768	1.0		688.0	768	0.895833
chemistry		130.0	130	1.0		130.0	130	1.000000
All		4513.0	4513	1.0		4419.0	4513	0.979171
		False						\
attached	has_supplierdatasheet	sum	count	percent	has_supplierlabel	sum	count	percent
func								
type								
grocery		4791.0	5755	0.832493		1921.0	5755	0.333797
nonAlcoholicDrink		458.0	551	0.831216		184.0	551	0.333938
alcoholicDrink		296.0	354	0.836158		74.0	354	0.209040
hygiene		1509.0	1733	0.870744		420.0	1733	0.242354
chemistry		310.0	329	0.942249		127.0	329	0.386018
All		7364.0	8722	0.844302		2726.0	8722	0.312543
		All						\
attached	has_supplierdatasheet	sum	count	percent	has_supplierlabel	sum	count	percent
func								
type								
grocery		7798.0	8762	0.889979		4917.0	8762	0.561173
nonAlcoholicDrink		813.0	906	0.897351		536.0	906	0.591611
alcoholicDrink		549.0	607	0.904448		327.0	607	0.538715
hygiene		2277.0	2501	0.910436		1108.0	2501	0.443023
chemistry		440.0	459	0.958606		257.0	459	0.559913
All		11877.0	13235	0.897393		7145.0	13235	0.539856

```

[209]: ### WARNING !!! This tex export requires some manual adjustments to have
       ### multiindex headers centered !!!

(

```

```

report_df4.rename({'has_supplierdatasheet': 'Fiche technique',
                  'has_supplierlabel': 'Etiquette',
                  'True': 'En qualité',
                  'False': 'Hors qualité',
                  'All': 'Total',
                  'sum': 'cpt',
                  'count': 'sur',
                  'percent': '%',
                  }, axis=1)
.rename({'grocery': 'Epicerie',
        'nonAlcoholicDrink': 'Boissons',
        'alcoholicDrink': 'Alcools',
        'hygiene': 'Hygiène',
        })

```

```

        'chemistry': 'Chimie',
        'All': 'Total'})
    .to_latex(#Path('..') / 'tbls' / 'attached_files_counts.tex',
              column_format='|l|ccc|ccc|ccc|ccc|ccc|ccc|',
              bold_rows=True,
              index_names=False,
              formatters=[lambda x: str(int(x)),
                          lambda x: str(int(x)),
                          lambda x: f'{int(x * 100):d}%',
                          lambda x: str(int(x)),
                          lambda x: f'{int(x * 100):d}%',
                          lambda x: str(int(x)),
                          lambda x: f'{int(x * 100):d}%',
                          lambda x: str(int(x)),
                          lambda x: f'{int(x * 100):d}%',],
            ]
        )
)
)
)
)
```

[209]: \\\begin{tabular}{lccccccccccccc}\n\\\toprule\n{} & \\\multicolumn{6}{l}{En qualité} & \\

\\\multicolumn{6}{l}{Hors qualité} & \\\multicolumn{6}{l}{Total} \\\n{} & \\\multicolumn{3}{l}{Fiche technique} & \\\multicolumn{3}{l}{Etiquette} & \\\multicolumn{3}{l}{Fiche technique} & \\\multicolumn{3}{l}{Etiquette}

\\\\\\n{} & \\\multicolumn{6}{r}{\%} & \\\multicolumn{6}{r}{\%} & \\\multicolumn{6}{r}{\%}

cpt & sur & \\\% & \\\multicolumn{6}{r}{\%} & \\\multicolumn{6}{r}{\%} & \\\multicolumn{6}{r}{\%}

\\\midrule\n\\\textbf{Epicerie} & 3007 & 3007 & 100\% & 2996 & 3007 & 99\% &

4791 & 5755 & 83\% & 1921 & 5755 & 33\% & 7798 & 8762 & 88\% & 4917 & 8762 & 56\%

458 & 355 & 355 & 355 & 355 & 99\% & 352 & 355 & 906 & 89\% & 536 & 906 & 59\%

551 & 83\% & 184 & 551 & 33\% & 813 & 813 & 813 & 813 & 813 & 813 & 906 & 906 & 906 & 906 & 906 & 906

296 & 253 & 253 & 253 & 253 & 253 & 253 & 253 & 253 & 253 & 253 & 253 & 253 & 253 & 253 & 253

354 & 83\% & 74 & 354 & 20\% & 549 & 549 & 549 & 549 & 549 & 549 & 607 & 607 & 607 & 607 & 607 & 607 & 607 & 607 & 607

1509 & 768 & 768 & 768 & 768 & 768 & 768 & 768 & 768 & 768 & 768 & 768 & 768 & 768 & 768 & 768 & 768

1733 & 87\% & 420 & 1733 & 24\% & 2277 & 2277 & 2277 & 2277 & 2277 & 2277 & 2501 & 2501 & 2501 & 2501 & 2501 & 2501 & 2501 & 2501 & 2501

310 & 130 & 130 & 130 & 130 & 130 & 130 & 130 & 130 & 130 & 130 & 130 & 130 & 130 & 130 & 130 & 130

7364 & 4419 & 4419 & 4419 & 4419 & 4419 & 4419 & 4513 & 4513 & 4513 & 4513 & 4513 & 4513 & 4513 & 4513 & 4513

7145 & 11877 & 11877 & 11877 & 11877 & 11877 & 11877 & 4513 & 4513 & 4513 & 4513 & 4513 & 4513 & 4513 & 4513 & 4513

53\% & 13235 & 13235 & 13235 & 13235 & 13235 & 13235 & 89\% & 89\% & 89\% & 89\% & 89\% & 89\% & 89\% & 89\% & 89\%

\\\\\\bottomrule\n\\\end{tabular}\n'

Annexe H

LE CODE DES DIFFÉRENTS MODULES

H.1 Gestion du fichier de configuration - Module conf

Ce petit module a pour but de permettre de gérer les paramètres du programme dans un fichier de configuration (afin de simplifier la maintenance). Il est utilisé dans l'ensemble des autres modules de ce projet.

Un exemple de fichier de configuration (dont certains champs ont été anonymisés pour des raisons de confidentialité) est présenté ci-dessous. TODO !! Mettre le fichier ici.

H.2 Extraction des données du PIM - Module pimapi

H.3 Conversion des pièces jointes en textes - Module pimpdf

H.4 Transformateurs et estimateurs spécifiques - Module pimest

Ce module définit divers estimateurs et transformateurs utilisés dans les modèles. Les fonctions de scoring, servant à la mesure de la performance, en font également partie. Les classes ‘IngredientExtractor‘ et ‘PIMIngredientExtractor‘ ont été construite au début des travaux sur le sujet, et sont donc plus « brouillonnes » que le reste du code.