

Extraction des ingrédients depuis les fiches techniques de produits alimentaires

Pierre MASSÉ

Juin 2020

Résumé

La gestion de l'information produit est devenu un enjeu de société majeur ces dernières années. Les scandales sanitaires récents ont déclenché une prise de conscience collective des consommateurs, en parallèle de la mise en place de réglementations de plus en plus contraignantes pour l'ensemble des acteurs de la filière [3][4].

La mise en place d'outils mettant en oeuvre les principes du Machine Learning appliqués au traitement du langage permettrait d'aider les opérationnels de la gestion de l'information à interpréter plus vite et mieux les documents mis à disposition par les fournisseurs du groupe. Le présent rapport détaille la mise en place d'un outil permettant d'extraire les listes d'ingrédients des fiches techniques transmises par les fabricants des produits.

Dans une première partie, on détaillera le contexte métier autour de la gestion de l'information produit. Nous nous analyserons ensuite les données disponibles, et les possibilités de les exploiter. Nous expliciterons alors les raisons qui ont poussé à choisir le cas d'usage, et la manière dont il pourrait être mis en oeuvre au sein du Groupe Pomona. La quatrième partie sera consacrée à la construction du modèle à proprement parler, et la dernière partie ouvrira la réflexion sur les travaux à venir.

TABLE DES MATIÈRES

I	Contexte métier	6
1	Description du groupe	6
1.1	Le métier du Groupe Pomona	6
1.2	La décentralisation	7
1.2.1	Les Directions fonctionnelles	7
1.2.2	Les clients du groupe	8
1.2.3	Premier niveau de décentralisation : les branches	8
1.2.4	Le second niveau de décentralisation : les succursales	11
2	La gestion de l'information produit	11
2.1	L'information produit	13
2.1.1	Utilisations de l'information produit	13
2.1.2	Des produits bruts aux produits transformés	14
2.1.3	Les grands types d'information	14
2.2	Le processus	18
2.2.1	Le fournisseur est propriétaire des informations produit	18
2.2.2	La notion de produit et d'article	18
2.2.3	Les acteurs	20
2.2.4	Les contrôles	20
2.3	Les outils informatiques associés	21
2.3.1	Les branches faiblement outillées	21
2.3.2	Le GIP	23
2.3.3	Le PIM	23
II	Les données	27
3	Le périmètre produit	27
3.1	Les produits non-alimentaires	27
3.2	Accessibilité de la donnée en fonction des branches	28
3.3	Analyses quantitatives	28
3.3.1	Comparatifs entre les branches	28
3.3.2	Les grands types de produits	29

4	Les données utilisables, issues du PIM	30
4.1	Données structurées	33
4.1.1	Description des données structurées	33
4.1.2	Analyse de ces données structurées	34
4.2	Données non structurées	38
4.2.1	Les libellés	38
4.2.2	Les listes d'ingrédients	38
4.3	Pièces jointes	39
4.3.1	Fiches techniques fournisseur	39
4.3.2	Étiquettes produit	39
4.3.3	Fiches logistiques fournisseur	39
4.4	Récapitulatif de la complétude des données	39
4.5	Analyse qualitative des données	40
4.5.1	Évaluation de la qualité des données	40
4.5.2	Types de pdf possédés	40
4.6	Les données « manuellement étiquetées »	40
4.6.1	Mode de constituion de l'échantillon	40
4.6.2	Règles de gestion pour l'étiquetage manuel	40
4.6.3	Confrontation avec le contenu du PIM	40
III	Les objectifs de ce projet	41
5	Les cas d'usage	41
5.1	Objectifs : Qualité et productivité	41
5.2	La préalimentation d'information	41
5.3	Le contrôle des informations transmises	41
5.3.1	Le contrôle à la saisie fournisseur	42
5.3.2	L'aide aux vérifications Pomona	42
5.3.3	Les contrôles en masse asynchrones	42
6	Le choix du cas d'usage	42
6.1	La représentation dominante des fiches techniques	42
6.2	Les multiples formats et le besoin de « spatialisation »	42
6.3	Les informations « spatialisées »	43
6.4	La complexité dans la représentation des données logistiques	43
6.5	L'identification d'une liste d'ingrédient par son contenu	43
6.6	Conclusion quant au choix du cas d'usage	43

IV	Construction du modèle	44
7	Les principes généraux	44
7.1	Contenu du texte d'une liste d'ingrédients	44
7.2	Limitation à l'identification des listes d'ingrédients	44
7.3	Conversion de documents en texte	44
8	Construction d'un modèle simple « ouvert »	45
8.1	Extraction des données	45
8.2	Conversion en blocs de texte	46
8.3	Train/Test split	46
8.4	Entraînement du modèle	46
8.5	Calcul de la similarité	46
8.6	Illustration des résultats obtenus	46
8.7	Pistes d'améliorations identifiées	46
9	Utilisation des données manuellement étiquetées	47
9.1	Chargement des données manuellement étiquetées	47
9.2	Train/Test split	47
9.3	Entraînement du modèle	48
9.4	Illustration des prédictions obtenues	48
10	Mesure de la performance	48
10.1	Précision	49
10.1.1	Approche naïve	49
10.1.2	Avec du « text-postprocessing »	49
10.2	Fonctions de « loss » spécifiques	49
10.2.1	Distance de Levenshtein	49
10.2.2	Distance de Damerau-Levenshtein	49
10.2.3	Distance de Jaro	49
10.2.4	Distance de Jaro-Winkler	49
10.2.5	Métriques non retenues	50
10.2.6	Conclusion sur la métrique à utiliser	50
10.3	Cross-validation	50
11	Transfer learning	50
11.1	Principe du pré-entraînement	50
11.2	Illustration de l'impact sur la performance	50

12 Hyperparameter tuning	51
12.1 Les paramètres ajustables	51
12.1.1 La prise en compte des « n-grams »dans la tokenization	51
12.1.2 L’application de « n-grams »de blocs	51
12.1.3 L’utilisation d’expressions régulières dans le split des blocs	51
12.1.4 Applications d’autres fonctions de similarité	51
12.2 Application d’une grid search	51
V Travaux subséquents	52
13 Opérationnalisation de cette maquette	52
13.1 Client et sponsor métier	52
13.2 Sélection du use case	52
13.3 Mise en place d’une organisation projet	52
13.3.1 Identification des compétences nécessaires	52
13.3.2 Choix d’un cadre méthodologique projet	52
13.3.3 Développement côté PIM	52
13.4 Industrialisation du code du modèle	53
13.5 Monitoring de la performance du modèle	53
14 Extension des fonctionnalités offertes	53
14.1 Prise en compte de nouveaux types de pièces jointes	53
14.2 Utilisation d’outil d’OCR pour les pdf non structurés	53
14.3 Mise en place d’outil de spatialisation des textes	53
14.4 Construction d’outils d’extraction de données connexes à la composition	53
14.5 Élargissement aux données nutritionnelles	54
14.6 Évaluation de la performances sur d’autres familles de produits	54
VI Annexes	55
A Figures, tableaux et bibliographie	55
B Exemple de documents fournisseur	57
B.1 Fiches techniques	57
B.1.1 Fiche technique sel Cerebos	58
B.1.2 Fiche technique olives Valtonia	59
B.1.3 Fiche technique Panna Cotta Nestlé	60

B.1.4	Fiche technique confiture Andros	62
B.1.5	Fiche technique ciboulette La case aux épices	64
B.2	Étiquettes produit	66
B.3	Fiches logistiques	66
C	Le code utilisé	66
C.1	Analyse quantitative	67
C.2	Gestion du fichier de configuration	77
C.3	Extraction des données du PIM	77
C.4	Analyse des données du PIM	89
	Analyse des données du PIM	90
C.5	Conversion des pièces jointes en textes	102
C.6	Identification des listes d'ingrédients	107

Première partie

CONTEXTE MÉTIER

Chapitre 1

DESCRIPTION DU GROUPE

L'objet de l'ensemble de cette première partie est de donner sur le Groupe Pomona des éclairages nécessaires à la compréhension du cas d'usage développé. Bien d'autres aspects sur la société, pourraient être mentionnés (ex : des indicateurs sur l'activité, l'histoire du groupe. . .) mais ils seront omis car non indispensables à la compréhension du sujet. Plus de détails sur le groupe sont accessibles sur le site web de la société[10].

1.1 Le métier du Groupe Pomona

Le Groupe Pomona est une société de distribution livrée de produits alimentaires à destination des professionnels des métiers de bouche. L'activité du groupe consiste uniquement à acheter et revendre de la marchandise, à l'exclusion de toute activité de fabrication ou de transformation¹. Le groupe Pomona est une société de *distribution*. Elle ne possède d'ailleurs pas d'actif industriel (autre que des entrepôts logistiques) ni d'agrément pour transformer les marchandises.

Cette activité d'achat/vente se fait dans la majorité des cas sous le régime du *négoce*, à savoir que le groupe acquiert la propriété des marchandises qu'il commercialise avant de la céder à ses clients. L'autre régime est celui dit de la *prestation (logistique)*. Dans ce cas, par le jeu d'écritures comptables, la valorisation du stock disparaît des comptes du groupe. Néanmoins, indépendamment de cet aspect purement comptable, l'ensemble :

des flux de documents : commandes d'achat, factures fournisseur, commandes de vente, factures clients

des flux financiers : paiements fournisseur, paiements client

des flux physiques : réception et stockage, préparation et expédition

1. de très rares cas de transformation existent (ex : mûrissage de fruits, filetage de poisson) mais sont extrêmement exceptionnels

restent largement inchangés.

Pour résumer, l'activité de l'ensemble des entités du groupe pourraient se résumer via le schéma présenté à la FIGURE 1 page 7




FIGURE 1 – Les flux métier avec les partenaires commerciaux

Le métier du groupe est d'être un grossiste, qui achète et revend des produits alimentaires² sans produire ou transformer quoi que ce soit.

1.2 La décentralisation

Le Groupe Pomona est un groupe fortement décentralisé, avec des organisations largement indépendantes les unes des autres.

1.2.1 Les Directions fonctionnelles

Pour des raisons évidentes de recherche de synergies ou de conformité réglementaires, certaines activités restent toutefois mutualisées à la maille du groupe. Il s'agit des organisations suivantes :

La Direction Administrative et Financière (DAF) : regroupe les équipes comptables groupe, l'audit interne et la consolidation financière

2. dans la grande majorité des cas, cf. *Les produits non-alimentaires* 3.1 page 27

La Direction Qualité Sécurité et Environnement (DQSE) : est en charge de définir et contrôler l'application des standard de qualité

La Direction des Systèmes d'Information (DSI) : développe et maintient en condition opérationnelles les systèmes d'information du groupe

La Direction Technique et Logistique (DTL) : est en charge des projets immobiliers (entrepôts), des négociations avec les transporteurs et joue un rôle de conseil interne sur les sujets logistiques

La Direction des Ressources Humaines : se charge de l'ensemble des aspects en lien avec le recrutement, la paye et les sujets sociaux

La Direction Commerciale groupe (DCG) : définit une stratégie et des bonnes pratiques commerciales et marketing

1.2.2 Les clients du groupe

Afin de comprendre l'organisation du groupe, il est nécessaire de connaître la typologie de ses clients. Comme mentionné précédemment, le groupe s'adresse exclusivement aux professionnels des métiers de bouche. Aucune marchandise n'est vendue à des particuliers. Les principales typologies de clients sont les suivantes :

Les Sociétés de Restauration : elles exploitent les restaurants d'entreprise, certaines cantines d'établissements d'enseignement, les maisons de retraite, ...

Les Marchés Publics : regroupent les clients qui dépendent des collectivités (écoles, hôpitaux, prisons, ...)

La restauration commerciale : est l'ensemble des restaurants à vocation commerciale, qu'ils soient chaînés (hippopotamus, O'Tacos, ...) ou indépendants (« le restaurant du coin »)

Les spécialistes : il s'agit des détaillants spécialisés qui s'adressent aux particuliers. Boulangers, pâtisseries, bouchers, traiteurs, vente à emporter, ...

Les Grandes et Moyennes surfaces (la GMS) : sont les enseignes de la grande distribution. En général, l'accès à ces clients est compliqué par les règles mises en place par leurs centrales d'achat. Il représentent en général qu'un canal de vente d'opportunité.

Les trois premières de ces catégories représentent ce que l'on appelle la *Restauration Hors Domicile (RHD)* (ou parfois également la Restauration Hors Foyer, RHF).

1.2.3 Premier niveau de décentralisation : les branches

Le Groupe Pomona est divisé en branches, qui sont des unités opérationnelles indépendantes, et qui ont toute latitude pour gérer leurs stratégie et politique commerciales, la gestion de leurs achats, leur stratégie marketing, ... En particulier, les systèmes d'information ne sont pas identiques entre les différentes branches. Afin d'éviter de se concurrencer entre elles, leurs domaines d'activité respectifs ont été partitionnés par familles de produit commercialisés, segments client cibles et géographie.

Les branches RHD

Les branches RHD s'adressent aux clients de la Restauration Hors Domicile (cf. section 1.2.2 page 8) en France. Elles se répartissent ce marché en travaillant des gammes de produits distinctes. Il s'agit des branches historiques du groupe, qui représentent l'essentiel de son chiffre d'affaire. La répartition par produit est la suivante :

PassionFroid : spécialiste des *produits surgelés, de la viande fraîche et des produits laitiers*

ÉpiSaveurs : spécialiste des produits qui se conservent à température ambiante : *produits d'épicerie, conserves, boissons et consommables de cuisine non-alimentaires*

TerreAzur : spécialités des *Fruits et Légumes frais, et Produits De la Mer frais*

La non-concurrence entre les branches est assurée par le fait qu'elles ne commercialisent pas les mêmes produits. Bien que nommées RHD, elles peuvent également vendre leurs produits à la grande distribution (GMS : Grandes et Moyennes Surfaces), mais généralement ces marchés sont verrouillés par les centrales d'achat des grandes enseignes. La branche TerreAzur arrive toutefois à prendre des parts de marché significatives sur ce segment. Les branches RHD utilisent le progiciel SAP comme système de gestion. La branche TerreAzur est en cours de déploiement, en 2020 environ les 2 tiers des succursales travaillent avec ce progiciel.

Les branches spécialistes

Les branches spécialistes s'adressent aux clients dits spécialistes (cf. section 1.2.2 page 8) en France. Elles sont en mesure de commercialiser tout type de produit pour répondre aux besoins de leurs clients. En particulier, elles peuvent tout à fait commercialiser certains produits qui sont également vendus par les branches RHD. Elles se répartissent la clientèle spécialiste de la manière suivante :

Délice et Création : s'adresse aux *Boulangers et Pâtisseries*

Saveurs d'Antoine : s'adresse aux *Bouchers, Charcutiers et Traiteurs*

Relais d'Or : s'adresse à la *restauration commerciale indépendante*

Comme pour les branches RHD, ces branches peuvent lorsqu'elles en ont l'opportunité vendre leurs produits à la GMS.

L'étranger

Bien que le Groupe Pomona soit une société dont l'essentiel de l'activité est faite sur le marché français, deux réseaux sont en cours de constitution sur des pays limitrophe. Ces branches sont susceptibles de travailler tout type de produit, à destination de tout type de client. Elles sont positionnées sur les marchés suivants :

Pomona Suisse : présente sur le marché Suisse

Pomona Iberia : présente sur le marché Espagnol

On peut synthétiser la répartition de l'activité par branche de la manière présentée à la FIGURE 2 page 10.




FIGURE 2 – La répartition de l'activité des branches

1.2.4 Le second niveau de décentralisation : les succursales

Chacune des branches est elle-même à son tour décentralisée en un réseau d'entrepôts régionaux : les succursales (parfois également appelées simplement « régions »). Ces succursales sont gérées comme des PME indépendantes, avec un directeur et un compte de résultat qui leur est propre. Si certaines négociations avec des fournisseurs ou des clients nationaux sont parfois menées par les branches, les succursales sont autonomes dans :

- la définition de leur assortiment, même si des contraintes s'appliquent
- la stratégie de développement commercial
- la négociation des prix d'achat
- la négociation des prix de vente
- la politique de rémunération de leurs employés

À ce titre, elles ont leurs propres équipes d'achat, leurs équipes commerciales (télévente et vente route), leurs équipes administratives et évidemment leurs équipes logistiques (essentiellement en entrepôt et les chauffeurs livreurs en charge des livraisons client).

Certaines activités restent de la responsabilité des équipes centrales des branches, comme : la négociation avec les clients ou les fournisseurs nationaux, la constitution de l'assortiment commun (les produits que toutes les succursales doivent détenir), la gestion des référentiels de données de base métier, ...

Un exemple de maillage régional est présenté en FIGURE 3 page 12, sachant que ce maillage régional est différent pour chacune des branches.

Chapitre 2

LA GESTION DE L'INFORMATION PRODUIT

Ce chapitre a pour vocation à éclairer les aspects métier en lien avec la gestion de l'information produit. C'est le seul processus métier qui sera détaillé dans la mesure où c'est uniquement celui qu'il est nécessaire de connaître pour comprendre les cas d'usage développés ultérieurement.



FIGURE 3 – Le maillage régional de la branche ÉpiSaveurs

2.1 L'information produit

2.1.1 Utilisations de l'information produit

Conformité réglementaire

La gestion de l'information produit est essentiellement une contrainte réglementaire à satisfaire. Comme mentionné au préambule, la réglementation autour de l'information des consommateurs s'est sans cesse complétée au cours des dernières années. Un des textes centraux est le règlement n°1169/2011 dit INCO (INformation COnsommateur)[3][4]. C'est ce règlement qui définit l'ensemble des informations qui doivent être étiquetées sur le produit (liste d'ingrédients, tableau de données nutritionnelles, ...), mais également affichée au client lors de commande en ligne sur les sites de e-commerce. Il s'agit principalement d'informations relatives à la sécurité alimentaire (ex : les allergènes) ou la santé (ex : informations nutritionnelles).

Attentes client

Les consommateurs finaux (les « convives ») étant de plus en plus sensibles au contenu de leur assiette, les clients du groupe sont de plus en plus demandeurs d'informations relatives aux produits qu'ils commandent. Ils demandent donc régulièrement des informations qui vont au-delà de ce qui est normalement prévu par la réglementation.

De plus, sur certains marchés pour lesquels des contrats courent sur de longues périodes - jusqu'à un an - sont établis (les marchés publics sont très concernés), il n'y a pas d'échantillonnage des produits. La seule manière pour ces clients d'évaluer la qualité des produits est de se référer aux documents contenant les informations produit, fournis par les distributeurs.

Gestion

Certaines informations relatives aux produits sont nécessaires pour des raisons de gestion administrative. Par exemple, la gestion des taxes sur les produits alimentaires est complexe :

- les taux de TVA sont variables en fonction du type de produit
- des taxes spécifiques s'appliquaient aux produits contenant de l'huile ou de la farine
- des règlements particuliers s'appliquent aux alcools
- ...

D'autres informations, comme la nomenclature douanière, sont nécessaires pour effectuer les déclarations auprès des douanes européennes.

Un autre type d'information capital pour la gestion des flux d'achat et de vente sont les informations logistiques, qui définissent par exemple le nombre d'unités consommateur dans le colis, le nombre de colis sur une palette, ... Une gestion rigoureuse de ces informations est indispensable pour que les flux d'achat

ou de vente soient correctement exécutés (que les quantités commandées soient les bonnes, que les montants facturés soient corrects, ...).

2.1.2 Des produits bruts aux produits transformés

Le niveau d'exigence en termes d'information produit est variable en fonction du niveau de transformation de ce produit. Par exemple, sur des fruits et légumes frais, à peu de choses près seul le pays d'origine doit être affiché au client. Sur une barre chocolatée, ou un plat cuisiné, il sera nécessaire d'afficher :

- une liste d'ingrédients (mettant en évidence les allergènes)
- un tableau de données nutritionnelles (protéines, glucides, ...)
- une dénomination réglementaire

2.1.3 Les grands types d'information

On se focalisera dans ce paragraphe sur les informations relatives aux *produits alimentaires*.

La composition

La première grande famille de données réglementaires sont les données de composition. Elles détaillent quels sont les ingrédients qui sont mis en oeuvre dans la fabrication des produits. Évidemment, la composition a en général plus de sens pour les produits transformés que pour les produits bruts. Elle peut prendre la forme d'un texte listant la liste des ingrédients (l'étiquetage de ce texte est en général obligatoire sur les emballages des produits), ou d'un tableau.

Les ingrédients incluent également les additifs. Il s'agit de substances ajoutées à la recette pour répondre à des fonctions particulières (colorant, exhausteur de goût, émulsifiant, ...). Elles ne représentent en général qu'un pourcentage en masse négligeable dans la composition totale du produit.

Le pourcentage en masse est parfois inclus sur certains ingrédients. La réglementation l'oblige dans certains cas, par exemple quand l'ingrédient en question est mentionné dans la dénomination du produit (pour une *tarte aux framboises*, la proportion de framboise doit être mentionnée dans la composition).

Enfin, un aspect à la fois réglementaire et particulièrement important est la présence d'allergènes dans la composition. Le règlement INCO[3][4] impose de mettre en évidence les allergènes relevant d'une des 14 catégories suivantes :

1. Céréales contenant du gluten, à savoir blé, seigle, orge, avoine, épeautre, kamut ou leurs souches hybridées, et produits à base de ces céréales
2. Crustacés et produits à base de crustacés
3. Œufs et produits à base d'œufs
4. Poissons et produits à base de poissons
5. Soja et produits à base de soja

6. Lait et produits à base de lait (y compris le lactose)
7. Fruits à coque, à savoir : amandes, noisettes, noix, noix de cajou, noix de pécan, noix du Brésil, pistaches, noix de Macadamia ou du Queensland, et produits à base de ces fruits
8. Céleri et produits à base de céleri
9. Moutarde et produits à base de moutarde
10. Graines de sésame et produits à base de graines de sésame
11. Anhydride sulfureux et sulfites
12. Lupin et produits à base de lupin
13. Mollusques et produits à base de mollusques

Il peut y avoir deux niveaux de présence d'un allergène dans un produit (au-delà de la simple absence) :

intentionnellement mis en oeuvre : dans le cas où un ingrédient allergène fait volontairement partie de la recette. Ex : présence de moutarde dans un plat cuisiné.

contamination croisée : par exemple lorsque le produit fini est issu d'une chaîne de transformation qui traite un ingrédient allergène, mais que cet ingrédient ne fait pas partie de la recette. Ce cas de figure est en général mis en évidence par des mentions telles que *"Peut contenir des traces de soja"* ou bien *"Transformé dans un atelier processant également des fruits à coques et du sésame"*.

Les informations nutritionnelles

Une autre grande famille d'information produit sont les informations nutritionnelles. Elles détaillent la quantité des principaux nutriments contenus dans les produits. Certains d'entre eux sont rendus obligatoires par le règlement INCO [3][4] cf. l'exemple de tableau à la TABLE 1 page 15, et d'autres sont optionnels, comme par exemple la quantité de fer, de calcium, ...

Informations nutritionnelles	Pour 100g	Pour un biscuit	% des AJR pour un biscuit
Énergie	1674 kJ 398 kcal	209 kJ 50 kcal	3 %
Protéines	3.0 g	1.0 g	3 %
Matières grasses	13.0 g	1.6 g	2 %
dont acides gras saturés	5.8 g	0.7 g	4 %
Glucides	66 g	8.2 g	3 %
dont sucres	48 g	6.1 g	7 %
Fibres alimentaires	2.5 g	0.3 g	
Protéines	3.3 g	0.4 g	1 %
Sel	0.41 g	0.05 g	1 %

TABLE 1 – Exemple de tableau de données nutritionnelles

La réglementation rend obligatoire de mentionner les informations nutritionnelles de cette table pour 100g, ou 100mL de produit (pour les boissons).

Les informations nutritionnelles peuvent également se présenter sous forme d’allégations, qui ont des définitions précises dans la réglementation. Ces allégations peuvent être : *sans sel, faible en sucres, riche en fibres, ...*

Les origines

Du fait de la complexification des opérations de transformation et de la complexification des flux d’échanges de marchandises, l’origine des produits alimentaires est une notion qui n’est pas définie avec précision dans l’absolu. Il n’y a donc pas non plus de réglementation précise sur le sujet, si ce n’est que l’information produit doit toujours être présentée de manière loyale au consommateur. On peut se donner une règle simple pour définir l’origine d’un produit alimentaire : plus il est brut, plus va compter l’origine de ses ingrédients ; plus il est transformé, plus va compter le lieu de dernière transformation.

Par exemple, sur des morceaux piécés de viande fraîche, on aura des origines multiples en fonction du pays de naissance, d’élevage ou d’abattage de la bête. Et à l’inverse, sur un steak haché cette information n’aura aucun sens dans la mesure où il est produit d’un assemblage de « minerais » pouvant provenir de multiples pays. L’industriel pourra choisir de communiquer sur le fait que la viande a été transformée en steak dans telle usine par exemple.

Les données logistiques

On appelle données logistiques essentiellement le plan de palettisation et de conditionnement du produit. Il s’agit de la définition de la « hiérarchie logistique » du produit. Cette hiérarchie se base d’abord sur la définition d’une « unité de base » qui est la plus petite unité légalement détaillable (i.e. qui porte l’ensemble des informations réglementaire pour sa commercialisation). Ces notions ont été standardisées par l’organisme international de standardisation GS1[6]. Deux exemples pour illustrer :

- pour un boîte de sachets de thé, l’unité de base est la boîte car les sachets de thé ne portent pas les informations nécessaires à leur commercialisation
- pour un paquet de barres chocolatées (comme celles qu’on peut trouver au détail en boulangerie), l’unité de base est la barre car elle porte l’ensemble des mentions réglementaires sur son emballage

La hiérarchie logistique est à la fois :

- la définition des niveaux successifs d’emballage des produits : combien d’unités de base dans un paquet, combien de paquets dans un carton, combien de cartons sur une palette, ...
- la définition du contenu de l’unité de base (ex : le nombre de sachets de thé, le nombre de doses dans une boîte d’aides culinaires, ...)

Les données logistiques concernent également les durées de vie du produit (qu’il s’agisse de Date Limite de Consommation ou Date de Durabilité Minimale) :

- la durée de vie totale à fin de production
- la durée de vie garantie à la livraison

Parfois, certaines contraintes d’approvisionnement peuvent être mentionnées :

- unités commandables (ex : on ne peut commander que des cartons complets)
- multiples de commande (ex : on ne peut commander les cartons que 10 par 10 pour des raisons de montage des palettes)
- minimum de commande (ex : il faut commander au minimum 30 cartons)

mais elles sont dépendantes d’un accord entre l’industriel et son client distributeur et ne sont donc pas à proprement parler des informations produit.

Les données administratives et financières

Les données dites administratives et financières regroupent le reste des informations de gestion pour lesquelles il existe des contraintes réglementaires. Il s’agit :

- du taux de TVA du produit
- de sa nomenclature douanière et du pays d’origine au sens de la déclaration d’échange de biens[5]
- de toute autre taxe applicable au produit

Les labels

Afin de garantir des qualités spécifiques à certains produit, des organismes de certification ont mis en place des labels pouvant s’appliquer aux produits. En général, ils se basent sur des cahiers des charges et peuvent être assortis d’audits de certification ou de contrôle. Ils peuvent garantir des méthodes de production ou transformation, des lieux de production, des caractéristiques de leurs ingrédients, des pratiques commerciales équitables, ... Les types de labels les plus connus sont :

- les produits Biologiques
- les origines protégées (Appellation d’Origine Protégée, Indication Géographique Protégée, *viandes* de France, Bleu Blanc Cor, Régions UltraPériphériques d’Europe...)
- les pratiques commerciales équitables (Max Havelaar, ...)
- les modes de production respectueux de l’environnement (Aquaculture Stewardship Council, Marine Stewardship Council, Roundtable on Sustainable Palm Oil, Nordic Swan, ...)
- la qualité « générale » des produits (Label Rouge, ...)

Les données marketing

Certaines données marketing font également partie de l’information produit. La plus évidente est la marque commerciale du produit, qui parfois définit totalement le produit. Par exemple, on sait ce qu’est un Snickers, de la Mousline, du Nutella, ... Les produits peuvent également porter d’autres allégations marketing, non réglementaires ou labelisantes : Élu produit de l’année, Vu à la télé, Issu de notre savoir-faire centenaire, ...

2.2 Le processus

2.2.1 Le fournisseur est propriétaire des informations produit

Comme présenté à la section 1.1 page 6, le Groupe Pomona n'a pas d'activité de fabrication ou de transformation de marchandises. À ce titre, l'ensemble des données produits ne peuvent être déterminées que par les fournisseurs de ces produits. L'ensemble des entités du groupe s'appuient donc sur les données transmises par les industriels ou producteurs de marchandises.

Il peut arriver que certains produits soient achetés par Pomona à d'autres négociants non-producteurs. Dans ce cas, de la même manière que le groupe Pomona a la responsabilité de collecter puis transmettre les informations produit à ses clients, ces fournisseurs négociants doivent eux-même aller chercher l'information produit et la transmettre à Pomona.

Dans tous les cas, c'est le fournisseur qui est responsable de produire et de transmettre l'information produit aux entités du groupe Pomona.

2.2.2 La notion de produit et d'article

Un mot sur la modélisation des données adoptée est nécessaire pour comprendre les grandes lignes du processus. Comme il a été vu à la section 1.2.3 page 8, certains produits sont susceptibles d'être commercialisés par plusieurs branches du groupe.

De plus, du fait que les systèmes d'information ne sont pas identiques entre les branches, certaines contraintes imposent parfois des différences de modélisation, des duplications volontaires de codes pour répondre à ces contraintes. Une illustration de ce point pour clarifier : la facturation client pour une canette de soda peut se faire au litre (permet de comparer les prix entre les différents conditionnement et les différentes marques) ou à la canette (permet de se faire une idée du coût portion d'un produit). Or, la possibilité de pouvoir facturer un même article dans plusieurs unités différentes n'est pas une fonctionnalité offerte par tous les systèmes d'information. En particulier, ÉpiSaveurs peut gérer dans ce cas un unique article et le facturer dans l'unité de son choix en fonction des demandes des clients. Mais Délice et Création (qui possède un système d'information différent) doit dupliquer cet article car une seule unité de facturation est possible pour un article donné.

Enfin, au-delà des contraintes liées au SI, certaines pratiques imposent de laisser aux branches une indépendance forte dans la gestion de leurs référentiels articles. Il faut savoir que commercialiser sous un même code article des produits qui sont similaires permet d'obtenir des gains de productivité à plusieurs niveaux :

- on économise des emplacements en entrepôt (un emplacement ne peut contenir qu'un article)
- on gagne du temps administratif dans la gestion des prix : le foisonnement d'articles impose de gérer plus de prix client

— ...

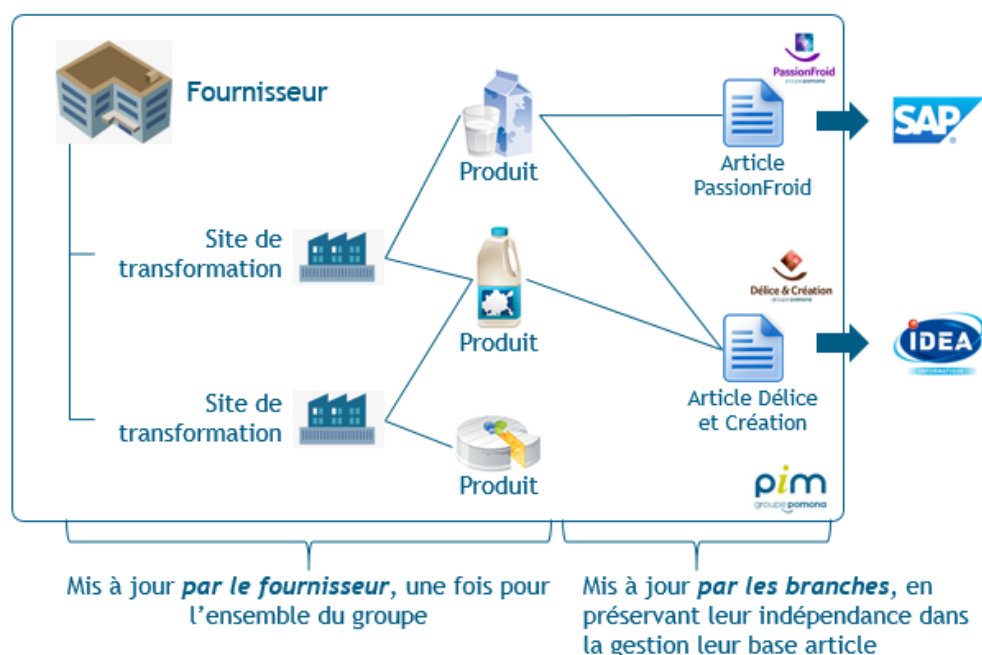
La contrepartie à adopter cette pratique est qu'il n'est alors plus possible de différencier ces produits similaires, par exemple pour leur appliquer des prix de vente distincts, ou bien offrir la possibilité à un vendeur de garantir au client la livraison d'un produit plutôt que l'autre. Néanmoins, en fonction de la clientèle adressée, certains produits pourront être considérés comme similaires, alors que pour d'autres ils ne seront pas interchangeables. Cet exemple est détaillé dans la FIGURE 4 page 19.

On différencie donc les deux notions suivantes :

les produits : ils représentent une marchandise physique produite par un fournisseur. Ce sont les produits qui portent les *informations produit* décrites à la section 2.1.3 page 14. Un produit ne peut appartenir qu'à un seul fournisseur. Le référentiel produit est unique pour l'ensemble du groupe.

les articles : ce sont les objets qui sont gérés par les branches dans leurs systèmes de gestion respectifs. Leurs attributs sont très liés au système d'information qui les porte. Chaque branche gère de manière autonome son référentiel article, incluant les liens qui sont faits entre produits et articles.

Cette modélisation permet de répondre à l'ensemble des contraintes présentées dans ce paragraphe.



Dans cet exemple fictif, le type de conditionnement du lait n'a aucun impact sur les clients de la branche Délice et Création. Elle commercialise donc sous un même code article deux produits distincts.

Pour des raisons de contrainte de conservation, la branche PassionFroid a quant à elle choisit de ne commercialiser qu'un seul produit - en brique. Elle pourrait choisir d'ouvrir un nouveau code article pour le lait en bouteille (non représenté sur le schéma ci-dessus).

FIGURE 4 – La distinction entre produit et article

2.2.3 Les acteurs

L'acheteur

L'acheteur peut être en succursale, ou à la centrale d'achat de la branche (cf. 1.2.3 page 8 et 1.2.4 page 11). Il est responsable de l'assortiment, i.e. des articles qui sont commercialisés par sa branche, ou sa succursale. Il est à l'origine de la création d'un nouveau produit, dans la mesure où c'est lui qui va décider de le référencer ou pas. La gestion de l'information produit ne représente qu'une petite partie de l'ensemble de ses responsabilités (qui peuvent inclure négociations fournisseurs, gestion du sourcing, gestion des approvisionnements, prévisions d'évolution des prix, ...).

Le fournisseur

Il a été vu que le Groupe Pomona - dans sa qualité de distributeur - n'est pas en mesure de déterminer seul les informations produit sur les marchandises qu'il commercialise. À ce titre, les équipes des fournisseurs sont en charge de transmettre les informations produit à Pomona. En général, ce sont deux types de profil qui effectuent cette tâche :

- les commerciaux (aux sens large, incluant les assistants commerciaux)
- les ingénieurs qualité

Le gestionnaire de référentiel - SEGER

Le gestionnaire de référentiel travaille au Service de Gestion des Référentiels (SEGER), qui sont des équipes positionnées au niveau des branches (cf. 1.2.3 page 8). Ils sont responsables de la qualité des données dans les référentiels métier (articles, fournisseurs, clients, ...). La gestion des données de base dans les référentiels est leur mission principale.

L'ingénieur qualité

L'ingénieur qualité travaille à la DQSE ou en succursale (cf. 1.2.1 page 7 et 1.2.4 page 11). Dans le processus de gestion de l'information produit, il est en charge de contrôler la qualité des données, mais également leur conformité réglementaire (ex : on ne peut qualifier un produit de « faible en sel » que s'il comporte moins de n grammes de sel pour 100 grammes de produit.) La gestion de l'information produit ne représente qu'une partie des responsabilités de l'ingénieur qualité.

2.2.4 Les contrôles

Comme cela a été vu dans la section 2.1.1 page 13, il est nécessaire que les différentes entités du groupe soient en possession d'une information produit fiable. Or, avoir des données de qualité nécessite des efforts de la part des métiers, en particulier lorsque le processus n'est pas entièrement porté en interne dans la société.

À ce titre, plusieurs étapes de contrôle ont été définies dans le processus de gestion du référentiel de données produit et article :

lorsque le fournisseur a saisi les données produit : la personne à l'origine de la demande de référencement (en général, un acheteur) doit contrôler la cohérence des données produit

lorsque le demandeur a demandé la création d'un article : le gestionnaire de référentiel valide à nouveau la cohérence des informations produit

après la création article, de manière asynchrone : le service qualité contrôle par échantillonnage les données d'une partie des produits et articles qui ont été modifiés pendant une période.

Le retour d'expérience montre que ces contrôles, loin d'être redondants, sont nécessaires pour avoir une qualité de données acceptable. Ces processus de contrôle sont décrits à la FIGURE 5 page 22.

Les contrôles effectués à chacune des étapes sont les suivants :

contrôle de la complétude des données : vérification que les données transmises comportent l'ensemble des données attendues

contrôle de cohérence entre les données : vérification que les informations transmises sont cohérentes entre elles (ex : un allergène présent dans la liste d'ingrédients du produit a bien été signalé comme allergène par ailleurs)

contrôle de la cohérence avec les pièces jointes : en plus de données structurées, les fournisseurs transmettent également des fichiers portant des informations produit (ex : l'étiquette produit ou le visuel de l'emballage). Ces pièces jointes sont décrites à la section 4.3 page 39. La personne en charge du contrôle vérifie que les données transmises sont cohérentes avec ces documents.

2.3 Les outils informatiques associés

Comme vu dans la description des branches du groupe (voir section 1.2.3 page 8), les outils informatiques ne sont pas tous les mêmes sur l'ensemble des branches. Ainsi, les outils utilisés pour la gestion de l'information produit ne sont pas les mêmes.

2.3.1 Les branches faiblement outillées

Les branches étrangères (Pomona Suisse, Pomona Iberia), spécialistes (Délice et Création, Saveurs d'Antoine) et la branche TerreAzur sont aujourd'hui faiblement outillées. Cela signifie que l'information produit est en général stockée uniquement sous la forme de fichiers (essentiellement les pièces jointes, décrites à la section 4.3 page 39). L'ensemble des échanges avec les fournisseurs se font par mail, et les articles sont créés directement dans les systèmes de gestion par les gestionnaires de référentiel. Les liens entre les articles et les informations produit ne sont pas matérialisés dans les systèmes informatiques.

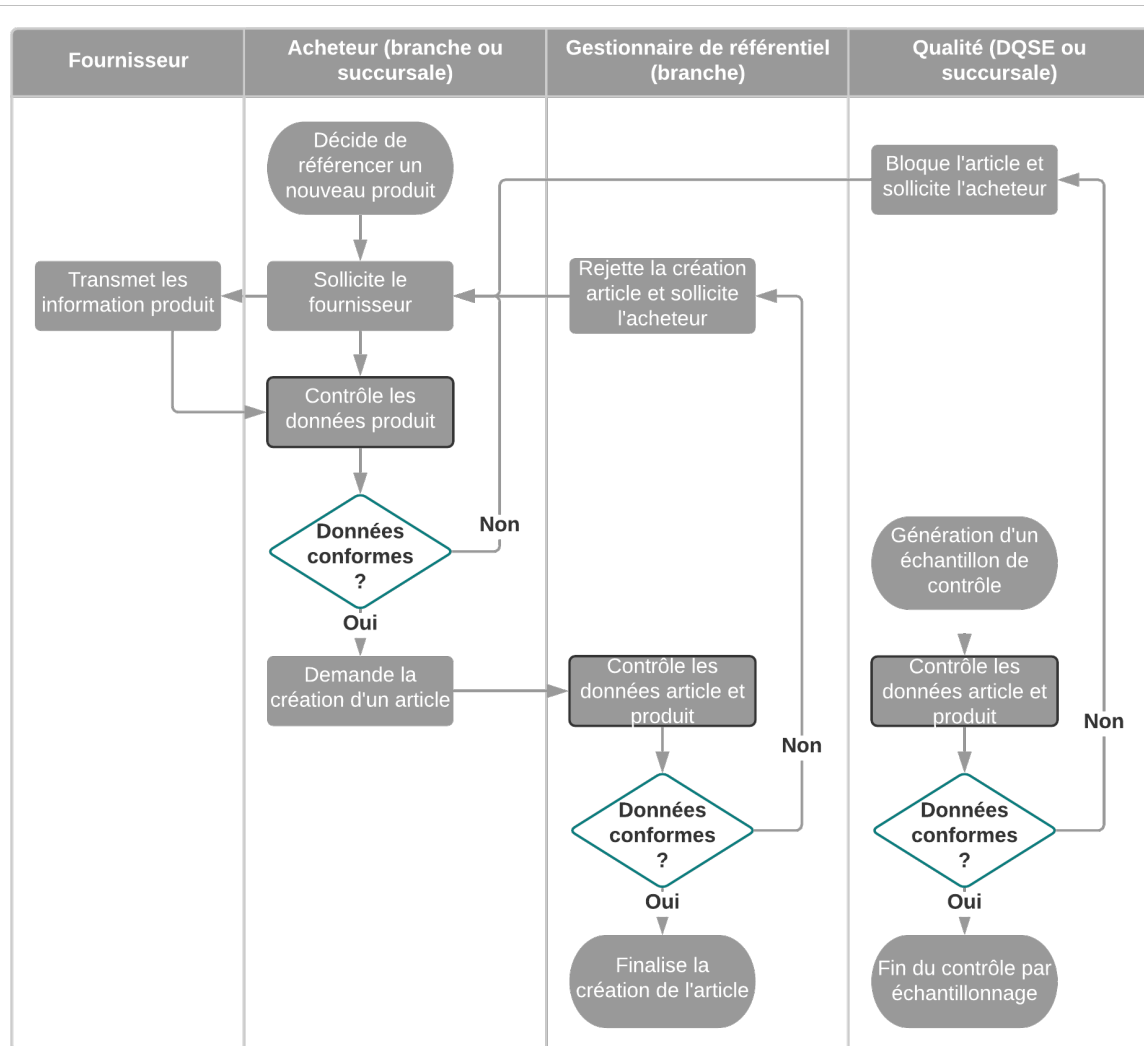


FIGURE 5 – Le processus de création article

2.3.2 Le GIP

Le GIP (Gestion de l'Information Produit) est utilisé sur la branche PassionFroid. C'est un système de gestion de l'information produit qui est maintenant obsolète et en cours de remplacement. Il a toutefois le mérite de permettre le stockage dans une application des données et des pièces jointes relatives aux produits, avec la possibilité d'accéder aux informations produit à partir des identifiants des articles. C'est ce système qui a permis de pouvoir alimenter les sites de e-commerce PassionFroid et ÉpiSaveurs avec les informations produit. Il est toutefois ancien, et ne propose pas de fonctionnalité d'export en masse fiable. Il s'agit d'une application qui n'est pas ouverte aux utilisateurs externes au groupe, et les échanges avec les fournisseurs passent donc par des échanges de mails.

2.3.3 Le PIM

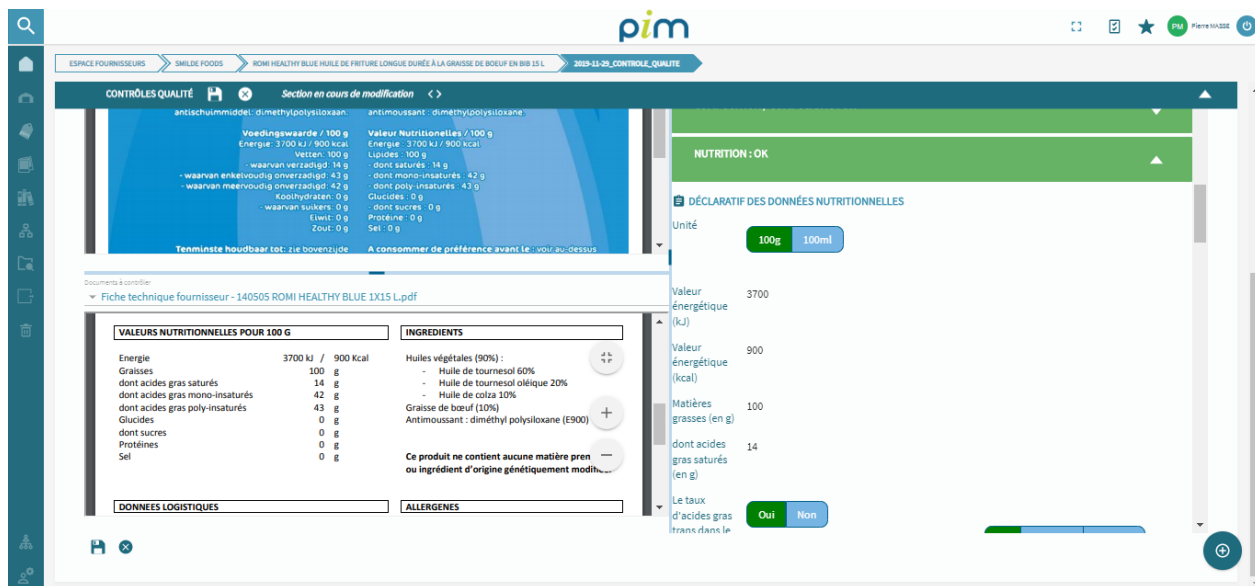
Le PIM (Product Information Management) est un système de gestion de l'information produit qui a été mis en production en mai 2019, pour la branche ÉpiSaveurs. Il a vocation à être déployé sur l'ensemble des branches du groupe. En terme de responsabilités, il vise à gérer la totalité des informations produit, mais également d'être maître sur les référentiels articles. Ce sera le système de référence pour tous les autres systèmes consommant de l'information produit, ou des données article.

Description générale de l'outil

C'est un système qui porte l'ensemble du processus de gestion de l'information produit, tel que décrit à la FIGURE 5 page 22. Il est accessible aux fournisseurs du groupe, qui viennent directement mettre à disposition les données et les pièces jointes. Les fonctionnalités caractéristiques de ce système par rapport à d'autres systèmes informatiques sont :

- la gestion de workflows (processus), qui permet d'orchestrer l'activité de l'ensemble des acteurs du système
- la possibilité de paramétrer un modèle de données relativement complet, avec des centaines de méta-données sur les différents objets
- la présentation de l'interface utilisateur via le navigateur, qui permet de s'adresser simplement à des acteurs hors du groupe (pas de client lourd à installer)
- la gestion performante de pièces jointes (documents informatiques) en grandes quantité
- Une gestion de versions des objets robuste, permettant d'auditer l'historique ou de restaurer des données dans un état précédent

Cet outil porte entre autres les fonctionnalités de contrôle des informations, comme illustré à la FIGURE 6 page 24. L'intégration du PIM au sein des systèmes informatiques du Groupe Pomona est décrite dans la FIGURE 7 page 24.



Cette capture d'écran montre l'outil de contrôle des données produit. Sur la partie gauche, le contenu des pièces jointes est affiché (visuel de l'emballage en haut, fiche technique en bas), sur la droite les données qui ont été transmises par le fournisseur.

FIGURE 6 – Une capture d'écran du PIM

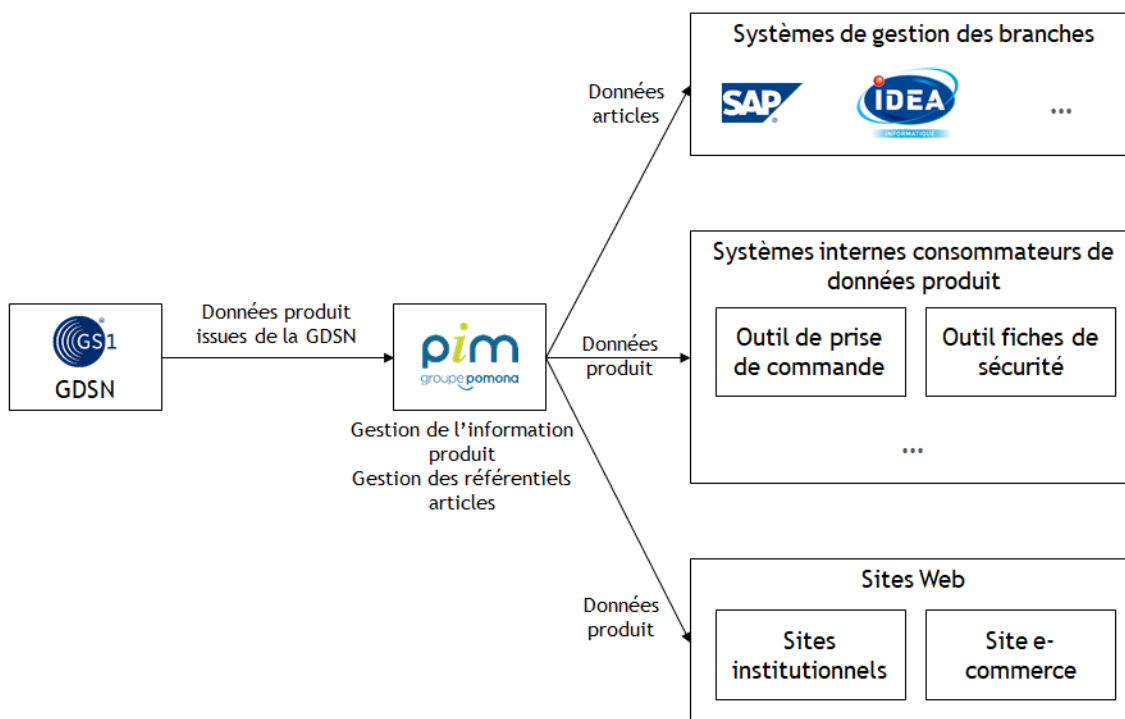


FIGURE 7 – L'intégration du PIM au sein des systèmes du Groupe Pomona

La GDSN

La GDSN (Global Data Synchronization Network) est un réseau d'échange de données produit entre industriels, distributeurs, restaurateurs, ... Ce réseau est exploité par des opérateurs privés, mais le format et la chorégraphie des échanges ont été standardisés par l'organisme de standardisation GS1. Son schéma de principe est décrit à la FIGURE 8 page 25. Sans rentrer dans le détail, au sein du Groupe Pomona l'utilisation qui en est faite est de récupérer les informations depuis ce réseau d'échange, afin de préalimenter les données produit pour les fournisseurs. Cette fonctionnalité permet de faire gagner du temps aux fournisseurs pour leur éviter une partie de ressaisie, mais également de limiter les erreurs. Toutefois, cette fonctionnalité ne permet pas à elle seule de garantir une parfaite qualité de données. Il s'agit uniquement d'un « tuyau », si les données en entrée ne sont pas correctes, elles ne seront pas correctes en sortie. Pour aller plus loin dans la compréhension de ce réseau, il est possible de consulter les ressources mises en ligne par GS1 [7][8].

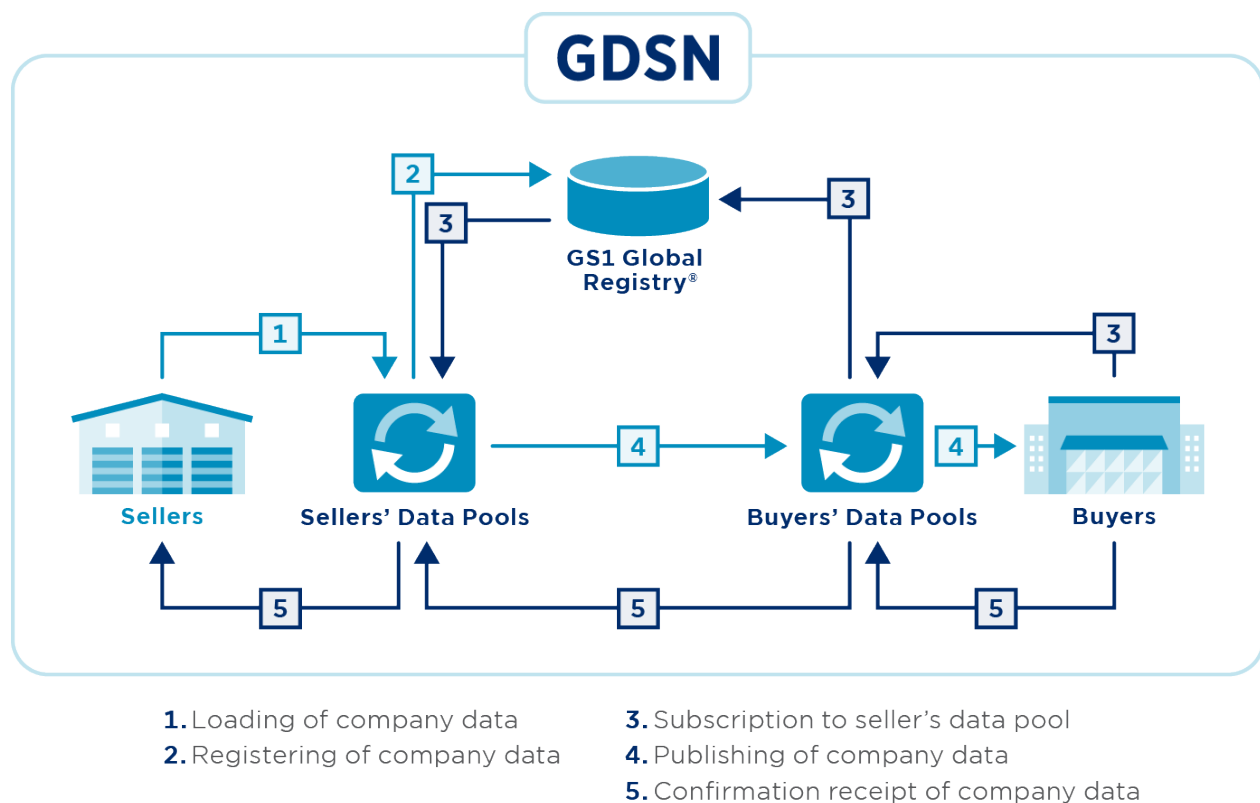


FIGURE 8 – Schéma de principe de la GDSN

L'identification des objets dans le PIM

Un dernier point à connaître à propos du PIM, est la manière d'identifier l'ensemble des objets en son sein. Chaque objet géré (ainsi que toute version archivée) porte un identifiant unique, nommé *uid* qui est totalement univoque. Pour la suite, on se basera sur ces uid pour faire référence à des produits stockés dans

le PIM. Une illustration est présentée à la FIGURE 9 page 26.



L'uid du produit affiché est mis en évidence dans l'url

FIGURE 9 – L'uid d'un produit

Les API

Un des aspects intéressants du PIM pour l'exploitation en masse des données produit, est qu'il expose des API permettant d'aller requêter l'ensemble de son contenu. Cela concerne à la fois les données dites structurées, mais également les pièces jointes. Cela rend les données produit de la branche ÉpiSaveurs bien plus simplement accessibles que celles des autres branches.

Deuxième partie

LES DONNÉES

Chapitre 3

LE PÉRIMÈTRE PRODUIT

3.1 Les produits non-alimentaires

Un petit aparté est nécessaire concernant les produits non-alimentaires. Si l'essentiel des produits commercialisés par les branches du groupe sont des produits alimentaires, comme évoqué précédemment une partie de l'activité commerciale se fait tout de même autour de produits non-alimentaires. Ces produits restent malgré tout destinés exclusivement aux professionnels des métiers de bouche, et il s'agit de consommables (par opposition à des articles d'électroménager, de la vaisselle non-jetable, ...).

On distingue en général deux catégories de produits non-alimentaires :

- les produits dits « d'hygiène »
- les produits dits « de chimie »

Les produits de chimie regroupent les produits qui doivent faire l'objet d'une fiche de données de sécurité au sens du règlement Européen No 1907/2006 dit « REACH » (Registration, Evaluation, Authorisation and Restriction of Chemicals) [2].

On appelle produits d'hygiène tous les autres produits non-alimentaires. L'appellation « d'hygiène » est donc réductrice, dans la mesure où cette large famille regroupe les consommables de nettoyage (éponges, papiers absorbants, ...) mais également tout type d'autres consommables (serviettes de tables, gobelets en plastiques, pics à brochettes, boîtes de produits à emporter, ...).

<i>La commercialisation de produits non-alimentaires existe au sein du groupe, mais on se focalisera pour la suite sur les produits alimentaires qui reste le coeur de métier.</i>
--

3.2 Accessibilité de la donnée en fonction des branches

Comme vu à la section 2.3 page 21, les systèmes d'information associés à la gestion de l'information produit offrent des niveaux d'accès hétérogènes à la donnée produit. Le récapitulatif par branche est le suivant :

ÉpiSaveurs : on peut simplement accéder à l'ensemble des données produit, structurées, non structurées (i.e. textes longs) et pièces jointes

PassionFroid : on a uniquement la possibilité d'exporter manuellement les données structurées articles depuis le système de gestion SAP. Elles permettent de produire quelques analyses quantitatives. Il est difficile de faire des exports en masse de l'outil de gestion de l'information produit GIP (cf. section 2.3.2 page 23).

TerreAzur : idem PassionFroid, si ce n'est qu'en plus le système GIP n'est pas utilisé au sein de cette branche.

Délice et Création : le système d'information ne permet pas d'exporter les données et donc de produire des indicateurs détaillés. On peut toutefois avoir des informations quantitatives de la part des opérationnels.

Saveurs d'Antoine : idem Délice et Création

Pomona Suisse : la branche est en cours de structuration, et les référentiels articles ne sont pas partagés entre les succursales. Il n'est pas possible d'obtenir d'information quantitative sur ces données.

Pomona Iberia : idem Pomona Suisse

Pour les analyses quantitatives, on pourra se baser sur des extractions uniquement pour les branches RHD (ÉpiSaveurs, PassionFroid, TerreAzur). L'ensemble des analyses portant sur les branches RHD sont produites sur la base d'extractions de leur système de gestion SAP.

3.3 Analyses quantitatives

Les graphes de cette section ont été produits via le code présenté en annexe, au chapitre C.1 page 67. Les données pour les branches spécialistes (Délice et Création et Saveurs d'Antoine) sont issues d'informations fournies par le métier, hors système. Dans l'ensemble de cette section, on raisonnera à la maille *article* (cf. la définition article vs. produits, présentée à la section 2.2.2 page 18).

3.3.1 Comparatifs entre les branches


En termes de volumétrie article (cf. FIGURE 10 page 29, c'est TerreAzur qui possède le référentiel le plus étendu (environ 62 000 articles de marchandises actifs). Cela s'explique par le fait que cette branche commercialise essentiellement des produits bruts, non-préemballés (ex : des caquettes de fruits ou de légumes). Or, ces produits ne sont pas clairement identifiés, par exemple par un GTIN. Au démarrage de SAP pour

cette branche, afin de limiter la charge sur les gestionnaires de référentiels, le parti a été pris de créer en avance de phase l'ensemble des articles susceptibles d'être commercialisés. Cela s'est traduit par la création d'un grand nombre d'articles, du fait de l'application « brutale » de la combinatoire des différents critères pouvant définir un produit. Un exemple (fictif) serait, sur les pommes :

- 8 variétés possibles (Gala, Golden, ...)
- 4 calibres possibles
- 6 conditionnements possibles (plateau 6kg, plateau 4,5kg, ...)
- 2 catégories (I, II)
- 8 origines (France, Espagne, ...)

ce qui donne un total de 3072 articles uniquement sur cette gamme de produits.

Viennent ensuite PassionFroid, et ÉpiSaveurs, qui sont les autres « grosses » branches historiques du Groupe.



Branche	Total	Actifs	Marchandises
PassionFroid	48478	24898	24554
EpiSaveurs	22498	12798	12241
TerreAzur	73804	62789	62710
Délice et Création	10000	-	-
Saveurs d'Antoine	12000	-	-

TABLE 2 – Volumétrie article par branche

FIGURE 10 – Volumétrie article par branche

Une analyse du recouvrement des référentiels montre que dans l'ensemble, les branches ne travaillent pas les mêmes articles (cf. FIGURE 11 page 30). PassionFroid commercialise certains produits des branches ÉpiSaveurs et TerreAzur, mais cela s'explique par une petite entité luxembourgeoise qui travaille des produits de tout type de stockage. Une réserve toutefois par rapport à cette analyse de recouvrement produit : elle sous-estime vraisemblablement lesdits recouvrements, dans la mesure où la présence de doublons n'est pas prise en compte.

3.3.2 Les grands types de produits

Comme montré à la FIGURE 12 page 31, on voit bien (en plus du fait que les articles étaient peu partagés entre les branches) que :

- les deux types d'articles (négoce et presté) sont utilisés par les 3 branches
- c'est tout de même PassionFroid qui fait l'utilisation majoritaire d'articles prestés

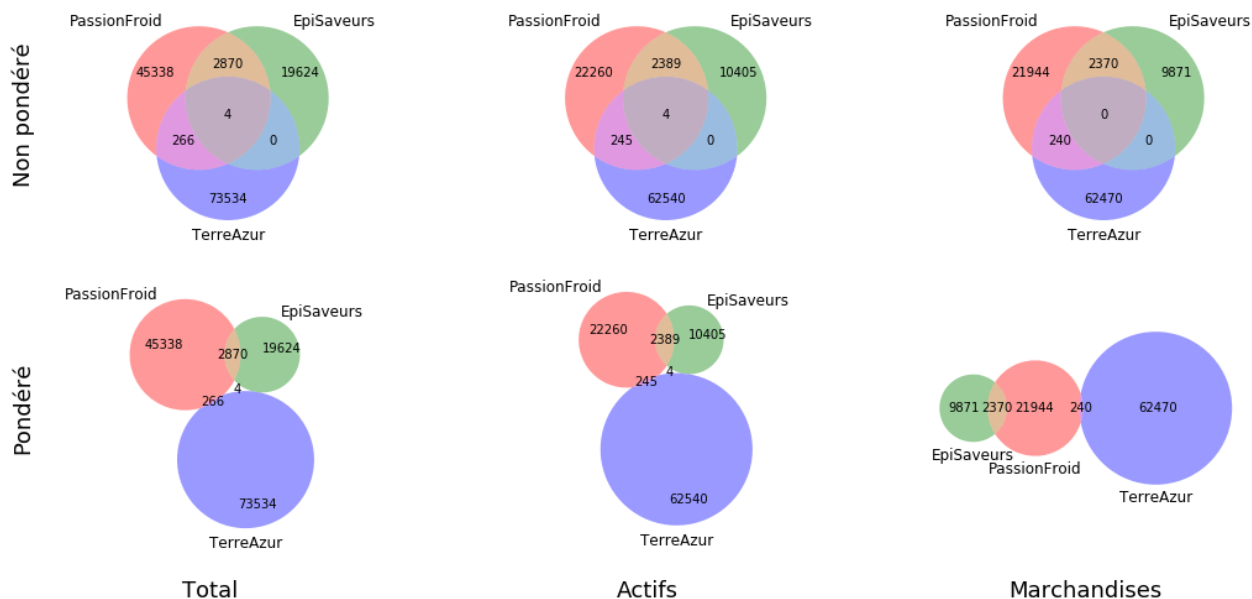


FIGURE 11 – Recouvrements entre branches RHD

- les branches *ne* partagent *pas* l'utilisation des autres « catégories » (groupe de marchandises, conditions de stockage, hiérarchie produit, ...)

Les indicateurs sont également récapitulés dans la TABLE 3 page 32.

Possibilité d'extension : - ajouter la vision produit (via les FIA) - faire une sorte d'heatmap qui montre la forte corrélation entre les différentes variables catégorielles (et les définitions associées. Ex : ZELAB + SA = Saurisserie, etc...)

Chapitre 4

LES DONNÉES UTILISABLES, ISSUES DU PIM

Comme vu au chapitre 3 page 27, les données produit ne sont simplement accessibles que pour la branche ÉpiSaveurs. On se focalisera donc sur cette branche pour la suite de cette étude, ainsi que sur les produits alimentaires (en excluant donc les produits d'hygiène et de chimie, cf. section 3.1 page 27). Contrairement au chapitre précédent, ici on travaillera à la maille *produit* (cf. la distinction produit vs. article section 2.2.2 page 18). L'ensemble des tableaux et graphes de ce chapitre ont été produit via le notebook "Analyse des données du

Répartition des articles selon les features catégorielles




FIGURE 12 – Répartition des articles en fonction des variable catégorielles

Branche Type de produit	PassionFroid	EpiSaveurs	TerreAzur	Total
ZNEG - Article de négoce	17166	11048	61273	89487
ZPRE - Article de prestation	7388	1193	1437	10018

Branche Groupe de marchandises	PassionFroid	EpiSaveurs	TerreAzur	Total
ZSURGE - Surgelés	7756	-	-	7756
ZFRAIS - Frais	13785	6	4	13795
ZEPI - Epicerie	2298	8305	-	10603
ZBOI - Boissons	126	826	-	952
ZHYG - Hygiène	350	3078	-	3428
ZFLF - Fruits et Légumes	4	-	44133	44137
ZPMF - Produits de la mer	142	-	11594	11736
ZELAB - Produits élaborés	91	-	6644	6735
ZFP - Fleurs et plantes	-	-	297	297
ZAUTRE - Autres	2	26	38	66

Branche Condition de stockage	PassionFroid	EpiSaveurs	TerreAzur	Total
SU - Surgelés	7758	-	-	7758
FR - Frais	13781	6	3	13790
EP - Epicerie	2430	9155	-	11585
HY - Hygiène	344	3080	-	3424
FL - Fruits et légumes	78	-	49508	49586
MA - Marée	126	-	10501	10627
FP - Fleurs et plantes	-	-	286	286
SA - Saurisserie	34	-	2408	2442
PL - Publicité	2	-	1	3

Branche Niveau 1 hiérarchie produit	PassionFroid	EpiSaveurs	TerreAzur	Total
10 - Beurre, oeufs, fromage	3010	6	1	3017
20 - Elaborés	4150	2	6	4158
30 - Garnitures et fruits	1701	-	-	1701
40 - Produits carnés	11413	-	-	11413
50 - Produits de la mer	1214	-	2	1216
60 - Consommables	1	-	-	1
70 - Emballage	-	1	-	1
80 - Publicité sur le lieu de vente	34	25	37	96
83 - Epicerie	2306	8296	-	10602
85 - Liquides	135	836	-	971
87 - Hygiène et entretien	348	3075	-	3423
90 - Services	10	-	-	10
92 - Fruits	35	-	26543	26578
94 - Légumes	37	-	22929	22966
96 - Produits de la mer Frais	160	-	12891	13051
98 - Fleurs - plantes	-	-	301	301

TABLE 3 – Utilisation des variables catégorielles article au sein des branches RHD

PIM", présenté en annexe C.4 page 90.

4.1 Données structurées

4.1.1 Description des données structurées

Les données dites structurées sont l'ensemble des données qui peuvent prendre leurs valeurs dans un domaine restreint. Par exemple, ce sont les données booléennes, les choix issus de listes déroulantes, les valeurs numériques. . . Les principales données structurées pour les produits alimentaires dans le PIM sont :

le code du produit : calculé par le système

le fournisseur : référence croisée vers le code du fournisseur

le type de produit : épicerie, boisson alcoolisée, hygiène, chimie, boisson non-alcoolisée

le GTIN du produit : identifiant numérique unique, utilisé entre autres pour l'étiquetage sous forme de code à barres [9]

le type d'unité de base : paquet, boîte, sachet, rouleau, bouteille, pot, . . .

les poids : brut, net, net égoutté (pour les conserves)

le volume : pour les produits liquides

les durées de vie : le type (Date Limite de Consommation ou Date de Durabilité Minimale) et la durée (totale à fin de production, garantie à livraison)

les modes de conservation avant/après ouverture : à température ambiante, au réfrigérateur puis à consommer sous 2 jours, . . .

les labels : le(s) label(s) s'appliquant au produit (cf. section 2.1.3 page 17)

les régimes particuliers : Halal, Casher, Sans porc, Végétarien, Végétalien, . . .

les caractéristiques spéciales : sans OGM, non traité par ionisation

la présence d'allergènes : le niveau de présence de chacun des 14 allergènes réglementés (cf. section 2.1.3 page 14) : absence, présence ou traces

les matières grasses utilisées : palme, beurre, coco, tournesol, palmiste, . . .

les additifs présents : les codes Exxx et les fonctions des additifs mis en oeuvre [1][11]

les données nutritionnelles obligatoires : pour 100g ou 100mL, valeur énergétique (en kJ et kcal), matières grasses, dont acides gras saturés, Glucides, dont sucres simples, Fibres, Protéines, simplement

les données nutritionnelles facultatives : vitamines, minéraux, omégas, . . .

les allégations nutritionnelles : riche en, faible en, sans, . . . associé à un nutriment défini dans les 2 points précédents

le nutriscore : note allant de A à E, définie dans la loi Santé de janvier 2016

le **taux de TVA** : un des quatre taux définis dans la réglementation française

le **code nomenclature douanière** : code identifiant les marchandises défini par les douanes pour la Déclaration d'Échange de Biens [5]

le **pays d'origine pour la DEB** : le pays d'origine à déclarer dans la Déclaration d'Échange de Biens [5]

les **informations logistiques** : il s'agit du plan de conditionnement et de palettisation du produit. Elles regroupent les différents niveaux et les quantités pour passer de l'un à l'autre (ex : 3 boîtes dans un cartons, 64 cartons dans une palette), les poids et dimensions de ces niveaux logistiques, leurs GTIN, ...

4.1.2 Analyse de ces données structurées

Données d'identification

Un exemple et une description statistique de ces données est présentées aux TABLE 5 page 36 et TABLE 6 page 36. On peut en tirer les conclusions suivantes :

- Les codes produits sont bien des identifiants uniques des produits : on a autant de valeurs uniques que de valeurs renseignées
- Une proportion importante de produits (91%) porte un GTIN (cf. [9]), ce qui reflète une « maturité » des filières produits avec lesquelles travaille ÉpiSaveurs.
- Ces GTIN sont également censés être des identifiants uniques des produits. Néanmoins, comme présenté à la FIGURE 13 page 34, il peut arriver que le même GTIN soit présent sur plusieurs produits. Quelques illustrations et explications sont présentées en annexe, dans le notebook d'analyse des données.
- La distribution numérique des produits par fournisseur est importante. Il existe plus de 600 fournisseurs pour les 13000 produits, et l'essentiel des fournisseurs n'ont qu'un nombre très limité de produits. On peut avoir une vision à la FIGURE 14 page 35 ou à la FIGURE 15 page 35.

TODO : illustrer ici les graphes suivants.




FIGURE 13 – Nombre de produits par GTIN

Nb de GTIN	
Pdt portant le GTIN	
1	11068
2	227
3	22
4	20
5	1

TABLE 4 – Nombre de produits par GTIN

TODO : continuer l'analyse par domaine de données.




FIGURE 14 – Distribution des fournisseurs par nombre de produits




FIGURE 15 – Le Pareto des produits en fonction des fournisseur

uid	Code produit	Code fournisseur	Type de produit	GTIN
1351c135-0d48-41ae-a568-2f33af6fdae9	PIMP-0000011253	PIMP-00000000416	grocery	3760063337099
ffa6f67f-314e-47a8-932e-37da7a3ab1ae	PIMP-0000011972	PIMP-00000000486	hygiene	-
7bb3d9a9-d50c-4042-9d28-21b31f5cbb1	PIMP-0000009973	PIMP-00000000328	alcoholicDrink	-
38b95b6e-5603-46bd-ad44-912a926ee0e4	PIMP-0000012507	PIMP-00000000391	chemistry	7615400045495
8738c768-9d5d-4233-b54c-993558fa66411	PIMP-00000000321	PIMP-00000000074	hygiene	3504082216054

TABLE 5 – Exemples de codes d'identification

	Code produit	Code fournisseur	Type de produit	GTIN
count	13193	13193	13193	12025
unique	13193	605	5	11339
top	PIMP-00000000721	PIMP-00000000179	grocery	
freq	1	370	8756	352

TABLE 6 – Description des codes d'identification sur le dataframe

uid	Unité de base	Poids net	Poids brut	Poids net égoutté	Volume
1351c135-0d48-41ae-a568-2f33af6fdae9	SAC	0.500	0.520	-	-
ffa6f67f-314e-47a8-932e-37da7a3ab1ae	PU	-	-	-	-
7bb3d9a9-d50c-4042-9d28-21b31f5cbb1	BIB	1.500	1.600	-	1.5
38b95b6e-5603-46bd-ad44-912a926ee0e4	BT.	1.053	1.150	-	-
8738c768-9d5d-4233-b54c-993558fa66411	COL	3.000	3.028	-	-

TABLE 7 – Exemples de dimensions

	Unité de base	Poids net	Poids brut	Poids net égoutté	Volume
count	13193	12827.000	12827.000	1026.000	1915.000
unique	30	-	-	-	-
top	BTE	-	-	-	-
freq	3051	-	-	-	-
mean	-	3.112	2.986	1.475	7.750
std	-	59.600	42.171	1.133	78.897
min	-	0.000	0.000	0.000	0.000
25%	-	0.482	0.535	0.480	0.500
50%	-	1.000	1.100	1.500	0.946
75%	-	3.000	3.298	2.380	2.500
max	-	4900.000	4730.500	10.000	3100.000

TABLE 8 – Description des dimensions sur le dataframe

uid	Durée de vie totale	Durée minimale restante	Type de conservation	Conservation avant ouv.	Conservation après ouv.	Température
1351c135-0d48-41ae-a568-2f33af6fdae9	-	720.0	AM	ambient Temperature	coolAndDryPlace	-
ffabf67f-314e-47a8-932e-37da7a3ab1ae	-	-	-	-	-	-
7bb3d9a9-d50c-4042-9d28-21b31f5cbbb1	-	-	AM	ambient Temperature	notConcerned	-
38b95b6e-5603-46bd-ad44-912a926ee0e4	-	-	AM	-	-	-
8738c768-9d5d-4233-b54c-993558fa66411	-	-	AM	-	-	-

TABLE 9 – Exemples de conservation

	Durée de vie totale	Durée minimale restante	Type de conservation	Conservation avant ouv.	Conservation après ouv.	Température
count	8946.000	9466.000	12806	9977	9947	21
unique	-	-	2	7	18	9
top	-	-	AM	ambient Temperature	coolAndDryPlace	15
freq	-	-	12772	8270	4512	6
mean	651.406	351.618	-	-	-	-
std	487.412	380.255	-	-	-	-
min	0.000	0.000	-	-	-	-
25%	360.000	180.000	-	-	-	-
50%	540.000	300.000	-	-	-	-
75%	900.000	480.000	-	-	-	-
max	9999.000	9999.000	-	-	-	-

TABLE 10 – Description des conservations sur le dataframe

4.2 Données non structurées

4.2.1 Les libellés

Plusieurs libellés permettent de faire référence à chaque produit, avec des usages distincts :

Libellé temporaire unité de besoin : il s’agit simplement d’un libellé qui est choisi par la personne à l’origine de la demande de référencement produit (souvent l’acheteur, cf. FIGURE 5 page 22), afin que le fournisseur comprenne sur quel produit porte le référencement.

Désignation du produit fournisseur : c’est le libellé qui est donné par le fournisseur afin d’identifier simplement son produit.

Code article interne fournisseur : c’est l’identifiant du produit, dans le système de gestion du fournisseur. Il s’agit généralement de codes, avec autant de formats distincts que de fournisseur venant contribuer.

Marque commerciale du produit : il s’agit du nom de la marque commerciale du produit.

Dénomination réglementaire : c’est le libellé qui doit décrire de manière neutre le produit, sans notion liée au marketing (telle que la marque, entre autres), et qui doit obligatoirement figurer sur l’emballage du produit.

TODO : Ajouter ici quelques exemples issus du PIM sur ces libellés.

4.2.2 Les listes d’ingrédients

L’autre grand type de donnée non structurées sont les listes d’ingrédients. La construction des listes d’ingrédients doit suivre les règles suivantes, même si l’application n’est pas toujours parfaitement respectée :

- elle doit détailler l’ensemble des ingrédients, y compris les additifs et les arômes
- elle doit être triée par ordre d’importance pondérale décroissante (i.e. les ingrédients les plus représentatifs en poids doivent être cités en premier)
- la quantité de certains ingrédients (en pourcentage de la masse) par exemple ceux mis en valeur sur l’étiquetage ou dans la dénomination de vente (ex. gâteau aux fraises, pizza au jambon)

Même s’il ne s’agit pas d’une exigence réglementaire, le Groupe Pomona demande à ses fournisseurs de ne pas distinguer les ingrédients par phase comme cela se fait parfois. Cela signifie, par exemple, séparer une partie de la composition du produit (la pâte de la garniture pour une tarte, la sauce et les raviolis, ...). De telles pratiques peuvent parfois induire le consommateur en erreur, comme par exemple dans la liste d’ingrédients suivante (s’applique à des chips de légumes) :

Légumes 64% (betterave, panais, carottes, patates douces), huile de tournesol, sel marin.

Sans l’artifice d’avoir regroupé les légumes en une seule phase, le premier ingrédient de la liste aurait pu être l’huile de tournesol, qui est un ingrédient moins attractif pour un consommateur de chips de légumes.

Les contraintes ci-dessus s'appliquant aux listes d'ingrédients font qu'en général, il s'agit d'une énumération d'ingrédients, sans doublon.

TODO : Fous-y des exemples ici aussi.

4.3 Pièces jointes

Dans chacune des sections, mentionner la volumétrie de données accessibles (avec les facettes migration, statuts, & compagnie) et tout

4.3.1 Fiches techniques fournisseur

Une fiche technique fournisseur est un document, d'une à une dizaine de pages, qui reprend l'essentiel des informations techniques à propos du produit. En général, cela ne porte pas d'information marketing. Cf. les exemples en annexe. Lister ici les données qu'on trouve usuellement dans les fiches techniques. Et la manière dont elles sont représentées.

4.3.2 Étiquettes produit

L'étiquette produit est la partie de l'emballage du produit qui porte les informations produit. Selon la technologie de l'emballage - très liée au fait que le produit est plutôt brut ou plutôt transformé - il peut s'agir :

- d'une photo de l'étiquette collante apposée sur l'extérieur de l'emballage du produit (cf. exemple)
- d'un applat de l'emballage, qui est le document qui est ensuite envoyé aux chaînes de production pour impression
- ou de tout autre visuel montrant une partie indissociable de l'emballage physique du produit

Pour résumer, l'étiquette est un document qui représente l'information produit qui « voyage avec le produit ».

Dire ici ce qu'on a dans les fiches techniques, et la manière dont elles sont représentées.

4.3.3 Fiches logistiques fournisseur

Parfois, la fiche technique ne mentionne pas les informations logistiques. Plusieurs explications : la fiche technique provient d'un service, et les informations logistiques d'un autre, ... Comme les données logistiques ont une importance cruciale, on demande aux fournisseurs de nous donner un document permettant de contrôler la cohérence des données transmises.

4.4 Récapitulatif de la complétude des données

Mettre ici un ou plusieurs tableaux récapitulatifs illustrant les données possédées quantitativement.

Montrer également la complétude en fonction du statut, de la date de création, et des facettes de migration.
Mettre l'exemple du champ "acide gras trans >1%"

4.5 Analyse qualitative des données

4.5.1 Évaluation de la qualité des données

Montrer qu'un sondage basique fait que la qualité actuelle est perfectible

4.5.2 Types de pdf possédés

Dire ici qu'il y a finalement beaucoup de pdf qui possèdent des textes extractibles vs. uniquement des images.

4.6 Les données « manuellement étiquetées »

4.6.1 Mode de constitution de l'échantillon

Montrer comment elles ont été produites

4.6.2 Règles de gestion pour l'étiquetage manuel

Expliquer que l'exercice n'est pas simple (car pas mal de petites spécificités sur les contenus). Parler des produits bruts, pour lesquels on n'a parfois pas de liste d'ingrédients. + la filière boissons qui est moins structurée. Expliciter les règles de gestion qui ont été listées pendant l'étiquetage manuel

4.6.3 Confrontation avec le contenu du PIM

Evaluer la cohérence entre étiquettes manuelles et contenu du PIM

Troisième partie

LES OBJECTIFS DE CE PROJET

Chapitre 5

LES CAS D'USAGE

5.1 Objectifs : Qualité et productivité

Comme présenté précédemment, 1 on dépense de l'énergie, et 2 on a une qualité de données qui est perfectible. Un traitement automatique des documents mis à disposition permettrait de décharger les personnes qui interviennent dans le processus (fournisseurs, acheteurs, gestionnaires de référentiels, ingénieurs qualité) et de garantir une meilleure pertinence de l'information produit.

5.2 La préalimentation d'information

Préalimenter les informations, sous réserve d'avoir un outil suffisamment fiable, permettrait de faire gagner du temps aux fournisseurs. Trois obstacles :

- cela n'a d'intérêt que si le système est capable de produire de l'information structurée avec une fiabilité élevée (par exemple, 80% de données correctes serait un minimum)
- cela entre en concurrence directe avec le système GDSN présenté au paragraphe portant le même nom à la section 2.3.3 page 25. Or, ce système est justement spécialement conçu pour faire transiter les informations produit des fournisseurs aux distributeurs, avec une standardisation des échanges
- cela apporte l'essentiel de la valeur aux fournisseurs, mais pas au Groupe

5.3 Le contrôle des informations transmises

Cf. le schéma présenté à la FIGURE 5 page 22. Plus le taux de détection des erreurs est élevé, et plus les erreurs sont détectées tôt, mieux c'est :

- la qualité des données s'en trouve évidemment améliorée

- le processus est plus court en temps, en évitant les aller-retours
- on décharge l'ensemble des acteurs, en limitant la

5.3.1 Le contrôle à la saisie fournisseur

Si on alerte le fournisseur au moment où il saisit, on peut dès le début du processus éviter une erreur. Cela pourrait avoir lieu quand il soumet ses données, on fait tourner un traitement et on remonte des avertissements dans l'IHM du PIM.

5.3.2 L'aide aux vérifications Pomona

Lors des contrôles, on pourrait également remonter les incohérences détectées entre pièces jointes et données à contrôler.

5.3.3 Les contrôles en masse asynchrones

Enfin, il pourrait être pertinent de faire tourner de manière asynchrone des contrôles de qualité de données sur l'ensemble de la base. TODO : détailler un peu le pourquoi c'est nécessaire (exemple du champ acides gras trans), et un des points difficile : acquiescement des avertissements non pertinents.

Chapitre 6

LE CHOIX DU CAS D'USAGE

6.1 La représentation dominante des fiches techniques

On a beaucoup de fiches techniques, pas beaucoup d'étiquettes ou de fiches logistiques (cf. la table qui va bien.) On va donc plutôt dans un premier temps tenter de travailler avec les fiches techniques.

6.2 Les multiples formats et le besoin de « spatialisation »

Chaque fournisseur décide évidemment du format de document qu'il souhaite produire. On a donc beaucoup de formats différents, et un Pareto finalement trop « mou » pour envisager de construire des templates pour récupérer les informations automatiquement (cf. FIGURE 15 page 35).

6.3 Les informations « spatialisées »

Les données que l'on souhaite récupérer sont globalement de 3 types :

- données de composition
- données nutritionnelles
- données logistiques

Comme vu dans la section 4.3.1 page 39, un grand nombre d'informations sont spatialisées. Par exemple, la représentation des données nutritionnelles se fait régulièrement sous forme de tableau. Or, c'est un peu compliqué à interpréter, car il fut réussi à interpréter un tableau, et à en sortir des couples de clé / valeur.

6.4 La complexité dans la représentation des données logistiques

Les données logistiques sont souvent difficile à interpréter pour un humain, donc cette activité peut paraître difficile à déléguer à une machine. Mettre 2-3 exemples.

6.5 L'identification d'une liste d'ingrédient par son contenu

Il est possible de dire si un texte est une liste d'ingrédients, juste en lisant ce texte. Par exemple, « 14g » peut être une quantité de glucides, de lipides, le poids d'une pièce unitaire, ... Mais un texte tel quel <mettre ici un exemple> a de forte chance d'être le contenu d'une liste d'ingrédients.

6.6 Conclusion quant au choix du cas d'usage

Tant la préalimentation, que l'aide au contrôle des données seraient faisable d'un point de vue technique. Il suffirait pour cela de publier un service, qui fonctionnerait de la manière suivante :

- le PIM appelle le service, avec un message contenant l'uid du produit à contrôler ou préalimenter
- le serveur récupère du PIM les données nécessaires au contrôle ou à la préalimentation
- en retour, il renvoie au PIM soit l'état du contrôle (OK, erreur, avertissement, avec les précisions nécessaires), soit les données telles qu'elles doivent être préalimentées
- le PIM, sur la base de ce retour, affiche le résultat du contrôle ou bien alimente les données et les présente à l'utilisateur

Au vu des différentes contraintes listées dans ce document, on s'attachera à extraire les listes d'ingrédients des produits alimentaires de la branche EpiSaveurs depuis les fiches techniques fournisseur, en se basant sur le contenu textuel de ces documents.

Quatrième partie

CONSTRUCTION DU MODÈLE

Chapitre 7

LES PRINCIPES GÉNÉRAUX

7.1 Contenu du texte d'une liste d'ingrédients

En général, chaque ingrédient sera présent une seule fois dans la liste (cf. section 4.2.2 page 38)

Le calcul d'embeddings via des modèles tels que SVD ou Word2Vec fait peu de sens.

l'extraction des textes se fait au format Bag Of Words, sans utiliser de notion d'IDF. L'utilisation de TF semble églament ne pas amener de valeur à priori.

7.2 Limitation à l'identification des listes d'ingrédients

On est sur une taxonomie d'informations limitée dans les fiches techniques.

On pourrait envisager de classifier l'ensemble des textes présents dans les fiches techniques.

Mais l'absence de données étiquetées rend cette tâche impossible. La charge d'étiquetage d'un nombre représentatif de blocs de texte de fiches techniques est trop importante pour être mise en oeuvre dans le cadre de ce projet.

7.3 Conversion de documents en texte

dire ici qu'on utilise principalement pdfminer vs. d'autres outils d'OCR.

De plus, on partira dans un premier temps sur une transformation basique d'un document en texte, sans passer par une analyse de la localisation des textes sur le document (cf. les difficultés présentées dans la section 6.2 page 42).

Chapitre 8

CONSTRUCTION D'UN MODÈLE SIMPLE

« OUVERT »

Le fonctionnement global de ce premier modèle (présenté à la FIGURE 16 page 45) ne respecte pas les principes du Machine Learning. Il permet juste d'éprouver la méthode pressentie, ainsi que de se faire une idée de l'efficacité d'un modèle de ce type. En effet, même si on utilise des briques d'extraction de features depuis des textes, il manque une partie de mesure de la performance, indispensable pour pouvoir évaluer et améliorer la pertinence du modèle. On peut toutefois tout de même effectuer un train/test split, afin d'éviter de surestimer la valeur des résultats. Le code est présenté en annexe (ref à mettre), il utilise les classes IngredientExtractor et PIMIngredientExtractor. Il n'utilise pas les données étiquetées manuellement (présentées à la section 4.6 page 40).

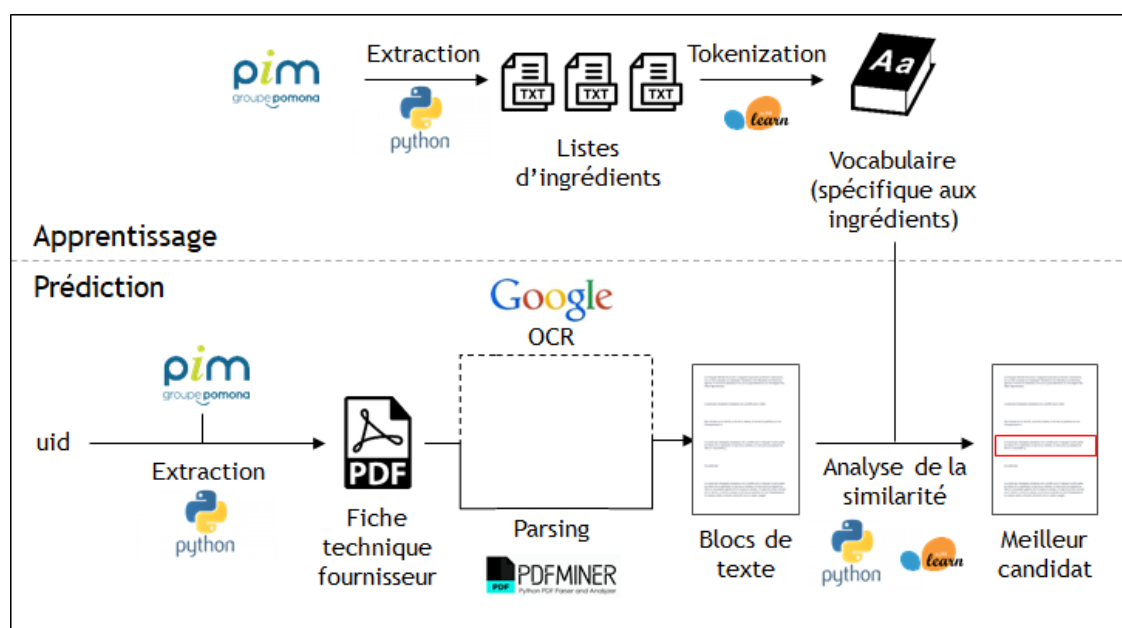


FIGURE 16 – Schéma de principe du « modèle ouvert »

8.1 Extraction des données

Ne garder que produits d'épicerie et boissons non alcoolisées

8.2 Conversion en blocs de texte

On utilise la bibliothèque PDFMiner.six. Elle nous sort un long string qui contient le texte entier du document. On applique une « bête » fonction : on splitte ce string quand on observe 2 retours à la lignes consécutifs. Le code est présenté en annexe. Pour le moment, vu la proportion importante de PDF dont le contenu est extractible

8.3 Train/Test split

On fait un split 50/50, on se base sur les uid pour identifier les produits. Sur le train set, on récupère les listes d'ingrédients du PIM.

8.4 Entraînement du modèle

L'entraînement est basique : on constitue seulement un vocabulaire en utilisant la fonctionnalité mise à disposition dans scikit-learn.

8.5 Calcul de la similarité

On calcule la similarité cosinus entre chacun des blocs, et le vocabulaire. On prend, systématiquement l'argmax de la similarité qu'on propose comme liste d'ingrédients.

8.6 Illustration des résultats obtenus

Mettre ici les résultats sur quelques fiches techniques présentées en annexe. Spoiler : rien que comme ça, les résultats sont encourageants.

8.7 Pistes d'améliorations identifiées

En plus de la mesure de la performance, qui est indispensable avant de pouvoir procéder à des ajustements. Pistes identifiées :

- Faire un découpage du gros texte en blocs plus malin, potentiellement avec des expressions régulières
- Faire des « ngrams de blocs », ce qui permettrait de parfois fusionner des blocs qui ont été séparés (car contenaient des retours à la ligne successifs)
- Essayer une autre manière de calculer la similarité ?

Chapitre 9

UTILISATION DES DONNÉES MANUELLEMENT ÉTIQUETÉES

Expliciter pourquoi on ne peut pas faire tourner (référence parties précédentes) sur les listes d'ingrédients déjà présentes dans le PIM => soucis de qualité de données source. Si on entraîne sur des données de mauvaise qualité, on aura de mauvais résultats. Le code de cette partie est présenté en annexe. Le fonctionnement de ce modèle est présentés à la FIGURE 17 page 47.

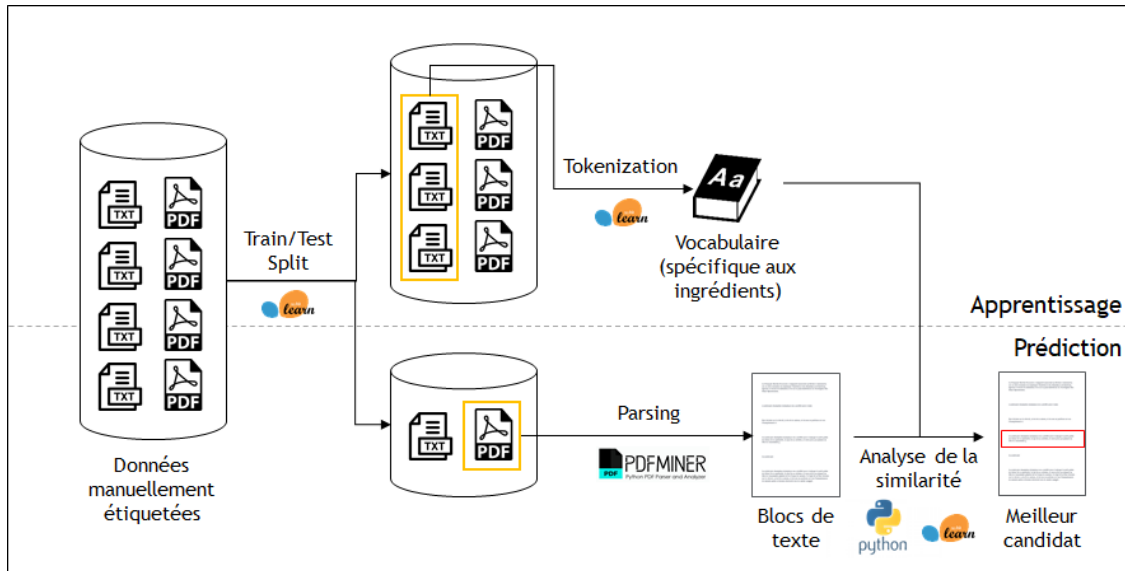


FIGURE 17 – Schéma de principe du modèle basé sur les données étiquetées

9.1 Chargement des données manuellement étiquetées

Un bon vieux `read_csv` des familles pour le résultat. Les transformations à pipeliner pour les pdf et la constitution des blocs.

9.2 Train/Test split

Vu qu'on a moins de données, on fait `train = 400` et `test = 100`.

9.3 Entraînement du modèle

On fait tourner de la même manière que sur le modèle dit « ouvert »

9.4 Illustration des prédictions obtenues

On illustre ici le résultat.

Chapitre 10

MESURE DE LA PERFORMANCE

Comme vu aux chapitre précédents, il est indispensable de mesurer la performance de nos modèles. On le fera sur le modèle se basant sur les données manuellement étiquetées. Le principe est présenté à la FIGURE 18 page 48.

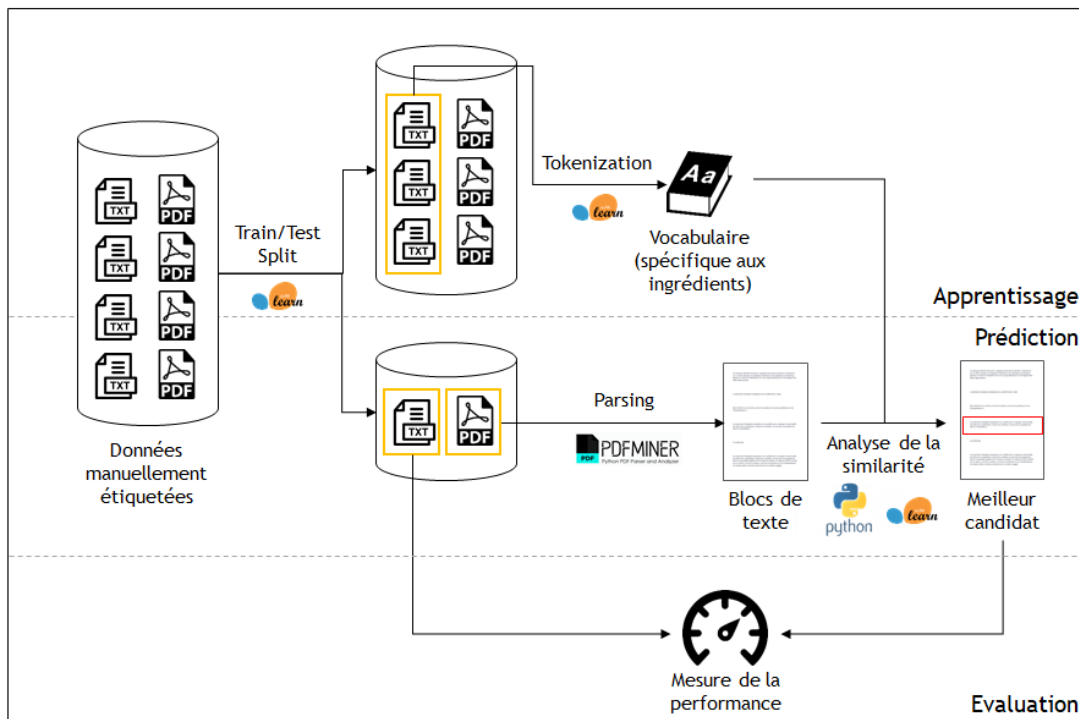


FIGURE 18 – Illustration de la méthodologie de mesure de la performance

10.1 Précision

La métrique qui tombe le plus sous le sens est la précision. On mesure la proportion de prédictions qui sont égales à la ground truth.

10.1.1 Approche naïve

Illustration des résultats. Comme on s’y attend, la précision sans transformation est très sévère. En particulier, prise en compte de la casse et des accents. La sortie du modèle contient des retours à la ligne à la fin des lignes de texte, là où la ground truth n’en contient pas.

10.1.2 Avec du « text-postprocessing »

On assouplit un peu les contraintes en effectuant du text processing, à la fois sur la ground truth et les résultats du modèle. On tokenize (pour retirer ponctuation, « blancs »), et on retire la casse et les accents pour constituer des textes qui ont plus de chance d’être égaux. Ce n’est pas une astuce pour améliorer les résultats, c’est juste que cette manière de mesurer est plus pertinente. Illustration des résultats en appliquant diverses manières de « post-processer ».

10.2 Fonctions de « loss » spécifiques

On peut aussi définir des fonctions de loss, qui permettent d’être plus fin qu’une simple évaluation OK / KO du résultat du modèle. On calculera une distance entre le résultat du modèle, et de la ground truth.

10.2.1 Distance de Levenshtein

Brève description de chacune de ces distances.

10.2.2 Distance de Damerau-Levenshtein

Brève description de chacune de ces distances.

10.2.3 Distance de Jaro

Brève description de chacune de ces distances.

10.2.4 Distance de Jaro-Winkler

Brève description de chacune de ces distances.

10.2.5 Métriques non retenues

Distance de Hamming

10.2.6 Conclusion sur la métrique à utiliser

Une fois que cela aura été fait.

10.3 Cross-validation

On effectue une cross validation sur le modèle travaillant sur les données manuellement étiquetées.

Chapitre 11

TRANSFER LEARNING

11.1 Principe du pré-entraînement

Expliquer qu'il s'agit d'une approche hybride des 2 modèles précédents On effectue un entraînement à la fois sur une partie des listes d'ingrédients du PIM, et sur une partie des données étiquetées. On vérifie ensuite, uniquement sur

11.2 Illustration de l'impact sur la performance

Ici, on montre l'impact sur la performance, du fait d'intégrer des listes d'ingrédients. On met en abscisse le nombre de listes d'ingrédients qu'on ajoute, et en ordonnée la performance du modèle (avec barre d'erreurs, via cross validation). On regarde si l'effet est positif : cela montrera s'il est intéressant d'avoir plus de données. On regarde si on observe une saturation : cela montrera si on a déjà suffisamment de données sous formes de listes d'ingrédients dans le PIM, ou bien si ce serait intéressant d'en acquérir plus.

Chapitre 12

HYPERPARAMETER TUNING

On peut, dans l'optique d'améliorer la performance du modèle, ajuster certains paramètres et d'évaluer l'impact via une grid search. On fera tourner sur le modèle avec transfer learning.

12.1 Les paramètres ajustables

12.1.1 La prise en compte des « n-grams » dans la tokenization

On peut utiliser les n-grams lors de la tokenisation.

12.1.2 L'application de « n-grams » de blocs

Voir si dans la recherche du meilleur candidat, on s'autorise la constitution de « n-grams » de blocs.

12.1.3 L'utilisation d'expressions régulières dans le split des blocs

Voir si certaines expressions régulières pour splitter les blocs procurent de meilleurs résultats.

12.1.4 Applications d'autres fonctions de similarité

Voir l'impact d'utiliser d'autres manières de calculer la similarité.

1 - autre chose que la similarité cosinus (fonction du nombre de mots du bloc et de la proportion de mots issus du vocabulaire des ingrédients)

2 - en appliquant du TF et du TF-IDF

12.2 Application d'une grid search

Illustrer ici les résultats d'une grid search ou d'une random search si trop gourmand.

Cinquième partie

TRAVAUX SUBSÉQUENTS

Chapitre 13

OPÉRATIONNALISATION DE CETTE MAQUETTE

13.1 Client et sponsor métier

Estimation du ROI et identification d'un sponsor et d'un client.

13.2 Sélection du use case

Préalimentation ou appui au contrôle de données ?

13.3 Mise en place d'une organisation projet

13.3.1 Identification des compétences nécessaires

Nécessite des compétences diverses : développement côté PIM, compétences infra, définition du niveau de criticité de cette fonctionnalité (pour définition du monitoring et des plans de reprise d'activité)

13.3.2 Choix d'un cadre méthodologique projet

Scrum, c'est ce qu'on connaît le mieux.

13.3.3 Développement côté PIM

Développement des fonctionnalités telles qu'elles ont été présentées dans la section sur le choix du use case.

13.4 Industrialisation du code du modèle

Refactoring de certaines classes (e.g. : le requester, qui porte trop de responsabilités) Poursuite de l'écriture de tests unitaire pour avoir une couverture $> 80\%$. Mise en place d'un processus de déploiement continu. Rédaction de la documentation : revue des docstring et mise en place d'un build Sphinx

13.5 Monitoring de la performance du modèle

voir la manière dont on peut superviser le niveau de performance du modèle. Capture-t-on en direct le retour des utilisateurs dans le PIM ?

Chapitre 14

EXTENSION DES FONCTIONNALITÉS OFFERTES

14.1 Prise en compte de nouveaux types de pièces jointes

Aller chercher également les étiquettes.

14.2 Utilisation d'outil d'OCR pour les pdf non structurés

Intégrer ce qui a déjà été fait autour des solutions cloud, Google ou Azure.

14.3 Mise en place d'outil de spatialisation des textes

Charge importante, mais pourrait être utilisé pour d'autres sujets

14.4 Construction d'outils d'extraction de données connexes à la composition

Détermination des allergènes sur la base du contenu des listes d'ingrédients.

14.5 Élargissement aux données nutritionnelles

Si spatialisation faisable, tenter de récupérer des données nutritionnelles.

14.6 Évaluation de la performances sur d'autres familles de produits

Construction d'une nouvelle ground truth sur des fiches techniques de PassionFroid et TerreAzur, et évaluation de la performance du modèle.

Sixième partie

ANNEXES

Annexe A

FIGURES, TABLEAUX ET BIBLIOGRAPHIE

Liste des tableaux

1	Exemple de tableau de données nutritionnelles	15
2	Volumétrie article par branche	29
3	Utilisation des variables catégorielles article au sein des branches RHD	32
4	Nombre de produits par GTIN	34
5	Exemples de codes d'identification	36
6	Description des codes d'identification sur le dataframe	36
7	Exemples de dimensions	36
8	Description des dimensions sur le dataframe	36
9	Exemples de conservation	37
10	Description des conservations sur le dataframe	37

Table des figures

1	Les flux métier avec les partenaires commerciaux	7
---	--	---

2	La répartition de l'activité des branches	10
3	Le maillage régional de la branche ÉpiSaveurs	12
4	La distinction entre produit et article	19
5	Le processus de création article	22
6	Une capture d'écran du PIM	24
7	L'intégration du PIM au sein des systèmes du Groupe Pomona	24
8	Schéma de principe de la GDSN	25
9	L'uid d'un produit	26
10	Volumétrie article par branche	29
11	Recouvrements entre branches RHD	30
12	Répartition des articles en fonction des variable catégorielles	31
13	Nombre de produits par GTIN	34
14	Distribution des fournisseurs par nombre de produits	35
15	Le Pareto des produits en fonction des fournisseur	35
16	Schéma de principe du « modèle ouvert »	45
17	Schéma de principe du modèle basé sur les données étiquetées	47
18	Illustration de la méthodologie de mesure de la performance	48

BIBLIOGRAPHIE

- [1] Conseil de l'Union Européenne. Règlement n°1333/2008 sur les additifs alimentaires, dec 2008. <https://eur-lex.europa.eu/LexUriServ/LexUriServ.do?uri=OJ:L:2008:354:0016:0033:FR:PDF>.
- [2] Conseil de l'Union Européenne. Règlement n°1907/2006 dit REACH, dec 2006. <https://bit.ly/2Jm05v9>.
- [3] Conseil de l'Union Européenne. Règlement n°1169/2011 dit INCO, nov 2011. https://www.senat.fr/europe/textes_europeens/ue0120.pdf.
- [4] Direction Générale de la Concurrence, de la Consommation et de la Répression des Fraudes. Étiquetage des denrées alimentaires : nouvelles règles européennes, jan 2015. <https://www.economie.gouv.fr/dgccrf/etiquetage-des-denrees-alimentaires-nouvelles-regles-europeennes>.
- [5] Direction Générales des Douanes et Droits Indirects. Notions essentielles sur la Déclaration d'Échanges de Biens. <https://www.douane.gouv.fr/notions-essentielles-sur-la-declaration-dechanges-de-biens>.

- [6] GS1. GDSN Trade Item Implementation Guide, nov 2019. https://www.gs1.org/docs/gdsn/tiig/3_1/GDSN_Trade_Item_Implementation_Guide.pdf.
- [7] GS1 France. Le réseau GDSN, le canal pour l'échange d'informations produits. <https://www.gs1.fr/Notre-offre/Le-reseau-GDSN-le-canal-pour-l-echange-d-informations-produits>.
- [8] GS1 Global. Global Data Synchronisation Network. <https://www.gs1.org/services/gdsn>.
- [9] GS1 Global. GS1 General Specifications. https://www.gs1.org/docs/barcodes/GS1_General_Specifications.pdf.
- [10] Groupe Pomona. Site institutionnel du groupe pomona. <https://www.groupe-pomona.fr/>.
- [11] Wikipedia. Liste des additifs alimentaires. https://fr.wikipedia.org/wiki/Liste_des_additifs_alimentaires.

Annexe B

EXEMPLE DE DOCUMENTS FOURNISSEUR

B.1 Fiches techniques

B.1.1 Fiche technique sel Cerebos

Fiche technique

CEREBOS® Sel Gros Alimentaire



Version 1.9

Page 1 / 1

date d'impression: 26.10.2010

No.-CAS: 7647-14-5

No.-EINECS: 231-598-3

Apparence:

produit blanc, cristallin

Analyses chimiques

- Chlorure de sodium
- Teneur en eau
- Insolubles dans l'eau
- Anti-agglomérant E 535

Spécification

> 99,8 %
< 0,1 %
< 0,01 %
< 20 mg/kg

Typique

99,9 %
0,02 %
0,005 %

Méthodes

ASTM 534-98
ISO 2483
ISO 2479
EuSalt AS 004

Granulométrie

- > 3,15 mm
- 1,00 - 3,15 mm
- < 1,00 mm

Typique

1 %
89 %
10 %

Méthodes

EN 1235

Propriétés physiques:

- Masse volumique apparente

1.100 - 1.300 kg/m³

Méthodes

EN 1236

Sur demande:

- Iode (sous la forme de NaI) exprimé en I
- Fluor (sous la forme KF)
- Législation nationale: 212,5 - 287,5 mg F/kg

15 - 20 mg/kg EuSalt AS 002
250 mg/kg EuSalt AS 017

Réglementation sur les denrées alimentaires, Impuretés et contaminants:
Conforme au CODEX ALIMENTARIUS.

Domaine d'application

Sel gros de table ou de cuisine de qualité alimentaire pouvant être supplémenté en iode ou en iode et fluor.

Site de conditionnement

Salines Cérébos et de Bayonne à Dombasle (France 54) et à Mouguerre (France 64) -
Groupe esco

Stockage

Il est conseillé de ne pas gerber les palettes. Le CHLORURE DE SODIUM étant un produit hygroscopique, tout conditionnement ouvert devra être stocké à l'abri de l'humidité.

Moyens de livraison

- sur demande

Les données précédentes résultent de nos contrôles qualité. Ces données ne dispensent pas l'utilisateur d'un contrôle à réception et ne sont pas forcément des garanties de vente. L'utilisateur est seul responsable du choix du produit en fonction de l'application souhaitée

esco - european salt company GmbH & Co.KG
Headquarters • Landschaftstraße 1 • 30159 • Hannover • Allemagne • ☎ +49-(0)511-85030-0 ☎ ...-131
esco benelux nv • Park Lane, Culliganlaan 2G bus 1 • B-1831 • Diegem • Belgique • ☎ +32-2711-0160 ☎ ...-0161
esco france s.a.s • 49 Avenue Georges Pompidou • F-92593 • Levallois-Perret Cedex • France • ☎ +33(0)1-49.64.59.00 ☎ ...1.49.64.59.10
Vatel S.A. • Apartado 211-Sobralinho • P-2616-956 • Alverca • Portugal • ☎ +35-1219-5184-20 ☎ ...-39
esco Espagne S.L. • Joan d'Austria, 39-47 • 08005 • Barcelona • Espagne • ☎ +34 (93) 2247238 ☎ +34 (93) 2214193
esco Nordic AB • Drakegatan 10 • 401 23 • Göteborg • La Suède • ☎ +46 -31 773 70-01 ☎ ...-02
www.esco-salt.com Certification EN ISO 9001:2008

B.1.2 Fiche technique olives Valtonia

	FICHE TECHNIQUE	Date : 10/12/2019	V 1.2
	OLIVES NOIRES CONFITES DENOYAUTEES 4/4 VALTONIA		

INGREDIENTS :	Olives, eau, sel, stabilisateur de couleur : E579
---------------	---

MARQUE :	VALTONIA
BOITAGE :	4/4
ORIGINE :	Espagne
EAN 13 :	3061435001137
EAN colis :	3061435101134

CARACTERISTIQUES PHYSICO-CHIMIQUES ET ORGANOLEPTIQUES	
PH :	5.5 à 8.0
TAUX DE SEL :	2.0 à 3.5 %
Calibre :	30/33 unités / 100 g d'olives entières
ODEUR ET SAVEUR :	Franche et caractéristique
COULEUR :	Noire à robe de moine
PRESENCE DE NOYAUX :	1 noyau pour 100 fruits 2 fragments pour 100 fruits
DEFAUTS AUTRES CRITERES	Se référer au code des olives

CARACTERISTIQUES MICROBIOLOGIQUES
Produit conforme à l'arrêté d'octobre 1997 relatif au contrôle de la stabilité des produits appertisés et assimilés (Norme AFNOR NF V08-401).

VALEURS NUTRITIVES MOYENNES POUR 100 G DE PRODUIT EGOUTTE								
Kj	Kcal	Protéines	Matières grasses	Dont AGS	Glucides	Dont sucres	Sel	Fibres
515	125	0.5 g	13.0 g	2.2 g	0 g	0 g	2.0 g	3.0 g
INFORMATIONS COMPLEMENTAIRES								
Présence d'allergènes :	Non			Pesticides :	Conforme à la législation en vigueur.			
OGM et ionisation :	Absence			Métaux lourds :	Conforme à la législation en vigueur.			

CONDITIONNEMENT		
Contenance :	Poids net :	Poids net égoutté :
850 ml	800 g	360 g
Nombre de boîtes / carton :	Nombre de cartons /couche :	Nombre de couches / palettes :
6	12	12

CONSERVATION	
DLUO avant ouverture	3 ans. Stocker à température ambiante à l'abri de l'humidité
Après ouverture	au réfrigérateur dans un récipient alimentaire avec son liquide de couverture une semaine

Les informations contenues dans cette fiche sont celles dont nous disposons à la date de validation. Elles sont donc susceptibles d'être modifiées ultérieurement. Pour toute réclamation ou demande d'information merci de préciser impérativement **le lot** et/ou **date de fabrication** portés sur le couvercle.

Copram - Société de commercialisation des produits alimentaires du Maroc
17, Quatrième Rue-Zone industrielle B.P. 168 – 13745 VITROLLES cedex – France
RC Salon B 315 712/299 - Siret : 315 712 299 00017
NAF : 511N - N° T.V.A. FR 03 315 712 299

B.1.3 Fiche technique Panna Cotta Nestlé



Panna Cotta
NESTLÉ Docello®
 Étui de 600 g (2 x 300g)
 pour 50 portions



CODE EAN
9002100034771

DESCRIPTION DU PRODUIT

Préparation en poudre pour Panna Cotta.

BÉNÉFICES CLÉS DU PRODUIT

Avec arôme naturel.
 Facile à mettre en œuvre et à personnaliser.

INGRÉDIENTS

Sucre, dextrose, maltodextrine, stabilisants (E460, E450, E516, E401, E404), épaississant (E407), arôme naturel (lait).
 Peut contenir : **fruits à coque, œuf, soja et gluten**.

ALLERGÈNES MAJEURS

Conformément aux réglementations vigueur :

- Allergènes présents dans la recette ou dans un de ses ingrédients : **lait**
- Allergènes potentiellement présents : **fruits à coque, œuf, soja et gluten**.

Merci de vérifier ces informations sur l'étiquette de votre produit, car seules celles-ci font foi.

ENGAGEMENT QUALITÉ

NESTLÉ a un système de management de la Qualité certifié par les normes ISO 9001 et FSSC 22000.
 Etiquetage conforme à la réglementation en vigueur sur les OGM.
 Ce produit ne contient pas d'ingrédients ionisés.

MODE D'EMPLOI

1. Porter à ébullition le mélange de lait et de crème liquide.
 2. Hors du feu, verser en pluie tout en fouettant la préparation pour Panna Cotta puis mélanger jusqu'à parfaite homogénéisation. Porter à nouveau le mélange à ébullition.
 3. Verser la préparation dans des ramequins, faire refroidir puis stocker en chambre froide (entre 0°C et +3°C). Servir frais.
- Suggestion: pour une Panna Cotta encore plus onctueuse vous pouvez réduire le dosage à 130g par litre de liquide.

DOSAGES

Produit déshydraté	Dosages			
	Base	Lait	Crème liquide	Nombre de portions (90g)
Panna Cotta	150 g	0,5 L	0,5 L	12
	300 g	1 L	1 L	25
	600 g	2 L	2 L	50

UTILISATION

Pour une texture plus souple et un rendement amélioré : un sachet (300 g) + 2 L de crème liquide + 1 L de lait = 36 portions (90 g).
 Idéal dans la composition d'un café gourmand.
 Facilement personnalisable, ce dessert se consomme nature ou parfumé (thé vert, cardamome, badiane, pulpe de fruits...), mais également accompagné de fruits frais, de Sauces Desserts NESTLÉ Docello®, de coulis de fruit...

Version du 05/07/2018

Les dernières mises à jour sont disponibles sur notre site internet www.nestleprofessional.fr

Page 1 / 2



**Panna Cotta
NESTLÉ Docello®
Étui de 600 g (2 x 300g)
pour 50 portions**



**CODE EAN
9002100034771**

DÉCLARATION NUTRITIONNELLE

	Pour 100 g	Par portion (90 g)*
Énergie	1563 kJ 368 kcal	811 kJ 195 kcal
Matières grasses	0 g	14 g
- dont acides gras saturés	0 g	9,0 g
Glucides	91 g	14 g
- dont sucres	86 g	14 g
Fibres alimentaires	2,1 g	0,3 g
Protéines	0 g	2,2 g
Sel	0,87 g	0,19 g

Bénéfices nutritionnels

Ce produit entre dans la catégorie GEMRCN** des desserts à limiter à hauteur de 3/20 repas maximum.

3/20 repas maximum

**Groupe d'Étude des Marchés Restauration Collective et Nutrition

*préparée avec du lait demi-écrémé et de la crème liquide (34% de matières grasses)

AVANTAGES ET BENEFICES DU PRODUIT

Crémeux et fondant, ce dessert est facile et rapide à mettre en œuvre.

CONSERVATION - STOCKAGE

Durabilité minimale : 24 mois

À conserver au sec et à l'abri de la chaleur dans son emballage d'origine. Bien refermer après chaque utilisation.

DONNÉES LOGISTIQUES

	Type UC / UD	Code EAN	Poids Net	Poids Brut	Dimensions (L x l x H) en mm
Unité consommateur (UC)	Boîte	9002100034771	600 g	691 g	80 x 185 x 200
Unité de distribution (UD)	Carton	9002100034788	3,6 kg	4,49 kg	388 x 253 x 216
Palette - Gerbabilité : OUI	Palette	7613033074578	129,6 kg	187 kg	1200 x 800 x 1014

Codes internes Nestlé			Code Douanier	Pays de production	Nbre UC par UD	Nbre UD par Couche	Couches par Palette	Nbre UD par Palette	Nbre UC par Palette
M74C/09	12202814	43825851	2106909855	Serbie	6	9	4	36	216

Nestlé France S.A.S. Noisiel 542 014 428 RCS MEAUX, NOISIEL © Reg. Trademark of Société des Produits Nestlé S.A.



Version du 05/07/2018

Les dernières mises à jour sont disponibles sur notre site internet www.nestleprofessional.fr

Page 2 / 2

B.1.4 Fiche technique confiture Andros



Route de Oinville
28 700 AUNEAU
Tél : + 33 2 37 33 16 33 - Fax : + 33 2 37 33 16 91



	05/01/2017
	—

DENOMINATION COMMERCIALE
Colis assorti de 60 bocaux de confitures et marmelade 30g Bonne Maman
15 Confiture Myrtilles et Cassis + 15 Confiture Fraises et Groseilles + 15 Confiture Abricots et Pêches + 15 Marmelade Oranges et Mandarines

DENOMINATION LEGALE DE VENTE
Confiture de Myrtilles et de Cassis - Confiture de Fraises et de Groseilles - Confiture d'Abricots et de Pêches - Marmelade d'Oranges et de Mandarines

CARACTERISTIQUES	
Variété(s) :	myrtille cassis, fraises groseilles, abricots pêches, oranges mandarines
Conservation :	A conserver au frais après ouverture. Date de durabilité minimale : Voir sur unité de vente
Gencod :	3 60858 082942 3 Code article : 50082942
Codes douaniers :	Confiture Myrtilles et Cassis: 20079939 Confiture Fraises et Groseilles: 20079933 Confiture Abricots et Pêches: 20079939 Marmelade Oranges et Mandarines: 2007993110
Confiture de myrtilles et de cassis Ingrédients : fruits (myrtilles 41%, cassis 9%), sucre, sucre roux de canne, jus de citrons concentré, gélifiant : pectine de fruits.	
Confiture de fraises et de groseilles Ingrédients : fruits (fraises 27 %, groseilles 23 %), sucre, sucre roux de canne, jus de citrons concentré, gélifiant : pectine de fruits.	
Confiture d'abricots et de pêches fruits (abricots 34%, pêches 16%), sucre, sucre roux de canne, jus de citrons concentré, gélifiant : pectine de fruits. Malgré tous nos soins, cette confiture peut contenir des noyaux.	
Marmelade d'oranges douces et de mandarines Ingrédients : fruits (oranges douces 37%, mandarines 3%), sucre, sucre roux de canne, jus de citrons concentré, gélifiant : pectine de fruits.	

The image displays four jars of Bonne Maman confiture, each with a pink and white checkered lid. The jars are arranged in a 2x2 grid. The top-left jar is labeled 'Confiture Bonne Maman Myrtilles et Cassis'. The top-right jar is labeled 'Confiture Bonne Maman Fraises et Groseilles'. The bottom-left jar is labeled 'Confiture Bonne Maman Abricots et Pêches'. The bottom-right jar is labeled 'Confiture Bonne Maman Oranges et Mandarines'. Each jar has a white label with black text and a small '30g' weight marking at the bottom.

ARGUMENTAIRE PRODUIT
Les confitures Bonne Maman duo, des alliances subtiles où le deuxième fruit vient rehausser la saveur et la gourmandise du premier fruit

VALEURS NUTRITIONNELLES MOYENNES												
		Myrtilles Cassis			Fraises Groseilles			Abricots Pêches			Oranges Mandarines	
		pour 100 g	pour 30 g	%AR* par ration	pour 100 g	pour 30 g	%AR* par ration	pour 100 g	pour 30 g	%AR* par ration	pour 100 g	pour 30 g
ENERGIE	En kJoules (kJ) :	1016	305	4%	1018	305	4%	1031	309	4%	1022	307
	En kcalories (kcal) :	239	72	4%	240	72	4%	243	73	4%	241	72
Matières grasses (g) :		0,2	0	0%	0,3	0	0%	0,2	0	0%	0,1	0
Dont Acides Gras saturés		0	0	0%	0	0	0%	0	0	0%	0	0
Glucides (g) :		58	17	7%	58	17	7%	59	18	7%	59	18
Dont sucres:		58	17	19%	58	17	19%	59	18	20%	59	18
Fibres (g):		1,8	1	—	1,5	0	—	1,3	0	—	1	0
Protéines (g):		0,5	0	0,3%	0,5	0	1,0%	0,6	0	0,4%	0,4	0
Sel (g):		0	0	0%	0	0	0%	0	0	0%	0	0

* Apports de Référence (Apports de référence pour un adulte type (8400kJ/2000kcal)). Ces valeurs et les portions peuvent varier selon l'âge, le sexe et l'activité physique

CARACTERISTIQUES PHYSICO - CHIMIQUES et ORGANOLEPTIQUES				
Parfums	Myrtilles Cassis	Fraises Groseilles	Abricots Pêches	Oranges Mandarines
Texture	onctueuse			gélifiée
Brix	60 ° brix			
Goût	Caractéristique des fruits			
Couleur	noire	rouge vif	orange	orange
pH	3,00 à 3,4	3,00 à 3,15	3,20 à 3,40	3,00 à 3,15

MENTIONS COMPLEMENTAIRES	
Allergène(s) obligatoire(s) présent(s) :	NON
Allergène(s) obligatoire(s) pouvant être introduit(s) de manière non intentionnelle :	
Présence OGM, ionisation :	
Les produits ANDROS sont exempts :	
- d'Organisme Génétiquement Modifié et / ou d'ingrédients provenant d'Organisme Génétiquement Modifié	
- d'ingrédient ionisé y compris dans les matières premières et les ingrédients utilisés.	

RECOMMANDATIONS	
GEMRCN	Programme 1 fruit pour la récré

CONDITIONNEMENT et PALETTISATION			
Bocal verre 44 ml / Capsule métallique TO 48 BM			
	Unité	COLIS	PALETTE
Format :	1 colis assorti de 60 pots de 30 g		
GENCOD :	3 60858 082942 3		03 60858 814419 1
Poids net (Kg) :	1,800		280,800
Poids brut (Kg) :	4,843		778,000
Largeur (mm) :	236		800
Longueur (mm) :	146		1200
Hauteur (mm) :	219		1459
Nombre de pièces :			156
Nombre de colis :			156
Nombre de couches :			6
Nombre de colis par couche :			26

COMMENTAIRES :
En cas d'incohérence entre la fiche technique et l'emballage, veuillez noter que seul l'emballage fait foi.

B.1.5 Fiche technique ciboulette La case aux épices

	FICHE TECHNIQUE		117801
	CIBOULETTE TUBULAIRE FLAPPERS		Indice : f Date : 20/11/2014 Page : 1 / 2



CARTONS de 8 Flapper's

Liste des ingrédients

Ciboulette

Caractéristiques organoleptiques

La Ciboulette tubulaire est constituée de feuilles séchées de l'*Allium schoenoprasum*.

Dénomination légale

Ciboulette tubulaire

Conservation : DDM (Date de Durabilité Minimale)

DDM : 36 mois
 DDM minimum à réception : 18 mois

Commentaires

Origine : Chine

Conditions de stockage

A conserver dans un endroit frais et sec

CARACTERISTIQUES PHYSICO-CHIMIQUES		VALEURS NUTRITIONNELLES MOYENNES pour 100g	
Humidité :	max 8 %	Valeur énergétique :	- kcal
aW :	-	soit	- kJ
Cendres totales :	max 13 %	Matières grasses :	- g
Cendres ins. dans l'acide :	max 2 %	dont acides gras saturés :	- g
Huiles essentielles :	- mL/100g	Glucides :	- g
		dont sucres :	- g
		Protéines :	- g
		Sel :	- g
		Fibres alimentaires :	- g

Commentaires Physico-chimie

CARACTERISTIQUES MICROBIOLOGIQUES	Critères	Tolérances
Flore totale / g	-	-
Entérobactéries / g	1 000	10 000
Coliformes totaux / g	-	-
Escherichia coli / g	100	1 000
Salmonella	absence dans 25g	-
Staphylocoques à coagulase positive / g	100	10 000
Listeria monocytogenes	absence dans 1g	100 /g
Anaérobies sulfito-réducteurs /g	-	-
Clostridium perfringens /g	1 000	10 000
Bacillus cereus /g	1 000	5 000
Levures /g	-	-
Moisissures /g	-	-

Commentaires Microbiologie

Epicez, saucez, dosez !





FICHE TECHNIQUE

CIBOULETTE TUBULAIRE FLAPPERS

117801

Indice : f

Date : 20/11/2014

Page : 2 / 2

CONDITIONNEMENT	Emballage primaire	Emballage secondaire	Emballage tertiaire	PaLETTE
Poids net	60 g	0.48 kg	- kg	47.04 kg
Poids brut	123 g	1.184 kg	- kg	139.03 kg
Longueur	- mm	315 mm	- cm	120 cm
Largeur	- mm	160 mm	- cm	80 cm
Hauteur	215 mm	220 mm	- cm	175 cm
Matériau	-	Carton	-	-
Marquage	-	-	-	-
GENCOD	3344540027736	3344540026111	-	-
Nb. emballages primaires	-	8	-	-
Plan de palettisation	Nb colis par rangée : 14		Nb rangées par palette : 7	Nb total colis par palette : 98

ALLERGENES (selon la directive 2007/68/CE)		Présence
AI11	Céréales contenant du gluten (à savoir blé, seigle, orge, avoine, épeautre, Kamut ou leurs souches hybrides) et Produits à base de ces Céréales.	Non
AI12	Poissons et Produits à base de Poissons.	Non
AI13	Crustacés et Produits à base de Crustacés.	Non
AI14	Oeufs et Produits à base d'Oeufs.	Non
AI15	Arachides et Produits à base d'Arachides.	Non
AI16	Soja et Produits à base de Soja.	Non
AI17	Lait et Produits à base de lait (y compris lactose)	Non
AI18	Fruits à coque, à savoir amandes, noisettes, noix, noix de cajou, noix de pécan, noix du Brésil, pistaches, noix de macadamia et noix du Queensland et Produits à base de ces fruits.	Non
AI19	Graines de sésame et Produit à base de graines de sésame.	Non
AI110	Céleri et Produits à base de céleri.	Non
AI111	Moutarde et Produits à base de moutarde.	Non
AI112	Anhydride sulfureux et sulfites en concentrations de plus de 10 mg/kg ou 10 mg/l exprimées en SO2.	Non
AI113	Lupin et Produits à base de lupin.	Non
AI114	Mollusques et produits à base de mollusques.	Non
Commentaires Allergènes		

ATTESTATIONS

Conformément à la réglementation européenne sur les OGM (règlements CE n°1829/2003 et 1830/2003), ce produit est un ingrédient conventionnel et ne nécessite donc pas d'étiquetage spécifique.

Conformément à la directive 1999/2/CE, ce produit n'est pas ionisé et ne contient aucun ingrédient soumis à ionisation.

Cette fiche technique est conforme au règlement UE 1169/2011.

CERTIFICATIONS



Une gamme complète de sauces et d'épices pour les professionnels de la restauration...



B.2 Étiquettes produit

B.3 Fiches logistiques

Annexe C

LE CODE UTILISÉ

,

Analyse quantitative

Pierre MASSÉ

April 22, 2020

1 Analyse quantitative multibranche

```
[1]: # data analysis
import pandas as pd
pd.options.display.width=108
import numpy as np

# visualization
import matplotlib.pyplot as plt
import seaborn as sns
from matplotlib_venn import venn3_unweighted, venn3
import matplotlib as mpl
# mpl.rcParams['text.usetex'] = True
# plt.rcParams['text.latex.preamble'] = [r'\usepackage{lmodern}']

# utils
from pathlib import Path
```

Définition des couleurs :

```
[2]: c_pomona = tuple(val / 255 for val in [0, 92, 132])
c_terreazur = tuple(val / 255 for val in [0, 152, 170])
c_episaveurs = tuple(val / 255 for val in [255, 69, 0])
c_passionfroid = tuple(val / 255 for val in [109, 32, 124])
c_deliceetcreation = tuple(val / 255 for val in [97, 45, 28])
c_saveursdantoine = tuple(val / 255 for val in [156, 34, 63])
```

On charge les données d'un fichier exporté du système de gestion des branches RHD (SAP).

```
[3]: path = Path('.') / 'data' / 'export2020.csv'

types = {
    'material': 'object',
    'branch': 'int',
    'plant': 'object',
    'type': 'object',
    'designation': 'object',
    'del_mand': 'bool',
    'del_plant': 'bool',
    'march_group': 'object',
    'storage_cond': 'object',
    'hier': 'object',
}
df = pd.read_csv(path,
                 sep=';',
                 encoding='latin-1',
                 engine='python',
                 header=0,
                 skipfooter=1, # footer line with totals in export
                 dtype=types,
                 true_values=['X'], # for del_mand and del_plant
                 false_values=['', np.nan], # for del_mand and del_plant
                 )
```

```
df = df[types.keys()] #filter and reorder columns
```

Parmi les colonnes conservées, on a : - le code article (material)

- le code de branche de création (branch).
 - 1: PassionFroid
 - 2: EpiSaveurs
 - 3: TerreAzur
- le code d'activation sur une branche (plant).
 - 1PPF: PassionFroid
 - 2PES: EpiSaveurs
 - 3PTA: TerreAzur
- le type d'article (type). Seuls ZNEG et ZPRE représentent des articles de marchandises.
 - ZNEG: Négoce
 - ZPRE: Prestation
 - ZENG: Article d'engagement (fictif pour facturation)
 - ZEMB: Article d'emballage (ex: palette)
 - ZSER: Article de service
- le libellé de l'article (designation)
- si l'article est marqué pour suppression pour toutes les branches (del_mand)
- si l'article est marqué pour suppression sur la branche mentionnée dans la colonne plant (del_plant).
- le groupe de marchandises (march_group) :
 - ZSURGE: Surgelés
 - ZFRAIS: Frais (PassionFroid)
 - ZEPI: Epicerie
 - ZBOI: Boissons
 - ZHYG: Hygiène et chimie
 - ZFLF: Fruits et légumes (TerreAzur)
 - ZPMF: Produits de la mer (TerreAzur)
 - ZFP: Fleurs et plantes
 - ZELAB: Produits élaborés (TerreAzur)
- la condition de stockage (storage_cond) :
 - FR: Frais (PassionFroid)
 - SU: Surgelé,
 - EP: Epicerie,
 - AL: Alcool
 - HY: Hygiène et chimie
 - FL: Fruits et légumes (TerreAzur)
 - FP: Fleurs et plantes
 - MA: Marée
 - SA: Saurisserie (produits élaborés de la mer)
 - SE: Articles de Service
 - PL: Articles de publicité
- la hiérarchie produit (hier). Un plan de classement sur 6 niveaux, représentés par 2 caractères numériques chacun.

On crée une nouvelle feature qui correspond au niveau 1 de la hiérarchie produit.

```
[4]: # Creation of first level of product hierarchy
df.loc[:, 'hier1'] = df.hier.str[:2]
```

On définit un dictionnaire permettant de rappeler les libellés long des divers codes présents dans le dataset.

```
[5]: # Label names
lab = {'type': 'Type de produit',
      'march_group': 'Groupe de marchandises',
      'storage_cond': 'Condition de stockage',
      'hier1': 'Niveau 1 hiérarchie produit',
      '1PPF': 'PassionFroid',
      '2PES': 'EpiSaveurs',
      '3PTA': 'TerreAzur',
      'ZNEG': 'Article de négoce',
      'ZPRE': 'Article de prestation',
      'ZSURGE': 'Surgelés',
      'ZFRAIS': 'Frais',
      'ZEPI': 'Epicerie',
      'ZBOI': 'Boissons',
      'ZHYG': 'Hygiène',
```

```

'ZFLF': 'Fruits et Légumes',
'ZPMF': 'Produits de la mer',
'ZELAB': 'Produits élaborés',
'ZFP': 'Fleurs et plantes',
'ZAUTRE': 'Autres',
'SU': 'Surgelés',
'FR': 'Frais',
'EP': 'Epicerie',
'AL': 'Alcool',
'HY': 'Hygiène',
'FL': 'Fruits et légumes',
'MA': 'Marée',
'FP': 'Fleurs et plantes',
'SA': 'Saurisserie',
'PL': 'Publicité',
'10': 'Beurre, oeufs, fromage',
'20': 'Elaborés',
'30': 'Garnitures et fruits',
'40': 'Produits carnés',
'50': 'Produits de la mer',
'60': 'Consommables',
'70': 'Emballage',
'80': 'Publicité sur le lieu de vente',
'83': 'Epicerie',
'85': 'Liquides',
'87': 'Hygiène et entretien',
'90': 'Services',
'92': 'Fruits',
'94': 'Légumes',
'96': 'Produits de la mer Frais',
'98': 'Fleurs - plantes',
}

```

```
[6]: df.loc[[5000, 90000, 100000, 130000, 110000], :]
```

```

[6]:      material  branch plant  type      designation  del_mand  del_plant  \
5000      15712         2  2PES  ZNEG  PSVNX CERN BRISURE S/AZ SAC 1KGX12 CERNO      True      True
90000     153086         3  3PTA  ZNEG    MANGUE KENT 351/550G PAD 12F DELIC BR°    False    False
100000     165387         1  1PPF  ZNEG              SALADE PLT 1KGX12 HAMAL    False    False
130000     203582         1  1PPF  ZPRE  EFFILOCHE BOEUF BARBACOA (2KGX6)/12KG CS    False    False
110000     177238         2  2PES  ZNEG    COMP POIRE ALL BIO BTE 5/1X3 STM    False    False

      march_group storage_cond      hier hier1
5000           ZEPI          EP  832020500505    83
90000          ZFLF          FL  920518010405    92
100000         ZFRAIS          FR  202520150505    20
130000         ZSURGE          SU  401015051505    40
110000          ZEPI          EP  832005451505    83

```

On va définir deux masques, permettant de filtrer : - les articles actifs (i.e. non supprimé niveau mandant ni branche) - les articles actifs de marchandises (i.e. qui ne sont pas des articles “spéciaux”)

```

[7]: active_mask = ~df.del_mand & ~df.del_plant
      active_march_mask = active_mask & df.type.isin(['ZNEG', 'ZPRE'])

```

On peut calculer la volumétrie d'articles et la représenter comme un histogramme. Les données de Délice et Création et Saveurs d'Antoine sont issue d'estimations fournies par le métier.

```

[8]: counts = df.groupby('plant')['material'].count().rename('Total')
      filtered_counts = df[active_mask].groupby('plant')['material'].count().rename('Actifs')
      filtered_counts2 = df[active_march_mask].groupby('plant')['material'].count().rename('Marchandises')

      report = pd.concat([counts, filtered_counts, filtered_counts2], axis=1)
      report.loc['Délice et Création', :] = [10000, np.nan, np.nan]
      report.loc['Saveurs d\'Antoine', :] = [12000, np.nan, np.nan]
      report.rename({'1PPF': 'PassionFroid',

```

```

        '2PES': 'EpiSaveurs',
        '3PTA': 'TerreAzur'},
        inplace=True)
report.index.rename('Branche', inplace=True)
report = report.astype('Int64')
report.to_latex(Path('.') / 'tbls' / 'Articles par branche.tex',
                bold_rows=True,
                column_format='lccc',
                na_rep='-')
report

```

```

[8]:


```

	Total	Actifs	Marchandises
Branche			
PassionFroid	48478	24898	24554
EpiSaveurs	22498	12798	12241
TerreAzur	73804	62789	62710
Délice et Création	10000	NaN	NaN
Saveurs d'Antoine	12000	NaN	NaN

```

[9]: fig, ax = plt.subplots(figsize=(5,3))
report.plot(kind='bar', ax=ax)
ax.set_title('Nombre d\'articles par branche')
ax.set_xlabel('')
fig.savefig(Path('.') / 'img' / 'Articles par branche.png', bbox_inches='tight')

```



On peut également contruire le diagramme de Venn des articles pour les branches RHD :

```

[10]: # Filtering the dataset with active materials, and active merchandize materials
branch_sets = [set(df.loc[df.plant == branch_, 'material']) for branch_ in ['1PPF', '2PES', '3PTA']]

filtered_df = df.loc[active_mask]

```



```

filtered_sets = [set(filtered_df.loc[filtered_df.plant == branch_, 'material']) for branch_ in ['1PPF', '2PES', '3PTA']]

filtered_march_df = df.loc[active_march_mask]
filtered_march_sets = [set(filtered_march_df.loc[filtered_march_df.plant == branch_, 'material'])
                      for branch_ in ['1PPF', '2PES', '3PTA']]

```

```

[11]: # This function is used to add label on Venn diagrams axes without showing spines
# (matplotlib-venn disables totally axis's, and spines need to get erased after
# axis's reactivation)

```

```

def labelize(ax, label, where='bottom', **kwargs):
    ax.set_axis_on()
    for spine in ['top', 'bottom', 'left', 'right']:
        ax.spines[spine].set_visible(False)
    if where == 'bottom':
        ax.set_xlabel(label, **kwargs)
    elif where == 'left':
        ax.set_ylabel(label, **kwargs)
    else:
        raise ValueError(f"Unexpected 'where' argument: {where}")

```

```

[12]: # Construction of the diagrams

```

```

scope = ['Total', 'Actifs', 'Marchandises']
types = ['Non pondéré', 'Pondéré']
nrows, ncols = len(types), len(scope)

fig, axs = plt.subplots(nrows, ncols, sharex='col', sharey='row', figsize=(18, 8))


for col, source_df in enumerate([branch_sets, filtered_sets, filtered_march_sets]):
    for row, venn_kind in enumerate([venn3_unweighted, venn3]):
        venn_kind(source_df, set_labels=['PassionFroid', 'EpiSaveurs', 'TerreAzur'], ax=axs[row, col])
        if col == 0:
            labelize(axs[row, col], types[row], where='left', fontsize=18, labelpad=10)
        if row == 1:
            labelize(axs[row, col], scope[col], where='bottom', fontsize=18, labelpad=40)

# Adjusting the min and max of axes lims, as they are not the same by default
xmin = min([axs[row][col].get_xlim()[0] for row in range(nrows) for col in range(ncols)])
xmax = max([axs[row][col].get_xlim()[1] for row in range(nrows) for col in range(ncols)])
ymin = min([axs[row][col].get_ylim()[0] for row in range(nrows) for col in range(ncols)])
ymax = max([axs[row][col].get_ylim()[1] for row in range(nrows) for col in range(ncols)]) + 0.1

for row in range(nrows):
    for col in range(ncols):
        axs[row, col].set_xlim(xmin, xmax)
        axs[row, col].set_ylim(ymin, ymax)

# Saving the file to disk so that it is included in the report
fig.savefig(Path('.') / 'img' / 'Diagrammes de Venn articles.png', bbox_inches='tight')

```



On peut constater que les articles utilisés par les 3 branches RHD sont des articles “spéciaux”.

```
[13]: df[df.material.isin(df.material.value_counts()[df.material.value_counts() >= 3].index)]
```

```
[13]:
```

	material	branch	plant	type	designation	del_mand	\
144564	DECOMPTE	1	2PES	ZSER	ARTICLE DE DECOMPTE CONDITIONS ARRIERES	False	
144565	DECOMPTE	1	3PTA	ZSER	ARTICLE DE DECOMPTE CONDITIONS ARRIERES	False	
144566	DECOMPTE	1	1PPF	ZSER	ARTICLE DE DECOMPTE CONDITIONS ARRIERES	False	
144612	FC41849	1	1PPF	ZSER	RÉGUL SURFACTURATION DÉCONDITIONNEMENT	False	
144613	FC41849	1	2PES	ZSER	RÉGUL SURFACTURATION DÉCONDITIONNEMENT	False	
144614	FC41849	1	3PTA	ZSER	RÉGUL SURFACTURATION DÉCONDITIONNEMENT	False	
144642	LOT_ENGT	1	1PPF	ZENG	LOT ENGAGEMENT	False	
144643	LOT_ENGT	1	3PTA	ZENG	LOT ENGAGEMENT	False	
144644	LOT_ENGT	1	2PES	ZENG	LOT ENGAGEMENT	False	
144719	S_PALETTE_PERDUE	3	3PTA	ZEMB	PALETTE 80X120 PERDUE	False	
144720	S_PALETTE_PERDUE	3	2PES	ZEMB	PALETTE 80X120 PERDUE	False	
144721	S_PALETTE_PERDUE	3	1PPF	ZEMB	PALETTE 80X120 PERDUE	False	

	del_plant	march_group	storage_cond	hier	hier1
144564	False	ZAUTRE	NaN	900505050505	90
144565	False	ZAUTRE	NaN	900505050505	90
144566	False	ZAUTRE	NaN	900505050505	90
144612	False	ZAUTRE	NaN	900505050505	90
144613	False	ZAUTRE	NaN	900505050505	90
144614	False	ZAUTRE	NaN	900505050505	90
144642	False	NaN	NaN	NaN	NaN
144643	False	NaN	NaN	NaN	NaN
144644	False	NaN	NaN	NaN	NaN
144719	False	ZAUTRE	NaN	700510050505	70
144720	False	ZAUTRE	NaN	700510050505	70
144721	False	ZAUTRE	NaN	700510050505	70

On peut ensuite essayer de représenter les comptages d'articles sur les diverses variables catégorielles.

```
[14]: # Definition of feature and order to show
features = {'type': None,
            'march_group': ['ZFRAIS', 'ZSURGE', 'ZEPI', 'ZHYG', 'ZBOI', 'ZFLF', 'ZPMF', 'ZELAB', 'ZFP'],
            'storage_cond': ['FR', 'SU', 'EP', 'HY', 'FL', 'MA', 'SA', 'FP', 'PL'],
            'hier1': None,
            }
```

```

# Definition of color palette
palette = {'1PPF': c_passionfroid,
          '2PES': c_episaveurs,
          '3PTA': c_terreazur,
          }

```

```

[15]: fig, axs = plt.subplots(nrows=len(features), ncols=2, figsize=(13, 15))
# for each feature, draw counts without and with hue
for idx, (feature, order) in enumerate(features.items()):
    # drawing without hue
    sns.countplot(data=df.loc[active_march_mask],
                  x=feature,
                  order=order,
                  ax=axs[idx][0],
                  color=c_pomona)

    # remove y label, and set x label to full length text
    axs[idx][0].set_ylabel('')
    axs[idx][0].set_xlabel(lab[feature], fontsize=16)
    # drawing with hue
    sns.countplot(data=df.loc[active_march_mask],
                  x=feature,
                  hue='plant',
                  order=order,
                  palette=palette,
                  ax=axs[idx][1],
                  )

    # remove y label, and set x label to full length text
    axs[idx][1].set_ylabel('')
    axs[idx][1].set_xlabel(lab[feature], fontsize=16)
    # hide legend for each axis
    axs[idx][1].legend().set_visible(False)

# redraw legend for the whole figure, above, centered and
# expanded
handles, labels = axs[3][1].get_legend_handles_labels()
fig.legend(handles,
          [lab[label] for label in labels],
          ncol=len(handles),
          title='Branches',
          loc='center',
          bbox_to_anchor=(0, 1, 1, 0.25),
          bbox_transform=axs[0][1].transAxes,
          # mode='expand',
          )


# adding a title
fig.suptitle('Répartition des articles selon les features catégorielles',
            fontsize=24,
            y=1.025,
            va='bottom',
            )

# adding padding between plots
fig.tight_layout(pad=3.0)

# saving to disk
fig.savefig(Path('..' ) / 'img' / 'Repartition articles categories.png', bbox_inches='tight')

```

Répartition des articles selon les features catégorielles



```
[24]: def long_lab(label):
    if label in lab:
        return(label + ' - ' + lab[label])
    else:
        return(label)

for feature in features.keys():
    # Construct the pivot table for the feature
```

```

piv = pd.pivot_table(df.loc[active_march_mask],
                     columns='plant',
                     index=feature,
                     values='material',
                     aggfunc='count',
                     fill_value=0,
                     )

# Add a 'Total' column
piv['Total'] = piv['1PPF'] + piv['2PES'] + piv['3PTA']

# Changing 0s to '-'
piv = piv.replace(0, '-')

# Reorder indices so that they follow the order defined in
# lab dictionary
if np.all(piv.index.isin(lab.keys())): # check to avoid filtering piv!
    piv = piv.reindex([key for key in lab.keys() if key in piv.index])

# Rename indices, columns and axes for pretty printing
piv = (piv.rename(long_lab, axis=0)
       .rename(lab, axis=1)
       .rename_axis(lab[feature])
       .rename_axis('Branche', axis=1))

print(piv)
print('-----')
# Save to LaTeX format to be included in report
piv.to_latex(Path('.') / 'tbls' / ('Repartition par ' + feature + '.tex'),
             bold_rows=True,
             column_format='lcccc',
             na_rep='-',
             )

```

Branche	PassionFroid	EpiSaveurs	TerreAzur	Total
Type de produit				
ZNEG - Article de négoce	17166	11048	61273	89487
ZPRE - Article de prestation	7388	1193	1437	10018

Branche	PassionFroid	EpiSaveurs	TerreAzur	Total
Groupe de marchandises				
ZSURGE - Surgelés	7756	-	-	7756
ZFRAIS - Frais	13785	6	4	13795
ZEPI - Epicerie	2298	8305	-	10603
ZBOI - Boissons	126	826	-	952
ZHYG - Hygiène	350	3078	-	3428
ZFLF - Fruits et Légumes	4	-	44133	44137
ZPMF - Produits de la mer	142	-	11594	11736
ZELAB - Produits élaborés	91	-	6644	6735
ZFP - Fleurs et plantes	-	-	297	297
ZAUTRE - Autres	2	26	38	66

Branche	PassionFroid	EpiSaveurs	TerreAzur	Total
Condition de stockage				
SU - Surgelés	7758	-	-	7758
FR - Frais	13781	6	3	13790
EP - Epicerie	2430	9155	-	11585
HY - Hygiène	344	3080	-	3424
FL - Fruits et légumes	78	-	49508	49586
MA - Marée	126	-	10501	10627
FP - Fleurs et plantes	-	-	286	286
SA - Saurisserie	34	-	2408	2442
PL - Publicité	2	-	1	3

Branche	PassionFroid	EpiSaveurs	TerreAzur	Total
Niveau 1 hiérarchie produit				
10 - Beurre, oeufs, fromage	3010	6	1	3017
20 - Elaborés	4150	2	6	4158
30 - Garnitures et fruits	1701	-	-	1701

40 - Produits carnés	11413	-	-	11413
50 - Produits de la mer	1214	-	2	1216
60 - Consommables	1	-	-	1
70 - Emballage	-	1	-	1
80 - Publicité sur le lieu de vente	34	25	37	96
83 - Epicerie	2306	8296	-	10602
85 - Liquides	135	836	-	971
87 - Hygiène et entretien	348	3075	-	3423
90 - Services	10	-	-	10
92 - Fruits	35	-	26543	26578
94 - Légumes	37	-	22929	22966
96 - Produits de la mer Frais	160	-	12891	13051
98 - Fleurs - plantes	-	-	301	301

C.2 Gestion du fichier de configuration

Ce petit module a pour but de permettre de gérer les paramètres du programme dans un fichier de configuration (afin de simplifier la maintenance). Il est utilisé dans l'ensemble des autres modules de ce projet.

```
"""Configuration Module

This module provides a class that enables to fetch configuration stored in the
cfg folder and make it available to other python modules.
"""

import yaml
import os

class Config:

    def __init__(self, env):
        if env not in {'dev', 'int', 'rec', 'qat', 'prd'}:
            raise ValueError(f'Specified env : {env} not expected')
        self.env = env
        self.path = os.path.join(os.path.dirname(__file__),
                                  '..',
                                  'cfg',
                                  'config.yaml')
        stream = open(self.path, 'r')
        data = yaml.safe_load(stream)
        config_keys = data['cross-env'].keys()
        for k in config_keys:
            setattr(self, k, data['cross-env'][k])
        config_keys = data[env].keys()
        for k in config_keys:
            setattr(self, k, data[env][k])
```

Un exemple de fichier de configuration (dont certains champs ont été anonymisés pour des raisons de confidentialité) est présenté ci-dessous. TODO!! Mettre le fichier ici. TODO : retirer ce test. Aller voir à la page 68!

C.3 Extraction des données du PIM

```
"""PIM API Module

This module aims to enable to fetch data from PIM system, into local folders.
"""

import requests
import os
import json
import warnings
```

```

import pandas as pd
import numpy as np
import copy
import threading
from requests.exceptions import ConnectionError

from . import conf

warnings.simplefilter('always', UserWarning)

class Requester(object):
    """Requester class to retrieve information from PIM
    """
    def __init__(self, env, proxies='default', auth=None):
        self.cfg = conf.Config(env)
        self.session = requests.Session()
        if not auth:
            self.session.auth = (self.cfg.user, self.cfg.password)
        else:
            self.session.auth = auth
        if proxies == 'default':
            try:
                target_proxies = self.cfg.proxies
            except (AttributeError):
                print('No proxy conf found for env : \'{self.cfg.env}\'. '
                      'No proxy will be used.')
                target_proxies = None
        else:
            target_proxies = proxies
        self.session.proxies = target_proxies
        if proxies == 'default':
            # We try the connection with the default proxy conf
            # If it fails, we retry with no proxy configuration
            # (e.g. in the case of working from outside the network)
            try:
                self.check_connection()
            except (ConnectionError):
                self.session.proxies = None
                self.check_connection()
        else:
            # If a proxy configuration has been passed as an argument, we
            # only validate the connexion with that configuration.
            self.check_connection()
        self.rlock = threading.RLock()
        self.result = []
        try:
            self._load_directory()
        except FileNotFoundError:
            warnings.warn('No directory found for current env : '
                          f'\'{self.cfg.env}\'. A new directory should be '
                          'set.')

    def check_connection(self):

```



```

"""Checks wether the connection with the environments works

The methods tries to get content of PIM system homepage. It returns
True if the request is handled properly, or raises an exception.
Note: this method does NOT check whether credentials are correct.
"""

resp = self.session.get(self.cfg.baseurl)
if resp.status_code != 200:
    raise ConnectionError('Connection could not be validated during '
                          'check_connection method call.for '
                          f'environment : \'{self.cfg.env}\'' )

return(True)

def check_credentials(self):
    """Checks wether the credentials provided allow to connect to PIM

The methods tries to get content of PIM root document. It returns
True if the request is handled properly, or raises an exception.
Note: if the connection is invalid for another reason (e.g. incorrect
proyx configuration), an exception will be raised. the
'check_connection' method should be used prior to checking the
credentials.
"""

resp = self.session.get(self.cfg.baseurl +
                        self.cfg.suffixid +
                        self.cfg.rootuid)
if resp.status_code != 200:
    raise ConnectionError('Connection could not be validated during '
                          'check_credentials method call for '
                          f'environment : \'{self.cfg.env}\'' )

return(True)

def fetch_all_from_PIM(self, nx_properties='*', max_page=None,
                      page_size=None,):
    """Fetches all product data from PIM into result

This method fetches all product data from PIM. It implements
multithreading to speed up retrieval.
"""

    query = (f"SELECT * "
             f"FROM Document "
             f"WHERE ecm:primaryType='pomProduct' "
             f"AND ecm:isVersion=0")
    headers = {'Content-Type': 'application/json',
              'X-NXproperties': nx_properties}
    params = {'query': query}
    url = (self.cfg.baseurl +
          self.cfg.suffixid +
          self.cfg.rootuid + '/' +
          '@search')
    result_count = self.query_size(headers, params, url)
    self.result = []
    max_page = max_page if max_page else self.cfg.maxpage
    page_size = page_size if page_size else self.cfg.pagesize

```

```

params['pageSize'] = page_size
thread_count = result_count // page_size + 1
if max_page != - 1 and thread_count > max_page:
    thread_count = max_page
    warnings.warn(f'\nMax size reached ! \n'
                  f'Only {max_page * page_size} results will be '
                  f'fetched out of {result_count} results\n')

threads = []
for page_index in range(thread_count):
    t = threading.Thread(target=self.get_page_from_query,
                        args=(url, headers, params, page_index))

    t.start()
    threads.append(t)
for t in threads:
    t.join()
print('Done')

def get_page_from_query(self, url, headers, params, currentPageIndex=0):
    """Fetches data for a single page of results

    This methods fetches data for a prepared query for a single page. It
    is used to implement multithreading for `fetch_all_from_PIM`
    """
    try:
        local_params = copy.deepcopy(params)
        local_params['currentPageIndex'] = currentPageIndex
        resp = self.session.get(url,
                                headers=headers,
                                params=local_params)

        with self.rlock:
            self.result.append(resp)
    except Exception as e:
        print('An error ocured in this thread!')
        print(e)

def fetch_list_from_PIM(self, iter_uid, batch_size=50, nx_properties='*'):
    """Fetches data from an uid iterable, from PIM

    This method fetches the data from PIM based on a iterable of uids.
    It creates threads to fetch the complete list, and bases on the
    Nuxeo @search API with a WHERE clause. It may therefore be less
    fast than a full fetch.

    Due to http limitations, it requires that no more than 50 uid be
    retrieved at a time in a single thread. Failing to enforce will result
    in incomplete responses an missed results.
    """
    if batch_size > 50:
        raise ValueError(f'batch_size needs to be < 50. '
                        f'Call with:{batch_size}')

    query = (f"SELECT * "
            f"FROM Document "
            f"WHERE ecm:primaryType='pomProduct' "
            f"AND ecm:isVersion=0")

    headers = {'Content-Type': 'application/json',

```

```

        'X-NXproperties': nx_properties}

url = (self.cfg.baseurl +
       self.cfg.suffixid +
       self.cfg.rootuid + '/' +
       '@search')

uid_lists = [iter_uid[i:i+batch_size]
              for i in range(0, len(iter_uid), batch_size)]

thread_list = []
self.result = []
for uid_list in uid_lists:
    uid_string = ', '.join(["'" + str(uid) + "'" for uid in uid_list])
    local_query = query + f" AND ecm:uuid in ({uid_string})"
    params = {'query': local_query}
    t = threading.Thread(target=self.get_page_from_query,
                        args=(url, headers, params))

    t.start()
    thread_list.append(t)
for thread in thread_list:
    thread.join()
print('Done')

def query_size(self, headers, params, url):
    """Runs a single result query to get the number of results

    This methods takes a query to be sent to Nuxeo in order to count the
    number of results.

    It then execute the query with page_size=1 and max_page=1 to fetch a
    single result, and extracts the total number of results from the
    response.
    """
    loc_headers = copy.deepcopy(headers)
    loc_headers['X-NXproperties'] = ''
    loc_params = copy.deepcopy(params)
    loc_params['pageSize'] = 1
    loc_params['currentPageIndex'] = 0
    resp = self.session.get(url,
                            headers=loc_headers,
                            params=loc_params)
    return(resp.json()['resultsCount'])

def _root_path(self):
    """Returns the root path for the dumps
    """
    return(os.path.join(os.path.dirname(__file__),
                        '..',
                        'dumps',
                        self.cfg.env))

def dump_data_from_result(self, filename='data.json',
                          update_directory=True, root_path=None):
    """Dumps data from result attribute as JSON files

    This method dumps data from result as JSON files.
    Note that result MUST be an iterable of responses (be it from PIM or

```

```

from disk), each response should have an 'entries' list of documents.
"""

if update_directory and not hasattr(self, '_directory'):
    self._load_directory()
now = pd.Timestamp.now(tz='UTC')
threads = []
for single_result in self.result:
    t = threading.Thread(target=self.dump_data_from_single_result,
                        args=(single_result, filename, now),
                        kwargs={'update_directory': update_directory,
                              'root_path': root_path})

    t.start()
    threads.append(t)
for t in threads:
    t.join()
print('Done')

def dump_data_from_single_result(self, single_result, filename, now,
                                update_directory=True, root_path=None):
    """Dumps data from a single result

    This method dumps data from a single result passed as an argument.
    It is used for multithreading the result list.
    """
    try:
        doc_list = single_result.json()['entries']
        s_list = []
        if root_path is None:
            root_path = self._root_path()
        for document in doc_list:
            path = os.path.join(root_path, document['uid'])
            if not os.path.exists(path):
                os.makedirs(path)
            full_path = os.path.join(path, filename)
            with open(full_path, 'w+') as outfile:
                json.dump(document, outfile)
            s_list.append(pd.Series(now,
                                   index=[document['uid']],
                                   name='lastFetchedData'))

        df = pd.concat(s_list, axis=0)
        if update_directory:
            with self.rlock:
                self._directory.update(df)
                self._save_directory()
    except Exception as e:
        print('An error occurred in this thread!')
        print(e)

def dump_files_from_result(self, update_directory=True, root_path=None):
    """Dumps attached files from result items on disk

    This method dumps files from PIM on disk.
    It also updates the local directory with current datetime.
    Note that result MUST be an iterable of responses (be it from PIM or

```

```

from disk), each response should have an 'entries' list of documents,
and each document mention the files attached to it.
Attached files definition MUST be set in the config.yaml file.
"""

if update_directory and not hasattr(self, '_directory'):
    self._load_directory()
now = pd.Timestamp.now(tz='UTC')
threads = []
print(f'Launching {len(self.result)} threads.')
for single_result in self.result:
    t = threading.Thread(target=self.dump_files_from_single_result,
                        args=(single_result, now),
                        kwargs={'update_directory': update_directory,
                              'root_path': root_path})

    t.start()
    threads.append(t)
for t in threads:
    t.join()
print('Done')

def dump_files_from_single_result(self, single_result, now,
                                update_directory=True, root_path=None):
    """Dumps attached files from items on disk - for a single result

    This method dumps files from a single result into the disk. It is used
    for multithreading in `dump_files_from_result` method.
    """
    try:
        doc_list = single_result.json()['entries']
        s_list = []
        if root_path is None:
            root_path = self._root_path()
        for document in doc_list:
            path = os.path.join(root_path, document['uid'])
            if not os.path.exists(path):
                os.makedirs(path)
            self.dump_attached_files(document, path)
            s_list.append(pd.Series(now,
                                   index=[document['uid']],
                                   name='lastFetchedFiles'))

        df = pd.concat(s_list, axis=0)
        if update_directory:
            with self.rlock:
                self._directory.update(df)
                self._save_directory()
            print('Thread complete!')
        except Exception as e:
            print('An error occurred in this thread!')
            print(e)

def _dump_file(self, file_url, path, filename='file'):
    """Dumps a file on disk from its url"""
    resp = self.session.get(file_url,
                            auth=(self.cfg.user, self.cfg.password),

```

```

        stream=True)
    full_path = os.path.join(path, filename)
    with open(full_path, 'wb') as outfile:
        outfile.write(resp.content)

def dump_attached_files(self, document, path):
    """Dumps attached files from a nuxeo document

    This function fetches attached files from a nuxeo document (stored as
    a JSON).
    Files definitions are stored in the configuration file.
    """
    for filekind, filedef in self.cfg.filedefs.items():
        try:
            pointer = document
            for node in filedef['nuxeopath']:
                pointer = pointer[node]
            nxfilename = pointer['name']
            url = (self.cfg.baseurl +
                  self.cfg.suffixfile +
                  self.cfg.nxrepo +
                  document['uid'] + '/' +
                  filedef['nuxeopath'][-1])
            ext = Requester.compute_extension(nxfilename)
            filename = filedef['dumpfilename'] + '.' + ext
            self._dump_file(url, path, filename=filename)
        except TypeError:
            pass

def get_directory(self, **kwargs):
    """Get the uid directory for the environment as a pandas DataFrame

    This function fetches the uid directory data for the current
    environment as a pandas DataFrame.
    To fetch all the results, set max_page attribute to -1.
    This function returns data as is from PIM, and requires it to be
    formatted as a directory later on with `_init_as_directory` or
    `_format_as_directory` methods. (else, columns are not consistent with
    directory definition)
    """
    self.fetch_all_from_PIM(nx_properties='', **kwargs)
    df_list = []
    for single_result in self.result:
        df_list.append(pd.DataFrame(single_result.json()['entries'])
                      .set_index('uid'))
    df = pd.concat(df_list)
    df['lastModified'] = pd.to_datetime(df.loc[:, 'lastModified'])
    return(df)

    @staticmethod
    def _directory_headers():
        """Returns the directory headers
        """
        headers = ['type',

```

```

        'title',
        'lastModified',
        'lastRefreshed',
        'lastFetchedData',
        'lastFetchedFiles']

    return(headers)

def _load_directory(self, filename=None):
    """Loads directory from disk into the tool attribute
    """
    directory_filename = filename if filename else self.cfg.uiddirectory
    full_path = os.path.join(self._root_path(), directory_filename)
    self._directory = (pd.read_csv(full_path,
                                   encoding='utf-8-sig',
                                   parse_dates=['lastModified',
                                                'lastRefreshed',
                                                'lastFetchedData',
                                                'lastFetchedFiles'])
                       .set_index('uid'))
    self._directory = Requester._format_as_directory(self._directory)

    @staticmethod
    def _init_as_directory(df):
        """Sets initial dates values for dataframes to be used as directories
        """
        df['lastRefreshed'] = pd.Timestamp.now(tz='UTC')
        df['lastFetchedData'] = np.nan
        df['lastFetchedFiles'] = np.nan
        return(Requester._format_as_directory(df))

    @staticmethod
    def _format_as_directory(df):
        """Formats a dataframe as a directory from dtypes point of view

        This method formats a dataframe columns as to be consistent with
        directory definition. It DOES NOT set initial values (see
        `_init_as_directory`).
        """
        types = {'lastFetchedData': 'datetime64[ns, UTC]',
                 'lastFetchedFiles': 'datetime64[ns, UTC]'}
        df = df.astype(types)
        df = df.loc[:, Requester._directory_headers()]
        return(df)

def reset_directory(self, page_size=None, max_page=None, filename=None):
    """COMPLETELY RESETS the directory for the environment

    Warning: this function will completely reset the directory for the
    current environment. It should only be used when first setting the
    directory or if it requires being remade from scratch.

    Warning: this function should never be used with max_page parameter
    different from -1 as it could result in incomplete data to erase
    current directory. Only relevant usage of max_page != -1 is for
    debugging purpose.

```

```

    """
    self._directory = Requester._init_as_directory(
        self.get_directory(max_page=max_page, page_size=page_size))
    self._save_directory()

def refresh_directory(self, max_page=None, filename=None, page_size=None):
    """Refreshes the directory for the environment

    Warning: this function should never be used with max_page parameter
    different from -1 except for debugging purpose. Yet, doing so does
    not corrupt or lose data whatsoever.
    """
    new_dir = self.get_directory(max_page=max_page, page_size=page_size)
    new_dir = Requester._init_as_directory(new_dir)
    self._load_directory(filename=filename)
    cur_dir = Requester._format_as_directory(self._directory)
    cur_dir.update(new_dir)
    cur_dir = pd.concat([cur_dir,
                        new_dir[~new_dir.index.isin(cur_dir.index)]])
    self._directory = cur_dir
    self._save_directory()

def _save_directory(self, filename=None):
    """Saves current directory to disk

    This methods saves the current directory to disk.
    """
    directory_filename = filename if filename else self.cfg.uiddirectory
    full_path = os.path.join(self._root_path(), directory_filename)
    self._directory.to_csv(full_path, encoding='utf-8-sig')

def modified_items(self, what='any', max_results=None):
    """Returns modified items according to directory

    This methods compares the date of last modification stored in the
    directory to the date of last fetching of data or attached files.
    If what = 'any', all outdated items will be returned
    If what = 'data', it will return only items with outdated data
    If what = 'files', it will return only items with outdated files
    max_results enables to fetch only a limited count of results.
    This returns an uid list
    """
    if not hasattr(self, '_directory'):
        self._load_directory()
    df = self._directory
    if what == 'any':
        mask = (df.lastFetchedFiles.isna() |
                (df.lastModified > df.lastFetchedFiles) |
                df.lastFetchedData.isna() |
                (df.lastModified > df.lastFetchedData))
    elif what == 'data':
        mask = (df.lastFetchedData.isna() |
                (df.lastModified > df.lastFetchedData))
    elif what == 'files':

```



```

        mask = (df.lastFetchedFiles.isna() |
                 (df.lastModified > df.lastFetchedFiles))

    else:
        raise ValueError(f"Unexpected 'what' argument: {what}")
    uid_list = mask.index[mask].tolist()
    if max_results:
        uid_list = uid_list[:max_results]
    return(uid_list)

def modification_report(self):
    """Prints some elements about current state

    This methods bases on current state of directory.
    """
    if not hasattr(self, '_directory'):
        self._load_directory()
    print(f'Number of items: {len(self._directory)}')
    print(f'Number of items with outdated data: '
          f'{len(self.modified_items(what="data"))}')
    print(f'Number of items with outdated files: '
          f'{len(self.modified_items(what="files"))}')

@staticmethod
def compute_extension(filename):
    """Computes the extension from a filename

    Returns the extension. If the filename has no "." (dot) in it, returns
    an empty string. If the computed extension has strictly more than 4
    characters, returns the empty string."""
    splitted = filename.split('.')
    if len(splitted) == 1:
        return('')
    elif len(splitted[-1]) > 4:
        return('')
    else:
        return(filename.split('.')[-1].lower())

def result_to_dataframe(self,
                        record_path='entries',
                        meta=None,
                        mapping=None,
                        index='uid'):
    """Formats result content as a dataframe with defined format

    record_path and meta are pandas json_normalize method arguments
    mapping is a key : adress mapping that maps return dataframe keys to
    data adress in the JSON. Reminder: json_normalize default separator
    is '.'

    So, for example if you want to have a record path down to the
    ingredients table (that is, down to
    record > properties > pprodc:mainIngredients), with the uid product as
    index, you should use the following parameters:

    record_path=['entries', 'properties', 'pprodc:mainIngredients'],
    meta=[['entries', 'uid']],

```

```

        index='entries.uid'
index is the field identifier(s) for the field(s) to be used as index
"""

result_json = [result.json() for result in self.result]
if mapping:
    with CleanJSONDataFrame(result_json,
                             record_path=record_path,
                             meta=meta) as df:
        for key, path in mapping.items():
            try:
                df[key] = df[df.prefix + path]
            except KeyError:
                df[key] = np.nan
    df = df.df
else:
    df = pd.json_normalize(result_json,
                           record_path=record_path,
                           meta=meta)

if index:
    df.set_index(index, inplace=True)
return(df)

def file_report_from_result(self, mapping, index=None, record_path=None):
    """Returns a dataframe about the files contained in the result

    This methods analyzes the content of the result, and generates a
    dataframe which enables the analysis of the files on the products
    Files to report on are based on the content of the config.yaml
    configuration file.
    """

    if not record_path:
        record_path = 'entries'
    for filekind, filedef in self.cfg.filedefs.items():
        mapping[filekind] = '.'.join(filedef['nuxeopath']) + '.name'
    df = self.result_to_dataframe(record_path=record_path,
                                  mapping=mapping,
                                  meta=None,
                                  index=index)

    for filekind in self.cfg.filedefs:
        df['has_' + filekind] = df[filekind].notna()
        del(df[filekind])
    return(df)

class CleanJSONDataFrame(object):
    """Context manager class for cleanly importing data from JSON

    This class enables to create a context manager that enables to read JSON
    data into a dataframe, by specifying the data to keep (this feature is not
    provided yet by the pandas json_normalize). It does so by following these
    steps:
    - read data from a JSON into a new dataframe
    - enable one to duplicate loaded data into new fields
    - delete the loaded data when exiting, thus keeping only duplicated data

```

Complicated prefix is set to avoid duplicates in column names.

```

"""
def __init__(self, data, record_path=None, meta=None,
              prefix='_prev_duplc1'):
    self.df = pd.json_normalize(data, record_path=record_path,
                                meta=meta, record_prefix=prefix,
                                meta_prefix=prefix)

    self.prefix = prefix
    self.columns = list(self.df.columns.values)

def __enter__(self):
    return(self)

def __exit__(self, exc_type, exc_val, exc_tb):
    self.df.drop([c for c in self.columns], axis=1, inplace=True)

```

C.4 Analyse des données du PIM

Analyse donnees du PIM

Pierre MASSÉ

April 25, 2020

1 Analyse des données du PIM

1.1 Extraction des données

1.1.1 Préambule technique

```
[1]: # setting up sys.path for relative imports
from pathlib import Path
import sys
project_root = str(Path(sys.path[0]).parents[1].absolute())
if project_root not in sys.path:
    sys.path.append(project_root)
```

```
[2]: # imports and customization of display
import io
import pandas as pd
pd.options.display.min_rows = 6
pd.options.display.width=108
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.ticker as ticker

from src.pimapi import Requester
```

1.1.2 Récupération des données

Le requêtage des données dans le PIM s'appuie sur la classe `Requester` du module `pimapi`.

```
[5]: requester = Requester('prd')
# Let's fetch the full content of PIM system
requester.fetch_all_from_PIM()
requester.result
```

Done

```
[5]: [<Response [200]>,
      <Response [200]>,
      <Response [200]>,
      <Response [200]>,
      <Response [200]>,
      <Response [200]>,
      <Response [200]>,
      <Response [200]>,
      <Response [200]>,
      <Response [200]>,
      <Response [200]>,
      <Response [200]>,
      <Response [200]>]
```

A ce stade, les données sont chargées en mémoire sous la forme de fichiers JSON. La conversion des données récupérées par l'API se fait via la méthode `result_to_dataframe` de la classe `Requester`.

```
[6]: df = requester.result_to_dataframe()
df.head(4)
```

```
[6]: entity-type repository \

uid
afee12c7-177e-4a68-9539-8cbb68442503 document default
7d390121-17e8-43bf-a357-9d06b79d2d47 document default
f234cd84-c8f6-433f-85ec-6e0b6980adc6 document default
e82a8173-b379-41ac-b319-aa058a04fcfb document default

path type \
uid
afee12c7-177e-4a68-9539-8cbb68442503 /default-domain/pomSupplierWorkspace/SICO/DEST... pomProduct
7d390121-17e8-43bf-a357-9d06b79d2d47 /default-domain/pomSupplierWorkspace/UNILEVER_... pomProduct
f234cd84-c8f6-433f-85ec-6e0b6980adc6 /default-domain/pomSupplierWorkspace/AZTECA_FO... pomProduct
e82a8173-b379-41ac-b319-aa058a04fcfb /default-domain/pomSupplierWorkspace/UVCDR_-C... pomProduct

state \
uid
afee12c7-177e-4a68-9539-8cbb68442503 product.waiting.supplier.validation
7d390121-17e8-43bf-a357-9d06b79d2d47 product.waiting.supplier.validation
f234cd84-c8f6-433f-85ec-6e0b6980adc6 product.waiting.supplier.validation
e82a8173-b379-41ac-b319-aa058a04fcfb product.waiting.sending.supplier

parentRef isCheckedOut isVersion \
uid
afee12c7-177e-4a68-9539-8cbb68442503 a58845c0-cab3-492f-b48d-531f146c3777 True False
7d390121-17e8-43bf-a357-9d06b79d2d47 a37abc27-f485-4ae9-921b-f761f16c8c1c False False
f234cd84-c8f6-433f-85ec-6e0b6980adc6 3ff7819a-a392-493f-beb8-0b323ac331c7 True False
e82a8173-b379-41ac-b319-aa058a04fcfb e4b5167c-ece2-4f7a-83c1-fb884034a1bf False False

isProxy changeToken ... \
uid
afee12c7-177e-4a68-9539-8cbb68442503 False 17-0 ...
7d390121-17e8-43bf-a357-9d06b79d2d47 False 15-0 ...
f234cd84-c8f6-433f-85ec-6e0b6980adc6 False 33-0 ...
e82a8173-b379-41ac-b319-aa058a04fcfb False 19-0 ...

properties.pprodqmqdd:manufacturingDiagram.length \
uid
afee12c7-177e-4a68-9539-8cbb68442503 NaN
7d390121-17e8-43bf-a357-9d06b79d2d47 NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6 NaN
e82a8173-b379-41ac-b319-aa058a04fcfb NaN

properties.pprodqmqdd:manufacturingDiagram.data \
uid
afee12c7-177e-4a68-9539-8cbb68442503 NaN
7d390121-17e8-43bf-a357-9d06b79d2d47 NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6 NaN
e82a8173-b379-41ac-b319-aa058a04fcfb NaN

properties.pprodq:visualPhoto.name \
uid
afee12c7-177e-4a68-9539-8cbb68442503 NaN
7d390121-17e8-43bf-a357-9d06b79d2d47 NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6 NaN
e82a8173-b379-41ac-b319-aa058a04fcfb NaN

properties.pprodq:visualPhoto.mime-type \
uid
afee12c7-177e-4a68-9539-8cbb68442503 NaN
7d390121-17e8-43bf-a357-9d06b79d2d47 NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6 NaN
e82a8173-b379-41ac-b319-aa058a04fcfb NaN

properties.pprodq:visualPhoto.encoding \
```

```

uid
afee12c7-177e-4a68-9539-8cbb68442503      NaN
7d390121-17e8-43bf-a357-9d06b79d2d47      NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6      NaN
e82a8173-b379-41ac-b319-aa058a04fcfb      NaN

                                properties.pprodq:visualPhoto.digestAlgorithm \

uid
afee12c7-177e-4a68-9539-8cbb68442503      NaN
7d390121-17e8-43bf-a357-9d06b79d2d47      NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6      NaN
e82a8173-b379-41ac-b319-aa058a04fcfb      NaN

                                properties.pprodq:visualPhoto.digest \

uid
afee12c7-177e-4a68-9539-8cbb68442503      NaN
7d390121-17e8-43bf-a357-9d06b79d2d47      NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6      NaN
e82a8173-b379-41ac-b319-aa058a04fcfb      NaN

                                properties.pprodq:visualPhoto.length \

uid
afee12c7-177e-4a68-9539-8cbb68442503      NaN
7d390121-17e8-43bf-a357-9d06b79d2d47      NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6      NaN
e82a8173-b379-41ac-b319-aa058a04fcfb      NaN

                                properties.pprodq:visualPhoto.data properties.notif:notifications

uid
afee12c7-177e-4a68-9539-8cbb68442503      NaN      NaN
7d390121-17e8-43bf-a357-9d06b79d2d47      NaN      NaN
f234cd84-c8f6-433f-85ec-6e0b6980adc6      NaN      NaN
e82a8173-b379-41ac-b319-aa058a04fcfb      NaN      NaN

[4 rows x 487 columns]

```

1.2 Définitions pour les mises en formes

1.2.1 Descriptifs longs

On définit un dictionnaire permettant de “traduire” les codes de champs en libellés long.

```

[7]: lab = {
      'code': 'Code produit',
      'supplier': 'Code fournisseur',
      'type': 'Type de produit',
      'GTIN': 'GTIN',
      'base_unit': 'Unité de base',
      'net_weight': 'Poids net',
      'gross_weight': 'Poids brut',
      'dry_weight': 'Poids net égoutté',
      'volume': 'Volume',
      'total_life': 'Durée de vie totale',
      'remaining_life': 'Durée minimale restante',
      'type_cons': 'Type de conservation',
      'before_open': 'Conservation avant ouv.',
      'after_open': 'Conservation après ouv.',
      'cons_temp': 'Température',
    }

```

1.2.2 Champs intéressants

On liste également les champs intéressants pour un affichage plus court du dataframe.

```

[8]: def_fields = {'properties.vig:code': 'code',
                  'properties.psec:supplierCode': 'supplier',

```

```
'properties.pprodtop:typeOfProduct': 'type',
'properties.pprodi:gtin': 'gtin',
'properties.pprodi:supplierDesignation': 'designation'}
```

1.3 Description des attributs des produit

1.3.1 Volumétrie des attributs

On constate que chaque produit porte un très grand nombre d'attributs :

```
[9]: print('Count of columns in df:', len(df.columns))
      print('\nInfo of df:')
      df.info()
```

Count of columns in df: 487

```
Info of df:
<class 'pandas.core.frame.DataFrame'>
Index: 13193 entries, afee12c7-177e-4a68-9539-8cbb68442503 to 6dfce29e-fd4c-4670-9f9c-5c02a5b4d52a
Columns: 487 entries, entity-type to properties.notif:notifications
dtypes: bool(12), float64(60), int64(2), object(413)
memory usage: 48.1+ MB
```

De plus, de par la nature hiérarchique du format JSON, certains attributs dits “multivalués” sont parfois stockés sous forme de liste dans le dataframe “à plat”. Par exemple, on peut voir que le pays de transformation, ou les facettes, peuvent être multivalués.

```
[10]: df.loc[['609af223-2f14-4f83-a553-cef276f2eca7',
              'c94013e4-0dca-441a-85c1-0b29ecb54d0a',
              '82d1af25-2bdd-4315-9670-67784b70dfa7'],
            ['properties.pprodg:transfoCountries',
             'facets']]
```

```
[10]:                                     properties.pprodg:transfoCountries \
uid
609af223-2f14-4f83-a553-cef276f2eca7                                     [PL, FR, ES]
c94013e4-0dca-441a-85c1-0b29ecb54d0a    [DE, NO, BE, RU, CH, BG, LT, GR, FR, UA, HU, E...
82d1af25-2bdd-4315-9670-67784b70dfa7                                     [FR]

                                     facets
uid
609af223-2f14-4f83-a553-cef276f2eca7    [Versionable, Folderish, Commentable, beginnin...
c94013e4-0dca-441a-85c1-0b29ecb54d0a    [endMigration, Versionable, Folderish, Comment...
82d1af25-2bdd-4315-9670-67784b70dfa7    [endMigration, Versionable, Folderish, Comment...
```

De plus, certains attributs sont dits “complexes”, car chacune des valeurs de la liste est elle-même un dictionnaire d'attribut. La combinaison des deux, des attributs “complexes multivalués” existe également. On a alors une liste de dictionnaires. On peut comme ceci imbriquer des niveaux jusqu'à n'importe quelle profondeur.

C'est par exemple le cas des labels qui sont multivalués (un produit peut porter plusieurs labels), qui sont des complexes portant : - le type de label (bio, Label Rouge, ...) - la date de fin de validité du label (si applicable) - le fichier de certification du label (si applicable), qui est lui-même un complexe...

```
[11]: multilabel_ds = df.loc[df['properties.pprod1:labels'].apply(len) > 1, 'properties.pprod1:labels']
      for uid, label_list in multilabel_ds.head(3).iteritems():
          print('product uid:', uid)
          for cpt, label in enumerate(label_list):
              print('\n\tlabel', cpt + 1, ':')
              for key, val in label.items():
                  print('\t\t', key, ':', val)
          print('-----')
```

product uid: 362e6230-ba3a-4396-8a47-728b0a1d56db

```
label 1 :
      labelCertificateEndDate : 2024-12-30T23:00:00.000Z
```

```

        typeOfLabel : 80
        labelCertificateFile : {'name': 'KCC Coleshill Tissue Paper Ecolabel Renewal Certificate
Mar 2020.pdf', 'mime-type': 'application/pdf', 'encoding': None, 'digestAlgorithm': 'MD5', 'digest':
'6615e3027ff2e014fdc3fa37e67851bb', 'length': '425662', 'data': 'https://produits.groupe-pomona.fr/nuxeo/nxf
ile/default/362e6230-ba3a-4396-8a47-728b0a1d56db/pprodl:labels/0/labelCertificateFile/KCC%20Coleshill%20Tiss
ue%20Paper%20Ecolabel%20Renewal%20Certificate%20Mar%202020.pdf?changeToken=36-0'}

        label 2 :
            labelCertificateEndDate : 2022-09-16T22:00:00.000Z
            typeOfLabel : NA
            labelCertificateFile : {'name': 'FCC_DoC_Coleshill Mill_PW_blue_Ref13351_Eng V01.pdf',
'mime-type': 'application/pdf', 'encoding': None, 'digestAlgorithm': 'MD5', 'digest':
'78cfcc67b8bf0f693e060088f7d97c48', 'length': '84473', 'data': 'https://produits.groupe-pomona.fr/nuxeo/nxfi
le/default/362e6230-ba3a-4396-8a47-728b0a1d56db/pprodl:labels/1/labelCertificateFile/FCC_DoC_Coleshill%20Mil
l_PW_blue_Ref13351_Eng%20V01.pdf?changeToken=36-0'}
-----
product uid: 3c2a8d1a-634d-40bb-9852-81eb8a340114

        label 1 :
            labelCertificateEndDate : None
            typeOfLabel : 30
            labelCertificateFile : None

        label 2 :
            labelCertificateEndDate : None
            typeOfLabel : 40
            labelCertificateFile : None
-----
product uid: d3681e26-b024-4603-ae0b-0d5630329fa0

        label 1 :
            labelCertificateEndDate : 2020-03-30T22:00:00.000Z
            typeOfLabel : 100
            labelCertificateFile : {'name': 'SAS - Certificat AB V2.pdf', 'mime-type':
'application/pdf', 'encoding': None, 'digestAlgorithm': 'MD5', 'digest': '1d424d2d2c9539abca07b8ad9576a339',
'length': '128780', 'data': 'https://produits.groupe-pomona.fr/nuxeo/nxfile/default/d3681e26-b024-4603-ae0b-
0d5630329fa0/pprodl:labels/0/labelCertificateFile/SAS%20-%20Certificat%20AB%20V2.pdf?changeToken=92-0'}

        label 2 :
            labelCertificateEndDate : 2020-03-30T22:00:00.000Z
            typeOfLabel : 80
            labelCertificateFile : {'name': 'SAS - Certificat AB V2.pdf', 'mime-type':
'application/pdf', 'encoding': None, 'digestAlgorithm': 'MD5', 'digest': '1d424d2d2c9539abca07b8ad9576a339',
'length': '128780', 'data': 'https://produits.groupe-pomona.fr/nuxeo/nxfile/default/d3681e26-b024-4603-ae0b-
0d5630329fa0/pprodl:labels/1/labelCertificateFile/SAS%20-%20Certificat%20AB%20V2.pdf?changeToken=92-0'}
-----

```

1.3.2 Description des principaux attributs

On commence par déclarer des utilitaires permettant de mettre en forme les représentations.

```

[12]: # Defining main data to explore
mappings = {
    'identification': {
        'properties.vig:code': 'code',
        'properties.psec:supplierCode': 'supplier',
        'properties.pprodtop:typeOfProduct': 'type',
        'properties.pprodi:gtin': 'GTIN',
    },
    'dimensions': {
        'properties.pprodtop:baseUnit': 'base_unit',
        'properties.pprodg:netWeight': 'net_weight',
        'properties.pprodg:grossWeight': 'gross_weight',
        'properties.pprodg:dryWeight': 'dry_weight',
        'properties.pprodg:volume': 'volume',
    },
    'conservation': {

```



```

        'properties.pprodg:totalLife': 'total_life',
        'properties.pprodg:guaranteedLife': 'remaining_life',
        'properties.pprodg:typeOfConservation': 'type_cons',
        'properties.pprodg:conservationBeforeOpening': 'before_open',
        'properties.pprodg:conservationAfterOpening': 'after_open',
        'properties.pprodg:conservationTemperature': 'cons_temp',
    }
}

# Helper function to transform pandas `to_latex` method output to a tabularx env instead.
def to_tabularx(stringio):
    text = stringio.getvalue()
    text = text.replace(r'\begin{tabular}', r'\begin{tabularx}{\linewidth}')
    text = text.replace(r'\end{tabular}', r'\end{tabularx}')
    return(text)

# Function that saves dataframe as Latex tabularx files as input
def save_to_disk(df, path, lab=lab, tex_label=None):
    text = io.StringIO()
    c_format = 'l' + 'X' * len(df.columns)
    (df.rename(lab, axis=1)
     .to_latex(text,
               bold_rows=True,
               column_format=c_format,
               na_rep='-',
               label=tex_label,
               ))
    with open(path, mode='w') as file:
        file.write(to_tabularx(text))

```

On boucle sur les différents mappings, et on les sauvegarde dans des tableaux latex pour intégration au rapport.

```

[13]: for map_type, mapping in mappings.items():
    cur_df = df.loc[:, list(mapping.keys())].rename(mapping, axis=1).fillna(np.nan)
    desc = cur_df.describe(include='all')
    samp = cur_df.sample(n=5, random_state=42)
    print(map_type)
    print(samp.rename(lab, axis=1))
    print('-----')
    print(desc.rename(lab, axis=1)
          .round(3)
          )
    print('-----')

    # Writing dataframes to .tex files
    text = io.StringIO()
    c_format = 'l' + 'X' * len(cur_df.columns)
    (samp.rename(lab, axis=1)
     .to_latex(text,
               bold_rows=True,
               column_format=c_format,
               na_rep='-'
               ))
    with open(Path('.') / 'tbls' / ('Exemple ' + map_type + '.tex'), mode='w') as file:
        file.write(to_tabularx(text))

    text = io.StringIO()
    (desc.rename(lab, axis=1)
     .round(3)
     .to_latex(text,
               bold_rows=True,
               column_format=c_format,
               na_rep='-'
               ))
    with open(Path('.') / 'tbls' / ('Desc ' + map_type + '.tex'), mode='w') as file:
        file.write(to_tabularx(text))

```

identification		Code produit	Code fournisseur	Type de produit	GTIN	
uid						
1351c135-0d48-41ae-a568-2f33af6fdae9		PIMP-0000011253	PIMF-0000000416	grocery	3760063337099	
ffabf67f-314e-47a8-932e-37da7a3ab1ae		PIMP-0000011972	PIMF-0000000486	hygiene	NaN	
7bb3d9a9-d50c-4042-9d28-21b31f5cbbb1		PIMP-0000009973	PIMF-0000000328	alcoholicDrink	NaN	
38b95b6e-5603-46bd-ad44-912a926ee0e4		PIMP-0000012507	PIMF-0000000391	chemistry	7615400045495	
8738c768-9d5d-4233-b54c-99358fa66411		PIMP-0000000321	PIMF-0000000074	hygiene	3504082216054	

	Code produit	Code fournisseur	Type de produit	GTIN		
count	13193	13193	13193	12025		
unique	13193	605	5	11339		
top	PIMP-0000000721	PIMF-0000000179	grocery			
freq	1	370	8756	352		

dimensions		Unité de base	Poids net	Poids brut	Poids net égoutté	Volume
uid						
1351c135-0d48-41ae-a568-2f33af6fdae9		SAC	0.500	0.520	NaN	NaN
ffabf67f-314e-47a8-932e-37da7a3ab1ae		PU	NaN	NaN	NaN	NaN
7bb3d9a9-d50c-4042-9d28-21b31f5cbbb1		BIB	1.500	1.600	NaN	1.5
38b95b6e-5603-46bd-ad44-912a926ee0e4		BT.	1.053	1.150	NaN	NaN
8738c768-9d5d-4233-b54c-99358fa66411		COL	3.000	3.028	NaN	NaN

	Unité de base	Poids net	Poids brut	Poids net égoutté	Volume	
count	13193	12827.000	12827.000	1026.000	1915.000	
unique	30	NaN	NaN	NaN	NaN	
top	BTE	NaN	NaN	NaN	NaN	
freq	3051	NaN	NaN	NaN	NaN	
mean	NaN	3.112	2.986	1.475	7.750	
std	NaN	59.600	42.171	1.133	78.897	
min	NaN	0.000	0.000	0.000	0.000	
25%	NaN	0.482	0.535	0.480	0.500	
50%	NaN	1.000	1.100	1.500	0.946	
75%	NaN	3.000	3.298	2.380	2.500	
max	NaN	4900.000	4730.500	10.000	3100.000	

conservation		Durée de vie totale	Durée minimale restante	Type de conservation	\	
uid						
1351c135-0d48-41ae-a568-2f33af6fdae9		NaN		720.0		AM
ffabf67f-314e-47a8-932e-37da7a3ab1ae		NaN		NaN		NaN
7bb3d9a9-d50c-4042-9d28-21b31f5cbbb1		NaN		NaN		AM
38b95b6e-5603-46bd-ad44-912a926ee0e4		NaN		NaN		AM
8738c768-9d5d-4233-b54c-99358fa66411		NaN		NaN		AM

	Conservation avant ouv.	Conervation après ouv.	Température			
uid						
1351c135-0d48-41ae-a568-2f33af6fdae9		ambientTemperature	coolAndDryPlace	NaN		
ffabf67f-314e-47a8-932e-37da7a3ab1ae		NaN	NaN	NaN		
7bb3d9a9-d50c-4042-9d28-21b31f5cbbb1		ambientTemperature	notConcerned	NaN		
38b95b6e-5603-46bd-ad44-912a926ee0e4		NaN	NaN	NaN		
8738c768-9d5d-4233-b54c-99358fa66411		NaN	NaN	NaN		

	Durée de vie totale	Durée minimale restante	Type de conservation	Conservation avant ouv.	\	
count	8946.000	9466.000	12806	9977		
unique	NaN	NaN	2	7		
top	NaN	NaN	AM	ambientTemperature		
freq	NaN	NaN	12772	8270		
mean	651.406	351.618	NaN	NaN		
std	487.412	380.255	NaN	NaN		
min	0.000	0.000	NaN	NaN		
25%	360.000	180.000	NaN	NaN		
50%	540.000	300.000	NaN	NaN		
75%	900.000	480.000	NaN	NaN		
max	9999.000	9999.000	NaN	NaN		

Convervation après ouv. Température						

```

count          9947          21
unique         18           9
top            coolAndDryPlace 15
freq           4512          6
mean           NaN          NaN
std            NaN          NaN
min            NaN          NaN
25%            NaN          NaN
50%            NaN          NaN
75%            NaN          NaN
max            NaN          NaN

```

1.3.3 Analyses spécifiques : GTIN

On peut mettre en évidence les produits qui portent les mêmes GTIN en double. En y jetant un oeil rapide, quelques explications peuvent être trouvées : - il peut s'agir d'un changement de code fournisseur (les 2 premières lignes ne portent pas le même code fournisseur) - il peut s'agir d'un changement de recette côté industriel, qui a décidé de conserver le même GTIN (second couple) - il peut s'agir d'une erreur, et de produits en doublon dans le système (troisième couple) - ...

```

[14]: GTIN_mask = (df['properties.pprodi:gtin'] != '') & ~(pd.isna(df['properties.pprodi:gtin']))
dups_mask = df.loc[GTIN_mask, 'properties.pprodi:gtin'].duplicated(keep=False)
examples = (df.loc[GTIN_mask & dups_mask, def_fields.keys()]
            .rename(def_fields, axis=1)
            .sort_values('gtin')
            .head(8))
save_to_disk(examples,
             Path('.') / 'tbls' / 'Duplicated_GTIN.tex',
             lab={},
             tex_label='tab:dup_gtin',
             )
print(examples)

```

uid	code	supplier	type	gtin \
048712e3-f145-4f40-b8ad-7c0b912983bd	PIMP-0000009515	PIMF-0000000420	grocery	0020176760607
4de8ce87-8df5-440c-959d-3d77d59bb4f3	PIMP-0000013159	PIMF-0000000182	grocery	0020176760607
7e455046-def3-4526-a28b-bc5c0e6e64fc	PIMP-0000011456	PIMF-0000000290	grocery	03344540125906
a92c6ac5-d5be-4f92-98b3-9f6c588f7613	PIMP-0000013198	PIMF-0000000290	grocery	03344540125906
66590f04-5eae-4829-b0da-c899a18dd9cb	PIMP-0000010839	PIMF-0000000250	grocery	3011360083845
27e20042-dc53-46b4-874c-f970db554aec	PIMP-0000001494	PIMF-0000000250	grocery	3011360083845
02803e27-487a-43e3-9324-9ad1660b63b2	PIMP-0000002338	PIMF-0000000348	grocery	3038353024906
52d3f309-e402-4931-974c-b6b6fa721aff	PIMP-0000002337	PIMF-0000000348	grocery	3038353024906

uid	designation
048712e3-f145-4f40-b8ad-7c0b912983bd	42 QUICHE FEUILL SG 11CM
4de8ce87-8df5-440c-959d-3d77d59bb4f3	QUICHE FEUILLETEE
7e455046-def3-4526-a28b-bc5c0e6e64fc	622028 SAUCE FUEGO SQUEEZE DE 580 G "O'TACOS"
a92c6ac5-d5be-4f92-98b3-9f6c588f7613	622029 SAUCE FUEGO (NR) SQUEEZE DE 580 G "O'TA...
66590f04-5eae-4829-b0da-c899a18dd9cb	Jus de poulet en boîte 750g KNORR
27e20042-dc53-46b4-874c-f970db554aec	Jus de poulet en boîte 750 g KNORR
02803e27-487a-43e3-9324-9ad1660b63b2	Torti aux œufs en sac 5 kg PANZANI
52d3f309-e402-4931-974c-b6b6fa721aff	Tagliatelle aux œufs en colis 5 kg PANZANI

Si l'on produit la répartition du nombre de produit portant un GTIN donné dans le système, on obtient :

```

[15]: df2 = (df.pivot_table(values='properties.vig:code',
                           index='properties.pprodi:gtin',
                           aggfunc='count')
        .rename({'properties.vig:code': 'code_count'}, axis=1)
        )

df2 = (df2.reset_index()
        .loc[df2.index != '']
        .pivot_table(index='code_count',
                      aggfunc='count',

```

```

        values='code_count')
    .rename({'properties.pprod:gtin': 'Nb de GTIN'},
            axis=1)
)

df2.index.rename('Pdt portant le GTIN', inplace=True)


print(df2)

save_to_disk(df2,
              Path('.') / 'tbls' / 'gtin_counts.tex')

fig, ax = plt.subplots(figsize=(5,3))
df2.plot(kind='bar', legend=None, title='Nombre de produit par GTIN', ax=ax)
fig.savefig(Path('.') / 'img' / 'repartition_gtin.png', bbox_inches='tight')

```

Pdt portant le GTIN	Nb de GTIN
1	11068
2	227
3	22
4	20
5	1



1.3.4 Analyse spécifique : distribution par fournisseur

On peut représenter la distribution produit, par fournisseur.

```

[16]: # construction the counts
counts = (df.loc[:, list(def_fields.keys())]
         .rename(def_fields, axis=1)
         .pivot_table(values='code',
                       index='supplier',
                       aggfunc='count')
         .reset_index()
         .pivot_table(values=['supplier', 'code'],
                       index='code',
                       aggfunc={'supplier': 'count',
                                'code': 'sum'})
)

```

```

# aligning index to have it continuous
new_idx = pd.RangeIndex(start=1, stop=max(counts.index) + 1)

counts = (counts.reindex(new_idx)
          .fillna(0)
)

counts = pd.concat([counts,
                    counts.cumsum().rename({'code': 'cum_code', 'supplier': 'cum_supplier'},
                                           axis=1),
                    ],
                  axis=1)

for feature in ['supplier', 'code']:
    counts['cump_' + feature] = 100 * counts['cum_' + feature] / counts.loc[:, 'cum_' + feature].iloc[-1]

counts

```

```

[16]:
   code  supplier  cum_code  cum_supplier  cump_supplier  cump_code
1   79.0      79.0    79.0      79.0      13.057851    0.598802
2  138.0      69.0   217.0     148.0     24.462810    1.644812
3  177.0      59.0   394.0     207.0     34.214876    2.986432
..    ...      ...      ...      ...      ...      ...
368  0.0      0.0  12454.0     603.0     99.669421    94.398545
369 369.0      1.0  12823.0     604.0     99.834711    97.195482
370 370.0      1.0  13193.0     605.0    100.000000   100.000000

```

[370 rows x 6 columns]

```

[17]: fig, axs = plt.subplots(nrows=2,
                             ncols=2,
                             figsize=(14, 6),
                             gridspec_kw= {'width_ratios': [2, 1]})

axs2 = [[ax.twinx() for ax in axrow] for axrow in axs]

for i, feature in enumerate(['supplier', 'code']):
    axs[i][0].bar(data=counts.loc[:, feature].reset_index(), x='index', height=feature)
    axs2[i][0].plot('index', 'cump_' + feature, data=counts.loc[:, 'cump_' + feature].reset_index(),
                    color='red', linestyle='--')
    axs2[i][0].grid(True, axis='y', color='red', alpha=0.5, linestyle='--')

    axs[i][1].bar(data=counts.loc[:, feature].reset_index(), x='index', height=feature)
    axs2[i][1].plot('index', 'cump_' + feature, data=counts.loc[:, 'cump_' + feature].reset_index(),
                    color='red', linestyle='--')
    axs2[i][1].grid(True, axis='y', color='red', alpha=0.5, linestyle='--')

    axs[i][1].set_xlim(0, 30)

for i in range(len(axs)):
    for j in range(len(axs[i])):
        axs2[i][j].set_ylim(0, 100)
        # remove all bottom ticks except for bottom line
        # set_yticks does not work as it removes the grid
        if i < len(axs) - 1:
            axs[i][j].set_xticklabels([])
            for tic in axs[i][j].xaxis.get_major_ticks():
                tic.tick1line.set_visible(False)
                tic.tick2line.set_visible(False)
        # remove all right ticks except for right column
        # set_yticks does not work as it removes the grid
        if j < len(axs[i]) - 1:
            axs2[i][j].set_yticklabels([])
            for tic in axs2[i][j].yaxis.get_major_ticks():
                tic.tick1line.set_visible(False)
                tic.tick2line.set_visible(False)

```

```

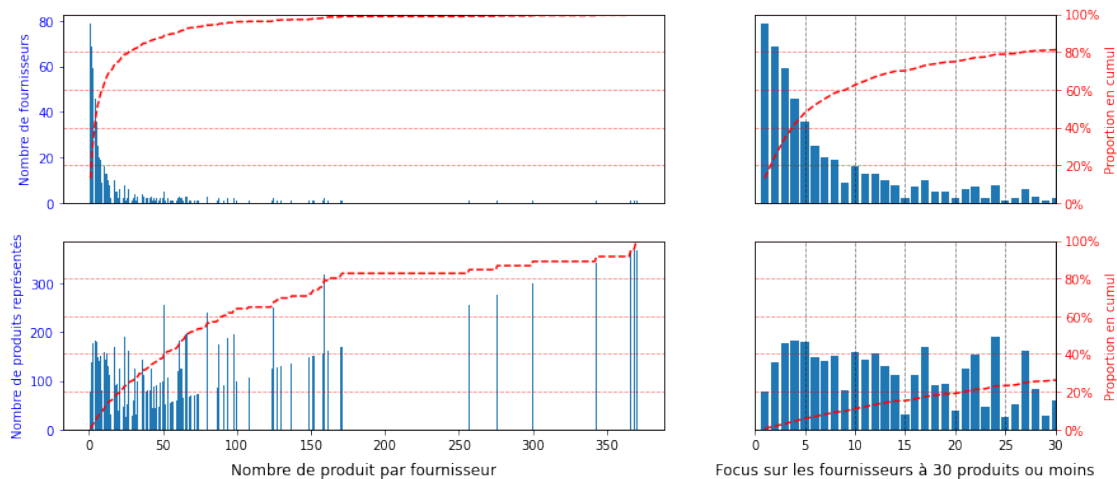
# remove all left ticks except for first column
if j > 0:
    axs[i][j].set_yticks([])
if j == len(axs[i]) - 1:
    axs2[i][j].tick_params(axis='y', colors='red')
    axs2[i][j].yaxis.set_major_formatter(ticker.PercentFormatter())
    axs2[i][j].set_ylabel('Proportion en cumul', color='red')
    axs[i][j].grid(True, axis='x', color='k', alpha=0.5, linestyle='--')
if j == 0:
    axs[i][j].tick_params(axis='y', colors='blue')
    if i == 0:
        axs[i][j].set_ylabel('Nombre de fournisseurs', color='blue')
    if i == 1:
        axs[i][j].set_ylabel('Nombre de produits représentés', color='blue')
axs[1][0].set_xlabel('Nombre de produit par fournisseur',
                    fontsize=12,
                    labelpad=8,
                    )
axs[1][1].set_xlabel('Focus sur les fournisseurs à 30 produits ou moins',
                    fontsize=12,
                    labelpad=8,
                    )

fig.suptitle('Distribution des fournisseurs fonction du nombre de produit par fournisseur',
            fontsize=16,
            )

fig.savefig(Path('.') / 'img' / 'distribution_fournisseurs_prd_count.png', bbox_inches='tight')

```

Distribution des fournisseurs fonction du nombre de produit par fournisseur



On peut également représenter le nombre de produits “récupérés” si on prend les fournisseurs par nombre de produits décroissant.

```

[18]: # construction the counts
counts = (df.loc[:, list(def_fields.keys())]
         .rename(def_fields, axis=1)
         .pivot_table(values='code',
                      index='supplier',
                      aggfunc='count')
         .sort_values('code', ascending=False)
         )
counts['code_cumsum'] = counts['code'].cumsum()
counts

```

```
[18]:
```

	code	code_cumsum
supplier		
PIMF-0000000179	370	370
PIMF-0000000250	369	739
PIMF-0000000283	366	1105
...
PIMF-0000000408	1	13191
PIMF-0000000407	1	13192
PIMF-0000000666	1	13193

[605 rows x 2 columns]


```
[19]: fig, axs = plt.subplots(nrows=1,
                             ncols=2,
                             figsize=(14, 3),
                             gridspec_kw= {'width_ratios': [2, 1]})

for j in range(len(axs)):
    axs[j].plot('index',
                'code_cumsum',
                data=counts.reset_index().reset_index(),
                color='red',
                linestyle='--',
                )

    axs[j].set_xlabel('Nombre de fournisseurs', fontsize=12)
    axs[j].set_ylim(0)
    axs[j].set_xlim(0)
    axs[j].grid(True)
    axs[j].yaxis.set_ticks(np.arange(0, 14000, 1000))

axs[0].set_ylabel('Nombre de produits cumulés')
axs[1].set_xlim(0, 30)
axs[1].set_xlabel('Nombre de fournisseurs (limite 30)', fontsize=12)
axs[1].set_yticklabels([])
for tic in axs[1].yaxis.get_major_ticks():
    tic.tick1line.set_visible(False)
    tic.tick2line.set_visible(False)

fig.suptitle('"Rappel" des produits en fonction des fournisseurs', fontsize=16)
fig.savefig(Path('.') / 'img' / 'rappel_produit_par_fournisseur.png', bbox_inches='tight')
```



C.5 Conversion des pièces jointes en textes

```
"""PIM PDF Module
```

```
This module aims to parse the content of PDF files into text.
```

```
"""
```

```
import pandas as pd
from multiprocessing import cpu_count
from pathos.multiprocessing import ProcessPool as Pool
from io import StringIO, BytesIO
from functools import partial

from pdfminer.converter import TextConverter
from pdfminer.layout import LParams
from pdfminer.pdfdocument import PDFDocument
from pdfminer.pdfinterp import PDFResourceManager, PDFPageInterpreter
from pdfminer.pdfpage import PDFPage
from pdfminer.pdfparser import PDFParser

class PDFDecoder(object):
    """Tool that provides basic pdf decoding fonctionnalités"""

    @staticmethod
    def content_to_text(content,
                        none_content='raise'):
        """Decodes the binary passed as argument

        content arg must be a Bytesio object.
        none_content arg must be raise (if it is not expected to have an empty
        input, the default) or to_empty (which will cause to return an empty
        string)
        """

        if none_content not in {'raise', 'to_empty'}:
            raise ValueError(f'Unexpected value for none_content parameter. '
                             f'Got {none_content} but only \'raise\' or '
                             f'\'to_empty\' are expected.')

        if not content.read():
            if none_content == 'raise':
                raise RuntimeError(f'PDFminer got an empty bytesIO object to '
                                   f'parse')

            if none_content == 'to_empty':
                return('')

        output_string = StringIO()
        parser = PDFParser(content)
        doc = PDFDocument(parser)
        rsrcmgr = PDFResourceManager()
        device = TextConverter(rsrcmgr, output_string,
                               laparams=LParams())
        interpreter = PDFPageInterpreter(rsrcmgr, device)
        for page in PDFPage.create_pages(doc):
```



```

        interpreter.process_page(page)
    return(output_string.getvalue())

@staticmethod
def path_to_text(path, missing_file='raise'):
    """Decodes file at local path in the form of a long string
    """
    if missing_file not in {'raise', 'ignore'}:
        raise ValueError(f'Unexpected value for missing_file parameter. '
                        f'Got {missing_file} but only \'raise\' or '
                        f'\'ignore\' are expected.')
    try:
        with open(path, mode='rb') as content:
            return(PDFDecoder.content_to_text(content))
    except FileNotFoundError:
        if missing_file == 'raise':
            raise
        if missing_file == 'ignore':
            print(f'File not found at path: {path}')
            return('')
    except Exception as e:
        print(e)
        print(f'An error happened at path: {path}')
        return('')

@staticmethod
def text_to_blocks(text, split_func=lambda x: x.split('\n\n')):
    """Splits text passed as an argument with splitter function

    split_func should be defined as to return a list like object.
    """
    return(split_func(text))

@staticmethod
def text_to_blocks_series(text, index=None,
                          split_func=lambda x: x.split('\n\n'),
                          return_type='along_index'
                          ):
    """Splits text passed as an argument (using splitter func) to a Series

    The return_type can be:
    - 'along_index': the return is a pandas Series of length the number
                     of blocks (with the index provided)
    - 'as_list'    : the return is a pandas Series of length 1, with
                     the provided scalar as index, and the value of the
                     Series being the blocks as a list of strings

    If return_type is 'along_index' (the default), the index arg is passed
    as provided to pd.Series constructor, or if it is a scalar it is
    broadcasted as a constant on all values.
    """
    blocks_list = PDFDecoder.text_to_blocks(text,
                                             split_func=split_func,
                                             )
    if return_type not in {'along_index', 'as_list'}:

```

```

        raise ValueError(f'Unexpected value for return_type parameter. '
                          f'Got {return_type} but only \'along_index\' or '
                          f'\'as_list\' are expected.')
if return_type == 'as_list':
    return(pd.Series([blocks_list], index=[index]))
elif return_type == 'along_index':
    try:
        return(pd.Series(blocks_list, index=index))
    except TypeError:
        index = [index] * len(blocks_list)
        return(pd.Series(blocks_list, index=index))

@staticmethod
def path_to_blocks(path, split_func=lambda x: x.split('\n\n'),
                  missing_file='raise'):
    """Decodes file at local path in the form of a list of blocks

    Blocks are part of the original string separated by at least 2
    carriage returns (i.e. with at least a single blank line between them)
    """
    text = PDFDecoder.path_to_text(path, missing_file=missing_file)
    return(PDFDecoder.text_to_blocks(text, split_func=split_func))

@staticmethod
def path_to_blocks_series(path,
                        index=None,
                        split_func=lambda x: x.split('\n\n'),
                        missing_file='raise'):
    """Decodes file at local path in the form a pd Series of blocks
    """
    text = PDFDecoder.path_to_text(path, missing_file=missing_file)
    return(PDFDecoder.text_to_blocks_series(text,
                                           split_func=split_func,
                                           index=index))

@staticmethod
def paths_to_blocks(path_series, split_func=lambda x: x.split('\n\n'),
                  missing_file='raise'):
    """Decodes files for each path in path list as a blocks Dataseries

    Blocks are part of the original string after the splitting function
    has been applied.

    The input must be a pandas dataseries of paths.

    The output is another pd Series, with the same indexes as the initial
    series (broadcasted to match the block count for each path)
    """
    ds_list = []
    for uid, path in path_series.items():
        ds = (PDFDecoder
              .path_to_blocks_series(path,
                                    split_func=split_func,
                                    index=uid,
                                    missing_file=missing_file))
        ds_list.append(ds)

```

```

        return(pd.concat(ds_list, axis=0))

    @staticmethod
    def threaded_paths_to_blocks(path_series, processes=None,
                                split_func=lambda x: x.split('\n\n'),
                                missing_file='raise',
                                ):
        """Threaded version of paths_to_blocks method

        It takes as input a series which index is the uid of the products,
        and the values are the path to the document.
        processes argument is the number of processes to launch. If omitted,
        it defaults to the number of cpu cores on the machine.
        """
        processor = partial(PDFDecoder.path_to_blocks_series,
                             split_func=split_func, missing_file=missing_file)
        processes = processes if processes else cpu_count()
        print(f'Launching {processes} processes.')

        # Pool with context manager do not seem to work due to issue 38501 of
        # standard python library. It hangs when running tests through pytest
        # see: https://bugs.python.org/issue38501
        # Below content should be tested again whenever this issue is closed
        #
        # with Pool(nodes=processes) as pool:
        #     ds_list = pool.map(processor,
        #                         path_series, path_series.index)
        #
        # End of block

        # This temporary solution should be removed when tests mentioned above
        # are successful.
        # This just closes each pool after execution or exception.
        try:
            pool = Pool(nodes=processes)
            pool.restart(force=True)
            ds_list = pool.map(processor,
                               path_series,
                               path_series.index)
        except Exception:
            pool.close()
            raise
        pool.close()
        # End of block

        return(pd.concat(ds_list, axis=0))

    @staticmethod
    def threaded_contents_to_text(content_series,
                                  processes=None,
                                  none_content='raise',
                                  ):
        """Threaded version of content_to_text method

```

```

It takes as input a series which index is the uid of the products,
and the values are the content (in the form of bytes) of the
documents.
processes argument is the number of processes to launch. If omitted,
it defaults to the number of cpu cores on the machine.
none_content arg can be 'raise' (default) or to_empty
"""

    processer = partial(PDFDecoder.content_to_text,
                        none_content=none_content,
                        )

    processes = processes if processes else cpu_count()
    print(f'Launching {processes} processes.')
    in_ds = content_series.apply(BytesIO)

    # Pool with context manager do not seem to work due to issue 38501 of
    # standard python library. It hangs when running tests through pytest
    # see: https://bugs.python.org/issue38501
    # Below content should be tested again whenever this issue is closed
    #
    # with Pool(nodes=processes) as pool:
    #     tuples = (list(in_ds.index),
    #               pool.map(processer, in_ds))
    #
    # End of block

    # This temporary solution should be removed when tests mentioned above
    # are successful.
    # This just closes each pool after execution or exception.
    try:
        pool = Pool(nodes=processes)
        pool.restart(force=True)
        tuples = (list(in_ds.index), pool.map(processer, in_ds))
    except Exception:
        pool.close()
        raise
    pool.close()
    # End of block

    ds = pd.Series(tuples[1], index=tuples[0])
    return(ds)

@staticmethod
def threaded_texts_to_blocks(text_series, processes=None,
                             split_func=lambda x: x.split('\n\n'),
                             return_type='along_index'
                             ):
    """Threaded version of text_to_blocks_series method

    It takes as input a series which index is the uid of the products,
    and the values are the content (in the form of bytes) of the
    documents..
    processes argument is the number of processes to launch. If omitted,
    it defaults to the number of cpu cores on the machine.
    As for text_to_blocks_series function, return_type can be 'along_axis'

```

```

or 'list_like'.
"""

processor = partial(PDFDecoder.text_to_blocks_series,
                    split_func=split_func,
                    return_type=return_type)
processes = processes if processes else cpu_count()
print(f'Launching {processes} processes.')

# Pool with context manager do not seem to work due to issue 38501 of
# standard python library. It hangs when running tests through pytest
# see: https://bugs.python.org/issue38501
# Below content should be tested again whenever this issue is closed
#
# with Pool(nodes=processes) as pool:
#     ds_list = pool.map(processor, text_series, text_series.index)
#
# End of block

# This temporary solution should be removed when tests mentioned above
# are successful.
# This just closes each pool after execution or exception.
try:
    pool = Pool(nodes=processes)
    pool.restart(force=True)
    ds_list = pool.map(processor, text_series, text_series.index)
except Exception:
    pool.close()
    raise
pool.close()
# End of block

ds = pd.concat(ds_list, axis=0)
return(ds)

```

C.6 Identification des listes d'ingrédients

```

"""PIM Estimator module

```

```

This modules enables to create an estimator to identify which block is the
ingredient list from an iterable of text blocks.
"""

```

```

import os
from io import BytesIO

import numpy as np
import pandas as pd
from pathlib import Path

from sklearn.feature_extraction.text import CountVectorizer
from sklearn.exceptions import NotFittedError
from sklearn.utils.validation import check_is_fitted
from scipy.sparse.linalg import norm as sparse_norm

```

```

from .pimapi import Requester
from .pimpdf import PDFDecoder
from .conf import Config

class CustomTransformer(object):
    """Abstract class for custom transformers
    """
    def __init__(self, source_col, target_col, target_exists):
        self.source_col = source_col
        self.target_col = target_col
        self.target_exists = target_exists

    def raise_if_not_a_df(self, X):
        if not isinstance(X, pd.DataFrame):
            raise TypeError(f'This transformer expects a pandas Dataframe '
                            f'object. Got an object of type \"{type(X)}\" '
                            f'instead')

    def check_target_exists(self):
        if self.target_exists not in {'raise', 'ignore', 'overwrite'}:
            raise ValueError(f'target_exists parameter should be set to '
                             f'\"raise\" or \"ignore\" or \"to_nan\". Got '
                             f'\"{self.target_exists}\" instead.')

    def raise_if_target(self, X):
        if self.target_col in X.columns and self.target_exists == 'raise':
            raise RuntimeError(f'Column \"{self.target_col}\" already exists '
                               f'in input DataFrame.')

    def raise_if_no_source(self, X):
        if self.source_col and self.source_col not in X.columns:
            raise KeyError(f'Input DataFrame has no \"{self.source_col}\" '
                           f'column.')

    def fit(self, X, y=None):
        self.check_target_exists()
        self.raise_if_not_a_df(X)
        self.raise_if_target(X)
        self.raise_if_no_source(X)

    def transform(self, X):
        check_is_fitted(self)
        self.check_target_exists()
        self.raise_if_not_a_df(X)
        self.raise_if_target(X)
        self.raise_if_no_source(X)
        if self.target_col in X.columns and self.target_exists == 'ignore':
            return(X)

    def fit_transform(self, X, y=None):
        return(self.fit(X).transform(X))

```

```

def get_params(self, deep=True):
    parms = dict()
    parms['source_col'] = self.source_col
    parms['target_col'] = self.target_col
    parms['target_exists'] = self.target_exists
    return(parms)

def set_params(self, **parameters):
    for parameter, value in parameters.items():
        setattr(self, parameter, value)
    return(self)

class IngredientExtractor(object):
    """Estimator that identifies the most 'ingredient like' block from a list
    """
    def __init__(self):
        """Constructor method of ingredient extractor"""
        pass

    def fit(self, X, y=None):
        """Fitter method of ingredient extractor

        X is an iterable of ingredient lists in the form of strings
        y is just here for compatibility in sklearn pipeline usage
        """
        self._count_vect = CountVectorizer()
        self.vectorized_texts_ = self._count_vect.fit_transform(X)
        self.vocabulary_ = self._count_vect.vocabulary_
        self.mean_corpus_ = self.vectorized_texts_.mean(axis=0)
        return(self)

    def predict(self, X):
        """Predicter method of ingredient extractor

        X is a list of text blocks.
        This methods returns the index of the text block that is most likely
        to hold the ingredient list"""
        X_against_ingred_voc = self._count_vect.transform(X)
        X_norms = sparse_norm(CountVectorizer().fit_transform(X), axis=1)
        X_dot_ingred = np.array(X_against_ingred_voc.sum(axis=1)).squeeze()
        pseudo_cosine_sim = np.divide(X_dot_ingred,
                                      X_norms,
                                      out=np.zeros(X_norms.shape),
                                      where=X_norms != 0)

        self.similarity_ = pseudo_cosine_sim
        return(np.argmax(pseudo_cosine_sim))

    def show_emphasize(self, X):
        """Method that prints strings with words from vocabulary emphasized
        """
        for text in self.emphasize_texts(X):
            print(text)

```

```

def emphasize_texts(self, X):
    """Method that returns strings with words from vocabulary emphasized

    This method shows how some candidates texts are projected on the
    vocabulary that has been provided or gotten from fitting.
    It is useful to see how different blocks compare.
    X argument is an iterable of block candidates.
    """
    check_is_fitted(self)
    preprocessor = self._count_vect.build_preprocessor()
    tokenizer = self._count_vect.build_tokenizer()
    vocabulary = self._count_vect.vocabulary_
    emphasized_texts = []
    for block in X:
        text = self.emphasize_words(block,
                                    preprocessor=preprocessor,
                                    tokenizer=tokenizer,
                                    vocabulary=vocabulary,
                                    )
        emphasized_texts.append(text)
    return(emphasized_texts)

def emphasize_words(self,
                    text,
                    preprocessor=None,
                    tokenizer=None,
                    vocabulary=None,
                    ansi_color='\033[92m', # green by default
                    ):
    """Method that returns a string with words emphasized

    This methods takes a string and returns a similar string with the words
    emphasized (with color markers)
    """
    check_is_fitted(self)
    ansi_end_block = '\033[0m'
    if not preprocessor:
        preprocessor = self._count_vect.build_preprocessor()
    if not tokenizer:
        tokenizer = self._count_vect.build_tokenizer()
    if not vocabulary:
        vocabulary = self._count_vect.vocabulary_
    preprocessed_text = preprocessor(text)
    tokenized_text = tokenizer(preprocessed_text)
    idx = 0
    emphasized_text = ''
    for token in tokenized_text:
        if token in vocabulary:
            while preprocessed_text[idx: idx + len(token)] != token:
                emphasized_text += text[idx]
                idx += 1
            emphasized_text += (ansi_color + text[idx: idx + len(token)] +
                               ansi_end_block)
            idx += len(token)

```



```

        emphasized_text += text[idx:]
    return(emphasized_text)

def score(self, X, y):
    """Scorer method of ingredient extractor estimator

    X is an iterable of ingredient lists in the form of string
    y is the target as the index of the correct block.
    """
    pass

class PIMIngredientExtractor(IngredientExtractor):
    """Wrapped estimator that directly extracts the ingredient list from uid
    """
    def __init__(self, env='prd', **kwargs):
        self.requester = Requester(env, **kwargs)
        super().__init__()

    def compare_uid_data(self, uid):
        check_is_fitted(self)
        print(f'Fetching data from PIM for uid {uid}...')
        self.requester.fetch_list_from_PIM(uid)
        try:
            ingredient_list = (self.requester.result[0]
                               .json()['entries'][0]['properties']
                               ['pprodc:ingredientsList'])
        except IndexError:
            raise IndexError(f'Fetching data with uid {uid} ')
        print('-----')
        print(f'Ingredient list from PIM is :\n\n{ingredient_list}')
        print('\n-----')
        print(f'Supplier technical datasheet from PIM for uid {uid} is:')
        nuxeo_path = (self.requester.cfg.filedefs['supplierdatasheet']
                      ['nuxeopath'])
        pointer = self.requester.result[0].json()['entries'][0]
        for node in nuxeo_path:
            pointer = pointer[node]
        file_url = pointer['data']
        print(file_url)
        print('-----')
        print(f'Downloading content of technical datasheet file...')
        self.resp = self.requester.session.get(file_url,
                                                stream=True)

        resp = self.resp
        print('Done!')
        print('-----')
        print(f'Parsing content of technical datasheet file...')
        blocks = (PDFDecoder.content_to_text(BytesIO(resp.content))
                  .split('\n\n'))
        idx = self.predict(blocks)
        print('Done!')
        print('-----')
        print(f'Ingredient list extracted from technical datasheet:\n')

```

```

print(blocks[idx])
print('\n-----')

def print_blocks(self):
    blocks = (PDFDecoder.content_to_text(BytesIO(self.resp.content))
              .split('\n\n'))
    for i, block in enumerate(blocks):
        print(i, ' | ', block, '\n')

class PathGetter(CustomTransformer):
    """Class that gets path for documents on disk

    This class aims to compute the path to documents, in order to
    fetch documents from the correct folder (depending on whether
    they are from train set or from ground truth)
    All these can be set at initialization, if such is not the case
    then their values is gotten from the configuration file.
    """
    def __init__(self,
                  env='prd',
                  ground_truth_uids=None,
                  train_set_path=None,
                  ground_truth_path=None,
                  path_factory=lambda x: x,
                  filename_factory=lambda x: 'FTF.pdf',
                  source_col=None,
                  target_col='path',
                  target_exists='raise'
                  ):
        self.env = env
        self.ground_truth_uids = ground_truth_uids
        self.train_set_path = train_set_path
        self.ground_truth_path = ground_truth_path
        self.path_factory = path_factory
        self.filename_factory = filename_factory
        super().__init__(source_col=source_col, target_col=target_col,
                         target_exists=target_exists)

    def fit(self, X, y=None):
        """No fit is required for this class.
        """
        super().fit(X)
        self.cfg = Config(self.env)
        if not self.train_set_path:
            self.train_set_path = os.path.join(*self.cfg.trainsetpath)
        if not self.ground_truth_path:
            self.ground_truth_path = os.path.join(*self.cfg.groundtruthpath)
        self.fitted_ = True
        return(self)

    def transform(self, X):
        """Returns the paths for the uids"""
        super().transform(X)

```

```

df = X.copy()
df[self.target_col] = None
for uid in X.index:
    if uid in self.ground_truth_uids:
        path = os.path.join(self.ground_truth_path,
                             self.path_factory(uid),
                             self.filename_factory(uid),
                             )
    else:
        path = os.path.join(self.train_set_path,
                             self.path_factory(uid),
                             self.filename_factory(uid),
                             )
    df.loc[uid, self.target_col] = path
return(df)

def get_params(self, deep=True):
    parms = super().get_params()
    parms['env'] = self.env
    parms['ground_truth_uids'] = self.ground_truth_uids
    parms['train_set_path'] = self.train_set_path
    parms['ground_truth_path'] = self.ground_truth_path
    parms['path_factory'] = self.path_factory
    parms['filename_factory'] = self.filename_factory
    return(parms)

class ContentGetter(CustomTransformer):
    """Class that fetches the content of documents on disk

    This class fetches the data from documents on disk as bytes.
    It requires a dataframe with a path column"""

    def __init__(self,
                 missing_file='raise',
                 target_exists='raise',
                 source_col='path',
                 target_col='content',
                 ):
        self.missing_file = missing_file
        super().__init__(source_col=source_col,
                        target_col=target_col,
                        target_exists=target_exists,
                        )

    def fit(self, X, y=None):
        super().fit(X)
        if self.missing_file not in {'raise', 'ignore', 'to_nan'}:
            raise ValueError(f'missing_file parameter should be set to '
                             f'\{self.missing_file}\' or \'raise\' or \'ignore\' or \'to_nan\'. Got '
                             f'\{self.missing_file}\' instead.')
        self._raise_if_no_file(X)
        self.fitted_ = True
        return(self)

```

```

def _raise_if_no_file(self, X):
    if self.missing_file == 'raise':
        mask = pd.DataFrame(index=X.index)
        mask['file_exists'] = X['path'].apply(ContentGetter.file_exists)
        if not mask['file_exists'].all():
            example_uid = mask.loc[~mask['file_exists']].index[0]
            example_path = X.loc[example_uid, 'path']
            raise RuntimeError(f'No file found for uid \"{example_uid}\" '
                               f'at path \"{example_path}\"')

def transform(self, X):
    super().transform(X)
    self._raise_if_no_file(X)
    X = X.copy()
    mask = pd.DataFrame(index=X.index)
    mask['file_exists'] = X['path'].apply(ContentGetter.file_exists)
    mask['target'] = X['path'].apply(ContentGetter.read_to_bytes)
    if self.missing_file == 'to_nan':
        idx_to_update = mask.index
    else:
        idx_to_update = mask['file_exists']
    X.loc[idx_to_update, 'content'] = mask.loc[idx_to_update, 'target']
    return(X)

    @staticmethod
def read_to_bytes(path):
    try:
        return(Path(path).read_bytes())
    except FileNotFoundError:
        return(None)

    @staticmethod
def file_exists(path):
    path = Path(path)
    return(path.is_file())

def get_params(self, deep=True):
    parms = super().get_params()
    parms['missing_file'] = self.missing_file
    return(parms)

class PDFContentParser(CustomTransformer):
    """Class that parses pdf content to text

    This class converts a file content (in the form of bytes) into text, using
    pypdf functionalities (based on pdminer.six)
    """
    def __init__(self,
        target_exists='raise',
        source_col='content',
        target_col='text',
        none_content='raise'
    ):

```

```

        self.none_content = none_content
        super().__init__(source_col=source_col,
                          target_col=target_col,
                          target_exists=target_exists,
                          )

    def fit(self, X, y=None):
        super().fit(X)
        self.fitted_ = True
        return(self)

    def transform(self, X):
        super().transform(X)
        X = X.copy()
        tran = (PDFDecoder
                 .threaded_contents_to_text(X[self.source_col],
                                           none_content=self.none_content))

        X[self.target_col] = tran
        return(X)

    def get_params(self, deep=True):
        parms = super().get_params()
        parms['none_content'] = self.none_content
        return(parms)

class BlockSplitter(CustomTransformer):
    """Class that splits texts into blocks

    This class converts a text string into blocks (a list of string), using
    the splitter function provided
    """

    def __init__(self,
                  target_exists='raise',
                  source_col='text',
                  target_col='blocks',
                  splitter_func=(lambda x: x.split('\n\n'))
                  ):
        self.splitter_func = splitter_func
        super().__init__(target_exists=target_exists,
                          source_col=source_col,
                          target_col=target_col,
                          )

    def fit(self, X, y=None):
        super().fit(X)
        self._check_splitter_callable()
        self.fitted_ = True
        return(self)

    def _check_splitter_callable(self):
        self.splitter_func('')

    def transform(self, X):

```

```

        super().transform(X)
        X = X.copy()
        blocks = (PDFDecoder
                   .threaded_texts_to_blocks(X[self.source_col],
                                             split_func=self.splitter_func,
                                             return_type='as_list',
                                             ))

        X[self.target_col] = blocks
        return(X)

def get_params(self, deep=True):
    parms = super().get_params()
    parms['splitter_func'] = self.splitter_func
    return(parms)

class SimilaritySelector(CustomTransformer):
    """Class that select the most similar block from a block list

    This class provides fonctionnalities to fit an estimator on a topic
    specific vocabulary, and to retrieve the best candidate amongst these
    blocks.

    It can append a new column to an input pandas DataFrame with the best
    candidate.
    """
    def __init__(self,
                  source_col='blocks',
                  target_col='predicted',
                  target_exists='raise',
                  fit_col='Ingrédients',
                  count_vect_kwargs=dict(),
                  ):
        super().__init__(source_col=source_col,
                          target_col=target_col,
                          target_exists=target_exists,
                          )

        self.fit_col = fit_col
        self.count_vect_kwargs = count_vect_kwargs

    def fit(self, X, y=None):
        super().fit(X)
        self.count_vect = CountVectorizer(self.count_vect_kwargs)
        self.count_vect.fit(X[self.fit_col].fillna(''))
        self.source_count_vect = CountVectorizer()
        self.fitted_ = True
        return(self)

    def predict(self, block_list):
        check_is_fitted(self)
        try:
            check_is_fitted(self.source_count_vect)
        except NotFittedError:
            self.source_count_vect.fit(block_list)
        X_norms = sparse_norm(self.source_count_vect.transform(block_list),

```

```

        axis=1)
X_against_ingred_voc = self.count_vect.transform(block_list)
X_dot_ingred = np.array(X_against_ingred_voc.sum(axis=1)).squeeze()
pseudo_cosine_sim = np.divide(X_dot_ingred,
                               X_norms,
                               out=np.zeros(X_norms.shape),
                               where=X_norms != 0)

self.similarity_ = pseudo_cosine_sim
return(block_list[np.argmax(pseudo_cosine_sim)])

def transform(self, X):
    super().transform(X)
    X = X.copy()
    block_texts = (text for block in X[self.source_col] for text in block)
    self.source_count_vect.fit(block_texts)
    X[self.target_col] = X[self.source_col].apply(self.predict)
    return(X)

```